LegatorOCR – Benutzerhandbuch

Ausgabe 0.2.0-pre.43 (Testversion). Text in Arbeit, auf Rumänisch verfasst.

1. Was LegatorOCR ist

LegatorOCR verwandelt Scans oder Fotos von Seiten in ein sauberes PDF mit durchsuchbarem Text. Es löst dasselbe Problem wie ScanTailor (Seiten trennen, geraderichten, beschneiden, bereinigen), fügt aber PDF-Export und OCR hinzu. Es ist in Rust geschrieben, mit eigenem Code, wobei jede Stufe eine Lehrbuchtechnik ist. Es läuft lokal, ohne Konto und ohne dass die Seiten ins Internet gesendet werden. Lizenz: MIT.

Es gibt zwei Arbeitsweisen, mit denselben Engines darunter:

- **Die grafische Oberfläche** (`legatorocr-gui`): Sie fügen Seiten hinzu, sehen Original und Ergebnis nebeneinander, korrigieren Seite für Seite und exportieren.
- **Die Kommandozeile** (`legatorocr`): für große Stapel, für die Automatisierung und für Optionen, die die Oberfläche nicht zeigt.

Was es leistet

- trennt Doppelseiten-Bögen in zwei Seiten, richtet schiefe Seiten gerade und beschneidet die Ränder;
- bereinigt Hintergrund, Flecken, Lochungen, Finger am Rand und Formularlinien;
- schreibt PDF (einschließlich PDF/A zur Archivierung) oder Bilder, mit OCR auf Rumänisch und in 7 weiteren Sprachen;
- erzeugt auch einfachen Text (`.txt`) und hOCR und kann das PDF signieren oder mit einem Zeitstempel versehen.

Was es nicht leistet (oder nicht nachgewiesen wurde)

- Es ist eine Testversion (0.2.0-pre.43). Sie wurde vom Autor und seinem Assistenten nur unter Linux ausgeführt; **Windows, macOS und arm64-Prozessoren wurden von Menschen nicht ausprobiert**.
- Die OCR-Genauigkeit wurde an 8 guten Seiten einer einzigen rumänischen Zeitschrift gemessen, gegenüber einem Referenztext, der von einem anderen Programm erzeugt und nicht von Menschen korrigiert wurde. Betrachten Sie sie nicht als Garantie für andere Druckarten.
- Die OCR kann Fehler machen: Prüfen Sie wichtige Seiten stichprobenartig.

2. Installation und erster Start

Laden Sie das Archiv für Ihr System von der Seite der Releases des Repositorys `chiuta/LegatorOCR` herunter. Jedes Archiv hat eine Datei `.sha256` zur Überprüfung.

System	Datei	Hinweise
Linux x86-64 oder ARM64	`.tar.gz`	benötigt OpenGL 2+ und X11 oder Wayland
Windows x86-64	`.zip`	benötigt OpenGL 2+; in einfachen RDP-Sitzungen kann es fehlen
macOS Apple-Silicon oder Intel	`.zip` mit `LegatorOCR.app`	**nicht signiert**: beim ersten Start Rechtsklick → Open, oder `xattr -dr com.apple.quarantine LegatorOCR.app`

Sie können auch aus dem Quellcode bauen: `cargo build --release` (erfordert Rust 1.95 oder neuer).

OCR

Das Programm hat eine eigene OCR-Engine, die ohne Installation funktioniert. Optional können Sie Tesseract installieren, ein separates Programm, das LegatorOCR automatisch verwendet, wenn es vorhanden ist und die angeforderte Sprache hat:

- Linux (Debian/Ubuntu): `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS: `brew install tesseract tesseract-lang`
- Windows: `winget install UB-Mannheim.TesseractOCR` und es zum `PATH` hinzufügen

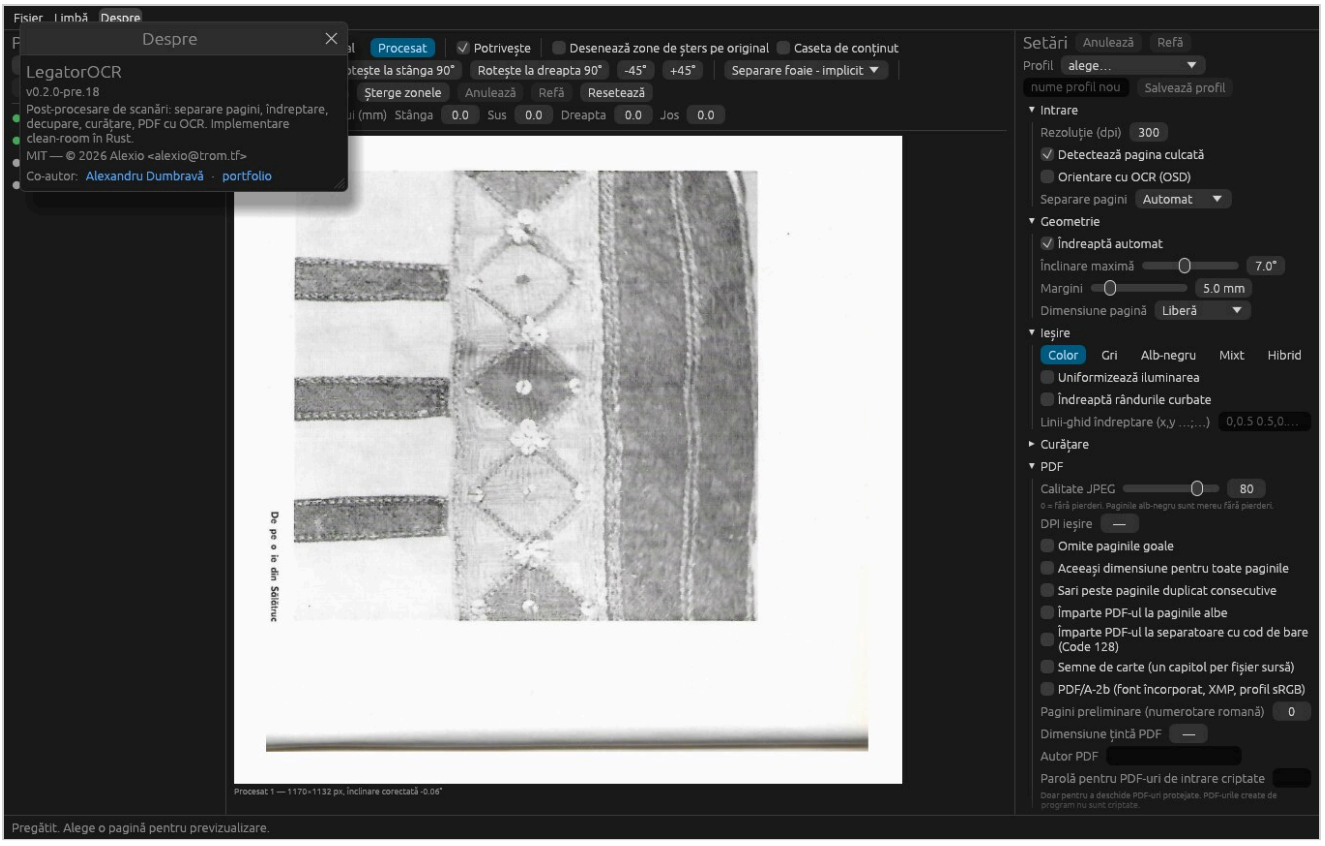
Das rumänische Modell aus den Paketen `apt` und `brew` ist die kleine Variante („fast“). Die Variante „best“ wird manuell heruntergeladen und mit `--tessdata DIR` angegeben. Welche Ihre Seiten besser liest, wurde nicht gemessen.

Die Installation prüfen

Führen Sie `legatorocr --doctor` aus. Es zeigt die Version, die native OCR-Engine, Tesseract und die Sprachmodelle an, danach Hilfswerkzeuge (`pdftoppm`, `gs`, `qpdf`, `mutool`). Das Ergebnis „missing“ bei einem optionalen Werkzeug ist kein Fehler; die Meldung darunter sagt, ob es gebraucht wird. Wenn etwas nicht funktioniert, kopieren Sie die gesamte Ausgabe des Befehls in einen Bericht (siehe Abschnitt 10).

```
$ legatorocr --doctor
[ok     ] legatorocr                        0.2.0-pre.19
[ok     ] native OCR engine                 built in
[ok     ] tesseract                         tesseract 5.3.4
[ok     ] tesseract model ro (Romanian)     installed
[ok     ] tesseract model en (English)      installed
[ok     ] tesseract model fr (French)       installed
[ok     ] tesseract model it (Italian)      installed
[ok     ] tesseract model es (Spanish)      installed
[ok     ] tesseract model pt (Portuguese)   installed
[ok     ] tesseract model de (German)       installed
[ok     ] tesseract model hu (Hungarian)    installed
[ok     ] pdftoppm                          pdftoppm
[missing] mutool                            not found
          -> optional: alternative renderer for those cases
[ok     ] gs                                gs
[ok     ] qpdf                              qpdf
14 check(s) ok, 1 missing. Missing helpers are optional unless a hint says otherwise.
```

Die Ausgabe des Befehls legatorocr --doctor (pre.20, Linux, in einem echten Terminal; ebenso alle Terminal-Screenshots im Handbuch, mit xterm aufgenommen): „missing“ bei mutool ist ein optionales Werkzeug, kein Fehler.



Das Menü Über zeigt die installierte Version (hier 0.2.0-pre.18). Screenshot aus dem Build pre.18 unter Linux, Oberfläche auf Rumänisch.

3. Der Arbeitsablauf, Schritt für Schritt

Für jede Seite durchläuft das Programm die folgenden Stufen in dieser Reihenfolge. Die Analyse erfolgt auf einer Kopie von etwa 150 dpi, und das Ergebnis wird anschließend auf den Scan in seiner vollen Auflösung angewendet.

1. **Orientierung.** Liegende Seiten (Vierteldrehung) werden anhand der Buchstaben der Seite erkannt: Eine Seite mit Bildern oder mit wenigen Wörtern wird von diesem Test nicht gedreht. Für die genaue Richtung kann Tesseract (OSD) oder die manuelle Drehung verwendet werden.

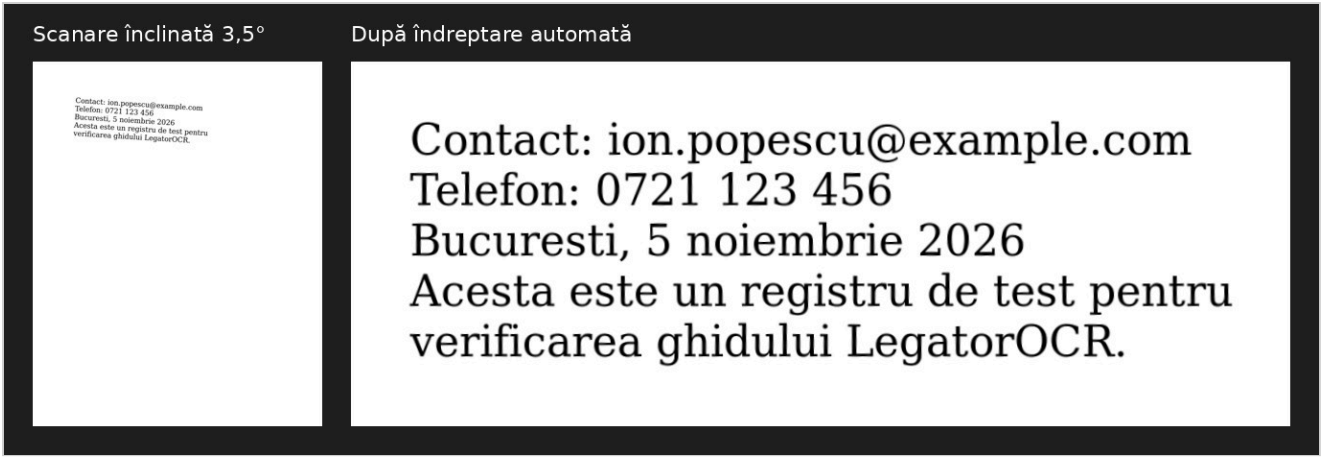
2. **Blatt trennen.** Ein Querformat-Blatt mit zwei Seiten wird in der Mitte geschnitten, am leeren Band in der Mitte. Das kann automatisch erfolgen, in der Mitte oder ausgeschaltet sein.

3. **Geraderichten.** Der Neigungswinkel wird aus den Textzeilen geschätzt, und die Seite wird zurückgedreht. Der Winkel kann manuell festgelegt werden.

4. **Inhaltsrahmen.** Der Bereich mit Text und Bildern wird gefunden; Scannerschatten und Staub werden ignoriert. Alles außerhalb wird in der Papierfarbe neu übermalt.

5. **Ränder und Größe.** Ränder in Millimetern, optional eine feste Seitengröße oder dieselbe Größe für das ganze Buch.

6. **Gekrümmte Zeilen begradigen** (optional). Für volle Buchseiten mit zum Buchrücken hin gekrümmten Zeilen.
7. **Beleuchtung** (optional). Gleicht den ungleichmäßigen Hintergrund aus.
8. **Bereinigen und Binarisieren.** Entfernt Flecken, Lochungen, Finger, Linien; danach Schwarzweiß, Grau, Farbe, gemischt oder hybrid.
9. **PDF und OCR.** Das PDF (oder die Bilder) wird geschrieben und, wenn angehakt, die Textebene.



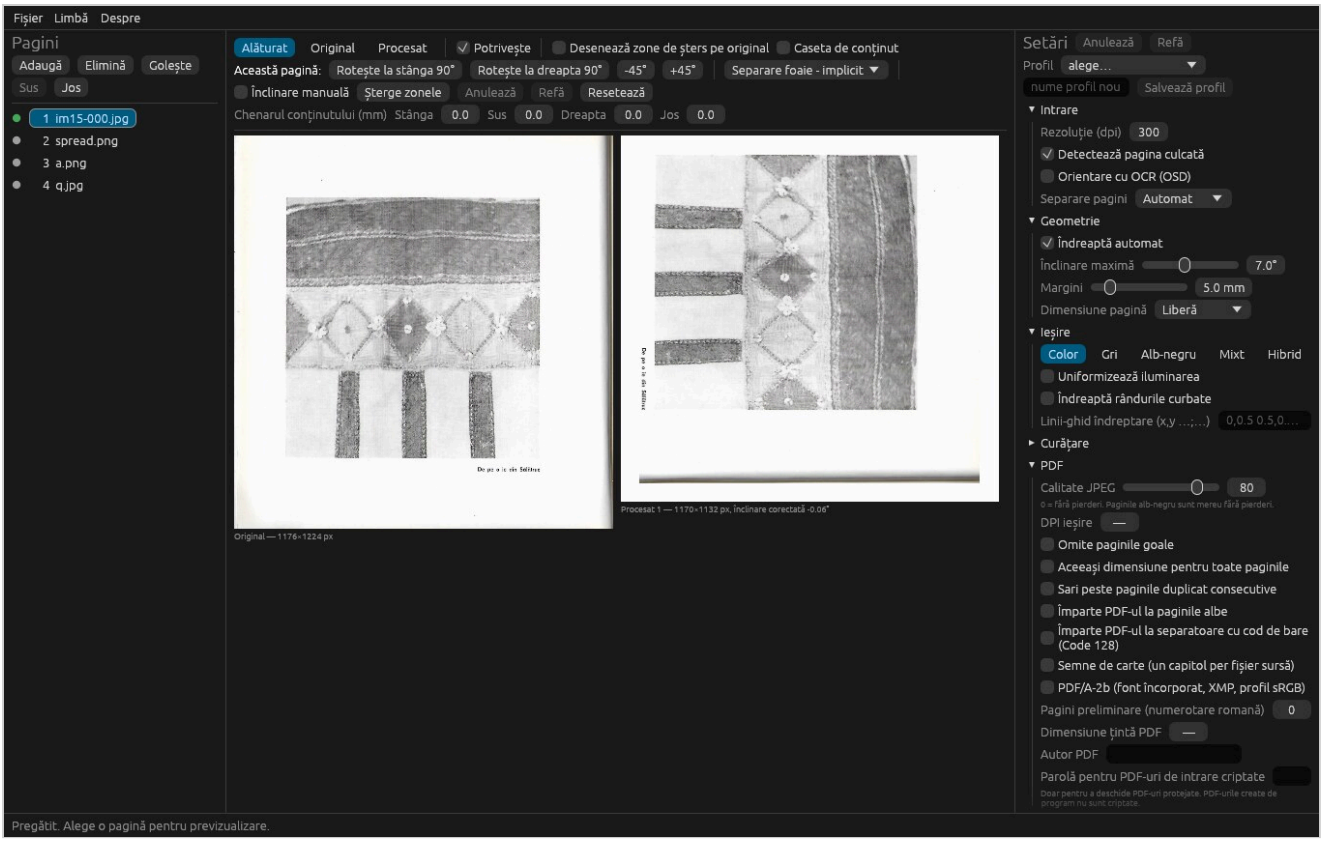
Automatisches Geraderichten: ein um 3,5° geneigter Scan (von mir erzeugtes Testblatt) und das Ergebnis; das Programm hat -3,50° gemessen.

Arbeitsregeln, die Zeit sparen

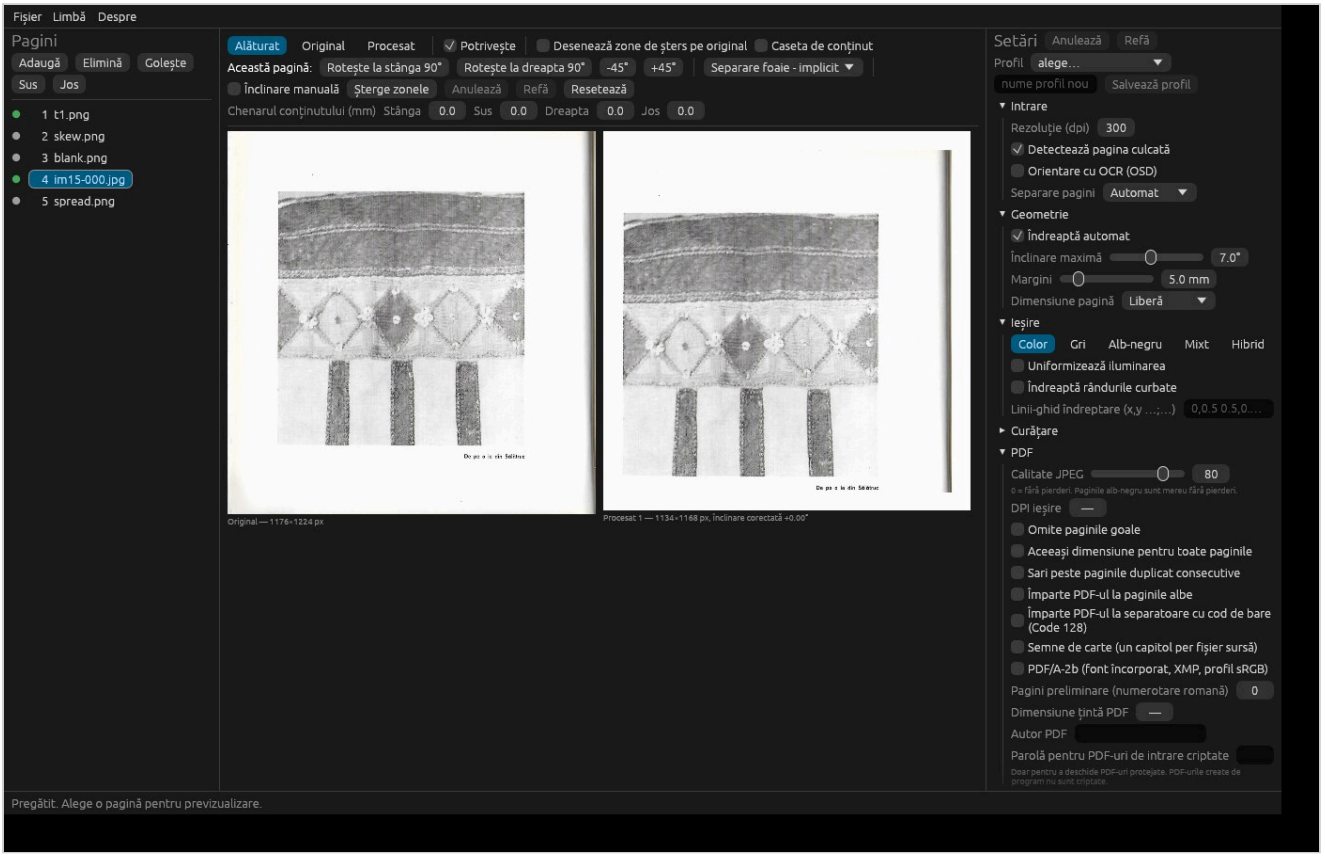
- Legen Sie zuerst die richtige **Auflösung** fest (meist 300 dpi für Text). Das Programm liest sie aus dem Bild, wenn sie zwischen 150 und 1200 liegt; andernfalls nimmt es 300 an.
- Wählen Sie ein zum Material passendes **Profil** (Abschnitt 6), bevor Sie an einzelnen Einstellungen drehen.
- Verarbeiten Sie 10–20 Seiten als Probe, prüfen Sie das Ergebnis und starten Sie dann den großen Stapel.
- Die Oberfläche markiert Seiten „Zu prüfen“ (leere Seite, Schräglage am Grenzwert, nichts gefunden, Inhalt am Rand klebend). Gehen Sie sie mit der Schaltfläche „Nächste“ durch.

4. Die grafische Oberfläche

Das Fenster hat drei Bereiche: die Seitenliste links, die Vorschau in der Mitte und die Einstellungen rechts. Das Menü **Datei** enthält „Bilder hinzufügen“, „Ordner hinzufügen“, „Projekt öffnen“, „Projekt speichern“, „PDF exportieren“ und „Bilder exportieren“. Die Sprache der Oberfläche (8 Sprachen) ändern Sie im Menü **Sprache**.



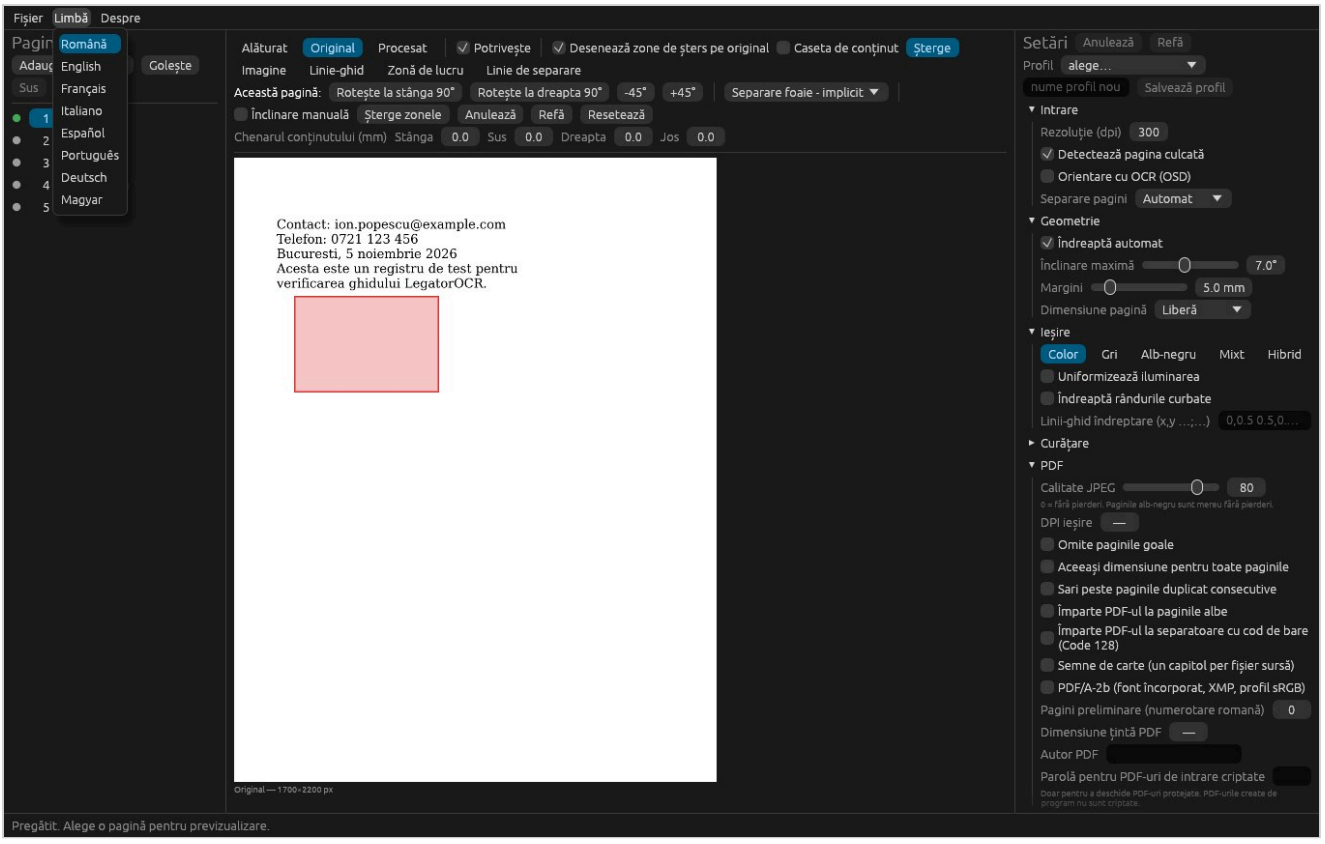
Das Hauptfenster: die Seitenliste links, das Original und die verarbeitete Seite in der Mitte, die Einstellungen rechts. Die Seite im Beispiel ist ein Foto ohne Text, daher hat die Erkennung liegender Seiten sie in pre.18 fälschlich gedreht (in pre.19 behoben, siehe unten). Screenshot pre.18 unter Linux.



Dieselbe Seite in pre.19, mit angehaktem „Gedrehte Seiten erkennen“: Sie wird nicht mehr gedreht (verarbeitet 1134×1168 px, Schräglage +0,00°). Screenshot pre.19 unter Linux.

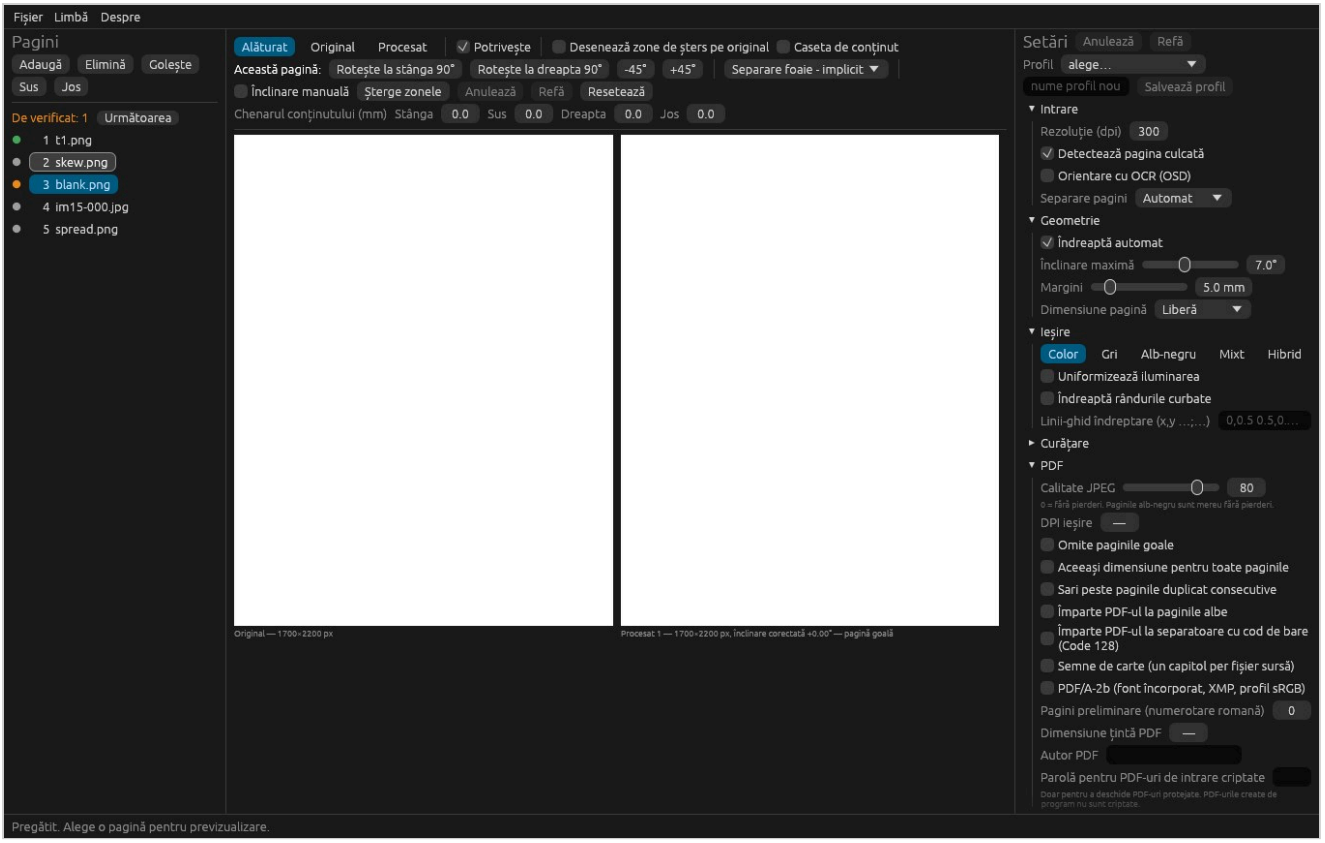


Das Menü Datei: Bilder oder einen Ordner hinzufügen, Projekt öffnen und speichern, PDF oder Bilder exportieren.



Das Menü Sprache: die acht Sprachen der Oberfläche (Rumänisch, Englisch, Französisch, Italienisch, Spanisch, Portugiesisch, Deutsch, Ungarisch).

Die Seitenliste

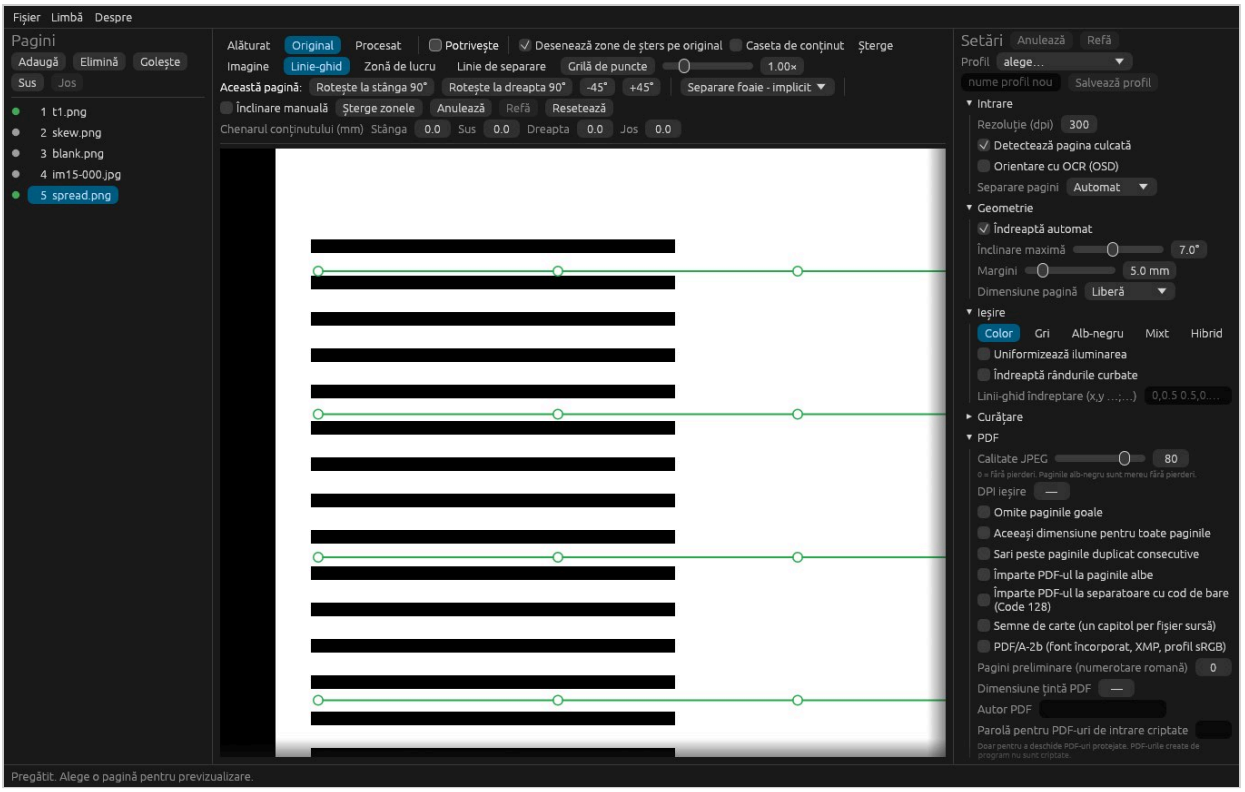


Eine komplett weiße Seite wird automatisch markiert: ein orangefarbener Punkt in der Liste und das Feld „Zu prüfen: 1“ mit der Schaltfläche „Nächste“.

Ziehen Sie Bilder, PDFs, Archive oder einen Ordner hinein, oder drücken Sie „Hinzufügen“. Die Schaltflächen Nach oben/Nach unten ändern die Reihenfolge, „Entfernen“ nimmt die gewählte Seite heraus, „Leeren“ nimmt alles heraus. Die Reihenfolge in der Liste ist die Reihenfolge im PDF.

Die Vorschau

- **Nebeneinander / Original / Bearbeitet** wählt, was Sie sehen. Die Zonen werden auf dem *Original* gezeichnet; der Inhaltsrahmen wird auf *Bearbeitet* korrigiert.
- **Einpassen** vergrößert oder verkleinert das Bild, damit es passt. Der Zoomregler (0,2×–4×) erscheint nur, wenn *Einpassen* nicht angehakt ist.

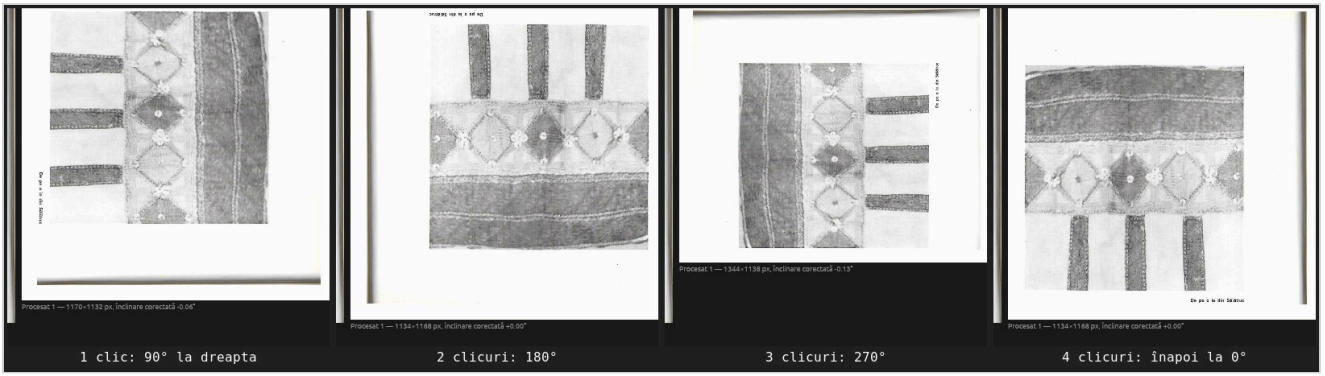


Bei nicht angehaktem „Einpassen“ erscheint der Zoomregler (hier 1,00×).

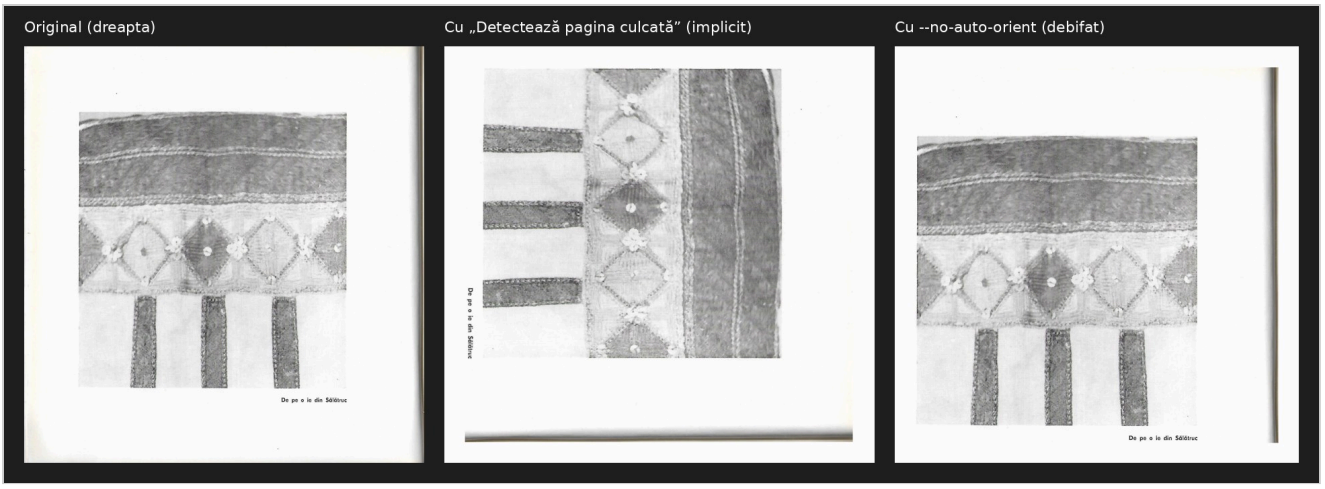
Die Leiste „Diese Seite“

Hier korrigieren Sie nur die gewählte Seite: Drehung nach links oder rechts um 90°, Schritte von ±45°, manuelle Schräglage, Modus der Blatttrennung (Standard, automatisch, in der Mitte, aus), Inhaltsrahmen in Millimetern (links, oben, rechts, unten; positive Werte vergrößern ihn) und „Zurücksetzen“. **Rückgängig** und **Wiederholen** (Ctrl+Z, Ctrl+Y) gelten für alle diese Befehle, nicht nur für Zonen.

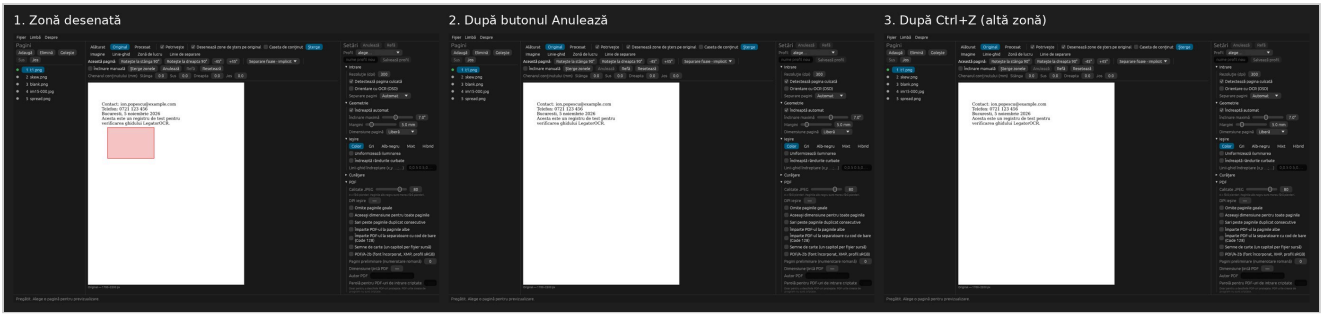
Manuelles Drehen sperrt die automatische Orientierung (seit pre.18): Nachdem Sie eine Drehtaste oder ±45° gedrückt haben, wird die Seite weder von der Erkennung liegender Seiten noch von OSD gedreht, nicht einmal bei 0°. „Zurücksetzen“ gibt ihr die automatische Orientierung zurück. Wenn eine Seite mit Bildern von Anfang an falsch gedreht wird, drücken Sie die Drehung viermal (oder haken Sie in den Einstellungen unter Eingabe „Ausrichtung per OCR (OSD)“ und „Gedrehte Seiten erkennen“ ab).



Vier Klicks hintereinander auf „90° nach rechts drehen“: 90°, 180°, 270°, dann zurück auf 0°, ohne Sprünge. Screenshot pre.18 unter Linux. Unter Windows 11 konnte ich es nicht prüfen.



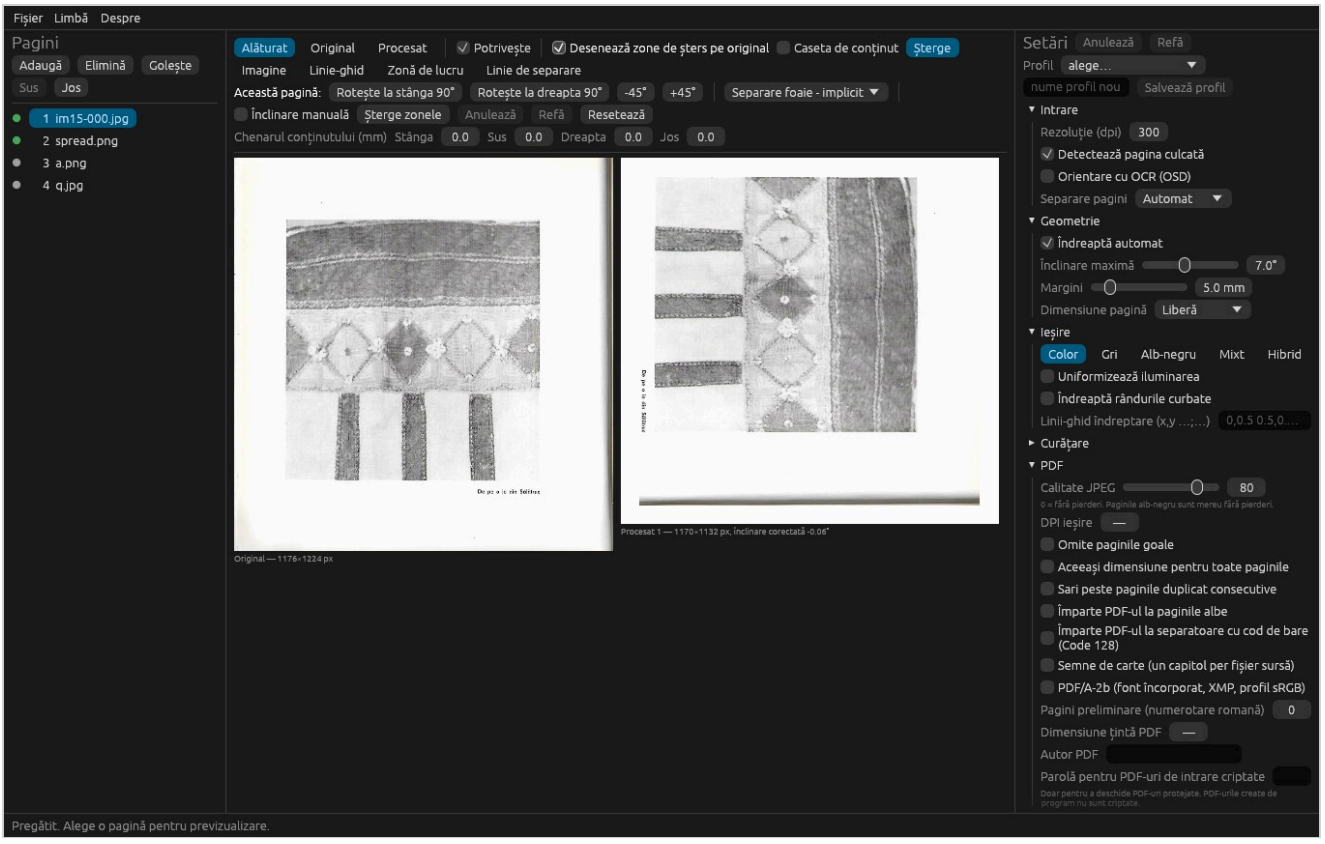
Dieselbe Seite (Seite 15 aus dem PDF des Testers) und dieselben Einstellungen, außer der Erkennung: In pre.18 drehte das Programm sie bei angehaktem „Gedrehte Seiten erkennen“ (Standard) um 90°, obwohl das Original gerade ist (ab pre.19–20 dreht es sie nicht mehr); mit --no-auto-orient (oder abgehakt in den Einstellungen) kommt sie gerade heraus. In der Kommandozeile geprüft; im Fenster habe ich die Drehung in pre.18 und ihr Fehlen in pre.19 gesehen.



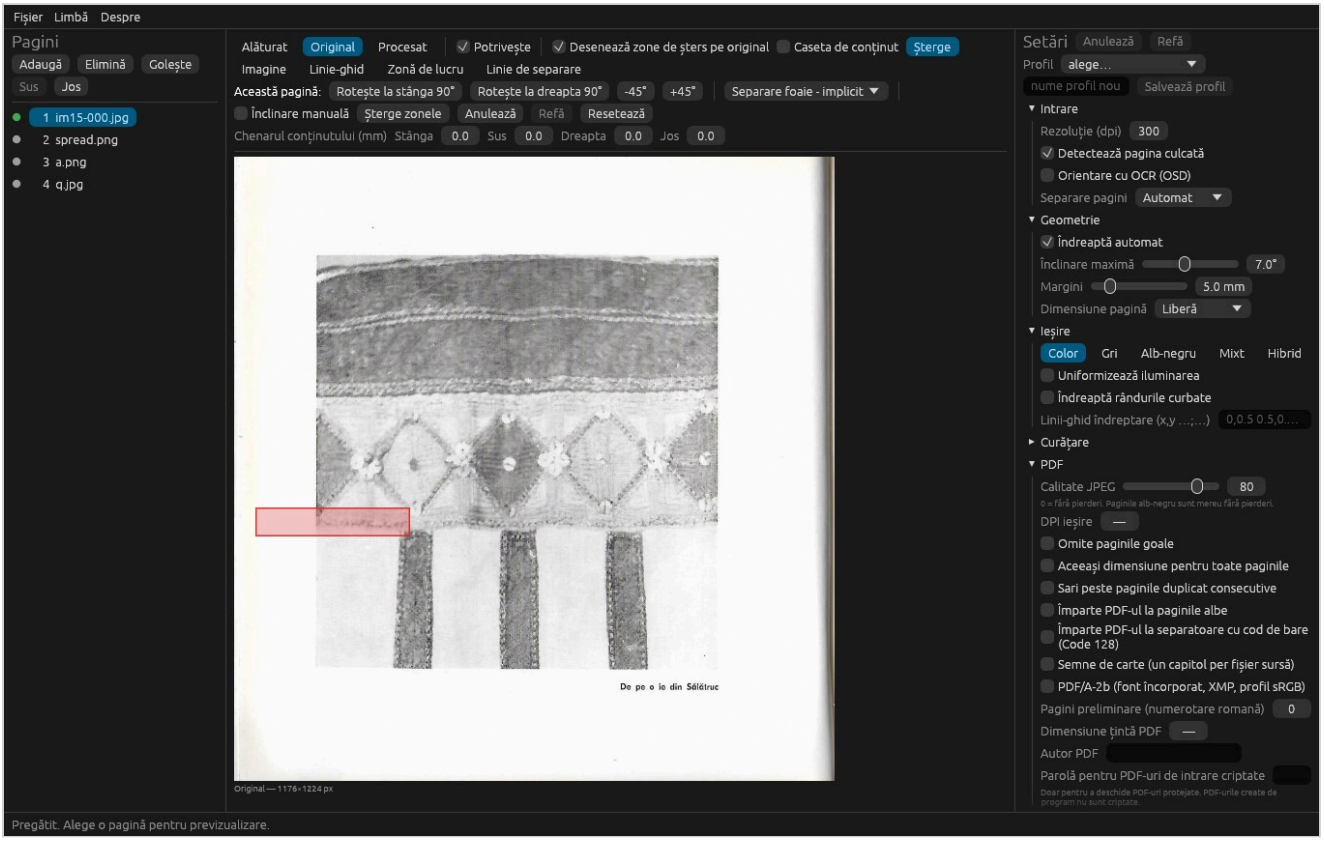
Rückgängig (die Schaltfläche) und Ctrl+Z (bei Fenster im Vordergrund) entfernen die zuletzt gezeichnete Zone. Im Fenster geprüft.

Zonen, Hilfslinien und der Inhaltsrahmen

Haken Sie „Zonen zum Löschen auf dem Original zeichnen“ an; es erscheinen fünf Zeichenarten (Löschen, Bild, Hilfslinie, Arbeitsbereich, Schnittlinie):

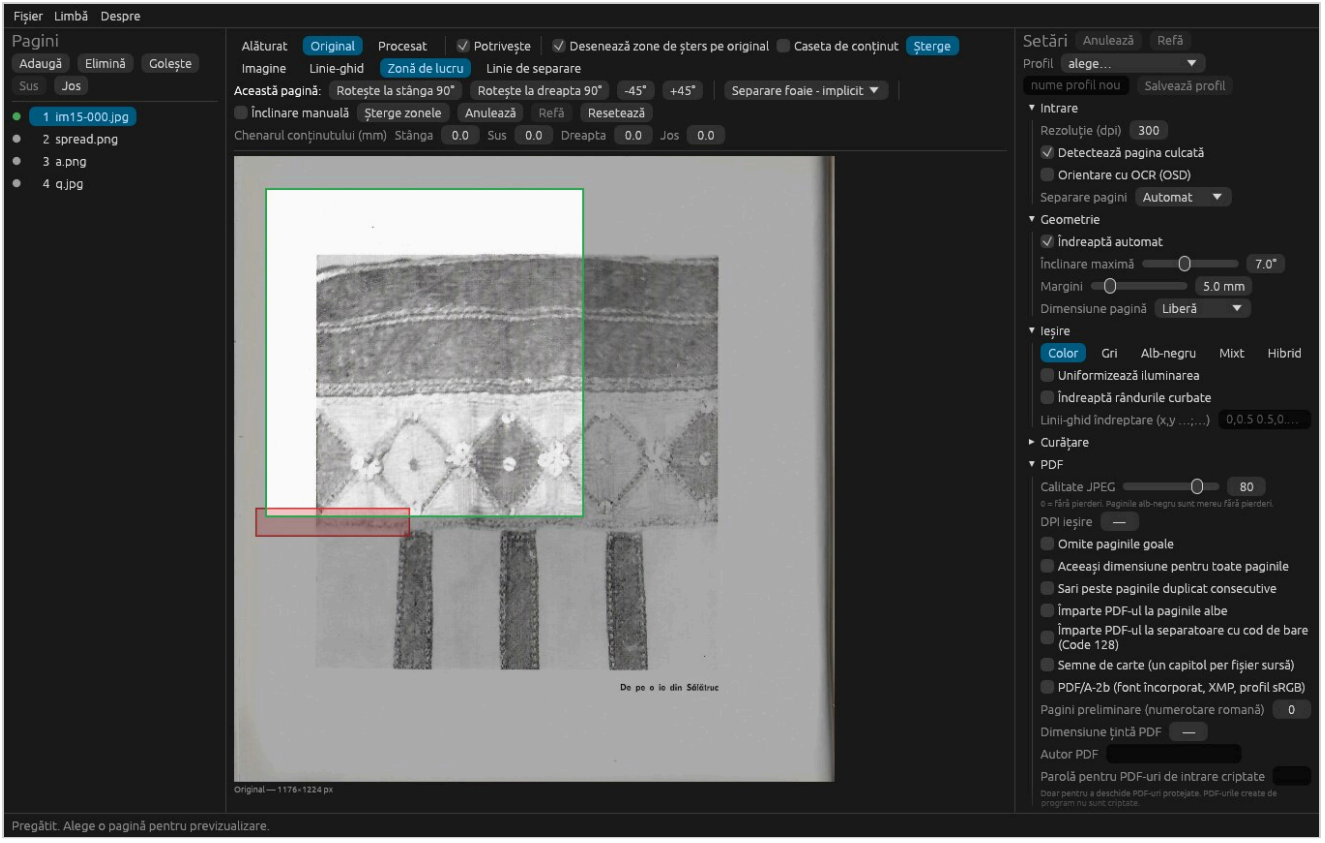


Bei angehaktem „Zonen zum Löschen auf dem Original zeichnen“ erscheinen die Zonenarten: Bild, Hilfslinie, Arbeitsbereich, Schnittlinie (und Löschen, die Standardart).

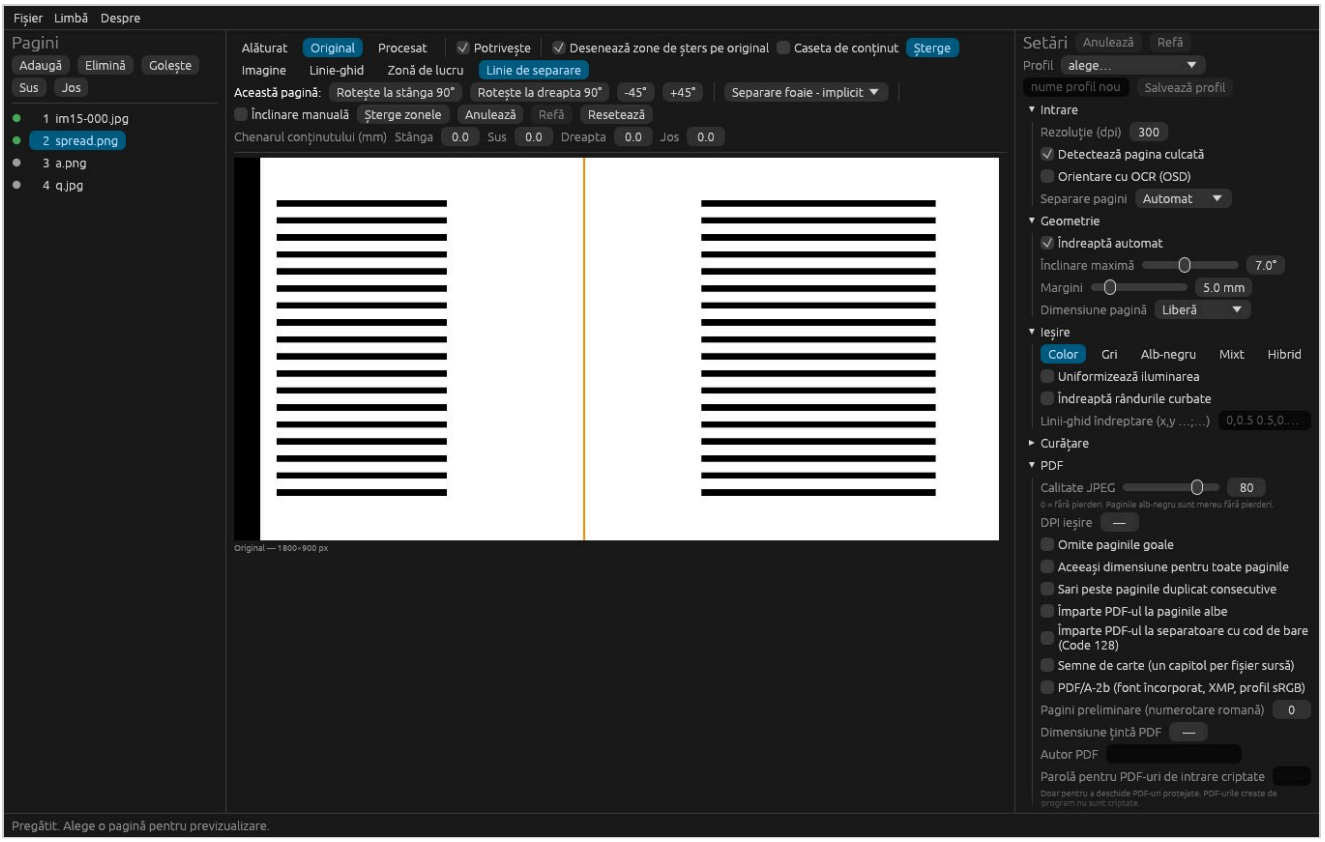


Eine Löschzone (rot), mit der Maus auf dem Original aufgezogen, in der Ansicht Original.

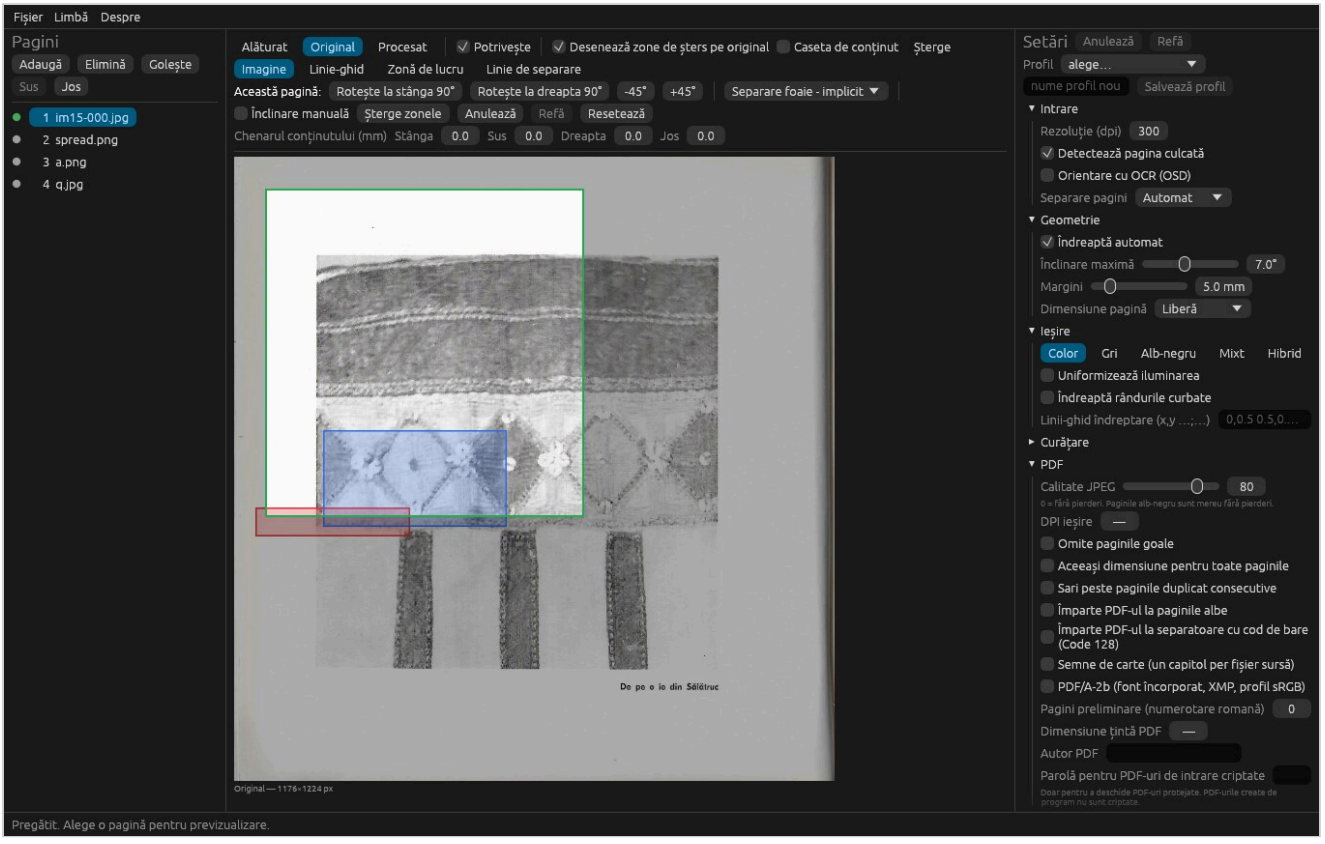
Art	So verwenden Sie sie	Wofür sie dient
Löschen	Ziehen Sie ein Rechteck auf dem Original. Rechtsklick darauf löscht es. Ziehen Sie an einer Ecke, um die Größe zu ändern.	Fleck, Stempel, jemandes Notiz, der Rand mit Schatten
Bild	Wie bei „Löschen“.	Sagt dem Programm, dass der Bereich ein Bild ist, kein Text (bleibt im Modus Gemischt farbig)
Hilfslinie	Ziehen Sie frei entlang einer gekrümmten Zeile. Ziehen Sie an einem Knoten, um ihn zu verschieben; Doppelklick auf die Linie fügt einen Knoten hinzu, Doppelklick auf einen Knoten löscht ihn; Rechtsklick auf die Linie löscht sie.	Richtet die Seite nach den Zeilen aus, die Sie nachgezogen haben



Der Arbeitsbereich (grüner Rahmen): Alles außerhalb wird entfernt, und der verbleibende Bereich ist auf der verarbeiteten Seite zu sehen. Es gibt außerdem eine Löschzone (rot).



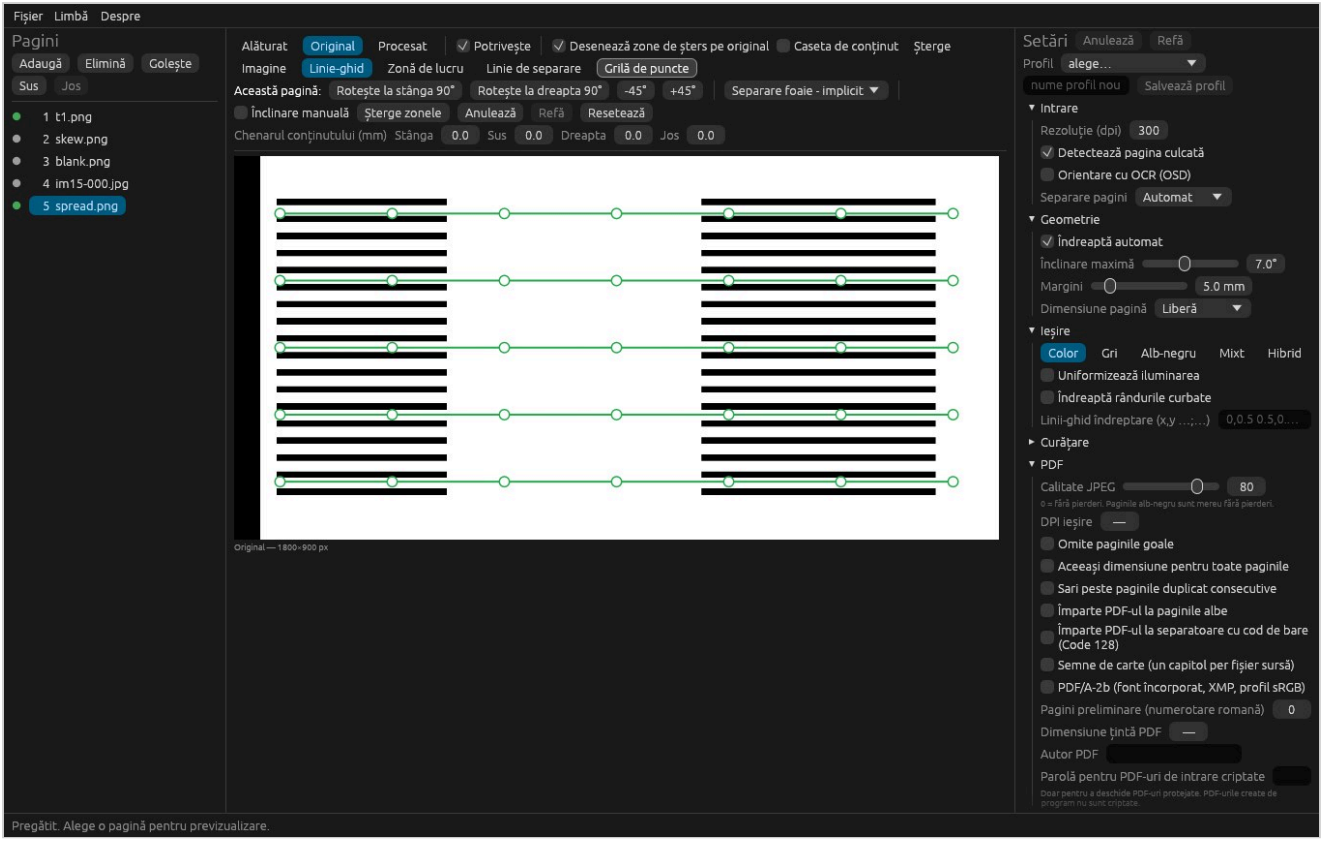
Die Schnittlinie (orange), mit der Maus auf einem Doppelblatt verschoben. Das Beispiel ist ein synthetisches Testblatt mit Linien statt Text.



Eine Bildzone (blau), auf dem Original gezeichnet. Im Modus Farbe ändert sie nichts; die Wirkung zeigt sich im Modus Gemischt (nächste Abbildung).



Dieselbe Seite und dieselbe Bildzone (blau): Im Modus Gemischt bleibt die Zone grau (links), im Modus Schwarzweiß wird alles schwarzweiß (rechts). Die Seite erscheint durch die Erkennung liegender Seiten um 90° gedreht (siehe oben).



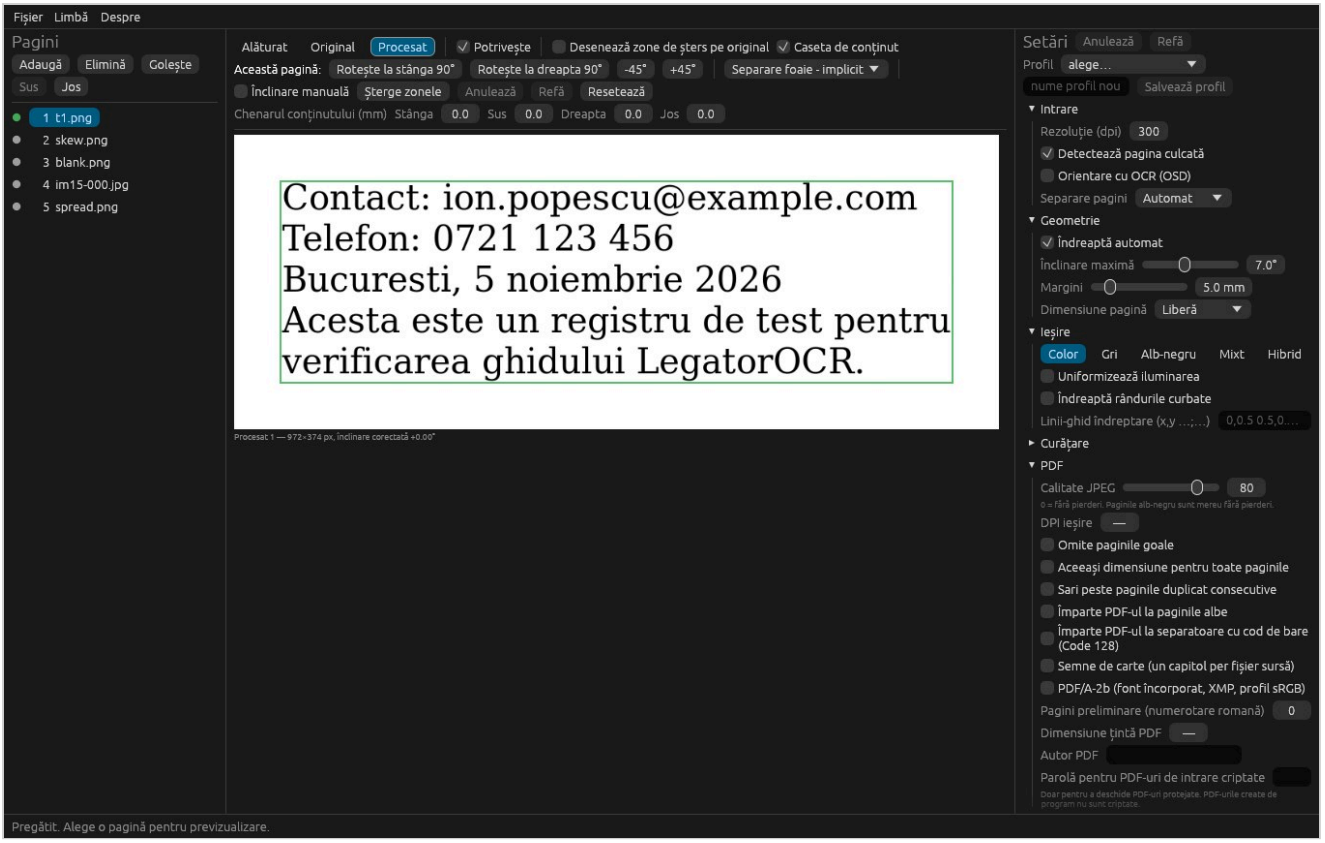
„Punktraster“ bei Hilfslinie: 5 Linien mit je 7 Punkten, über den Textzeilen.

Punktraster (bei *Hilfslinie*) fügt 5 Linien mit je 7 Punkten hinzu, deren Punkte Sie auf die Textzeilen ziehen. Ein zweiter Klick auf die Schaltfläche fügt dasselbe Raster nicht ein zweites Mal hinzu. Wenn Sie bereits Punkte verschoben haben, wird ein neues Raster zusätzlich zum verschobenen hinzugefügt.

Arbeitsbereich (seit der Ausgabe pre.18): Sie ziehen ein Rechteck auf dem Original; alles außerhalb wird vor jeder Messung in der Papierfarbe übermalt, ein dunkler Rand oder die Nachbarseite spielen also keine Rolle mehr. Rechtsklick auf das Original entfernt ihn. In der Kommandozeile: `--work-area X,Y,L,H` (Millimeter).

Schnittlinie (seit der Ausgabe pre.18): Mit Klick oder Ziehen auf dem Original verschieben Sie die senkrechte orangefarbene Linie; das Doppelblatt wird dort geschnitten, nicht in der Mitte oder am Bund. Ab pre.21 funktioniert das bei jeder Drehung; bei um 90° oder 270° gedrehten Blättern schneidet die Linie waagerecht, und die Seiten kommen untereinander heraus (die linke Seite des Originals zuerst). Rechtsklick entfernt sie. In der Kommandozeile: `--cut-at 0.45`.

Inhaltsrahmen (das gleichnamige Häkchen) zeigt auf der verarbeiteten Seite einen grünen Rahmen an. Sie ziehen an den Seiten, um den beibehaltenen Bereich zu erweitern oder zu verengen. Bei einem in zwei Seiten geschnittenen Blatt ändert sich nur die Seite, auf der man den Rahmen zieht.



Der Inhaltsrahmen (grüner Rahmen) auf der verarbeiteten Seite.

Verzogene Seiten, schräger Schnitt und Einstellungen pro Seite

Drei Hilfen für von Hand fotografierte Blätter:

- **Schräge Schnittlinie.** Mit „Löschzonen auf dem Original zeichnen“ und dem Typ Schnittlinie neigt der Regler „Neigung der Linie“ (−20° bis 20°) die Linie; jede Seite behält ihre Seite der schrägen Linie, die andere Seite wird mit der Papierfarbe übermalt. Rechtsklick auf die Linie löscht sie und setzt die Neigung auf null. Auf der Kommandozeile: `--cut-angle GRAD`.
- **Trapezkorrektur.** Zwei Regler in der Leiste „Diese Seite“ („Trapez oben–unten“, „Trapez links–rechts“, ±30 %) richten ein schräg fotografiertes Blatt vor dem Schnitt gerade. Die Schaltfläche **Auto-Trapez** (nach dem Teilen der Seiten) misst jede Seite — Neigung der Textzeilen und Textbreite oben und unten — und merkt sich eine Korrektur nur für diese Seite. Sie ist absichtlich vorsichtig: bei zu wenigen Zeilen oder widersprüchlichen Messungen bleibt die Seite unverändert. Das Ergebnis prüfen, Rückgängig griffbereit. Die

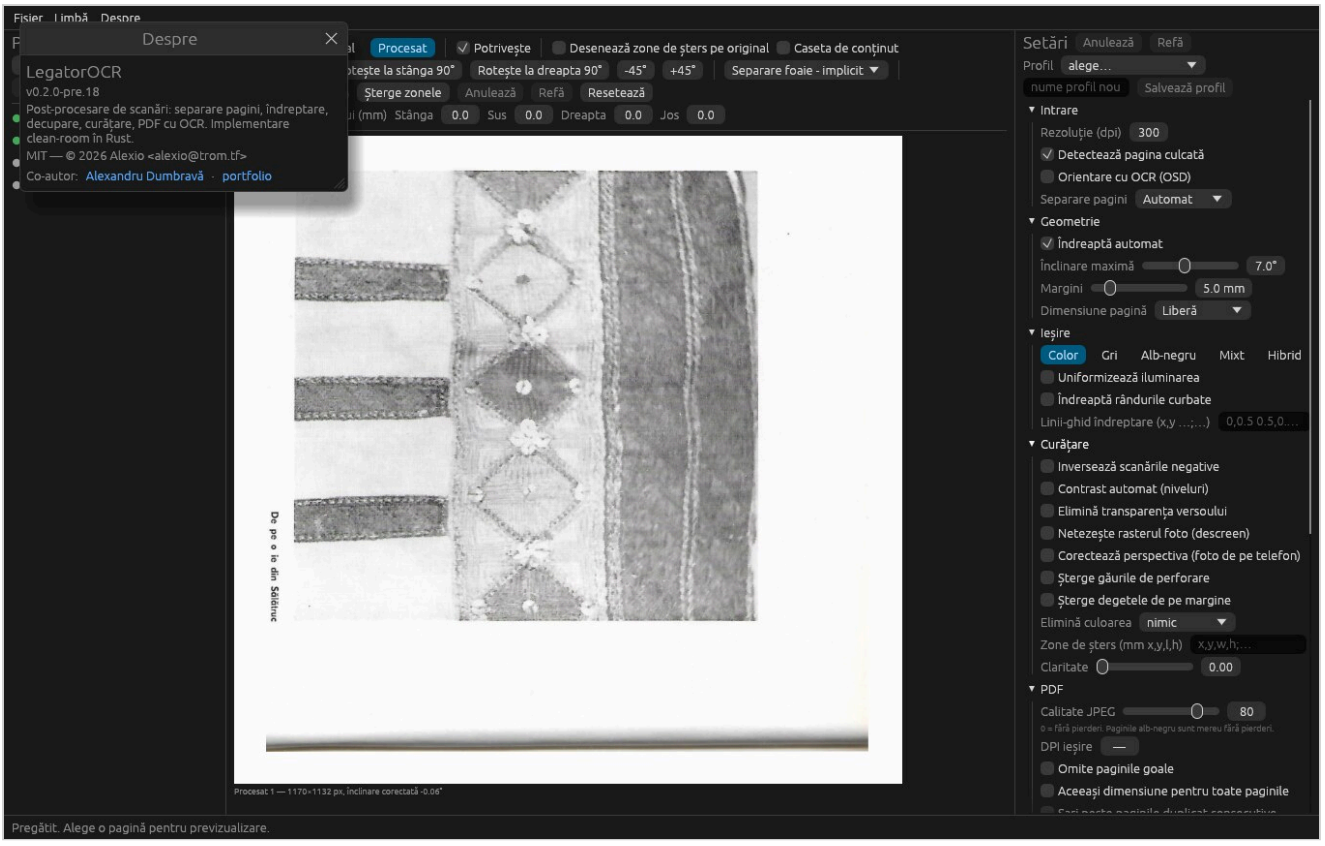
Schaltflächen −45°/+45° bleiben. Auf der Kommandozeile: `--keystone-v` und `--keystone-h` (Prozent).

- **Einstellungen pro Seite.** „Einstellungen für: Alle Seiten / Nur diese Seite“ über Ausgabe und Bereinigung wendet Ausgabemodus, Schwelle, Fleckenentfernung und die übrigen Bereinigungseinstellungen auf eine einzelne Seite eines geschnittenen Blatts an; der grüne Inhaltsrahmen ändert nur die Seite, auf der er gezogen wird. In einem Projekt: `page1.SCHLÜSSEL = WERT` / `page2.SCHLÜSSEL = WERT` unter [sheet]. Ein Klick auf eine verarbeitete Seite wählt sie aus (blauer Rahmen): Ausgabemodus (Grau, Schwarzweiß, Gemischt), Bereinigung, Trapezkorrektur, der grüne Rahmen und die OCR-Stifte wirken dann nur auf diese Seite. Gezeichnete OCR-Zonen bleiben bei dieser Seite (`page1.page_ocr_zones`, `page_ocr_ignore`).

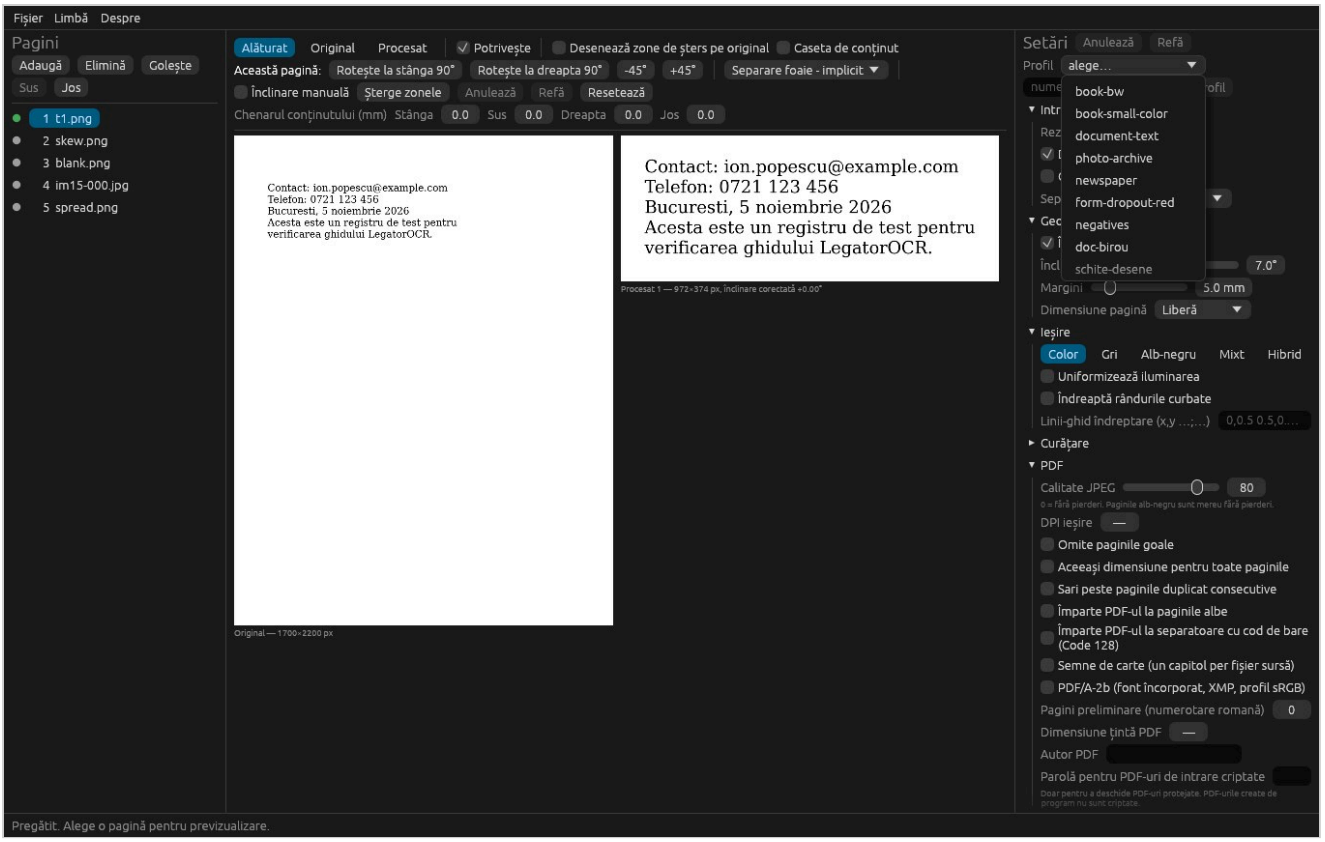
Die Seitenformate umfassen jetzt A2–A6, B3–B6, Letter, Legal und Tabloid (`--page-size` kennt dieselben Namen). OCR-Stifte auf verarbeiteten Seiten: grün (OCR-Zone), rot (ignorierter Bereich), violett (Tabelle, als ein Block zeilenweise gelesen; `--ocr-zone X,Y,W,H#table`).

Die Einstellungen rechts

Sie sind nach Abschnitten gruppiert: Eingabe, Geometrie, Ausgabe, Bereinigung, PDF, OCR, dazu die Profile. Abschnitt 6 erklärt, was jede bewirkt.



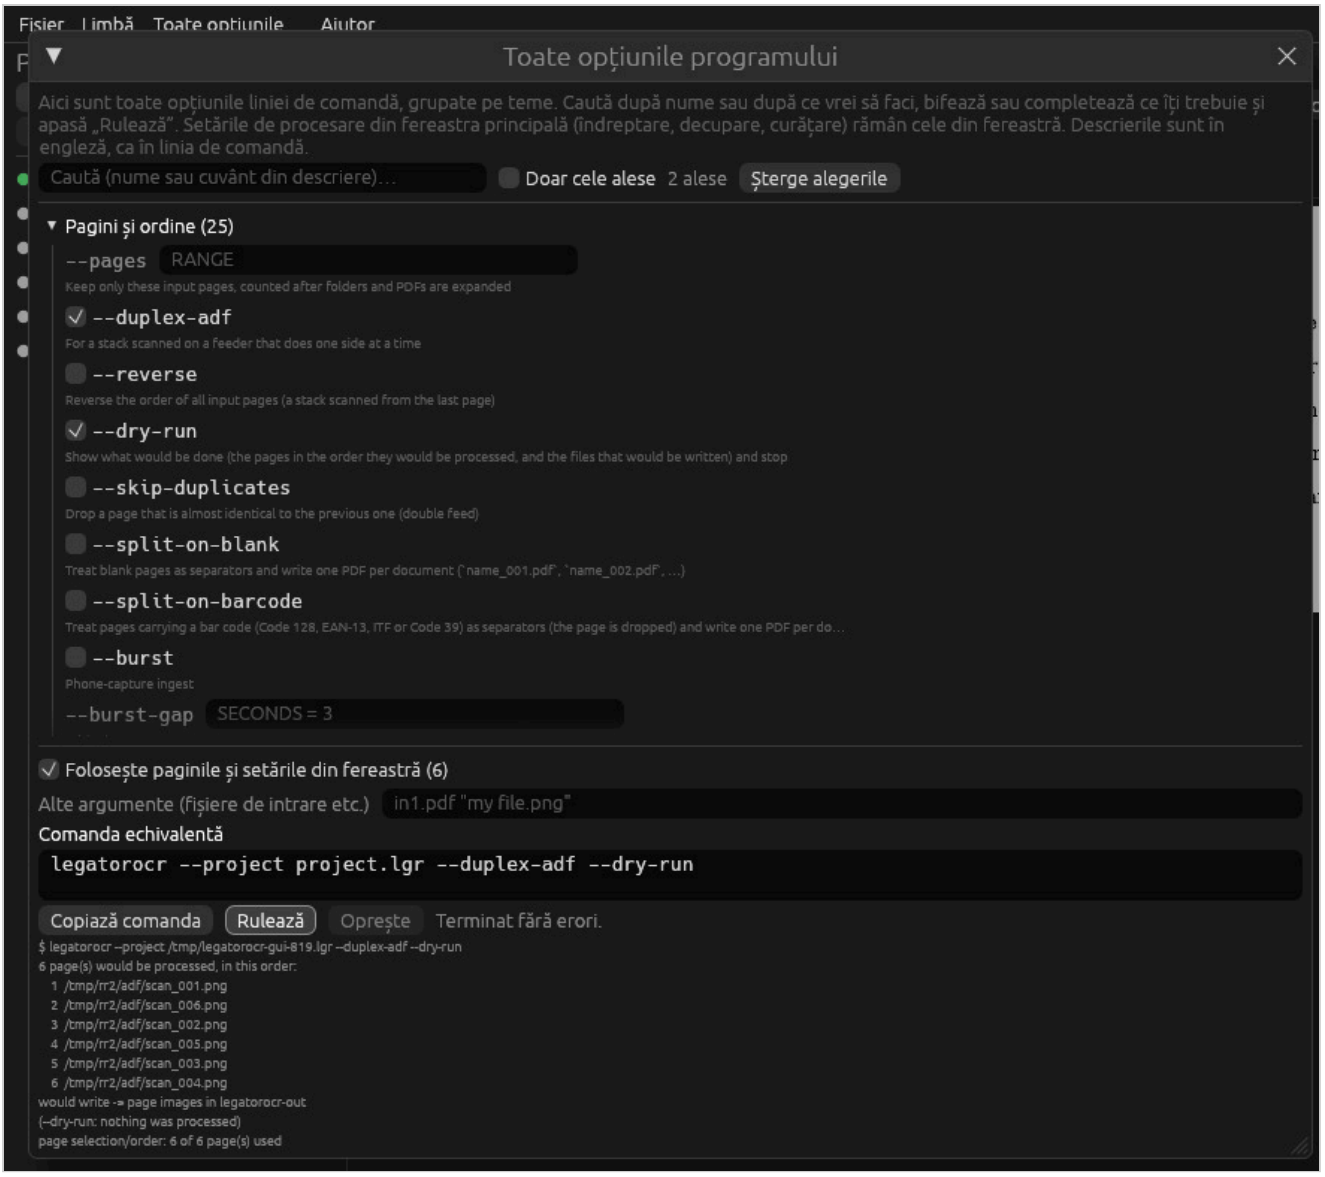
Der Abschnitt Bereinigung in den Einstellungen, aufgeklappt: Negativ-Scans invertieren, Auto-Kontrast, Perspektive, Lochungen entfernen, Löschbereiche als Zahlen.



Die Liste „Profil“ in den Einstellungen (die eingebauten Profile; Ihre eigenen erscheinen an derselben Stelle nach „Profil speichern“).

Alle Optionen und das Benutzerhandbuch

Die Schaltfläche **Alle Optionen…** in der oberen Leiste öffnet ein Fenster mit **allen** Optionen der Kommandozeile (über 200), nach Themen gruppiert: Seiten und Reihenfolge; Geraderichten, Beschneiden und Bereinigen; Ausgaben (PDF, Bilder, Dokumente); OCR und Text; Archivierung, Signatur und Prüfung; Suchen und Vergleichen; Stapel, System und Module. Die Liste wird direkt aus dem Kommandozeilenprogramm gelesen, das mit dem Fenster ausgeliefert wird, und passt daher immer zu der Ausgabe, die Sie haben.

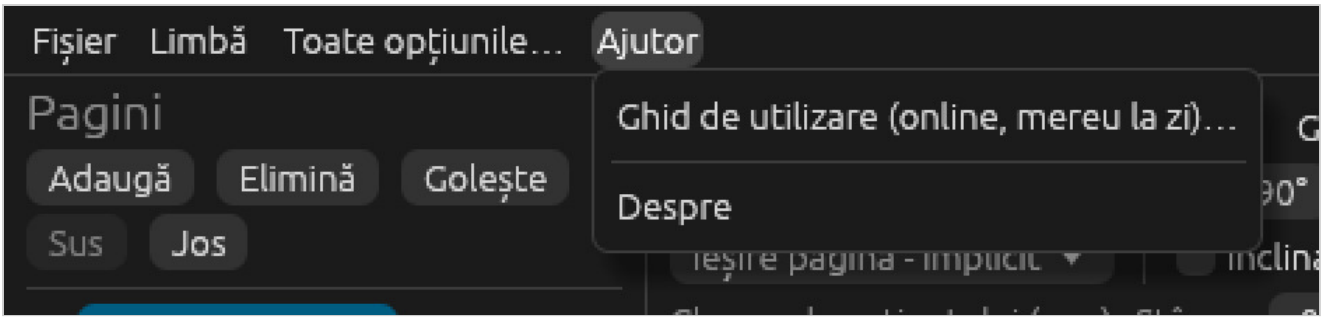


Das Fenster „Alle Optionen" mit geöffneter Gruppe „Seiten und Reihenfolge", angehakten `--duplex-adf` und `--dry-run` und dem Ergebnis des Laufs: die Reihenfolge, in der die sechs Seiten des Stapels verarbeitet würden (von mir erstellte Testseiten).

- **Suchen** nach Namen (`pdf`, `dry`) oder nach einem Wort der Beschreibung; Gruppen mit Treffern öffnen sich von selbst. „Nur gewählte" zeigt, was Sie angehakt oder ausgefüllt haben.
- Leere Felder werden nicht gesendet: Eine Option mit Wert kommt nur dann in den Befehl, wenn Sie etwas eintragen (oder aus der Liste wählen). Die Schaltfläche **Wählen…** öffnet den Datei- oder Ordnerdialog. Bei Optionen, die sich wiederholen lassen (zum Beispiel `--erase`), schreiben Sie einen Wert pro Zeile.
- **Seiten und Einstellungen des Fensters verwenden** (standardmäßig angehakt): Der Befehl erhält die geladenen Seiten mit den Anpassungen jeder einzelnen über ein temporäres Projekt. Die Verarbeitungseinstellungen des Hauptfensters (Geraderichten, Beschneiden, Bereinigen) haben Vorrang; hier ergänzen Sie die Ausgaben und die Spezialfunktionen. Haken Sie es ab für Befehle ohne Seiten (`--doctor`, `--verify-sums`) oder schreiben Sie die Eingabedateien in „Weitere Argumente".

- **Entsprechender Befehl** wird aktualisiert, während Sie wählen; Sie können ihn kopieren und im Terminal oder in Skripten verwenden. **Ausführen** führt ihn aus und zeigt das Ergebnis darunter; **Stopp** bricht ihn ab. Relative Pfade beziehen sich auf Ihren persönlichen Ordner.
- Die Beschreibungen der Optionen sind auf Englisch, wie in der Kommandozeile; der Rest des Fensters ist in der gewählten Sprache.

Das Menü **Hilfe** enthält den Link zu diesem Handbuch: *Benutzerhandbuch (online, immer aktuell)* öffnet die neueste auf legatorocr.chiuta.ro veröffentlichte Version, und *Handbuch dieser Ausgabe* (erscheint, wenn die PDF-Datei neben dem Programm liegt, wie in den veröffentlichten Archiven) öffnet die mit dem Programm ausgelieferte Kopie. Das Handbuch wird bei jeder Ausgabe neu erstellt, und die Veröffentlichung einer Ausgabe wird angehalten, wenn das Handbuch ihre Version nicht nennt.



Geprüft: das Fenster, die Suche, das Anhaken, das Ausführen eines Befehls mit den Seiten des Fensters (der Screenshot oben) und das Öffnen des Menüs Hilfe, unter Linux, auf einem virtuellen Bildschirm. Nicht geprüft: Windows, macOS und arm64; das tatsächliche Öffnen des Handbuchs in einem Browser (ich habe nur das Menü geprüft); die Dialoge „Wählen…“; die Übersetzungen der neuen Texte des Fensters (automatisch geschrieben).

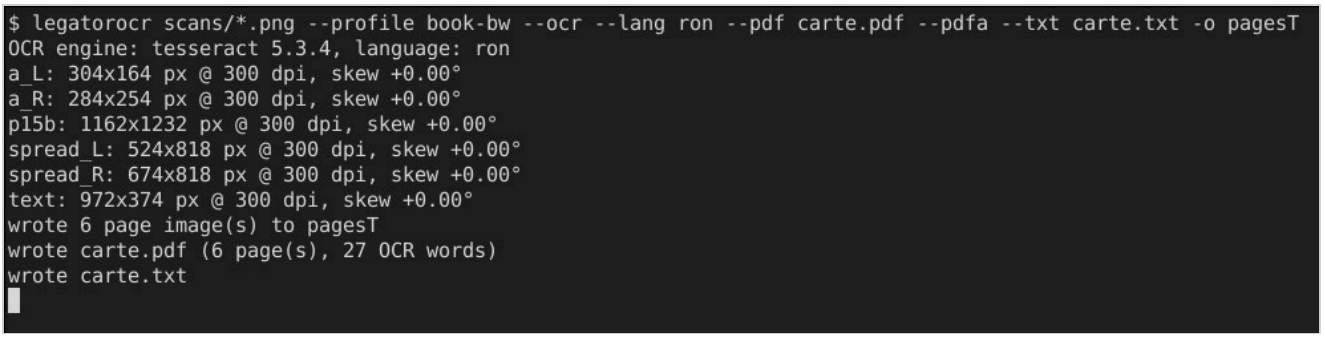
5. Die Kommandozeile: Rezepte für häufige Aufgaben

Allgemeine Syntax: `legatorocr EINGABEN... [Optionen]`. Eingaben können Bilder (PNG, JPEG, TIFF, BMP), gescannte PDFs oder ein Ordner sein. `legatorocr --help` listet alle Optionen auf; `--list-profiles` zeigt die Profile. Die Optionen in den Rezepten werden vor jeder Ausgabe automatisch geprüft, sie existieren also wirklich; die Rezepte selbst wurden nicht alle an echtem Material ausprobiert.

Gescanntes Buch → PDF mit durchsuchbarem Text

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

`--pdfa` schreibt PDF/A-2b zur Archivierung, und `--txt` speichert auch den Text. `-o pages` ist der Ordner für die verarbeiteten Bilder.

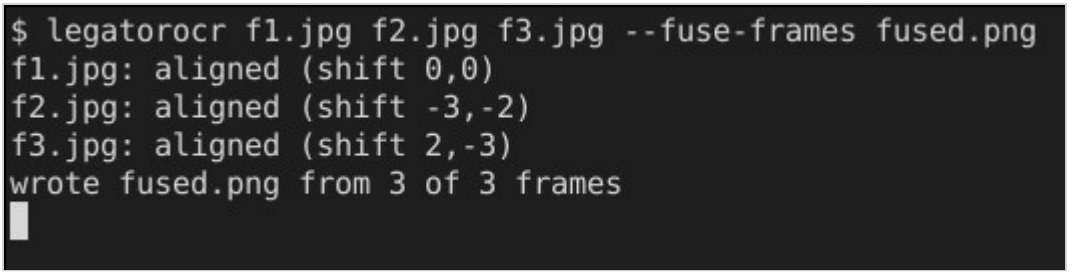


Das Rezept an 4 Testdateien: 6 Seiten in carte.pdf. Mit --pdfa schreibt das Programm PDF/A-2b.

Handyfotos → saubere Seiten

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

Das Profil gleicht das Licht an, korrigiert die Perspektive, löscht den Hintergrund um die Seite (`--trim-background`), schneidet aufgeschlagene Bücher in der Mitte, erweitert den Bereich der Schräglage und entfernt Finger, ohne den Text zu berühren. Eine Seite, die ohne Text herauskommt, wird ein zweites Mal gelesen, und zwar nur auf ihrem Inhalt. Für einheitliche Seiten auf A4 mit vergrößertem Text verwenden Sie `--profile phone-photos-a4`. Mehrere Fotos derselben Seite lassen sich zuerst mit `--fuse-frames` kombinieren (hilft bei starkem Rauschen; bei mäßigem Rauschen nicht). Die Option erhält eine Ausgabedatei: legatorocr poza1.jpg poza2.jpg poza3.jpg --fuse-frames pagina.png, danach verarbeiten Sie pagina.png wie gewohnt; das erste Foto ist die Referenz.



--fuse-frames mit drei Fotos derselben Seite: richtet sie aus und schreibt fused.png aus 3 von 3 Bildern.

Archivkopie mit Integritätsnachweis

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

Das Paket bewahrt die Originale, das Projekt, die OCR-Wörter mit Konfidenz, die Ausgaben und eine `RUN.txt` auf, die sagt, wie die Arbeit wieder aufgenommen wird. Für Kopien auf andere Datenträger: `--backup-from` und `--backup-to`.

```
$ rm -rf registru-arhiva2; legatorocr scans/text.png --profile registre-manuscrise --ocr --lang ron --pdf registru2.pdf
--pdfa --checksums --archive-package registru-arhiva2 -o pagesT2; legatorocr --verify-sums registru-arhiva2/SHA256SUMS.t
xt
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 1 page image(s) to pagesT2
wrote registru2.pdf (1 page(s), 20 OCR words)
wrote registru-arhiva2/derived/ocr.json
archive package: registru-arhiva2 (6 files, 1 originals)
wrote ./SHA256SUMS.txt (2 file(s) added or updated)
5 ok, 0 mismatched, 0 missing
```

Das erstellte und geprüfte Archivpaket: „5 ok, 0 mismatched, 0 missing“.

Namen und Nummern vor dem Teilen schwärzen

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

Die gefundenen Wörter werden im Bild geschwärzt und aus dem Text entfernt. **Prüfen Sie das Ergebnis mit eigenen Augen:** Ein Wort, das die OCR nicht erkannt hat, wird nicht verborgen.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Echtes Ergebnis: Die Telefonnummer wurde verborgen, die E-Mail-Adresse aber NICHT, weil die OCR „@“ als „G“ gelesen hat (ion.popescuGexample.com) und das E-Mail-Muster nicht gepasst hat. Deshalb müssen Sie das Ergebnis mit eigenen Augen prüfen. Ab pre.20 schreibt das Programm am Ende, wie viele Wörter jedes Muster abgedeckt hat, und warnt, wenn ein Muster nichts gefunden hat oder wenn im Text Wörter übrig geblieben sind, die wie Adressen oder lange Nummern aussehen, genau wie im Screenshot oben.

Großer Stapel auf mehreren Rechnern

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Führen Sie auf jedem Rechner dieselbe Liste aus, mit einem anderen `--shard`. Bei wenig Speicher: `--max-memory 500`. Für unbekannte oder feindliche Dateien: `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

Der in zwei Teile geteilte Stapel (--shard 1/2 und 2/2) und danach mit --merge-pdf zusammengefügt.

Ein PDF signieren

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

Die rechtliche Stufe der Signatur ist die Ihres Zertifikats. Das Passwort des Zertifikats wird über die Umgebungsvariable übergeben, nicht in der Kommandozeile. Der Zeitstempel (`--sign-timestamp`) wurde nur mit einer lokalen Stelle über HTTP geprüft, nicht mit einer echten über HTTPS.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Signieren und Prüfen mit einem von mir erstellten Testzertifikat (kein echtes Zertifikat). „time stamp inside: none“: Ich habe keinen Zeitstempel angefordert.

Stapel vom Einzug gescannt, Reihenfolge und Seitenbereich

Viele Scanner mit Einzug lassen den Stapel einmal pro Seite durchlaufen: zuerst alle Vorderseiten (1, 3, 5…), dann alle Rückseiten in umgekehrter Reihenfolge (6, 4, 2). Die Dateien kommen in der Reihenfolge des Scannens heraus, nicht in der des Buches. `--duplex-adf` bringt sie in Lesereihenfolge: Vorderseite 1, Rückseite 1, Vorderseite 2, Rückseite 2… Die Anzahl der Seiten muss gerade sein (andernfalls bricht das Programm mit einer Meldung ab).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Sechs Dateien in der Reihenfolge des Scannens (scan_001 … scan_006). `--dry-run` zeigt die Reihenfolge, in der sie verarbeitet würden, und welche Dateien geschrieben würden, und hält

dann an, ohne etwas zu verarbeiten: scan_006 landet auf Platz 2, scan_005 auf Platz 4.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

Derselbe Befehl ohne `--dry-run`, mit nativer OCR: Der Text kommt in der Reihenfolge „Pagina 1 … Pagina 6“ heraus (von mir erstellte Testseiten, kein echtes Buch).

Weitere Optionen zu Reihenfolge und Auswahl (kombinierbar; der Bereich bezieht sich auf die Nummerierung der Eingabedateien, ab 1):

- `--pages 1-10,15,20-`: behält nur die angegebenen Seiten; `20-` bedeutet „ab 20 bis zum Ende“. Funktioniert auch bei Seiten aus PDFs oder aus mehrseitigen TIFF-Blättern.
- `--reverse`: kehrt die Reihenfolge um (Stapel, der von der letzten Seite an gescannt wurde).
- `--dry-run`: prüft einen großen Stapel vor dem langen Lauf.

Geprüft: die Reihenfolge und der Bereich mit automatischen Tests und mit sechs Testseiten; einen echten Scanner mit Einzug habe ich nicht ausprobiert. Die Optionen lassen sich auch im Fenster unter „Alle Optionen…“ wählen (Abschnitt 4).

Sauberer Text: eigene Korrekturen, Kopfzeilen und Cedilla

Für die Dateien `.txt` und `.docx` (die Textebene im PDF, hOCR und JSON behalten die gelesenen Wörter unverändert):

- `--clean-text`: ș und ț mit Komma darunter, am Zeilenende getrennte Wörter zusammengefügt (mit beibehaltenem Bindestrich, wenn die beiden Hälften Wörter aus der Liste sind und das einfache Zusammenfügen keines ist), typografische Anführungszeichen, Leerzeichen neben Satzzeichen. `--cedilla` schreibt stattdessen ş und ţ, für Programme und Schriften, die die Buchstaben mit Komma nicht kennen.
- `--find-replace DATEI`: Ihre eigenen Korrekturen, eine pro Zeile, `falsch => richtig`. Zeilen, die mit `#` beginnen, sind Kommentare. Es passen nur ganze Wörter (`Ion => Ioan` berührt „Ionescu“ nicht), und sie werden in der Reihenfolge der Datei nach `--clean-text` angewendet. Nützlich für Eigennamen, Abkürzungen oder einen Stempel, den die Engine immer gleich falsch liest.
- `--drop-running-heads`: lässt Kopfzeilen, Fußzeilen und gedruckte Seitenzahlen weg: die erste oder letzte Zeile einer Seite, die sich auf mindestens der Hälfte der Seiten wiederholt (Ziffern zählen nicht); es sind mindestens vier Seiten nötig. Die entfernten Zeilen werden auf stderr aufgelistet, damit Sie sehen, was weggegangen ist.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

Die Regeldatei (erster Block) und dieselben zwei Zeilen von der Testseite gelesen ohne und mit `--find-replace`: „Ionescu“ wurde zu „Ionescu-Vale“ und „ha“ wurde zu „hectare“.

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

Bei sechs Testseiten mit der Kopfzeile „Anuarul Văii Mari“ und einer Nummer hat das Programm sechs Kopfzeilen entfernt; der Text beginnt direkt mit „Pagina 1“. Achtung: Die Regel entfernt jede erste/letzte Zeile, die sich wiederholt, bei einem Buch, in dem die letzte Zeile jeder Seite ähnlich aussieht (zum Beispiel „Poziția în raft: 14“), würden also auch diese Zeilen verschwinden; deshalb werden sie aufgelistet. Die Funktion wurde mit Tests und an einigen Seiten geprüft, nicht an einem großen Satz von Büchern.

Weitere Rezepte

Die vollständigen Rezepte stehen in `docs/tasks/` im Repository, auf Englisch und Rumänisch (Dokumentenprüfung mit `--verify-document` und `--mrz`, Archivkopie, großer Stapel).

6. Wichtige Einstellungen und wann man sie verwendet

Profile

```
$ legatorocr --list-profiles | cut -c1-100
book-bw             Text books: auto threshold, black & white, punch holes removed
book-small-color    Colour books: sharp text over a light background, smallest files
document-text       Office documents: sharp text, pictures kept in colour
photo-archive       Archive quality colour, light sharpening
newspaper           Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red    Forms with red rules or stamps: drop red, erase ruled lines
negatives           Negative scans: invert and stretch contrast
doc-birou           Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene       Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim        Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft        Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum        Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma             Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta               Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura           Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos        Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof           user profile
```

legatorocr --list-profiles. Die letzte Zeile (smokeprof) ist ein Testprofil von mir und gehört nicht zum Programm.

Ein Profil ist ein fertiger Satz von Einstellungen für eine Materialart. Man wählt es im Abschnitt „Profil“ (Oberfläche) oder mit `--profile NAME` (Kommandozeile). Sie können eigene Profile haben: Sie konfigurieren die Einstellungen, tragen einen Namen ein und drücken „Profil speichern“.

Profil	Wofür
`book-bw`	Bücher mit Text, Schwarzweiß, Lochungen entfernt
`book-small-color`	farbige Bücher, klarer Text auf hellem Hintergrund, kleine Dateien
`document-text`	Büro-Dokumente, Bilder bleiben farbig
`photo-archive`	Fotografien, Archivqualität
`newspaper`	Zeitungen: Wolf-Schwelle, Flecken stärker entfernt
`form-dropout-red`	Formulare mit roten Linien oder Stempeln
`negatives`	Negativ-Scans
`phone-photos`	Handyfotos: Perspektive korrigiert, Hintergrund um die Seite gelöscht, aufgeschlagene Bücher in der Mitte geschnitten, Finger entfernt
`phone-photos-a4`	wie `phone-photos`, aber jede Seite auf einem A4-Blatt, mit so vergrößertem Text, dass er das Blatt füllt (auch bei Seiten mit wenigen Zeilen)
`registre-manuscrise`	alte Register und Handschriften (300–600 dpi), Farben beibehalten
`schite-desene`	Skizzen und Bleistiftzeichnungen (400 dpi)
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	Abläufe für Büro-Dokumente, von maximaler Qualität bis zu hohem Volumen
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**an echten Proben nicht geprüft**

Die vollständige Liste gibt `--list-profiles` aus.

Die wichtigsten Einstellungen

Einstellung	Was sie bewirkt	Wann Sie sie ändern
Auflösung (dpi)	mit welcher Auflösung die Seiten gescannt wurden	wenn das Bild keine dpi im Header hat; für Text 300
Automatisch begradigen / Max. Schräglage	die Grenze des automatisch korrigierten Winkels	wenn eine Seite, die „am Grenzwert“ herauskommt, in Wirklichkeit schief ist
Ränder, Seitengröße, Gleiche Größe für alle Seiten	die Ränder in mm; freie, benutzerdefinierte oder für das ganze Buch identische Seite	bei Büchern mit gemischten Formaten
Ausgabemodus	Farbe, Grau, Schwarzweiß, gemischt (1-Bit-Text + Farbbilder), hybrid (+ Hintergrund mit niedriger Auflösung)	Schwarzweiß für reinen Text; gemischt für Text mit Bildern
Schwellwert-Verfahren	Sauvola (Standard), Wolf, Niblack, NICK, Bradley, Otsu oder automatisch	wenn der Text blass oder voller Flecken herauskommt; `auto` probiert auf jeder Seite mehrere aus
Empfindlichkeit	die Empfindlichkeit des Sauvola-Verfahrens für die Schwarzweiß-Ausgabe	Standard 0,3; ändern Sie sie in kleinen Schritten und vergleichen Sie das Ergebnis auf derselben Seite
Bildempfindlichkeit	wie leicht ein Bereich als Bild eingestuft wird	im Modus gemischt/hybrid
Kleine Flecken entfernen	die Stärke der Fleckenbereinigung (0,25–4; 1 = Standard)	verringern Sie sie, wenn Punkte oder Diakritika verschwinden; erhöhen Sie sie, wenn Flecken bleiben
Dewarp (gekrümmte Zeilen)	begradigt die zum Buchrücken hin gewölbten Zeilen	für dicke Bücher; wird übersprungen, wenn keine deutliche Krümmung zu sehen ist
Beleuchtung angleichen	gleicht den Hintergrund aus	für Fotos mit Schatten oder ungleichmäßiger Beleuchtung
JPEG-Qualität	0 = verlustfrei; Schwarzweiß-Seiten sind immer verlustfrei	für kleinere Dateien (Vorschlag: probieren Sie 80–90 und vergleichen Sie Größe und Aussehen)
Ausgabe-dpi	verkleinert das Ausgabebild auf diese dpi (“—” = nicht verkleinern)	für kleinere PDFs; Seiten unter 250 dpi werden vor der OCR automatisch vergrößert, eine zu starke Verkleinerung hilft der Erkennung also nicht
PDF/A-2b	PDF zur Archivierung, mit eingebundener Schrift und eingebundenem Farbprofil	für die Ablage in Archiven; wurde an den Ausgaben des Programms nicht mit veraPDF geprüft

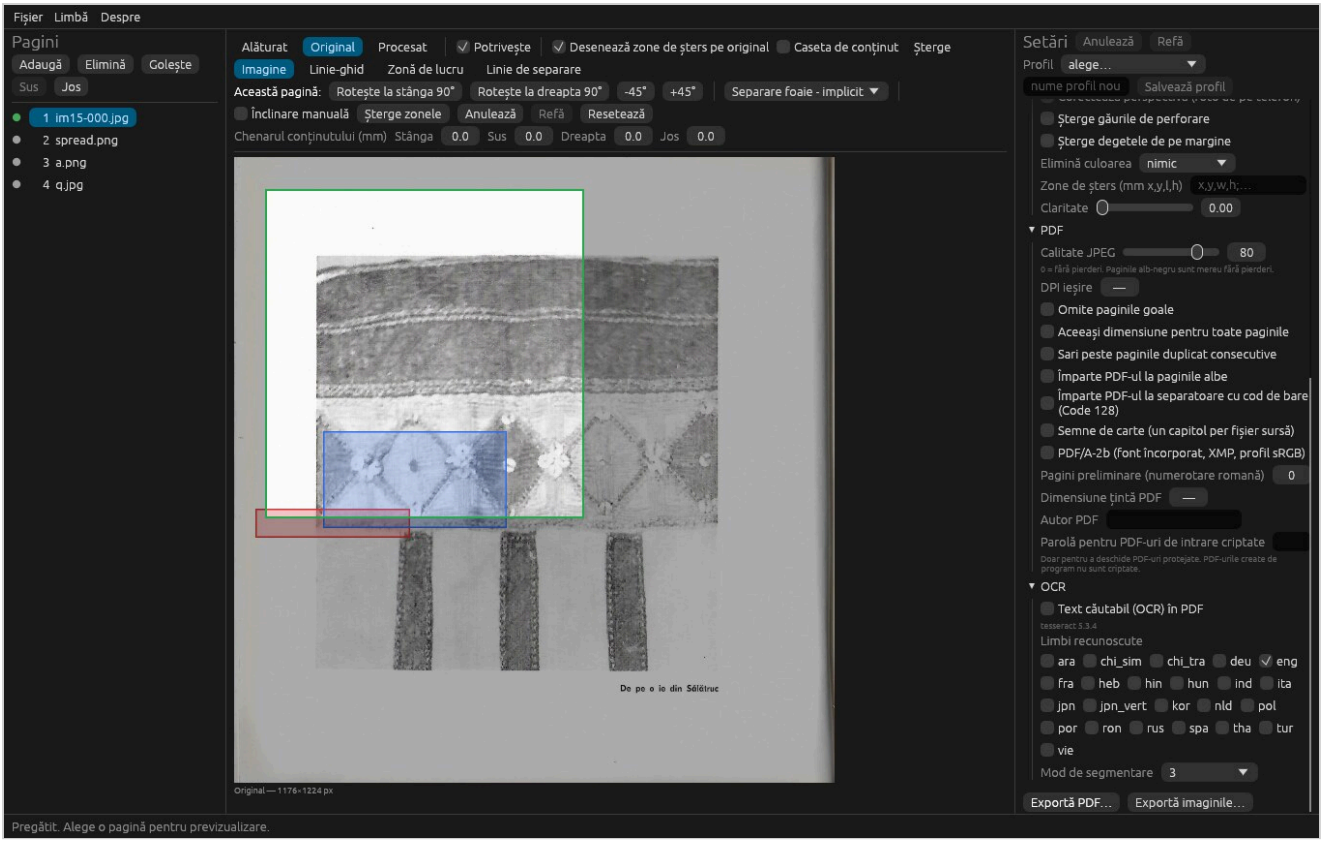
Die Formate der Textfelder

Diese Felder gibt es in den Einstellungen, aber es ist einfacher, auf dem Original zu zeichnen (Abschnitt 4):

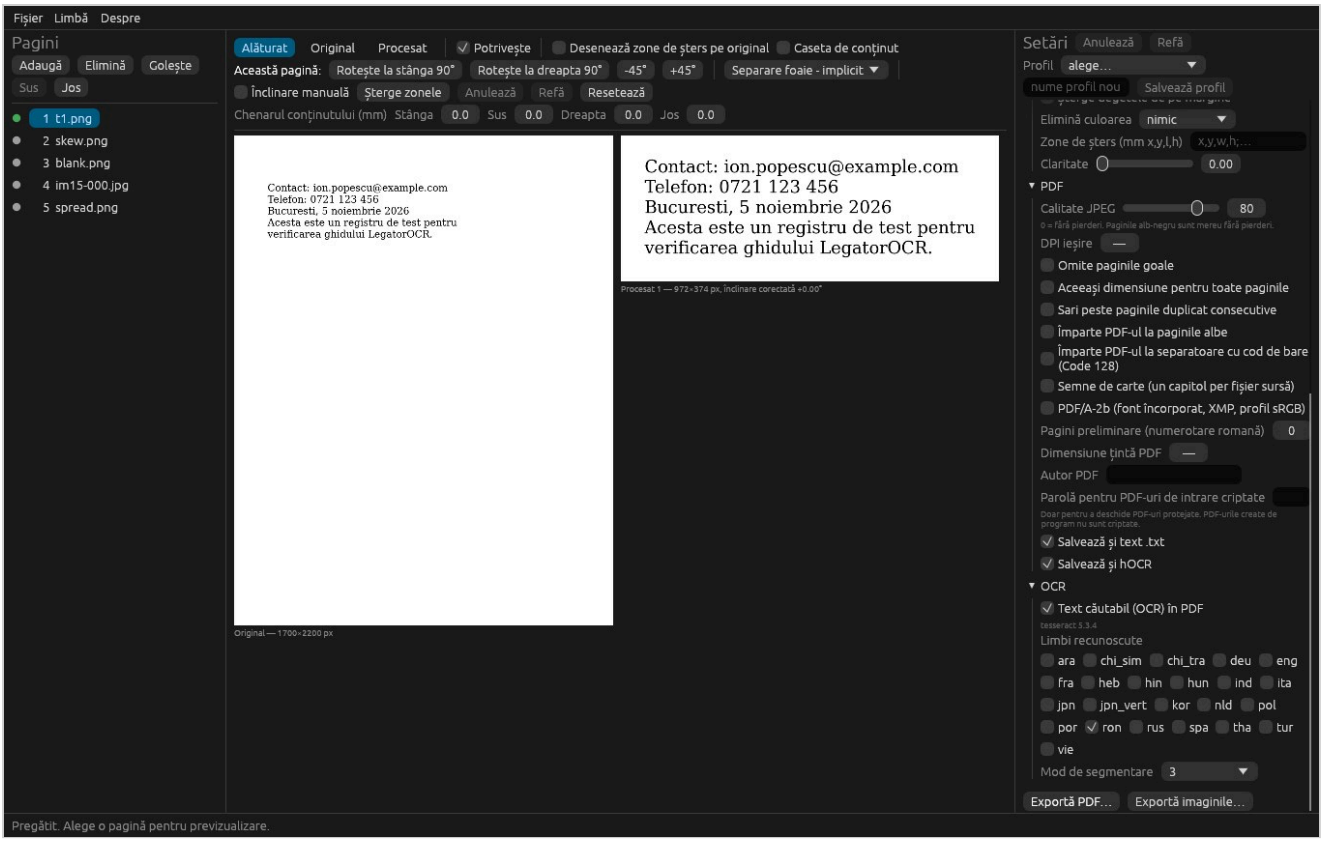
- **Löschbereiche** und **Bildbereiche**: `x,y,b,h` in **Millimetern** von der oberen linken Ecke der Seite. Mehrere Bereiche trennt man mit Semikolon: 10,20,30,40;50,60,20,20. Höchstens 64; Breite und Höhe müssen positiv sein. Ist die Form falsch, wird das Feld rot.
- **Hilfslinien zum Begradigen**: `x,y x,y x,y;x,y x,y x,y`, mit **Bruchteilen zwischen 0 und 1** der bereits geradegerückten Seite (0,0 = obere linke Ecke). Jede Linie hat mindestens zwei Punkte; insgesamt höchstens 64 Linien.
- In der Kommandozeile: `--erase X,Y,W,H` (wiederholbar) und `--dewarp-guide "X,Y X,Y …"` (wiederholbar).

7. OCR: Engines, Sprachen und Genauigkeit

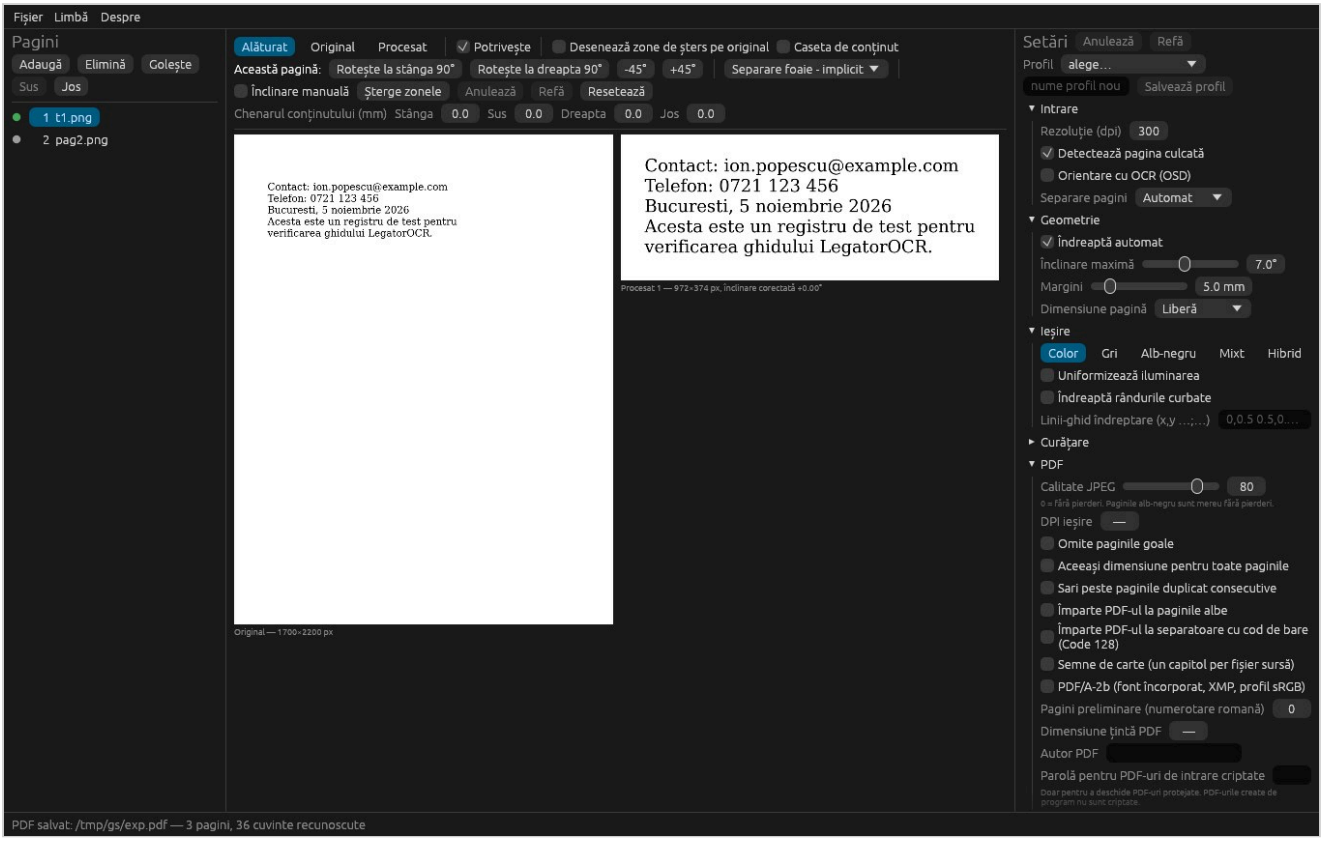
Das Häkchen „Durchsuchbarer Text (OCR) im PDF“ (oder `--ocr` in der Kommandozeile) fügt über dem Bild eine unsichtbare Textebene hinzu. Die Sprache wird unter „Erkennungssprachen“ gewählt (oder `--lang ron`); sie kann kombiniert werden, zum Beispiel `ron+eng`. Die Sprachen der Oberfläche und der eigenen Engine: Rumänisch, Englisch, Französisch, Italienisch, Spanisch, Portugiesisch, Deutsch, Ungarisch.



Der Abschnitt OCR in den Einstellungen: das Häkchen „Durchsuchbarer Text (OCR) im PDF“, die erkannten Sprachen (die bei Tesseract installierten) und der Segmentierungsmodus. Im Screenshot war Tesseract 5.3.4 installiert, daher erscheinen alle seine Sprachen; die Wahl ron habe ich in der nächsten Abbildung verwendet.



Bei angehaktem OCR erscheinen auch „Text zusätzlich speichern (.txt)“ und „hOCR zusätzlich speichern“. Hier ist die gewählte Sprache ron.



Nach dem Export zeigt die untere Leiste: „PDF gespeichert: … — 3 Seiten, 36 Wörter erkannt“. (Den Export habe ich mit einem Testmechanismus des Programms gestartet, nicht über den Dateidialog.)

Drei Engines

Engine	Wie Sie sie wählen	Hinweise
Nativ (die des Programms)	`--engine native`	ohne Installation, in Rust geschrieben; Modell, trainiert auf synthetischem Text, danach feinabgestimmt auf Zeilen aus einer rumänischen Zeitschrift und aus einem Lehrbuch von 1960
Tesseract	`--engine tesseract`	separates Programm, siehe Abschnitt 2; wird automatisch verwendet, wenn es installiert ist und die angeforderte Sprache hat (`--engine auto`, Standard)
ONNX-Brücke	`--engine tesseract --tesseract scripts/engine-onnx.py`	für fortgeschrittene Benutzer; erfordert Python, onnxruntime und separat heruntergeladene Modelle

```
$ legatorocr scans/text.png --engine native --ocr --lang ron --txt nat.txt --format none; cat nat.txt; echo; legatorocr
scans/text.png --engine tesseract --ocr --lang ron --txt tes.txt --format none; cat tes.txt
OCR engine: LegatorOCR native engine 0.2.0-pre.19, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote nat.txt
Contact: ion.popescu(aexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote tes.txt
Contact: ion.popescuGexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
```

Dieselbe Testseite, von den beiden Engines gelesen. Beide haben sich gleich geirrt: „@“ wurde bei der nativen Engine zu „(a“ und bei Tesseract zu „G“.

Die gemessenen Zahlen (und was sie nicht sagen)

Gemessen wurden 8 gute Seiten einer rumänischen Zeitschrift, gegenüber einem von ABBYY erzeugten Referenztext, der nicht von Menschen korrigiert wurde. Die Fehlerrate pro Zeichen, mit Diakritika (die ursprüngliche Messung, aus der Ausgabe 0.2.0-pre.21; bei einer neuen Messung in pre.26 an denselben 8 Seiten, mit derselben Methode, ergab die native Engine 2,76 %; den Unterschied zu 2,55 % habe ich nicht untersucht):

Engine	Fehler pro Zeichen
Nativ	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (mit Tesseract)	4,62 %

Einfach gelesen: Die native Engine macht **bei dieser Druckart** weniger Fehler. Aber sie wurde an Text aus denselben Quellen feinabgestimmt, man kann also nicht sagen, dass sie im Allgemeinen besser ist. Bei anderen Dokumenten, vor allem bei altem oder ungewöhnlichem Druck, kann sie schwächer sein als Tesseract. Die Erkennung ganzer Wörter ist zwischen den Engines nahezu gleich (etwa 92 %).

Der genaue Modus und die alte Orthografie

- `--accurate` (native Engine): Jede Zeile wird dreimal gelesen (um ein Pixel nach oben und unten verschoben), und die Wahrscheinlichkeiten werden gemittelt. Es ist langsamer (gemessen: 18 % bis 74 % mehr Zeit) und hat nur bei den Zeitschriftenseiten geholfen

(Zeichenfehler 3,66 % → 3,39 % bei 12 Seiten); bei Büchern und Broschüren hat es nichts Messbares geändert. Es ist standardmäßig ausgeschaltet.

- Die Liste rumänischer Wörter akzeptiert auch die Orthografie von 1953–1993 (`cuvînt`, `romîn`, `sînt`): Bei fünf Seiten aus einem Lehrbuch von 1960, von Hand transkribiert, stiegen die korrekten Zeichen von 99,6 % auf 99,7 % und die Wörter von 96,0 % auf 96,3 %. Ein kleiner Unterschied, bei fünf Seiten.
- Wörter werden an großen Abständen getrennt, auch wenn das Netz kein Leerzeichen geschrieben hat: Die Zellen einer Tabelle kommen nicht mehr zusammengeklebt heraus (`CantitatePreț`). Eine Tabelle mit Linien wird als eine einzige Tabelle gefunden (Excel: `--tables-xlsx`); eine Tabelle ohne Linien wird noch immer als zwei Tabellen gefunden (links und rechts), ein ungelöstes Problem.

Tipps

- Vergleichen Sie bei Ihren eigenen Dokumenten die Engines vor dem Stapel an 5–10 Seiten: `scripts/compare-ocr-text.py` misst die Fehler gegenüber Referenztexten, die Sie selbst haben.
- Seiten unter 250 dpi werden vor der Erkennung automatisch vergrößert.
- Seiten mit Illustrationen oder Diagrammen können im Bildbereich sinnlosen Text erzeugen (Tesseract hat auf einer der gemessenen Seiten eine Illustration als Text gelesen). Prüfen Sie diese Bereiche.
- Jede OCR kann Wörter erfinden oder verlieren. Bei Urkunden, Registern oder Zahlen prüfen Sie stichprobenartig.

8. Ausgaben und Archivierung

Was Sie möchten	Wie
PDF mit durchsuchbarem Text	`--pdf DATEI.pdf --ocr` (Oberfläche: PDF exportieren bei angehaktem OCR)
PDF zur Archivierung (PDF/A-2b)	`--pdfa`; andere Teile mit `--pdfa-part 1` oder `3`
Verarbeitete Bilder	`-o ORDNER`, mit `--format png`, `jpeg` oder `tiff`; `--format none` schreibt keine Bilder
Einfacher Text der Seiten	`--txt DATEI.txt`
hOCR	das Häkchen „hOCR zusätzlich speichern“
Struktur für Barrierefreiheit	`--tagged ro` (getaggte Absätze). Die PDF/UA-Konformität wurde **nicht** validiert
DjVu-Kopie	`--djvu DATEI.djvu`
Integritätsnachweis	`--checksums` und `--archive-package DIR`, danach `--verify-sums`
Projekt (Einstellungen und Korrekturen)	Datei → Projekt speichern… (`.lgr`), oder `--save-project`; `--embed-project` versteckt es im PDF

Zu PDF/A

Das Programm schreibt PDF/A-2b mit eingebetteter Schrift und eingebettetem sRGB-Profil. Die Konformität wurde an Stichproben geprüft, **nicht** mit veraPDF an jeder Ausgabe. Verlangt eine Institution zertifizierte Konformität, lassen Sie Ihren eigenen Validator über die fertigen Dateien laufen.

Zu ScanTailor-Projekten

`--project DATEI.ScanTailor` öffnet ein ScanTailor-Projekt: Die Scan-Liste und die Drehung je Bild werden übernommen, Schräglage, Teilung und Inhaltsrahmen werden neu ermittelt. Der Reader wurde nach der Beschreibung des Formats geschrieben und an einem von Hand erstellten Projekt getestet, nicht an Dateien aus jeder ScanTailor-Version.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project und --project: Das Projekt wird gespeichert und mit demselben Ergebnis wieder geöffnet (2 Seiten). Achtung: In pre.18 wurden --work-area und --cut-at nicht im Projekt behalten; in pre.19 behoben (geprüft: Das gespeicherte und wieder geöffnete Projekt ergibt dieselben Seiten).

9. Häufige Probleme und bekannte Grenzen

Symptom	Was Sie prüfen sollten
Die Seite kommt abgeschnitten oder mit zu viel Weiß heraus	der Inhaltsrahmen (Abschnitt 4); der Rahmen in mm in der Leiste „Diese Seite“
Eine schiefe Seite bleibt schief	die maximal zulässige Schräglage; legen Sie den Winkel manuell fest
Das Doppelblatt wird nicht an der richtigen Stelle geschnitten	der Trennmodus der Seite: „in der Mitte“ oder „aus“; ab pre.18 können Sie eine „Schnittlinie“ auf dem Original ziehen oder `--cut-at 0.45` verwenden
Ein Textfeld wird rot	das Format des Feldes (Abschnitt 6): Millimeter für Zonen, Bruchteile 0–1 für Hilfslinien
Der OCR-Text hat Fehler	vergleichen Sie die Engines (Abschnitt 7); prüfen Sie die Auflösung; wechseln Sie zu Tesseract oder umgekehrt
Das Feld „Zu prüfen“	Seiten, die als verdächtig markiert sind (leer, Schräglage am Grenzwert, nichts gefunden, Inhalt am Rand klebend); sie sind nicht unbedingt falsch, aber einen Blick wert
Das Fenster funktioniert unter Windows oder in RDP nicht	fehlendes OpenGL 2+; probieren Sie den Treiber der Grafikkarte
Die macOS-App startet nicht	sie ist nicht signiert: Rechtsklick → Open oder der Befehl `xattr` aus Abschnitt 2

Bekannte Grenzen der Ausgabe 0.2.0-pre.43

- Auto-Trapez: geprüft an synthetischen Blättern und an 67 Handyfotos eines einzigen Buchs (133 Seiten), wo es die meisten Seiten unberührt ließ und bei den übrigen die gemessene Neigung senkte; niemand hat das Ergebnis bei anderen Büchern oder bei Seiten mit großen Bildern, Tabellen oder sehr kurzen Zeilen nach Augenschein beurteilt, wo es nichts oder zu wenig tun kann. Die Einstellungen pro Seite und die Neigung der Schnittlinie wurden an synthetischen Blättern und in Tests erprobt; der Tabellenstift lässt die OCR die Zone als einen Block lesen, er findet keine Zellen.

- Drehung um 90°: Bei einer Seite mit einem Foto von Ornamenten (Seite 15 aus einem PDF) sah ein Tester unter Windows, wie die Drehung von 90° auf 180° sprang. Einen Teil des Problems habe ich unter Linux reproduziert: In pre.18 drehte das Programm bei angehaktem „Gedrehte Seiten erkennen“ (Standard) diese Seite fälschlich um 90°, obwohl das Original gerade ist (die Abbildung in Abschnitt 4). Die Schwelle in pre.19 war zu fragil (ich habe inzwischen entdeckt, dass eine andere Seite desselben PDFs, Seite 13, sich ebenfalls falsch drehte). In pre.20 zählt der Detektor nur Teile in der Größe eines Buchstabens und enthält sich bei Seiten mit Bildern oder mit wenigen Wörtern. Bei 98 Buchseiten (gedreht auf 0° und 90°) und 5 Seiten mit Bildern ist das Ergebnis identisch mit pre.18, außer Seite 13 (in pre.18 falsch gedreht, jetzt gerade) und einer Seite mit einem liegenden Bild, die der Detektor nicht mehr dreht (OSD und manuelle Drehung bleiben). In der Kommandozeile geprüft, unter Linux, an einem kleinen Korpus. Die wahrscheinliche Ursache des Sprungs (die automatische Orientierung addierte sich zur manuellen Drehung) wurde in pre.18 behoben: Nach einem Klick auf die Drehung bleibt die Seite gesperrt, und vier Klicks ergeben 90°, 180°, 270° und zurück auf 0° (im Fenster geprüft, unter Linux). Was der Tester unter Windows 11 genau gesehen hat, konnte ich nicht prüfen. Wenn eine Seite mit Bildern trotzdem falsch gedreht wird, haken Sie „Gedrehte Seiten erkennen“ ab oder verwenden Sie --no-auto-orient.

- Der Arbeitsbereich, die verschiebbare Schnittlinie, die Lösch- und Bildzonen, das Punktraster, Rückgängig und Ctrl+Z, der Inhaltsrahmen, die OCR und der PDF-Export wurden in einem echten Fenster unter Linux mit simulierter Maus ausprobiert (die Screenshots im Handbuch). Das Ändern der Größe einer Zone an der Ecke funktionierte im Fenster. Die nativen Dateidialoge („PDF exportieren…“, „Projekt speichern“, „Projekt öffnen“) funktionierten mit dem GTK-Dialog eines xdg-Portals unter Linux; unter Windows und macOS habe ich sie nicht ausprobiert. Wenn das System überhaupt keinen Dialog hat, sagt das Fenster das ab pre.21, statt nichts zu tun (Sie können die Dateien ins Fenster ziehen oder die Kommandozeile verwenden). Das Speichern eines eigenen Profils funktionierte. Die Wirkung der Schnittlinie habe ich durch automatische Tests, mit --cut-at und im Fenster geprüft (ein Doppelblatt in zwei ungleiche Seiten geschnitten, 524 und 674 px). Bei um 90° oder 270° gedrehten Blättern (ab pre.21) kommen die Seiten untereinander heraus; das ist nur durch einen automatischen Test geprüft, nicht im Fenster.

  --save-project: Im veröffentlichten Build pre.18 wurden --work-area und --cut-at, in der Kommandozeile angegeben, nicht in der Datei .lgr behalten (bei der Prüfung dieses Handbuchs gefunden). In pre.19 behoben. Wenn Sie pre.18 verwenden, geben Sie die Optionen bei --project erneut an, nicht nur aus dem Projekt.

- Die grafische Oberfläche wurde von Menschen unter Windows, macOS oder arm64 nicht geprüft.

- Die Prüfung von PDF/UA, die elektronische Rechnung CIUS-RO und der Zeitstempel über HTTPS mit einer echten Stelle wurden nicht validiert.

- Für eine zertifizierte PDF/A-Kopie ist der Validator Ihre Sache (zum Beispiel veraPDF).

- Das Nutzungsrecht am eigenen OCR-Modell (teilweise trainiert auf Seiten mit ungeklärten Rechten) ist beim Autor eine offene Frage; siehe `docs/audit/assets-licences.md`.

10. So melden Sie ein Problem

Der nützlichste Beitrag ist ein Bericht von einem System, das der Autor nicht ausprobiert hat. Er dauert fünf Minuten:

1. Laden Sie die neueste Ausgabe für Ihr System herunter.
2. Führen Sie `legatorocr --doctor` aus und kopieren Sie die gesamte Ausgabe.
3. Verarbeiten Sie eine Seite, die Sie teilen können: `legatorocr SEITE.jpg --ocr --pdf rezultat.pdf -o pagini`.
4. Öffnen Sie `rezultat.pdf`: Ist die Seite gerade und richtig beschnitten? Lässt sich der Text markieren und durchsuchen?

Senden Sie als Issue im Repository `chiuta/LegatorOCR` (oder per E-Mail):

- das System und die Version (zum Beispiel Windows 11 23H2, macOS 15 arm64, Debian 12 arm64);
- die Version von LegatorOCR;
- die Ausgabe des Befehls `--doctor`;
- den ausgeführten Befehl (oder die Einstellung in der Oberfläche);
- was Sie erwartet haben und was passiert ist (Fehlertext oder Screenshot);
- ob das Bild geteilt werden kann.

Senden Sie keine Dokumente mit personenbezogenen Daten. Ein Bericht „alles hat funktioniert“ ist ebenfalls nützlich: Es ist der einzige Weg, wie der Autor erfährt, dass ein System funktioniert.

Sicherheitsprobleme werden gemäß `SECURITY.md` gemeldet, nicht öffentlich.