LegatorOCR – Guía de uso

Edición 0.2.0-pre.61 (versión de prueba). Texto en elaboración, en rumano.

1. Qué es LegatorOCR

LegatorOCR convierte escaneos o fotos de páginas en un PDF limpio, con texto en el que se puede buscar. Resuelve el mismo problema que ScanTailor (separación de páginas, enderezado, recorte, limpieza), pero añade exportación a PDF y OCR. Está escrito en Rust, con código propio, y cada etapa es una técnica de manual. Se ejecuta en local, sin cuenta y sin enviar las páginas por internet. Licencia: MIT.

Hay dos modos de trabajo, con los mismos motores por debajo:

- **La interfaz gráfica** (`legatorocr-gui`): se añaden páginas, se ve el original y el resultado lado a lado, se corrige página por página y se exporta.
- **La línea de comandos** (`legatorocr`): para lotes grandes, para automatización y para opciones que la interfaz no muestra.

Qué hace

- separa las hojas a doble página en dos páginas, endereza las páginas inclinadas y recorta los márgenes;
- limpia el fondo, las manchas, los agujeros de perforación, los dedos del borde y las líneas de formulario;
- escribe PDF (incluido PDF/A para archivo) o imágenes, con OCR en rumano y en otros 7 idiomas;
- produce también texto simple (`.txt`) y hOCR, y puede firmar o fechar el PDF.

Qué no hace (o no se ha demostrado)

- Es una versión de prueba (0.2.0-pre.61). El autor y su asistente solo la han ejecutado en Linux; **Windows, macOS y los procesadores arm64 no los han probado personas**.
- La precisión del OCR se midió en 8 páginas buenas de una sola revista rumana, frente a un texto de referencia producido por otro programa, no corregido por una persona. No la tome como garantía para otros tipos de impresión.
- El OCR puede equivocarse: compruebe por muestreo las páginas importantes.

2. Instalación y primera ejecución

Descargue el archivo para su sistema desde la página de versiones (Releases) del repositorio `chiuta/LegatorOCR`. Cada archivo tiene un fichero `.sha256` para la verificación.

Sistema	Archivo	Notas
Linux x86-64 o ARM64	`.tar.gz`	necesita OpenGL 2+ y X11 o Wayland
Windows x86-64	`.zip`	necesita OpenGL 2+; en sesiones RDP simples puede faltar
macOS Apple-silicon o Intel	`.zip` con `LegatorOCR.app`	**sin firmar**: en el primer arranque, clic derecho → Open, o `xattr -dr com.apple.quarantine LegatorOCR.app`

También puede compilar desde el código fuente: `cargo build --release` (requiere Rust 1.95 o más reciente).

OCR

El programa tiene un motor de OCR propio, que funciona sin instalación. Opcionalmente puede instalar Tesseract, un programa aparte que LegatorOCR usa automáticamente cuando está presente y tiene el idioma solicitado:

- Linux (Debian/Ubuntu): `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS: `brew install tesseract tesseract-lang`
- Windows: `winget install UB-Mannheim.TesseractOCR` y añadirlo al `PATH`

El modelo rumano de los paquetes `apt` y `brew` es la variante pequeña („fast”). La variante „best” se descarga a mano y se indica con `--tessdata DIR`. No se ha medido cuál de las dos lee mejor sus páginas.

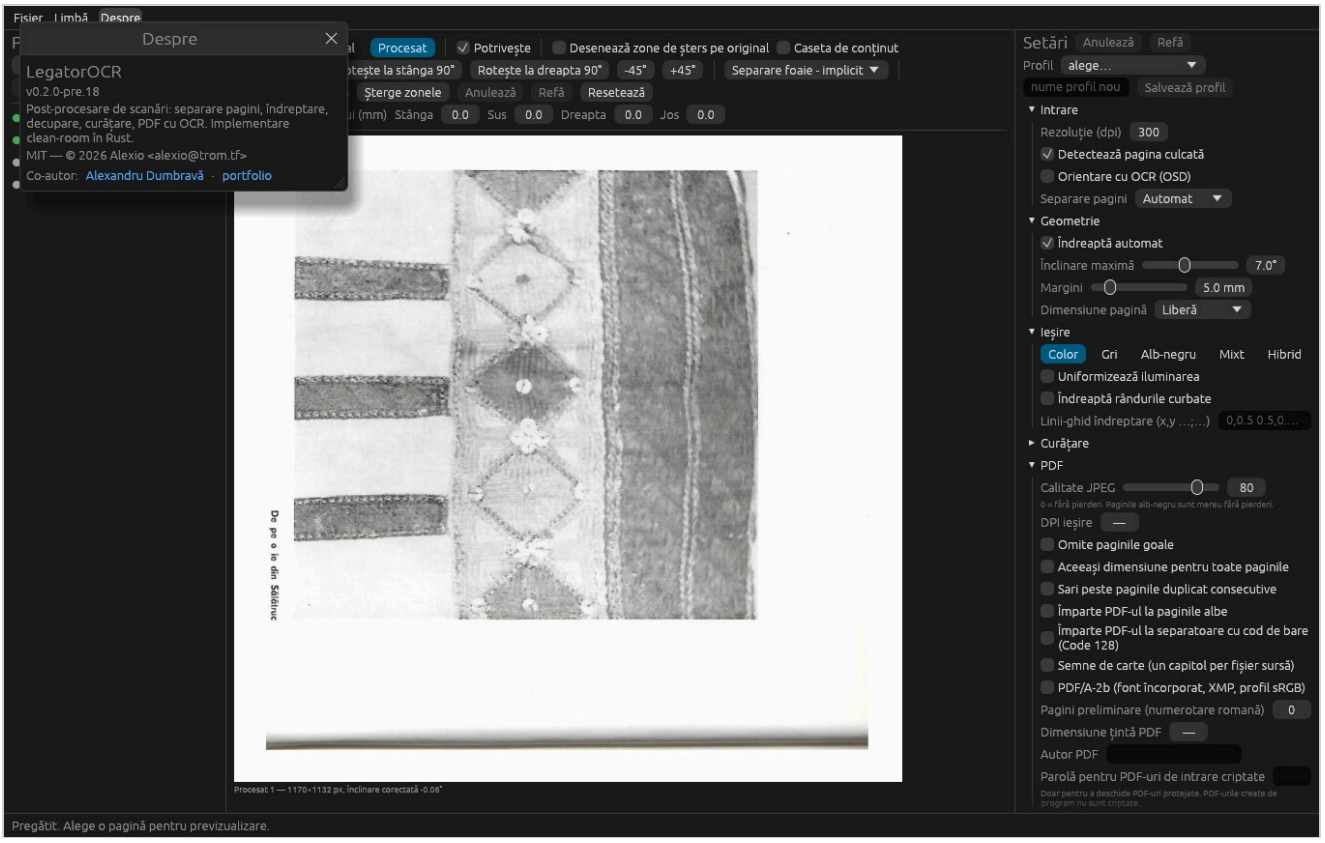
Compruebe la instalación

Ejecute `legatorocr --doctor`. Muestra la versión, el motor de OCR nativo, Tesseract y los modelos de idioma, y después las herramientas auxiliares (`pdftoppm`, `gs`, `qpdf`, `mutool`). El resultado „missing” en una herramienta opcional no es un error; el mensaje que figura debajo dice si hace falta. Si algo no funciona, copie todo el resultado del comando en un informe (véase la sección 10).

```
$ legatorocr --doctor
[ok     ] legatorocr                        0.2.0-pre.19
[ok     ] native OCR engine                 built in
[ok     ] tesseract                         tesseract 5.3.4
[ok     ] tesseract model ro (Romanian)     installed
[ok     ] tesseract model en (English)      installed
[ok     ] tesseract model fr (French)       installed
[ok     ] tesseract model it (Italian)      installed
[ok     ] tesseract model es (Spanish)      installed
[ok     ] tesseract model pt (Portuguese)   installed
[ok     ] tesseract model de (German)       installed
[ok     ] tesseract model hu (Hungarian)    installed
[ok     ] pdftoppm                          pdftoppm
[missing] mutool                            not found
          -> optional: alternative renderer for those cases
[ok     ] gs                                gs
[ok     ] qpdf                              qpdf
14 check(s) ok, 1 missing. Missing helpers are optional unless a hint says otherwise.
```

Resultado del comando legatorocr --doctor (pre.20, Linux, en un terminal real; igual todas las capturas de terminal de la guía, hechas con xterm): „missing” en mutool es una herramienta

opcional, no un error.



El menú Acerca de muestra la versión instalada (aquí 0.2.0-pre.18). Captura de la compilación pre.18 en Linux, interfaz en rumano.

3. El flujo de trabajo, paso a paso

Para cada página, el programa recorre las etapas siguientes en este orden. El análisis se hace sobre una copia de aproximadamente 150 dpi, y el resultado se aplica después al escaneo a su resolución completa.

1. **Orientación.** Se detectan las páginas tumbadas (un cuarto de vuelta) a partir de las letras de la página: una página con fotos o con pocas palabras no es girada por esta prueba. Para la dirección exacta se puede usar Tesseract (OSD) o el giro manual.

2. **Separación de la hoja.** Una hoja apaisada con dos páginas se corta por la mitad, en la banda vacía del centro. Puede ser automática, por la mitad o estar desactivada.

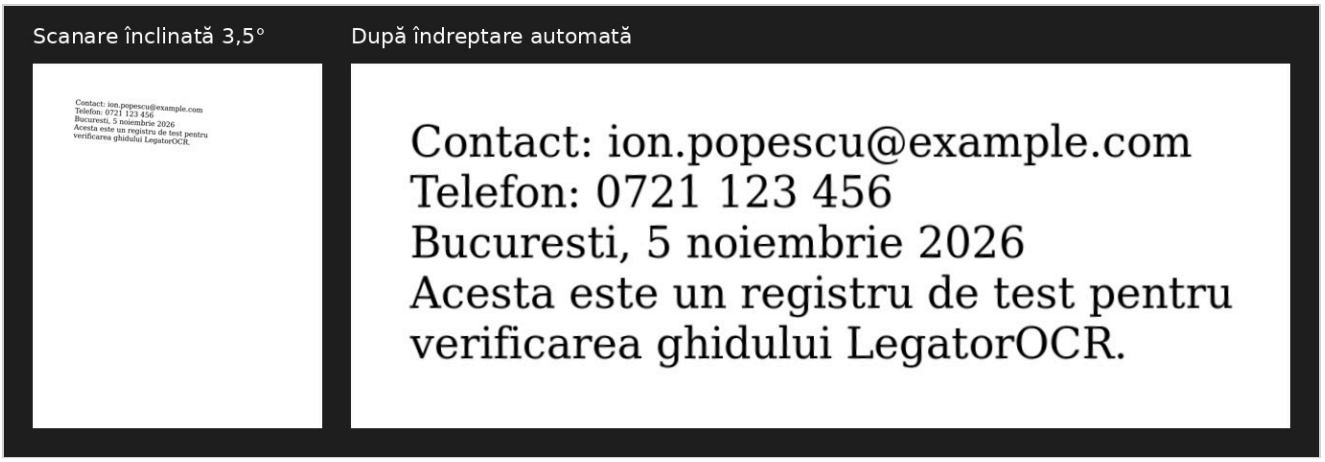
3. **Enderezado.** Se estima el ángulo de inclinación a partir de las líneas de texto y la página se gira de vuelta. El ángulo se puede fijar a mano.

4. **Cuadro de contenido.** Se encuentra la zona con texto e imágenes; las sombras del escáner y el polvo se ignoran. Todo lo que queda fuera se repinta con el color del papel.

5. **Márgenes y tamaño.** Márgenes en milímetros, opcionalmente un tamaño de página fijo o el mismo tamaño para todo el libro.

6. **Enderezado de las líneas curvas** (opcional). Para páginas de libro gruesas, con líneas curvadas junto al lomo.

7. **Iluminación** (opcional). Iguala el fondo desigual.
8. **Limpieza y binarización.** Elimina manchas, agujeros de perforación, dedos, líneas; después blanco y negro, gris, color, mixto o híbrido.
9. **PDF y OCR.** Se escribe el PDF (o las imágenes) y, si está marcado, la capa de texto.



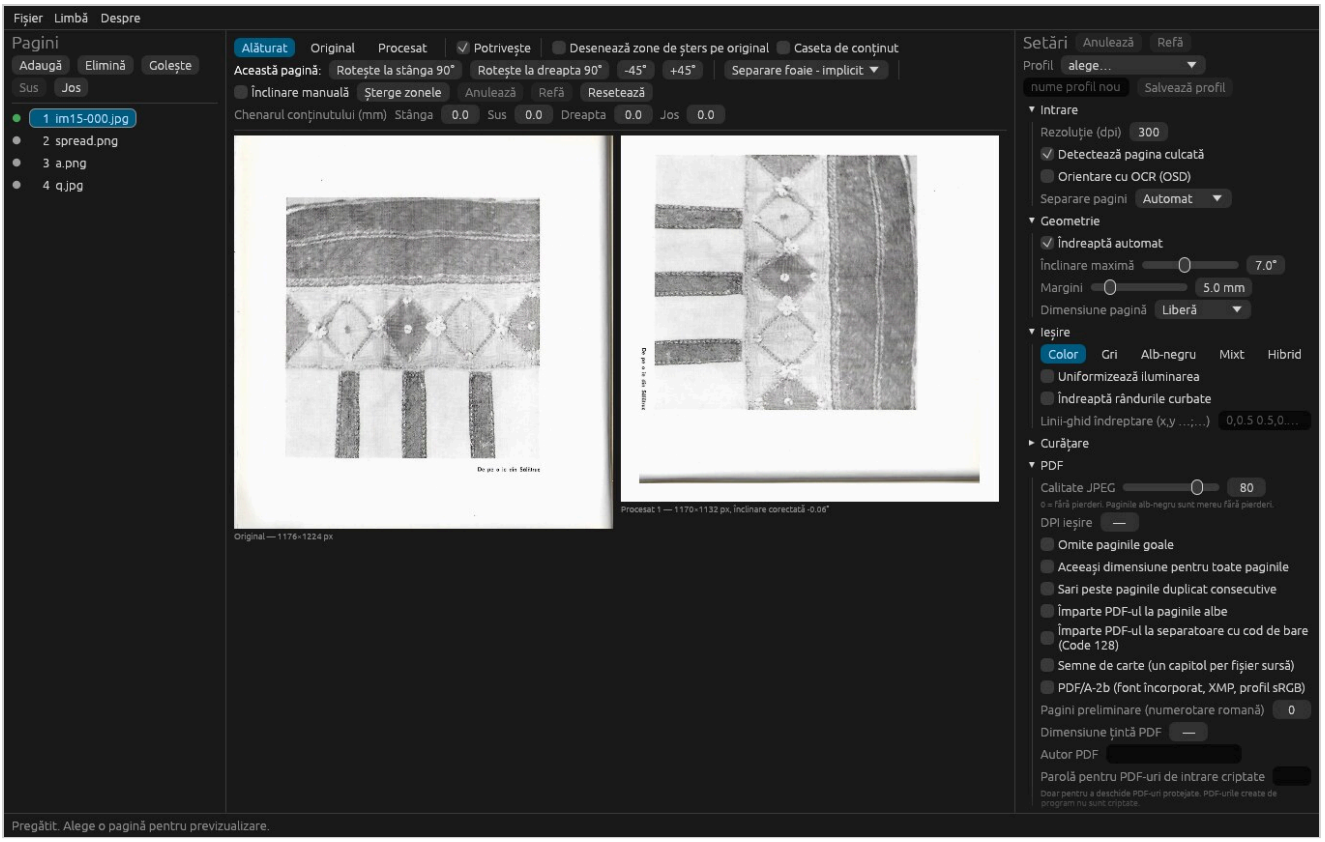
El enderezado automático: un escaneo inclinado 3,5° (hoja de prueba generada por mí) y el resultado; el programa midió -3,50°.

Reglas de trabajo que ahorran tiempo

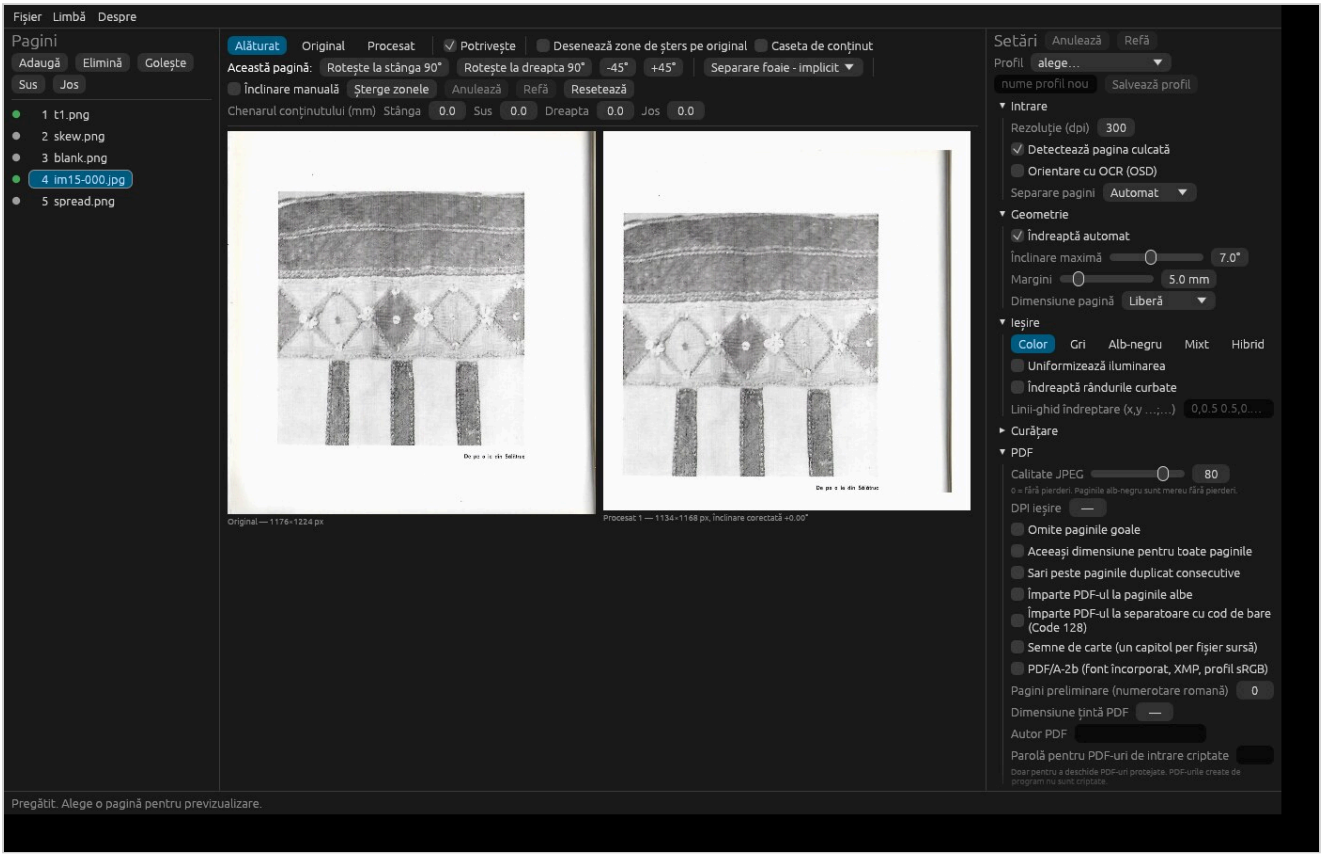
- Fije primero la **resolución** correcta (normalmente 300 dpi para texto). El programa la lee de la imagen si está entre 150 y 1200; si no, supone 300.
- Elija un **perfil** adecuado al material (sección 6) antes de tocar los ajustes individuales.
- Procese 10–20 páginas como prueba, compruebe el resultado y después lance el lote grande.
- La interfaz marca las páginas „por revisar” (página en blanco, inclinación al límite, nada encontrado, contenido pegado al borde). Pase por ellas con el botón „Siguiente”.

4. La interfaz gráfica

La ventana tiene tres zonas: la lista de páginas a la izquierda, la vista previa en el centro y los ajustes a la derecha. El menú **Archivo** contiene „Añadir imágenes”, „Añadir una carpeta”, „Abrir proyecto”, „Guardar el proyecto”, „Exportar PDF” y „Exportar las imágenes”. El idioma de la interfaz (8 idiomas) se cambia desde el menú **Idioma**.



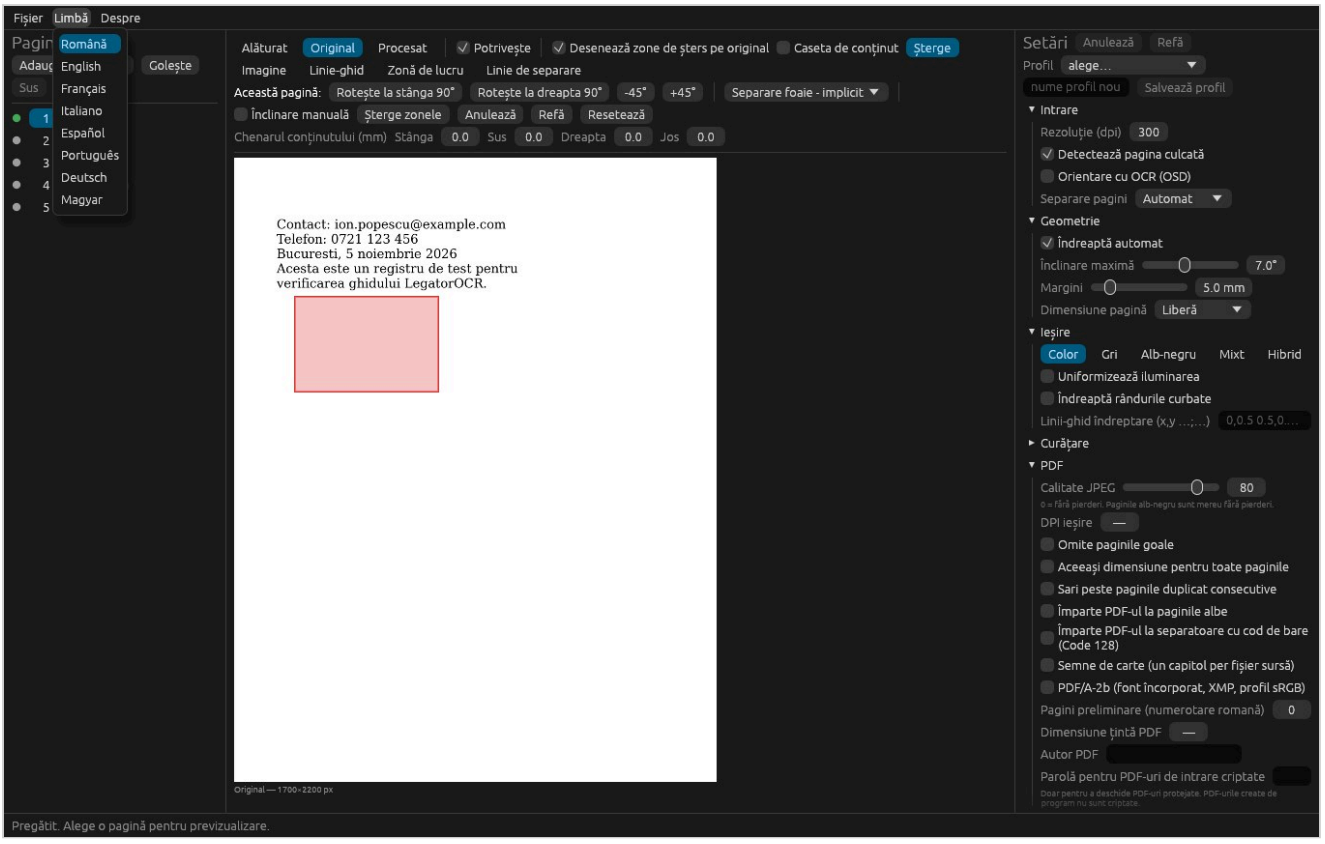
La ventana principal: la lista de páginas a la izquierda, el original y la página procesada en el centro, los ajustes a la derecha. La página del ejemplo es una foto sin texto, así que la detección de página tumbada la giró por error en pre.18 (corregido en pre.19, véase más abajo). Captura pre.18 en Linux.



La misma página en pre.19, con „Detectar página tumbada” marcado: ya no se gira (procesado 1134×1168 px, inclinación +0,00°). Captura pre.19 en Linux.

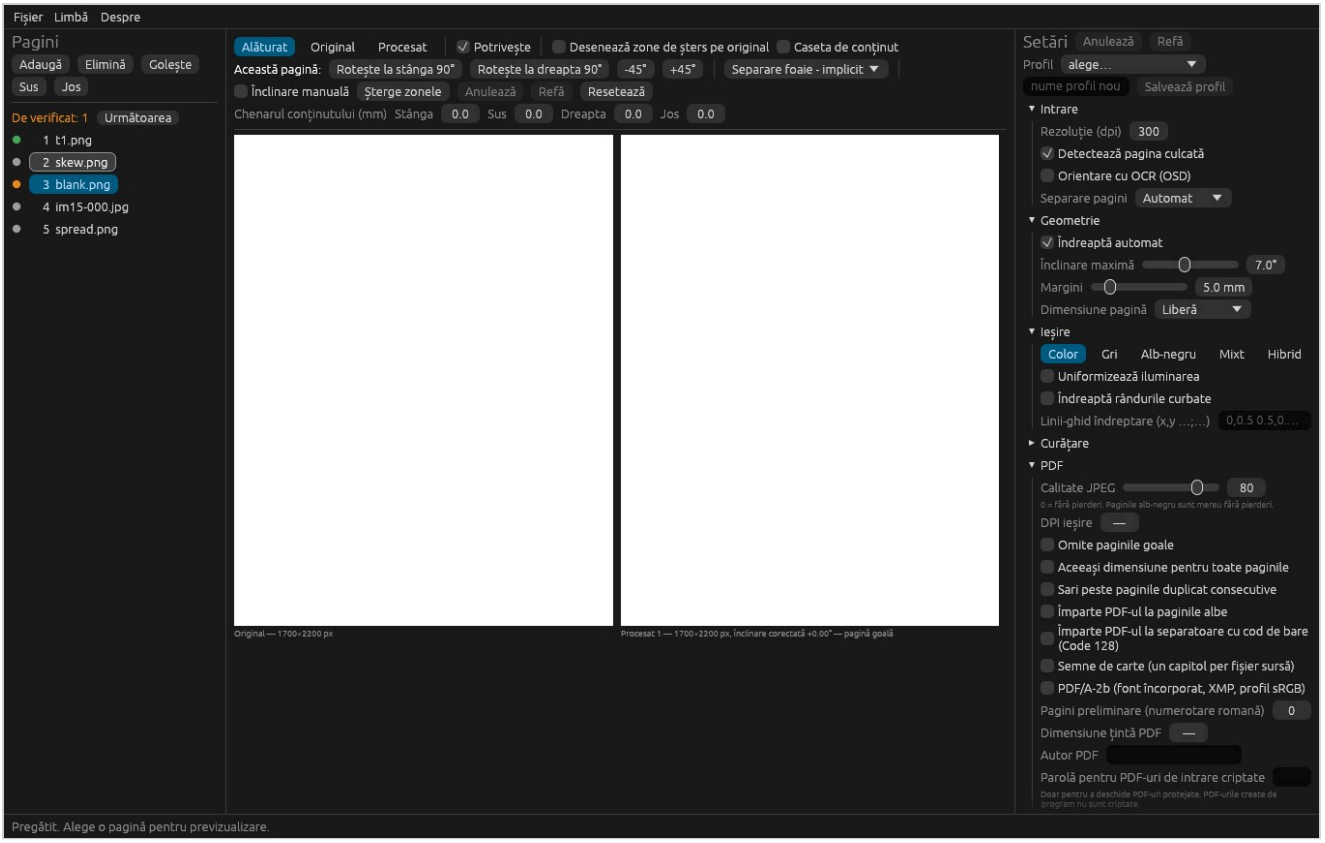


El menú Archivo: añade imágenes o una carpeta, abre y guarda el proyecto, exporta PDF o imágenes.



El menú Idioma: los ocho idiomas de la interfaz (rumano, inglés, francés, italiano, español, portugués, alemán, húngaro).

La lista de páginas

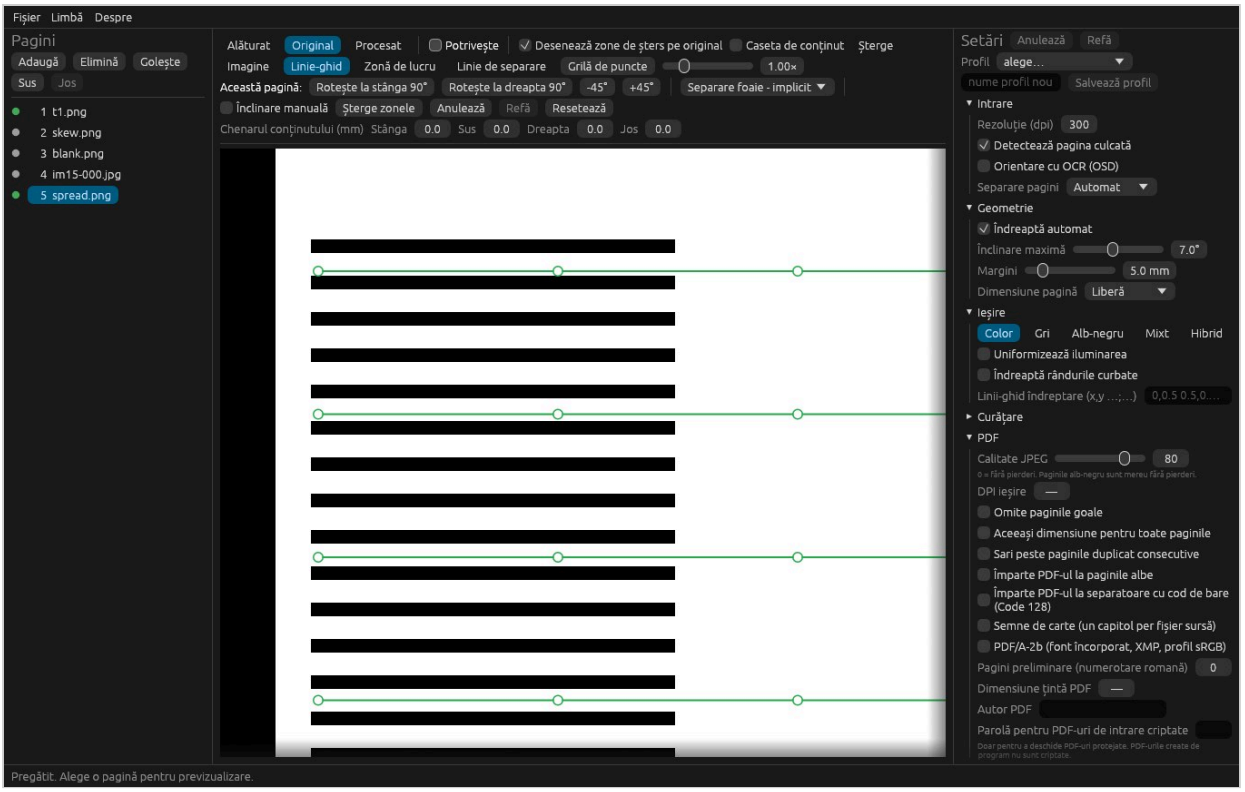


Una página completamente blanca se marca automáticamente: punto naranja en la lista y panel „Por revisar: 1” con el botón „Siguiente”.

Arrastre a ella imágenes, PDF, archivos comprimidos o una carpeta, o pulse „Añadir”. Los botones Arriba/Abajo cambian el orden, „Quitar” saca la página elegida, „Vaciar” saca todo. El orden de la lista es el orden del PDF.

La vista previa

- **Lado a lado / Original / Procesado** elige lo que se ve. Las zonas se dibujan en *Original*; el cuadro de contenido se corrige en *Procesado*.
- **Ajustar** agranda o reduce la imagen para que quepa. El deslizador de zoom (0,2×–4×) aparece solo cuando *Ajustar* está desmarcado.



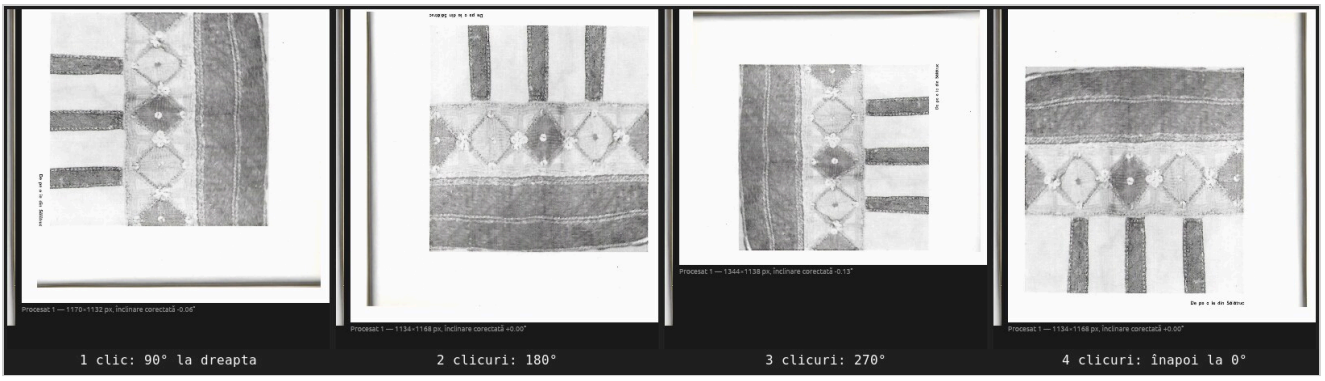
Con „Ajustar” desmarcado aparece el deslizador de zoom (aquí 1,00×).

Miniaturas (desde pre.58). Cada página es una ficha: la imagen pequeña arriba, el número y el nombre debajo, y la página elegida tiene un marco azul alrededor de ambos. Junto a la casilla «Miniaturas» se elige el tamaño: S (120×90 px), M (240×180, por defecto) o L (320×240); si el panel es más estrecho, las imágenes se reducen. Las miniaturas se leen en segundo plano, solo para las páginas visibles, así que una lista larga no ralentiza la ventana. Desmarca «Miniaturas» para la lista compacta de una línea por página.

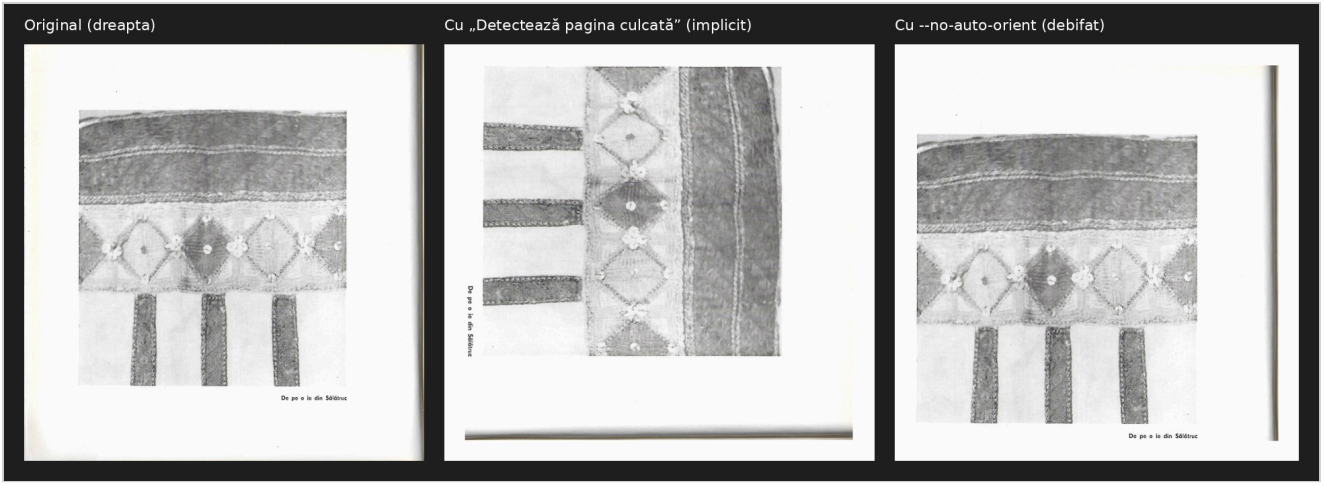
La barra „Esta página”

Aquí se corrige solo la página elegida: giro a la izquierda o a la derecha de 90°, pasos de ±45°, inclinación manual, modo de separación de la hoja (predeterminado, automático, por la mitad, desactivado), el marco del contenido en milímetros (izquierda, arriba, derecha, abajo; los valores positivos lo agrandan) y „Restablecer”. **Deshacer** y **Rehacer** (Ctrl+Z, Ctrl+Y) valen para todos estos comandos, no solo para las zonas.

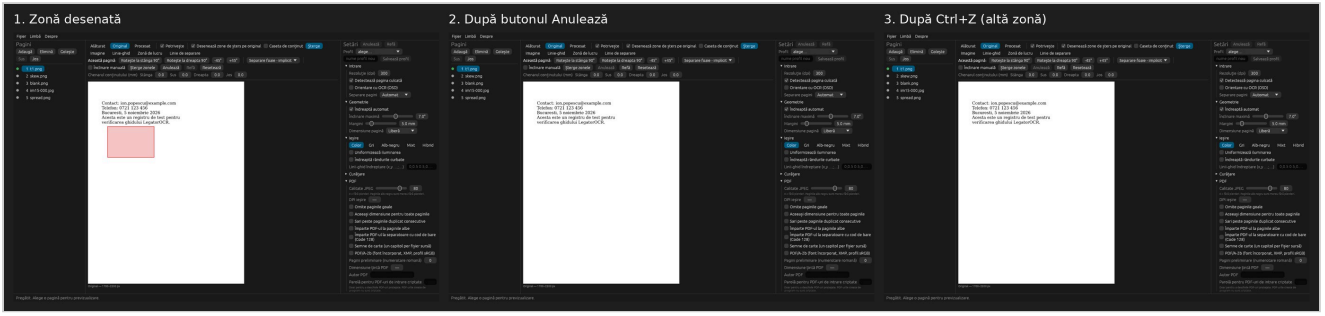
El giro manual bloquea la orientación automática (desde pre.18): después de pulsar un botón de giro o ±45°, la página ya no la gira la detección de página tumbada ni el OSD, ni siquiera a 0°. „Restablecer” le devuelve la orientación automática. Si una página con fotos está girada por error desde el principio, pulse el giro cuatro veces (o desmarque „Orientación con OCR (OSD)” y „Detectar página tumbada” en los ajustes, en Entrada).



Cuatro clics seguidos en „Girar a la derecha 90°”: 90°, 180°, 270°, y de nuevo a 0°, sin saltos. Captura pre.18 en Linux. En Windows 11 no pude comprobarlo.



La misma página (página 15 del PDF del probador) y los mismos ajustes, salvo la detección: en pre.18, con „Detectar página tumbada” marcado (predeterminado), el programa la giraba 90° aunque el original está derecho (desde pre.19–20 ya no la gira); con --no-auto-orient (o desmarcado en los ajustes) sale derecha. Comprobado en la línea de comandos; en la ventana vi el giro en pre.18 y su ausencia en pre.19.

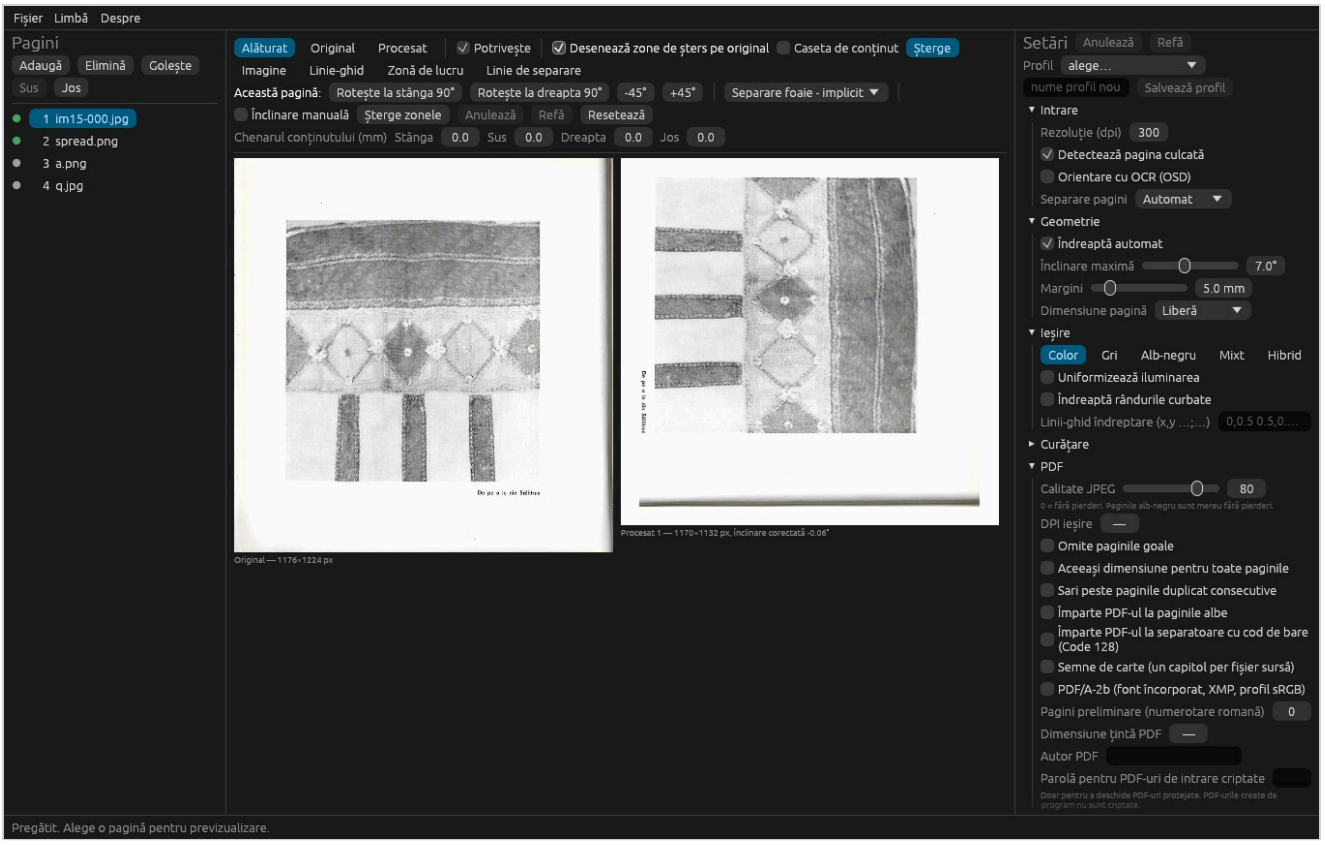


Deshacer (el botón) y Ctrl+Z (con la ventana en primer plano) quitan la última zona dibujada. Comprobado en la ventana.

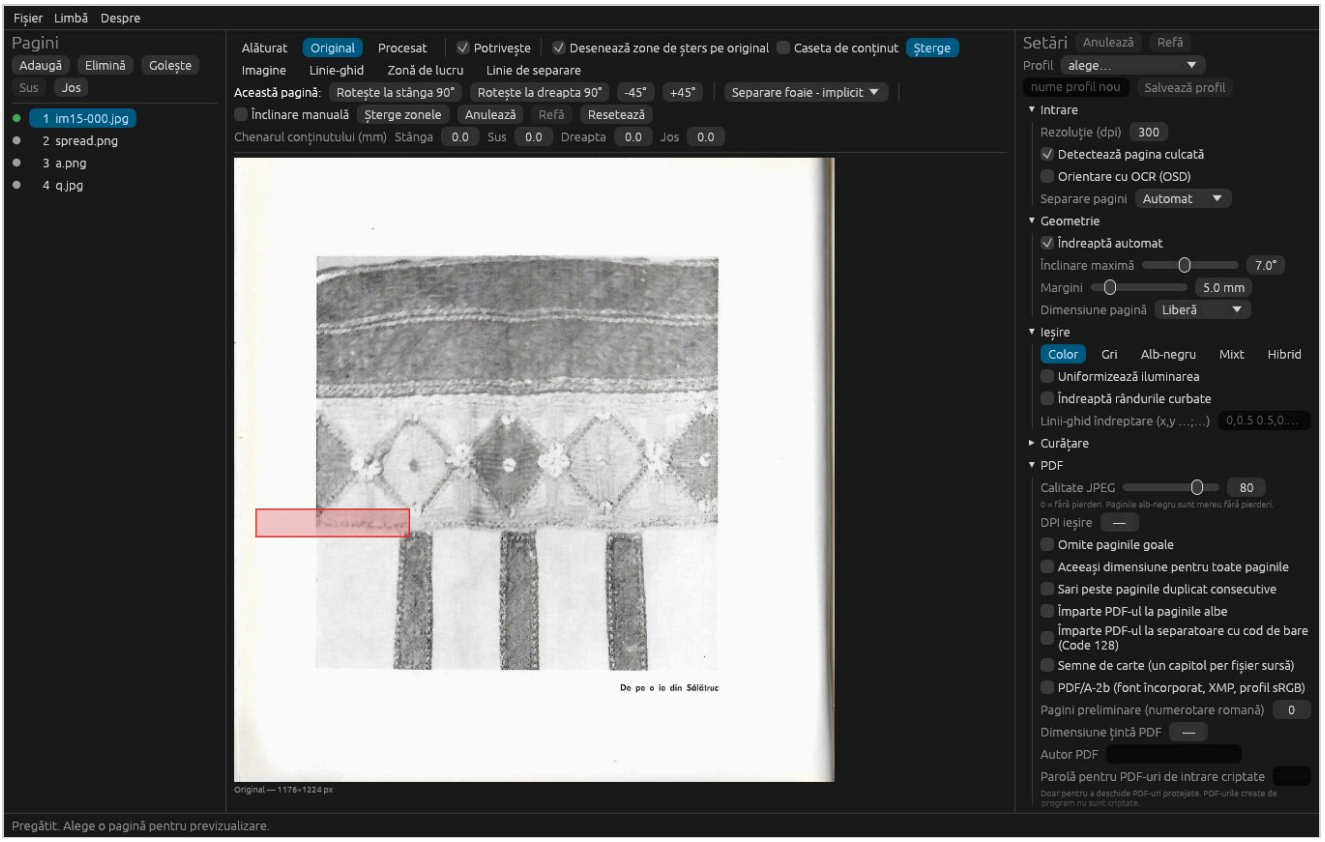
Páginas boca abajo. El botón «180°» gira la página elegida (Ctrl+Z lo deshace). Además, en textos de escritura latina, el programa detecta solo las páginas boca abajo, tras enderezarlas: en el texto, los trazos ascendentes y las mayúsculas sobresalen por encima de la línea más que los descendentes por debajo, y en una página girada el equilibrio se invierte. Solo decide si la página tiene al menos 12 líneas y al menos el 70 % de ellas «votan» igual; si no, no toca nada. No funciona con otras escrituras y no toca las páginas que giraste a mano. Comprobado en páginas sintéticas y algunas fotografías; si una página sigue boca abajo, pulsa «180°».

Zonas, guías y el cuadro de contenido

Marque „Dibujar zonas de borrado sobre el original”; aparecen cinco tipos de dibujo (Borrar, Imagen, Línea guía, Área de trabajo, Línea de corte):

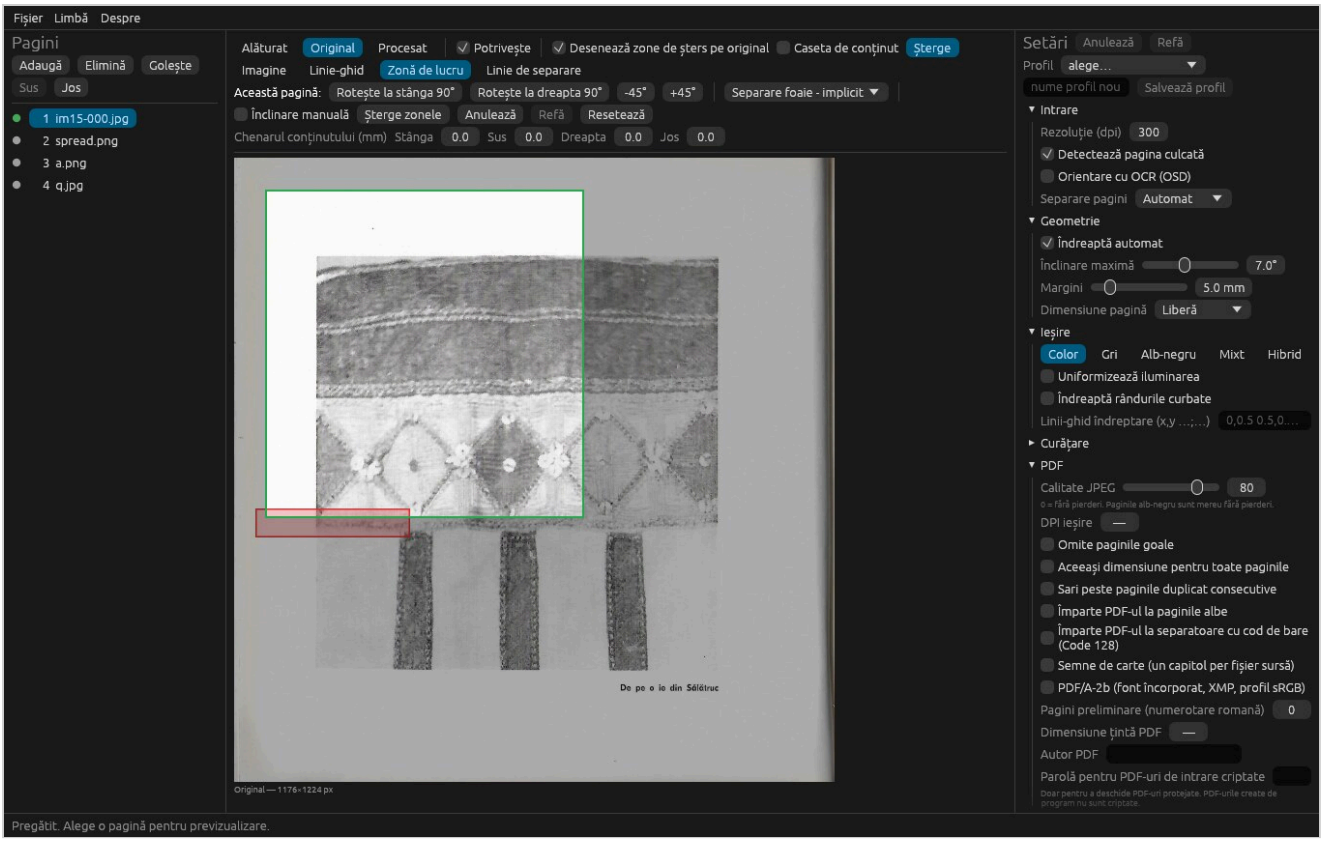


Con „Dibujar zonas de borrado sobre el original” marcado aparecen los tipos de zonas: Imagen, Línea guía, Área de trabajo, Línea de corte (y Borrar, el tipo predeterminado).

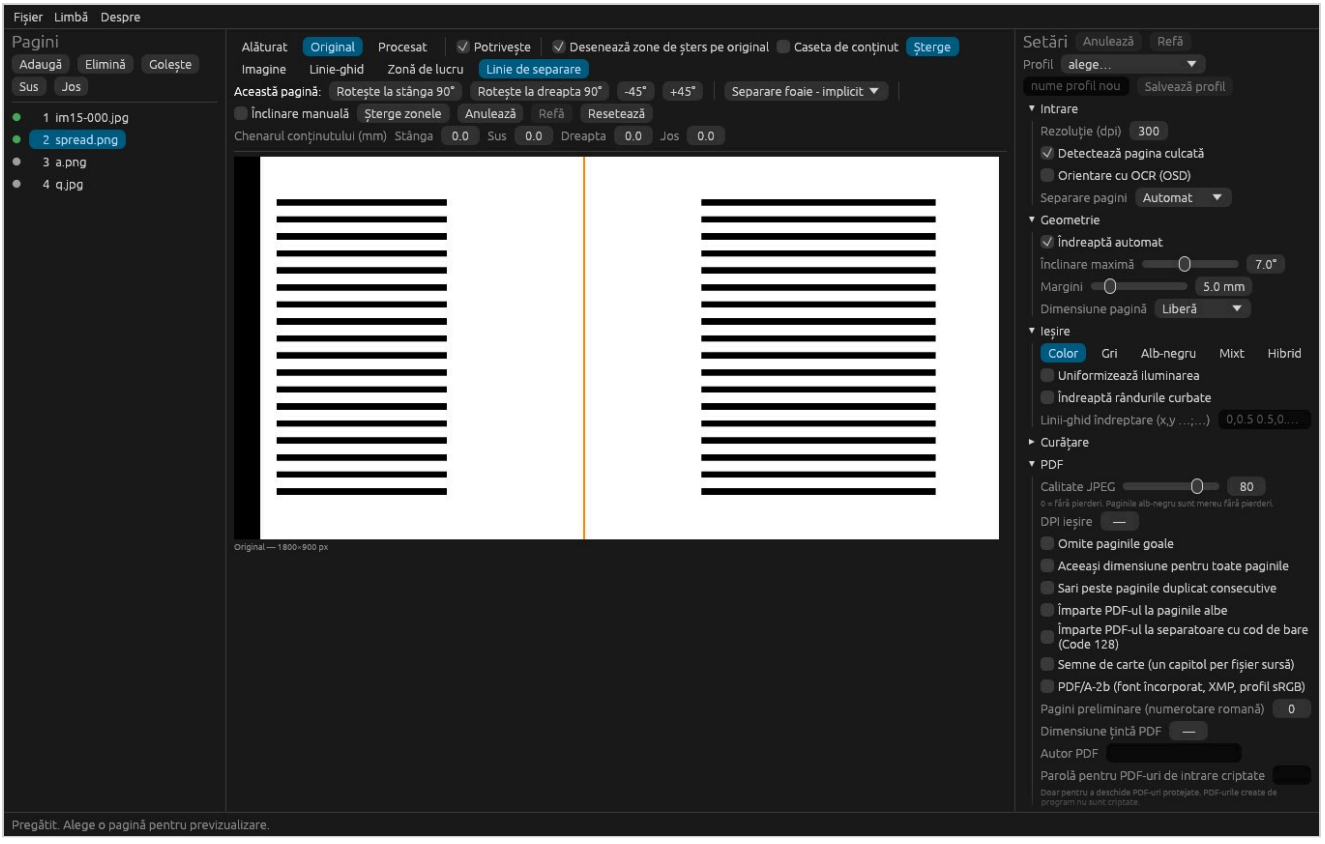


Una zona de borrado (roja) trazada con el ratón sobre el original, en la vista Original.

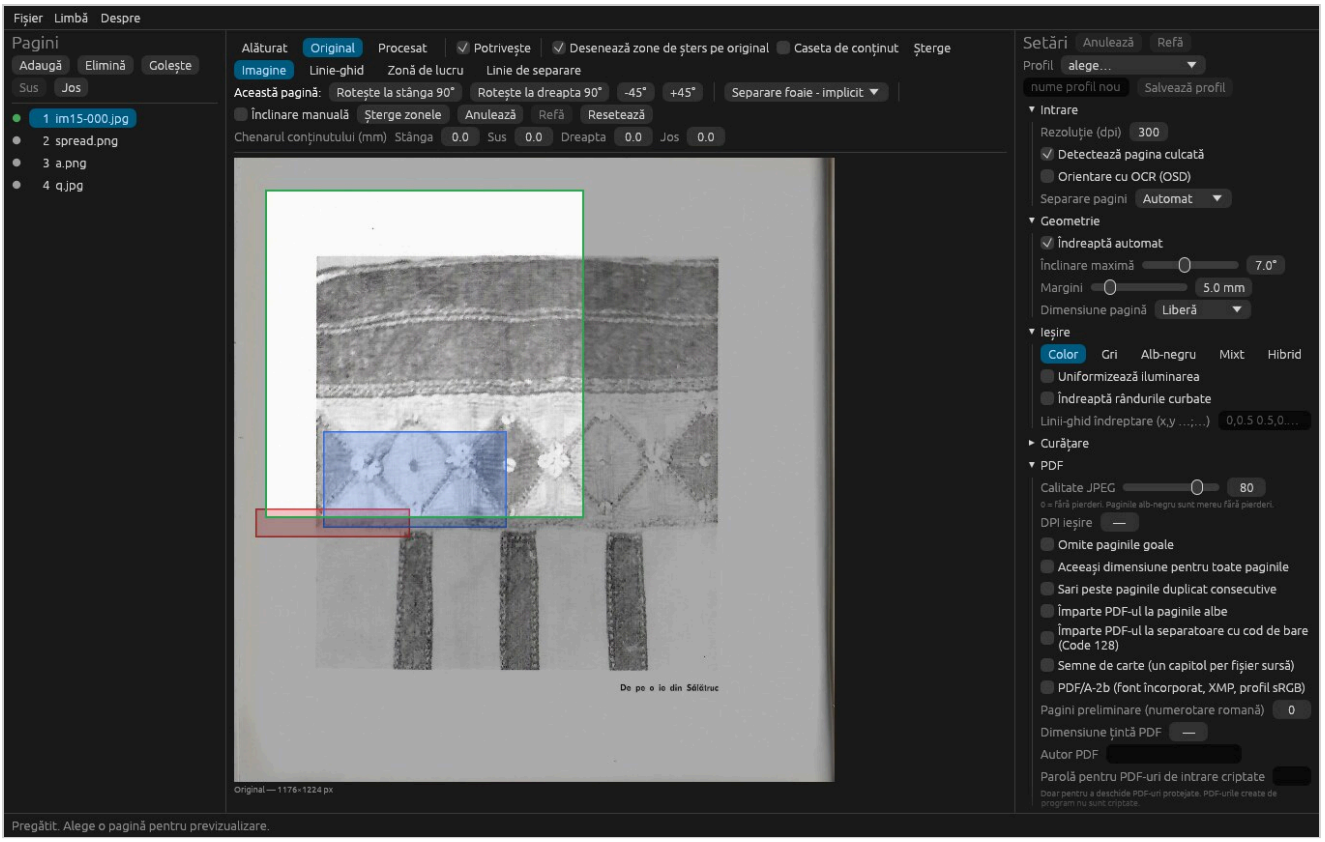
Tipo	Cómo se usa	Para qué sirve
Borrar	Arrastre un rectángulo sobre el original. El clic derecho sobre él lo elimina. Arrastre una esquina para redimensionarlo.	Mancha, sello, nota de alguien, borde con sombra
Imagen	Igual que „Borrar”.	Indica al programa que la zona es una imagen, no texto (se queda en color en el modo mixto)
Línea guía	Arrastre libremente a lo largo de una línea curvada. Arrastre un nodo para moverlo; el doble clic en la línea añade un nodo, el doble clic en un nodo lo elimina; el clic derecho en la línea la elimina.	Endereza la página según las líneas que ha trazado



El área de trabajo (marco verde): todo lo que queda fuera se descarta, y la zona restante se ve en la página procesada. Tiene además una zona de borrado (roja).



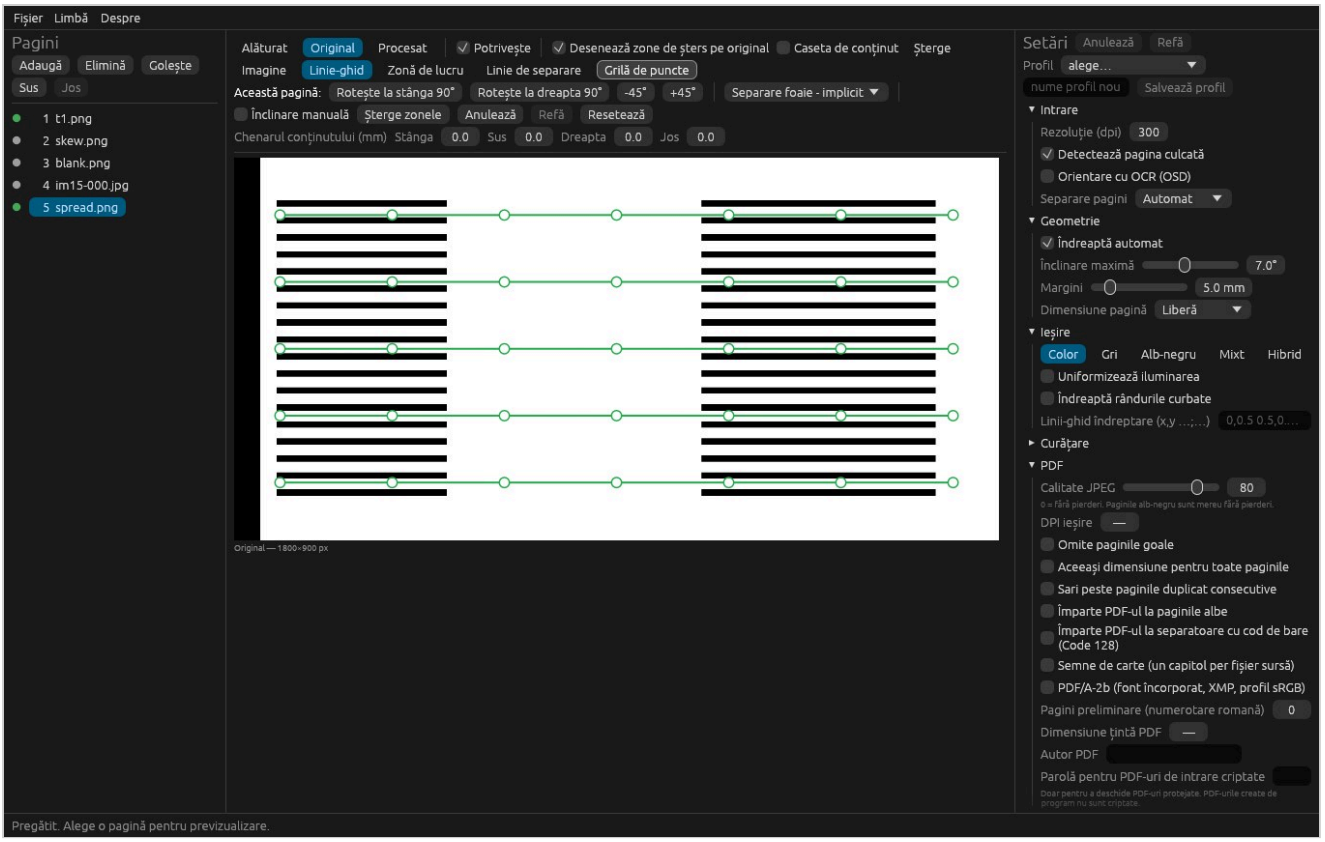
La línea de corte (naranja) movida con el ratón sobre una hoja doble. El ejemplo es una hoja de prueba sintética, con líneas en lugar de texto.



Una zona de imagen (azul) dibujada sobre el original. En el modo Color no cambia nada; el efecto se ve en el modo Mixto (figura siguiente).



La misma página y la misma zona de imagen (azul): en el modo Mixto la zona permanece gris (izquierda), en el modo Blanco y negro todo se vuelve blanco y negro (derecha). La página aparece girada 90° por la detección de página tumbada (véase más arriba).



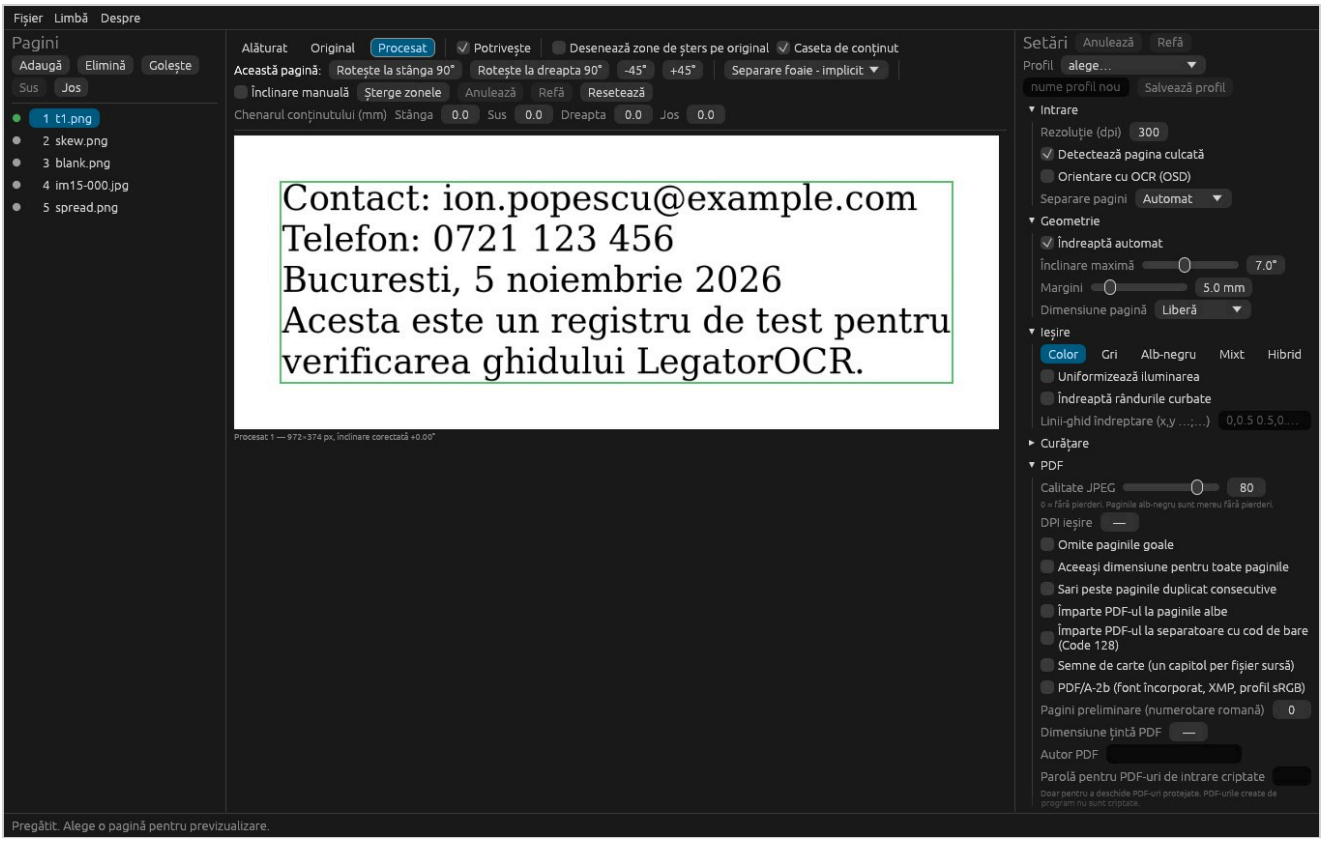
„Cuadrícula de puntos” en Línea guía: 5 líneas de 7 puntos cada una, sobre las líneas de texto.

Cuadrícula de puntos (en *Línea guía*) añade 5 líneas de 7 puntos cada una, sobre las cuales arrastra los puntos hasta las líneas de texto. Un segundo clic en el botón no vuelve a añadir la misma cuadrícula. Si ya ha movido puntos, se añade una cuadrícula nueva junto a la movida.

Área de trabajo (desde la edición pre.18): arrastre un rectángulo sobre el original; todo lo que queda fuera se pinta con el color del papel antes de cualquier medición, de modo que un borde oscuro o la página vecina dejan de importar. El clic derecho sobre el original la elimina. En la línea de comandos: `--work-area X,Y,L,H` (milímetros).

Línea de corte (desde la edición pre.18): con un clic o arrastrando sobre el original se mueve la línea vertical naranja; la hoja doble se corta allí, no por la mitad ni por el lomo. Desde pre.21 funciona con cualquier giro; en las hojas giradas 90° o 270° la línea corta en horizontal y las páginas salen una debajo de la otra (primero la página izquierda del original). El clic derecho la elimina. En la línea de comandos: `--cut-at 0.45`.

El cuadro de contenido (la casilla del mismo nombre) muestra un marco verde sobre la página procesada. Arrastre los lados para ensanchar o estrechar la zona conservada. En una hoja cortada en dos páginas, solo cambia la página donde se arrastra el marco.



El cuadro de contenido (marco verde) sobre la página procesada.

Páginas torcidas, corte oblicuo y ajustes por página

Tres herramientas para hojas fotografiadas a mano:

- **Línea de corte oblicua.** Con «Dibujar zonas de borrado sobre el original» y el tipo Línea de corte, el control «Inclinación de la línea» (de −20° a 20°) inclina la línea; cada página conserva su lado de la línea oblicua y el otro lado se pinta con el color del papel. Clic derecho sobre la línea: la elimina y devuelve la inclinación a cero. En la línea de comandos: `--cut-angle GRADOS`.
- **Corrección trapezoidal.** Dos controles de la barra «Esta página» («Trapecio arriba–abajo», «Trapecio izquierda–derecha», ±30 %) enderezan antes del corte una hoja fotografiada en ángulo. El botón **Trapecio auto** (tras dividir las páginas) mide cada página — inclinación de las líneas de texto y ancho del texto arriba y abajo — y guarda una corrección solo para esa página. Es prudente a propósito: si hay muy pocas líneas o las medidas se contradicen, deja la página como está. Revisa el resultado, con Deshacer a mano. Los botones −45°/+45° se mantienen. En la línea de comandos: `--keystone-v` y `--keystone-h` (porcentajes).
- **Ajustes por página.** «Ajustes para: Todas las páginas / Solo esta página», sobre Salida y Limpieza, aplica el modo de salida, el umbral, la eliminación de motas y los demás ajustes de limpieza a una sola página de una hoja cortada; el marco verde del contenido cambia solo la página donde se arrastra. En un proyecto: `page1.CLAVE = VALOR` / `page2.CLAVE = VALOR` bajo [sheet]. Un clic en una página procesada la selecciona (marco azul): el modo de salida (gris, blanco y negro, mixto), la limpieza, la corrección trapezoidal, el cuadro verde y los lápices OCR actúan entonces solo sobre ella. Las zonas OCR dibujadas se quedan con esa página (`page1.page_ocr_zones`, `page_ocr_ignore`).

La barra bajo la vista previa incluye el cuadro de contenido, los lápices OCR y el **Auto-lápiz OCR** (por separado para la página izquierda y la derecha): pone la zona OCR sobre el contenido de esa página.

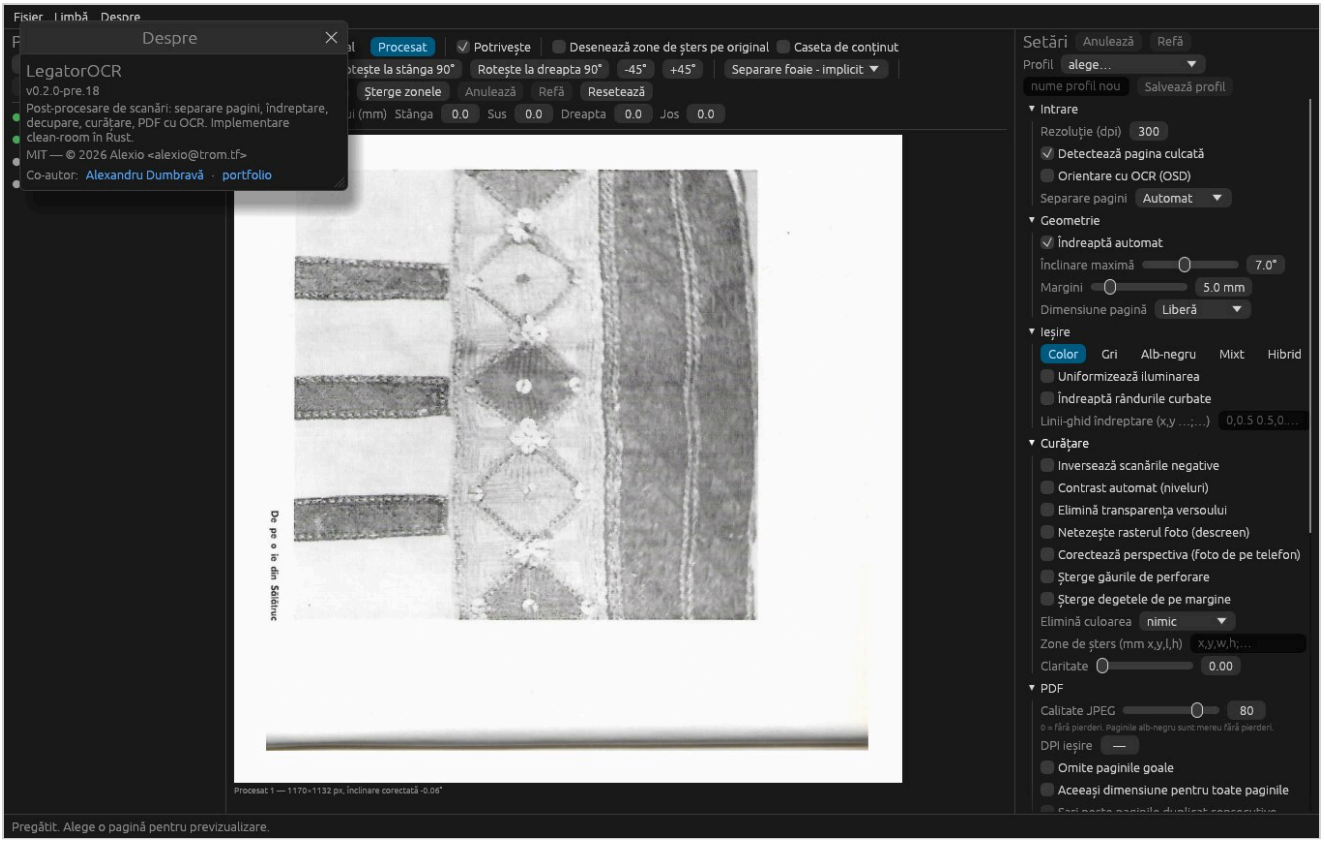
La inclinación manual actúa sobre la página seleccionada (izquierda o derecha) de una hoja cortada: cada página puede tener su propio ángulo (`page1.page_skew`, `page2.page_skew`).

Zoom: en la barra inferior, **A+** / **A-** agrandan o reducen toda la interfaz (también Ctrl + / Ctrl −) y **Auto** la ajusta al tamaño de la ventana. La ventana arranca maximizada con zoom automático, para que el texto se vea grande y llene la pantalla; la elección se conserva.

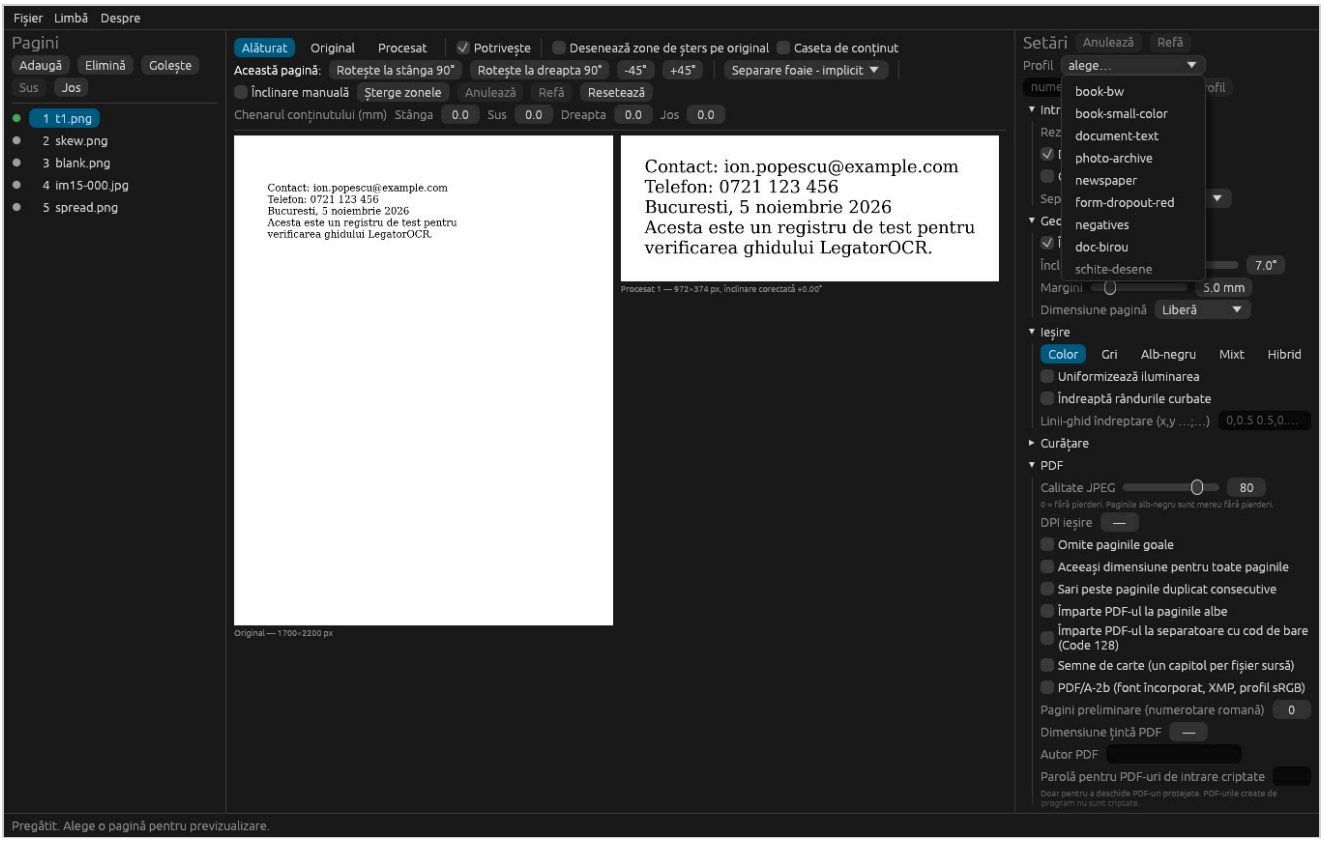
Los tamaños de página incluyen ahora A2–A6, B3–B6, Letter, Legal y Tabloid (`--page-size` acepta los mismos nombres). Lápices OCR sobre las páginas procesadas: verde (zona OCR), rojo (zona ignorada), violeta (tabla, leída como un bloque fila por fila; `--ocr-zone X,Y,W,H#table`).

Los ajustes de la derecha

Se agrupan por secciones: Entrada, Geometría, Salida, Limpieza, PDF, OCR, más los perfiles. La sección 6 explica qué hace cada una.



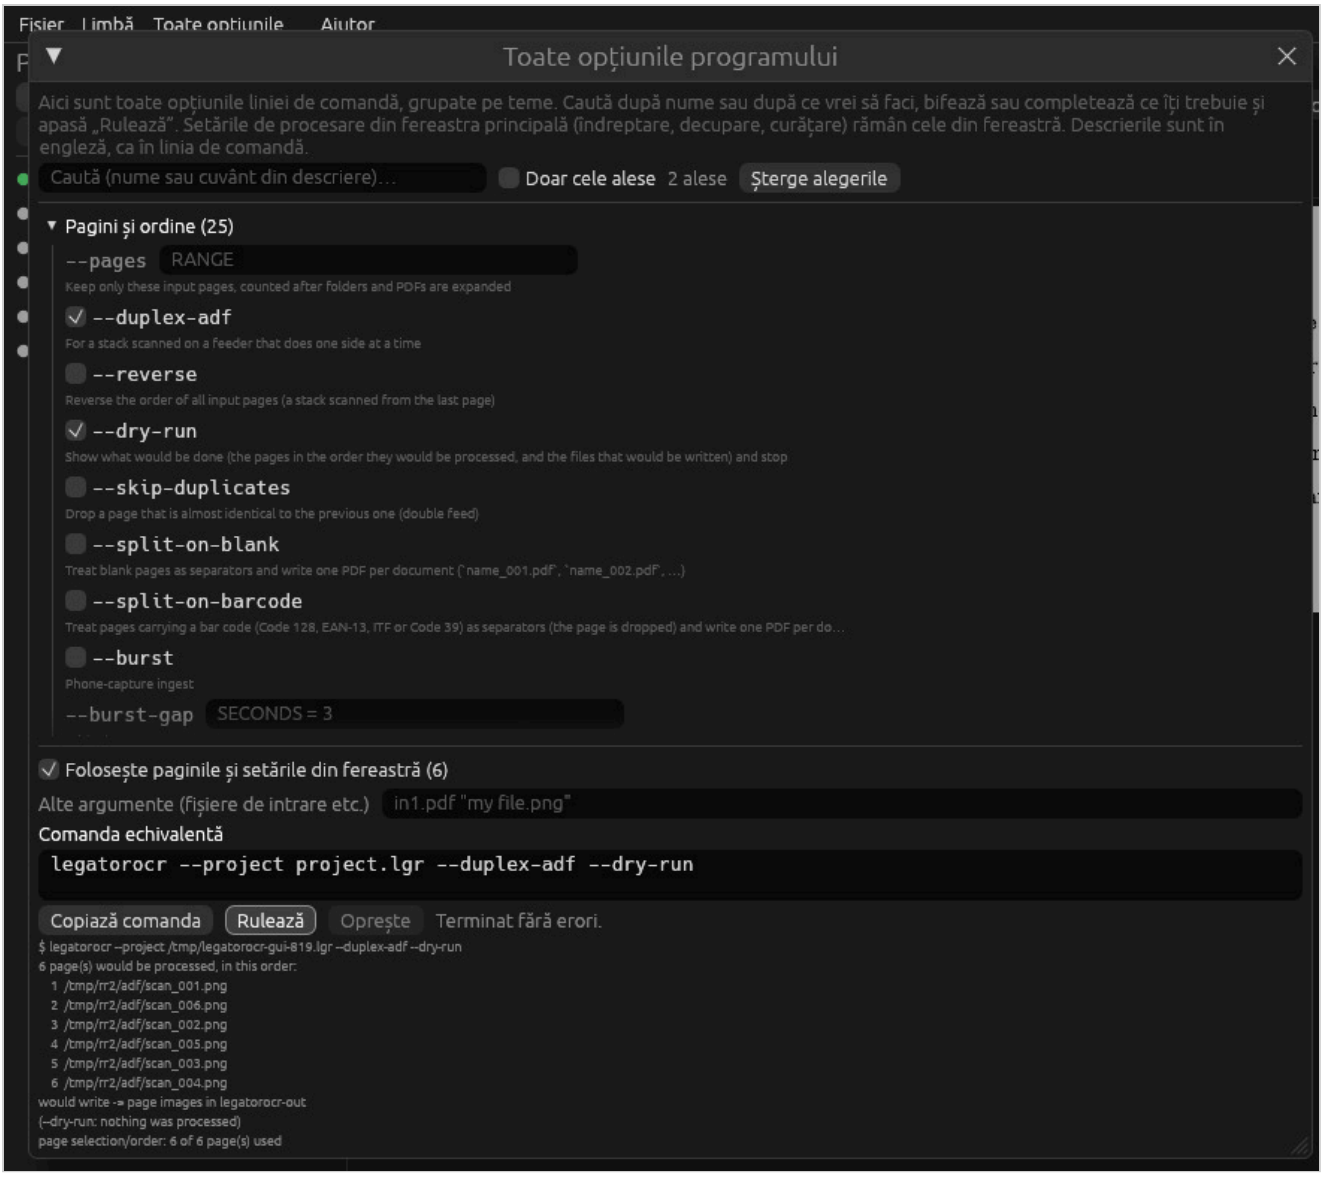
La sección Limpieza de los ajustes, desplegada: inversión de escaneos negativos, contraste automático, perspectiva, borrado de agujeros de perforación, zonas de borrado como números.



La lista „Perfil” de los ajustes (los perfiles integrados; los suyos aparecen en el mismo lugar tras „Guardar perfil”).

Todas las opciones y la guía de uso

El botón **Todas las opciones…** de la barra superior abre una ventana con **todas** las opciones de la línea de comandos (más de 200), agrupadas por temas: páginas y orden; enderezado, recorte y limpieza; salidas (PDF, imágenes, documentos); OCR y texto; archivo, firma y verificación; búsqueda y comparación; lotes, sistema y módulos. La lista se lee del propio programa de línea de comandos entregado con la ventana, por lo que siempre coincide con la edición que tiene.



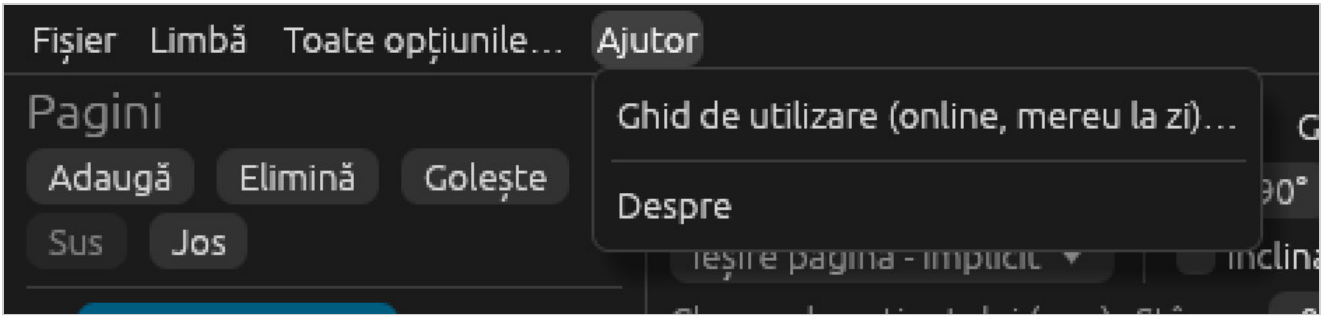
La ventana „Todas las opciones”, con el grupo „Páginas y orden” abierto, `--duplex-adf` y `--dry-run` marcados y el resultado de la ejecución: el orden en que se procesarían las seis páginas de la pila (páginas de prueba hechas por mí).

- **Buscar** por nombre (`pdf`, `dry`) o por una palabra de la descripción; los grupos con resultados se abren solos. „Solo las elegidas” muestra lo que ha marcado o rellenado.
- Los cuadros vacíos no se envían: una opción con valor entra en el comando solo cuando escribe algo (o elige de una lista). El botón **Elegir…** abre el diálogo de archivos o de carpetas. En las opciones que se pueden repetir (por ejemplo `--erase`) escriba un valor por línea.
- **Usar las páginas y los ajustes de la ventana** (marcado por defecto): el comando recibe las páginas cargadas, con los ajustes de cada una, mediante un proyecto temporal. Los ajustes de procesamiento de la ventana principal (enderezado, recorte, limpieza) tienen prioridad; aquí se completan las salidas y las funciones especiales. Desmárquelo para comandos sin páginas (`--doctor`, `--verify-sums`) o escriba los archivos de entrada en „Otros argumentos”.
- **El comando equivalente** se actualiza a medida que elige; puede copiarlo y usarlo en el terminal o en scripts. **Ejecutar** lo ejecuta y muestra el resultado debajo; **Detener** lo

interrumpe. Las rutas relativas lo son respecto a su carpeta personal.

- Las descripciones de las opciones están en inglés, como en la línea de comandos; el resto de la ventana está en el idioma elegido.

El menú **Ayuda** tiene el enlace a esta guía: *Guía de uso (en línea, siempre al día)* abre la última versión publicada en legatorocr.chiuta.ro, y *Guía de esta edición* (aparece cuando el archivo PDF está junto al programa, como en los archivos publicados) abre la copia entregada con el programa. La guía se rehace en cada edición, y la publicación de una edición se detiene si la guía no menciona su versión.



Comprobado: la ventana, la búsqueda, el marcado, la ejecución de un comando con las páginas de la ventana (la captura de arriba) y la apertura del menú Ayuda, en Linux, en una pantalla virtual. No comprobado: Windows, macOS y arm64; la apertura efectiva de la guía en un navegador (solo comprobé el menú); los diálogos „Elegir…”; las traducciones de los textos nuevos de la ventana (escritas automáticamente).

Colecciones

Una colección reúne periódicos, revistas, libros y similares en un solo archivo `.lgrcol` (JSON). Guárdelo en la carpeta de los escaneos: las rutas del archivo se escriben relativas a él cuando el destino está bajo una carpeta común, de modo que la carpeta puede moverse o copiarse. Cada elemento tiene tipo, título, número o volumen, fecha o año, idiomas, fuentes (imágenes, una carpeta de imágenes, un PDF, un proyecto `.lgr` guardado), el PDF resultante, un perfil, un estado (por hacer, procesado, OCR hecho, verificado), número de páginas, etiquetas y notas.

```
legatorocr collection new Archive/ --name "Old papers"
legatorocr collection add Archive/old_papers.lgrcol --folder Archive/scans
legatorocr collection list Archive/old_papers.lgrcol
legatorocr collection run Archive/old_papers.lgrcol --out Archive/pdf
legatorocr collection search Archive/old_papers.lgrcol "Scînteia"
legatorocr collection reindex Archive/old_papers.lgrcol
legatorocr collection set Archive/old_papers.lgrcol i1 --status checked --tags "1977, youth"
legatorocr collection remove Archive/old_papers.lgrcol i2
```

- `add --folder`: cada PDF, proyecto `.lgr` y subcarpeta de imágenes se convierte en un elemento. Título, tipo, fecha y número se deducen del nombre: `scinteia_tineretului_1977_09_8801.pdf` da un periódico, «Scinteia Tineretului», 1977-09, n.º 8801. Es solo una suposición (los nombres de archivo no llevan diacríticos; el tipo se apoya en unas pocas palabras clave y en la numeración: una fecha completa o un número de 500 o más se toma por periódico); corríjala en la ventana. Para `nombre_año_mes_número` un número de tres o más cifras es el número de la edición (`..._1977_09_8801`); un número de una o dos cifras justo después del mes es un día solo si es un día real de ese mes y, cuando es la

última parte, el nombre no dice revista o libro (`gazeta_1914_05_12` es el 12 de mayo, `revista_sinteza_1985_03_12` es el número 12, `..._1977_09_12_8801` es el día 12, número 8801).

- `run` procesa los elementos con estado «por hacer», cada uno con su perfil (si no, el de la colección, si no, los ajustes predeterminados), con el mismo código que la línea de comandos y la ventana (`run_export`). Un elemento que falla (fuente ausente, perfil desconocido, página ilegible) se marca con el motivo y los demás siguen; el archivo de la colección y el índice se guardan tras cada elemento, así que una cancelación o un fallo no pierde lo hecho. Los PDF van junto al archivo de la colección o a `--out`. Con OCR (activado por defecto; `--no-ocr` lo apaga) el texto reconocido de cada página va a `NOMBRE.lgrindex`; el idioma del OCR sale de los idiomas del elemento, si no de `ocr_langs` del perfil, si no el rumano. Un elemento fallido no se reintenta salvo con `--retry-failed` o `--item ID`.

- `search` busca en ese índice. Mayúsculas, diacríticos y la antigua ortografía rumana no cuentan (`Scînteia` encuentra `Scânteia`, `sînt` encuentra `sunt`). Muestra elemento, página y un fragmento: primero las páginas con las palabras seguidas, luego (marcadas) las que tienen todas las palabras pero separadas.

- `reindex` (alias `index`) lee la capa de texto de los PDF en el mismo índice **sin procesar nada de nuevo**: para un elemento cuya fuente es un solo PDF que ya tiene texto (PDF con búsqueda de otro programa, o hechos por LegatorOCR) y para los elementos procesados antes. Lee el PDF hecho por `run` si existe, si no la única fuente PDF del elemento; el estado y los archivos del elemento no cambian. Un escaneo sin texto se avisa (`no text layer`) y no se indexa (procéselo con OCR); un elemento con varias fuentes, o solo imágenes, no tiene PDF que leer. `--item ID` lo restringe. El texto se toma como lo tiene el PDF (fuentes con tabla ToUnicode, como las escriben LegatorOCR, Tesseract, ABBYY, Word …); un PDF cuyo texto no se puede decodificar no da nada o da texto sin sentido.

- `set ARCHIVO ELEMENTO` cambia `--title --issue --date --kind --profile --status --tags --notes` (solo los dados; un texto vacío borra el campo; un valor erróneo no cambia nada; `--status todo` hace que el próximo `run` procese de nuevo el elemento). `remove ARCHIVO ELEMENTO...` saca elementos de la colección y del índice; sus PDF y archivos fuente no se tocan.

- La ventana **Colecciones…** (menú Archivo, o Ctrl+K): una tabla con la letra del tipo, título, número/fecha, páginas y una etiqueta de estado (color y texto), con filtro y orden; los detalles a la derecha; Añadir archivos, Añadir carpeta, Procesar la selección, Procesar todo lo pendiente (con progreso y Cancelar), Indexar el texto / Indexar todo (el `reindex` de arriba), Abrir PDF, Mostrar carpeta; un cuadro de búsqueda en toda la colección con resultados en los que se puede pulsar. El doble clic en un resultado abre el PDF en esa página cuando el programa PDF predeterminado del ordenador es uno que se sabe que respeta el número de página (Linux: Okular, Evince, Zathura, MuPDF, Firefox, Chrome, Chromium, Edge; Windows: SumatraPDF, Adobe Acrobat/Reader, Chrome, Edge, Firefox; averiguado preguntando al sistema qué programa abre los PDF); si no, el PDF se abre normalmente y el número de página se escribe en la línea de estado. El procesamiento desde la ventana usa el Tesseract fijado en los ajustes de la ventana principal (el perfil de un elemento aún puede nombrar otro). Sus textos existen en los 8 idiomas de la ventana.

Verificado: pruebas unitarias (adivinar el nombre, incluidos los patrones año-mes-número, rutas relativas, archivos dañados, búsqueda con diacríticos, un lote que sigue tras un fallo y tras un pánico, cancelación, el archivo de índice con y sin su caché, archivos de índice del formato antiguo, un índice truncado o dañado, reindexar un PDF con y sin texto, `set` y `remove`, los

comandos de visor de cada plataforma), pruebas del programa real y una ejecución con Tesseract real sobre dos páginas sintéticas, también tras mover la carpeta. **Medido** en un índice sintético de 5000 elementos × 20 páginas (100.000 páginas de 350 palabras, archivo de texto de 357 MB; compilación release en una máquina compartida de 2 núcleos, así que solo órdenes de magnitud): la apertura tarda 62 ms con la caché de las listas de palabras (38 MB) y 12 s sin ella (primera apertura, o el archivo fue cambiado por otro programa); 82 MB de memoria tras abrir (el índice anterior, entero en memoria: 34 s y unos 480 MB); una búsqueda de una palabra 40–130 ms, de dos palabras muy frecuentes que nunca van juntas 3 s.

Límites: la ventana se escribió y compiló, pero nadie la ha visto en pantalla ni ha pulsado en ella, así que sus botones nuevos, la línea de estado y la apertura en una página no se han probado; los comandos de visor solo se prueban como texto, nunca se ejecutaron con Okular, Acrobat u otros; en macOS y con cualquier otro programa PDF la página no se transmite, solo se muestra en la línea de estado; la página de un resultado es la del PDF leído (en un elemento procesado, el PDF hecho por `run`), así que tras sustituir ese PDF por uno con otras páginas ejecute `reindex`; `reindex` no hace OCR y no puede leer texto que un PDF no decodifica; el índice se reescribe entero en cada guardado (unos 2 s para 357 MB), así que cambiar uno muy grande es más lento que uno pequeño; dos programas que escriben los mismos archivos a la vez: gana el último; la regla de la ortografía antigua es la de `--ocr-modern-spelling` y puede unir palabras distintas (`mână` / `mină`).

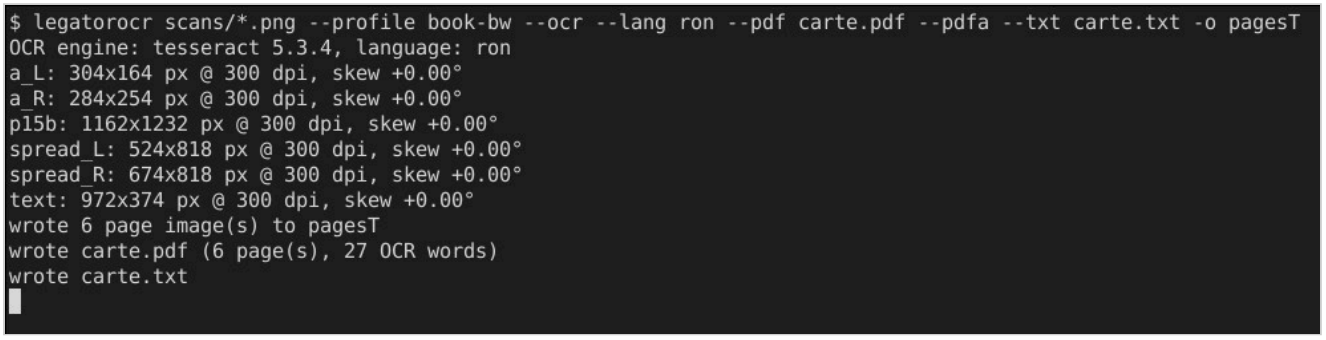
5. La línea de comandos: recetas para tareas frecuentes

Sintaxis general: `legatorocr ENTRADAS... [opciones]`. Las entradas pueden ser imágenes (PNG, JPEG, TIFF, BMP), PDF escaneados o una carpeta. `legatorocr --help` lista todas las opciones; `--list-profiles` muestra los perfiles. Las opciones de las recetas se comprueban automáticamente antes de cada edición, por lo que existen de verdad; las recetas en sí no se han probado todas con material real.

Libro escaneado → PDF con texto buscable

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

`--pdfa` escribe PDF/A-2b para archivo, y `--txt` guarda también el texto. `-o pages` es la carpeta para las imágenes procesadas.

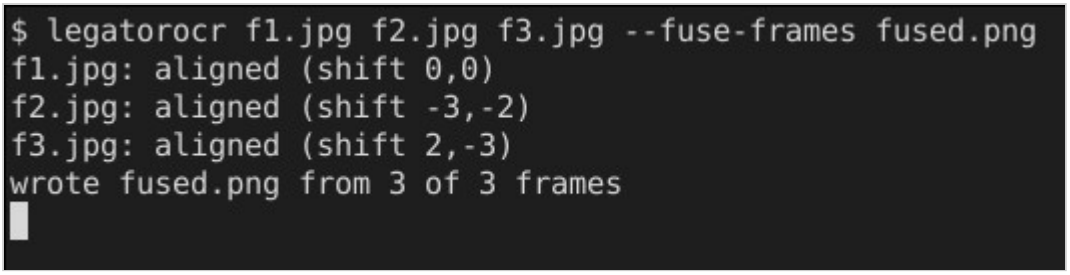


La receta con 4 archivos de prueba: 6 páginas en carte.pdf. Con --pdfa el programa escribe PDF/A-2b.

Fotos del móvil → páginas limpias

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

El perfil uniformiza la luz, corrige la perspectiva, borra el fondo alrededor de la página (`--trim-background`), corta por la mitad los libros abiertos, amplía el intervalo de inclinación y quita los dedos sin tocar el texto. Una página que sale sin texto se lee por segunda vez solo sobre su contenido. Para páginas uniformes en A4, con el texto ampliado, use `--profile phone-photos-a4`. Varias fotos de la misma página se pueden combinar antes con `--fuse-frames` (ayuda con ruido fuerte; con ruido moderado no). La opción recibe un archivo de salida: legatorocr foto1.jpg foto2.jpg foto3.jpg --fuse-frames pagina.png, y después se procesa pagina.png como de costumbre; la primera foto es la referencia.

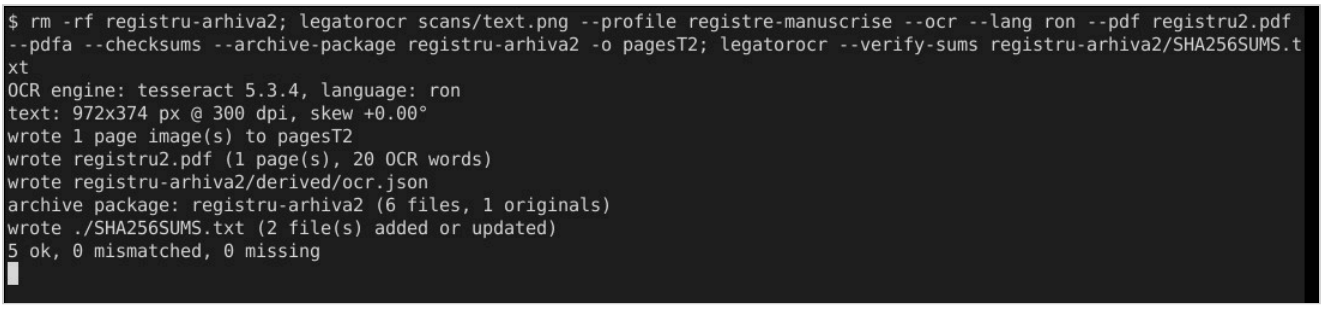


--fuse-frames con tres fotos de la misma página: las alinea y escribe fused.png a partir de 3 de 3 fotogramas.

Copia de archivo con prueba de integridad

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

El paquete conserva los originales, el proyecto, las palabras del OCR con su confianza, las salidas y un `RUN.txt` que explica cómo se retoma el trabajo. Para copias en otros discos: `--backup-from` y `--backup-to`.



El paquete de archivo creado y verificado: „5 ok, 0 mismatched, 0 missing”.

Ocultar nombres y números antes de compartir

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

Las palabras encontradas se ennegrecen en la imagen y se quitan del texto. **Compruebe el resultado a ojo:** una palabra que el OCR no ha reconocido no se oculta.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Resultado real: el número de teléfono se ocultó, pero la dirección de correo NO, porque el OCR leyó „@” como „G” (ion.popescuGexample.com) y el patrón de correo no coincidió. Por eso hay que comprobar el resultado a ojo. Desde pre.20 el programa escribe al final cuántas palabras ha cubierto cada patrón y avisa cuando un patrón no ha encontrado nada o cuando han quedado en el texto palabras que parecen direcciones o números largos, exactamente como en la captura de arriba.

Lote grande en varios ordenadores

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Ejecute la misma lista en cada máquina, con otro `--shard`. Para poca memoria: `--max-memory 500`. Para archivos desconocidos u hostiles: `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

El lote dividido en dos (--shard 1/2 y 2/2) y unido después con --merge-pdf.

Firmar un PDF

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

El valor jurídico de la firma es el de su certificado. La contraseña del certificado se da mediante la variable de entorno, no en la línea de comandos. El sello de tiempo (`--sign-timestamp`) se comprobó solo con una autoridad local por HTTP, no con una real por HTTPS.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Firma y verificación con un certificado de prueba creado por mí (no un certificado real). „time stamp inside: none”: no pedí sello de tiempo.

Pila escaneada en alimentador, orden e intervalo de páginas

Muchos escáneres con alimentador pasan la pila una vez por cada cara: primero todos los anversos (1, 3, 5…), después todos los reversos, en orden inverso (6, 4, 2). Los archivos salen en el orden del escaneo, no en el del libro. `--duplex-adf` los pone en el orden de lectura: anverso 1, reverso 1, anverso 2, reverso 2… El número de páginas debe ser par (si no, el programa se detiene con un mensaje).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Seis archivos en el orden del escaneo (scan_001 … scan_006). `--dry-run` muestra el orden en que se procesarían y qué archivos se escribirían, y después se detiene sin procesar nada: scan_006 queda en el puesto 2, scan_005 en el 4.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

El mismo comando sin `--dry-run`, con OCR nativo: el texto sale en el orden „Pagina 1 … Pagina 6” (páginas de prueba hechas por mí, no un libro real).

Otras opciones de orden y selección (se pueden combinar; el intervalo se aplica a la numeración de los archivos de entrada, desde 1):

- `--pages 1-10,15,20-`: conserva solo las páginas indicadas; `20-` significa „desde la 20 hasta el final”. Funciona también con páginas tomadas de PDF o de hojas TIFF de varias páginas.
- `--reverse`: invierte el orden (pila escaneada desde la última página).
- `--dry-run`: comprueba un lote grande antes de la ejecución larga.

Comprobado: el orden y el intervalo con pruebas automáticas y con seis páginas de prueba; no he probado un escáner real con alimentador. Las opciones también se pueden elegir desde la ventana, en „Todas las opciones…” (sección 4).

Texto limpio: correcciones propias, cabeceras y cedilla

Para los archivos `.txt` y `.docx` (la capa de texto del PDF, el hOCR y el JSON conservan las palabras leídas, sin cambios):

- `--clean-text`: ș y ț con coma debajo, palabras cortadas al final de línea unidas (conservando el guion cuando las dos mitades son palabras de la lista y la unión simple no lo es), comillas

tipográficas, espacios junto a la puntuación. `--cedilla` escribe en su lugar ş y ţ, para programas y fuentes que no conocen las letras con coma.

- `--find-replace ARCHIVO`: sus propias correcciones, una por línea, `erróneo => correcto`. Las líneas que empiezan por `#` son comentarios. Solo coinciden palabras enteras (`Ion => Ioan` no toca „Ionescu”) y se aplican en el orden del archivo, después de `--clean-text`. Útiles para nombres propios, abreviaturas o un sello que el motor lee siempre igual de mal.

- `--drop-running-heads`: deja fuera las cabeceras, los pies y los números de página impresos: la primera o la última línea de una página que se repite (las cifras no cuentan) en al menos la mitad de las páginas; hacen falta al menos cuatro páginas. Las líneas quitadas se listan en stderr, para que vea lo que se ha ido.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

El archivo de reglas (primer bloque) y las mismas dos líneas leídas de la página de prueba sin y con `--find-replace`: „Ionescu” pasó a ser „Ionescu-Vale” y „ha” pasó a ser „hectare”.

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

En seis páginas de prueba con la cabecera „Anuarul Văii Mari” y un número, el programa quitó seis líneas de cabecera; el texto empieza directamente con „Pagina 1”. Atención: la regla quita cualquier primera/última línea que se repita, por lo que en un libro cuya última línea de cada página es parecida (por ejemplo „Poziția în raft: 14”) también se irían esas líneas; por eso se listan. La función se comprobó con pruebas y en unas pocas páginas, no en un conjunto grande de libros.

Otras recetas

Las recetas completas están en `docs/tasks/` del repositorio, en inglés y rumano (verificación de documentos con `--verify-document` y `--mrz`, copia de archivo, lote grande).

6. Ajustes importantes y cuándo se usan

Perfiles

```
$ legatorocr --list-profiles | cut -c1-100
book-bw             Text books: auto threshold, black & white, punch holes removed
book-small-color    Colour books: sharp text over a light background, smallest files
document-text       Office documents: sharp text, pictures kept in colour
photo-archive       Archive quality colour, light sharpening
newspaper           Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red    Forms with red rules or stamps: drop red, erase ruled lines
negatives           Negative scans: invert and stretch contrast
doc-birou           Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene       Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim        Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft        Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum        Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma             Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta               Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura           Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos        Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof           user profile
```

legatorocr --list-profiles. La última línea (smokeprof) es un perfil de prueba mío, no forma parte del programa.

Un perfil es un conjunto de ajustes ya preparado para un tipo de material. Se elige en la sección „Perfil” (interfaz) o con `--profile NOMBRE` (línea de comandos). Puede tener sus propios perfiles: configure los ajustes, escriba un nombre y pulse „Guardar perfil”.

Perfil	Para qué
`book-bw`	libros con texto, blanco y negro, agujeros de perforación eliminados
`book-small-color`	libros en color, texto claro sobre fondo claro, archivos pequeños
`document-text`	documentos de oficina, imágenes conservadas en color
`photo-archive`	fotografías, calidad de archivo
`newspaper`	periódicos: umbral Wolf, manchas eliminadas con más fuerza
`form-dropout-red`	formularios con líneas o sellos rojos
`negatives`	escaneos en negativo
`phone-photos`	fotos del móvil: perspectiva corregida, fondo alrededor de la página borrado, libros abiertos cortados por la mitad, dedos eliminados
`phone-photos-a4`	como `phone-photos`, pero cada página en una hoja A4, con el texto ampliado para llenar la hoja (también las páginas con pocas líneas)
`registre-manuscrise`	registros y manuscritos antiguos (300–600 dpi), colores conservados
`schite-desene`	bocetos y dibujos a lápiz (400 dpi)
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	flujos para documentos de oficina, de la máxima calidad al gran volumen
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**no verificados con muestras reales**

La lista completa la da `--list-profiles`.

Los ajustes que más cuentan

Ajustes	Qué hace	Cuándo se cambia
Resolución (dpi)	a cuánto están escaneadas las páginas	cuando la imagen no tiene dpi en la cabecera; para texto, 300
Enderezar automáticamente / inclinación máxima	el límite del ángulo corregido automáticamente	cuando una página que sale „al límite” está en realidad torcida
Márgenes, tamaño de página, mismo tamaño	los márgenes en mm; página libre, personalizada o idéntica para todo el libro	para libros con formatos mezclados
Modo de salida	color, gris, blanco y negro, mixto (texto de 1 bit + imágenes en color), híbrido (+ fondo de baja resolución)	blanco y negro para texto puro; mixto para texto con fotos
Método de umbral	Sauvola (predeterminado), Wolf, Niblack, NICK, Bradley, Otsu o automático	cuando el texto sale pálido o lleno de manchas; `auto` prueba varios en cada página
Sensibilidad	la sensibilidad del método Sauvola para la salida en blanco y negro	predeterminada 0,3; cámbiela en pasos pequeños y compare el resultado en la misma página
Sensib. imágenes	con qué facilidad se considera una zona como imagen	en el modo mixto/híbrido
Eliminar motas pequeñas	la fuerza de la limpieza de manchas (0,25–4; 1 = predeterminado)	redúzcala si desaparecen puntos o diacríticos; auméntela si quedan manchas
Dewarp (líneas curvas)	endereza las líneas arqueadas junto al lomo	para libros gruesos; se omite si no se ve una curvatura clara
Uniformizar la iluminación	iguala el fondo	para fotos con sombra o iluminación desigual
Calidad JPEG	0 = sin pérdidas; las páginas en blanco y negro son siempre sin pérdidas	para archivos más pequeños (sugerencia: pruebe 80–90 y compare el tamaño y el aspecto)
DPI de salida	reduce la imagen de salida a estos dpi (“—” = no reducir)	para PDF más pequeños; las páginas por debajo de 250 dpi se amplían automáticamente antes del OCR, por lo que una reducción demasiado grande no ayuda al reconocimiento
PDF/A-2b	PDF para archivo, con fuente y perfil de color incluidos	para depósito en archivos; no se ha verificado con veraPDF en las salidas del programa

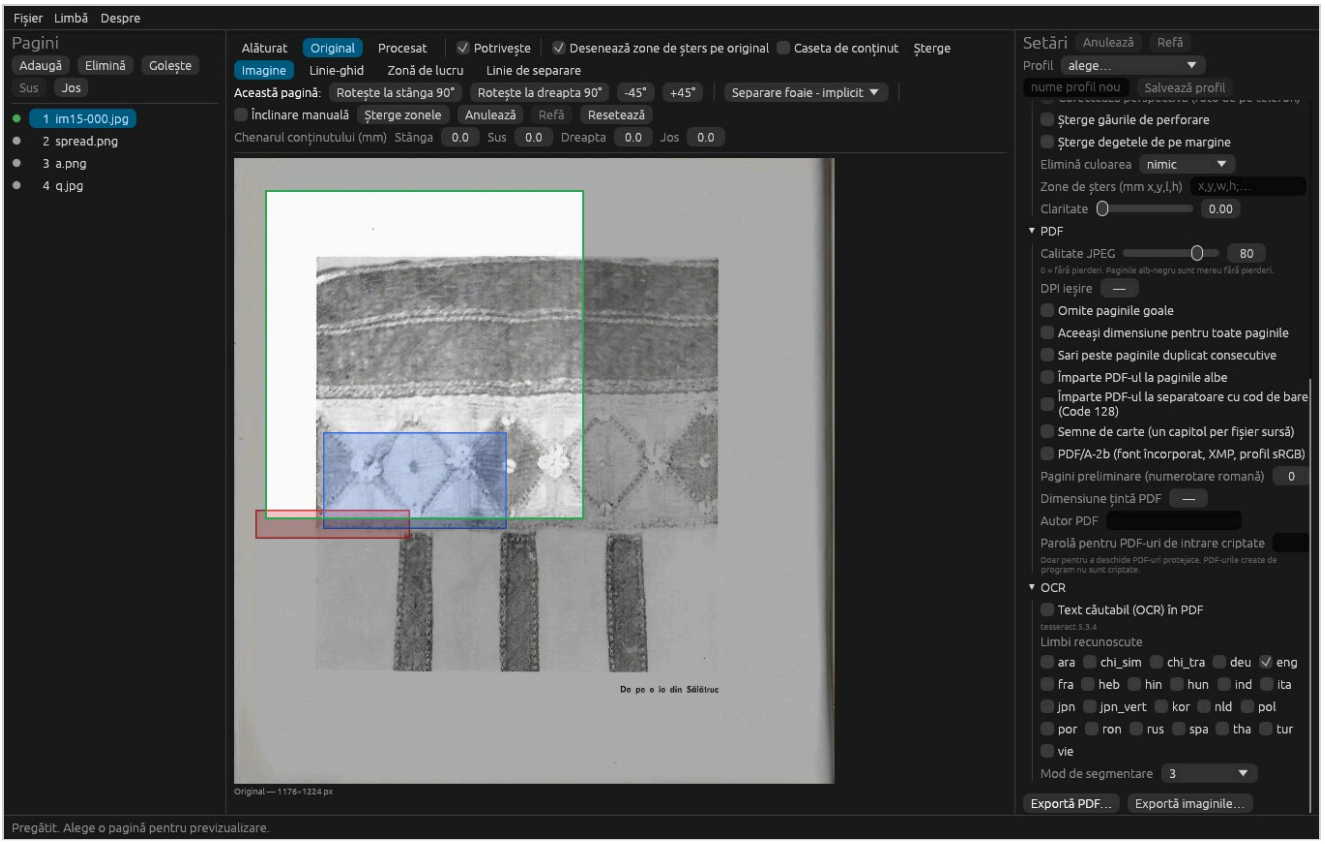
Los formatos de los campos de texto

Estos campos existen en los ajustes, pero es más fácil dibujar sobre el original (sección 4):

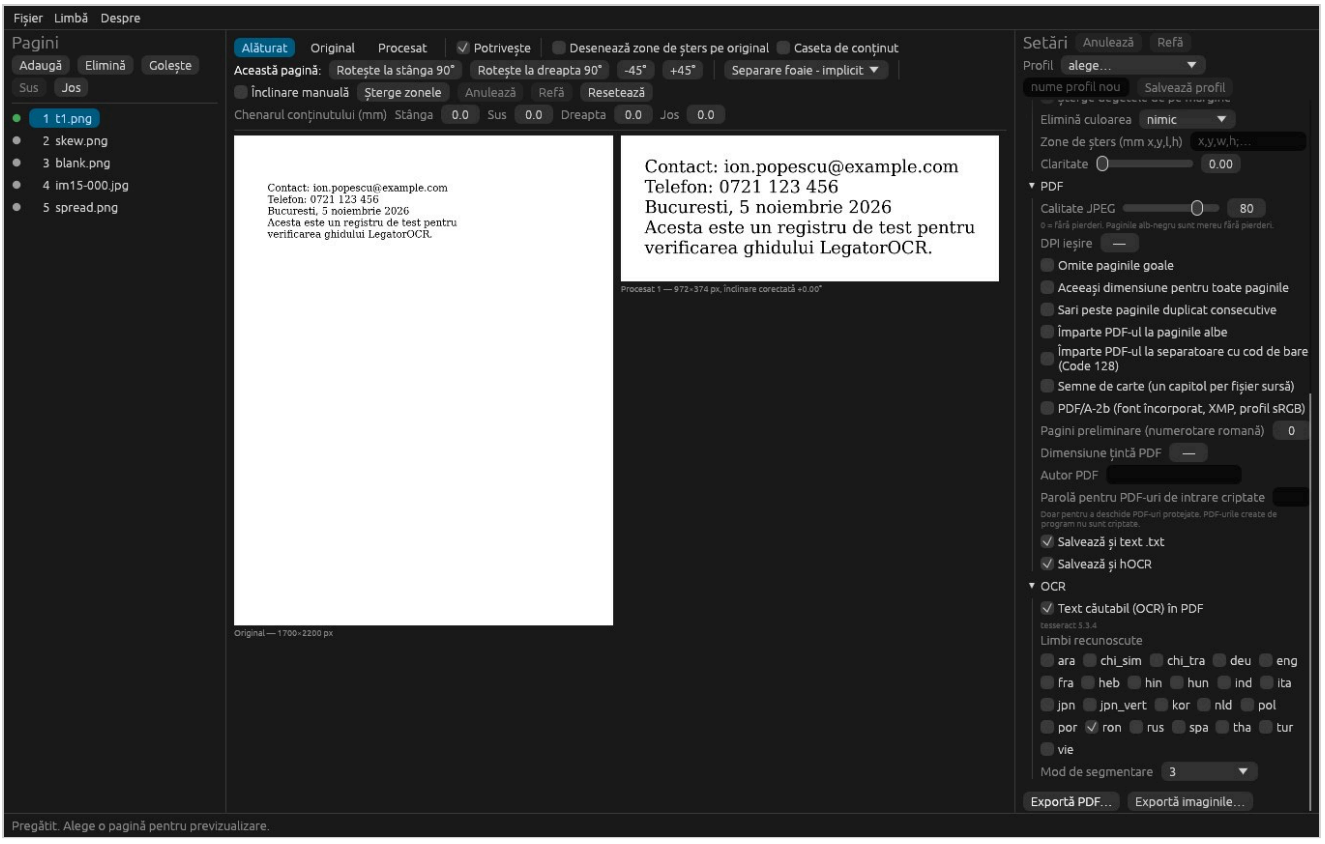
- **Zonas de borrado** y **Zonas de imagen**: `x,y,l,h` en **milímetros** desde la esquina superior izquierda de la página. Varias zonas se separan con punto y coma: 10,20,30,40;50,60,20,20. Como máximo 64; el ancho y el alto deben ser positivos. Si el formato es erróneo, el campo se pone rojo.
- **Líneas guía de enderezado**: `x,y x,y x,y;x,y x,y x,y`, con **fracciones entre 0 y 1** de la página ya enderezada (0,0 = esquina superior izquierda). Cada línea tiene al menos dos puntos; en total, como máximo 64 líneas.
- En la línea de comandos: `--erase X,Y,W,H` (repetible) y `--dewarp-guide "X,Y X,Y …"` (repetible).

7. OCR: motores, idiomas y precisión

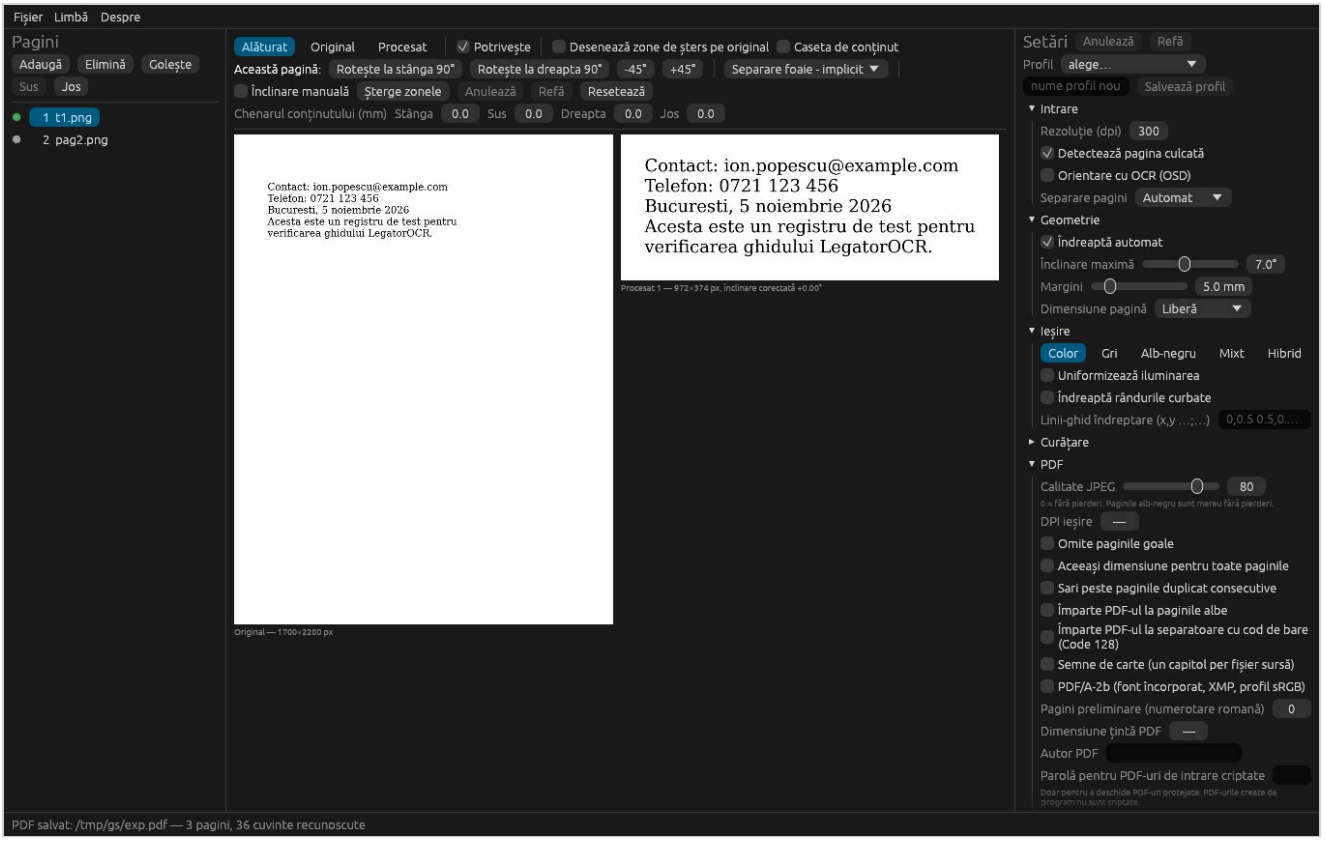
La casilla „Texto buscable (OCR) en el PDF” (o `--ocr` en la línea de comandos) añade una capa de texto invisible sobre la imagen. El idioma se elige en „Idiomas reconocidos” (o `--lang ron`); se puede combinar, por ejemplo `ron+eng`. Los idiomas de la interfaz y del motor propio: rumano, inglés, francés, italiano, español, portugués, alemán, húngaro.



La sección OCR de los ajustes: la casilla „Texto buscable (OCR) en el PDF”, los idiomas reconocidos (los instalados en Tesseract) y el modo de segmentación. En la captura estaba instalado Tesseract 5.3.4, por eso aparecen todos sus idiomas; la opción ron la usé en la figura siguiente.



Con OCR marcado aparecen también „Guardar también texto .txt” y „Guardar también hOCR”. Aquí el idioma elegido es ron.



Tras la exportación, la barra inferior muestra: „PDF guardado: … — 3 páginas, 36 palabras reconocidas”. (La exportación la lancé con un mecanismo de prueba del programa, no desde el diálogo de archivos.)

Tres motores

Motor	Cómo se elige	Notas
Nativo (del programa)	`--engine native`	sin instalación, escrito en Rust; modelo entrenado con texto sintético y luego ajustado con líneas de una revista rumana y de un manual de 1960
Tesseract	`--engine tesseract`	programa aparte, véase la sección 2; se usa automáticamente cuando está instalado y tiene el idioma solicitado (`--engine auto`, predeterminado)
Puente ONNX	`--engine tesseract --tesseract scripts/engine-onnx.py`	para usuarios avanzados; requiere Python, onnxruntime y modelos descargados por separado



La misma página de prueba leída por los dos motores. Ambos se equivocaron igual: „@” salió „(a” en el motor nativo y „G” en Tesseract.

Las cifras medidas (y lo que no dicen)

Se midieron 8 páginas buenas de una revista rumana, frente a un texto de referencia producido por ABBYY, no corregido por una persona. Tasa de errores por carácter, con diacríticos (la medición original, de la edición 0.2.0-pre.21; en una nueva medición en pre.26 sobre las mismas 8 páginas, con el mismo método, el motor nativo dio 2,76 %; la diferencia respecto a 2,55 % no la he investigado):

Motor	Errores por carácter
Nativo	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (con Tesseract)	4,62 %

Leído de forma simple: el motor nativo se equivoca menos **en este tipo de impresión**. Pero fue ajustado con texto de las mismas fuentes, así que no se puede decir que sea mejor en general. En otros documentos, sobre todo de impresión antigua o poco habitual, puede ser más débil que Tesseract. El reconocimiento de palabras enteras es casi igual entre los motores (aproximadamente 92 %).

El modo preciso y la ortografía antigua

- `--accurate` (motor nativo): cada línea se lee tres veces (desplazada un píxel hacia arriba y hacia abajo) y se promedian las probabilidades. Es más lento (medido: entre un 18 % y un 74 % más de tiempo) y solo ayudó en las páginas de revista (error por carácter 3,66 % →

3,39 % en 12 páginas); en libros y folletos no cambió nada medible. Está desactivado por defecto.

- La lista de palabras rumanas acepta también la ortografía de 1953–1993 (`cuvînt`, `romîn`, `sînt`): en cinco páginas de un manual de 1960, transcritas a mano, los caracteres correctos subieron del 99,6 % al 99,7 % y las palabras del 96,0 % al 96,3 %. Una diferencia pequeña, en cinco páginas.
- Las palabras se separan en los espacios grandes aunque la red no haya escrito espacio: las celdas de una tabla ya no salen pegadas (`CantitatePreț`). Una tabla con líneas se encuentra como una sola tabla (Excel: `--tables-xlsx`); una tabla sin líneas todavía se encuentra como dos tablas (izquierda y derecha), problema sin resolver.

Consejos

- En sus documentos, compare los motores en 5–10 páginas antes del lote: `scripts/compare-ocr-text.py` mide los errores frente a textos de referencia que tenga usted.
- Las páginas por debajo de 250 dpi se amplían automáticamente antes del reconocimiento.
- Las páginas con ilustraciones o diagramas pueden producir texto sin sentido en la zona de la imagen (Tesseract leyó una ilustración como texto en una de las páginas medidas). Compruebe estas zonas.
- Cualquier OCR puede inventar o perder palabras. Para actas, registros o cifras, compruebe por muestreo.

8. Salidas y archivo

Qué quiere	Cómo
PDF con texto buscable	`--pdf ARCHIVO.pdf --ocr` (interfaz: Exportar PDF con OCR marcado)
PDF para archivo (PDF/A-2b)	`--pdfa`; otras partes con `--pdfa-part 1` o `3`
Imágenes procesadas	`-o CARPETA`, con `--format png`, `jpeg` o `tiff`; `--format none` no escribe imágenes
Texto simple de las páginas	`--txt ARCHIVO.txt`
hOCR	la casilla „Guardar también hOCR”
Estructura para accesibilidad	`--tagged ro` (párrafos etiquetados). La conformidad PDF/UA **no** se ha validado
Copia DjVu	`--djvu ARCHIVO.djvu`
Prueba de integridad	`--checksums` y `--archive-package DIR`, después `--verify-sums`
Proyecto (ajustes y correcciones)	Archivo → Guardar el proyecto (`.lgr`), o `--save-project`; `--embed-project` lo esconde dentro del PDF

Sobre PDF/A

El programa escribe PDF/A-2b con fuente y perfil sRGB incorporados. La conformidad se verificó en muestras, **no** con veraPDF en cualquier salida. Si una institución exige conformidad certificada, ejecute su propio validador sobre los archivos finales.

Sobre los proyectos de ScanTailor

`--project ARCHIVO.ScanTailor` abre un proyecto de ScanTailor: se toman la lista de escaneos y el giro por imagen, y la inclinación, la separación y el cuadro de contenido se encuentran de nuevo. El lector se escribió a partir de la descripción del formato y se probó con un proyecto hecho a mano, no con archivos de cualquier versión de ScanTailor.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project y --project: el proyecto se guarda y se reabre con el mismo resultado (2 páginas). Atención: en pre.18, --work-area y --cut-at no se conservaban en el proyecto; corregido en pre.19 (comprobado: el proyecto guardado y reabierto da las mismas páginas).

9. Problemas frecuentes y límites conocidos

Síntoma	Qué comprobar
La página sale cortada o con demasiado blanco	el cuadro de contenido (sección 4); el marco en mm de la barra „Esta página”
Una página inclinada sigue inclinada	la inclinación máxima permitida; fije el ángulo a mano
La hoja a doble página no se corta donde debe	el modo de separación de la página: „por la mitad” o „desactivada”; desde pre.18 puede arrastrar una „Línea de corte” sobre el original o usar `--cut-at 0.45`
Un campo de texto se pone rojo	el formato del campo (sección 6): milímetros para las zonas, fracciones 0–1 para las guías
El texto del OCR tiene errores	compare los motores (sección 7); compruebe la resolución; pase a Tesseract o al revés
El panel „Por revisar”	páginas marcadas como sospechosas (en blanco, inclinación al límite, nada encontrado, contenido pegado al borde); no están necesariamente mal, pero merece la pena mirarlas
La ventana no funciona en Windows o en RDP	falta de OpenGL 2+; pruebe el controlador de la tarjeta gráfica
La aplicación de macOS no arranca	no está firmada: clic derecho → Open o el comando `xattr` de la sección 2

Límites conocidos de la edición 0.2.0-pre.61

- Trapecio auto: comprobado en hojas sintéticas y en 67 fotos de teléfono de un solo libro (133 páginas), donde dejó intactas la mayoría de las páginas y redujo la inclinación medida en el resto; nadie ha juzgado el resultado a simple vista en otros libros, ni en páginas con imágenes grandes, tablas o líneas muy cortas, donde puede no hacer nada o hacer muy poco. Los ajustes por página y la inclinación de la línea de corte se probaron en hojas sintéticas y en pruebas; el lápiz de tabla hace que el OCR lea la zona como un bloque, no encuentra celdas.

- El giro de 90°: en una página con una fotografía de ornamentos (página 15 de un PDF) un probador en Windows vio el giro saltar de 90° a 180°. Reproduje en Linux una parte del problema: en pre.18, con „Detectar página tumbada” marcado (predeterminado), el programa giraba por error 90° esta página, aunque el original está derecho (figura de la sección 4). El umbral de pre.19 era demasiado frágil (descubrí entretanto que otra página del mismo PDF, la 13, también se giraba por error). En pre.20 el detector cuenta solo las piezas del tamaño de una letra y se abstiene en las páginas con fotos o con pocas palabras. En 98 páginas de libro (giradas a 0° y 90°) y 5 páginas con fotos, el resultado es idéntico al de pre.18, salvo la página 13 (girada por error en pre.18, ahora derecha) y una página con foto tumbada, que el detector ya no endereza (quedan el OSD y el giro manual). Comprobado en la línea de comandos, en Linux, con un corpus pequeño. La causa probable del salto (la orientación automática se sumaba al giro manual) se corrigió en pre.18: tras un clic en el giro la página queda bloqueada, y cuatro clics dan 90°, 180°, 270° y de nuevo 0° (comprobado en la ventana, en Linux). Lo que vio exactamente el probador en Windows 11 no pude comprobarlo. Si una página con fotos sigue girada por error, desmarque „Detectar página tumbada” o use --no-auto-orient.

- El área de trabajo, la línea de corte movible, las zonas de borrado y de imagen, la cuadrícula de puntos, Deshacer y Ctrl+Z, el cuadro de contenido, el OCR y la exportación a PDF se probaron en una ventana real en Linux, con ratón simulado (las capturas de la guía). El redimensionado de una zona desde la esquina funcionó en la ventana. Los diálogos nativos de archivos („Exportar PDF…”, „Guardar proyecto”, „Abrir proyecto”) funcionaron con el diálogo GTK de un portal xdg en Linux; en Windows y macOS no los he probado. Si el sistema no tiene ningún diálogo, desde pre.21 la ventana lo dice en lugar de no hacer nada (puede arrastrar los archivos a la ventana o usar la línea de comandos). Guardar un perfil propio funcionó. El efecto de la línea de corte lo comprobé con pruebas automáticas, con --cut-at y en la ventana (una hoja doble cortada en dos páginas desiguales, 524 y 674 px). En las hojas giradas 90° o 270° (desde pre.21) las páginas salen una debajo de la otra; esto está comprobado solo con una prueba automática, no en la ventana.

  --save-project: en la compilación publicada pre.18, --work-area y --cut-at dados en la línea de comandos no se conservaban en el archivo .lgr (encontrado al verificar esta guía). Corregido en pre.19. Si usa pre.18, vuelva a dar las opciones junto a --project, no solo desde el proyecto.

- La interfaz gráfica no ha sido verificada por personas en Windows, macOS o arm64.

- La verificación PDF/UA, la factura electrónica CIUS-RO y el sello de tiempo por HTTPS con una autoridad real no se han validado.

- Para una copia PDF/A certificada, el validador es suyo (por ejemplo veraPDF).

- El derecho de uso del modelo de OCR propio (entrenado en parte con páginas cuyos derechos no están aclarados) es una cuestión abierta para el autor; véase `docs/audit/assets-licences.md`.

- Detección automática de páginas boca abajo: solo escritura latina, al menos 12 líneas por página; una página con tablas o poco texto puede quedar intacta (usa «180°»). La ventana de colecciones y las miniaturas grandes tienen pruebas automáticas, pero el autor no las ha visto en pantalla.

10. Cómo informar de un problema

La contribución más útil es un informe desde un sistema que el autor no ha probado. Lleva cinco minutos:

1. Descargue la última edición para su sistema.
2. Ejecute `legatorocr --doctor` y copie todo el resultado.
3. Procese una página que pueda compartir: `legatorocr PAGINA.jpg --ocr --pdf rezultat.pdf -o pagini`.
4. Abra `rezultat.pdf`: ¿la página está derecha y recortada como debe? ¿El texto se selecciona y se busca?

Envíe, como incidencia en el repositorio `chiuta/LegatorOCR` (o por correo electrónico):

- el sistema y la versión (por ejemplo Windows 11 23H2, macOS 15 arm64, Debian 12 arm64);
- la versión de LegatorOCR;
- el resultado del comando `--doctor`;
- el comando ejecutado (o el ajuste de la interfaz);
- lo que esperaba y lo que ocurrió (texto del error o captura de pantalla);
- si la imagen se puede compartir.

No envíe documentos con datos personales. Un informe „todo funcionó” también es útil: es la única vía por la que el autor sabe que un sistema funciona.

Los problemas de seguridad se comunican conforme a `SECURITY.md`, no en público.