LegatorOCR – Guide d’utilisation

Édition 0.2.0-pre.60 (version d’essai). Texte en cours de rédaction, en roumain.

1. Qu’est-ce que LegatorOCR

LegatorOCR transforme des scans ou des photos de pages en un PDF propre, avec un texte interrogeable. Il résout le même problème que ScanTailor (séparation des pages, redressement, recadrage, nettoyage), mais ajoute l’export PDF et l’OCR. Il est écrit en Rust, avec du code propre, chaque étape étant une technique de manuel. Il s’exécute en local, sans compte et sans envoyer les pages sur Internet. Licence : MIT.

Il existe deux modes de travail, avec les mêmes moteurs en dessous :

- **L’interface graphique** (`legatorocr-gui`) : vous ajoutez des pages, vous voyez l’original et le résultat côte à côte, vous corrigez page par page et vous exportez.
- **La ligne de commande** (`legatorocr`) : pour les gros lots, pour l’automatisation et pour les options que l’interface ne montre pas.

Ce qu’il fait

- sépare les feuilles recto-verso en deux pages, redresse les pages inclinées et rogne les marges ;
- nettoie le fond, les taches, les trous de perforation, les doigts sur le bord et les lignes de formulaire ;
- écrit un PDF (y compris PDF/A pour l’archivage) ou des images, avec OCR en roumain et dans 7 autres langues ;
- produit aussi du texte brut (`.txt`) et du hOCR, et peut signer ou horodater le PDF.

Ce qu’il ne fait pas (ou n’a pas été prouvé)

- C’est une version d’essai (0.2.0-pre.60). Elle n’a été exécutée par l’auteur et son assistant que sous Linux ; **Windows, macOS et les processeurs arm64 n’ont pas été essayés par des humains**.
- La précision de l’OCR a été mesurée sur 8 bonnes pages d’un seul magazine roumain, par rapport à un texte de référence produit par un autre programme, non corrigé par un humain. Ne la prenez pas pour une garantie sur d’autres types d’impression.
- L’OCR peut se tromper : vérifiez par sondage les pages importantes.

2. Installation et premier lancement

Téléchargez l’archive correspondant à votre système sur la page des publications (Releases) du dépôt `chiuta/LegatorOCR`. Chaque archive a un fichier `.sha256` pour la vérification.

Système	Fichier	Remarques
Linux x86-64 ou ARM64	`.tar.gz`	nécessite OpenGL 2+ et X11 ou Wayland
Windows x86-64	`.zip`	nécessite OpenGL 2+ ; il peut manquer dans les sessions RDP simples
macOS Apple-silicon ou Intel	`.zip` avec `LegatorOCR.app`	**non signé** : au premier lancement, clic droit → Open, ou `xattr -dr com.apple.quarantine LegatorOCR.app`

Vous pouvez aussi compiler depuis les sources : `cargo build --release` (nécessite Rust 1.95 ou plus récent).

OCR

Le programme a son propre moteur OCR, qui fonctionne sans installation. Facultativement, vous pouvez installer Tesseract, un programme séparé que LegatorOCR utilise automatiquement quand il est présent et possède la langue demandée :

- Linux (Debian/Ubuntu) : `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS : `brew install tesseract tesseract-lang`
- Windows : `winget install UB-Mannheim.TesseractOCR` puis son ajout au `PATH`

Le modèle roumain des paquets `apt` et `brew` est la petite variante (« fast »). La variante « best » se télécharge manuellement et s'indique avec `--tessdata DIR`. Laquelle lit le mieux vos pages n'a pas été mesuré.

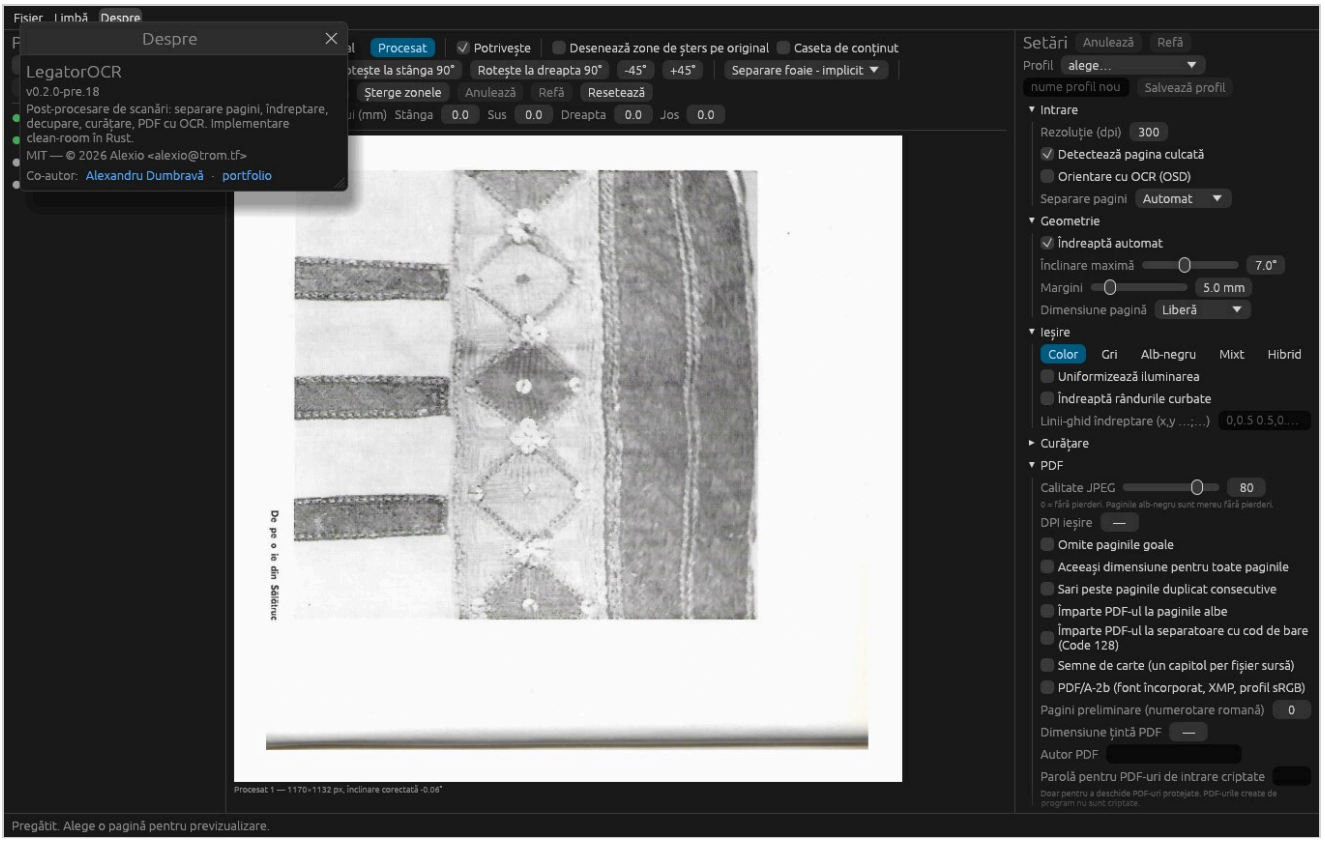
Vérifier l'installation

Exécutez `legatorocr --doctor`. Il affiche la version, le moteur OCR natif, Tesseract et les modèles de langue, puis des outils auxiliaires (`pdftoppm`, `gs`, `qpdf`, `mutool`). Le résultat « missing » pour un outil facultatif n'est pas une erreur ; le message en dessous dit s'il est nécessaire. Si quelque chose ne marche pas, copiez toute la sortie de la commande dans un rapport (voir la section 10).

```
$ legatorocr --doctor
[ok     ] legatorocr                        0.2.0-pre.19
[ok     ] native OCR engine                 built in
[ok     ] tesseract                         tesseract 5.3.4
[ok     ] tesseract model ro (Romanian)     installed
[ok     ] tesseract model en (English)      installed
[ok     ] tesseract model fr (French)       installed
[ok     ] tesseract model it (Italian)      installed
[ok     ] tesseract model es (Spanish)      installed
[ok     ] tesseract model pt (Portuguese)   installed
[ok     ] tesseract model de (German)       installed
[ok     ] tesseract model hu (Hungarian)    installed
[ok     ] pdftoppm                          pdftoppm
[missing] mutool                            not found
          -> optional: alternative renderer for those cases
[ok     ] gs                                gs
[ok     ] qpdf                              qpdf
14 check(s) ok, 1 missing. Missing helpers are optional unless a hint says otherwise.
```

Résultat de la commande legatorocr --doctor (pre.20, Linux, dans un vrai terminal ; il en va de même pour toutes les captures de terminal du guide, faites avec xterm) : « missing » pour

mutool est un outil facultativ, pas une erreur.



Le menu À propos montre la version installée (ici 0.2.0-pre.18). Capture du build pre.18 sous Linux, interface en roumain.

3. Le flux de travail, pas à pas

Pour chaque page, le programme parcourt les étapes ci-dessous dans cet ordre. L’analyse se fait sur une copie d’environ 150 dpi, puis le résultat est appliqué au scan à sa pleine résolution.

1. **Orientation.** Les pages couchées (quart de tour) sont détectées d’après les lettres de la page : une page avec des images ou peu de mots n’est pas pivotée par ce test. Pour la direction exacte, on peut utiliser Tesseract (OSD) ou la rotation manuelle.

2. **Séparation de la feuille.** Une feuille en paysage portant deux pages est coupée au milieu, à la bande vide du centre. Elle peut être automatique, au milieu ou désactivée.

3. **Redressement.** L’angle d’inclinaison est estimé d’après les lignes de texte et la page est repivotée. L’angle peut être fixé manuellement.

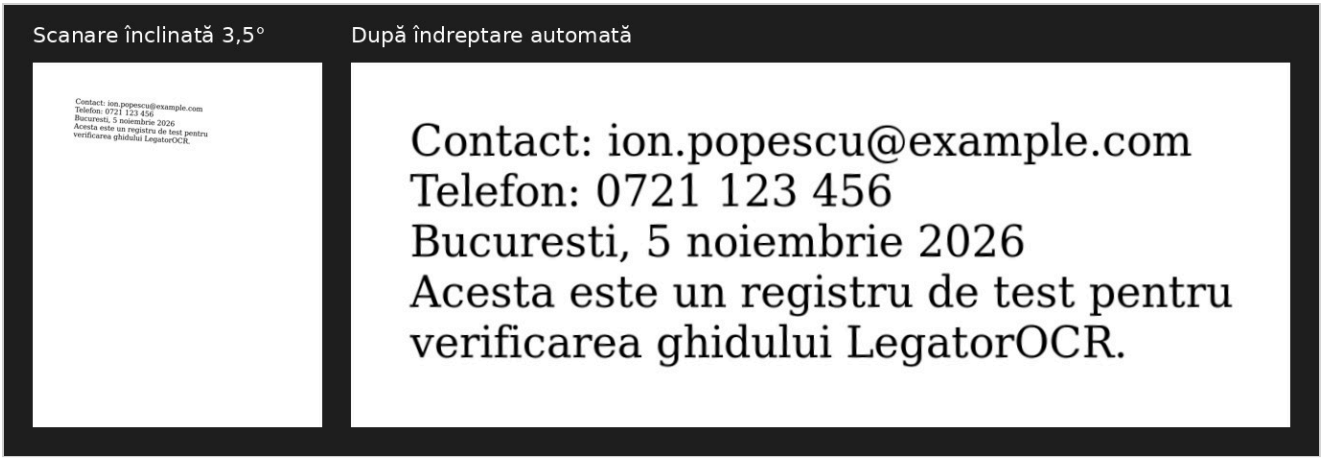
4. **Zone de contenu.** La zone de texte et d’images est trouvée ; les ombres du scanner et la poussière sont ignorées. Tout ce qui est en dehors est repeint à la couleur du papier.

5. **Marges et dimensions.** Marges en millimètres, taille de page fixe facultative ou même taille pour tout le livre.

6. **Redressement des lignes courbes** (facultatif). Pour les pages de livre chargées, aux lignes courbées près de la reliure.

7. **Éclairage** (facultatif). Égalise le fond inégal.

8. **Nettoyage et binarisation.** Élimine taches, trous de perforation, doigts, lignes ; puis noir et blanc, gris, couleur, mixte ou hybride.
9. **PDF et OCR.** Le PDF (ou les images) est écrit et, si la case est cochée, la couche de texte aussi.



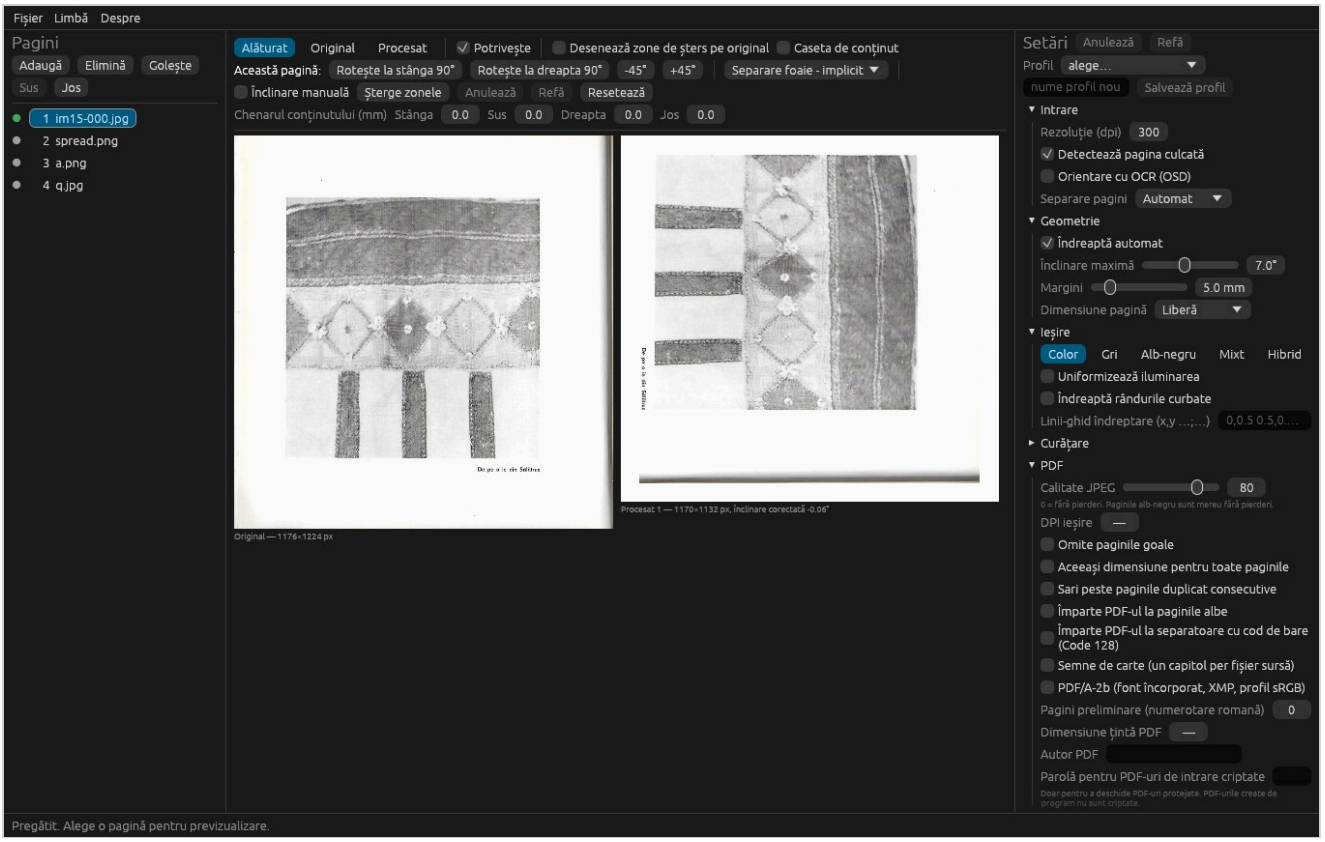
Le redressement automatique : un scan incliné de 3,5° (feuille de test que j'ai générée) et le résultat ; le programme a mesuré -3,50°.

Règles de travail qui font gagner du temps

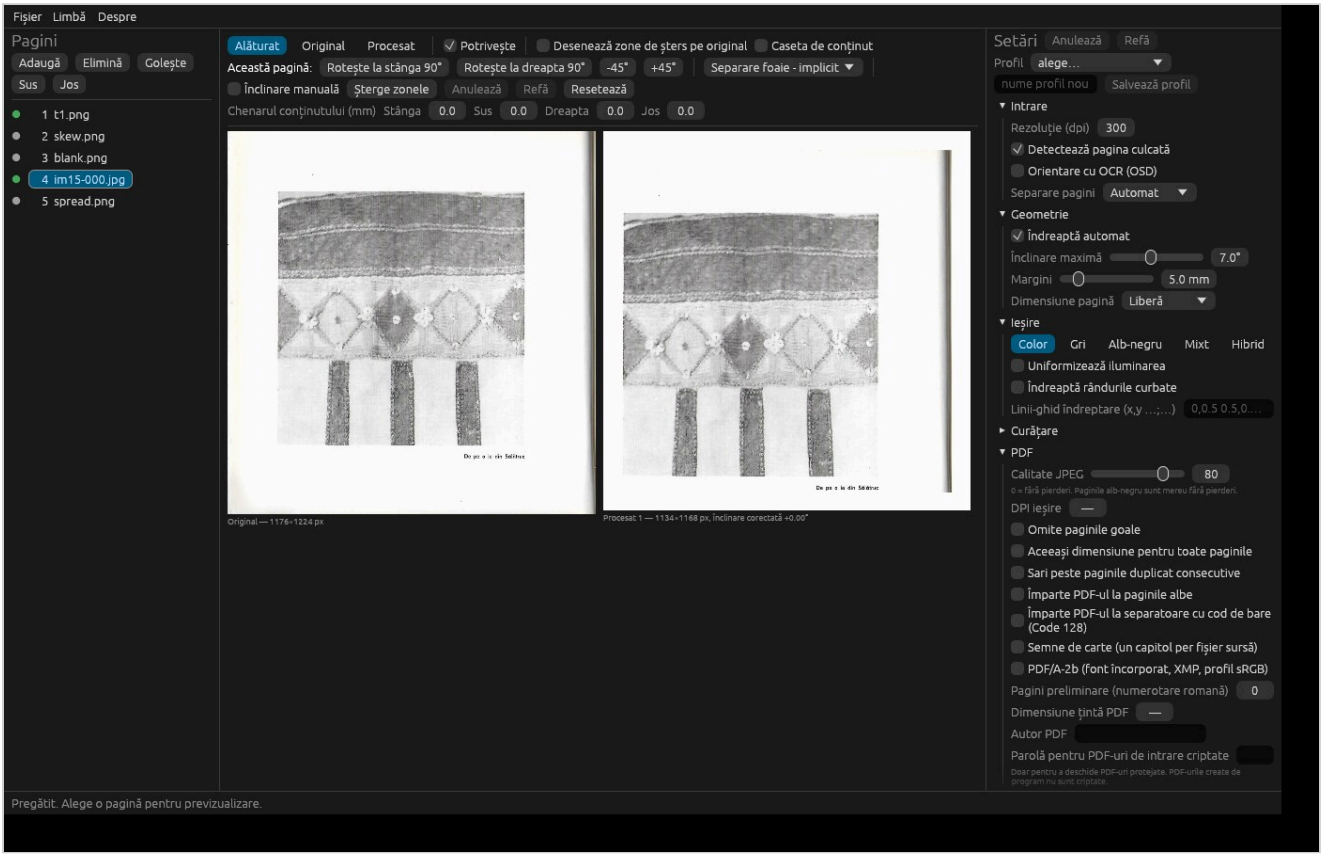
- Fixez d'abord la **résolution** correcte (en général 300 dpi pour du texte). Le programme la lit dans l'image si elle est comprise entre 150 et 1200 ; sinon il suppose 300.
- Choisissez un **profil** adapté au matériau (section 6) avant de toucher aux réglages individuels.
- Traitez 10–20 pages en essai, vérifiez le résultat, puis lancez le gros lot.
- L'interface marque les pages « à vérifier » (page blanche, inclinaison à la limite, rien trouvé, contenu collé au bord). Parcourez-les avec le bouton « Suivante ».

4. L'interface graphique

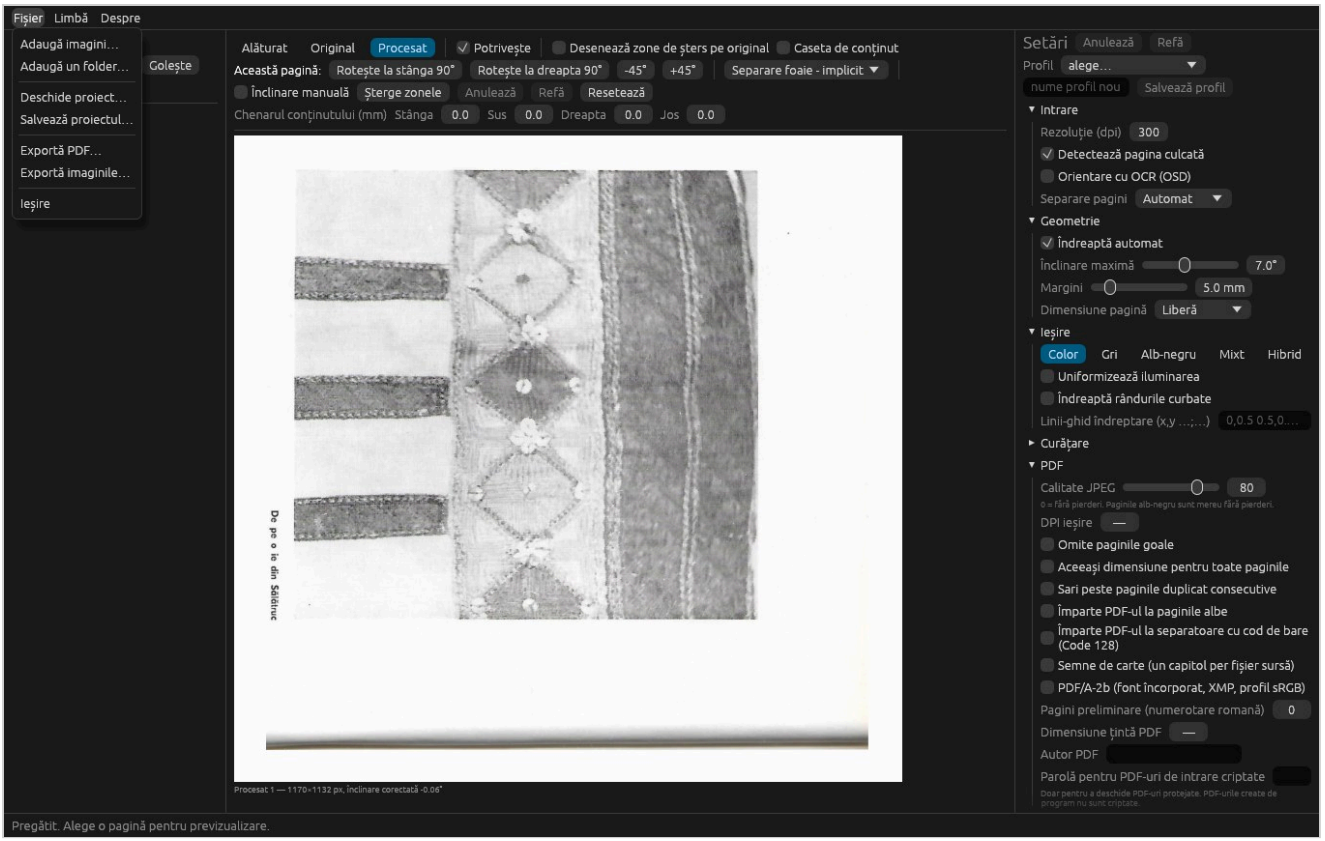
La fenêtre a trois zones : la liste des pages à gauche, l'aperçu au centre et les réglages à droite. Le menu **Fichier** contient « Ajouter des images », « Ajouter un dossier », « Ouvrir un projet », « Enregistrer le projet », « Exporter le PDF » et « Exporter les images ». La langue de l'interface (8 langues) se change dans le menu **Langue**.



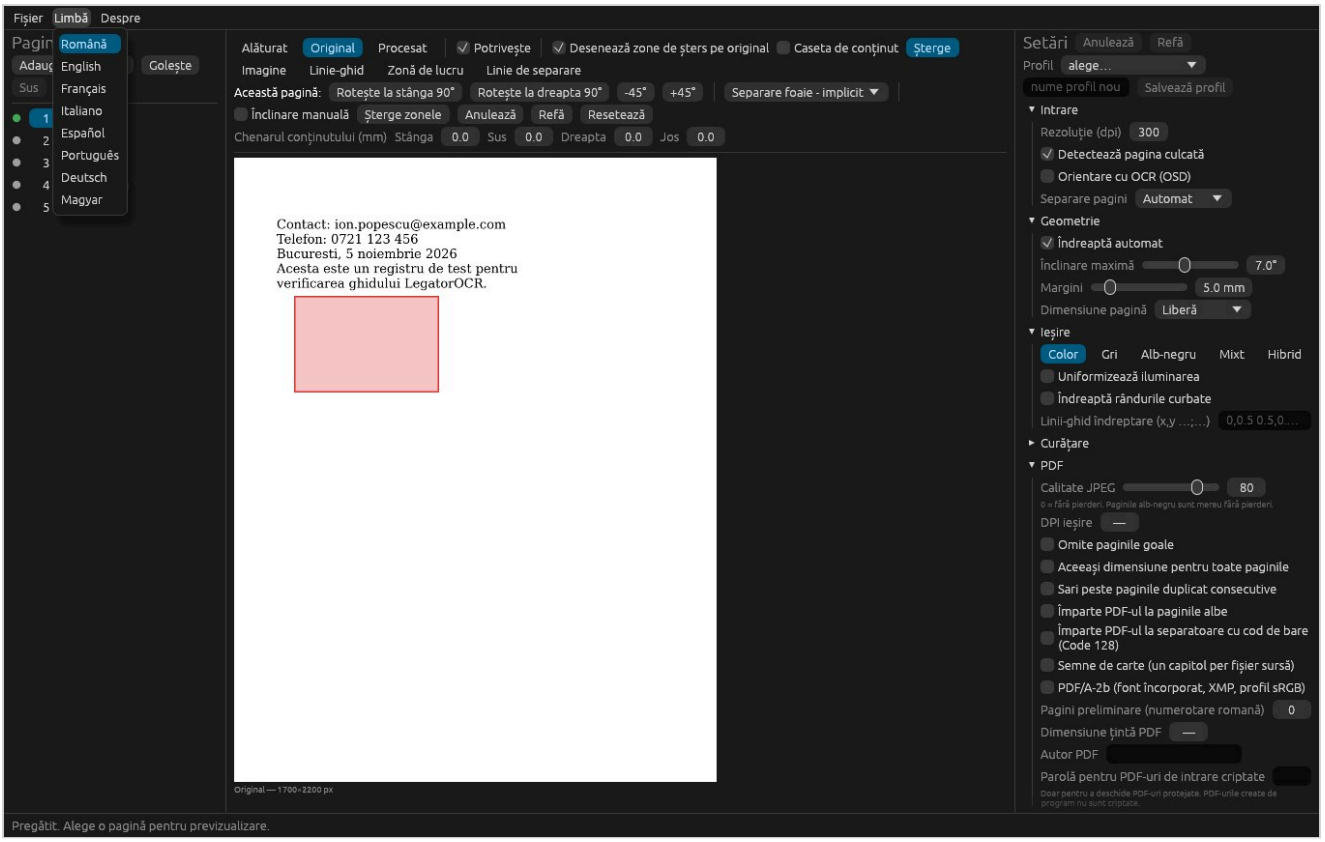
La fenêtre principale : la liste des pages à gauche, l’original et la page traitée au milieu, les réglages à droite. La page de l’exemple est une photo sans texte, si bien que la détection de page couchée l’a mal pivotée dans pre.18 (corrigé dans pre.19, voir plus bas). Capture pre.18 sous Linux.



La même page dans pre.19, avec « Détecter la page couchée » cochée : elle n’est plus pivotée (traité 1134×1168 px, inclinaison +0,00°). Capture pre.19 sous Linux.

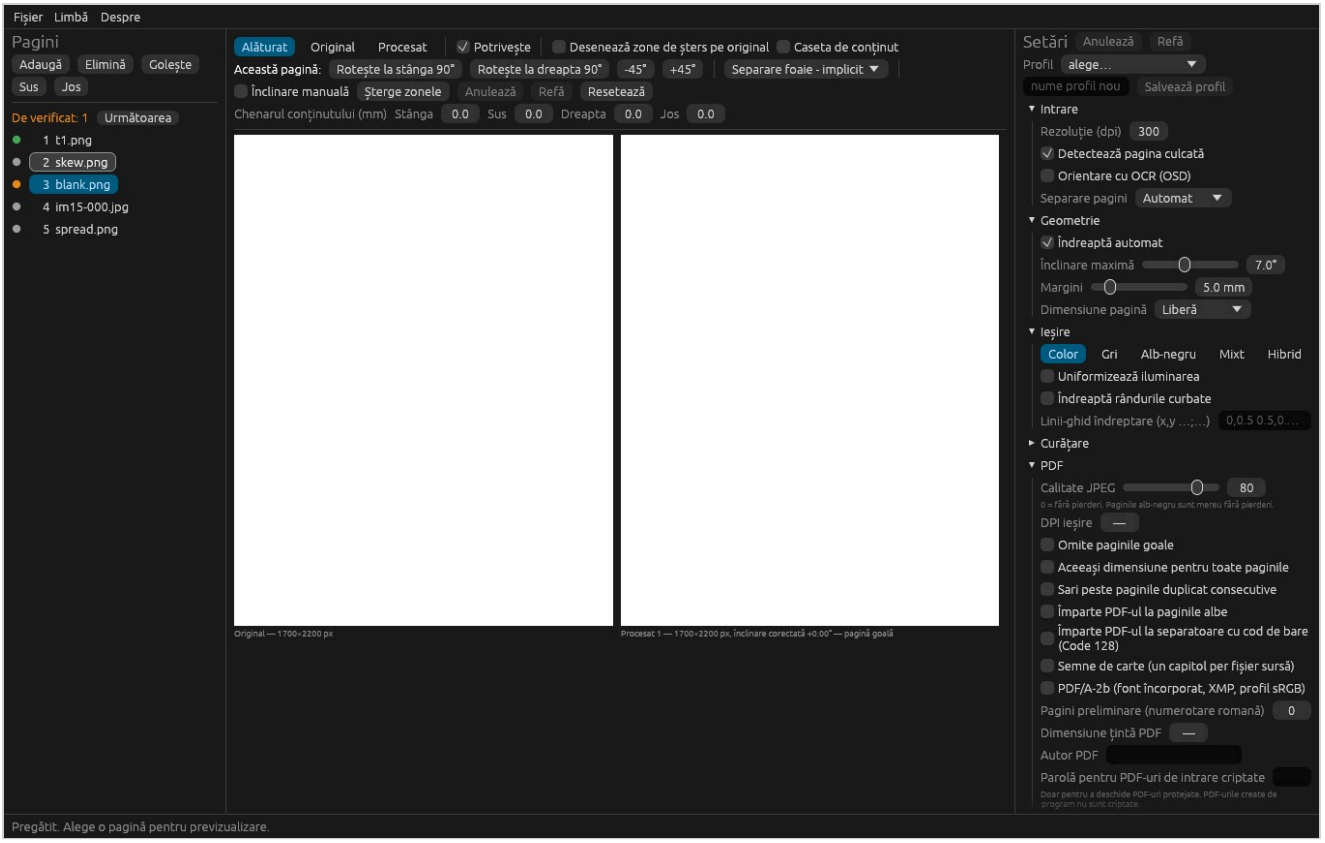


Le menu Fichier : ajouter des images ou un dossier, ouvrir et enregistrer le projet, exporter le PDF ou les images.



Le menu Langue : les huit langues de l’interface (roumain, anglais, français, italien, espagnol, portugais, allemand, hongrois).

La liste des pages

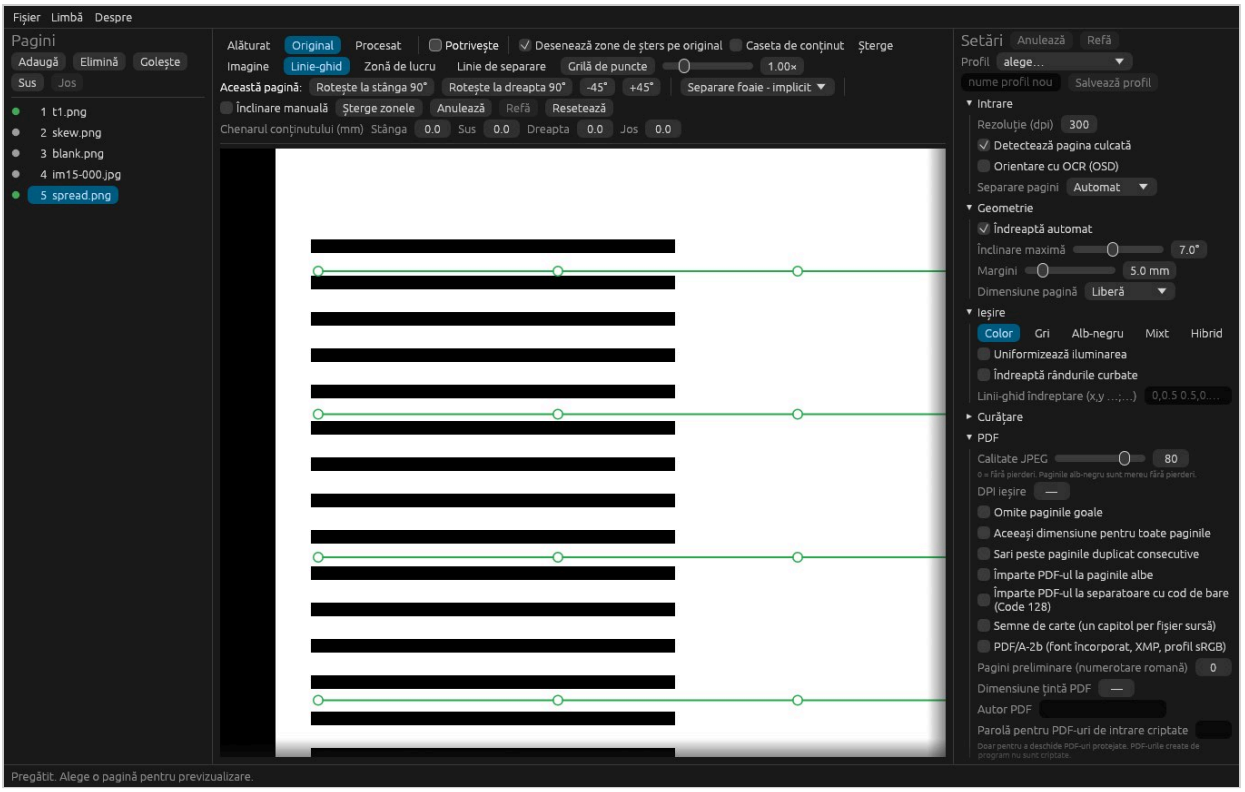


Une page entièrement blanche est marquée automatiquement : point orange dans la liste et panneau « À vérifier : 1 » avec le bouton « Suivante ».

Faites-y glisser des images, des PDF, des archives ou un dossier, ou appuyez sur « Ajouter ». Les boutons Haut/Bas changent l’ordre, « Retirer » enlève la page choisie, « Vider » enlève tout. L’ordre de la liste est l’ordre du PDF.

L’aperçu

- **Côte à côte / Original / Traité** choisit ce que vous voyez. Les zones se tracent sur l’*Original* ; la zone de contenu se corrige sur le *Traité*.
- **Ajuster** agrandit ou réduit l’image pour qu’elle tienne. Le curseur de zoom (0,2×–4×) n’apparaît que lorsque *Ajuster* est décoché.

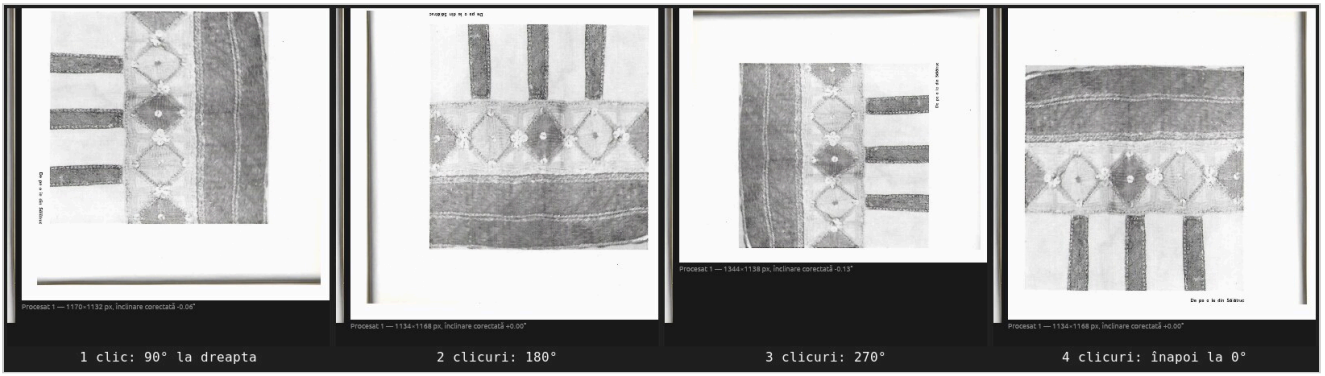


Avec « Ajuster » décoché apparaît le curseur de zoom (ici 1,00×).

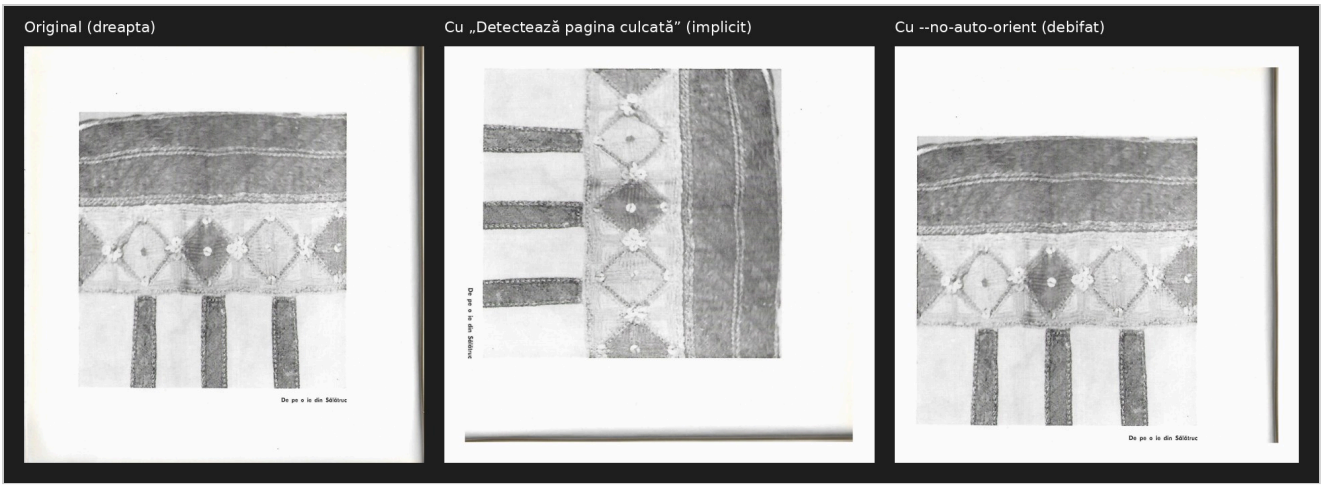
La barre « Cette page »

Ici vous corrigez seulement la page choisie : rotation à gauche ou à droite de 90°, pas de ±45°, inclinaison manuelle, mode de séparation de la feuille (par défaut, automatique, au milieu, désactivé), cadre du contenu en millimètres (gauche, haut, droite, bas ; les valeurs positives l’agrandissent) et « Réinitialiser ». **Annuler** et **Rétablir** (Ctrl+Z, Ctrl+Y) valent pour toutes ces commandes, pas seulement pour les zones.

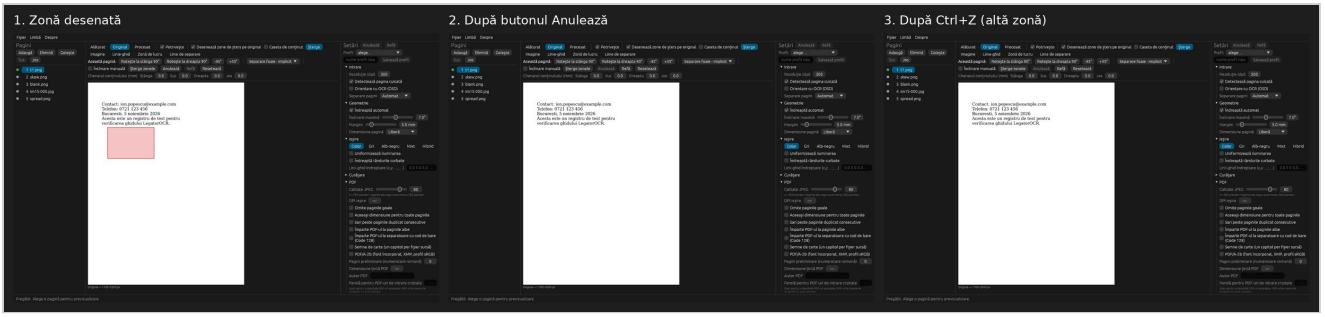
La rotation manuelle verrouille l’orientation automatique (depuis pre.18) : après avoir appuyé sur un bouton de rotation ou sur ±45°, la page n’est plus pivotée par la détection de page couchée ni par l’OSD, pas même à 0°. « Réinitialiser » lui rend l’orientation automatique. Si une page avec des images est mal pivotée dès le départ, appuyez quatre fois sur la rotation (ou décochez « Orientation par OCR (OSD) » et « Détecter la page couchée » dans les réglages, à Entrée).



Quatre clics de suite sur « Pivoter à droite de 90° » : 90°, 180°, 270°, puis retour à 0°, sans saut. Capture pre.18 sous Linux. Sous Windows 11, je n’ai pas pu vérifier.



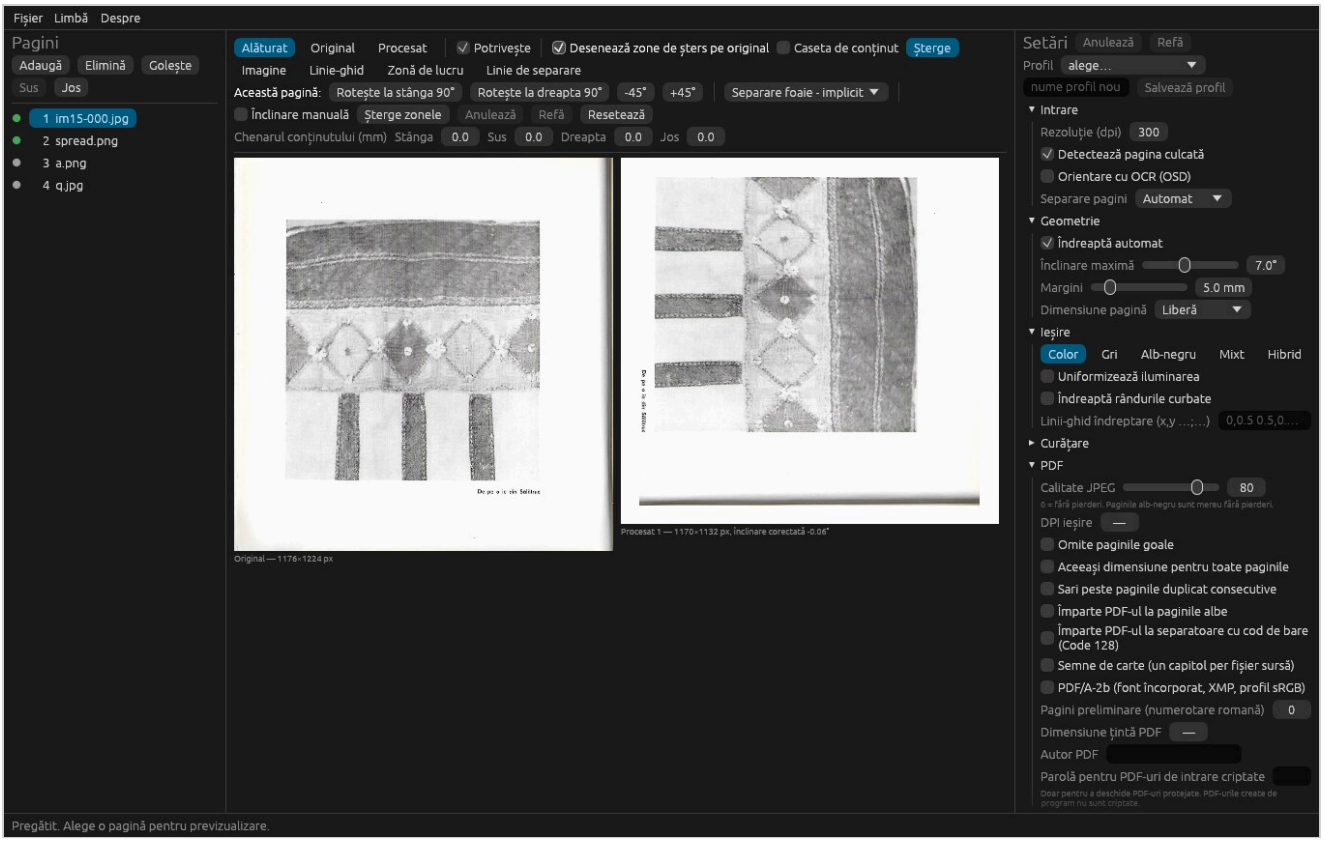
La même page (page 15 du PDF du testeur) et les mêmes réglages, hormis la détection : dans pre.18, avec « Détecter la page couchée » cochée (par défaut), le programme la pivotait de 90° alors que l’original est droit (à partir de pre.19–20 il ne la pivote plus) ; avec --no-auto-orient (ou décoché dans les réglages) elle ressort droite. Vérifié en ligne de commande ; dans la fenêtre, j’ai vu la rotation dans pre.18 et son absence dans pre.19.



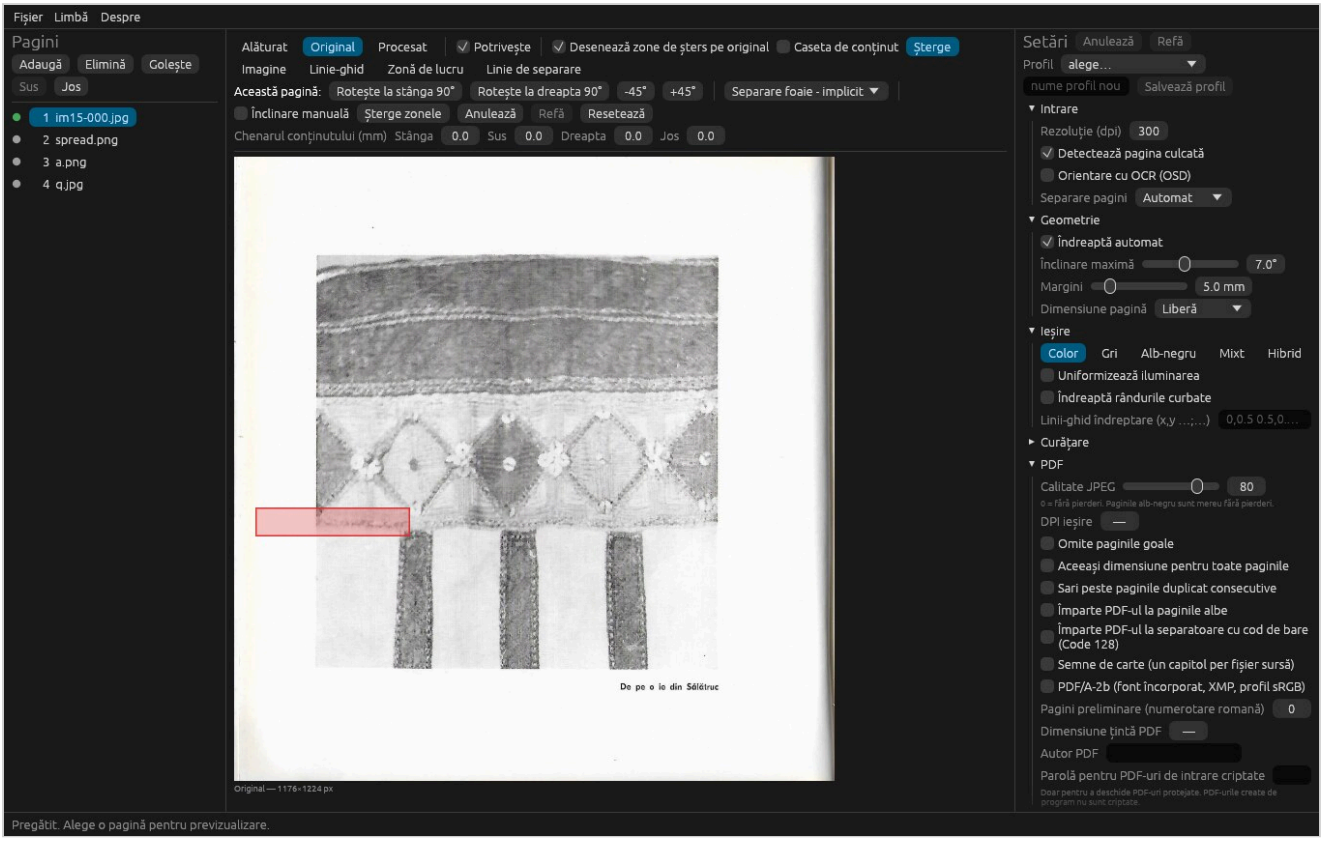
Annuler (le bouton) et Ctrl+Z (la fenêtre étant au premier plan) retirent la dernière zone tracée. Vérifié dans la fenêtre.

Zones, guides et zone de contenu

Cochez « Tracer des zones à effacer sur l’original » ; cinq types de tracé apparaissent (Effacer, Image, Ligne-guide, Zone de travail, Ligne de séparation) :

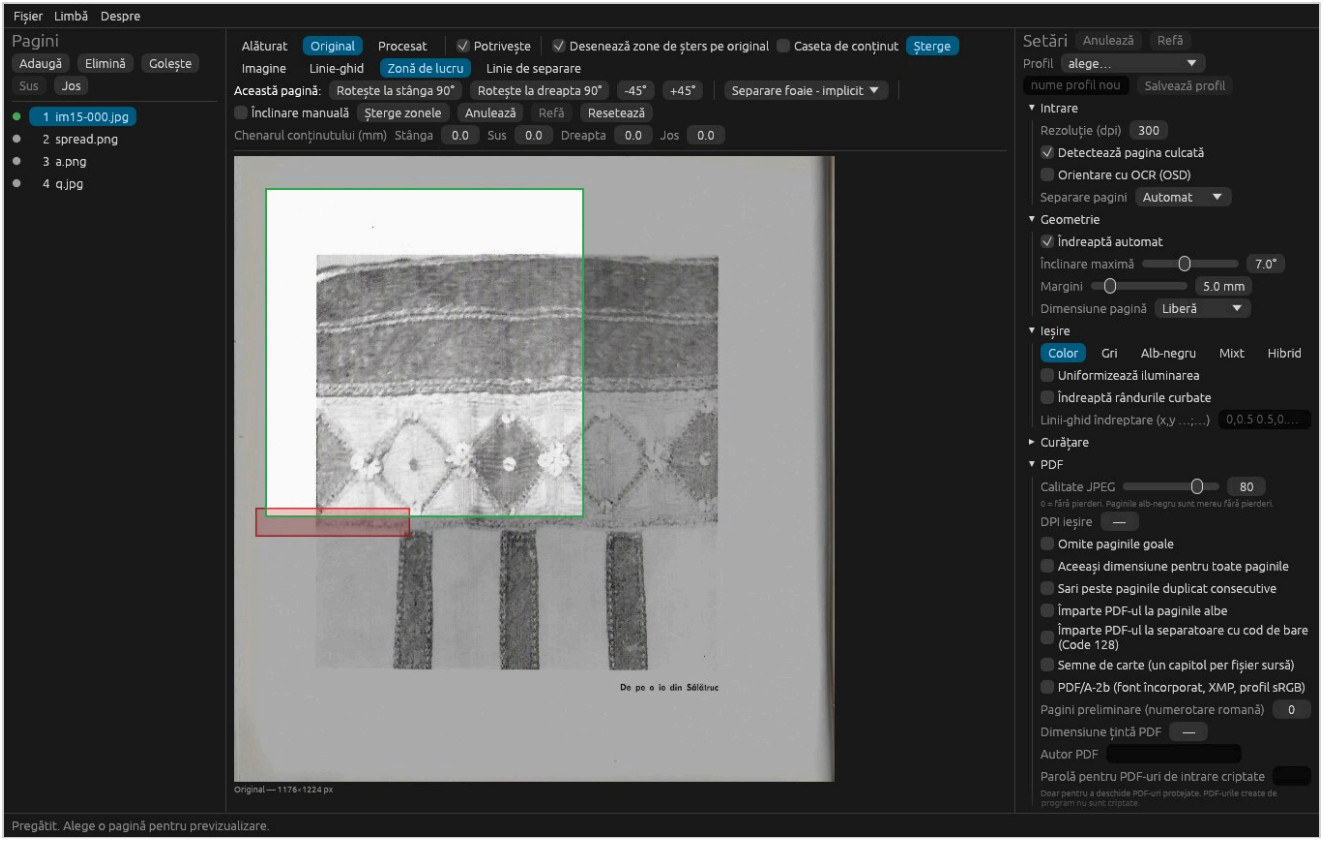


Avec « Tracer des zones à effacer sur l’original » cochée, les types de zones apparaissent : Image, Ligne-guide, Zone de travail, Ligne de séparation (et Effacer, le type par défaut).

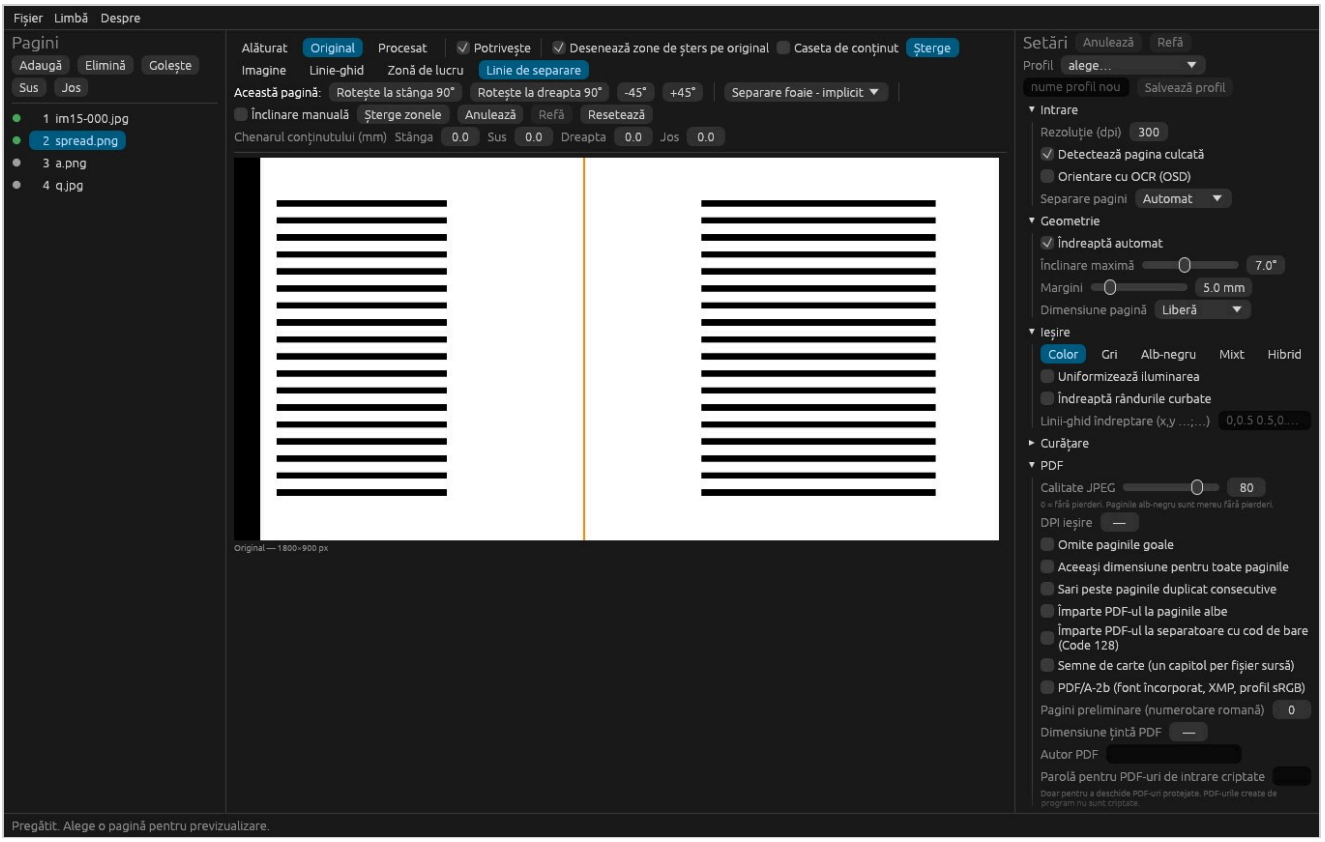


Une zone à effacer (rouge) tracée à la souris sur l’original, dans la vue Original.

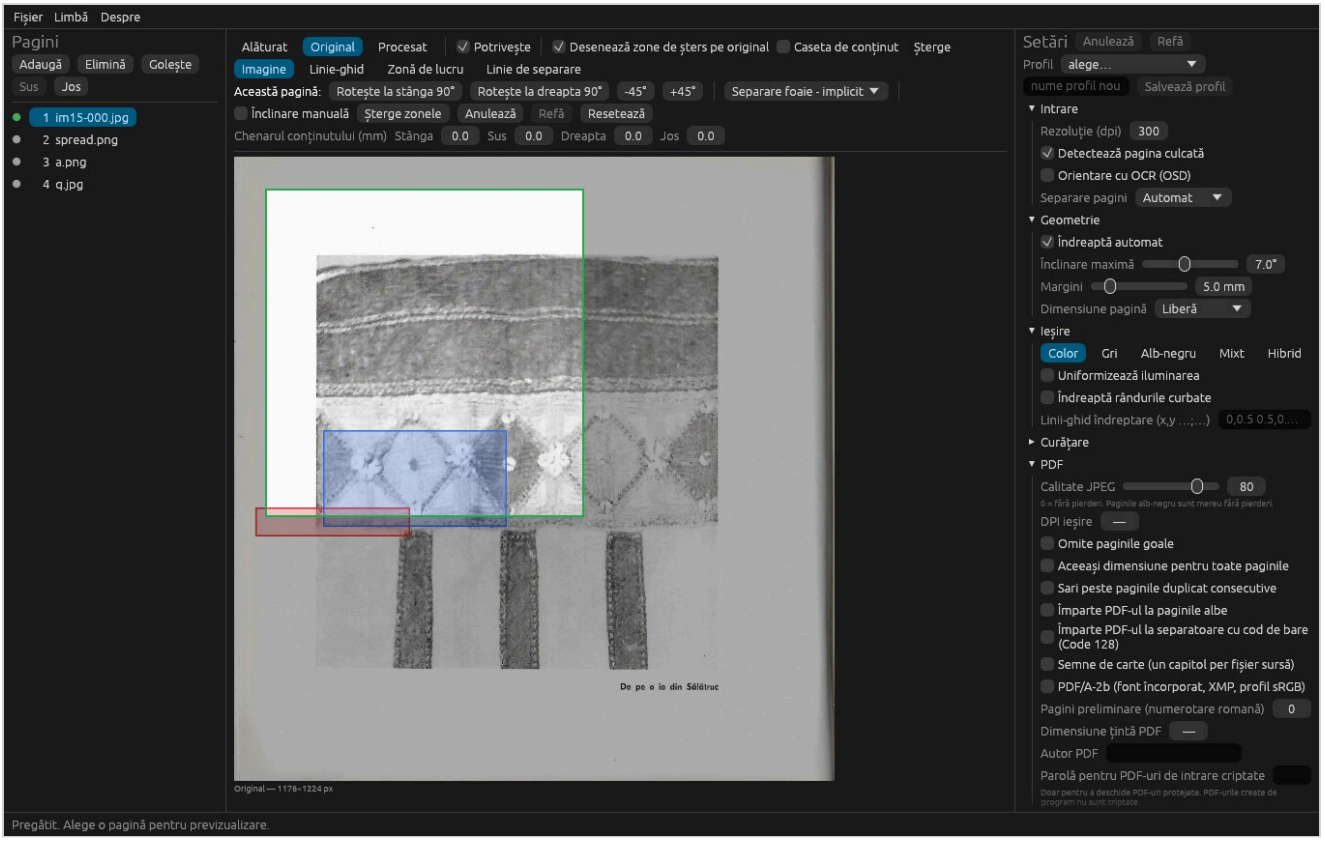
Type	Comment l’utiliser	À quoi cela sert
Effacer	Faites glisser un rectangle sur l’original. Clic droit dessus pour le supprimer. Tirez sur un coin pour le redimensionner.	Tache, tampon, note de quelqu’un, bord avec ombre
Image	Comme « Effacer ».	Indique au programme que la zone est une image, pas du texte (elle reste en couleurs en mode mixte)
Ligne-guide	Tracez à main levée le long d’une ligne courbée. Tirez sur un nœud pour le déplacer ; double-clic sur la ligne ajoute un nœud, double-clic sur un nœud le supprime ; clic droit sur la ligne la supprime.	Redresse la page d’après les lignes que vous avez tracées



La zone de travail (cadre vert) : tout ce qui est en dehors est écarté, et la zone restante se voit dans la page traitée. Elle a aussi une zone à effacer (rouge).



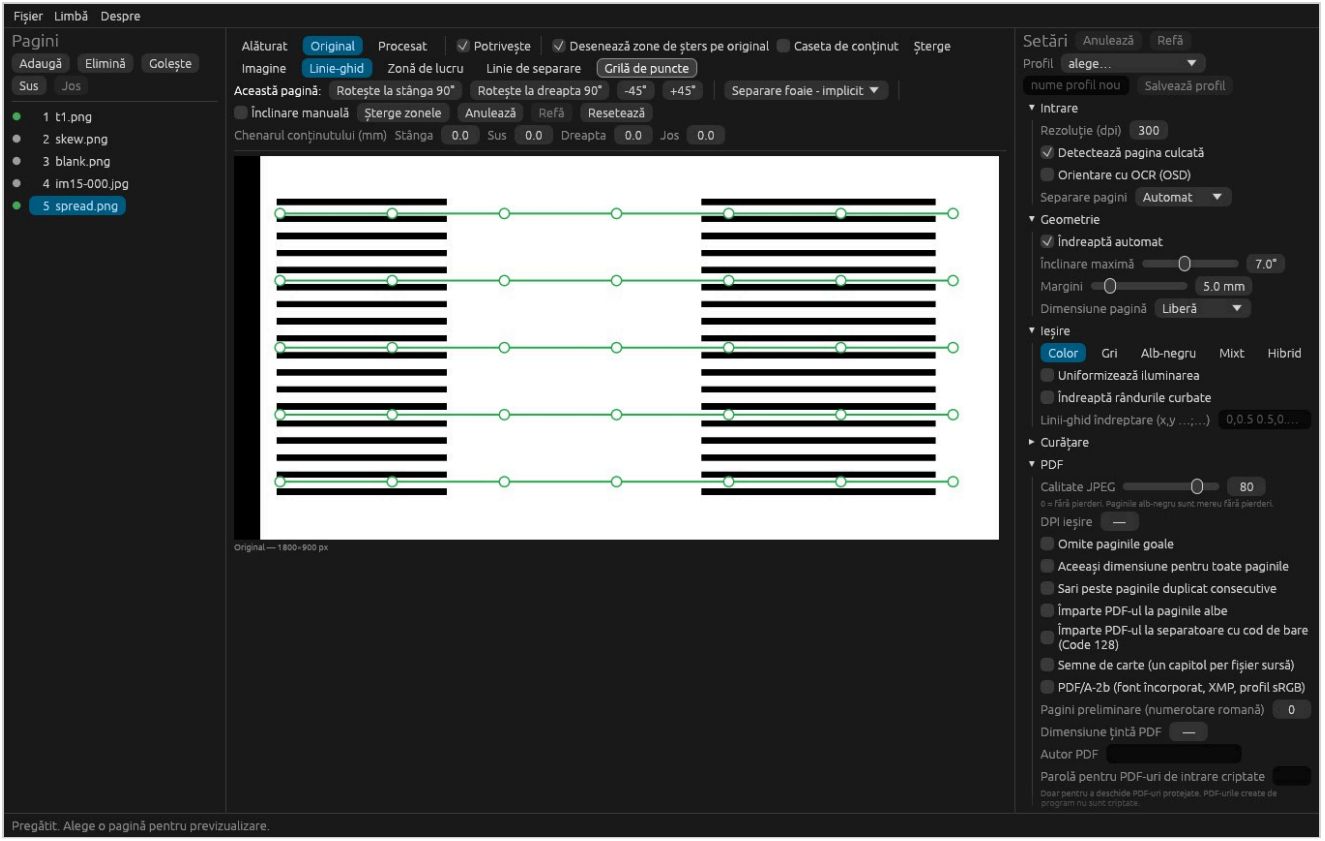
La ligne de séparation (orange) déplacée à la souris sur une double feuille. L’exemple est une feuille de test synthétique, avec des lignes à la place du texte.



Une zone d’image (bleue) tracée sur l’original. En mode Couleur elle ne change rien ; l’effet se voit en mode Mixte (figure suivante).



La même page et la même zone d’image (bleue) : en mode Mixte la zone reste grise (à gauche), en mode Noir et blanc tout devient noir et blanc (à droite). La page apparaît pivotée de 90° par la détection de page couchée (voir plus haut).



« Grille de points » pour la Ligne-guide : 5 lignes de 7 points, au-dessus des lignes de texte.

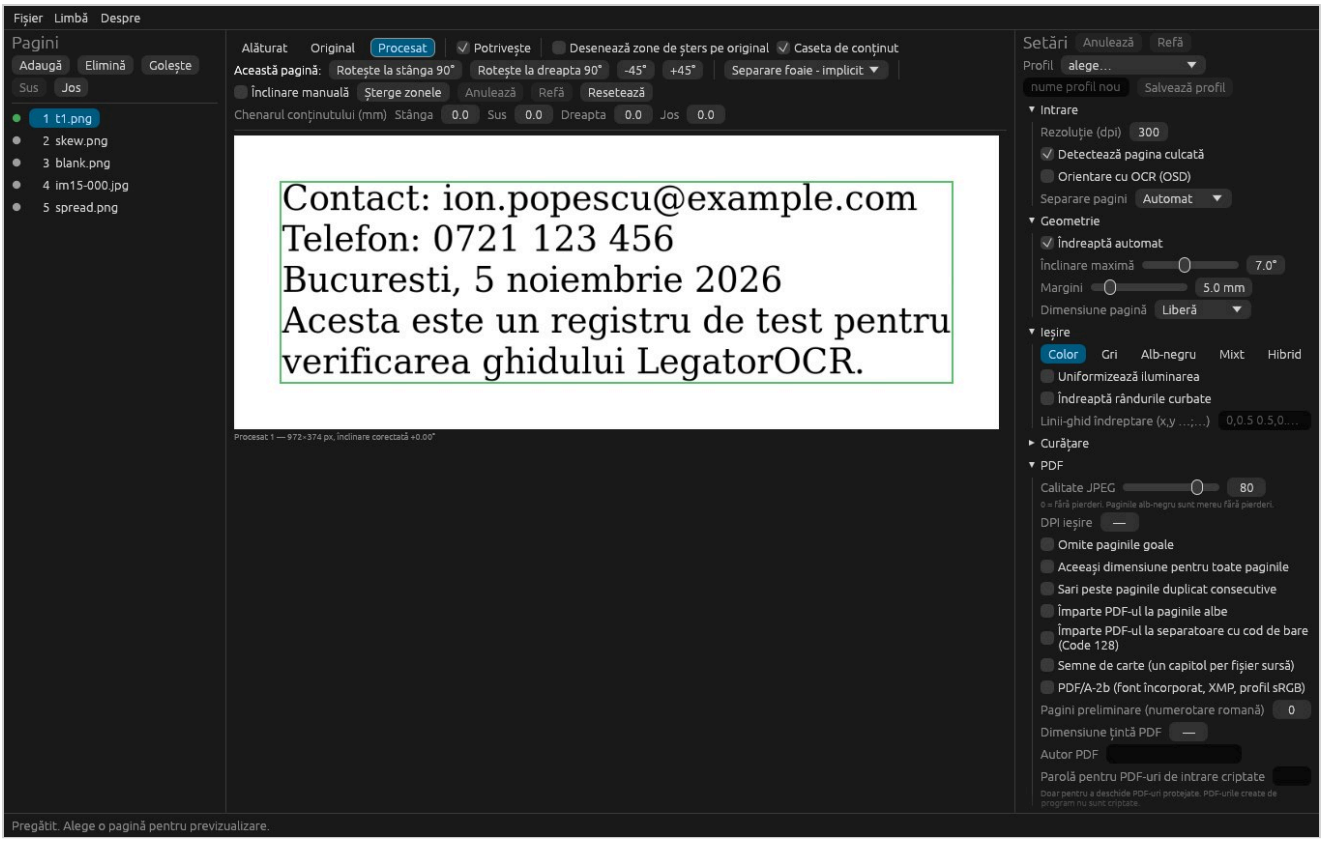
Grille de points (pour *Ligne-guide*) ajoute 5 lignes de 7 points, que vous faites glisser sur les lignes de texte. Un second clic sur le bouton n’ajoute pas la même grille une deuxième fois. Si vous avez déjà déplacé des points, une nouvelle grille s’ajoute à côté de celle qui a été déplacée.

Zone de travail (depuis l’édition pre.18) : vous faites glisser un rectangle sur l’original ; tout ce qui est en dehors est peint à la couleur du papier avant toute mesure, si bien qu’un bord sombre ou la page voisine ne compte plus. Clic droit sur l’original pour la supprimer. En ligne de commande : `--work-area X,Y,L,H` (millimètres).

Ligne de séparation (depuis l’édition pre.18) : d’un clic ou en glissant sur l’original, vous déplacez la ligne verticale orange ; la double feuille est coupée là, et non au milieu ou à la

gouttière. Depuis pre.21 cela fonctionne à toute rotation ; pour les feuilles tournées de 90° ou 270°, la ligne coupe à l'horizontale et les pages sortent l'une sous l'autre (la page de gauche de l'original d'abord). Clic droit pour la supprimer. En ligne de commande : `--cut-at 0.45`.

La zone de contenu (la case du même nom) affiche un cadre vert sur la page traitée. Vous tirez sur les côtés pour élargir ou rétrécir la zone conservée. Sur une feuille coupée en deux pages, seule la page sur laquelle on tire le cadre change.



La zone de contenu (cadre vert) sur la page traitée.

Pages courbées, coupe oblique et réglages par page

Trois outils pour les feuilles photographiées à la main :

- **Ligne de coupe oblique.** Avec « Dessiner des zones d'effacement sur l'original » et le type Ligne de coupe, le curseur « Inclinaison de la ligne » (−20° à 20°) incline la ligne ; chaque page garde son côté de la ligne oblique et l'autre côté est peint de la couleur du papier. Clic droit sur la ligne : la supprimer et remettre l'inclinaison à zéro. En ligne de commande : `--cut-angle DEGRÉS`.
- **Correction trapézoïdale.** Deux curseurs de la barre « Cette page » (« Trapèze haut–bas », « Trapèze gauche–droite », ±30 %) redressent avant la coupe une feuille photographiée en biais. Le bouton **Trapèze auto** (après la séparation des pages) mesure chaque page — inclinaison des lignes de texte et largeur du texte en haut et en bas — et retient une correction pour cette page seulement. Il est prudent à dessein : si les lignes sont trop peu nombreuses ou si les mesures se contredisent, il laisse la page telle quelle. Vérifiez le résultat, Annuler sous la main. Les boutons −45°/+45° restent. En ligne de commande : `--keystone-v` et `--keystone-h` (pourcentages).
- **Réglages par page.** « Réglages pour : Toutes les pages / Cette page seulement », au-dessus de Sortie et Nettoyage, applique le mode de sortie, le seuil, l'élimination des points

et les autres réglages de nettoyage à une seule page d'une feuille coupée ; le cadre vert du contenu ne change que la page sur laquelle on le tire. Dans un projet : `page1.CLÉ = VALEUR` / `page2.CLÉ = VALEUR` sous [sheet]. Un clic sur une page traitée la sélectionne (cadre bleu) : le mode de sortie (gris, noir et blanc, mixte), le nettoyage, la correction trapézoïdale, le cadre vert et les crayons OCR n'agissent alors que sur elle. Les zones OCR dessinées restent attachées à cette page (`page1.page_ocr_zones`, `page_ocr_ignore`).

La barre sous l'aperçu contient le cadre de contenu, les crayons OCR et l'**Auto-crayon OCR** (séparément pour la page de gauche et celle de droite) : il place la zone OCR sur le contenu de cette page.

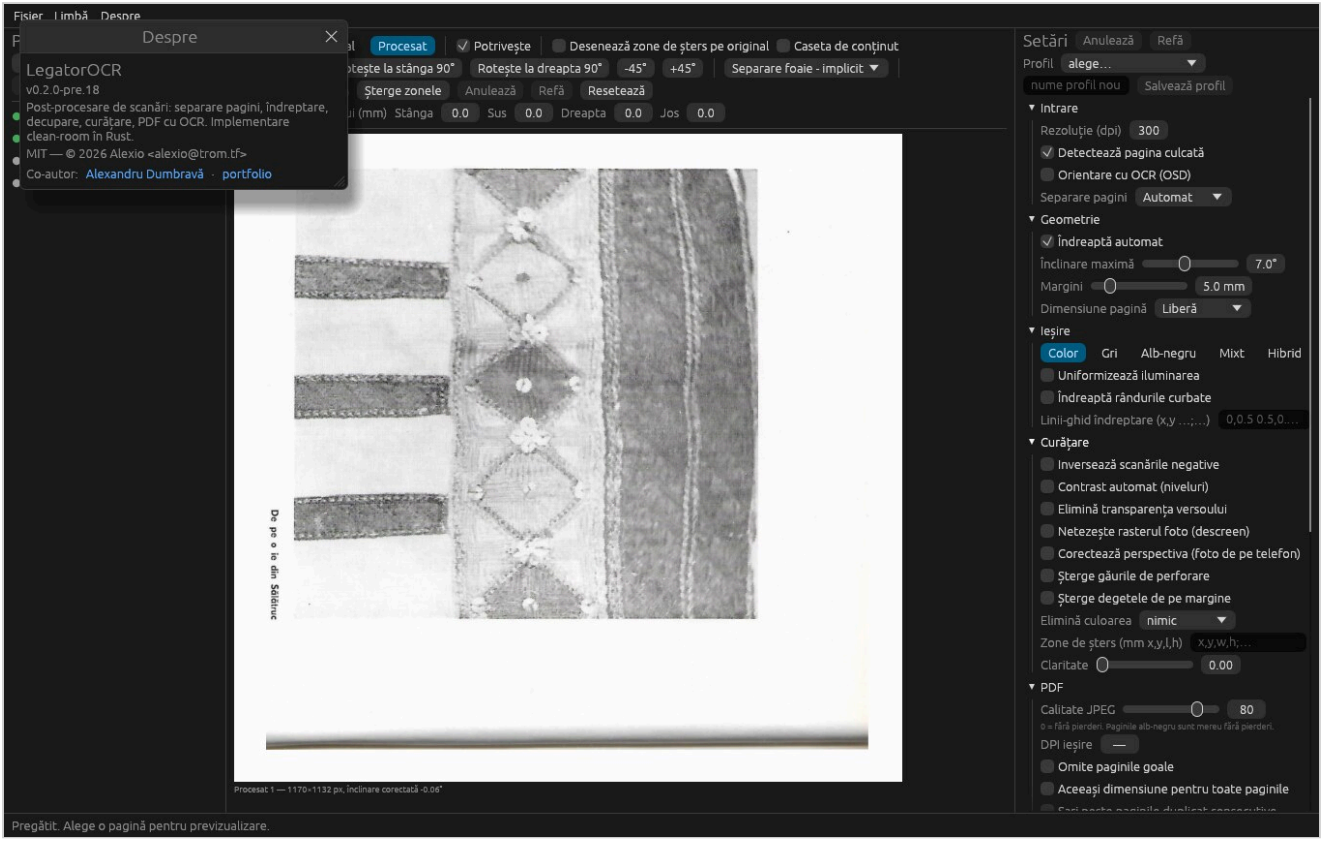
L'inclinaison manuelle agit sur la page sélectionnée (gauche ou droite) d'une feuille coupée : chaque page peut avoir son propre angle (`page1.page_skew`, `page2.page_skew`).

Zoom : dans la barre du bas, **A+** / **A-** agrandissent ou réduisent toute l'interface (aussi Ctrl + / Ctrl −), et **Auto** l'ajuste à la taille de la fenêtre. La fenêtre démarre agrandie avec un zoom automatique, pour que le texte soit grand et occupe l'écran ; votre choix est conservé.

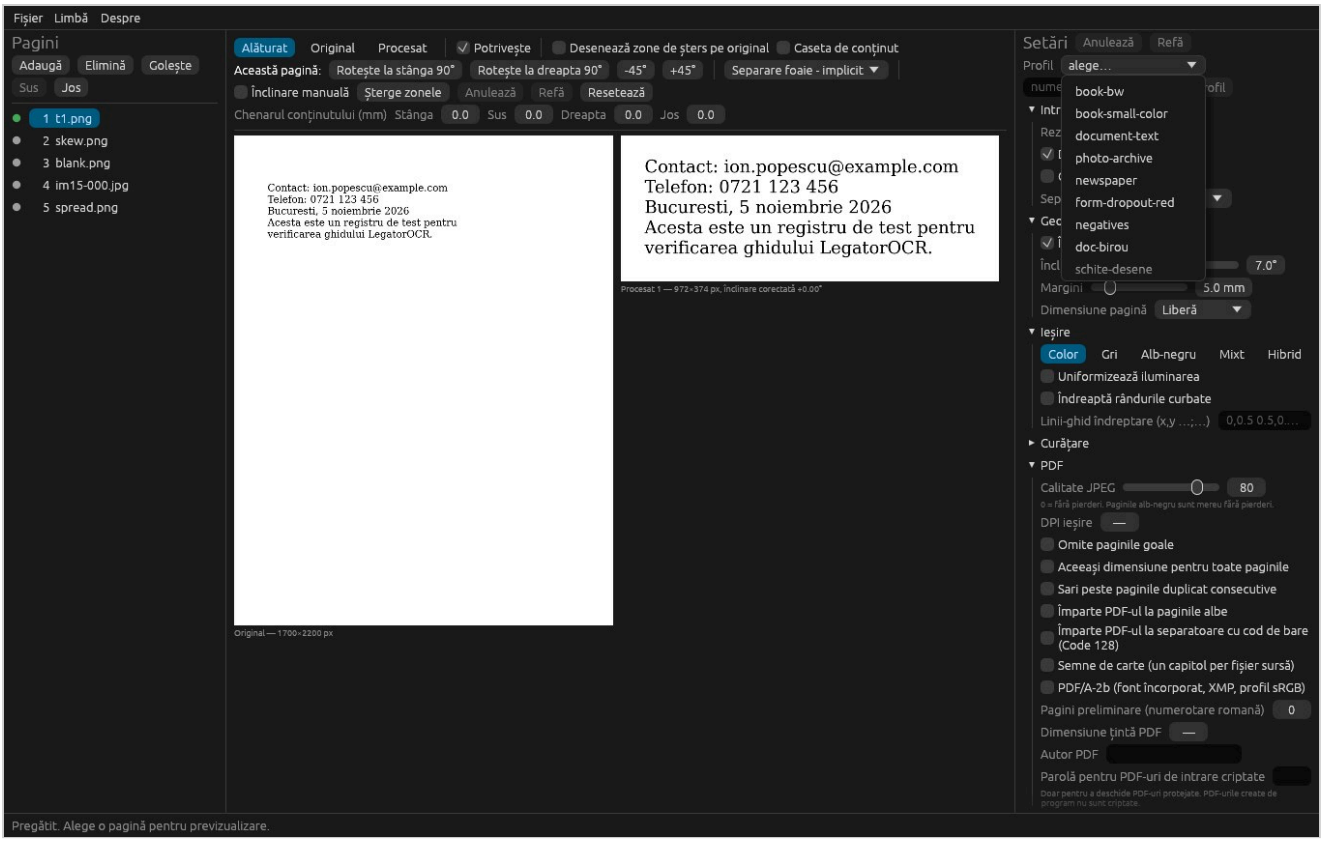
Les formats de page comprennent maintenant A2–A6, B3–B6, Letter, Legal et Tabloid (`--page-size` accepte les mêmes noms). Crayons OCR sur les pages traitées : vert (zone OCR), rouge (zone ignorée), violet (tableau, lu comme un bloc ligne par ligne ; `--ocr-zone X,Y,W,H#table`).

Les réglages à droite

Ils sont groupés par sections : Entrée, Géométrie, Sortie, Nettoyage, PDF, OCR, plus les profils. La section 6 explique ce que fait chacune.



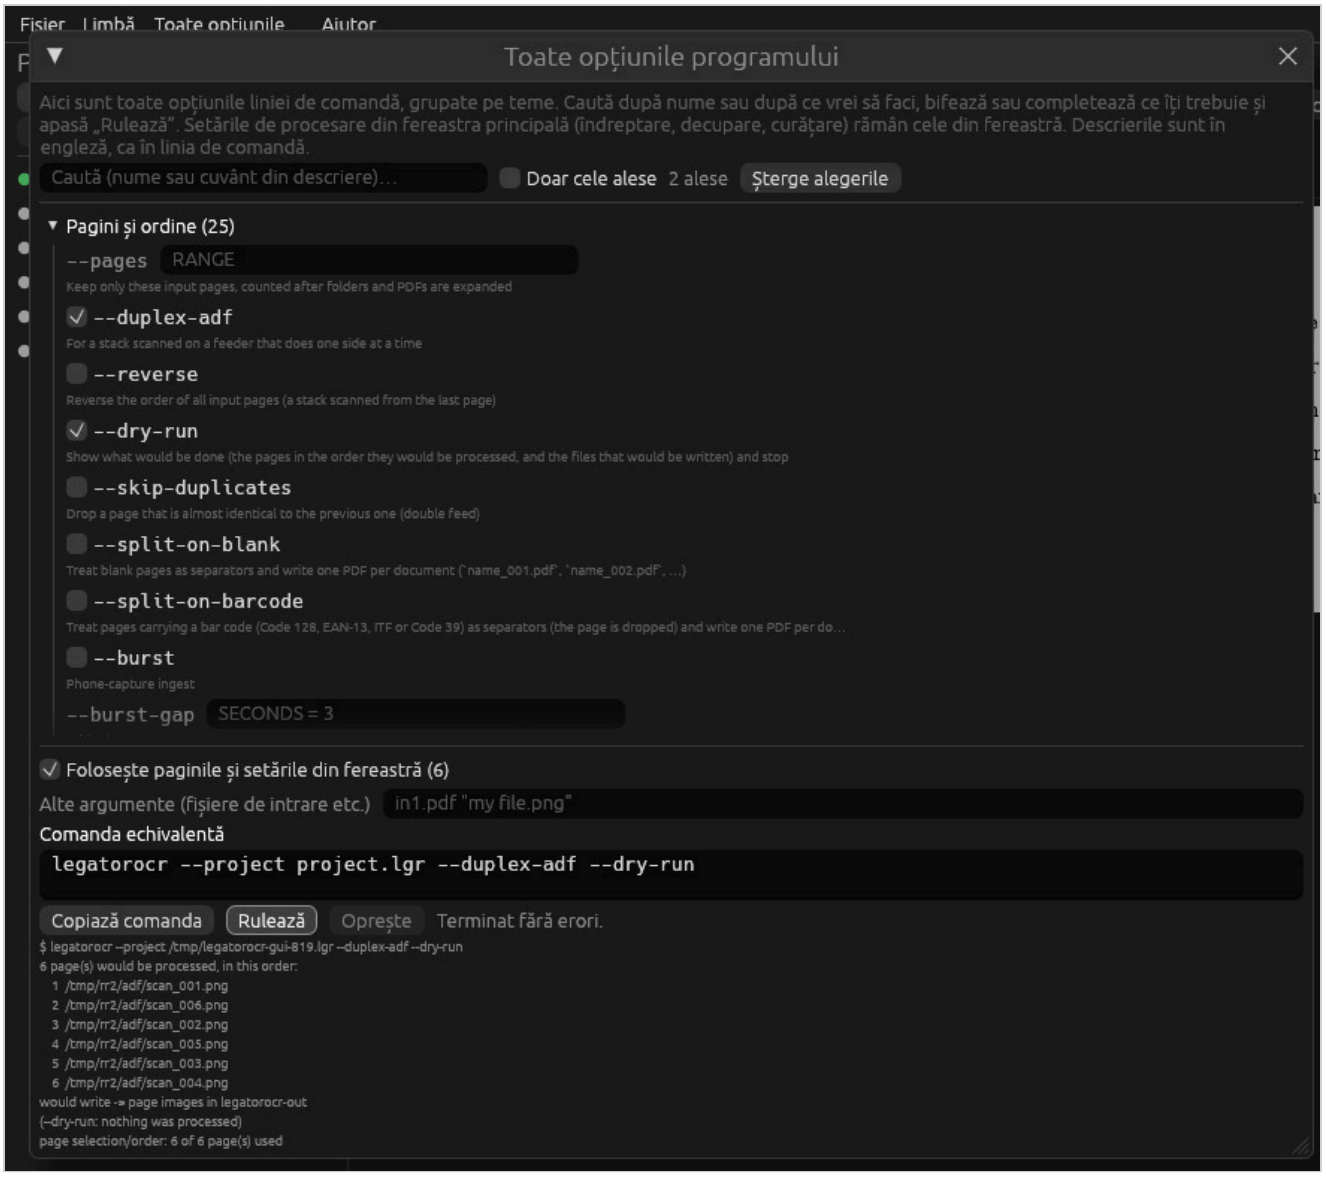
La section Nettoyage des réglages, déroulée : inversion des scans négatifs, contraste automatique, perspective, suppression des trous de perforation, zones à effacer sous forme de nombres.



La liste « Profil » des réglages (les profils intégrés ; les vôtres apparaissent au même endroit après « Enregistrer le profil »).

Toutes les options et le guide d’utilisation

Le bouton **Toutes les options…** de la barre du haut ouvre une fenêtre avec **toutes** les options de la ligne de commande (plus de 200), groupées par thèmes : pages et ordre ; redressement, rognage et nettoyage ; sorties (PDF, images, documents) ; OCR et texte ; archivage, signature et vérification ; recherche et comparaison ; lots, système et modules. La liste est lue directement depuis le programme en ligne de commande livré avec la fenêtre, elle correspond donc toujours à l’édition que vous avez.

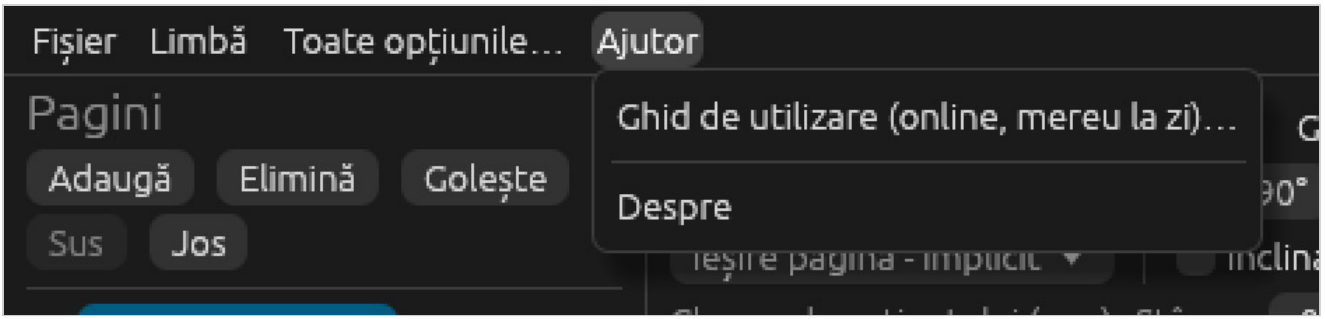


La fenêtre « Toutes les options », avec le groupe « Pages et ordre » ouvert, `--duplex-adf` et `--dry-run` cochées et le résultat de l'exécution : l'ordre dans lequel les six pages de la pile seraient traitées (pages de test faites par moi).

- **Rechercher** par nom (`pdf`, `dry`) ou par un mot de la description ; les groupes qui ont des résultats s'ouvrent d'eux-mêmes. « Seulement les choisies » montre ce que vous avez coché ou rempli.
- Les champs vides ne sont pas envoyés : une option avec valeur n'entre dans la commande que lorsque vous écrivez quelque chose (ou choisissez dans la liste). Le bouton **Choisir…** ouvre la boîte de dialogue de fichiers ou de dossiers. Pour les options qui peuvent se répéter (par exemple `--erase`), vous écrivez une valeur par ligne.
- **Utiliser les pages et les réglages de la fenêtre** (cochée par défaut) : la commande reçoit les pages chargées, avec les ajustements de chacune, via un projet temporaire. Les réglages de traitement de la fenêtre principale (redressement, rognage, nettoyage) ont priorité ; ici vous complétez les sorties et les fonctions spéciales. Décochez pour des commandes sans pages (`--doctor`, `--verify-sums`) ou écrivez les fichiers d'entrée dans « Autres arguments ».

- **La commande équivalente** se met à jour au fil de vos choix ; vous pouvez la copier et l'utiliser dans un terminal ou dans des scripts. **Exécuter** la lance et montre le résultat en dessous ; **Arrêter** l'interrompt. Les chemins relatifs sont relatifs à votre dossier personnel.
- Les descriptions des options sont en anglais, comme en ligne de commande ; le reste de la fenêtre est dans la langue choisie.

Le menu **Aide** contient le lien vers ce guide : *Guide d'utilisation (en ligne, toujours à jour)* ouvre la dernière version publiée sur legatorocr.chiuta.ro, et *Guide de cette édition* (apparaît quand le fichier PDF se trouve à côté du programme, comme dans les archives publiées) ouvre la copie livrée avec le programme. Le guide est refait à chaque édition, et la publication d'une édition est interrompue si le guide ne mentionne pas sa version.



Vérifié : la fenêtre, la recherche, le cochage, l'exécution d'une commande avec les pages de la fenêtre (la capture ci-dessus) et l'ouverture du menu Aide, sous Linux, sur un écran virtuel. Non vérifié : Windows, macOS et arm64 ; l'ouverture effective du guide dans un navigateur (je n'ai vérifié que le menu) ; les boîtes de dialogue « Choisir… » ; les traductions des textes nouveaux de la fenêtre (écrites automatiquement).

Collections

Une collection réunit journaux, revues, livres et autres dans un seul fichier `.lgrcol` (JSON). Gardez-le dans le dossier des scans : les chemins du fichier sont écrits relativement à lui quand la cible se trouve sous un dossier commun, de sorte que le dossier peut être déplacé ou copié. Chaque élément a un type, un titre, un numéro ou volume, une date ou année, des langues, des sources (images, un dossier d'images, un PDF, un projet `.lgr` enregistré), le PDF obtenu, un profil, un état (à faire, traité, OCR fait, vérifié), un nombre de pages, des étiquettes et des notes.

```
legatorocr collection new Archive/ --name "Old papers"
legatorocr collection add Archive/old_papers.lgrcol --folder Archive/scans
legatorocr collection list Archive/old_papers.lgrcol
legatorocr collection run Archive/old_papers.lgrcol --out Archive/pdf
legatorocr collection search Archive/old_papers.lgrcol "Scînteia"
legatorocr collection reindex Archive/old_papers.lgrcol
legatorocr collection set Archive/old_papers.lgrcol i1 --status checked --tags "1977, youth"
legatorocr collection remove Archive/old_papers.lgrcol i2
```

- `add --folder` : chaque PDF, projet `.lgr` et sous-dossier d'images devient un élément. Titre, type, date et numéro sont déduits du nom : `scinteia_tineretului_1977_09_8801.pdf` donne un journal, « Scinteia Tineretului », 1977-09, n° 8801. Ce n'est qu'une supposition (les noms de fichiers n'ont pas de diacritiques ; le type repose sur quelques mots-clés et sur la numérotation : une date complète ou un numéro de 500 ou plus passe pour un journal) ; corrigez-la dans la fenêtre. Pour `nom_année_mois_numéro`, un nombre de trois chiffres ou plus est le numéro (`..._1977_09_8801`) ; un nombre d'un ou deux chiffres juste après le mois n'est

un jour que si c'est un vrai jour de ce mois et, quand c'est la dernière partie, si le nom ne dit pas revue ou livre (`gazeta_1914_05_12` est le 12 mai, `revista_sinteza_1985_03_12` est le numéro 12, `..._1977_09_12_8801` est le 12, numéro 8801).

- `run` traite les éléments à l'état « à faire », chacun avec son profil (sinon celui de la collection, sinon les réglages par défaut), par le même code que la ligne de commande et la fenêtre (`run_export`). Un élément qui échoue (source absente, profil inconnu, page illisible) est marqué avec la raison et les autres continuent ; le fichier de la collection et l'index sont enregistrés après chaque élément, donc une annulation ou un plantage ne perd rien de ce qui était fait. Les PDF vont à côté du fichier de la collection, ou dans `--out`. Avec l'OCR (activé par défaut ; `--no-ocr` le coupe) le texte reconnu de chaque page va dans `NOM.lgrindex` ; la langue de l'OCR vient des langues de l'élément, sinon de `ocr_langs` du profil, sinon le roumain. Un élément en échec n'est pas retenté sauf avec `--retry-failed` ou `--item ID`.

- `search` cherche dans cet index. Majuscules, diacritiques et ancienne orthographe roumaine sont ignorées (`Scînteia` trouve `Scânteia`, `sînt` trouve `sunt`). Elle affiche élément, page et un extrait : d'abord les pages où les mots se suivent, puis (marquées) les pages qui ont tous les mots mais séparés.

- `reindex` (alias `index`) lit la couche de texte des PDF dans le même index **sans rien retraiter** : pour un élément dont la source est un seul PDF qui a déjà du texte (PDF interrogeables d'un autre programme, ou faits par LegatorOCR) et pour les éléments traités auparavant. Il lit le PDF fait par `run` s'il existe, sinon l'unique source PDF de l'élément ; l'état et les fichiers de l'élément ne changent pas. Un scan sans texte est signalé (`no text layer`) et non indexé (traitez-le avec l'OCR) ; un élément à plusieurs sources, ou seulement des images, n'a pas de PDF à lire. `--item ID` le restreint. Le texte est pris tel que le PDF l'a (polices avec table ToUnicode, comme l'écrivent LegatorOCR, Tesseract, ABBYY, Word …) ; un PDF dont le texte ne peut pas être décodé ne donne rien ou du charabia.

- `set FICHIER ÉLÉMENT` modifie `--title --issue --date --kind --profile --status --tags --notes` (seulement ce qui est donné ; un texte vide efface le champ ; une valeur incorrecte ne change rien ; `--status todo` fait que le prochain `run` retraite l'élément). `remove FICHIER ÉLÉMENT...` retire des éléments de la collection et de l'index ; leurs PDF et fichiers sources ne sont pas touchés.

- La fenêtre **Collections…** (menu Fichier, ou Ctrl+K) : un tableau avec la lettre du type, titre, numéro/date, pages et une pastille d'état (couleur et texte), avec filtre et tri ; les détails à droite ; Ajouter des fichiers, Ajouter un dossier, Traiter la sélection, Traiter tout ce qui attend (avec progression et Annuler), Indexer le texte / Tout indexer (le `reindex` ci-dessus), Ouvrir le PDF, Afficher le dossier ; une zone de recherche dans toute la collection avec des résultats sur lesquels on peut cliquer. Un double clic sur un résultat ouvre le PDF à cette page quand le programme PDF par défaut de l'ordinateur est de ceux dont on sait qu'ils respectent un numéro de page (Linux : Okular, Evince, Zathura, MuPDF, Firefox, Chrome, Chromium, Edge ; Windows : SumatraPDF, Adobe Acrobat/Reader, Chrome, Edge, Firefox ; trouvé en demandant au système quel programme ouvre les PDF) ; sinon le PDF s'ouvre normalement et le numéro de page est écrit dans la ligne d'état. Le traitement depuis la fenêtre utilise le Tesseract réglé dans les paramètres de la fenêtre principale (le profil d'un élément peut encore en nommer un autre). Ses textes existent dans les 8 langues de la fenêtre.

Vérifié : tests unitaires (devinette du nom, y compris les motifs année-mois-numéro, chemins relatifs, fichiers abîmés, recherche avec diacritiques, un lot qui continue après un échec et après

une panique, annulation, le fichier d'index avec et sans son cache, fichiers d'index de l'ancien format, un index tronqué ou abîmé, réindexation d'un PDF avec et sans texte, `set` et `remove`, les commandes de lecteur de chaque plateforme), tests du vrai programme et un essai avec le vrai Tesseract sur deux pages synthétiques, aussi après déplacement du dossier. **Mesuré** sur un index synthétique de 5000 éléments × 20 pages (100 000 pages de 350 mots, fichier texte de 357 Mo ; version release sur une machine partagée à 2 cœurs, donc des ordres de grandeur seulement) : l'ouverture prend 62 ms avec le cache des listes de mots (38 Mo) et 12 s sans lui (première ouverture, ou fichier modifié par un autre programme) ; 82 Mo de mémoire après ouverture (l'ancien index, gardé entier en mémoire : 34 s et environ 480 Mo) ; une recherche d'un mot 40 à 130 ms, de deux mots très fréquents jamais côte à côte 3 s.

Limites : la fenêtre a été écrite et compilée, mais personne ne l'a vue à l'écran ni n'y a cliqué, donc ses nouveaux boutons, la ligne d'état et l'ouverture à une page n'ont pas été essayés ; les commandes de lecteur ne sont testées que comme texte, jamais lancées avec Okular, Acrobat ou les autres ; sous macOS et avec tout autre programme PDF la page n'est pas transmise, seulement affichée dans la ligne d'état ; la page d'un résultat est celle du PDF lu (pour un élément traité, le PDF fait par `run`), donc après remplacement de ce PDF par un autre aux pages différentes lancez `reindex` ; `reindex` ne fait pas d'OCR et ne peut pas lire un texte que le PDF ne décode pas ; l'index est réécrit entièrement à chaque sauvegarde (environ 2 s pour 357 Mo), donc modifier un très gros index est plus lent qu'un petit ; deux programmes qui écrivent les mêmes fichiers en même temps : le dernier gagne ; la règle de l'ancienne orthographe est celle de `--ocr-modern-spelling` et peut réunir des mots différents (`mână` / `mină`).

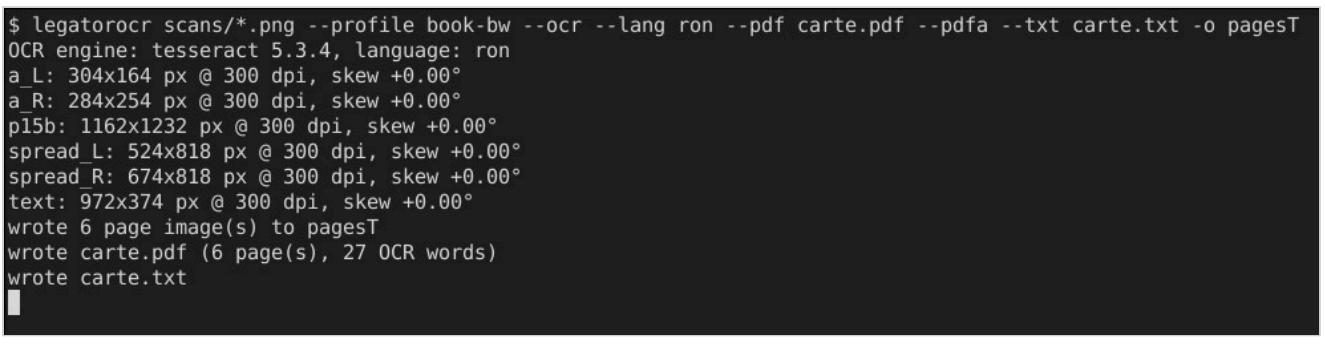
5. La ligne de commande : recettes pour les tâches courantes

Syntaxe générale : `legatorocr ENTREES... [options]`. Les entrées peuvent être des images (PNG, JPEG, TIFF, BMP), des PDF numérisés ou un dossier. `legatorocr --help` liste toutes les options ; `--list-profiles` montre les profils. Les options des recettes sont vérifiées automatiquement avant chaque édition, elles existent donc réellement ; les recettes elles-mêmes n’ont pas toutes été essayées sur du matériel réel.

Livre numérisé → PDF avec texte interrogeable

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

`--pdfa` écrit du PDF/A-2b pour l’archivage, et `--txt` enregistre aussi le texte. `-o pages` est le dossier des images traitées.

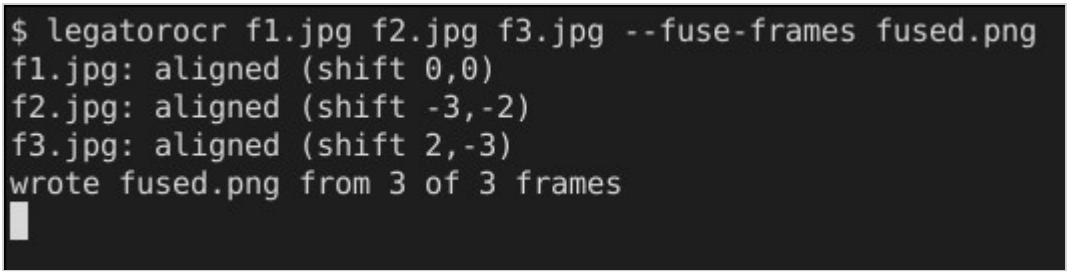


La recette sur 4 fichiers de test : 6 pages dans carte.pdf. Avec --pdfa le programme écrit du PDF/A-2b.

Photos de téléphone → pages propres

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

Le profil uniformise la lumière, corrige la perspective, efface le fond autour de la page (`--trim-background`), coupe les livres ouverts au milieu, élargit la plage d'inclinaison et retire les doigts sans toucher au texte. Une page qui ressort sans texte est relue une seconde fois, uniquement sur son contenu. Pour des pages uniformes en A4, avec le texte agrandi, utilisez `--profile phone-photos-a4`. Plusieurs photos d'une même page peuvent d'abord être combinées avec `--fuse-frames` (utile en cas de fort bruit ; pas en cas de bruit modéré). L'option reçoit un fichier de sortie : legatorocr poza1.jpg poza2.jpg poza3.jpg --fuse-frames pagina.png, puis vous traitez pagina.png comme d'habitude ; la première photo sert de référence.

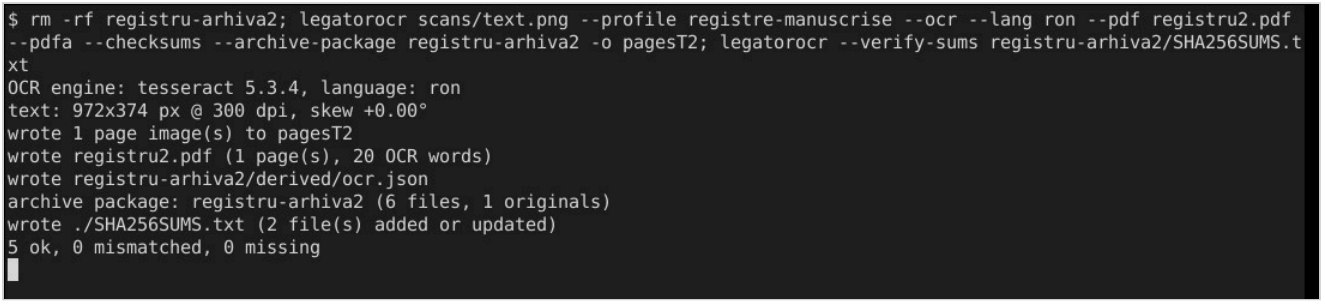


--fuse-frames avec trois photos d'une même page : il les aligne et écrit fused.png à partir de 3 images sur 3.

Copie d'archive avec preuve d'intégrité

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

Le paquet conserve les originaux, le projet, les mots OCR avec confiance, les sorties et un `RUN.txt` qui explique comment reprendre le travail. Pour des copies sur d'autres disques : `--backup-from` et `--backup-to`.



Le paquet d'archive créé et vérifié : « 5 ok, 0 mismatched, 0 missing ».

Masquer noms et numéros avant le partage

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

Les mots trouvés sont noircis dans l'image et retirés du texte. **Vérifiez le résultat à l'œil :** un mot que l'OCR n'a pas reconnu n'est pas masqué.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Résultat réel : le numéro de téléphone a été masqué, mais l'adresse e-mail NON, parce que l'OCR a lu « @ » comme « G » (ion.popescuGexample.com) et que le modèle d'e-mail n'a pas correspondu. C'est pourquoi vous devez vérifier le résultat à l'œil. Depuis pre.20, le programme écrit à la fin combien de mots chaque motif a couverts et avertit quand un motif n'a rien trouvé ou quand il reste dans le texte des mots qui ressemblent à des adresses ou à de longs numéros, exactement comme dans la capture ci-dessus.

Gros lot sur plusieurs ordinateurs

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Exécutez la même liste sur chaque machine, avec un `--shard` différent. Pour une mémoire réduite : `--max-memory 500`. Pour des fichiers inconnus ou hostiles : `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

Le lot divisé en deux (--shard 1/2 et 2/2) puis réuni avec --merge-pdf.

Signer un PDF

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

Le niveau juridique de la signature est celui de votre certificat. Le mot de passe du certificat se donne par la variable d'environnement, pas sur la ligne de commande. L'horodatage (`--sign-timestamp`) n'a été vérifié qu'avec une autorité locale par HTTP, pas avec une vraie autorité par HTTPS.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Signature et vérification avec un certificat de test que j'ai créé (pas un vrai certificat). « time stamp inside: none » : je n'ai pas demandé d'horodatage.

Pile numérisée sur chargeur, ordre et plage de pages

De nombreux scanners à chargeur font passer la pile une fois sur chaque face : d'abord toutes les faces recto (1, 3, 5…), puis tous les versos, en ordre inverse (6, 4, 2). Les fichiers sortent dans l'ordre du scan, pas dans celui du livre. `--duplex-adf` les remet dans l'ordre de lecture : recto 1, verso 1, recto 2, verso 2… Le nombre de pages doit être pair (sinon le programme s'arrête avec un message).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Six fichiers dans l'ordre du scan (scan_001 … scan_006). `--dry-run` montre l'ordre dans lequel ils seraient traités et quels fichiers seraient écrits, puis s'arrête sans rien traiter : scan_006 se retrouve en 2e position, scan_005 en 4e.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

La même commande sans `--dry-run`, avec l'OCR natif : le texte ressort dans l'ordre « Pagina 1 … Pagina 6 » (pages de test faites par moi, pas un vrai livre).

Autres options d'ordre et de sélection (combinables ; la plage s'applique à la numérotation des fichiers d'entrée, à partir de 1) :

- `--pages 1-10,15,20-` : ne garde que les pages indiquées ; `20-` signifie « de 20 jusqu'à la fin ». Fonctionne aussi sur des pages tirées de PDF ou de feuilles TIFF multipages.
- `--reverse` : inverse l'ordre (pile numérisée à partir de la dernière page).
- `--dry-run` : vérifie un gros lot avant le long traitement.

Vérifié : l'ordre et la plage avec des tests automatiques et avec six pages de test ; je n'ai pas essayé un vrai scanner à chargeur. Les options peuvent aussi se choisir depuis la fenêtre, dans « Toutes les options… » (section 4).

Texte propre : corrections personnelles, titres courants et cédille

Pour les fichiers `.txt` et `.docx` (la couche de texte du PDF, le hOCR et le JSON conservent les mots lus, inchangés) :

- `--clean-text` : ș et ț avec virgule souscrite, mots coupés en fin de ligne recollés (avec trait d'union conservé quand les deux moitiés sont des mots de la liste et que le simple collage n'en est pas un), guillemets typographiques, espaces près de la ponctuation. `--cedilla` écrit à la place ş et ţ, pour les programmes et polices qui ne connaissent pas les lettres à virgule.
- `--find-replace FICHIER` : vos propres corrections, une par ligne, `faux => juste`. Les lignes qui commencent par `#` sont des commentaires. Seuls les mots entiers correspondent (`Ion => Ioan` ne touche pas « Ionescu ») et elles s'appliquent dans l'ordre du fichier, après `--clean-text`. Utile pour les noms propres, les abréviations ou un tampon que le moteur lit toujours aussi mal.
- `--drop-running-heads` : exclut les titres courants, les pieds de page et les numéros de page imprimés : la première ou la dernière ligne d'une page qui se répète (les chiffres ne comptent pas) sur au moins la moitié des pages ; il faut au moins quatre pages. Les lignes retirées sont listées sur stderr, pour que vous voyiez ce qui est parti.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

Le fichier de règles (premier bloc) et les deux mêmes lignes lues sur la page de test sans et avec `--find-replace` : « Ionescu » est devenu « Ionescu-Vale » et « ha » est devenu « hectare ».

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

Sur six pages de test avec le titre courant « Anuarul Văii Mari » et un numéro, le programme a retiré six lignes de titre ; le texte commence directement par « Pagina 1 ». Attention : la règle retire toute première/dernière ligne qui se répète ; dans un livre où la dernière ligne de chaque page se ressemble (par exemple « Poziția în raft: 14 »), ces lignes partiraient aussi ; c'est

pourquoi elles sont listées. La fonction a été vérifiée avec des tests et sur quelques pages, pas sur un grand ensemble de livres.

Autres recettes

Les recettes complètes se trouvent dans `docs/tasks/` du dépôt, en anglais et en roumain (vérification de document avec `--verify-document` et `--mrz`, copie d'archive, gros lot).

6. Réglages importants et quand les utiliser

Profils

```
$ legatorocr --list-profiles | cut -c1-100
book-bw              Text books: auto threshold, black & white, punch holes removed
book-small-color     Colour books: sharp text over a light background, smallest files
document-text        Office documents: sharp text, pictures kept in colour
photo-archive        Archive quality colour, light sharpening
newspaper            Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red     Forms with red rules or stamps: drop red, erase ruled lines
negatives            Negative scans: invert and stretch contrast
doc-birou            Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene        Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise  Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim         Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft         Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum         Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma              Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta                Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura            Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos         Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof            user profile
```

legatorocr --list-profiles. La dernière ligne (smokeprof) est un profil de test à moi, il ne fait pas partie du programme.

Un profil est un ensemble de réglages tout prêt pour un type de matériau. On le choisit dans la section « Profil » (interface) ou avec `--profile NOM` (ligne de commande). Vous avez vos propres profils : vous configurez les réglages, écrivez un nom et appuyez sur « Enregistrer le profil ».

Profil	Pour quoi
`book-bw`	livres de texte, noir et blanc, trous de perforation retirés
`book-small-color`	livres en couleur, texte net sur fond clair, petits fichiers
`document-text`	documents de bureau, images conservées en couleur
`photo-archive`	photographies, qualité d'archive
`newspaper`	journaux : seuil Wolf, taches éliminées plus fortement
`form-dropout-red`	formulaires à lignes ou tampons rouges
`negatives`	scans de négatifs
`phone-photos`	photos de téléphone : perspective corrigée, fond autour de la page effacé, livres ouverts coupés au milieu, doigts retirés
`phone-photos-a4`	comme `phone-photos`, mais chaque page sur une feuille A4, avec le texte agrandi pour remplir la feuille (y compris les pages à peu de lignes)
`registre-manuscrise`	registres et manuscrits anciens (300–600 dpi), couleurs conservées
`schite-desene`	esquisses et dessins au crayon (400 dpi)

Profil	Pour quoi
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	flux pour documents de bureau, de la qualité maximale au gros volume
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**non vérifiés sur des échantillons réels**

La liste complète est donnée par `--list-profiles`.

Les réglages qui comptent le plus

Réglage	Ce qu'il fait	Quand le changer
Résolution (dpi)	la résolution à laquelle les pages sont numérisées	quand l'image n'a pas de dpi dans l'en-tête ; pour du texte 300
Redresser automatiquement / inclinaison maximale	la limite de l'angle corrigé automatiquement	quand une page qui ressort « à la limite » est en fait de travers
Marges, taille de page, même taille	marges en mm ; page libre, personnalisée ou identique pour tout le livre	pour des livres aux formats mélangés
Mode de sortie	couleur, gris, noir et blanc, mixte (texte 1 bit + images en couleur), hybride (+ fond basse résolution)	noir et blanc pour du texte pur ; mixte pour du texte avec des photos
Méthode de seuil	Sauvola (par défaut), Wolf, Niblack, NICK, Bradley, Otsu ou automatique	quand le texte ressort pâli ou plein de taches ; `auto` en essaie plusieurs sur chaque page
Sensibilité	la sensibilité de la méthode Sauvola pour la sortie noir et blanc	par défaut 0,3 ; changez-la par petits pas et comparez le résultat sur la même page
Sensib. images	avec quelle facilité une zone est considérée comme une image	en mode mixte/hybride
Éliminer les petites taches	la force du nettoyage des taches (0,25–4 ; 1 = par défaut)	réduisez-la si des points ou des diacritiques disparaissent ; augmentez-la si des taches restent
Dewarp (lignes courbes)	redresse les lignes arquées près de la reliure	pour les livres épais ; ignoré si aucune courbure nette n'est visible
Uniformiser l'éclairage	égalise le fond	pour des photos avec ombre ou éclairage inégal
Qualité JPEG	0 = sans perte ; les pages en noir et blanc sont toujours sans perte	pour des fichiers plus petits (suggestion : essayez 80–90 et comparez la taille et l'aspect)
DPI de sortie	réduit l'image de sortie à ce dpi ("—" = ne pas réduire)	pour des PDF plus petits ; les pages sous 250 dpi sont agrandies automatiquement avant l'OCR, une trop forte réduction n'aide donc pas la reconnaissance
PDF/A-2b	PDF d'archivage, avec police et profil de couleur inclus	pour le dépôt dans des archives ; n'a pas été vérifié avec veraPDF sur les sorties du programme

Formats des champs texte

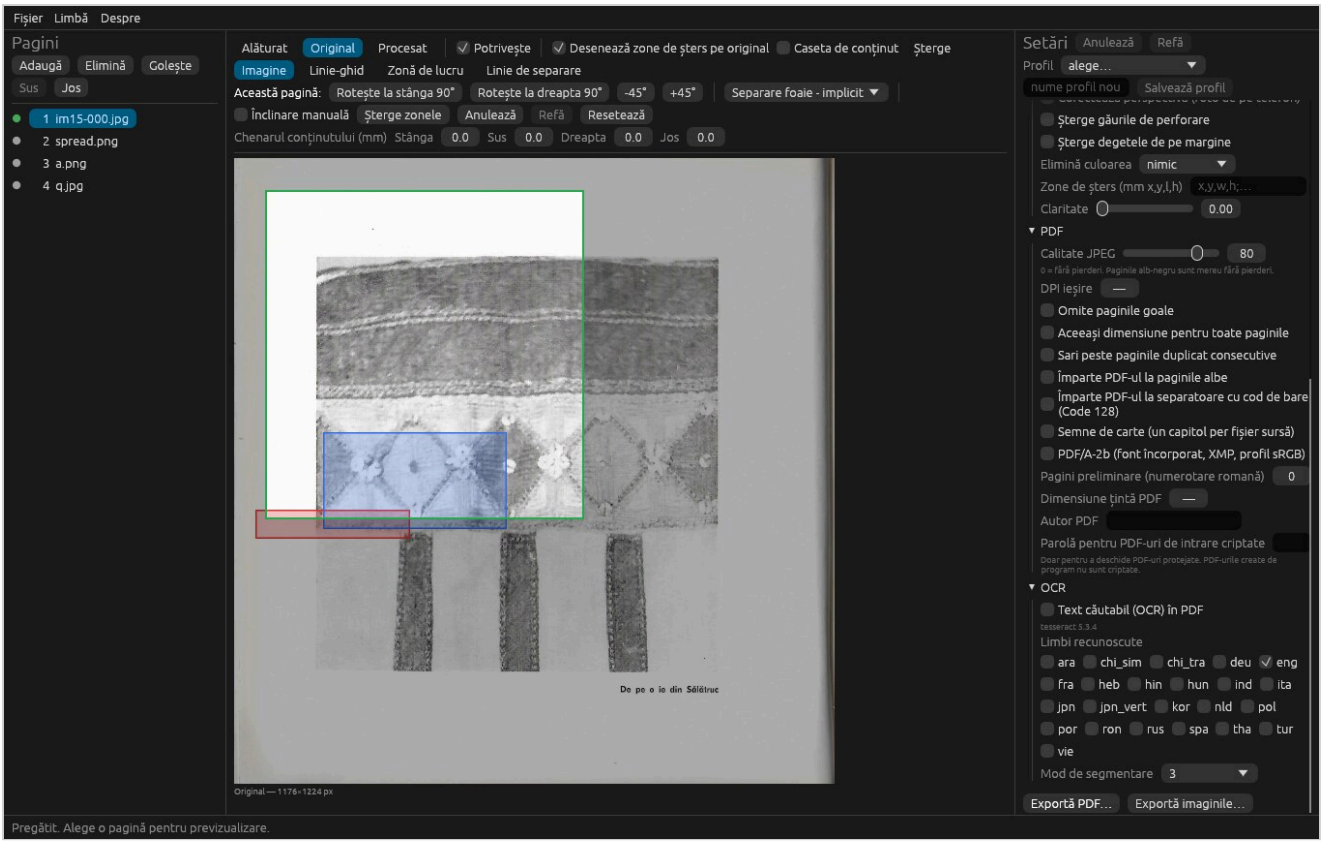
Ces champs existent dans les réglages, mais il est plus facile de tracer sur l'original (section 4) :

- **Zones à effacer** et **Zones d'image** : `x,y,l,h` en **millimètres** depuis le coin supérieur gauche de la page. Plusieurs zones se séparent par des points-virgules : 10,20,30,40;50,60,20,20. Au plus 64 ; la largeur et la hauteur doivent être positives. Si la forme est erronée, le champ devient rouge.

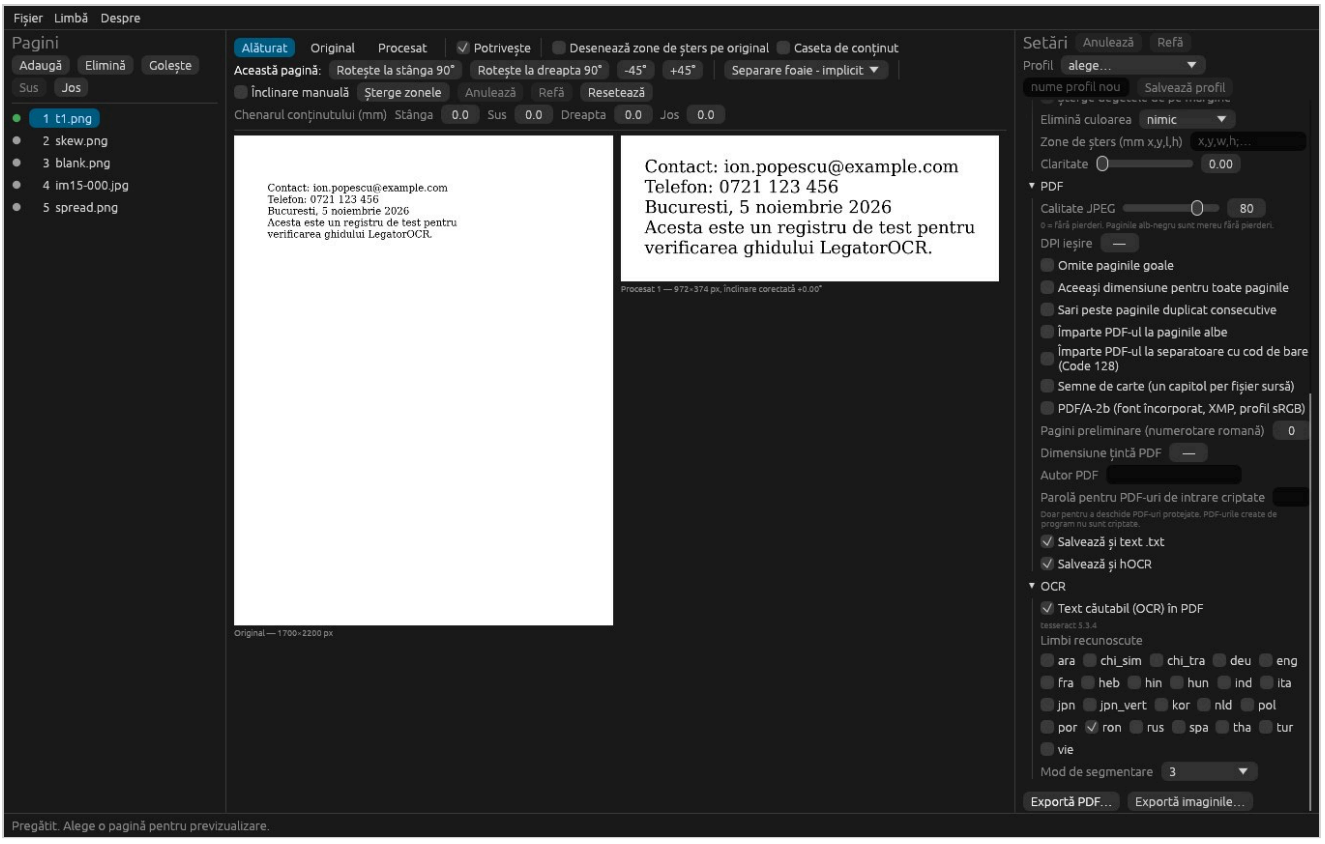
- **Lignes-guides de redressement** : `x,y x,y x,y;x,y x,y x,y`, avec des **fractions entre 0 et 1** de la page déjà redressée (0,0 = coin supérieur gauche). Chaque ligne a au moins deux points ; au plus 64 lignes au total.
- En ligne de commande : `--erase X,Y,W,H` (répétable) et `--dewarp-guide "X,Y X,Y …"` (répétable).

7. OCR : moteurs, langues et précision

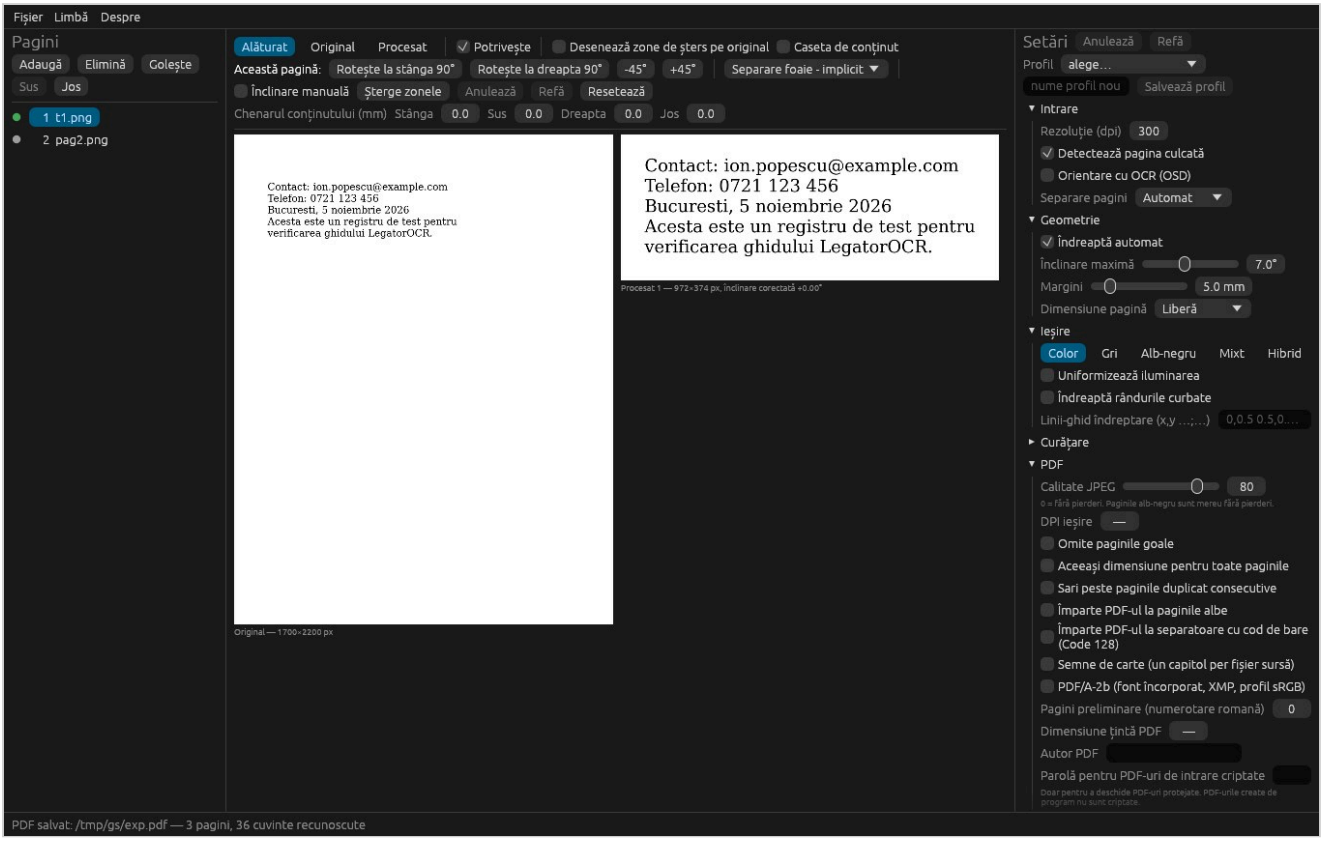
La case « Texte interrogeable (OCR) dans le PDF » (ou `--ocr` en ligne de commande) ajoute une couche de texte invisible sur l’image. La langue se choisit dans « Langues reconnues » (ou `--lang ron`) ; elle peut être combinée, par exemple `ron+eng`. Les langues de l’interface et du moteur propre : roumain, anglais, français, italien, espagnol, portugais, allemand, hongrois.



La section OCR des réglages : la case « Texte interrogeable (OCR) dans le PDF », les langues reconnues (celles installées dans Tesseract) et le mode de segmentation. Sur la capture, Tesseract 5.3.4 était installé, c’est pourquoi toutes ses langues apparaissent ; j’ai utilisé le choix ron dans la figure suivante.



Avec l’OCR coché apparaissent aussi « Enregistrer aussi le texte .txt » et « Enregistrer aussi le hOCR ». Ici la langue choisie est ron.



Après l’export, la barre du bas affiche : « PDF enregistré : … — 3 pages, 36 mots reconnus ». (J’ai lancé l’export avec un mécanisme de test du programme, pas depuis la boîte de dialogue de fichiers.)

Trois moteurs

Moteur	Comment le choisir	Remarques
Natif (celui du programme)	`--engine native`	sans installation, écrit en Rust ; modèle entraîné sur du texte synthétique, puis ajusté sur des lignes d'un magazine roumain et d'un manuel de 1960
Tesseract	`--engine tesseract`	programme séparé, voir la section 2 ; utilisé automatiquement quand il est installé et possède la langue demandée (`--engine auto`, par défaut)
Pont ONNX	`--engine tesseract --tesseract scripts/engine-onnx.py`	pour utilisateurs avancés ; nécessite Python, onnxruntime et des modèles téléchargés séparément

```
$ legatorocr scans/text.png --engine native --ocr --lang ron --txt nat.txt --format none; cat nat.txt; echo; legatorocr
scans/text.png --engine tesseract --ocr --lang ron --txt tes.txt --format none; cat tes.txt
OCR engine: LegatorOCR native engine 0.2.0-pre.19, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote nat.txt
Contact: ion.popescu(aexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote tes.txt
Contact: ion.popescuGexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
```

La même page de test lue par les deux moteurs. Tous deux se sont trompés de la même façon : « @ » est ressorti « (a » avec le moteur natif et « G » avec Tesseract.

Les chiffres mesurés (et ce qu'ils ne disent pas)

On a mesuré 8 bonnes pages d'un magazine roumain, par rapport à un texte de référence produit par ABBYY, non corrigé par un humain. Taux d'erreurs par caractère, avec diacritiques (mesure d'origine, de l'édition 0.2.0-pre.21 ; lors d'une nouvelle mesure en pre.26 sur les mêmes 8 pages, avec la même méthode, le moteur natif a donné 2,76 % ; je n'ai pas étudié l'écart avec 2,55 %) :

Moteur	Erreurs par caractère
Natif	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (avec Tesseract)	4,62 %

Lu simplement : le moteur natif se trompe moins **sur ce type d'impression**. Mais il a été ajusté sur du texte issu des mêmes sources, on ne peut donc pas dire qu'il est meilleur en général. Sur d'autres documents, surtout les impressions anciennes ou inhabituelles, il peut être moins bon que Tesseract. La reconnaissance des mots entiers est presque égale entre les moteurs (environ 92 %).

Le mode précis et l'ancienne orthographe

- `--accurate` (moteur natif) : chaque ligne est lue trois fois (décalée d'un pixel vers le haut et vers le bas) et les probabilités sont moyennées. C'est plus lent (mesuré : de 18 % à 74 % de temps en plus) et cela n'a aidé que sur les pages de magazine (erreur par caractère 3,66 % → 3,39 % sur 12 pages) ; sur les livres et brochures, rien de mesurable n'a changé. Désactivé par défaut.

- La liste de mots roumains accepte aussi l'orthographe de 1953–1993 (`cuvînt`, `romîn`, `sînt`) : sur cinq pages d'un manuel de 1960, transcrites à la main, les caractères corrects sont passés de 99,6 % à 99,7 % et les mots de 96,0 % à 96,3 %. Une petite différence, sur cinq pages.
- Les mots sont séparés aux grandes espaces même quand le réseau n'a pas écrit d'espace : les cellules d'un tableau ne ressortent plus collées (`CantitatePreț`). Un tableau à lignes est trouvé comme un seul tableau (Excel : `--tables-xlsx`) ; un tableau sans lignes est encore trouvé comme deux tableaux (gauche et droite), problème non résolu.

Conseils

- Sur vos propres documents, comparez les moteurs sur 5–10 pages avant le lot : `scripts/compare-ocr-text.py` mesure les erreurs par rapport à des textes de référence que vous possédez.
- Les pages sous 250 dpi sont agrandies automatiquement avant la reconnaissance.
- Les pages avec illustrations ou diagrammes peuvent produire un texte dénué de sens dans la zone de l'image (Tesseract a lu une illustration comme du texte sur l'une des pages mesurées). Vérifiez ces zones.
- Tout OCR peut inventer ou perdre des mots. Pour des actes, registres ou chiffres, vérifiez par sondage.

8. Sorties et archivage

Ce que vous voulez	Comment
PDF avec texte interrogeable	`--pdf FICHIER.pdf --ocr` (interface : Exporter le PDF avec l'OCR coché)
PDF d'archivage (PDF/A-2b)	`--pdfa` ; autres parties avec `--pdfa-part 1` ou `3`
Images traitées	`-o DOSSIER`, avec `--format png`, `jpeg` ou `tiff` ; `--format none` n'écrit pas d'images
Texte brut des pages	`--txt FICHIER.txt`
hOCR	la case « Enregistrer aussi le hOCR »
Structure pour l'accessibilité	`--tagged ro` (paragraphes balisés). La conformité PDF/UA n'a **pas** été validée
Copie DjVu	`--djvu FICHIER.djvu`
Preuve d'intégrité	`--checksums` et `--archive-package DIR`, puis `--verify-sums`
Projet (réglages et corrections)	Fichier → Enregistrer le projet (`.lgr`), ou `--save-project` ; `--embed-project` le cache dans le PDF

À propos du PDF/A

Le programme écrit du PDF/A-2b avec police et profil sRGB incorporés. La conformité a été vérifiée sur des échantillons, **pas** avec veraPDF sur toute sortie. Si une institution exige une conformité certifiée, exécutez votre propre validateur sur les fichiers finaux.

À propos des projets ScanTailor

`--project FICHIER.ScanTailor` ouvre un projet ScanTailor : la liste des scans et la rotation par image sont reprises, tandis que l'inclinaison, la séparation et la zone de contenu sont retrouvées. Le lecteur a été écrit d'après la description du format et testé sur un projet fait à la main, pas sur des fichiers de toutes les versions de ScanTailor.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project et --project : le projet s'enregistre et se rouvre avec le même résultat (2 pages). Attention : dans pre.18, --work-area et --cut-at n'étaient pas conservés dans le projet ; corrigé dans pre.19 (vérifié : le projet enregistré puis rouvert donne les mêmes pages).

9. Problèmes fréquents et limites connues

Symptôme	Que vérifier
La page ressort coupée ou avec trop de blanc	la zone de contenu (section 4) ; le cadre en mm de la barre « Cette page »
Une page inclinée reste inclinée	l'inclinaison maximale permise ; réglez l'angle manuellement
La feuille recto-verso n'est pas coupée où il faut	le mode de séparation de la page : « au milieu » ou « désactivée » ; depuis pre.18 vous pouvez faire glisser une « Ligne de séparation » sur l'original ou utiliser `--cut-at 0.45`
Un champ texte devient rouge	le format du champ (section 6) : millimètres pour les zones, fractions 0–1 pour les guides
Le texte OCR comporte des erreurs	comparez les moteurs (section 7) ; vérifiez la résolution ; passez à Tesseract ou inversement
Le panneau « À vérifier »	pages marquées comme suspectes (blanche, inclinaison à la limite, rien trouvé, contenu collé au bord) ; elles ne sont pas forcément fausses, mais méritent un coup d'œil
La fenêtre ne fonctionne pas sous Windows ou en RDP	absence d'OpenGL 2+ ; essayez le pilote de la carte vidéo
L'application macOS ne démarre pas	elle n'est pas signée : clic droit → Open ou la commande `xattr` de la section 2

Limites connues de l'édition 0.2.0-pre.60

- Trapèze auto : vérifié sur des feuilles synthétiques et sur 67 photos de téléphone d'un seul livre (133 pages), où il a laissé la plupart des pages intactes et réduit l'inclinaison mesurée sur les autres ; personne n'a jugé le résultat à l'œil sur d'autres livres, ni sur des pages à grandes images, tableaux ou lignes très courtes, où il peut ne rien faire ou trop peu. Les réglages par page et l'inclinaison de la ligne de coupe ont été essayés sur des feuilles synthétiques et en tests ; le crayon tableau fait lire la zone par l'OCR comme un bloc, il ne trouve pas les cellules.

- La rotation de 90° : sur une page avec une photographie d'ornements (page 15 d'un PDF), un testeur sous Windows a vu la rotation sauter de 90° à 180°. J'ai reproduit sous Linux une partie du problème : dans pre.18, avec « Détecter la page couchée » cochée (par défaut), le programme pivotait à tort cette page de 90°, alors que l'original est droit (la figure de la section 4). Le seuil de pre.19 était trop fragile (j'ai découvert entre-temps qu'une autre page du même PDF, la page 13, était elle aussi mal pivotée). Dans pre.20, le détecteur ne compte que les pièces de la taille d'une lettre et s'abstient sur les pages avec des images ou peu de mots. Sur 98 pages de livre (pivotées à 0° et 90°) et 5 pages avec images, le résultat est identique à pre.18, sauf la page 13 (mal pivotée dans pre.18, maintenant droite) et une page avec une photo couchée, que le détecteur ne retourne plus (restent l'OSD et la rotation manuelle). Vérifié en ligne de commande, sous Linux, sur un petit corpus. La cause probable du saut (l'orientation automatique s'ajoutait à la rotation manuelle) a été corrigée dans pre.18 : après un clic sur la rotation, la page reste verrouillée, et quatre clics donnent 90°, 180°, 270° et retour à 0° (vérifié dans la fenêtre, sous Linux). Ce que le testeur a exactement vu sous Windows 11, je n'ai pas pu le vérifier. Si une page avec des images est toujours mal pivotée, décochez « Détecter la page couchée » ou utilisez --no-auto-orient.

- La zone de travail, la ligne de séparation déplaçable, les zones à effacer et d'image, la grille de points, Annuler et Ctrl+Z, la zone de contenu, l'OCR et l'export PDF ont été essayés dans une vraie fenêtre sous Linux, avec une souris simulée (les captures du guide). Le redimensionnement d'une zone par un coin a fonctionné dans la fenêtre. Les boîtes de dialogue natives de fichiers (« Exporter le PDF… », « Enregistrer le projet », « Ouvrir un projet ») ont fonctionné avec la boîte de dialogue GTK d'un portail xdg sous Linux ; sous Windows et macOS, je ne les ai pas essayées. Si le système n'a aucune boîte de dialogue, depuis pre.21 la fenêtre le dit au lieu de ne rien faire (vous pouvez faire glisser les fichiers dans la fenêtre ou utiliser la ligne de commande). L'enregistrement d'un profil personnel a fonctionné. L'effet de la ligne de séparation, je l'ai vérifié par des tests automatiques, avec --cut-at et dans la fenêtre (une double feuille coupée en deux pages inégales, 524 et 674 px). Pour les feuilles tournées de 90° ou 270° (depuis pre.21), les pages sortent l'une sous l'autre ; cela n'est vérifié que par un test automatique, pas dans la fenêtre.

  --save-project : dans le build publié pre.18, --work-area et --cut-at donnés en ligne de commande n'étaient pas conservés dans le fichier .lgr (trouvé lors de la vérification de ce guide). Corrigé dans pre.19. Si vous utilisez pre.18, redonnez les options avec --project, et pas seulement depuis le projet.

- L'interface graphique n'a pas été vérifiée par des humains sous Windows, macOS ou arm64.

- La vérification PDF/UA, la facture électronique CIUS-RO et l'horodatage par HTTPS avec une vraie autorité n'ont pas été validés.

- Pour une copie PDF/A certifiée, le validateur est le vôtre (par exemple veraPDF).

- Le droit d'utiliser le modèle OCR propre (entraîné en partie sur des pages aux droits non clarifiés) est une question ouverte chez l'auteur ; voir `docs/audit/assets-licences.md`.

10. Comment signaler un problème

La contribution la plus utile est un rapport depuis un système que l'auteur n'a pas essayé. Cela prend cinq minutes :

1. Téléchargez la dernière édition pour votre système.
2. Exécutez `legatorocr --doctor` et copiez toute la sortie.
3. Traitez une page que vous pouvez partager : `legatorocr PAGINA.jpg --ocr --pdf rezultat.pdf -o pagini`.
4. Ouvrez `rezultat.pdf` : la page est-elle droite et rognée comme il faut ? Le texte se sélectionne-t-il et se recherche-t-il ?

Envoyez, comme ticket dans le dépôt `chiuta/LegatorOCR` (ou par e-mail) :

- le système et sa version (par exemple Windows 11 23H2, macOS 15 arm64, Debian 12 arm64) ;
- la version de LegatorOCR ;
- la sortie de la commande `--doctor` ;
- la commande exécutée (ou le réglage de l’interface) ;
- ce que vous attendiez et ce qui s’est passé (texte d’erreur ou capture d’écran) ;
- si l’image peut être partagée.

N’envoyez pas de documents contenant des données personnelles. Un rapport « tout a fonctionné » reste utile : c’est le seul moyen pour l’auteur de savoir qu’un système fonctionne.

Les problèmes de sécurité se signalent conformément à `SECURITY.md`, pas publiquement.