LegatorOCR – Felhasználói útmutató

0.2.0-pre.43 kiadás (próbaverzió). Munkában lévő szöveg, román nyelven.

1. Mi a LegatorOCR

A LegatorOCR a szkenneléseket vagy az oldalakról készült fényképeket tiszta, kereshető szövegű PDF-fé alakítja. Ugyanazt a problémát oldja meg, mint a ScanTailor (az oldalak szétválasztása, kiegyenesítése, levágása, tisztítása), de ezen felül PDF-exportot és OCR-t is ad. Rust nyelven íródott, saját kóddal, és minden szakasza egy tankönyvi technika. Helyben fut, fiók nélkül, és az oldalakat nem küldi el az internetre. Licenc: MIT.

Két munkamód van, ugyanazokkal a motorokkal alatta:

- **A grafikus felület** (`legatorocr-gui`): oldalakat adsz hozzá, egymás mellett látod az eredetit és az eredményt, oldalról oldalra javítasz, majd exportálsz.
- **A parancssor** (`legatorocr`): nagy kötegekhez, automatizáláshoz és olyan opciókhoz, amelyeket a felület nem mutat.

Mit csinál

- a kétoldalas lapokat két oldalra választja szét, kiegyenesíti a ferde oldalakat és levágja a széleket;
- megtisztítja a hátteret, a foltokat, a lyukasztásokat, a szélen lévő ujjakat és az űrlapvonalakat;
- PDF-et (köztük archiváláshoz PDF/A-t) vagy képeket ír, román és további 7 nyelvű OCR-rel;
- egyszerű szöveget (`.txt`) és hOCR-t is előállít, és a PDF-et alá is tudja írni vagy időbélyegezni.

Mit nem csinál (vagy nem bizonyított)

- Ez egy próbaverzió (0.2.0-pre.43). A szerző és asszisztense csak Linuxon futtatta; **a Windowst, a macOS-t és az arm64 processzorokat emberek nem próbálták ki**.
- Az OCR pontosságát egyetlen román folyóirat 8 jó oldalán mérték, egy másik program által készített, ember által nem javított referenciaszöveggel szemben. Ne vedd garanciának más típusú nyomtatványokra.
- Az OCR tévedhet: a fontos oldalakat ellenőrizd szúrópróbaszerűen.

2. Telepítés és az első futtatás

Töltsd le a rendszerednek megfelelő archívumot a `chiuta/LegatorOCR` tároló kiadási oldaláról (Releases). Minden archívumhoz tartozik egy `.sha256` fájl az ellenőrzéshez.

Rendszer	Fájl	Megjegyzések
Linux x86-64 vagy ARM64	`.tar.gz`	OpenGL 2+ és X11 vagy Wayland szükséges
Windows x86-64	`.zip`	OpenGL 2+ szükséges; az egyszerű RDP-munkamenetekből hiányozhat
macOS Apple-silicon vagy Intel	`.zip` a `LegatorOCR.app`-pal	**aláíratlan**: az első indításkor jobb kattintás → Open, vagy `xattr -dr com.apple.quarantine LegatorOCR.app`

Forrásból is fordíthatsz: `cargo build --release` (Rust 1.95 vagy újabb szükséges).

OCR

A programnak saját OCR-motorja van, amely telepítés nélkül működik. Opcionálisan telepítheted a Tesseractot, egy külön programot, amelyet a LegatorOCR automatikusan használ, ha jelen van és megvan a kért nyelve:

- Linux (Debian/Ubuntu): `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS: `brew install tesseract tesseract-lang`
- Windows: `winget install UB-Mannheim.TesseractOCR`, majd add hozzá a `PATH`-hoz

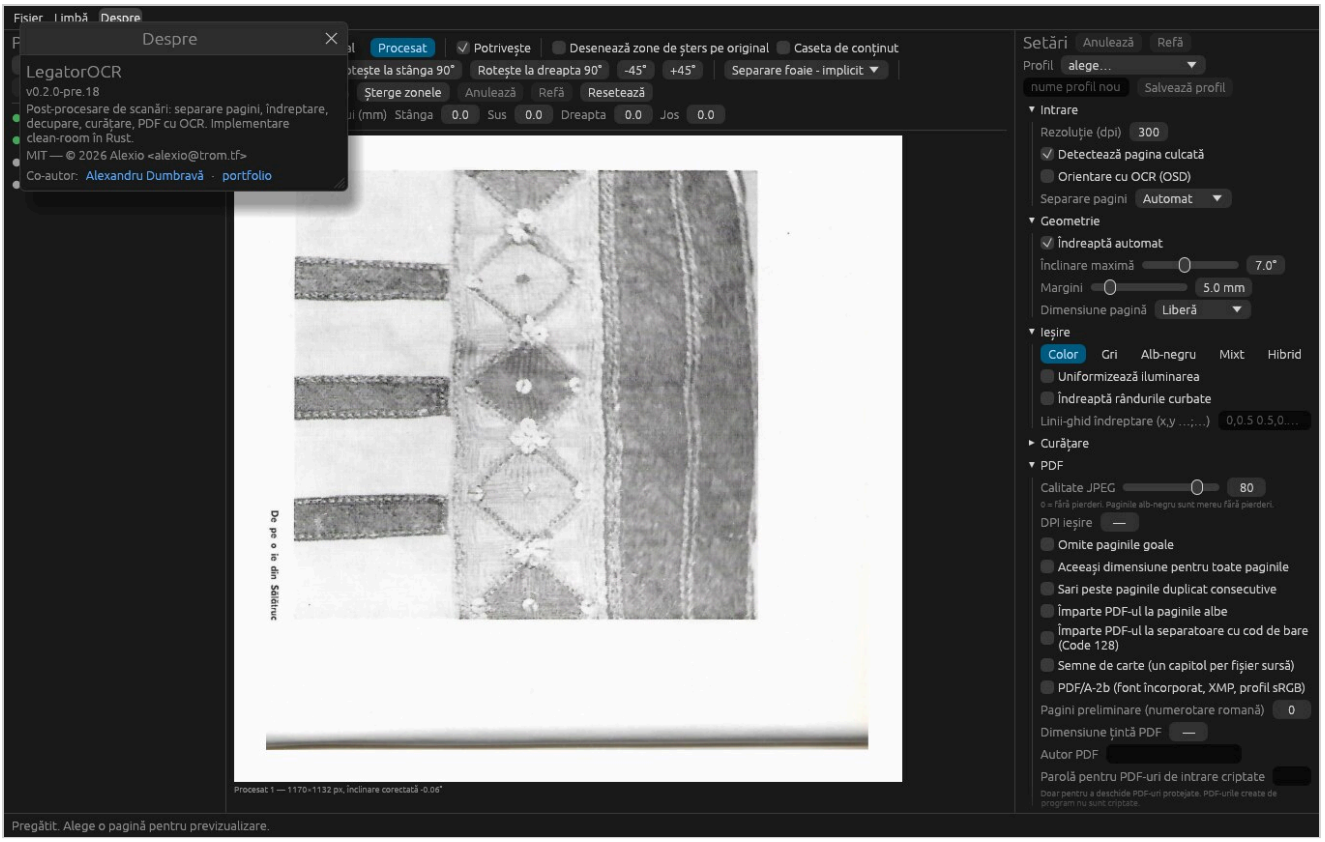
Az `apt` és `brew` csomagokban lévő román modell a kicsi változat („fast"). A „best" változatot kézzel kell letölteni, és a `--tessdata DIR` kapcsolóval kell megadni. Hogy melyik olvassa jobban az oldalaidat, azt nem mértük.

A telepítés ellenőrzése

Futtasd a `legatorocr --doctor` parancsot. Kiírja a verziót, a natív OCR-motort, a Tesseractot és a nyelvi modelleket, majd a segédeszközöket (`pdftoppm`, `gs`, `qpdf`, `mutool`). Egy opcionális eszköznél a „missing" eredmény nem hiba; az alatta lévő üzenet megmondja, szükség van-e rá. Ha valami nem működik, másold ki a parancs teljes kimenetét egy jelentésbe (lásd a 10. szakaszt).

```
$ legatorocr --doctor
[ok     ] legatorocr                        0.2.0-pre.19
[ok     ] native OCR engine                 built in
[ok     ] tesseract                         tesseract 5.3.4
[ok     ] tesseract model ro (Romanian)     installed
[ok     ] tesseract model en (English)      installed
[ok     ] tesseract model fr (French)       installed
[ok     ] tesseract model it (Italian)      installed
[ok     ] tesseract model es (Spanish)      installed
[ok     ] tesseract model pt (Portuguese)   installed
[ok     ] tesseract model de (German)       installed
[ok     ] tesseract model hu (Hungarian)    installed
[ok     ] pdftoppm                          pdftoppm
[missing] mutool                            not found
          -> optional: alternative renderer for those cases
[ok     ] gs                                gs
[ok     ] qpdf                              qpdf
14 check(s) ok, 1 missing. Missing helpers are optional unless a hint says otherwise.
```

A legatorocr --doctor parancs kimenete (pre.20, Linux, valódi terminálban; az útmutató minden terminál-képernyőképe ilyen, xterm-mel készült): a „missing" a mutool-nál egy opcionális eszköz, nem hiba.



A Névjegy menü a telepített verziót mutatja (itt 0.2.0-pre.18). Képernyőkép a pre.18 buildből Linuxon, román nyelvű felülettel.

3. A munkafolyamat lépésről lépésre

Minden oldalon a program az alábbi szakaszokat járja végig ebben a sorrendben. Az elemzés egy kb. 150 dpi-s másolaton történik, az eredményt pedig utána a szkennelésre alkalmazza a teljes felbontásában.

1. **Tájolás.** Észleli az oldalára fektetett oldalakat (negyedfordulat) az oldal betűi alapján: a képes vagy kevés szavas oldalt ez a teszt nem forgatja el. A pontos irányhoz a Tesseract (OSD) vagy a kézi forgatás használható.

2. **A lap szétválasztása.** A két oldalt tartalmazó fekvő lapot félbevágja, a közepén lévő üres sávnál. Lehet automatikus, középen vagy kikapcsolt.

3. **Kiegyenesítés.** A szövegsorokból megbecsüli a dőlésszöget, és az oldalt visszaforgatja. A szög kézzel is rögzíthető.

4. **Tartalomdoboz.** Megkeresi a szöveges és képes területet; a szkenner árnyékait és a port figyelmen kívül hagyja. Ami rajta kívül van, azt papírszínre festi át.

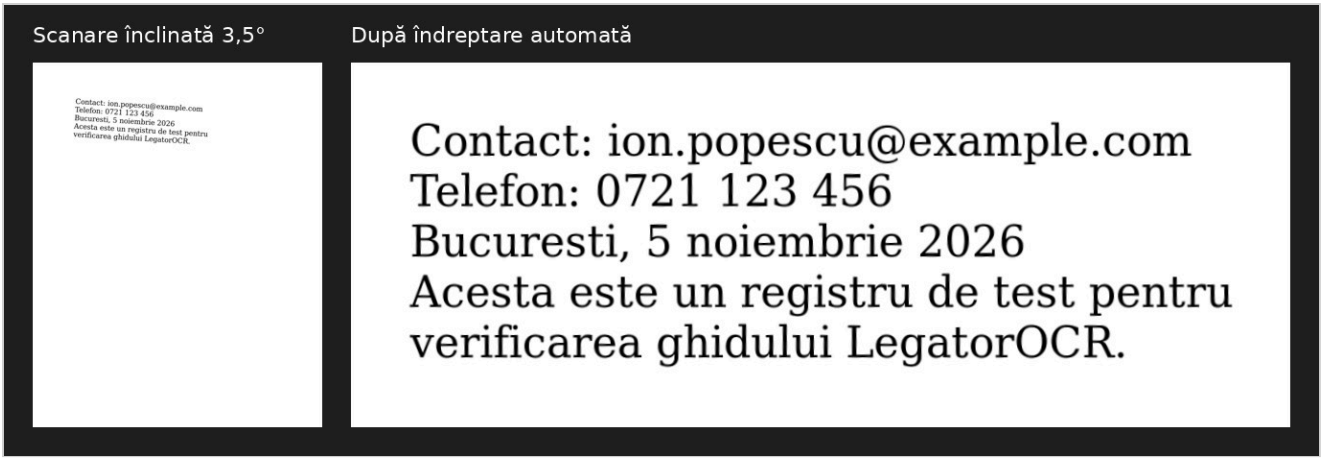
5. **Margók és méret.** Milliméteres margók, opcionálisan rögzített oldalméret vagy az egész könyvre azonos méret.

6. **A görbe sorok kiegyenesítése** (opcionális). Vastag könyvoldalakhoz, amelyeknek a sorai a gerinc mellett elhajlanak.

7. **Megvilágítás** (opcionális). Kiegyenlíti az egyenetlen hátteret.

8. **Tisztítás és binarizálás.** Eltávolítja a foltokat, lyukasztásokat, ujjakat, vonalakat; majd fekete-fehér, szürke, színes, vegyes vagy hibrid.

9. **PDF és OCR.** Kiírja a PDF-et (vagy a képeket) és, ha be van jelölve, a szövegréteget.



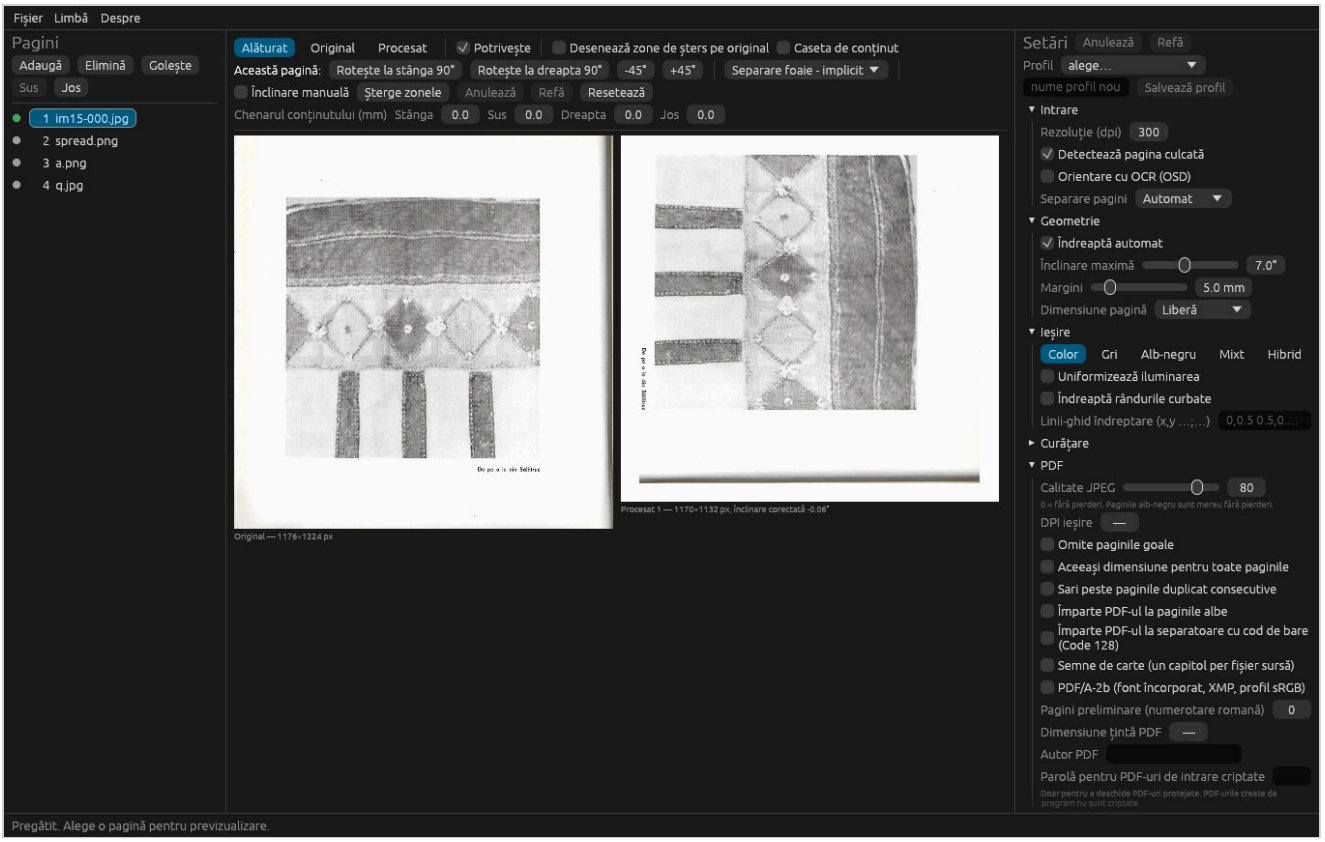
Automatikus kiegyenesítés: egy 3,5°-kal megdöntött szkennelés (általam generált tesztlap) és az eredmény; a program -3,50°-ot mért.

Időt takarító munkaszabályok

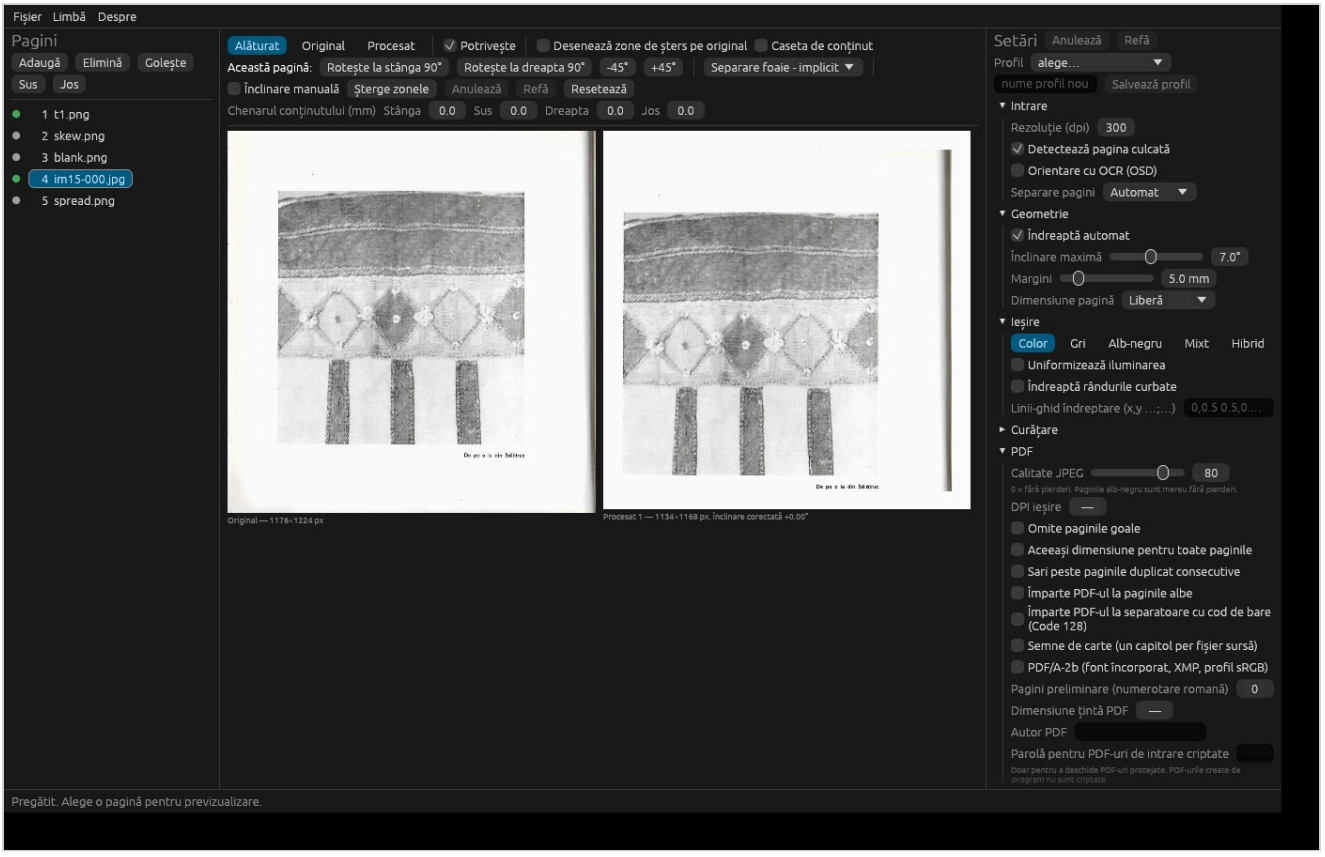
- Először a helyes **felbontást** állítsd be (szövegnél általában 300 dpi). A program a képből olvassa ki, ha 150 és 1200 között van; különben 300-at feltételez.
- Válassz az anyagnak megfelelő **profilt** (6. szakasz), mielőtt az egyes beállításokhoz nyúlnál.
- Dolgozz fel 10–20 oldalt próbaként, nézd meg az eredményt, és csak utána indítsd a nagy köteget.
- A felület „ellenőrizendő" jelöléssel látja el az oldalakat (üres oldal, határérték közeli dőlés, semmi nem található, a határhoz tapadó tartalom). Menj végig rajtuk a „Következő" gombbal.

4. A grafikus felület

Az ablaknak három területe van: az oldallista balra, az előnézet középen és a beállítások jobbra. A **Fájl** menü tartalmazza a „Képek hozzáadása…", „Mappa hozzáadása…", „Projekt megnyitása…", „Projekt mentése…", „PDF exportálása…" és „Képek exportálása…" parancsokat. A felület nyelve (8 nyelv) a **Nyelv** menüből váltható. (A képernyőképeken a felület román nyelvű.)



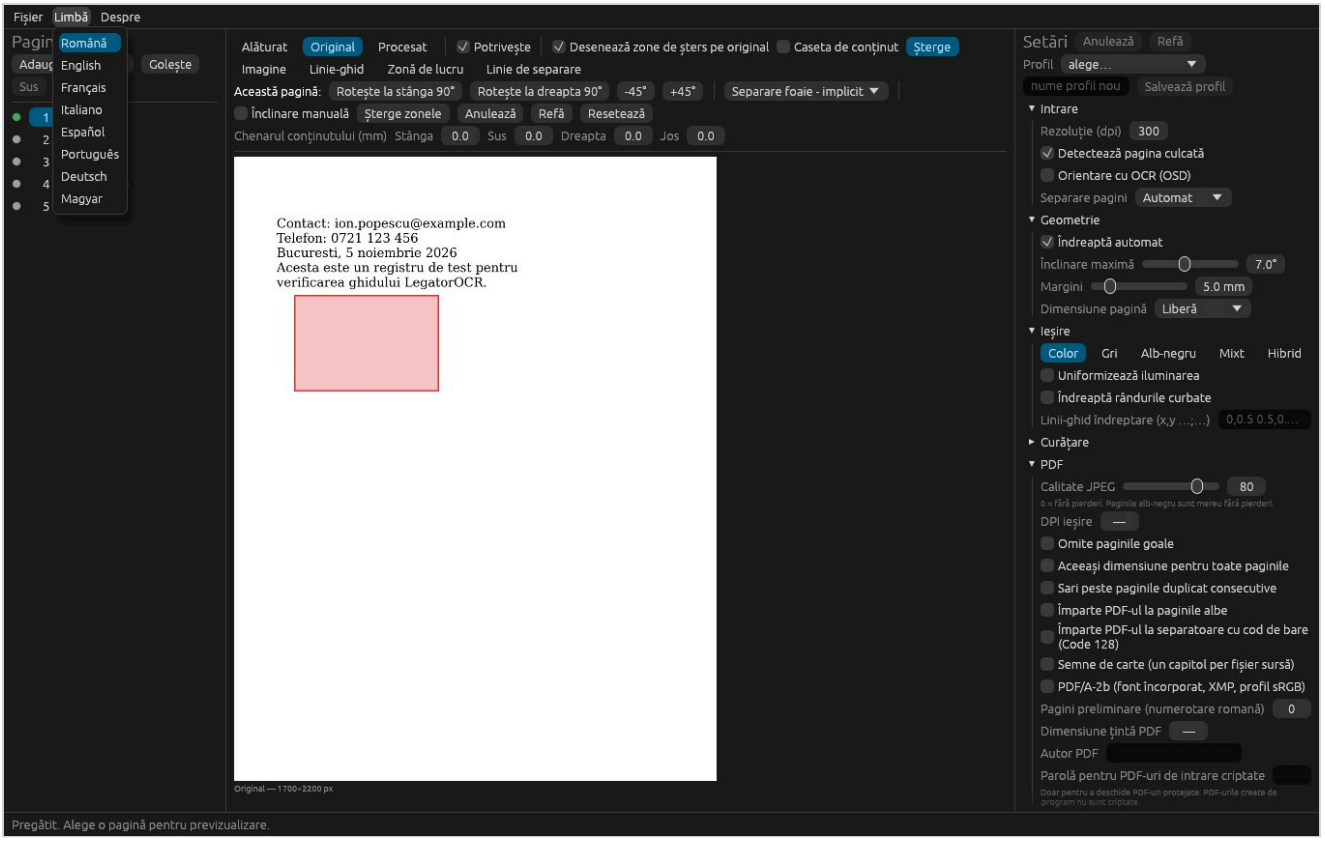
A főablak: az oldallista balra, az eredeti és a feldolgozott oldal középen, a beállítások jobbra. A példaoldal szöveg nélküli fénykép, ezért az oldalra fektetett oldal észlelése tévesen elforgatta a pre.18-ban (a pre.19-ben javítva, lásd lejjebb). Képernyőkép a pre.18-ból, Linuxon.



Ugyanaz az oldal a pre.19-ben, bejelölt „Oldalra fordított lapok felismerése" mellett: már nem forog el (feldolgozva 1134×1168 px, dőlés +0,00°). Képernyőkép a pre.19-ből, Linuxon.

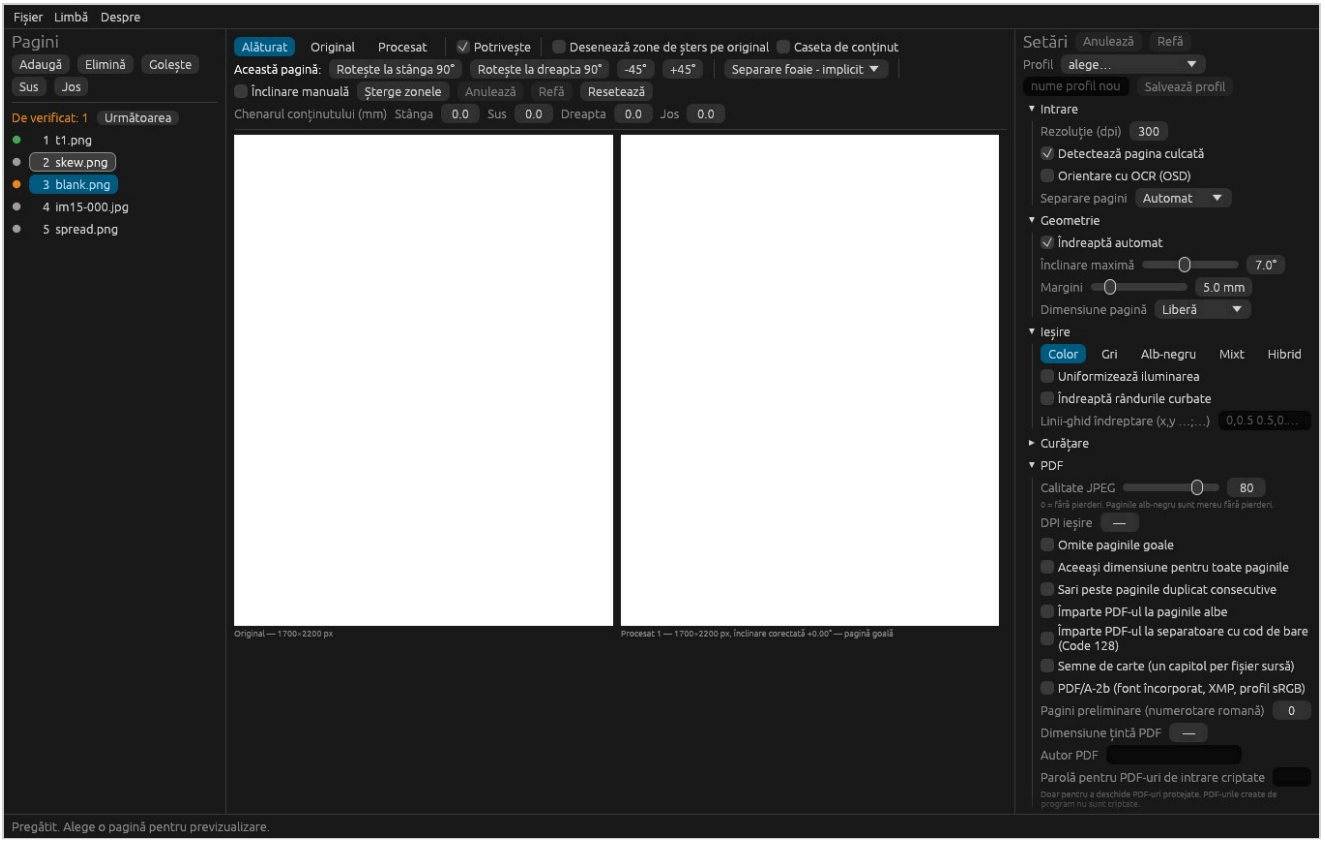


A Fájl menü: képek vagy mappa hozzáadása, projekt megnyitása és mentése, PDF vagy képek exportálása.



A Nyelv menü: a felület nyolc nyelve (román, angol, francia, olasz, spanyol, portugál, német, magyar).

Az oldallista

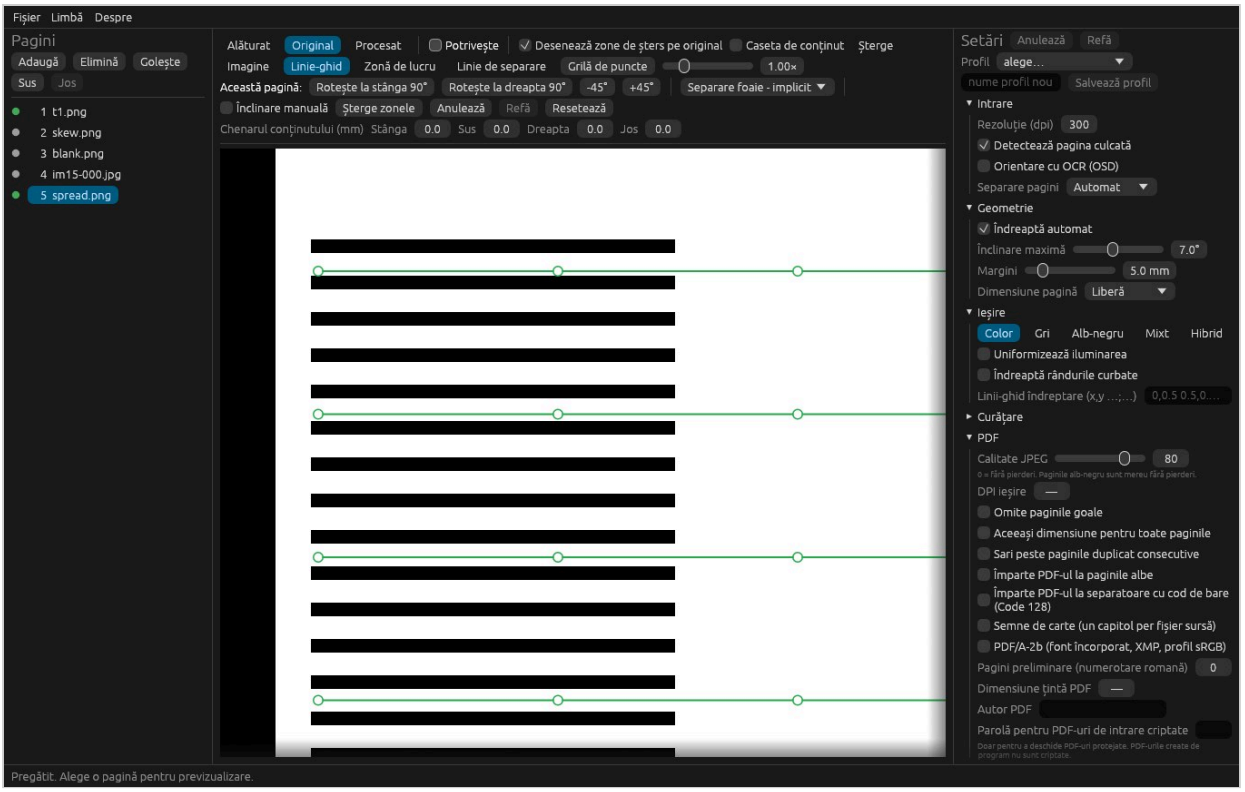


Egy teljesen üres oldalt automatikusan megjelöl: narancssárga pont a listában és az „Ellenőrizendő: 1" panel a „Következő" gombbal.

Húzz bele képeket, PDF-eket, archívumokat vagy egy mappát, vagy nyomd meg a „Hozzáadás" gombot. A Fel/Le gombok a sorrendet változtatják, az „Eltávolítás" a kijelölt oldalt veszi ki, a „Törlés" mindent kivesz. A listabeli sorrend a PDF-beli sorrend.

Az előnézet

- Az **Egymás mellett** / **Eredeti** / **Feldolgozott** választja ki, mit látsz. A zónákat az *Eredeti* nézeten rajzolod; a tartalomdobozt a *Feldolgozott* nézeten javítod.
- Az **Illesztés** kinagyítja vagy lekicsinyíti a képet, hogy elférjen. A nagyítás csúszkája (0,2×–4×) csak akkor jelenik meg, ha az *Illesztés* nincs bejelölve.

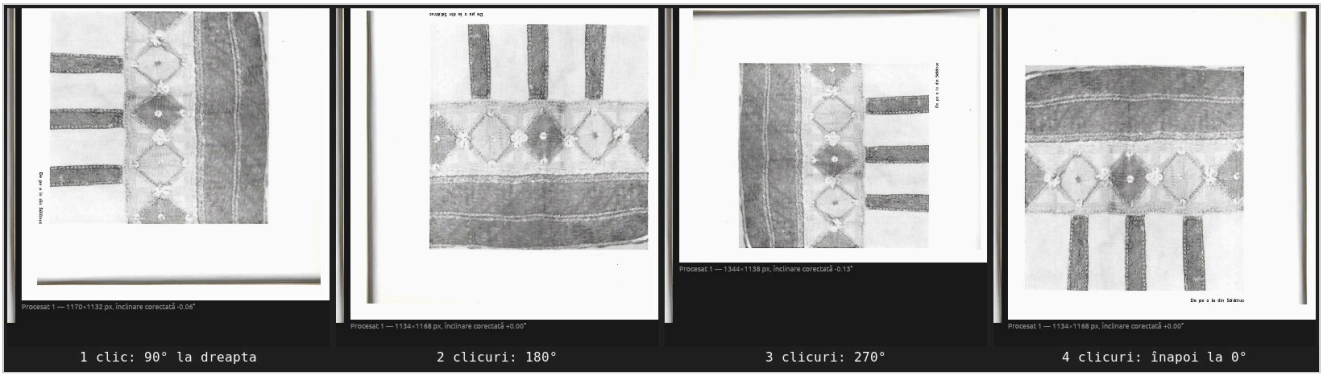


Az „Illesztés" kijelölésének megszüntetésekor megjelenik a nagyítás csúszkája (itt 1,00×).

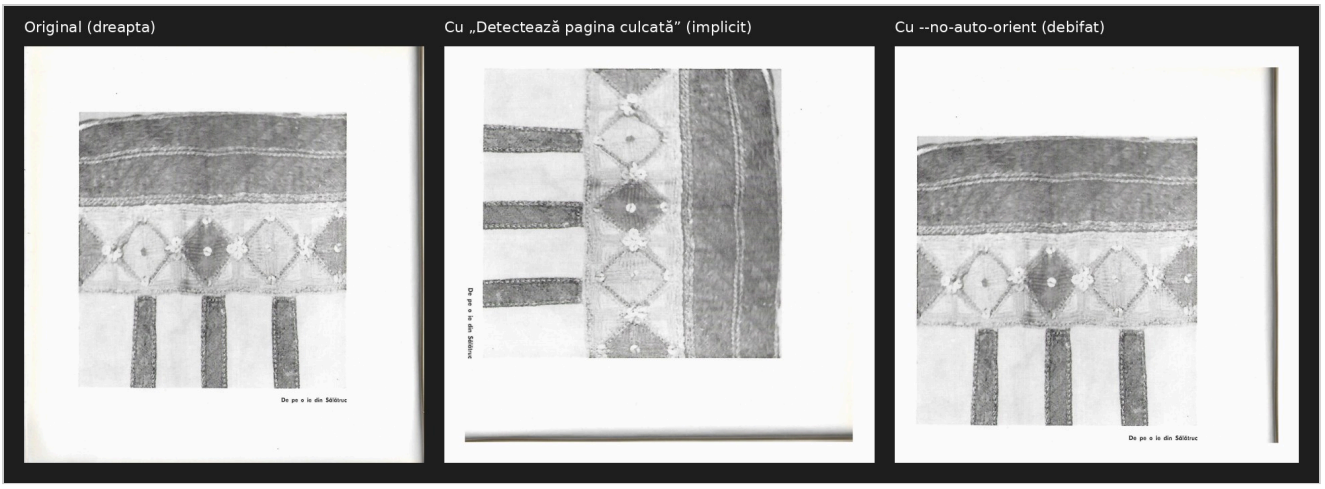
Az „Ez az oldal" sáv

Itt csak a kiválasztott oldalt javítod: forgatás balra vagy jobbra 90°-kal, ±45°-os lépések, kézi dőlés, a lap szétválasztásának módja (alapértelmezett, automatikus, középen, ki), a tartalom kerete milliméterben (bal, felül, jobb, alul; a pozitív értékek növelik) és a „Visszaállítás". A **Visszavonás** és az **Újra** (Ctrl+Z, Ctrl+Y) ezekre a parancsokra mind működik, nem csak a zónákra.

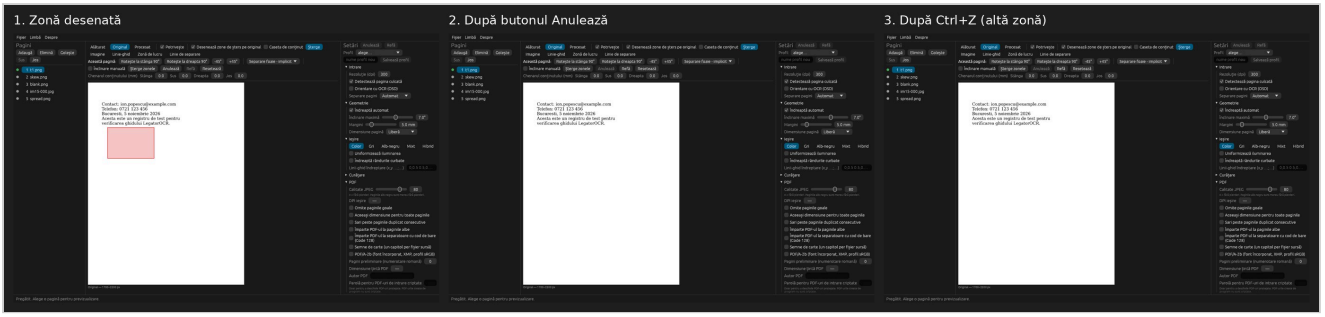
A kézi forgatás zárolja az automatikus tájolást (a pre.18-tól): miután megnyomsz egy forgatógombot vagy a ±45°-ot, az oldalt az oldalra fektetett oldal észlelése vagy az OSD már nem forgatja el, 0°-nál sem. A „Visszaállítás" visszaadja neki az automatikus tájolást. Ha egy képes oldal eleve rosszul van elforgatva, nyomd meg a forgatást négyszer (vagy szüntesd meg a „Tájolás OCR-rel (OSD)" és az „Oldalra fordított lapok felismerése" jelölését a beállításokban, a Bemenetnél).



Négy egymás utáni kattintás a „Forgatás jobbra 90°-kal" gombon: 90°, 180°, 270°, majd vissza 0°-ra, ugrások nélkül. Képernyőkép a pre.18-ból, Linuxon. Windows 11-en nem tudtam ellenőrizni.



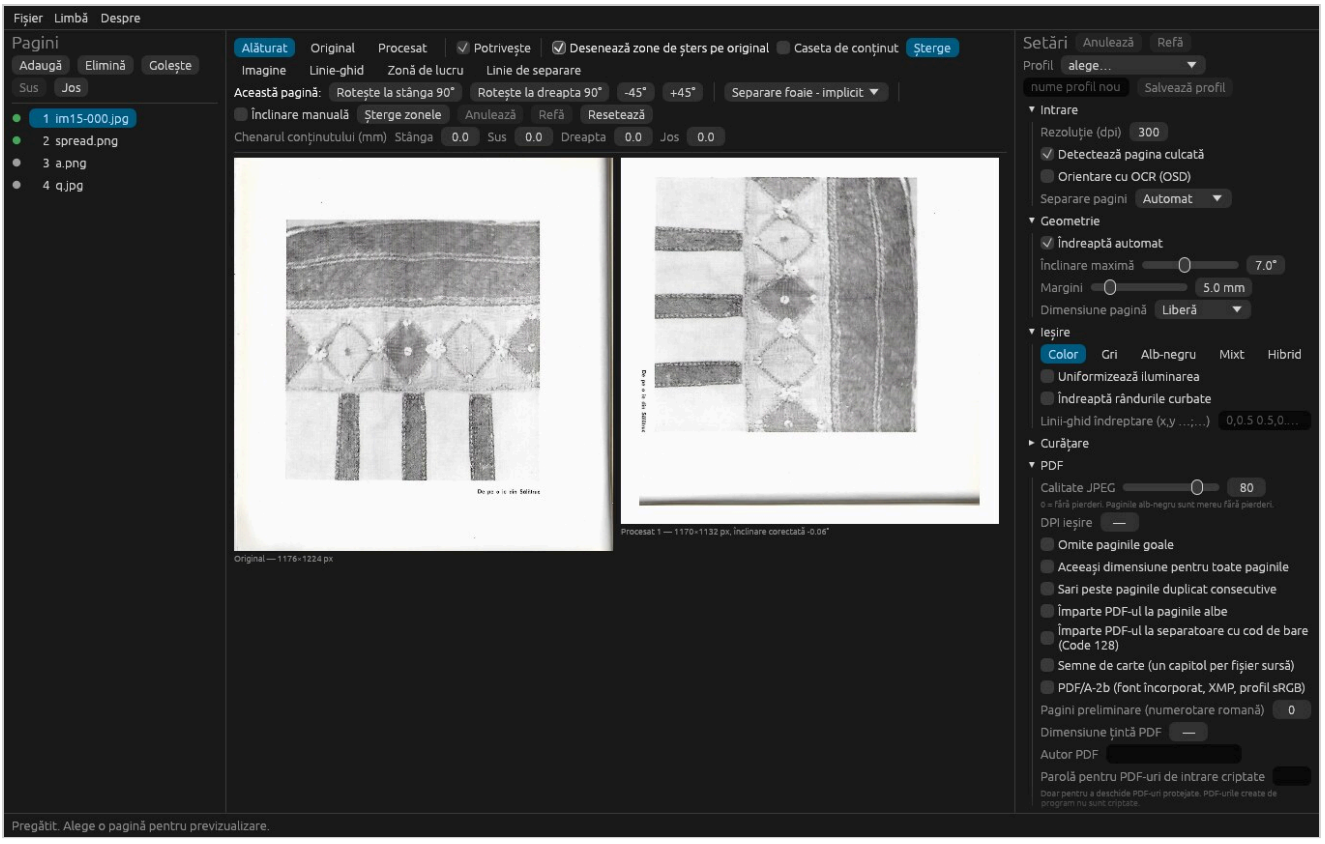
Ugyanaz az oldal (a 15. oldal a tesztelő PDF-jéből) és ugyanazok a beállítások, az észlelést kivéve: a pre.18-ban, bejelölt „Oldalra fordított lapok felismerése" mellett (alapértelmezett) a program 90°-kal elforgatta, noha az eredeti egyenes (a pre.19–20-tól már nem forgatja el); a --no-auto-orient kapcsolóval (vagy a beállításokban kijelölés nélkül) egyenesen jön ki. A parancssorban ellenőrizve; az ablakban a forgatást a pre.18-ban, a hiányát a pre.19-ben láttam.



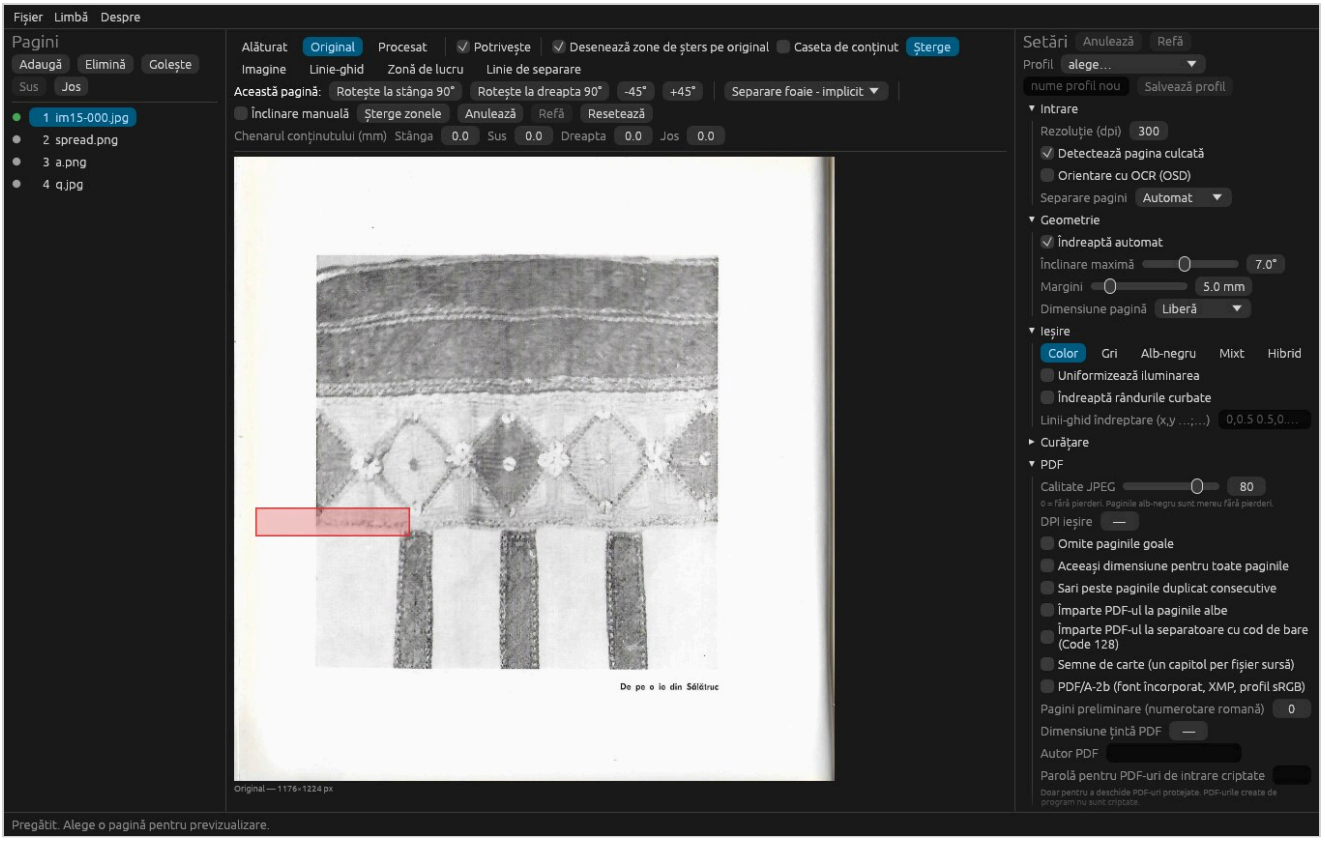
A Visszavonás (a gomb) és a Ctrl+Z (az ablakkal az előtérben) eltávolítja az utoljára rajzolt zónát. Az ablakban ellenőrizve.

Zónák, vezetők és a tartalomdoboz

Jelöld be a „Zónák rajzolása" négyzetet; öt rajzolási típus jelenik meg (Törlés, Kép, Vezetővonal, Munkaterület, Vágóvonal):

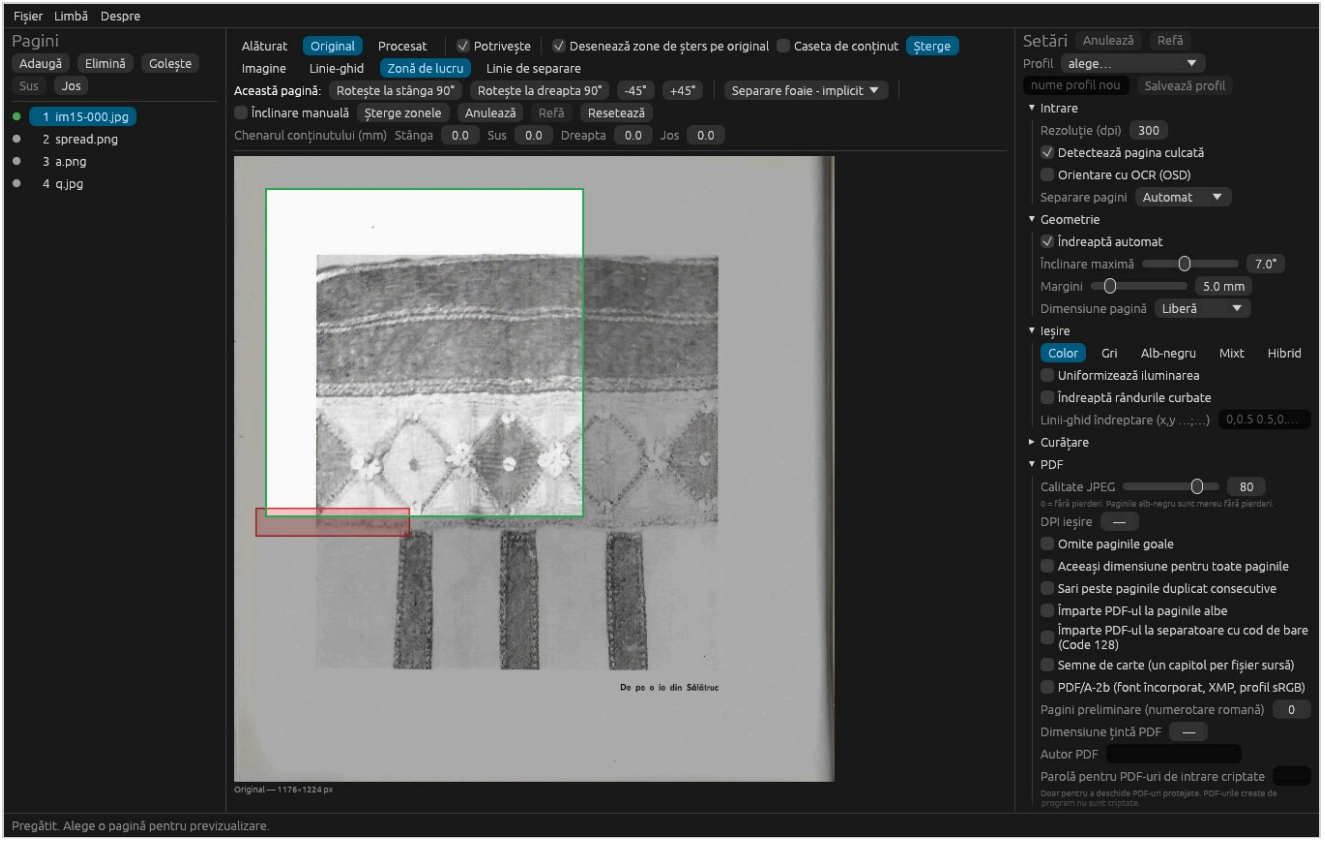


A „Zónák rajzolása" bejelölésekor megjelennek a zónatípusok: Kép, Vezetővonal, Munkaterület, Vágóvonal (és a Törlés, az alapértelmezett típus).

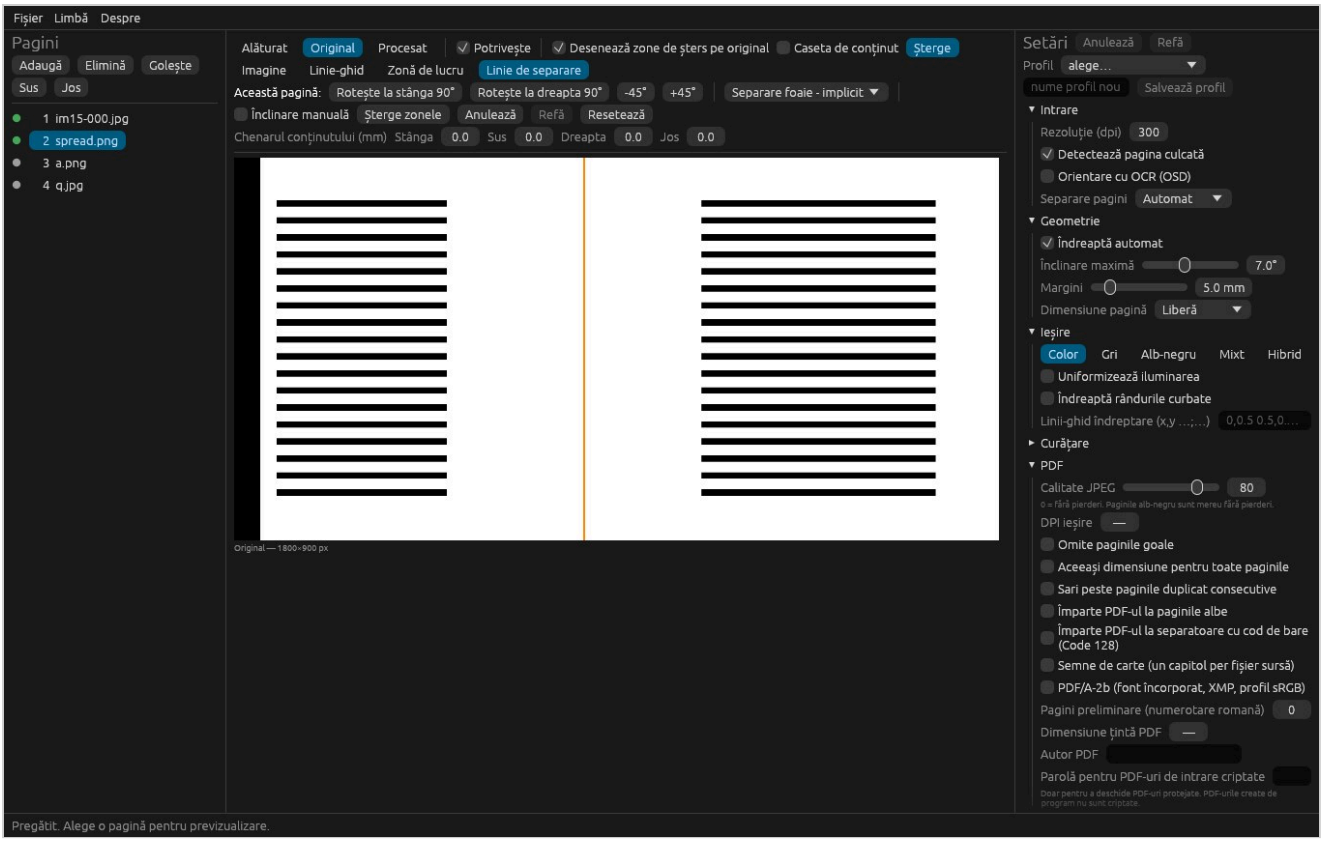


Egy egérrel az eredetire húzott törlési zóna (piros), az Eredeti nézetben.

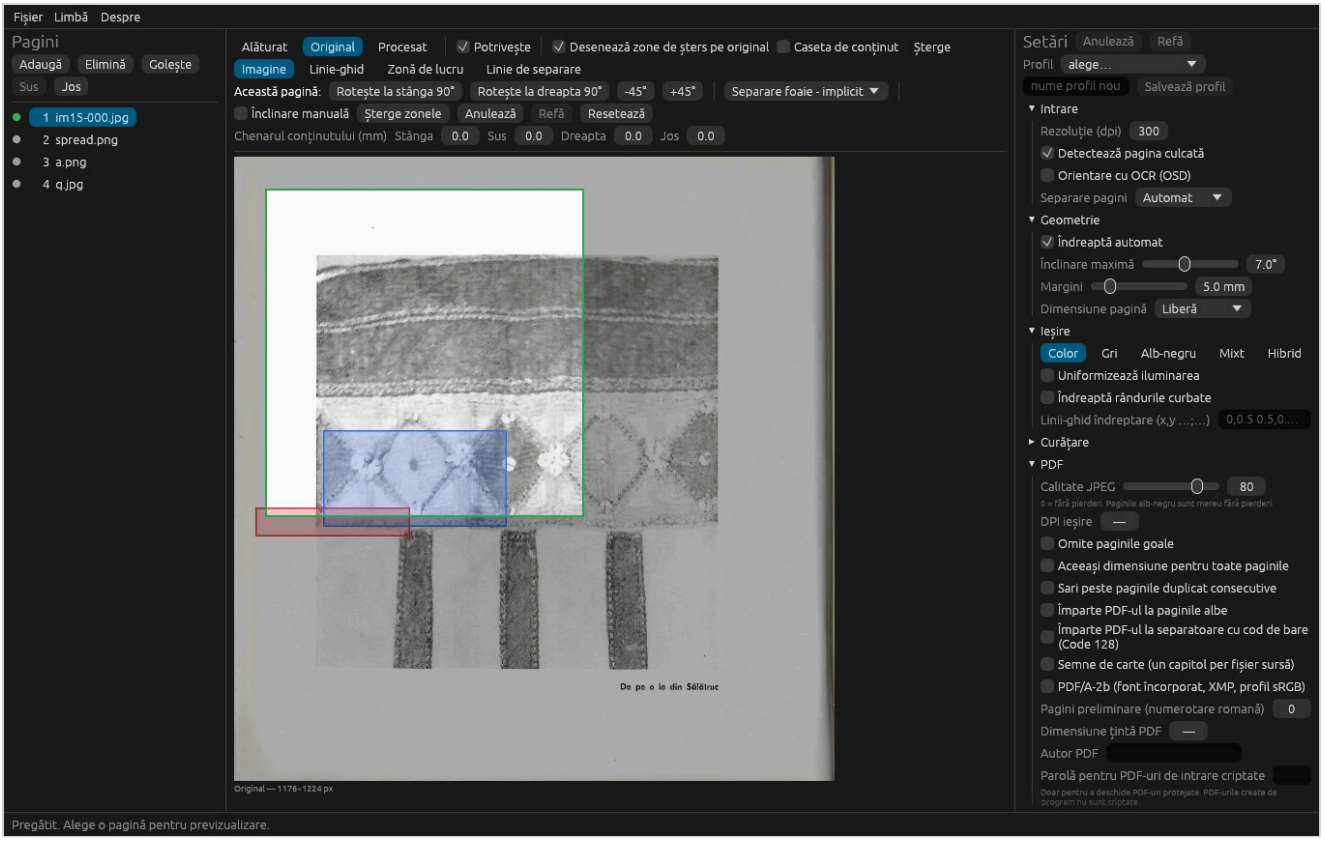
Típus	Hogyan használod	Mire való
Törlés	Húzol egy téglalapot az eredetin. A jobb kattintás rajta törli. A sarkát húzva átméretezheted.	Folt, bélyegző, valakinek a jegyzete, az árnyékos szél
Kép	Ugyanúgy, mint a „Törlés".	Megmondja a programnak, hogy a terület kép, nem szöveg (vegyes módban színes marad)
Vezetővonal	Szabadon húzod egy görbe sor mentén. Egy csomópontot húzva áthelyezed; a vonalon duplán kattintva csomópontot adsz hozzá, a csomóponton duplán kattintva törlöd; a vonalon jobb kattintással törlöd.	Az általad húzott sorok szerint egyenesíti ki az oldalt



A munkaterület (zöld keret): ami kívül esik rajta, az eltávolításra kerül, a megmaradt terület pedig a feldolgozott oldalon látszik. Van rajta egy törlési zóna is (piros).



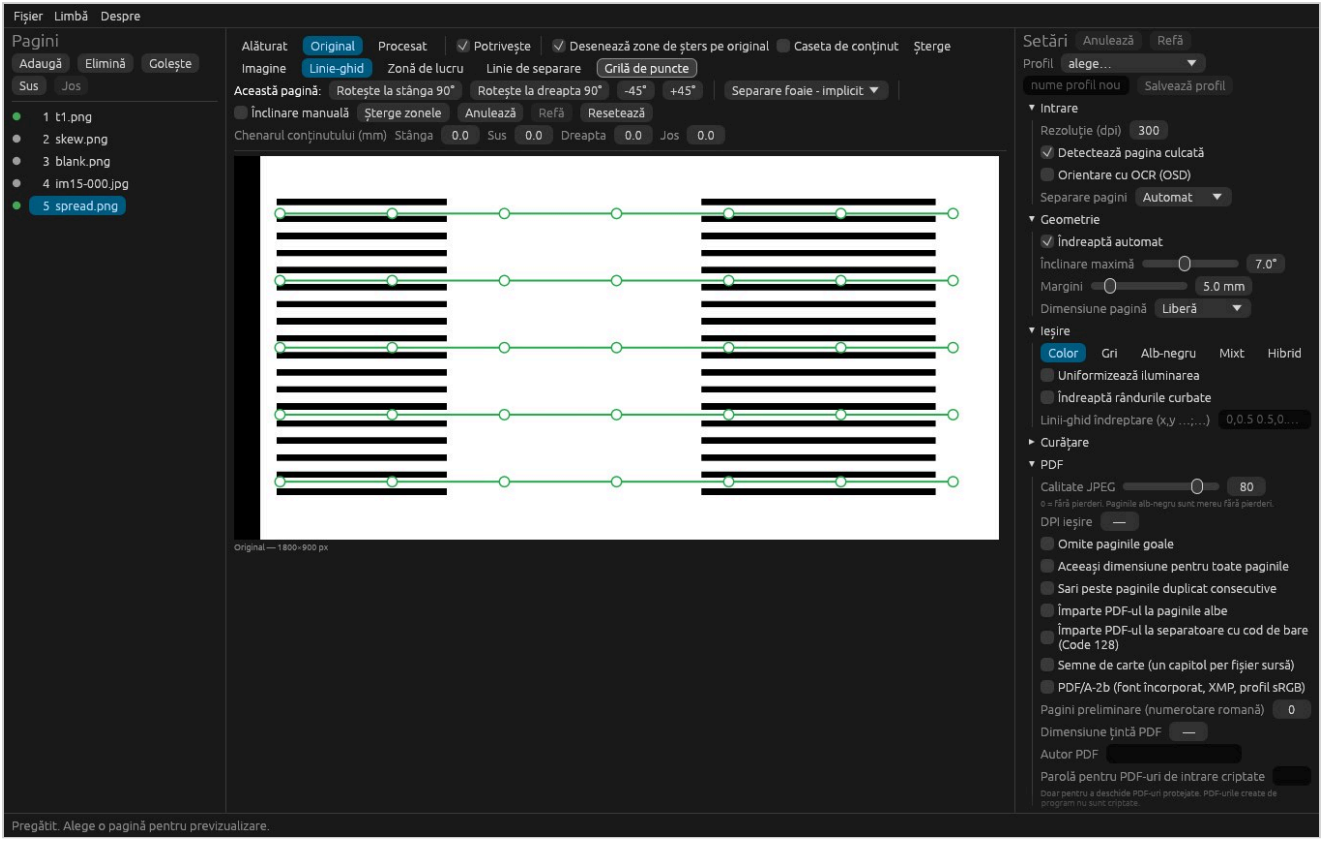
A vágóvonal (narancssárga) egérrel egy kétoldalas lapon áthelyezve. A példa egy szintetikus tesztlap, szöveg helyett vonalakkal.



Az eredetire rajzolt képzóna (kék). Color módban nem változtat semmin; a hatás Vegyes módban látszik (a következő ábra).



Ugyanaz az oldal és ugyanaz a képzóna (kék): Vegyes módban a zóna szürke marad (balra), Fekete-fehér módban minden fekete-fehér lesz (jobbra). Az oldal az oldalra fektetett oldal észlelése miatt 90°-kal elforgatva jelenik meg (lásd fentebb).



A „Pontrács" a Vezetővonalnál: 5 vonal 7-7 ponttal, a szövegsorok fölött.

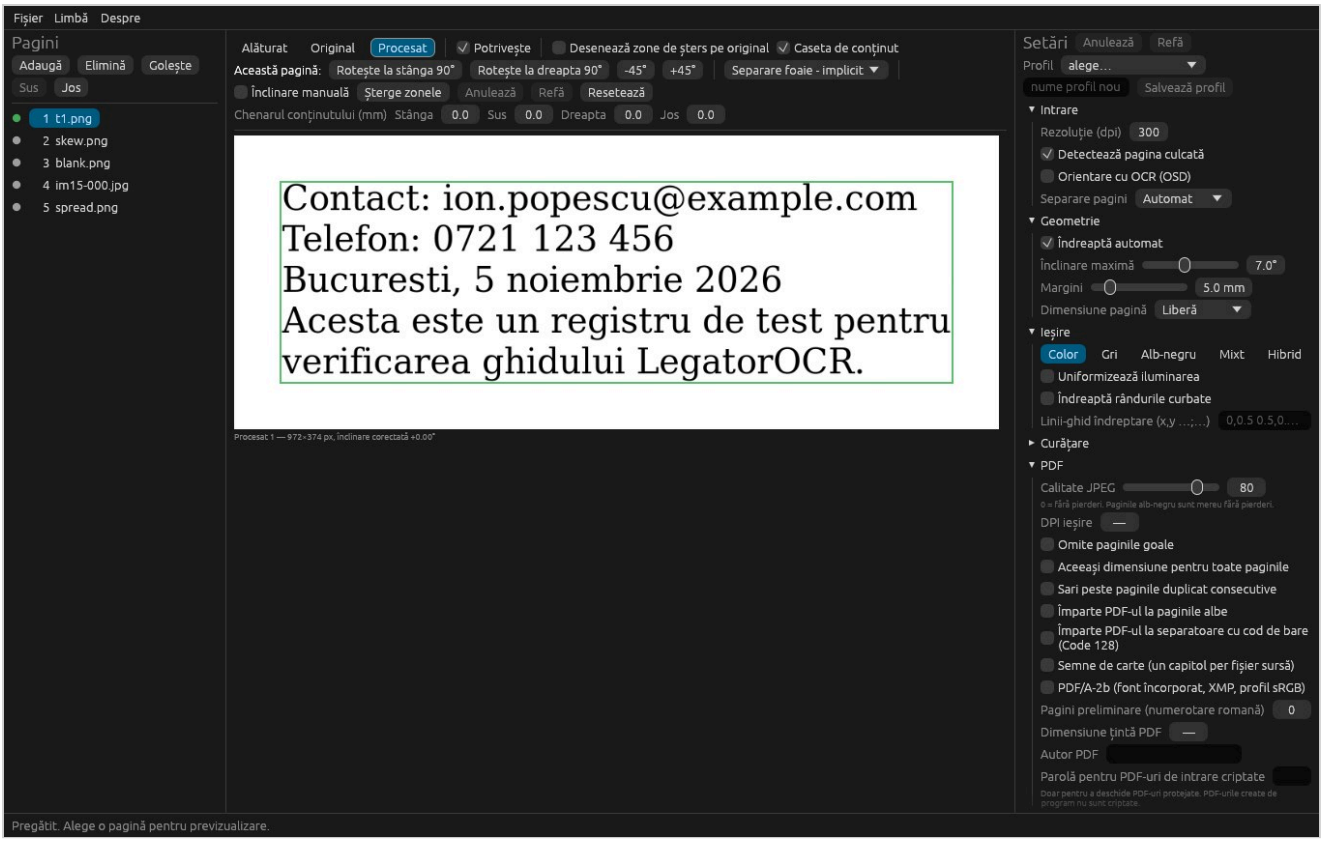
A **Pontrács** (a *Vezetővonal* alatt) 5 vonalat ad hozzá 7-7 ponttal, amelyeknek a pontjait a szövegsorokra húzod. A gombra másodszor kattintva nem ad hozzá még egyszer ugyanolyan rácsot. Ha már áthelyeztél pontokat, az új rács az áthelyezett mellé kerül.

Munkaterület (a pre.18 kiadástól): húzol egy téglalapot az eredetin; ami kívül esik rajta, azt bármilyen mérés előtt papírszínre festi, így egy sötét szél vagy a szomszédos oldal már nem számít. Az eredetin jobb kattintással eltávolítható. A parancssorban: `--work-area X,Y,L,H` (milliméter).

Vágóvonal (a pre.18 kiadástól): kattintással vagy húzással az eredetin mozgatod a függőleges narancssárga vonalat; a kétoldalas lap ott lesz kettévágva, nem középen vagy a gerincnél. A

pre.21-től bármilyen forgatásnál működik; a 90°-kal vagy 270°-kal elfordított lapoknál a vonal vízszintesen vág, és az oldalak egymás alatt jönnek ki (az eredeti bal oldala az első). A jobb kattintás eltávolítja. A parancssorban: `--cut-at 0.45`.

A **Tartalomdoboz** (az azonos nevű jelölőnégyzet) zöld keretet jelenít meg a feldolgozott oldalon. Az oldalakat húzva szélesíted vagy szűkíted a megtartott területet. A két oldalra vágott lapnál csak az az oldal változik, amelyen a keretet húzzák.



A tartalomdoboz (zöld keret) a feldolgozott oldalon.

Görbe oldalak, ferde vágás és oldalankénti beállítások

Három segítség kézzel fotózott lapokhoz:

- **Ferde vágóvonal.** A „Törlési zónák rajzolása az eredetin” bejelölésével és a Vágóvonal típussal az „A vonal dőlése” csúszka (−20° … 20°) megdönti a vonalat; minden oldal megtartja a ferde vonal rá eső oldalát, a másik oldalt papírszínre festi. A vonalra jobb kattintással törölhető, és a dőlés nullára áll. Parancssorban: `--cut-angle FOK`.
- **Trapézkorrekció.** Két csúszka az „Ez az oldal” sávban („Trapéz fent–lent”, „Trapéz bal–jobb”, ±30 %) a vágás előtt kiegyenesíti a ferdén fotózott lapot. Az **Auto trapéz** gomb (az oldalak szétválasztása után) minden oldalt megmér — a szövegsorok dőlését és a szöveg szélességét fent és lent —, és csak arra az oldalra jegyez meg korrekciót. Szándékosan óvatos: ha túl kevés a sor, vagy a mérések ellentmondanak, az oldalt változatlanul hagyja. Ellenőrizd az eredményt, a Visszavonás kéznél legyen. A −45°/+45° gombok megmaradnak. Parancssorban: `--keystone-v` és `--keystone-h` (százalék).
- **Oldalankénti beállítások.** A Kimenet és Tisztítás fölötti „Beállítások ehhez: Minden oldal / Csak ez az oldal” a kimeneti módot, a küszöböt, a foltmentesítést és a többi tisztítási beállítást a vágott lap egyetlen oldalára alkalmazza; a zöld tartalomkeret csak azt az oldalt módosítja, amelyen húzzák. Projektben: `page1.KULCS = ÉRTÉK` / `page2.KULCS = ÉRTÉK` a [sheet]

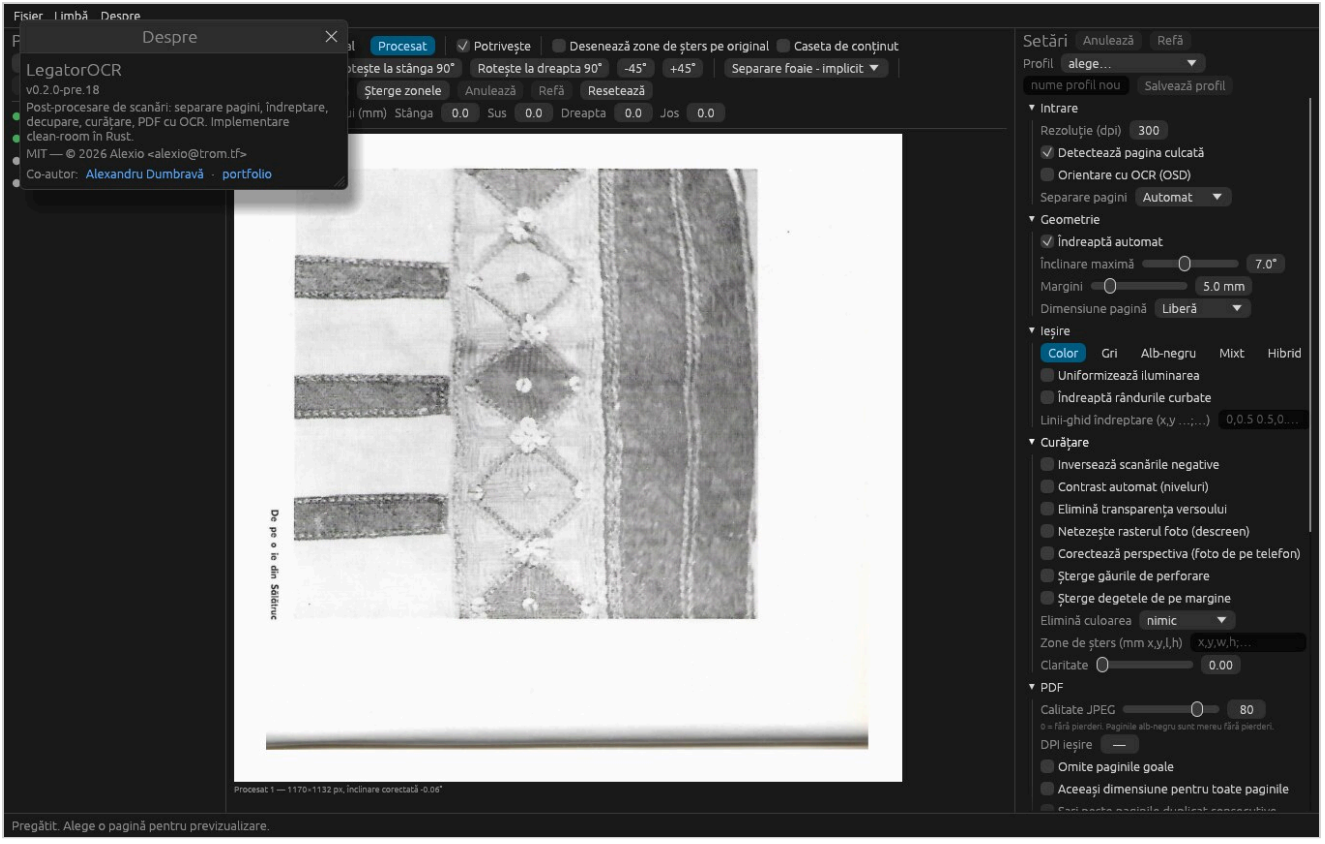
alatt. Egy feldolgozott oldalra kattintva kijelölöd (kék keret): a kimeneti mód (szürke, fekete-fehér, vegyes), a tisztítás, a trapézkorrekció, a zöld doboz és az OCR-ceruzák ezután csak arra az oldalra hatnak. A rajzolt OCR-zónák az adott oldalhoz tartoznak (`page1.page_ocr_zones`, `page_ocr_ignore`).

Az előnézet alatti sáv tartalmazza a tartalomdobozt, az OCR-ceruzákat és az **Auto OCR-ceruzát** (külön a bal és a jobb oldalra): az adott oldal tartalmára teszi az OCR-zónát.

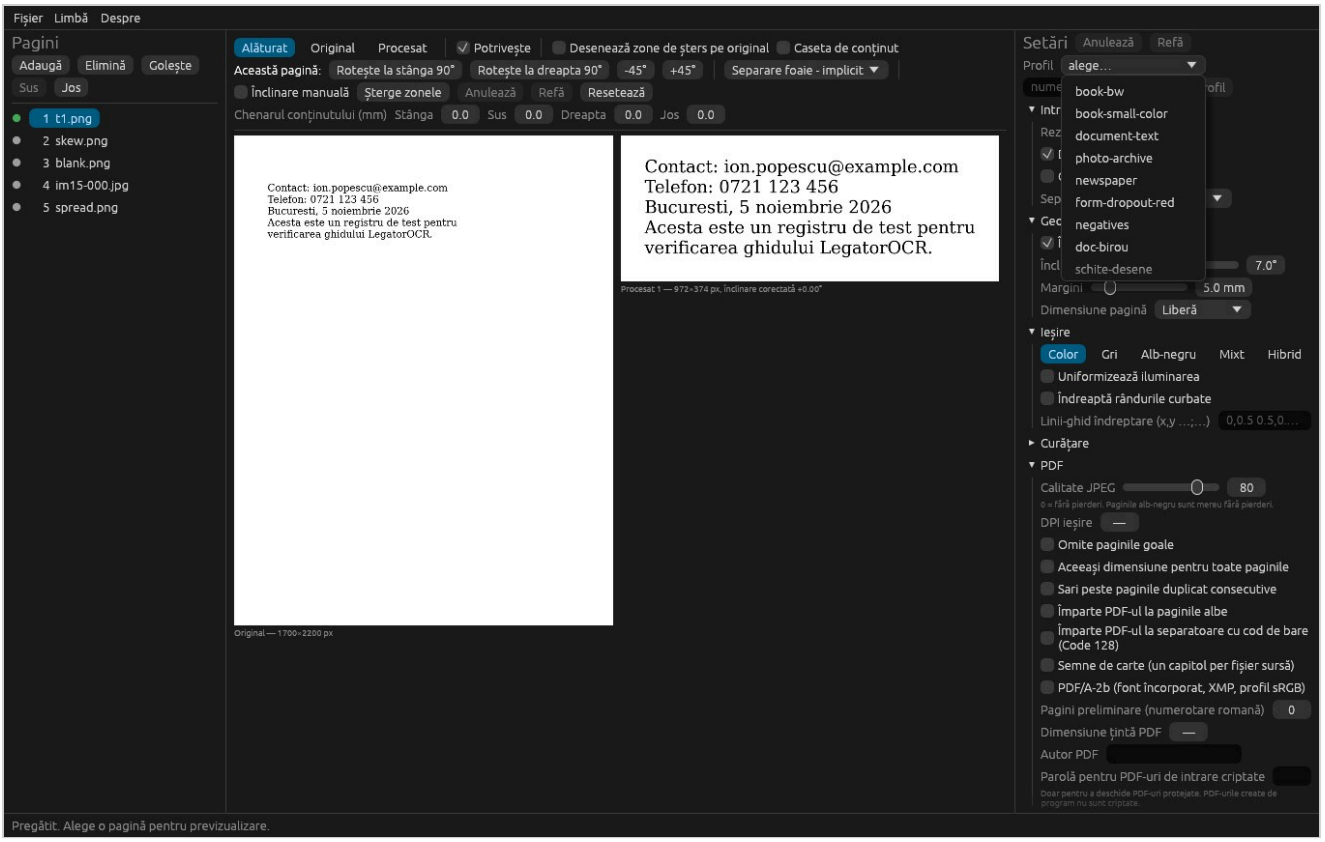
Az oldalméretek között mostantól ott van az A2–A6, B3–B6, Letter, Legal és Tabloid (a `--page-size` ugyanezeket a neveket fogadja). OCR-ceruzák a feldolgozott oldalakon: zöld (OCR-zóna), piros (kihagyott terület), lila (táblázat, egy blokként, soronként olvasva; `--ocr-zone X,Y,W,H#table`).

A jobb oldali beállítások

Szakaszokba vannak csoportosítva: Bemenet, Geometria, Kimenet, Tisztítás, PDF, OCR, valamint a profilok. A 6. szakasz elmagyarázza, melyik mit csinál.



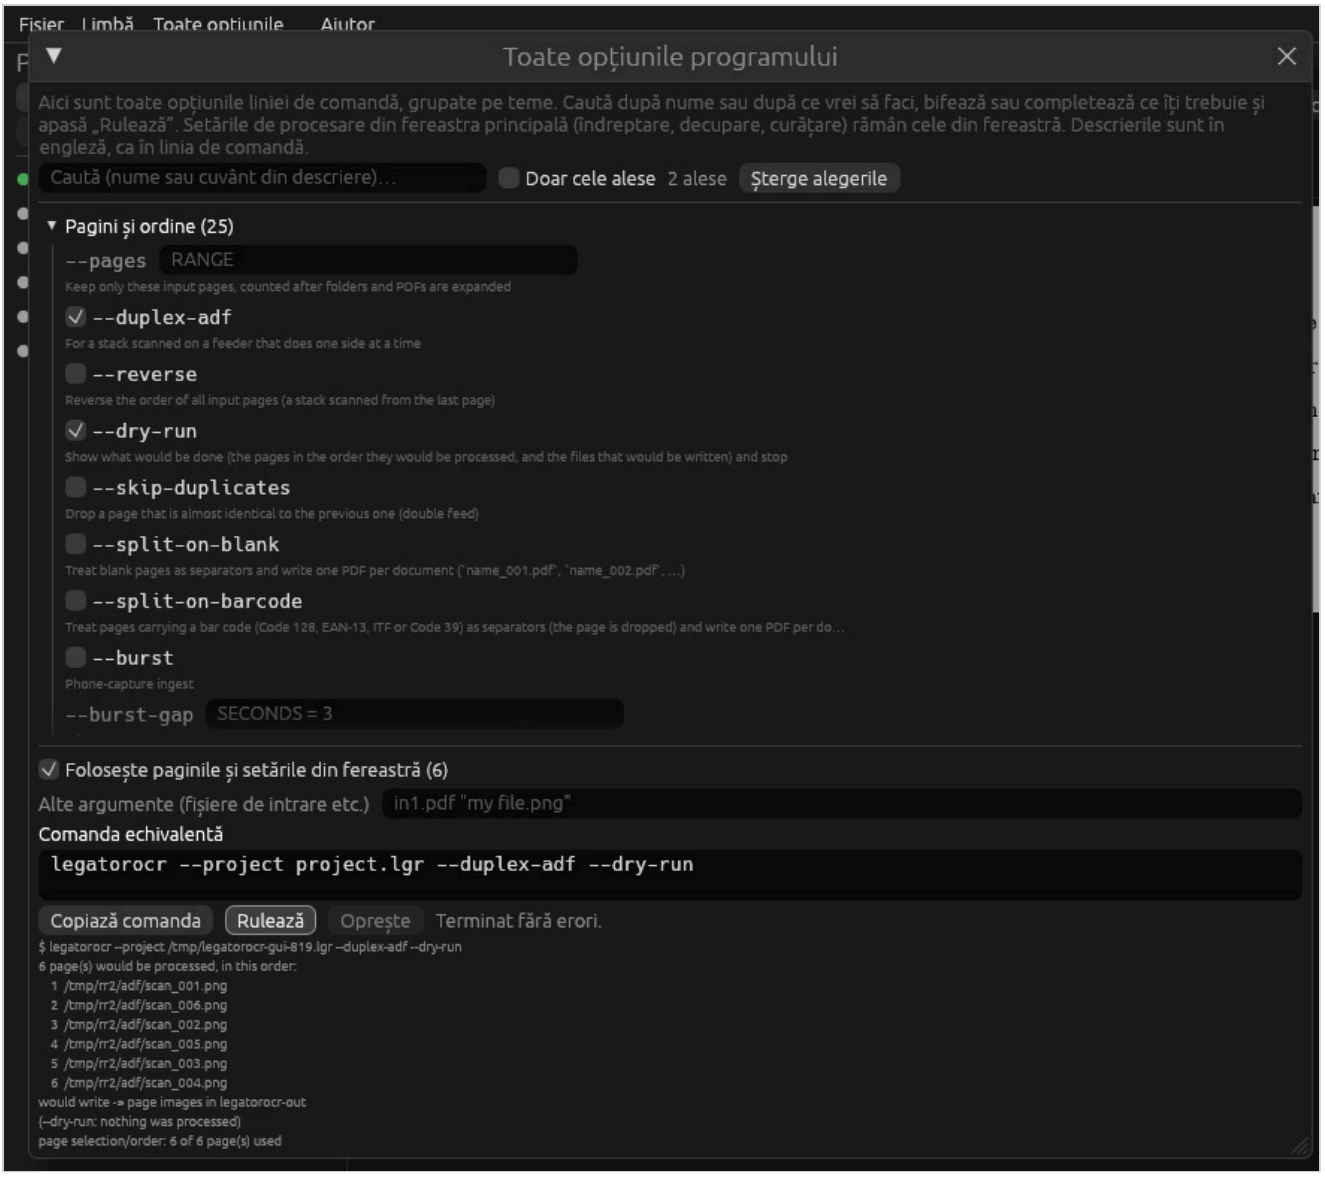
A beállítások Tisztítás szakasza kinyitva: negatív szkennelések invertálása, automatikus kontraszt, perspektíva, a lyukasztások eltávolítása, törlési zónák számokként.



A beállítások „Profil" listája (a beépített profilok; a sajátjaid ugyanitt jelennek meg a „Profil mentése" után).

Minden opció és a felhasználói útmutató

A felső sávban lévő **Minden beállítás…** gomb egy ablakot nyit a parancssor **összes** opciójával (több mint 200), témák szerint csoportosítva: oldalak és sorrend; kiegyenesítés, vágás és tisztítás; kimenetek (PDF, képek, dokumentumok); OCR és szöveg; archiválás, aláírás és ellenőrzés; keresés és összehasonlítás; kötegek, rendszer és modulok. A lista közvetlenül az ablakkal szállított parancssori programból van beolvasva, így mindig megegyezik azzal a kiadással, amelyet használsz.

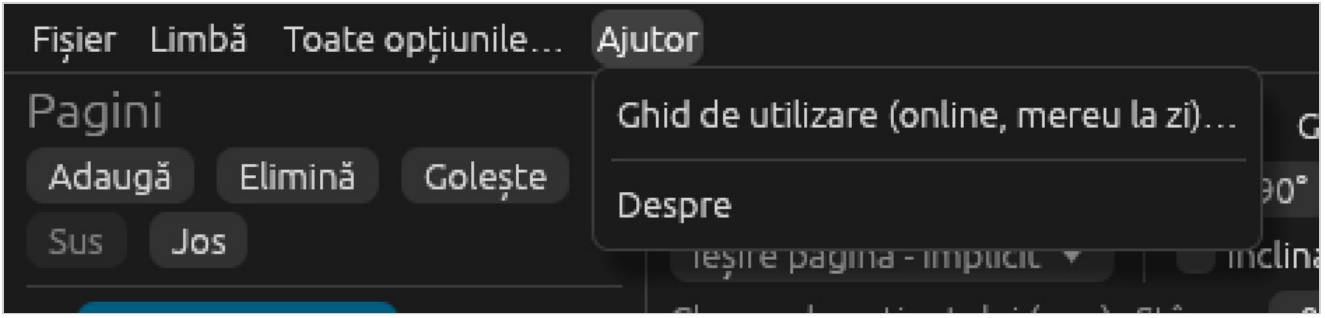


A „Minden beállítás" ablak, megnyitott „Oldalak és sorrend" csoporttal, bejelölt `--duplex-adf` és `--dry-run` opciókkal, és a futtatás eredményével: a sorrend, amelyben a köteg hat oldalát feldolgoznák (általam készített tesztoldalak).

- **Keresés** név (`pdf`, `dry`) vagy a leírásban szereplő szó alapján; az eredményt tartalmazó csoportok maguktól kinyílnak. A „Csak a kiválasztottak" azt mutatja, amit bejelöltél vagy kitöltöttél.
- Az üres mezők nem kerülnek elküldésre: egy értékkel rendelkező opció csak akkor kerül a parancsba, ha írsz valamit (vagy választasz a listából). A **Választás…** gomb a fájl- vagy mappaválasztó párbeszédablakot nyitja. Az ismételhető opcióknál (például `--erase`) soronként egy értéket írsz.
- **Az ablak oldalainak és beállításainak használata** (alapból bejelölve): a parancs a betöltött oldalakat kapja, mindegyik módosításaival, egy ideiglenes projekten keresztül. A főablak feldolgozási beállításai (kiegyenesítés, vágás, tisztítás) elsőbbséget élveznek; itt a kimeneteket és a különleges funkciókat töltöd ki. Szüntesd meg a bejelölést oldalak nélküli parancsoknál (`--doctor`, `--verify-sums`), vagy írd a bemeneti fájlokat az „Egyéb argumentumok" közé.

- Az **Egyenértékű parancs** frissül, ahogy választasz; kimásolhatod és használhatod terminálban vagy szkriptekben. A **Futtatás** végrehajtja és alatta megmutatja az eredményt; a **Leállítás** megszakítja. A relatív útvonalak a személyes mappádhoz képest értendők.
- Az opciók leírásai angolul vannak, mint a parancssorban; az ablak többi része a választott nyelven van.

A **Súgó** menü tartalmazza az erre az útmutatóra mutató hivatkozást: a *Használati útmutató (online, mindig friss)…* a legatorocr.chiuta.ro-n közzétett legutóbbi változatot nyitja meg, az *Ennek a kiadásnak az útmutatója (PDF)…* (akkor jelenik meg, ha a PDF-fájl a program mellett van, mint a közzétett archívumokban) pedig a programmal együtt szállított másolatot. Az útmutató minden kiadásnál újraépül, és a kiadás közzététele leáll, ha az útmutató nem említi a verzióját.



Ellenőrizve: az ablak, a keresés, a bejelölés, egy parancs futtatása az ablak oldalaival (a fenti képernyőkép) és a Súgó menü megnyitása, Linuxon, virtuális kijelzőn. Nem ellenőrizve: Windows, macOS és arm64; az útmutató tényleges megnyitása böngészőben (csak a menüt ellenőriztem); a „Választás…" párbeszédablakok; az ablak új szövegeinek fordításai (automatikusan írva).

5. A parancssor: receptek gyakori feladatokhoz

Az általános szintaxis: `legatorocr BEMENETEK... [opciók]`. A bemenetek lehetnek képek (PNG, JPEG, TIFF, BMP), beszkennelt PDF-ek vagy egy mappa. A `legatorocr --help` felsorol minden opciót; a `--list-profiles` a profilokat mutatja. A receptekben szereplő opciókat minden kiadás előtt automatikusan ellenőrzik, tehát valóban léteznek; magukat a recepteket nem próbálták ki mind valódi anyagon.

Beszkennelt könyv → PDF kereshető szöveggel

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

A `--pdfa` PDF/A-2b-t ír archiváláshoz, a `--txt` pedig a szöveget is elmenti. A `-o pages` a feldolgozott képek mappája.

```
$ legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt carte.txt -o pagesT
OCR engine: tesseract 5.3.4, language: ron
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to pagesT
wrote carte.pdf (6 page(s), 27 OCR words)
wrote carte.txt
```

A recept 4 tesztfájlon: 6 oldal a carte.pdf-ben. A --pdfa-val a program PDF/A-2b-t ír.

Telefonos fotók → tiszta oldalak

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

A profil egységesíti a fényt, korrigálja a perspektívát, letörli az oldal körüli hátteret (`--trim-background`), a nyitott könyveket középen kettévágja, kiszélesíti a dőlési tartományt, és kiszedi az ujjakat anélkül, hogy a szöveghez érne. Az az oldal, amely szöveg nélkül jön ki, másodszor is beolvasásra kerül, csak a tartalmán. Egységes A4-es oldalakhoz, megnagyobbított szöveggel használd a `--profile phone-photos-a4` profilt. Ugyanannak az oldalnak több fotója először összevonható a `--fuse-frames`-szel (erős zajnál segít; mérsékelt zajnál nem). Az opció egy kimeneti fájlt kap: legatorocr poza1.jpg poza2.jpg poza3.jpg --fuse-frames pagina.png, majd a pagina.png-t a szokásos módon dolgozod fel; az első fotó a referencia.

```
$ legatorocr f1.jpg f2.jpg f3.jpg --fuse-frames fused.png
f1.jpg: aligned (shift 0,0)
f2.jpg: aligned (shift -3,-2)
f3.jpg: aligned (shift 2,-3)
wrote fused.png from 3 of 3 frames
```

A --fuse-frames ugyanannak az oldalnak három fotójával: igazítja őket, és kiírja a fused.png-t 3 képkockából 3-ból.

Archív másolat integritási bizonyítékkal

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

A csomag megőrzi az eredetiket, a projektet, az OCR-szavakat megbízhatósággal, a kimeneteket és egy `RUN.txt` fájlt, amely megmondja, hogyan folytatható a munka. Más lemezekre készülő másolatokhoz: `--backup-from` és `--backup-to`.

```
$ rm -rf registru-arhiva2; legatorocr scans/text.png --profile registre-manuscrise --ocr --lang ron --pdf registru2.pdf
--pdfa --checksums --archive-package registru-arhiva2 -o pagesT2; legatorocr --verify-sums registru-arhiva2/SHA256SUMS.t
xt
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 1 page image(s) to pagesT2
wrote registru2.pdf (1 page(s), 20 OCR words)
wrote registru-arhiva2/derived/ocr.json
archive package: registru-arhiva2 (6 files, 1 originals)
wrote ./SHA256SUMS.txt (2 file(s) added or updated)
5 ok, 0 mismatched, 0 missing
```

A létrehozott és ellenőrzött archív csomag: „5 ok, 0 mismatched, 0 missing".

Nevek és számok elrejtése megosztás előtt

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

A megtalált szavak feketére festődnek a képen, és kikerülnek a szövegből. **Az eredményt szemmel ellenőrizd:** az a szó, amelyet az OCR nem ismert fel, nem kerül elrejtésre.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Valódi eredmény: a telefonszám el lett rejtve, de az e-mail-cím NEM, mert az OCR a „@"-ot „G"-nek olvasta (ion.popescuGexample.com), és az e-mail minta nem illeszkedett. Ezért kell az eredményt szemmel ellenőrizned. A pre.20-tól a program a végén kiírja, hogy az egyes minták hány szót fedtek le, és figyelmeztet, ha egy minta nem talált semmit, vagy ha a szövegben olyan szavak maradtak, amelyek címnek vagy hosszú számnak tűnnek, pontosan mint a fenti képernyőképen.

Nagy köteg több számítógépen

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Ugyanazt a listát futtasd minden gépen, más `--shard`-dal. Kevés memóriához: `--max-memory 500`. Ismeretlen vagy ellenséges fájlokhoz: `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

Kettéosztott köteg (--shard 1/2 és 2/2), majd a --merge-pdf-fel egyesítve.

PDF aláírása

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

Az aláírás jogi szintje a tanúsítványodé. A tanúsítvány jelszavát környezeti változóval add meg, ne a parancssorban. Az időbélyeget (`--sign-timestamp`) csak egy helyi hatósággal ellenőrizték HTTP-n, nem egy valódival HTTPS-en.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Aláírás és ellenőrzés egy általam készített tesztprogram-tanúsítvánnyal (nem valódi tanúsítvány). „time stamp inside: none": nem kértem időbélyeget.

Adagolón beszkennelt köteg, sorrend és oldaltartomány

Sok adagolós szkenner egyszer megy végig a kötegen minden oldalon: először minden előlap (1, 3, 5…), majd minden hátlap, fordított sorrendben (6, 4, 2). A fájlok a szkennelés sorrendjében jönnek ki, nem a könyvéében. A `--duplex-adf` olvasási sorrendbe teszi őket: 1. előlap, 1. hátlap, 2. előlap, 2. hátlap… Az oldalak számának párosnak kell lennie (különben a program üzenettel leáll).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Hat fájl a szkennelés sorrendjében (scan_001 … scan_006). A `--dry-run` megmutatja, milyen sorrendben dolgoznák fel őket és mely fájlokat írnák ki, majd leáll anélkül, hogy bármit feldolgozna: a scan_006 a 2. helyre kerül, a scan_005 a 4.-re.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

Ugyanaz a parancs `--dry-run` nélkül, natív OCR-rel: a szöveg a „Pagina 1 … Pagina 6" sorrendben jön ki (általam készített tesztoldalak, nem valódi könyv).

További sorrend- és kijelölési opciók (kombinálhatók; a tartomány a bemeneti fájlok számozására vonatkozik, 1-től):

- `--pages 1-10,15,20-`: csak a megadott oldalakat tartja meg; a `20-` azt jelenti: „20-tól a végéig". PDF-ekből vagy többoldalas TIFF-lapokból vett oldalakon is működik.
- `--reverse`: megfordítja a sorrendet (az utolsó oldaltól beszkennelt köteg).
- `--dry-run`: ellenőriz egy nagy köteget a hosszú futtatás előtt.

Ellenőrizve: a sorrend és a tartomány automatikus tesztekkel és hat tesztoldallal; valódi adagolós szkennert nem próbáltam. Az opciók az ablakból is kiválaszthatók, a „Minden beállítás…" alatt (4. szakasz).

Tiszta szöveg: saját javítások, élőfejek és cedilla

A `.txt` és `.docx` fájlokhoz (a PDF szövegrétege, a hOCR és a JSON a beolvasott szavakat változatlanul őrzi):

- `--clean-text`: vessző alatti ș és ț, sorvégen széttört szavak összeillesztése (a kötőjel megmarad, ha a két fél szólistabeli szó, az egyszerű összeillesztés pedig nem az), tipográfiai idézőjelek, szóközök az írásjelek mellett. A `--cedilla` ehelyett ş és ţ betűket ír, a vesszős betűket nem ismerő programokhoz és betűtípusokhoz.
- `--find-replace FÁJL`: a saját javításaid, soronként egy, `hibás => helyes`. A `#`-tel kezdődő sorok megjegyzések. Csak egész szavak illeszkednek (az `Ion => Ioan` nem érinti az „Ionescu"-t), és a fájl sorrendjében, a `--clean-text` után kerülnek alkalmazásra. Hasznos tulajdonnevekhez, rövidítésekhez vagy egy bélyegzőhöz, amelyet a motor mindig ugyanúgy olvas félre.
- `--drop-running-heads`: kihagyja az élőfejeket, élőlábakat és a nyomtatott oldalszámokat: egy oldal első vagy utolsó sorát, amely az oldalak legalább felén ismétlődik (a számjegyek nem számítanak); legalább négy oldal kell. A kihagyott sorok a stderr-en vannak felsorolva, hogy lásd, mi ment el.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

A szabályfájl (az első blokk) és ugyanaz a két sor a tesztoldalról beolvasva a `--find-replace` nélkül és azzal: az „Ionescu" „Ionescu-Vale" lett, a „ha" pedig „hectare".

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

Hat tesztoldalon „Anuarul Văii Mari" élőfejjel és egy számmal a program hat élőfejsort kihagyott; a szöveg közvetlenül a „Pagina 1"-gyel kezdődik. Figyelem: a szabály minden ismétlődő első/utolsó sort kihagy, tehát egy olyan könyvnél, amelyben minden oldal utolsó sora hasonló (például „Poziția în raft: 14"), ezek a sorok is elmennének; ezért vannak felsorolva. A funkciót tesztekkel és néhány oldalon ellenőrizték, nem egy nagy könyvkészleten.

Más receptek

A teljes receptek a tároló `docs/tasks/` mappájában vannak, angolul és románul (dokumentumellenőrzés a `--verify-document` és `--mrz` opcióval, archív másolat, nagy köteg).

6. Fontos beállítások és mikor használd őket

Profilok

```
$ legatorocr --list-profiles | cut -c1-100
book-bw              Text books: auto threshold, black & white, punch holes removed
book-small-color     Colour books: sharp text over a light background, smallest files
document-text        Office documents: sharp text, pictures kept in colour
photo-archive        Archive quality colour, light sharpening
newspaper            Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red     Forms with red rules or stamps: drop red, erase ruled lines
negatives            Negative scans: invert and stretch contrast
doc-birou            Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene        Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise  Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim         Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft         Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum         Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma              Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta                Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura            Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos         Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof            user profile
```

legatorocr --list-profiles. Az utolsó sor (smokeprof) egy saját tesztprofilom, nem része a programnak.

A profil egy kész beállításkészlet egy anyagtípushoz. A „Profil" szakaszból (felület) vagy a `--profile NÉV` kapcsolóval (parancssor) választható. Saját profiljaid is lehetnek: beállítod a

paramétereket, beírsz egy nevet, és megnyomod a „Profil mentése" gombot.

Profil	Mire való
`book-bw`	szöveges könyvek, fekete-fehér, a lyukasztások eltávolítva
`book-small-color`	színes könyvek, tiszta szöveg világos háttéren, kis fájlok
`document-text`	irodai dokumentumok, a képek színesek maradnak
`photo-archive`	fényképek, archív minőség
`newspaper`	újságok: Wolf-küszöb, erősebben eltávolított foltok
`form-dropout-red`	piros vonalas vagy bélyegzős űrlapok
`negatives`	negatív szkennelések
`phone-photos`	telefonos fotók: javított perspektíva, letörölt háttér az oldal körül, középen kettévágott nyitott könyvek, eltávolított ujjak
`phone-photos-a4`	mint a `phone-photos`, de minden oldal egy A4-es lapra kerül, a szöveg a lapot kitöltésig megnagyítva (a kevés soros oldalakat is)
`registre-manuscrise`	régi anyakönyvek és kéziratok (300–600 dpi), a színek megmaradnak
`schite-desene`	ceruzavázlatok és rajzok (400 dpi)
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	folyamatok irodai dokumentumokhoz, a maximális minőségtől a nagy mennyiségig
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**valódi mintákon nem ellenőrizve**

A teljes listát a `--list-profiles` adja.

A legfontosabb beállítások

Beállítás	Mit csinál	Mikor változtasd
Felbontás (dpi)	mekkora felbontással vannak az oldalak beszkennelve	ha a kép fejlécében nincs dpi; szövegnél 300
Automatikus kiegyenesítés / max. dőlés	az automatikusan korrigált szög határa	ha egy „határértéken" kijövő oldal valójában ferde
Margók, oldalméret, azonos méret	a margók mm-ben; szabad, egyéni vagy az egész könyvre azonos oldal	vegyes formátumú könyvekhez
Kimeneti mód	színes, szürke, fekete-fehér, vegyes (1 bites szöveg + színes képek), hibrid (+ kis felbontású háttér)	fekete-fehér tiszta szöveghez; vegyes képes szöveghez
Küszöbölési módszer	Sauvola (alapértelmezett), Wolf, Niblack, NICK, Bradley, Otsu vagy automatikus	ha a szöveg halvány vagy foltos lesz; az `auto` oldalanként többet is kipróbál
Érzékenység	a Sauvola-módszer érzékenysége a fekete-fehér kimenethez	alapértelmezés 0,3; kis lépésekben változtasd, és ugyanazon az oldalon hasonlítsd össze az eredményt
Képérzékenység	mennyire könnyen számít egy terület képnek	vegyes/hibrid módban
Apró foltok eltávolítása	a foltszűrés erőssége (0,25–4; 1 = alapértelmezett)	csökkentsd, ha pontok vagy diakritikus jelek tűnnek el; növeld, ha foltok maradnak
Dewarp (görbe sorok)	kiegyenesíti a gerinc mellett ívelő sorokat	vastag könyvekhez; kimarad, ha nem látszik egyértelmű hajlás
Megvilágítás kiegyenlítése	kiegyenlíti a hátteret	árnyékos vagy egyenetlenül megvilágított fotókhoz
JPEG minőség	0 = veszteségmentes; a fekete-fehér oldalak mindig veszteségmentesek	kisebb fájlokhoz (javaslat: próbáld a 80–90-et, és hasonlítsd össze a méretet és a megjelenést)
Kimeneti dpi	a kimeneti képet erre a dpi-re kicsinyíti (“—” = nem kicsinyít)	kisebb PDF-ekhez; a 250 dpi alatti oldalakat az OCR előtt automatikusan

Beállítás	Mit csinál	Mikor változtasd
		megnagyítja, tehát a túl nagy csökkentés nem segíti a felismerést
PDF/A-2b	archiváló PDF, beágyazott betűtípussal és színprofillal	archívumba való leadáshoz; a program kimenetein nem ellenőrizték veraPDF-fel

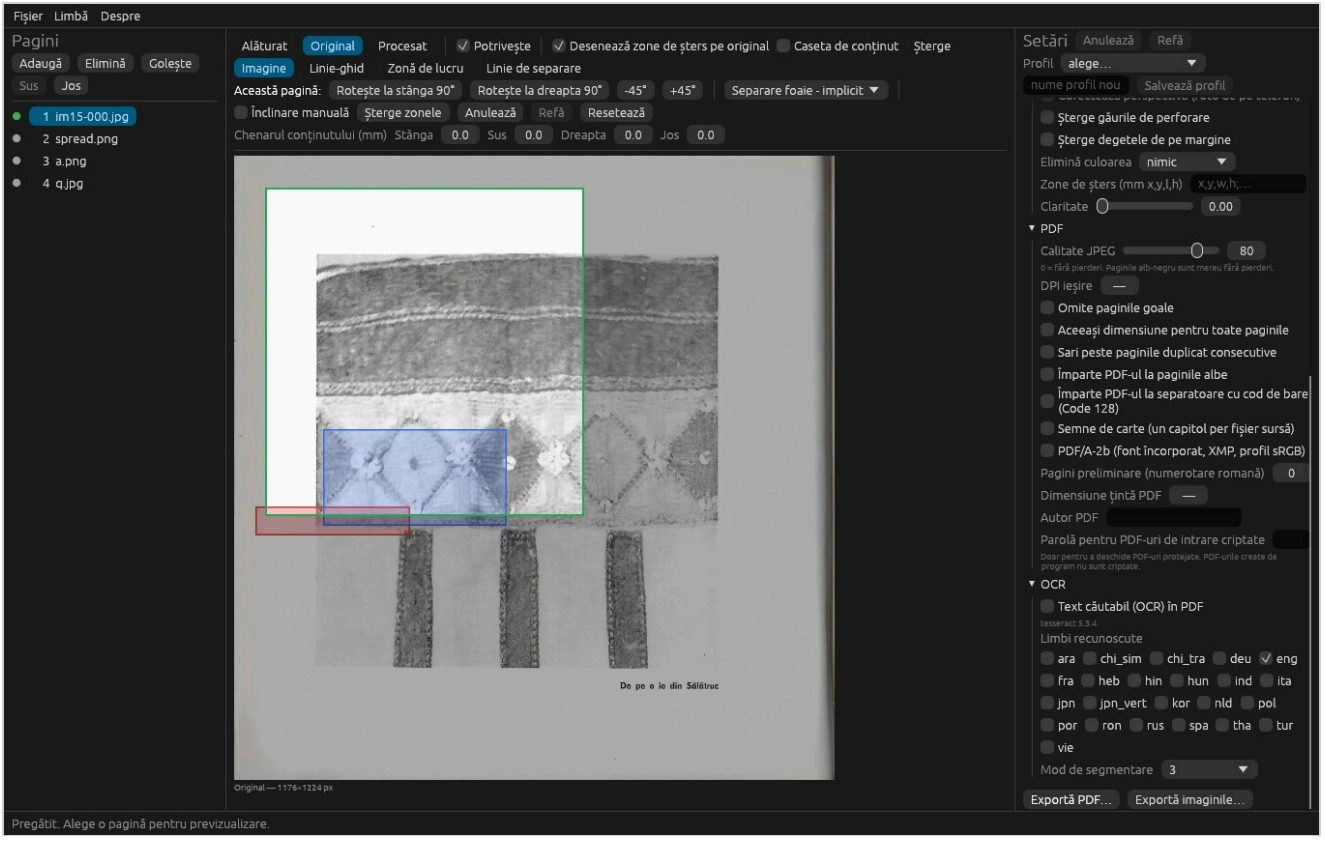
A szövegmezők formátuma

Ezek a mezők megvannak a beállításokban, de egyszerűbb az eredetire rajzolni (4. szakasz):

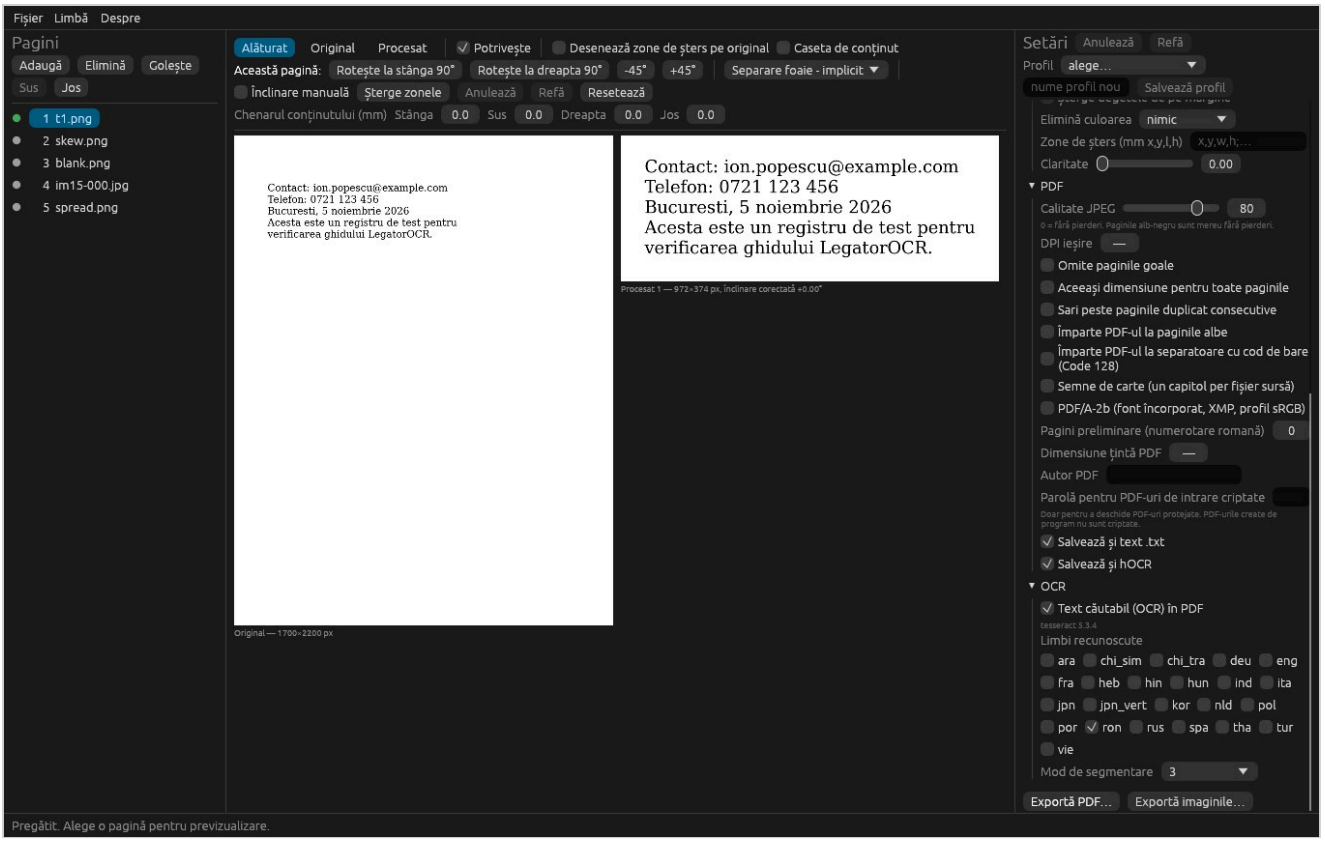
- **Törlendő zónák** és **Képzónák**: `x,y,sz,m` **milliméterben** az oldal bal felső sarkától. Több zónát pontosvessző választ el: 10,20,30,40;50,60,20,20. Legfeljebb 64; a szélességnek és a magasságnak pozitívnak kell lennie. Ha az alak hibás, a mező pirosra vált.
- **Kiegyenesítő vezetővonalak**: `x,y x,y x,y;x,y x,y x,y`, a már kiegyenesített oldal **0 és 1 közötti törtrészeivel** (0,0 = bal felső sarok). Minden vonalnak legalább két pontja van; összesen legfeljebb 64 vonal.
- A parancssorban: `--erase X,Y,W,H` (ismételhető) és `--dewarp-guide "X,Y X,Y …"` (ismételhető).

7. OCR: motorok, nyelvek és pontosság

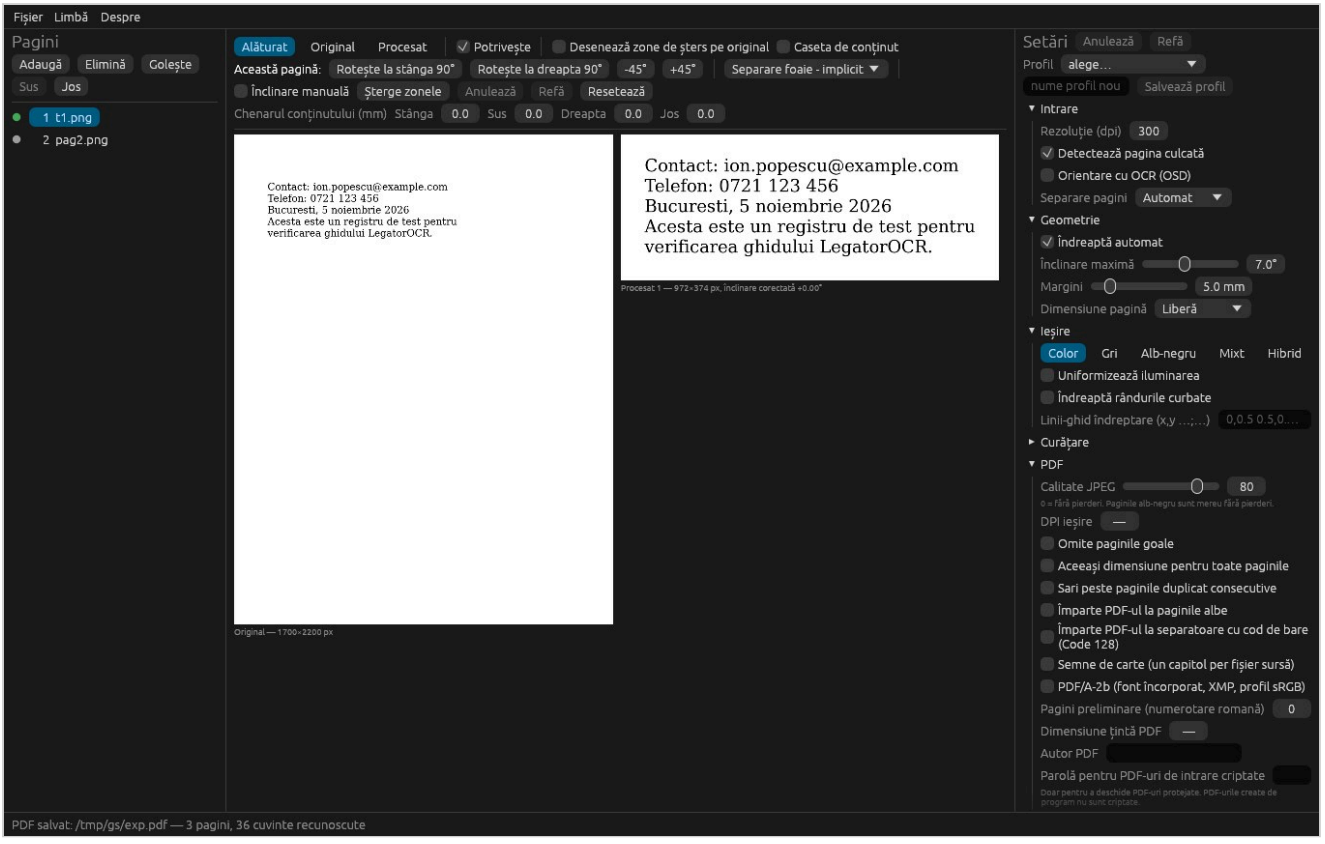
A „Kereshető szöveg (OCR) a PDF-ben" jelölőnégyzet (vagy a parancssorban az `--ocr`) egy láthatatlan szövegréteget ad a kép fölé. A nyelvet a „Felismerési nyelvek" közül választod (vagy `--lang ron`); kombinálható, például `ron+eng`. A felület és a saját motor nyelvei: román, angol, francia, olasz, spanyol, portugál, német, magyar.



A beállítások OCR szakasza: a „Kereshető szöveg (OCR) a PDF-ben" jelölőnégyzet, a felismerési nyelvek (a Tesseractnál telepítettek) és a szegmentálási mód. A képernyőképen a Tesseract 5.3.4 volt telepítve, ezért jelenik meg minden nyelve; a ron választást használtam a következő ábrán.



Bejelölt OCR-rel a „Szöveg mentése is (.txt)" és a „hOCR mentése is" is megjelenik. Itt a választott nyelv a ron.



Az exportálás után az alsó sáv ezt mutatja: „PDF mentve: … — 3 oldal, 36 szó felismerve". (Az exportálást a program egy tesztmechanizmusával indítottam, nem a fájlpárbeszédablakból.)

Három motor

Motor	Hogyan választod	Megjegyzések
Natív (a programé)	`--engine native`	telepítés nélkül, Rustban írva; szintetikus szövegen tanított modell, majd egy román folyóirat és egy 1960-as tankönyv soraival finomhangolva
Tesseract	`--engine tesseract`	külön program, lásd a 2. szakaszt; automatikusan használatos, ha telepítve van és megvan a kért nyelve (`--engine auto`, alapértelmezett)
ONNX-híd	`--engine tesseract --tesseract scripts/engine-onnx.py`	haladó felhasználóknak; Python, onnxruntime és külön letöltött modellek szükségesek

```
$ legatorocr scans/text.png --engine native --ocr --lang ron --txt nat.txt --format none; cat nat.txt; echo; legatorocr
scans/text.png --engine tesseract --ocr --lang ron --txt tes.txt --format none; cat tes.txt
OCR engine: LegatorOCR native engine 0.2.0-pre.19, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote nat.txt
Contact: ion.popescu(aexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote tes.txt
Contact: ion.popescuGexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
```

Ugyanazt a tesztoldalt a két motor olvasta. Mindkettő ugyanúgy tévedett: a „@" a natív motornál „(a", a Tesseractnál „G" lett.

A mért számok (és amit nem mondanak)

Egy román folyóirat 8 jó oldalát mérték, egy ABBYY által készített, ember által nem javított referenciaszöveggel szemben. A karakterhiba-arány diakritikus jelekkel (az eredeti mérés a 0.2.0-pre.21 kiadásból; a pre.26-ban ugyanazon a 8 oldalon, ugyanazzal a módszerrel újramérve a natív motor 2,76 %-ot adott; az eltérést a 2,55 %-hoz képest nem vizsgáltam):

Motor	Karakterhibák
Natív	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (Tesseracttal)	4,62 %

Egyszerűen olvasva: a natív motor kevesebbet téved **ennél a nyomtatványtípusnál**. De ugyanazokból a forrásokból származó szövegen finomhangolták, így nem mondható, hogy általában jobb. Más dokumentumokon, főleg régi vagy szokatlan nyomtatványoknál, gyengébb lehet a Tesseractnál. A teljes szavak felismerése a motorok között közel egyenlő (kb. 92 %).

A pontos mód és a régi helyesírás

- Az `--accurate` (natív motor): minden sort háromszor olvas (egy pixellel felfelé és lefelé eltolva), és a valószínűségeket átlagolja. Lassabb (mérve: 18 %-tól 74 %-ig több idő), és csak a folyóiratoldalakon segített (a karakterhiba 3,66 % → 3,39 % 12 oldalon); könyveken és füzeteken semmi mérhetőt nem változtatott. Alapból ki van kapcsolva.

- A román szólista elfogadja az 1953–1993-as helyesírást is (`cuvînt`, `romîn`, `sînt`): egy 1960-as tankönyv kézzel átírt öt oldalán a helyes karakterek 99,6 %-ról 99,7 %-ra, a szavak 96,0 %-ról 96,3 %-ra nőttek. Kis különbség, öt oldalon.
- A szavakat a széles szóközöknél elválasztja akkor is, ha a hálózat nem írt szóközt: egy táblázat cellái már nem jönnek ki összeragadva (`CantitatePreț`). Egy vonalas táblázatot egyetlen táblázatként talál meg (Excel: `--tables-xlsx`); egy vonal nélküli táblázatot még mindig két táblázatként talál meg (bal és jobb oldal), megoldatlan probléma.

Tanácsok

- A saját dokumentumaidon hasonlítsd össze a motorokat 5–10 oldalon a köteg előtt: a `scripts/compare-ocr-text.py` a hibákat a nálad lévő referenciaszövegekhez méri.
- A 250 dpi alatti oldalakat a felismerés előtt automatikusan megnagyítja.
- Az illusztrációkat vagy ábrákat tartalmazó oldalak értelmetlen szöveget adhatnak a kép területén (a Tesseract az egyik mért oldalon egy illusztrációt szövegnek olvasott). Ellenőrizd ezeket a területeket.
- Bármely OCR kitalálhat vagy elveszíthet szavakat. Iratoknál, anyakönyveknél vagy számoknál ellenőrizd szúrópróbaszerűen.

8. Kimenetek és archiválás

Mit szeretnél	Hogyan
PDF kereshető szöveggel	`--pdf FÁJL.pdf --ocr` (felület: PDF exportálása bejelölt OCR-rel)
Archiváló PDF (PDF/A-2b)	`--pdfa`; más részek a `--pdfa-part 1` vagy `3` kapcsolóval
Feldolgozott képek	`-o MAPPA`, a `--format png`, `jpeg` vagy `tiff` kapcsolóval; a `--format none` nem ír képeket
Az oldalak egyszerű szövege	`--txt FÁJL.txt`
hOCR	a „hOCR mentése is" jelölőnégyzet
Szerkezet a hozzáférhetőséghez	`--tagged ro` (címkézett bekezdések). A PDF/UA-megfelelőséget **nem** validálták
DjVu másolat	`--djvu FÁJL.djvu`
Integritási bizonyíték	`--checksums` és `--archive-package DIR`, majd `--verify-sums`
Projekt (beállítások és javítások)	Fájl → Projekt mentése… (`.lgr`), vagy `--save-project`; az `--embed-project` elrejti a PDF-ben

A PDF/A-ról

A program PDF/A-2b-t ír beágyazott betűtípussal és sRGB-profillal. A megfelelőséget mintákon ellenőrizték, **nem** veraPDF-fel minden kimeneten. Ha egy intézmény tanúsított megfelelőséget kér, futtasd a saját validálódat a végső fájlokon.

A ScanTailor-projektekről

A `--project FÁJL.ScanTailor` megnyit egy ScanTailor-projektet: a szkennelések listáját és a képenkénti forgatást átveszi, a dőlést, a szétválasztást és a tartalomdobozt pedig újra megkeresi. Az olvasó a formátum leírása alapján készült, és egy kézzel készített projekten tesztelték, nem a ScanTailor bármely verziójának fájljain.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project és --project: a projekt elmentődik és ugyanazzal az eredménnyel nyílik meg újra (2 oldal). Figyelem: a pre.18-ban a --work-area és a --cut-at nem maradt meg a projektben; a pre.19-ben javítva (ellenőrizve: az elmentett és újra megnyitott projekt ugyanazokat az oldalakat adja).

9. Gyakori problémák és ismert korlátok

Tünet	Mit ellenőrizz
Az oldal levágva vagy túl sok fehérrel jön ki	a tartalomdoboz (4. szakasz); a keret mm-ben az „Ez az oldal" sávban
A ferde oldal ferde marad	a megengedett maximális dőlés; állítsd be kézzel a szöget
A kétoldalas lap nem ott vágódik, ahol kellene	az oldal szétválasztási módja: „középen" vagy „ki"; a pre.18-tól húzhatsz egy „Vágóvonal"-at az eredetin, vagy használhatod a `--cut-at 0.45` kapcsolót
Egy szövegmező pirosra vált	a mező formátuma (6. szakasz): milliméter a zónákhoz, 0–1 törtek a vezetőkhöz
Az OCR-szövegben hibák vannak	hasonlítsd össze a motorokat (7. szakasz); ellenőrizd a felbontást; válts Tesseractra vagy fordítva
Az „Ellenőrizendő" panel	gyanúsként jelölt oldalak (üres, határértéken lévő dőlés, semmi nem található, a határhoz tapadó tartalom); nem feltétlenül hibásak, de érdemes megnézni őket
Az ablak nem működik Windowson vagy RDP-ben	hiányzó OpenGL 2+; próbáld a videokártya illesztőprogramját
A macOS-alkalmazás nem indul	nincs aláírva: jobb kattintás → Open, vagy az `xattr` parancs a 2. szakaszból

A 0.2.0-pre.43 kiadás ismert korlátai

- Auto trapéz: szintetikus lapokon és egyetlen könyv 67 telefonos fotóján (133 oldal) ellenőrizve, ahol a legtöbb oldalt érintetlenül hagyta, a többin pedig csökkentette a mért dőlést; más könyveken, illetve nagy képes, táblázatos vagy nagyon rövid soros oldalakon senki sem ítélte meg szemmel az eredményt, ott előfordulhat, hogy semmit vagy túl keveset tesz. Az oldalankénti beállításokat és a vágóvonal dőlését szintetikus lapokon és tesztekben próbáltuk; a táblázat-ceruza az OCR-rel egy blokként olvastatja a zónát, cellákat nem keres.
- A 90°-os forgatás: egy ornamentikát ábrázoló fényképes oldalnál (egy PDF 15. oldala) egy windowsos tesztelő azt látta, hogy a forgatás 90°-ról 180°-ra ugrik. A probléma egy részét Linuxon reprodukáltam: a pre.18-ban, bejelölt „Oldalra fordított lapok felismerése" mellett (alapértelmezett), a program tévesen 90°-kal elforgatta ezt az oldalt, noha az eredeti egyenes (az ábra a 4. szakaszban). A pre.19 küszöbe túl törékeny volt (azóta kiderült, hogy ugyanennek a PDF-nek egy másik oldala, a 13., szintén tévesen elforgott). A pre.20-ban az észlelő csak a betűnyi méretű darabokat számolja, és tartózkodik a képes vagy kevés szavas oldalaktól. 98 könyvoldalon (0°-ra és 90°-ra elforgatva) és 5 képes oldalon az eredmény megegyezik a pre.18-éval, kivéve a 13. oldalt (a pre.18-ban tévesen elforgatva,

most egyenes) és egy oldalára fektetett fényképes oldalt, amelyet az észlelő már nem fordít vissza (marad az OSD és a kézi forgatás). A parancssorban ellenőrizve, Linuxon, egy kis korpuszon. Az ugrás valószínű okát (az automatikus tájolás hozzáadódott a kézi forgatáshoz) a pre.18-ban javították: egy forgatáskattintás után az oldal zárolva marad, négy kattintás pedig 90°-ot, 180°-ot, 270°-ot és vissza 0°-ot ad (az ablakban ellenőrizve, Linuxon). Hogy pontosan mit látott a tesztelő Windows 11-en, azt nem tudtam ellenőrizni. Ha egy képes oldal még mindig tévesen van elforgatva, szüntesd meg az „Oldalra fordított lapok felismerése" kijelölését, vagy használd a --no-auto-orient kapcsolót.

- A munkaterületet, az áthelyezhető vágóvonalat, a törlési és képzónákat, a pontrácsot, a Visszavonást és a Ctrl+Z-t, a tartalomdobozt, az OCR-t és a PDF-exportot egy valódi ablakban próbálták ki Linuxon, szimulált egérrel (az útmutató képernyőképei). Egy zóna sarokból való átméretezése működött az ablakban. A natív fájlpárbeszédablakok („PDF exportálása…", „Projekt mentése…", „Projekt megnyitása…") működtek egy xdg-portál GTK-párbeszédablakával Linuxon; Windowson és macOS-en nem próbáltam. Ha a rendszernek nincs párbeszédablaka, a pre.21-től az ablak ezt közli ahelyett, hogy nem csinálna semmit (a fájlokat az ablakba húzhatod, vagy használhatod a parancssort). Egy saját profil mentése működött. A vágóvonal hatását automatikus tesztekkel, a --cut-at-tal és az ablakban ellenőriztem (egy kétoldalas lap két egyenlőtlen oldalra vágva, 524 és 674 px). A 90°-kal vagy 270°-kal elforgatott lapoknál (a pre.21-től) az oldalak egymás alatt jönnek ki; ezt csak egy automatikus teszt ellenőrzi, az ablakban nem.

  --save-project: a közzétett pre.18 buildben a parancssorban megadott --work-area és --cut-at nem maradt meg a .lgr fájlban (ennek az útmutatónak az ellenőrzésekor találták meg). A pre.19-ben javítva. Ha a pre.18-at használod, add meg újra az opciókat a --project mellett, ne csak a projektből.

- A grafikus felületet emberek nem ellenőrizték Windowson, macOS-en vagy arm64-en.
- A PDF/UA-ellenőrzést, a CIUS-RO elektronikus számlát és az időbélyeget HTTPS-en egy valódi hatósággal nem validálták.
- Tanúsított PDF/A másolathoz a validáló a tiéd (például veraPDF).
- A saját OCR-modell használati joga (részben tisztázatlan jogú oldalakon tanítva) a szerzőnél nyitott kérdés; lásd `docs/audit/assets-licences.md`.

10. Hogyan jelents egy problémát

A leghasznosabb hozzájárulás egy jelentés egy olyan rendszerről, amelyet a szerző nem próbált ki. Öt percig tart:

1. Töltsd le a legutóbbi kiadást a rendszeredhez.
2. Futtasd a `legatorocr --doctor` parancsot, és másold ki a teljes kimenetet.
3. Futtass egy olyan oldalt, amelyet megoszthatsz: `legatorocr OLDAL.jpg --ocr --pdf rezultat.pdf -o pagini`.
4. Nyisd meg a `rezultat.pdf` fájlt: az oldal egyenes és megfelelően levágott? A szöveg kijelölhető és kereshető?

Küldd el problémaként a `chiuta/LegatorOCR` tárolóban (vagy e-mailben):

- a rendszert és a verziót (például Windows 11 23H2, macOS 15 arm64, Debian 12 arm64);
- a LegatorOCR verzióját;
- a `--doctor` parancs kimenetét;
- a futtatott parancsot (vagy a felületen lévő beállítást);
- mire számítottál, és mi történt (hibaszöveg vagy képernyőkép);
- hogy a kép megosztható-e.

Ne küldj személyes adatokat tartalmazó dokumentumokat. A „minden működött" jelentés is hasznos: ez az egyetlen módja annak, hogy a szerző megtudja, egy rendszer működik.

A biztonsági problémákat a `SECURITY.md` szerint jelentsd, ne nyilvánosan.