LegatorOCR – Guida per l’utente

Edizione 0.2.0-pre.61 (versione di prova). Testo in lavorazione, in rumeno.

1. Che cos’è LegatorOCR

LegatorOCR trasforma scansioni o foto di pagine in un PDF pulito, con testo ricercabile. Risolve lo stesso problema di ScanTailor (separazione delle pagine, raddrizzamento, ritaglio, pulizia), ma aggiunge l’esportazione in PDF e l’OCR. È scritto in Rust, con codice proprio, e ogni fase è una tecnica da manuale. Funziona in locale, senza account e senza inviare le pagine su internet. Licenza: MIT.

Ci sono due modi di lavorare, con gli stessi motori sotto:

- **L’interfaccia grafica** (`legatorocr-gui`): aggiungi le pagine, vedi l’originale e il risultato affiancati, correggi pagina per pagina ed esporti.
- **La riga di comando** (`legatorocr`): per grandi lotti, per l’automazione e per le opzioni che l’interfaccia non mostra.

Che cosa fa

- separa i fogli fronte-retro in due pagine, raddrizza le pagine inclinate e ritaglia i margini;
- pulisce lo sfondo, le macchie, i fori di perforazione, le dita sul bordo e le linee dei moduli;
- scrive PDF (anche PDF/A per l’archiviazione) o immagini, con OCR in rumeno e in altre 7 lingue;
- produce anche testo semplice (`.txt`) e hOCR, e può firmare o datare il PDF.

Che cosa non fa (o non è stato dimostrato)

- È una versione di prova (0.2.0-pre.61). È stata eseguita dall’autore e dal suo assistente solo su Linux; **Windows, macOS e i processori arm64 non sono stati provati da persone**.
- L’accuratezza dell’OCR è stata misurata su 8 pagine buone di una sola rivista rumena, rispetto a un testo di riferimento prodotto da un altro programma, non corretto da una persona. Non prenderla come garanzia per altri tipi di stampa.
- L’OCR può sbagliare: controlla a campione le pagine importanti.

2. Installazione e primo avvio

Scarica l’archivio per il tuo sistema dalla pagina delle versioni (Releases) del repository `chiuta/LegatorOCR`. Ogni archivio ha un file `.sha256` per la verifica.

Sistema	File	Note
Linux x86-64 o ARM64	`.tar.gz`	richiede OpenGL 2+ e X11 o Wayland
Windows x86-64	`.zip`	richiede OpenGL 2+; nelle semplici sessioni RDP può mancare

Sistema	File	Note
macOS Apple-silicon o Intel	`.zip` con `LegatorOCR.app`	**non firmato**: al primo avvio clic destro → Open, oppure `xattr -dr com.apple.quarantine LegatorOCR.app`

Puoi anche compilare dai sorgenti: `cargo build --release` (richiede Rust 1.95 o più recente).

OCR

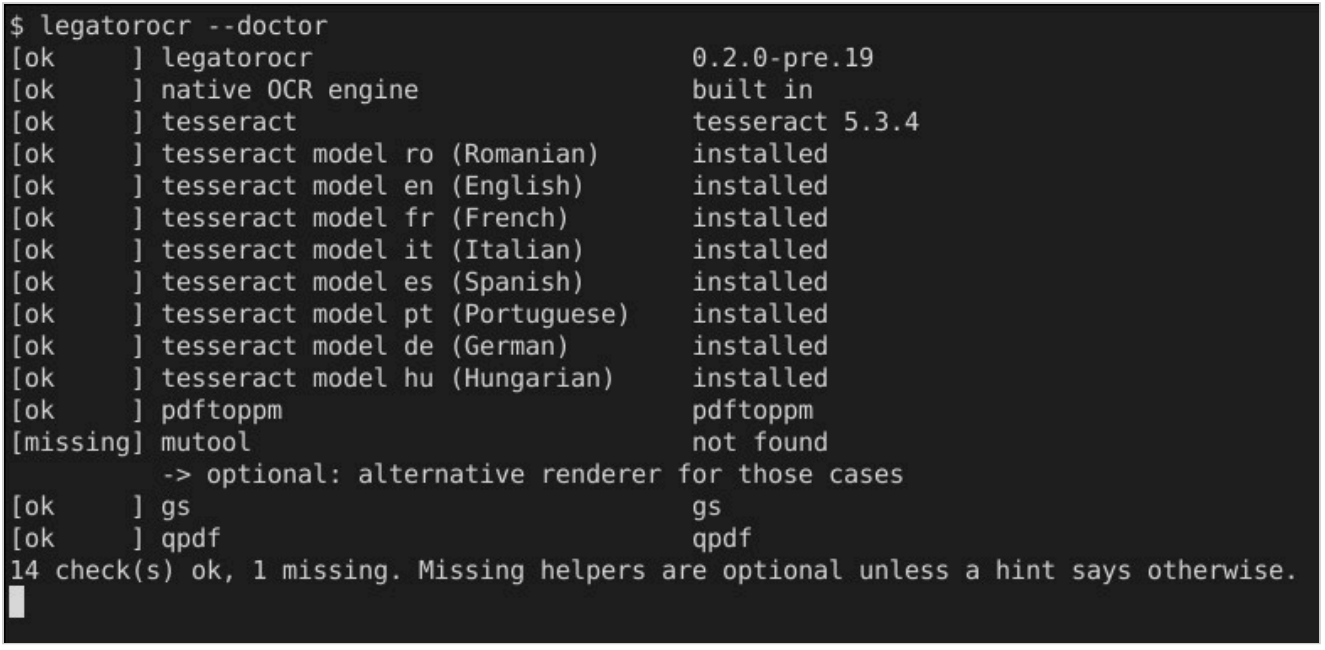
Il programma ha un motore OCR proprio, che funziona senza installazione. Facoltativamente puoi installare Tesseract, un programma separato, che LegatorOCR usa automaticamente quando è presente e ha la lingua richiesta:

- Linux (Debian/Ubuntu): `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS: `brew install tesseract tesseract-lang`
- Windows: `winget install UB-Mannheim.TesseractOCR` e aggiunta al `PATH`

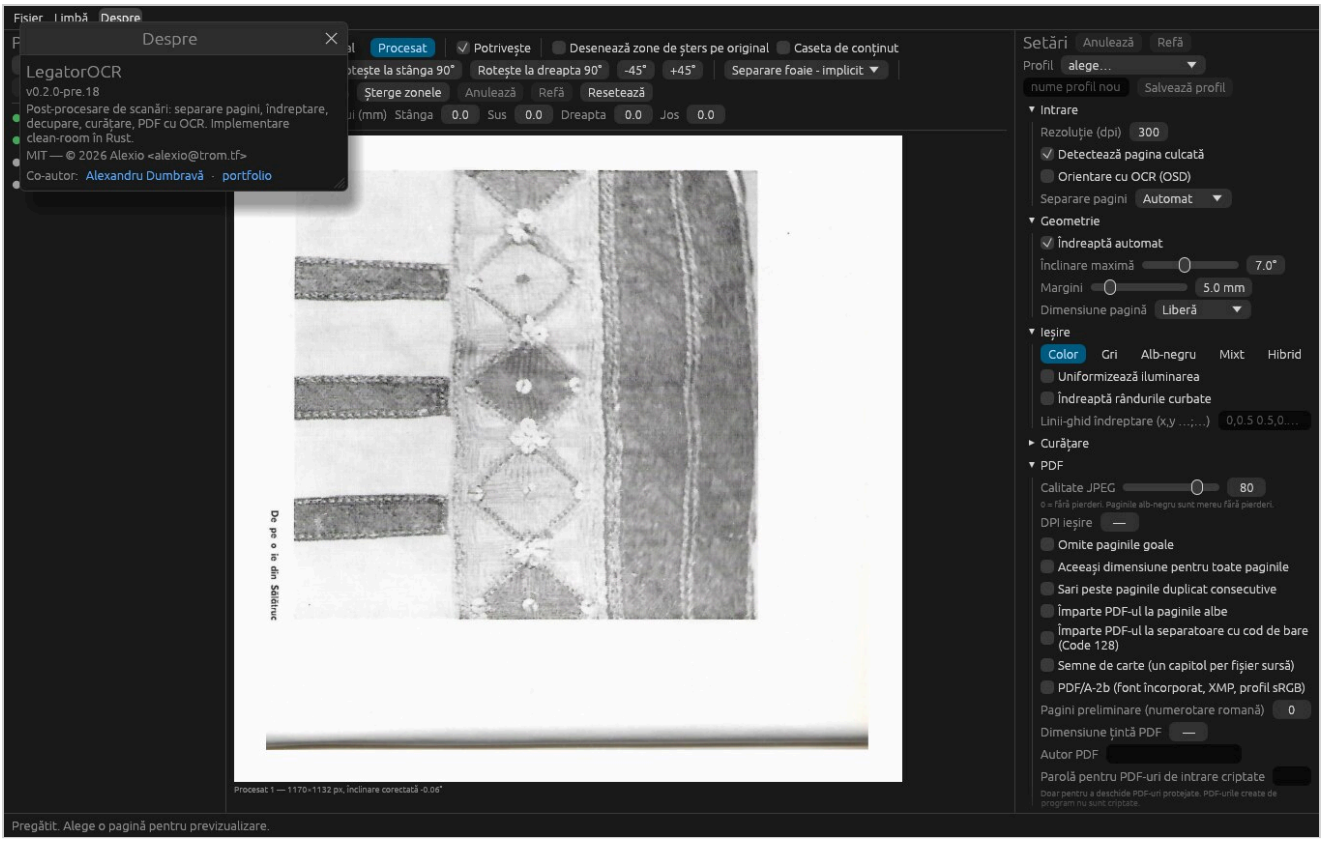
Il modello rumeno dei pacchetti `apt` e `brew` è la variante piccola («fast»). La variante «best» si scarica a mano e si indica con `--tessdata DIR`. Quale delle due legga meglio le tue pagine non è stato misurato.

Verifica l’installazione

Esegui `legatorocr --doctor`. Mostra la versione, il motore OCR nativo, Tesseract e i modelli di lingua, poi gli strumenti ausiliari (`pdftoppm`, `gs`, `qpdf`, `mutool`). Il risultato «missing» per uno strumento opzionale non è un errore; il messaggio sotto dice se serve. Se qualcosa non funziona, copia tutto l’output del comando in una segnalazione (vedi la sezione 10).



Il risultato del comando legatorocr --doctor (pre.20, Linux, in un terminale reale; così tutte le schermate di terminale della guida, fatte con xterm): «missing» per mutool è uno strumento opzionale, non un errore.



Il menu Informazioni mostra la versione installata (qui 0.2.0-pre.18). Schermata dalla build pre.18 su Linux, interfaccia in rumeno.

3. Il flusso di lavoro, passo per passo

Per ogni pagina, il programma percorre le fasi qui sotto in quest’ordine. L’analisi si fa su una copia di circa 150 dpi, e il risultato viene poi applicato alla scansione alla sua risoluzione piena.

1. **Orientamento.** Si rilevano le pagine coricate (un quarto di giro), in base alle lettere della pagina: una pagina con immagini o con poche parole non viene ruotata da questo controllo. Per la direzione esatta si può usare Tesseract (OSD) oppure la rotazione manuale.

2. **Separazione del foglio.** Un foglio orizzontale (landscape) con due pagine si taglia a metà, sulla banda vuota al centro. Può essere automatica, a metà o disattivata.

3. **Raddrizzamento.** Si stima l’angolo di inclinazione dalle righe di testo e la pagina viene ruotata all’indietro. L’angolo si può fissare a mano.

4. **Riquadro del contenuto.** Si individua l’area con testo e immagini; le ombre dello scanner e la polvere vengono ignorate. Tutto ciò che sta fuori viene ridipinto con il colore della carta.

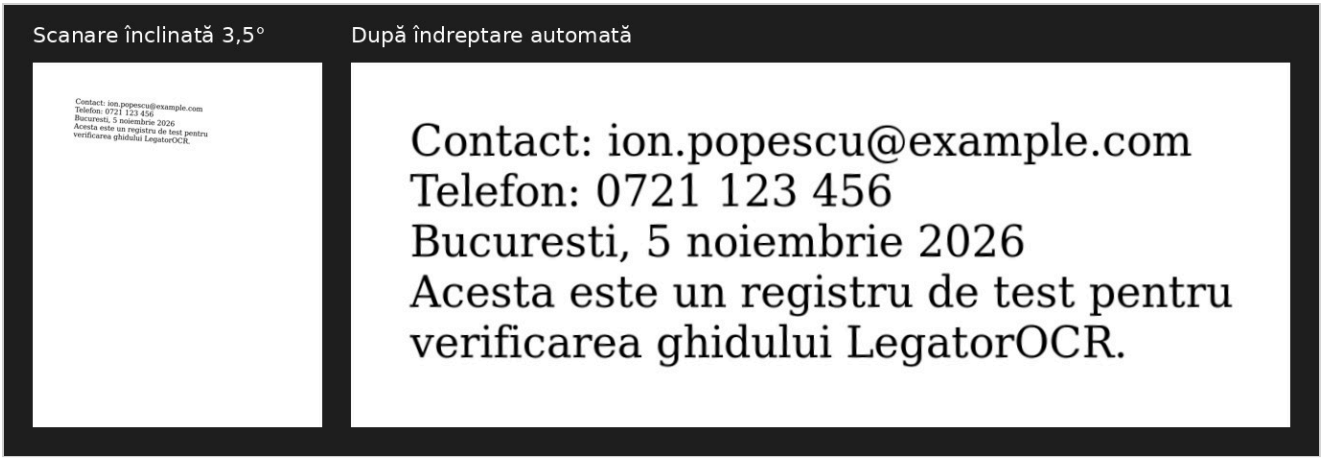
5. **Margini e dimensione.** Margini in millimetri, facoltativamente dimensione fissa della pagina o la stessa dimensione per tutto il libro.

6. **Raddrizzamento delle righe curve** (facoltativo). Per pagine di libro piene, con righe curve vicino alla rilegatura.

7. **Illuminazione** (facoltativo). Uniforma lo sfondo irregolare.

8. **Pulizia e binarizzazione.** Elimina macchie, fori di perforazione, dita, linee; poi bianco e nero, grigio, colore, misto o ibrido.

9. **PDF e OCR.** Si scrive il PDF (o le immagini) e, se spuntato, il livello di testo.



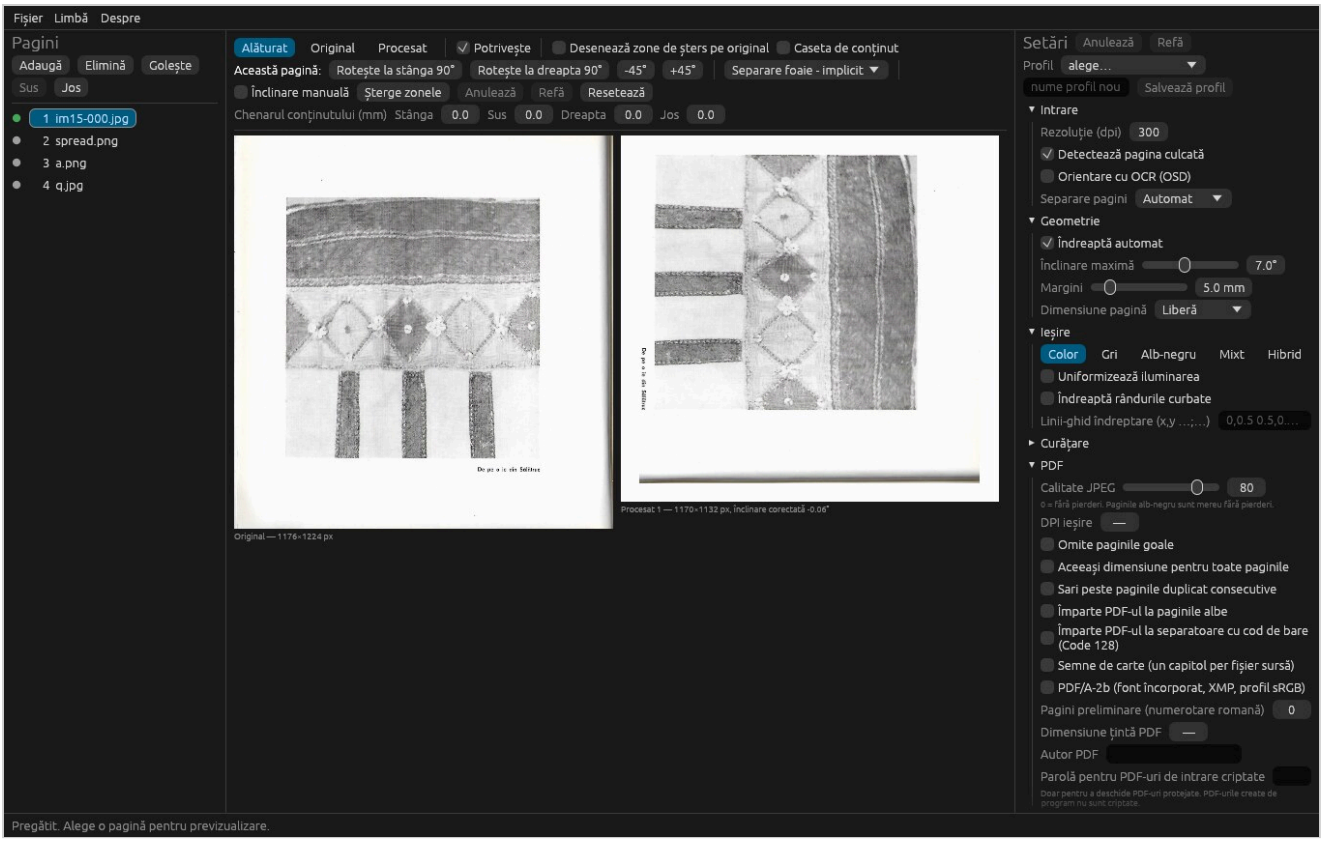
Il raddrizzamento automatico: una scansione inclinata di 3,5° (foglio di prova generato da me) e il risultato; il programma ha misurato -3,50°.

Regole di lavoro che fanno risparmiare tempo

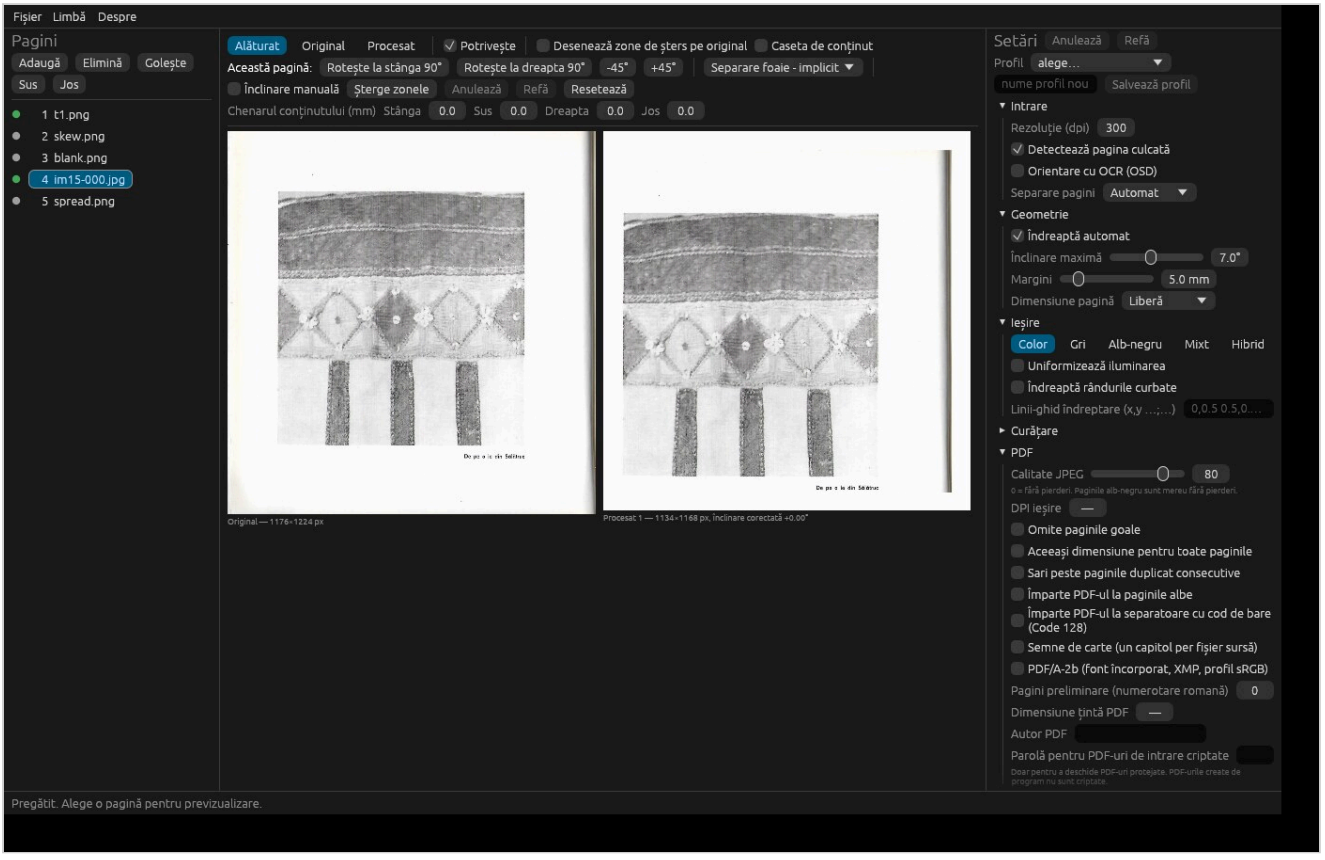
- Imposta prima la **risoluzione** corretta (di solito 300 dpi per il testo). Il programma la legge dall'immagine se è compresa tra 150 e 1200; altrimenti presume 300.
- Scegli un **profilo** adatto al materiale (sezione 6) prima di mettere mano alle singole impostazioni.
- Elabora 10–20 pagine come prova, controlla il risultato, poi avvia il lotto grande.
- L'interfaccia segnala le pagine «da controllare» (pagina vuota, inclinazione al limite, nulla trovato, contenuto attaccato al bordo). Scorrile con il pulsante «Successiva».

4. L'interfaccia grafica

La finestra ha tre zone: l'elenco delle pagine a sinistra, l'anteprima al centro e le impostazioni a destra. Il menu **File** contiene «Aggiungi immagini», «Aggiungi cartella», «Apri progetto», «Salva progetto», «Esporta PDF» ed «Esporta immagini». La lingua dell'interfaccia (8 lingue) si cambia dal menu **Lingua**.



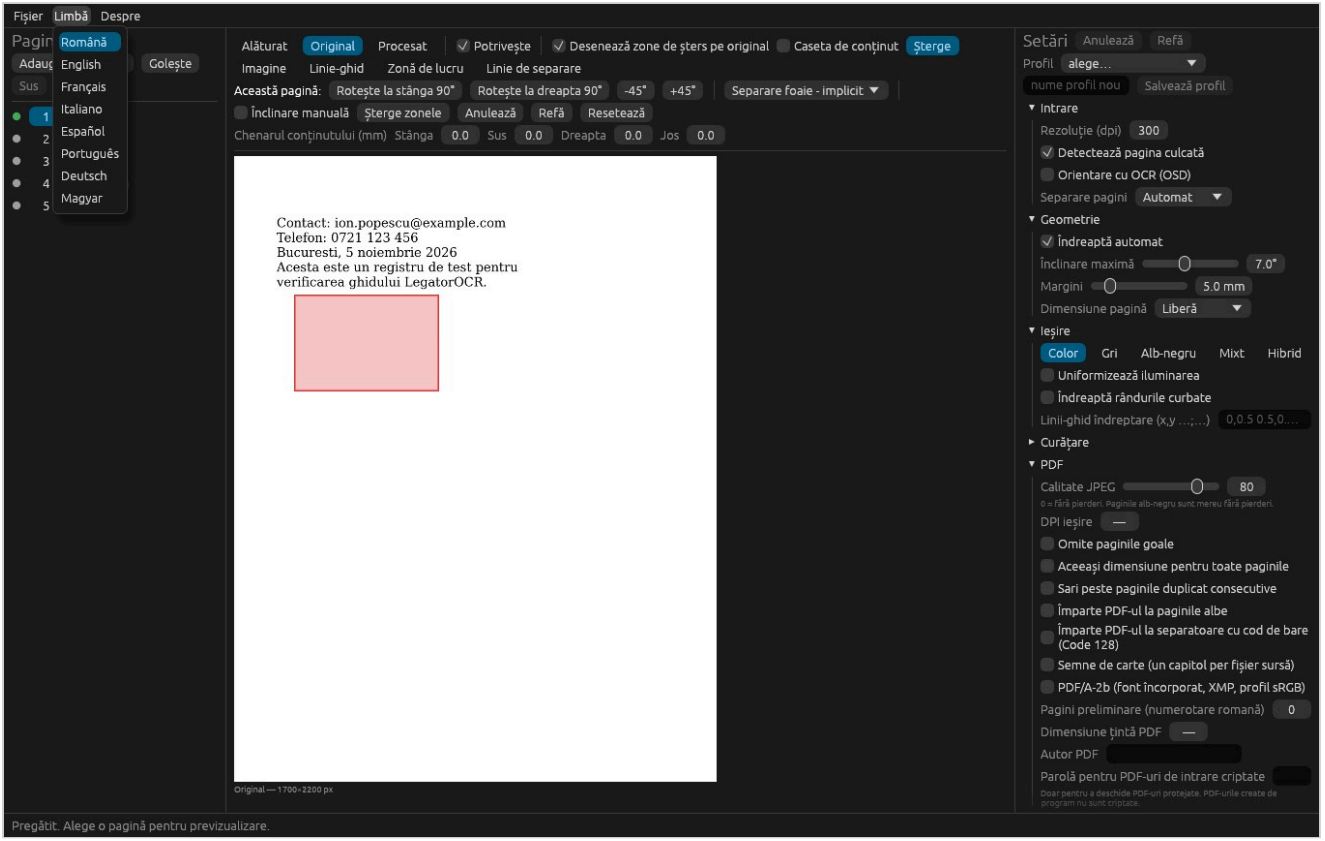
La finestra principale: l’elenco delle pagine a sinistra, l’originale e la pagina elaborata al centro, le impostazioni a destra. La pagina dell’esempio è una foto senza testo, quindi il rilevamento della pagina coricata l’ha ruotata per errore in pre.18 (corretto in pre.19, vedi sotto). Schermata pre.18 su Linux.



La stessa pagina in pre.19, con «Rileva le pagine di lato» spuntato: non viene più ruotata (elaborata 1134×1168 px, inclinazione +0,00°). Schermata pre.19 su Linux.

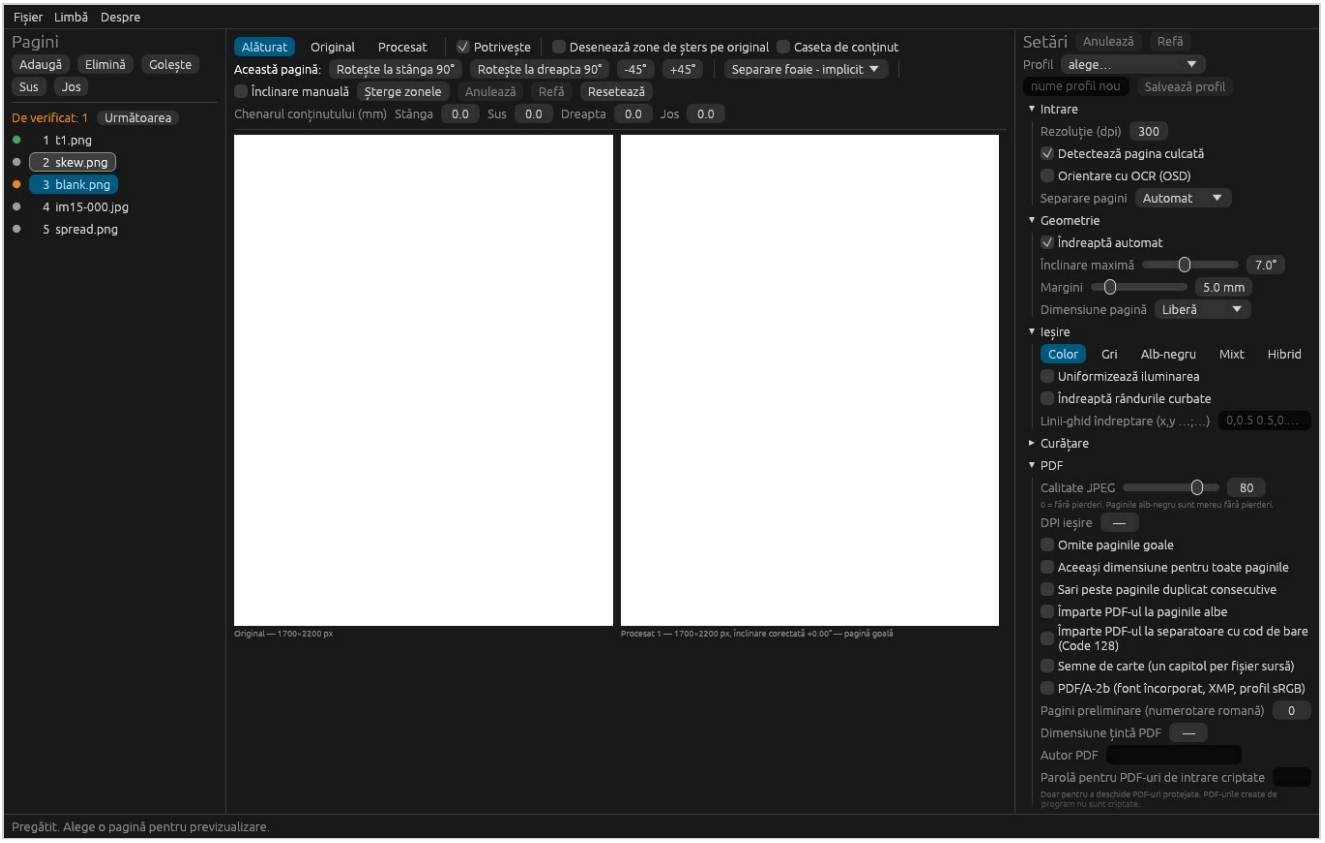


Il menu File: aggiunge immagini o una cartella, apre e salva il progetto, esporta PDF o immagini.



Il menu Lingua: le otto lingue dell’interfaccia (rumeno, inglese, francese, italiano, spagnolo, portoghese, tedesco, ungherese).

L’elenco delle pagine

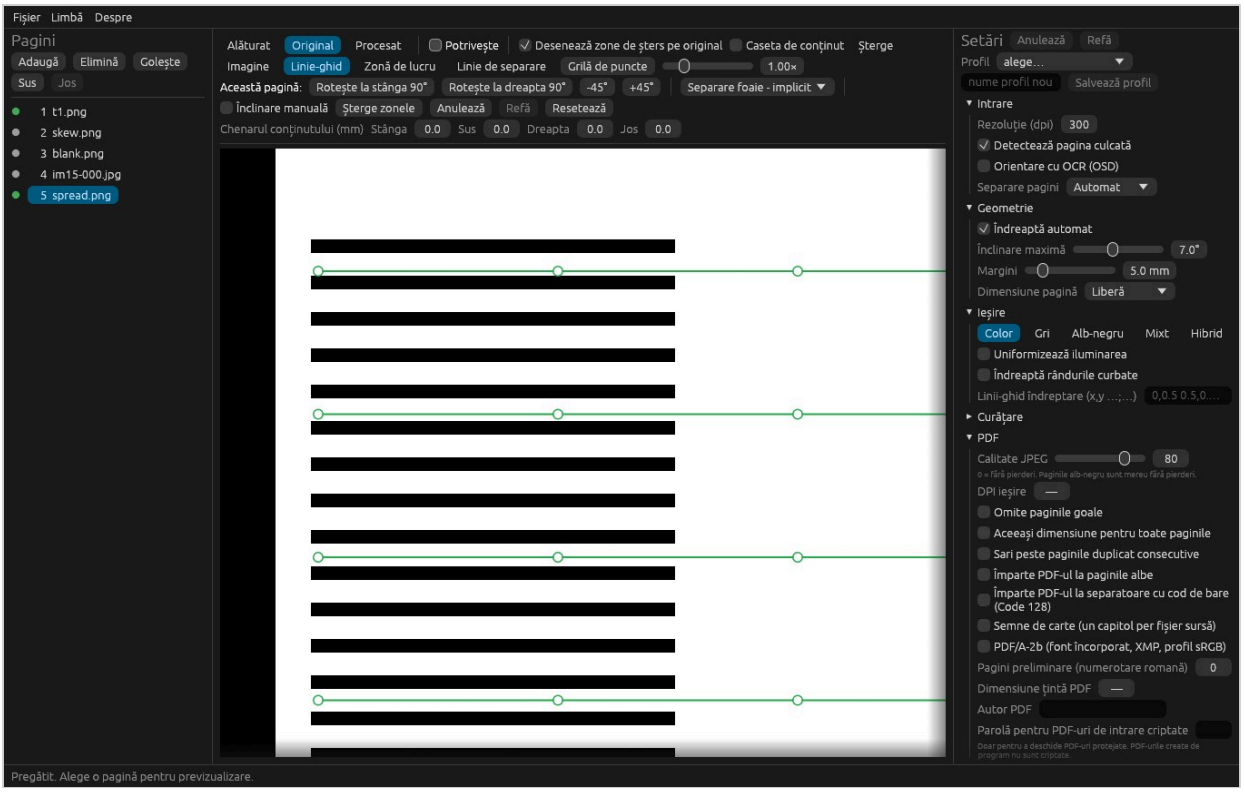


Una pagina completamente bianca viene segnalata automaticamente: punto arancione nell’elenco e pannello «Da controllare: 1» con il pulsante «Successiva».

Trascinaci dentro immagini, PDF, archivi o una cartella, oppure premi «Aggiungi». I pulsanti Su/Giù cambiano l’ordine, «Rimuovi» toglie la pagina scelta, «Svuota» toglie tutto. L’ordine dell’elenco è l’ordine nel PDF.

L’anteprima

- **Affiancati / Originale / Elaborato** sceglie che cosa vedi. Le zone si disegnano sull’*Originale*; il riquadro del contenuto si corregge sull’*Elaborato*.
- **Adatta** ingrandisce o riduce l’immagine perché entri. Il cursore dello zoom (0,2×–4×) compare solo quando *Adatta* è deselezionato.



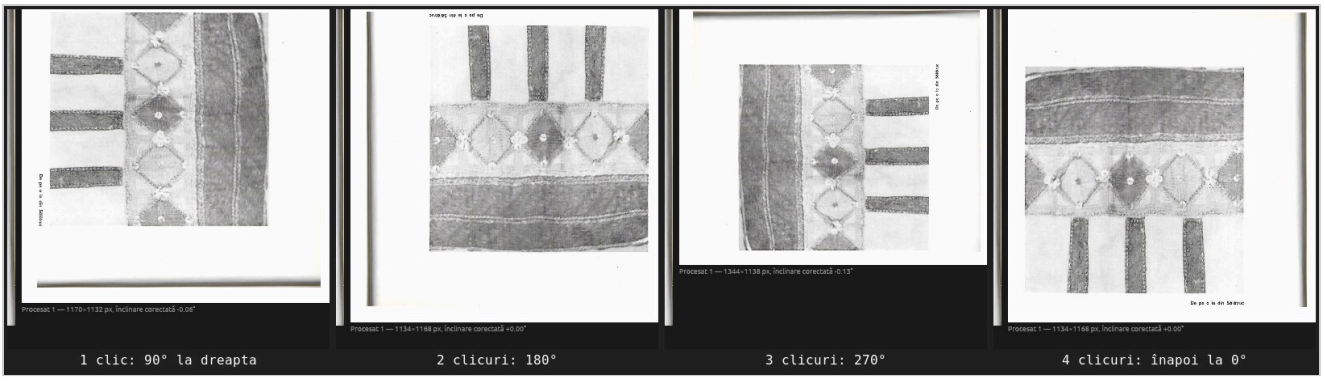
Con «Adatta» deselezionato compare il cursore dello zoom (qui 1,00×).

Miniature (da pre.58). Ogni pagina è una scheda: l'immagine piccola sopra, numero e nome sotto, e la pagina scelta ha una cornice blu attorno a entrambi. Accanto alla casella «Miniature» si sceglie la dimensione: S (120×90 px), M (240×180, predefinita) o L (320×240); se il pannello è più stretto le immagini si riducono. Le miniature vengono lette in background, solo per le pagine visibili, quindi un elenco lungo non rallenta la finestra. Deseleziona «Miniature» per l'elenco compatto a una riga per pagina.

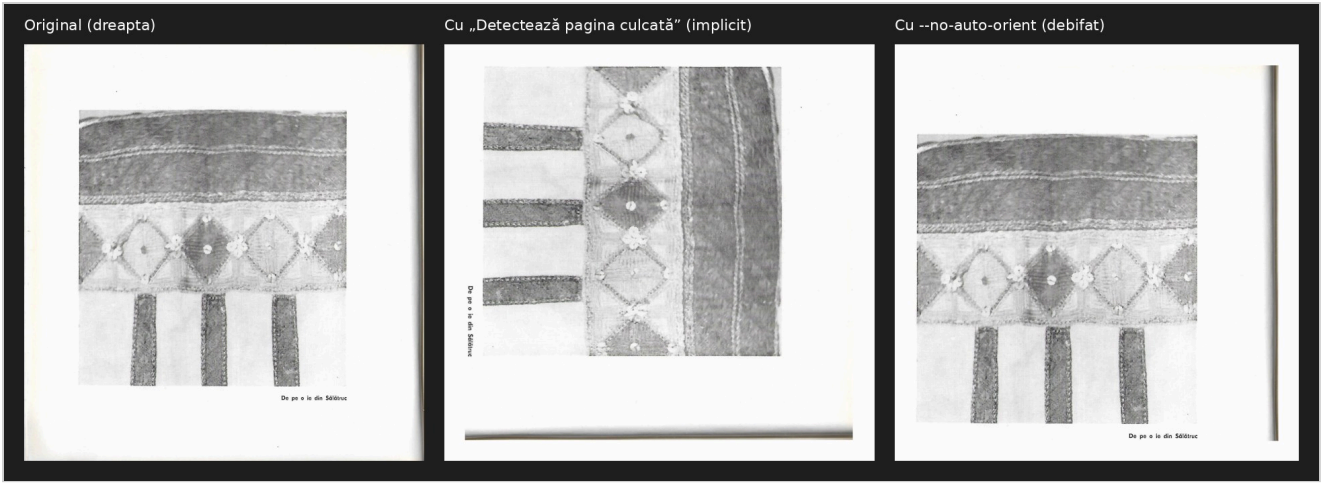
La barra «Questa pagina»

Qui correggi solo la pagina scelta: rotazione a sinistra o a destra di 90°, passi di ±45°, inclinazione manuale, la modalità di separazione del foglio (predefinita, automatica, a metà, disattivata), il riquadro del contenuto in millimetri (sinistra, alto, destra, basso; i valori positivi lo ingrandiscono) e «Ripristina». **Annulla** e **Ripeti** (Ctrl+Z, Ctrl+Y) valgono per tutti questi comandi, non solo per le zone.

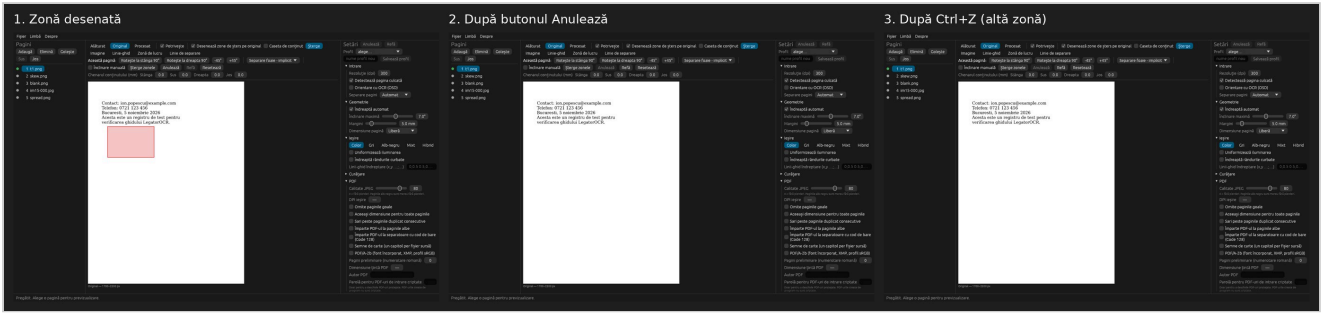
La rotazione manuale blocca l’orientamento automatico (da pre.18): dopo aver premuto un pulsante di rotazione o ±45°, la pagina non viene più ruotata dal rilevamento della pagina coricata né dall’OSD, nemmeno a 0°. «Ripristina» le restituisce l’orientamento automatico. Se una pagina con immagini è ruotata male fin dall’inizio, premi la rotazione quattro volte (oppure deseleziona «Orientamento tramite OCR (OSD)» e «Rileva le pagine di lato» nelle impostazioni, sotto Ingresso).



Quattro clic di fila su «Ruota a destra di 90°»: 90°, 180°, 270°, poi di nuovo 0°, senza salti. Schermata pre.18 su Linux. Su Windows 11 non ho potuto verificare.



La stessa pagina (pagina 15 del PDF del tester) e le stesse impostazioni, tranne il rilevamento: in pre.18, con «Rileva le pagine di lato» spuntato (predefinito), il programma la ruotava di 90° benché l’originale sia dritto (da pre.19–20 non la ruota più); con --no-auto-orient (o deselezionato nelle impostazioni) esce dritta. Verificato sulla riga di comando; nella finestra ho visto la rotazione in pre.18 e la sua assenza in pre.19.

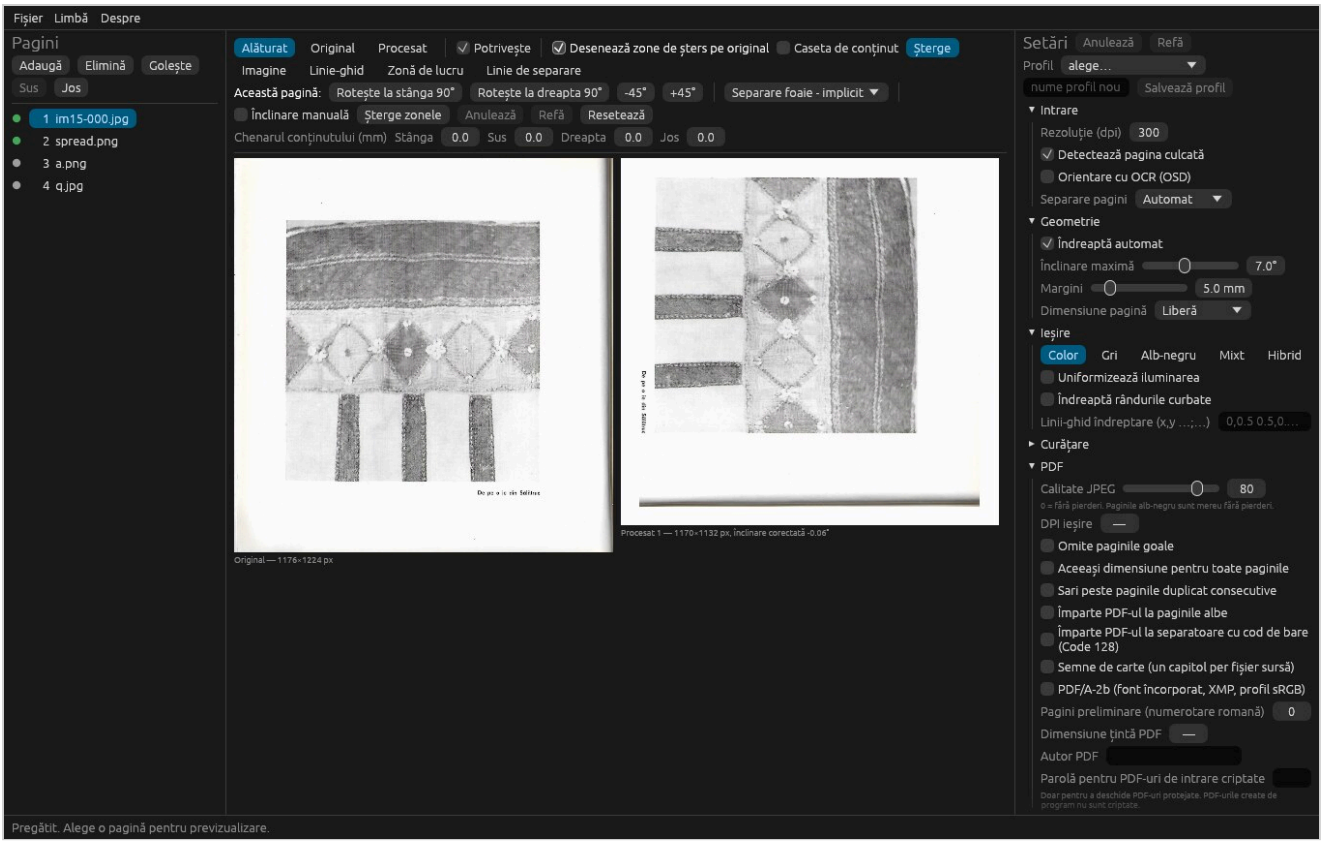


Annulla (il pulsante) e Ctrl+Z (con la finestra in primo piano) tolgono l’ultima zona disegnata. Verificato nella finestra.

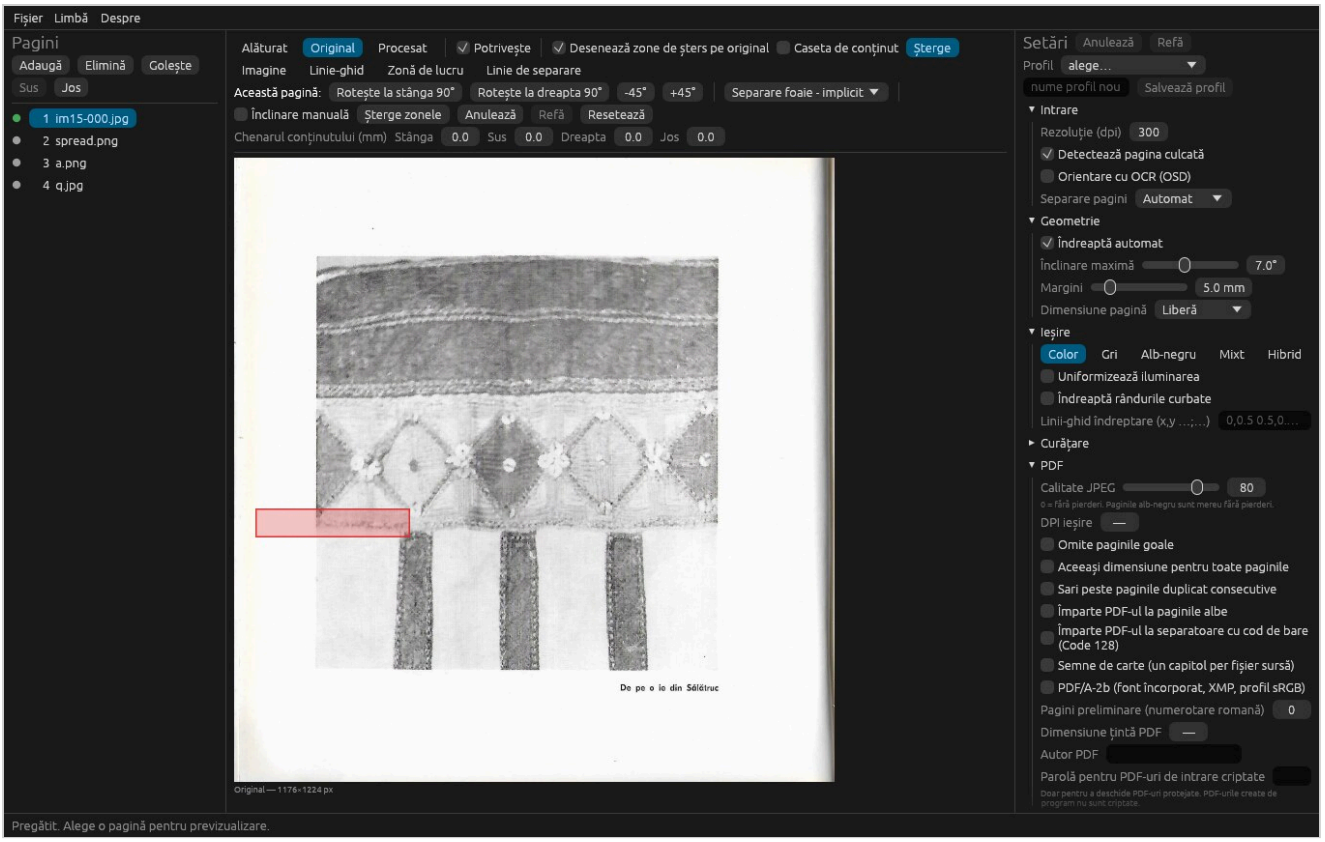
Pagine capovolte. Il pulsante «180°» ruota la pagina scelta (Ctrl+Z annulla). Inoltre, nei testi in alfabeto latino, il programma riconosce da solo le pagine capovolte, dopo il raddrizzamento: nel testo, le aste ascendenti e le maiuscole sporgono sopra la riga più delle discendenti sotto, e in una pagina capovolta l'equilibrio si inverte. Decide solo se la pagina ha almeno 12 righe e almeno il 70 % di esse «vota» allo stesso modo; altrimenti non tocca nulla. Non funziona con altri alfabeti e non tocca le pagine ruotate a mano. Verificato su pagine sintetiche e alcune fotografie; se una pagina resta capovolta, premi «180°».

Zone, guide e riquadro del contenuto

Spunta «Disegna zone da cancellare sull’originale»; compaiono cinque tipi di disegno (Cancella, Immagine, Linea guida, Area di lavoro, Linea di taglio):

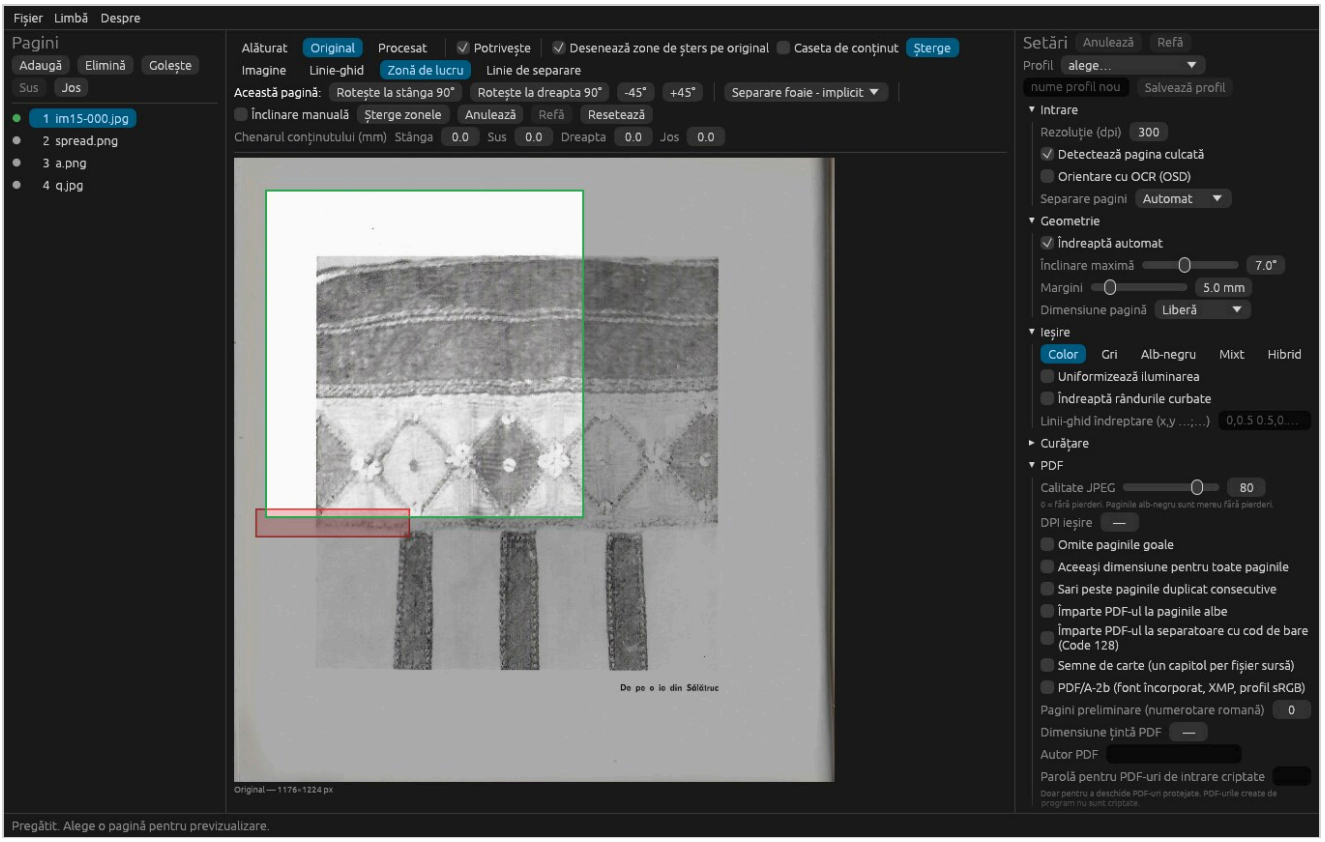


Con «Disegna zone da cancellare sull’originale» spuntato compaiono i tipi di zona: Immagine, Linea guida, Area di lavoro, Linea di taglio (e Cancella, il tipo predefinito).

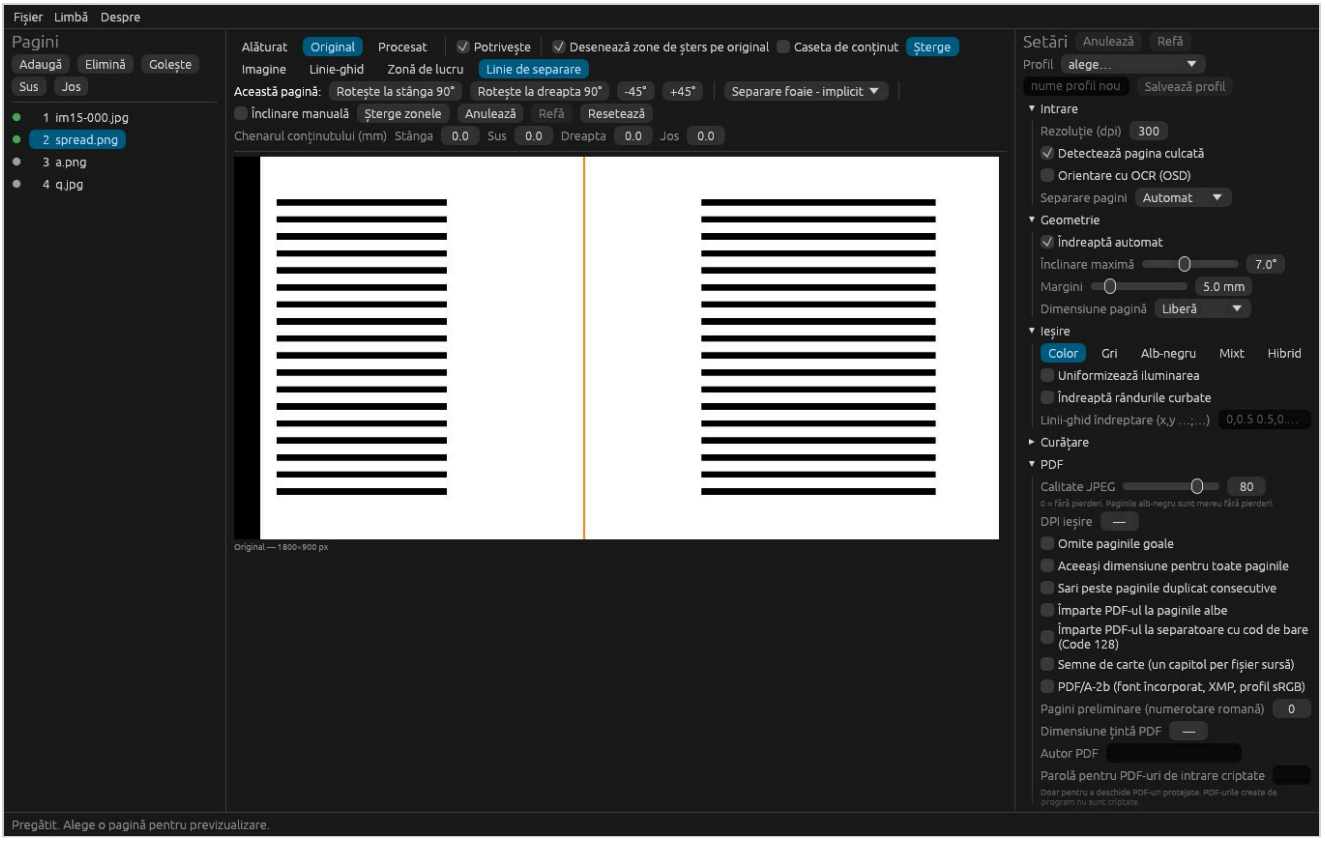


Una zona da cancellare (rossa) tracciata con il mouse sull’originale, nella vista Originale.

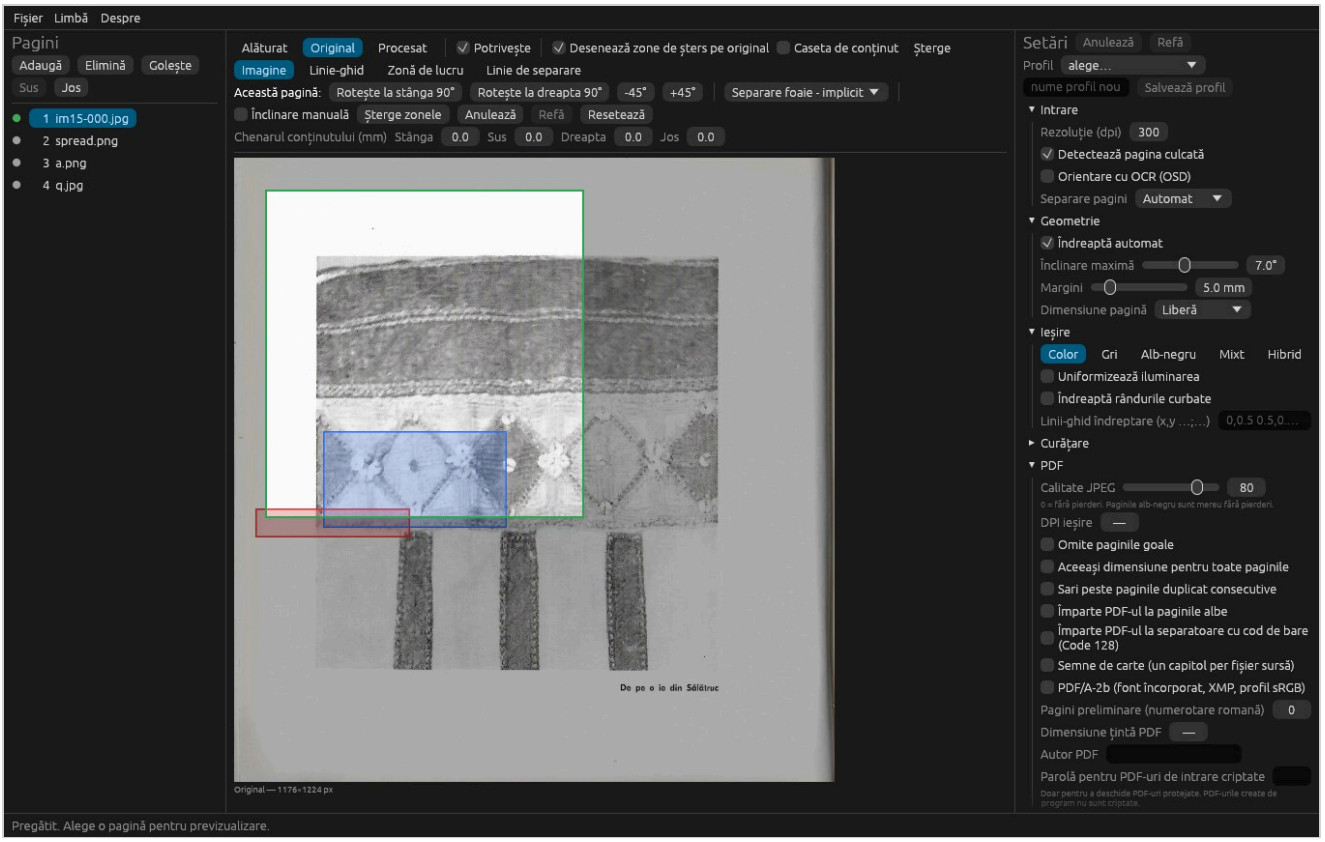
Tipo	Come si usa	A che cosa serve
Cancella	Trascini un rettangolo sull’originale. Il clic destro lo elimina. Trascini un angolo per ridimensionarlo.	Macchia, timbro, appunto di qualcuno, bordo con ombra
Immagine	Come «Cancella».	Dice al programma che la zona è un’immagine, non testo (resta a colori nella modalità mista)
Linea guida	Trascini liberamente lungo una riga curva. Trascini un nodo per spostarlo; il doppio clic sulla linea aggiunge un nodo, il doppio clic sul nodo lo elimina; il clic destro sulla linea la elimina.	Raddrizza la pagina in base alle righe che hai tracciato



L’area di lavoro (cornice verde): tutto ciò che sta fuori viene eliminato, e l’area rimasta si vede nella pagina elaborata. C’è anche una zona da cancellare (rossa).



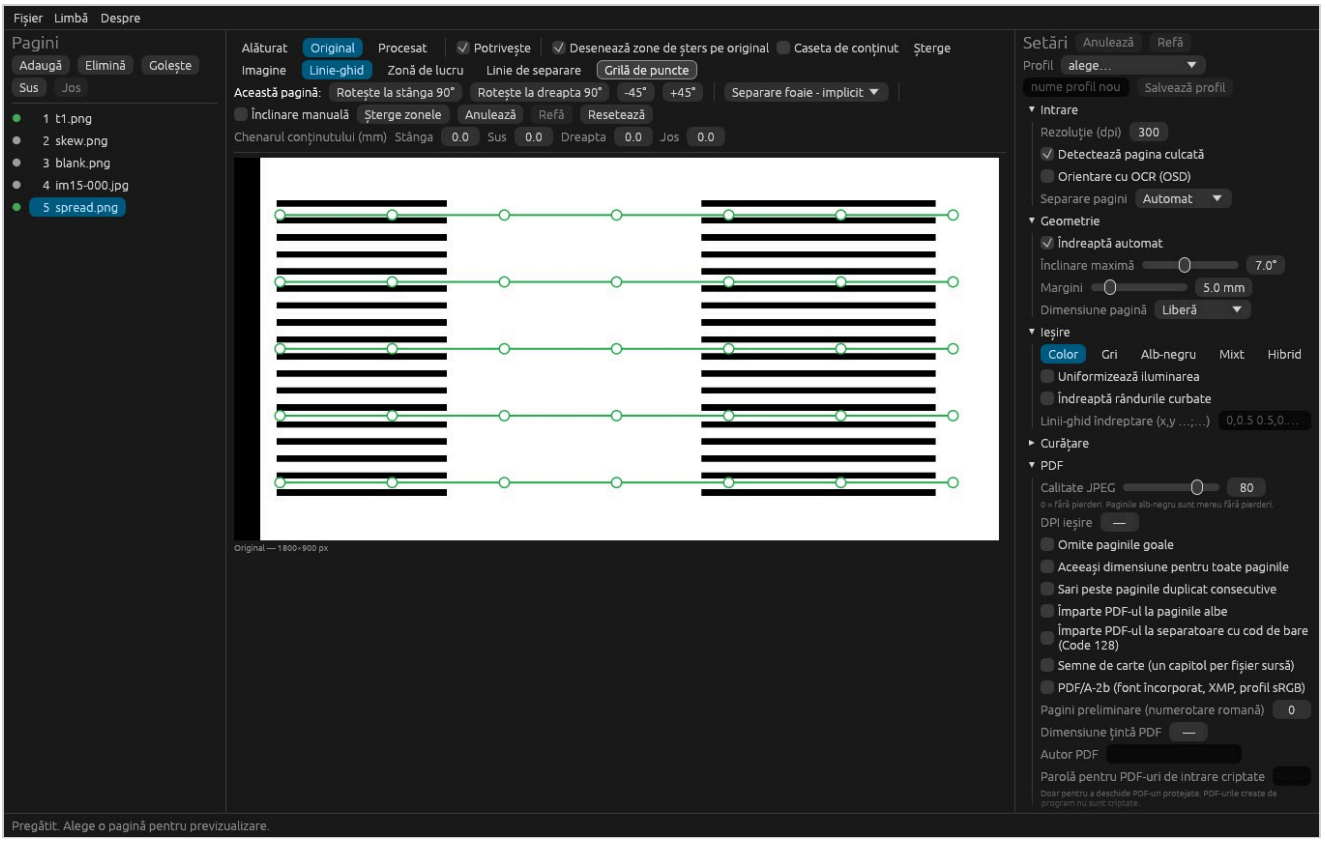
La linea di taglio (arancione) spostata con il mouse su un foglio doppio. L’esempio è un foglio di prova sintetico, con linee al posto del testo.



Una zona immagine (blu) disegnata sull’originale. Nella modalità Colore non cambia nulla; l’effetto si vede nella modalità Misto (figura seguente).



La stessa pagina e la stessa zona immagine (blu): nella modalità Misto la zona resta grigia (a sinistra), nella modalità Bianco e nero tutto diventa bianco e nero (a destra). La pagina appare ruotata di 90° dal rilevamento della pagina coricata (vedi sopra).



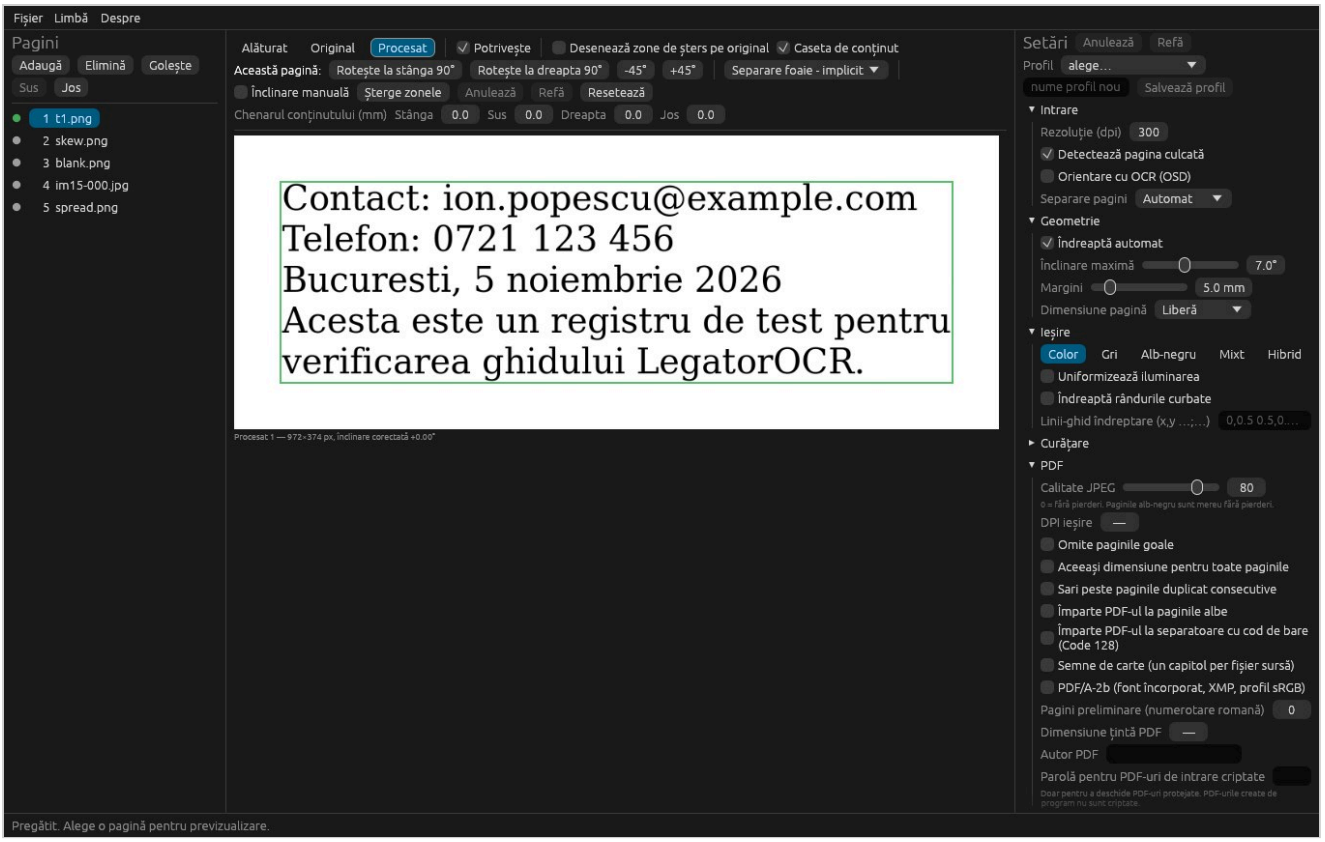
«Griglia di punti» in Linea guida: 5 linee di 7 punti ciascuna, sopra le righe di testo.

Griglia di punti (in *Linea guida*) aggiunge 5 linee di 7 punti ciascuna, sulle quali trascini i punti lungo le righe di testo. Un secondo clic sul pulsante non aggiunge di nuovo la stessa griglia. Se hai già spostato dei punti, una nuova griglia viene aggiunta accanto a quella spostata.

Area di lavoro (dall'edizione pre.18): trascini un rettangolo sull'originale; tutto ciò che sta fuori viene dipinto con il colore della carta prima di qualsiasi misurazione, quindi un bordo scuro o la pagina vicina non contano più. Il clic destro sull'originale la elimina. Sulla riga di comando: `--work-area X,Y,L,H` (millimetri).

Linea di taglio (dall'edizione pre.18): con un clic o trascinando sull'originale sposti la linea verticale arancione; il foglio doppio viene tagliato lì, non a metà né sul dorso. Da pre.21 funziona con qualsiasi rotazione; nei fogli ruotati di 90° o 270° la linea taglia in orizzontale e le pagine escono una sotto l'altra (prima la pagina di sinistra dell'originale). Il clic destro la elimina. Sulla riga di comando: `--cut-at 0.45`.

Riquadro del contenuto (la casella con lo stesso nome) mostra sulla pagina elaborata un riquadro verde. Trascini i lati per allargare o restringere l'area mantenuta. In un foglio tagliato in due pagine, cambia solo la pagina su cui si trascina la cornice.



Il riquadro del contenuto (cornice verde) sulla pagina elaborata.

Pagine storte, taglio obliquo e impostazioni per pagina

Tre strumenti per i fogli fotografati a mano:

- **Linea di taglio obliqua.** Con «Disegna zone di cancellazione sull'originale» e il tipo Linea di taglio, il cursore «Inclinazione della linea» (da −20° a 20°) inclina la linea; ogni pagina tiene il suo lato della linea obliqua e l'altro lato è dipinto col colore della carta. Clic destro sulla linea: la elimina e azzera l'inclinazione. Da riga di comando: `--cut-angle GRADI`.
- **Correzione trapezoidale.** Due cursori nella barra «Questa pagina» («Trapezio alto–basso», «Trapezio sinistra–destra», ±30 %) raddrizzano prima del taglio un foglio fotografato di sbieco. Il pulsante **Trapezio auto** (dopo la divisione delle pagine) misura ogni pagina — inclinazione delle righe di testo e larghezza del testo in alto e in basso — e conserva una correzione solo per quella pagina. È prudente di proposito: se le righe sono troppo poche o le misure si contraddicono, lascia la pagina com'è. Controlla il risultato, con Annulla a portata di mano. I pulsanti −45°/+45° restano. Da riga di comando: `--keystone-v` e `--keystone-h` (percentuali).
- **Impostazioni per pagina.** «Impostazioni per: Tutte le pagine / Solo questa pagina», sopra Uscita e Pulizia, applica modalità di uscita, soglia, eliminazione dei puntini e le altre impostazioni di pulizia a una sola pagina di un foglio tagliato; la cornice verde del contenuto cambia solo la pagina su cui viene trascinata. In un progetto: `page1.CHIAVE = VALORE` / `page2.CHIAVE = VALORE` sotto [sheet]. Un clic su una pagina elaborata la seleziona (cornice blu): modalità di uscita (grigio, bianco e nero, misto), pulizia, correzione trapezoidale, riquadro verde e matite OCR agiscono poi solo su di essa. Le zone OCR disegnate restano con quella pagina (`page1.page_ocr_zones`, `page_ocr_ignore`).

La barra sotto l’anteprima contiene il riquadro del contenuto, le matite OCR e l’**Auto-matita OCR** (separata per la pagina sinistra e destra): imposta la zona OCR sul contenuto di quella pagina.

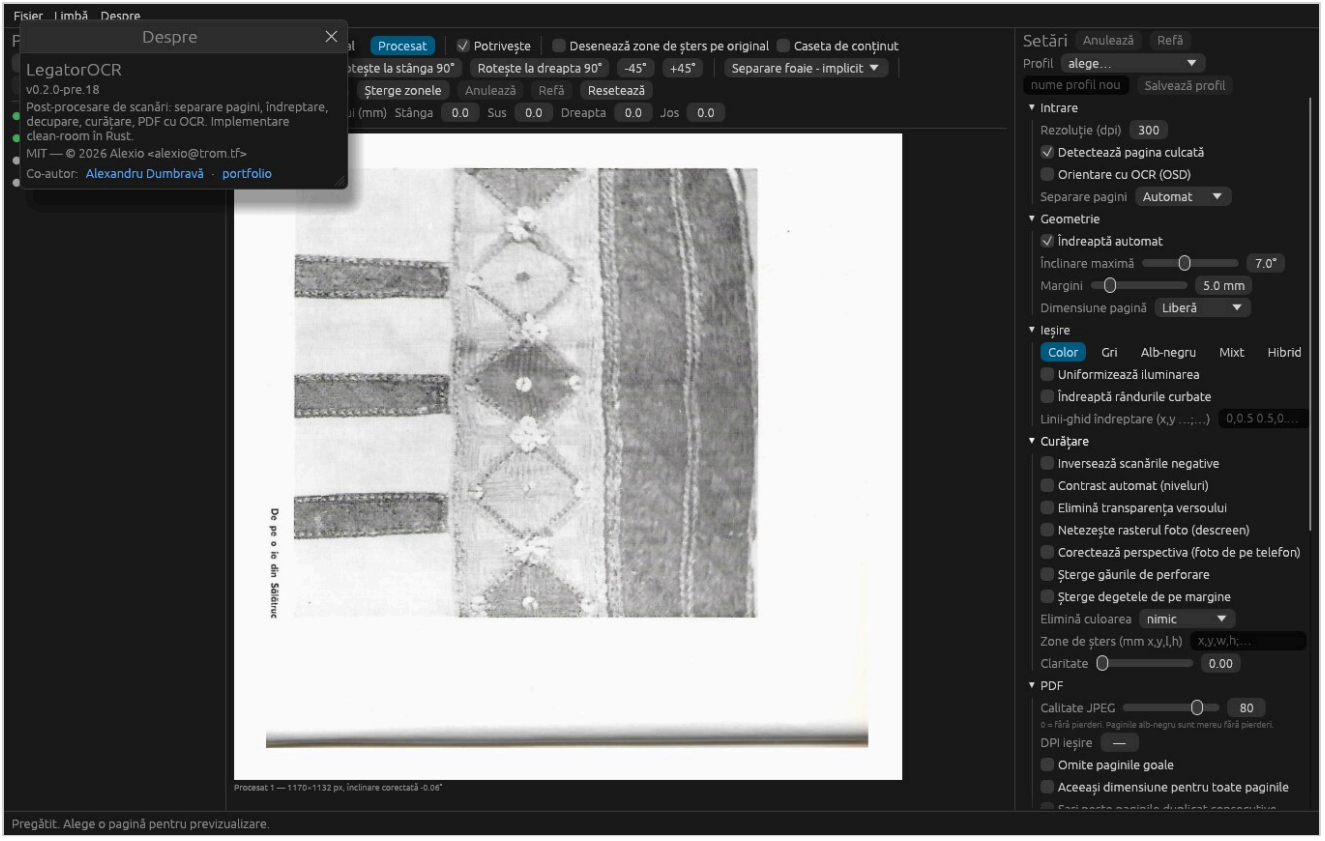
L’inclinazione manuale agisce sulla pagina selezionata (sinistra o destra) di un foglio tagliato: ogni pagina può avere il proprio angolo (`page1.page_skew`, `page2.page_skew`).

Zoom: nella barra in basso, **A+** / **A-** ingrandiscono o riducono tutta l’interfaccia (anche Ctrl + / Ctrl −) e **Auto** la adatta alla dimensione della finestra. La finestra parte ingrandita con zoom automatico, così il testo è grande e riempie lo schermo; la scelta viene conservata.

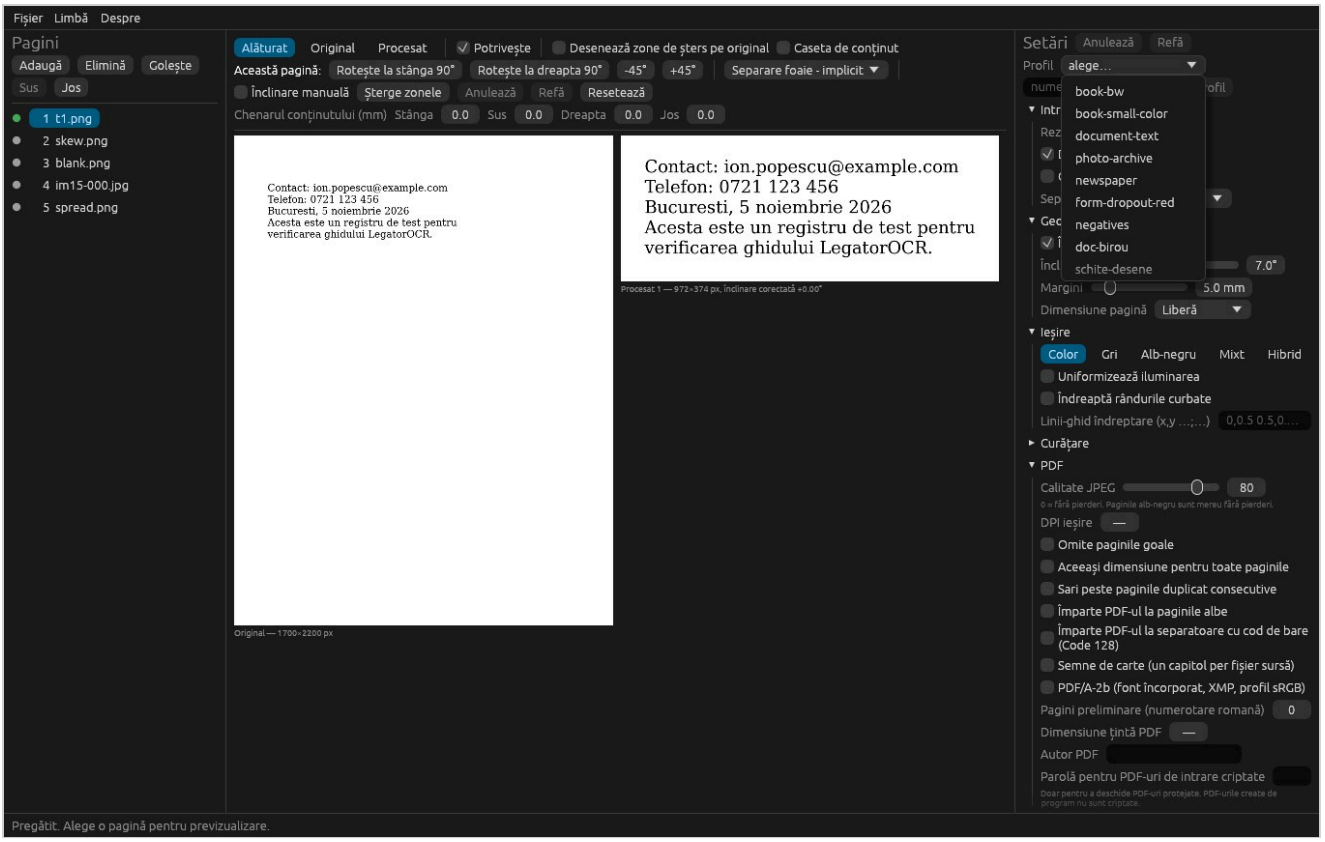
I formati di pagina comprendono ora A2–A6, B3–B6, Letter, Legal e Tabloid (`--page-size` accetta gli stessi nomi). Matite OCR sulle pagine elaborate: verde (zona OCR), rosso (zona ignorata), viola (tabella, letta come un blocco riga per riga; `--ocr-zone X,Y,W,H#table`).

Le impostazioni a destra

Sono raggruppate per sezioni: Ingresso, Geometria, Uscita, Pulizia, PDF, OCR, più i profili. La sezione 6 spiega che cosa fa ciascuna.



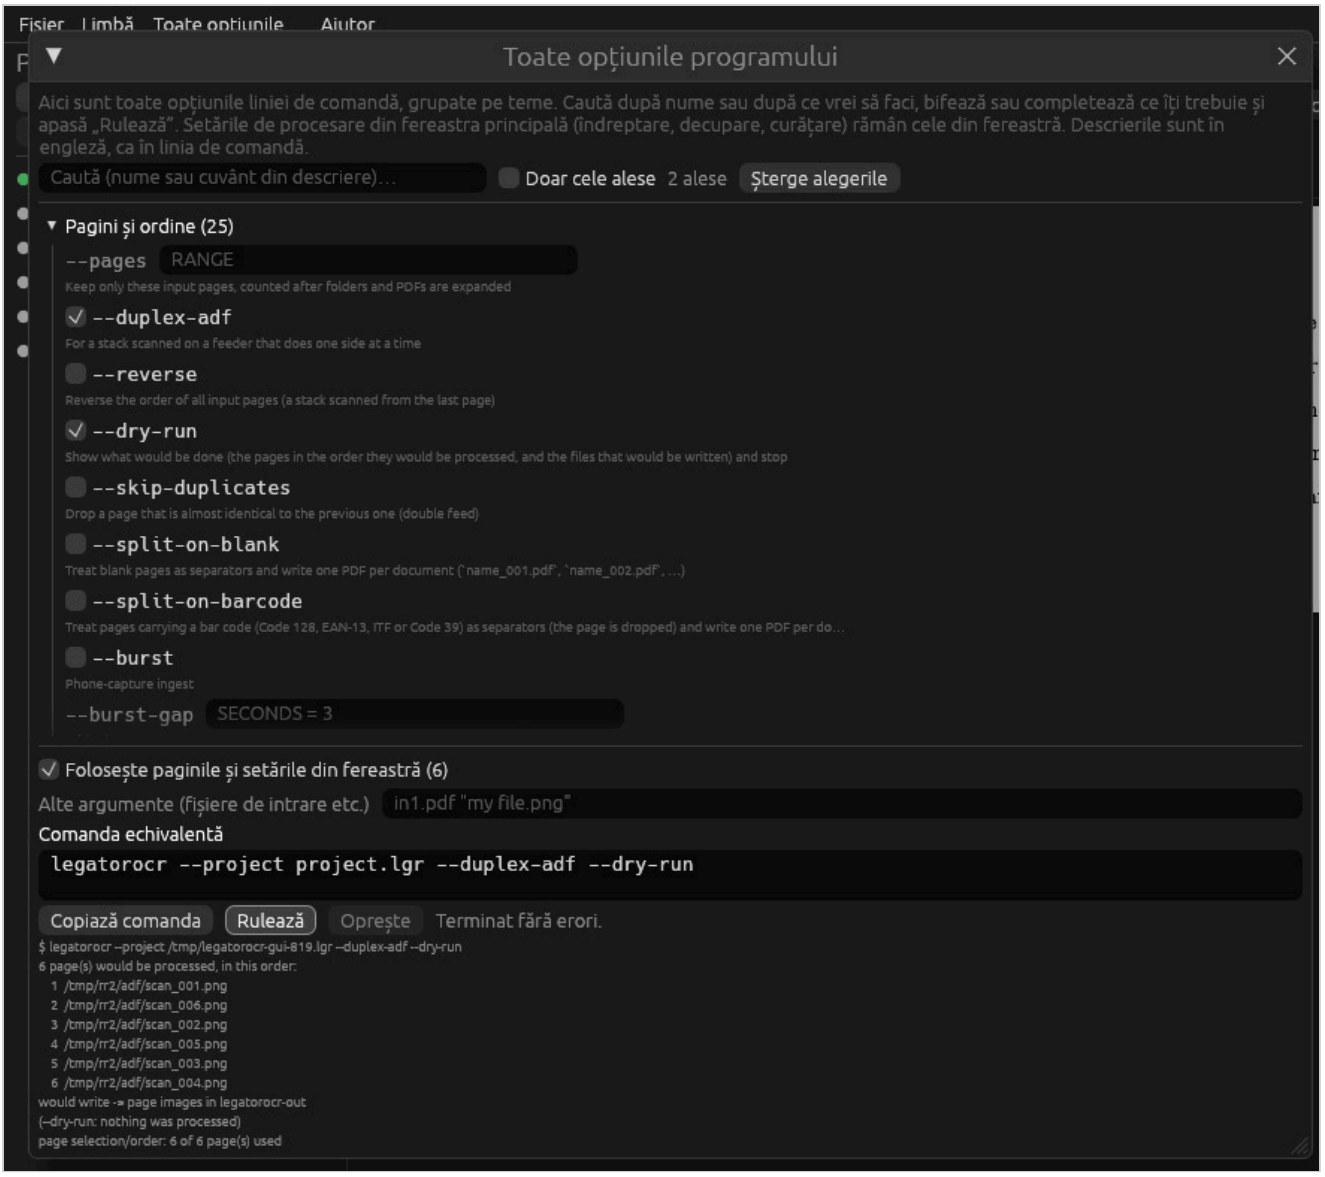
La sezione Pulizia delle impostazioni, aperta: inversione delle scansioni negative, contrasto automatico, prospettiva, rimozione dei fori di perforazione, zone da cancellare come numeri.



L’elenco «Profilo» nelle impostazioni (i profili integrati; i tuoi compaiono nello stesso posto dopo «Salva profilo»).

Tutte le opzioni e la guida all’uso

Il pulsante **Tutte le opzioni…** nella barra in alto apre una finestra con **tutte** le opzioni della riga di comando (oltre 200), raggruppate per tema: pagine e ordine; raddrizzamento, ritaglio e pulizia; uscite (PDF, immagini, documenti); OCR e testo; archiviazione, firma e verifica; ricerca e confronto; lotti, sistema e moduli. L’elenco viene letto direttamente dal programma a riga di comando fornito insieme alla finestra, quindi corrisponde sempre all’edizione che hai.



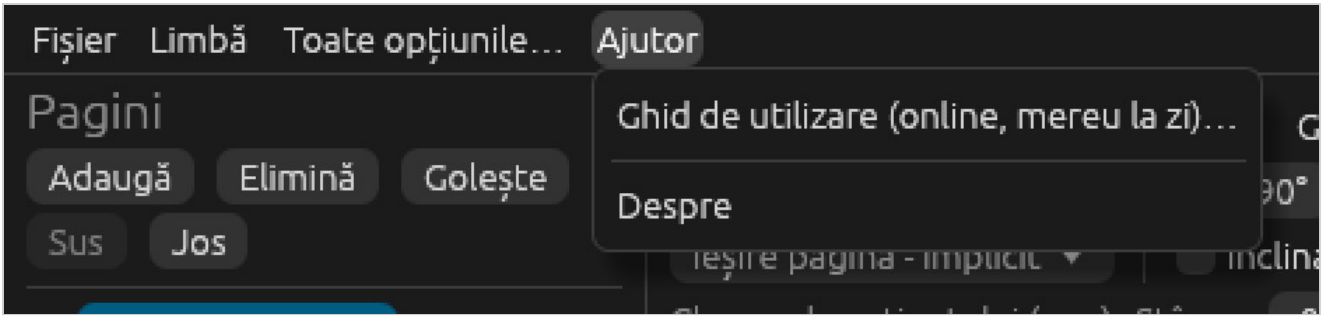
La finestra «Tutte le opzioni», con il gruppo «Pagine e ordine» aperto, `--duplex-adf` e `--dry-run` spuntati e il risultato dell'esecuzione: l'ordine in cui verrebbero elaborate le sei pagine della pila (pagine di prova fatte da me).

- **Cerca** per nome (`pdf`, `dry`) o per una parola della descrizione; i gruppi con risultati si aprono da soli. «Solo quelle scelte» mostra ciò che hai spuntato o compilato.
- Le caselle vuote non vengono inviate: un'opzione con valore entra nel comando solo quando scrivi qualcosa (o scegli dall'elenco). Il pulsante **Scegli…** apre la finestra di dialogo dei file o delle cartelle. Per le opzioni che si possono ripetere (per esempio `--erase`) scrivi un valore per riga.
- **Usa le pagine e le impostazioni della finestra** (spuntato in modo predefinito): il comando riceve le pagine caricate, con le regolazioni di ciascuna, tramite un progetto temporaneo. Le impostazioni di elaborazione della finestra principale (raddrizzamento, ritaglio, pulizia) hanno la priorità; qui completi le uscite e le funzioni speciali. Deseleziona per i comandi senza pagine (`--doctor`, `--verify-sums`) oppure scrivi i file di ingresso in «Altri argomenti».
- **Il comando equivalente** si aggiorna mentre scegli; puoi copiarlo e usarlo nel terminale o negli script. **Esegui** lo esegue e mostra il risultato sotto; **Ferma** lo interrompe. I percorsi

relativi sono rispetto alla tua cartella personale.

- Le descrizioni delle opzioni sono in inglese, come nella riga di comando; il resto della finestra è nella lingua scelta.

Il menu **Aiuto** ha il collegamento a questa guida: *Guida all'uso (online, sempre aggiornata)* apre l'ultima versione pubblicata su legatorocr.chiuta.ro, mentre *Guida di questa edizione* (compare quando il file PDF si trova accanto al programma, come negli archivi pubblicati) apre la copia fornita insieme al programma. La guida viene rifatta a ogni edizione, e la pubblicazione di un'edizione si ferma se la guida non ne cita la versione.



Verificato: la finestra, la ricerca, la spunta, l'esecuzione di un comando con le pagine della finestra (la schermata qui sopra) e l'apertura del menu Aiuto, su Linux, in uno schermo virtuale. Non verificato: Windows, macOS e arm64; l'apertura effettiva della guida in un browser (ho verificato solo il menu); le finestre di dialogo «Scegli…»; le traduzioni dei nuovi testi della finestra (scritte automaticamente).

Collezioni

Una collezione raccoglie giornali, riviste, libri e simili in un solo file `.lgrcol` (JSON). Tenetelo nella cartella con le scansioni: i percorsi nel file sono scritti relativi ad esso quando la destinazione sta sotto una cartella comune, quindi la cartella si può spostare o copiare. Ogni elemento ha tipo, titolo, numero o volume, data o anno, lingue, sorgenti (immagini, una cartella di immagini, un PDF, un progetto `.lgr` salvato), il PDF ottenuto, un profilo, uno stato (da fare, elaborato, OCR fatto, verificato), numero di pagine, etichette e note.

```
legatorocr collection new Archive/ --name "Old papers"
legatorocr collection add Archive/old_papers.lgrcol --folder Archive/scans
legatorocr collection list Archive/old_papers.lgrcol
legatorocr collection run Archive/old_papers.lgrcol --out Archive/pdf
legatorocr collection search Archive/old_papers.lgrcol "Scînteia"
legatorocr collection reindex Archive/old_papers.lgrcol
legatorocr collection set Archive/old_papers.lgrcol i1 --status checked --tags "1977, youth"
legatorocr collection remove Archive/old_papers.lgrcol i2
```

- `add --folder`: ogni PDF, progetto `.lgr` e sottocartella di immagini diventa un elemento. Titolo, tipo, data e numero sono dedotti dal nome: `scinteia_tineretului_1977_09_8801.pdf` dà un giornale, «Scinteia Tineretului», 1977-09, n. 8801. È solo un'ipotesi (i nomi dei file non hanno diacritici; il tipo si basa su poche parole chiave e sulla numerazione: una data completa o un numero di 500 o più è preso per un giornale); correggetela nella finestra. Per `nome_anno_mese_numero` un numero di tre o più cifre è il numero dell'edizione (`..._1977_09_8801`); un numero di una o due cifre subito dopo il mese è un giorno solo se è un giorno reale di quel mese e, quando è l'ultima parte, il nome non dice rivista o libro

(`gazeta_1914_05_12` è il 12 maggio, `revista_sinteza_1985_03_12` è il numero 12, `..._1977_09_12_8801` è il giorno 12, numero 8801).

- `run` elabora gli elementi nello stato «da fare», ciascuno con il proprio profilo (altrimenti quello della collezione, altrimenti le impostazioni predefinite), con lo stesso codice della riga di comando e della finestra (`run_export`). Un elemento che fallisce (sorgente mancante, profilo sconosciuto, pagina illeggibile) viene segnato con il motivo e gli altri proseguono; il file della collezione e l'indice sono salvati dopo ogni elemento, quindi un'annullamento o un arresto anomalo non perde il già fatto. I PDF vanno accanto al file della collezione o in `--out`. Con l'OCR (attivo per default; `--no-ocr` lo spegne) il testo riconosciuto di ogni pagina va in `NOME.lgrindex`; la lingua dell'OCR viene dalle lingue dell'elemento, altrimenti da `ocr_langs` del profilo, altrimenti il rumeno. Un elemento fallito non viene ritentato se non con `--retry-failed` o `--item ID`.

- `search` cerca in questo indice. Maiuscole, diacritici e vecchia ortografia rumena non contano (`Scînteia` trova `Scânteia`, `sînt` trova `sunt`). Stampa elemento, pagina e un frammento: prima le pagine con le parole vicine, poi (segnate) le pagine che hanno tutte le parole ma separate.

- `reindex` (alias `index`) legge lo strato di testo dei PDF nello stesso indice **senza rielaborare nulla**: per un elemento la cui sorgente è un solo PDF che ha già testo (PDF ricercabili di un altro programma, o fatti da LegatorOCR) e per gli elementi elaborati prima. Legge il PDF fatto da `run` se c'è, altrimenti l'unica sorgente PDF dell'elemento; lo stato e i file dell'elemento non cambiano. Una scansione senza testo è segnalata (`no text layer`) e non indicizzata (elaboratela con l'OCR); un elemento con più sorgenti, o solo immagini, non ha un PDF da leggere. `--item ID` lo restringe. Il testo è preso come lo ha il PDF (font con tabella ToUnicode, come li scrivono LegatorOCR, Tesseract, ABBYY, Word …); un PDF il cui testo non si può decodificare non dà nulla o dà testo senza senso.

- `set FILE ELEMENTO` cambia `--title --issue --date --kind --profile --status --tags --notes` (solo quelli dati; un testo vuoto cancella il campo; un valore errato non cambia nulla; `--status todo` fa sì che il prossimo `run` rielabori l'elemento). `remove FILE ELEMENTO...` toglie elementi dalla collezione e dall'indice; i loro PDF e file sorgente non vengono toccati.

- La finestra **Collezioni…** (menu File, o Ctrl+K): una tabella con lettera del tipo, titolo, numero/data, pagine e un'etichetta di stato (colore e testo), con filtro e ordinamento; i dettagli a destra; Aggiungi file, Aggiungi cartella, Elabora selezione, Elabora tutto ciò che attende (con avanzamento e Annulla), Indicizza il testo / Indicizza tutto (il `reindex` di sopra), Apri PDF, Mostra cartella; una casella di ricerca in tutta la collezione con risultati cliccabili. Il doppio clic su un risultato apre il PDF a quella pagina quando il programma PDF predefinito del computer è uno che si sa rispetta il numero di pagina (Linux: Okular, Evince, Zathura, MuPDF, Firefox, Chrome, Chromium, Edge; Windows: SumatraPDF, Adobe Acrobat/Reader, Chrome, Edge, Firefox; trovato chiedendo al sistema quale programma apre i PDF); altrimenti il PDF si apre normalmente e il numero di pagina è scritto nella riga di stato. L'elaborazione dalla finestra usa il Tesseract impostato nelle impostazioni della finestra principale (il profilo di un elemento può comunque indicarne un altro). I suoi testi esistono nelle 8 lingue della finestra.

Verificato: test unitari (indovinare il nome, compresi gli schemi anno-mese-numero, percorsi relativi, file danneggiati, ricerca con diacritici, un lotto che prosegue dopo un errore e dopo un panic, annullamento, il file indice con e senza la sua cache, file indice del formato vecchio, un indice troncato o danneggiato, reindicizzazione di un PDF con e senza testo, `set` e `remove`, i

comandi del lettore di ogni piattaforma), test del programma reale e una prova con Tesseract reale su due pagine sintetiche, anche dopo lo spostamento della cartella. **Misurato** su un indice sintetico di 5000 elementi × 20 pagine (100.000 pagine di 350 parole, file di testo da 357 MB; build release su una macchina condivisa a 2 core, quindi solo ordini di grandezza): l'apertura richiede 62 ms con la cache degli elenchi di parole (38 MB) e 12 s senza (prima apertura, o file modificato da un altro programma); 82 MB di memoria dopo l'apertura (il vecchio indice, tenuto intero in memoria: 34 s e circa 480 MB); una ricerca di una parola 40–130 ms, di due parole molto frequenti mai affiancate 3 s.

Limiti: la finestra è stata scritta e compilata, ma nessuno l'ha vista sullo schermo né ci ha cliccato, quindi i suoi nuovi pulsanti, la riga di stato e l'apertura a una pagina non sono stati provati; i comandi del lettore sono testati solo come testo, mai eseguiti con Okular, Acrobat o gli altri; su macOS e con qualsiasi altro programma PDF la pagina non viene passata, solo mostrata nella riga di stato; la pagina di un risultato è quella del PDF letto (per un elemento elaborato, il PDF fatto da `run`), quindi dopo aver sostituito quel PDF con uno con altre pagine eseguite `reindex`; `reindex` non fa OCR e non può leggere testo che un PDF non decodifica; l'indice viene riscritto per intero a ogni salvataggio (circa 2 s per 357 MB), quindi modificarne uno molto grande è più lento che uno piccolo; due programmi che scrivono gli stessi file contemporaneamente: vince l'ultimo; la regola dell'ortografia antica è quella di `--ocr-modern-spelling` e può unire parole diverse (`mână` / `mină`).

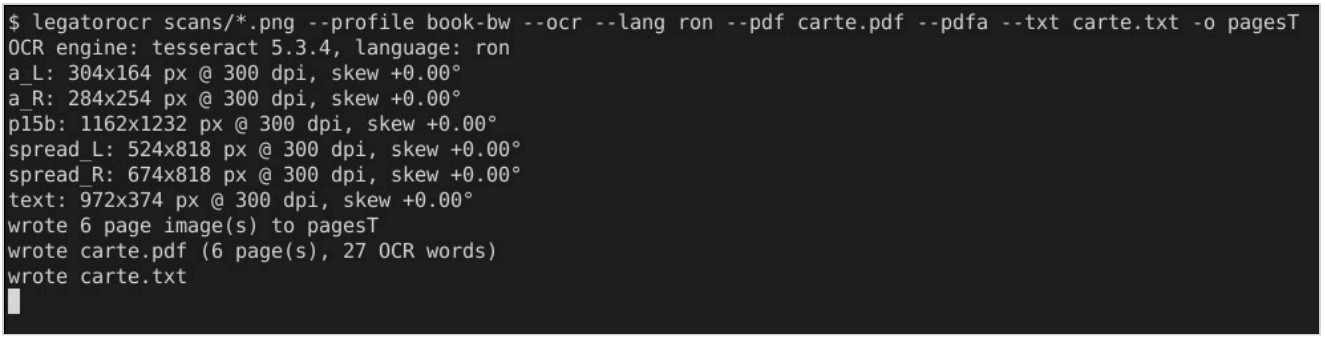
5. La riga di comando: ricette per i compiti frequenti

Sintassi generale: `legatorocr INTRARI... [opțiuni]`. Gli ingressi possono essere immagini (PNG, JPEG, TIFF, BMP), PDF scansionati o una cartella. `legatorocr --help` elenca tutte le opzioni; `--list-profiles` mostra i profili. Le opzioni delle ricette vengono controllate automaticamente prima di ogni edizione, quindi esistono davvero; le ricette in sé non sono state provate tutte su materiale reale.

Libro scansionato → PDF con testo ricercabile

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

`--pdfa` scrive PDF/A-2b per l’archiviazione, e `--txt` salva anche il testo. `-o pages` è la cartella per le immagini elaborate.

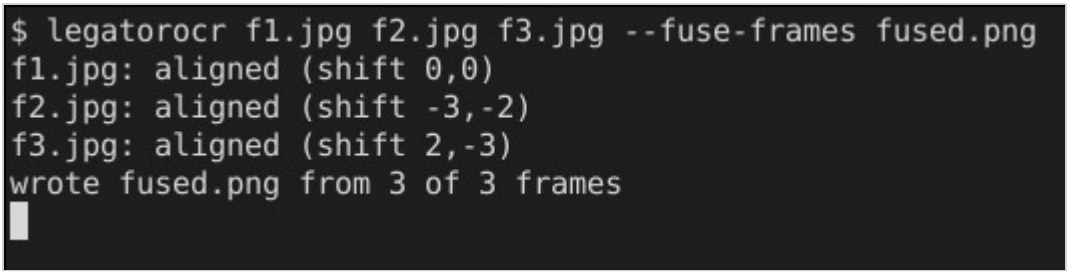


La ricetta su 4 file di prova: 6 pagine in carte.pdf. Con --pdfa il programma scrive PDF/A-2b.

Foto da telefono → pagine pulite

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

Il profilo uniforma la luce, corregge la prospettiva, cancella lo sfondo attorno alla pagina (`--trim-background`), taglia a metà i libri aperti, allarga l'intervallo di inclinazione e toglie le dita senza toccare il testo. Una pagina che esce senza testo viene letta una seconda volta solo sul suo contenuto. Per pagine uniformi su A4, con il testo ingrandito, usa `--profile phone-photos-a4`. Più foto della stessa pagina si possono combinare prima con `--fuse-frames` (aiuta con rumore forte; con rumore moderato no). L'opzione riceve un file di uscita: legatorocr foto1.jpg foto2.jpg foto3.jpg --fuse-frames pagina.png, poi elabori pagina.png come al solito; la prima foto è il riferimento.

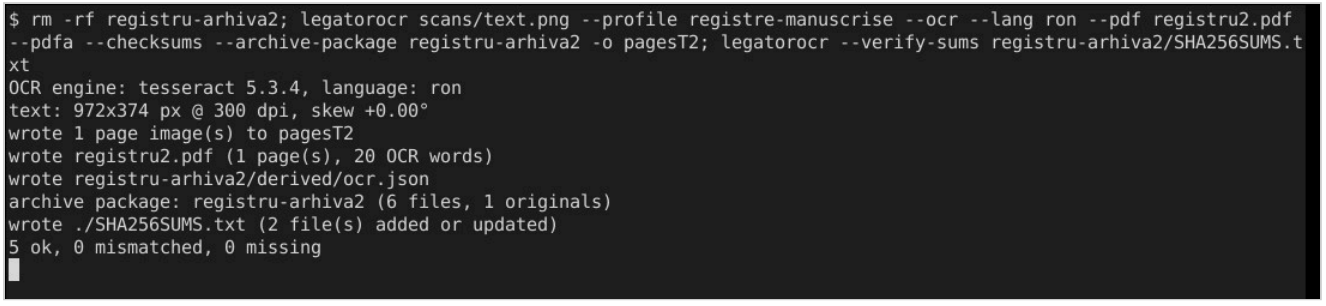


--fuse-frames con tre foto della stessa pagina: le allinea e scrive fused.png da 3 fotogrammi su 3.

Copia d'archivio con prova di integrità

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

Il pacchetto conserva gli originali, il progetto, le parole OCR con la confidenza, le uscite e un `RUN.txt` che spiega come riprendere il lavoro. Per copie su altri dischi: `--backup-from` e `--backup-to`.



Il pacchetto d'archivio creato e verificato: «5 ok, 0 mismatched, 0 missing».

Nascondere nomi e numeri prima della condivisione

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

Le parole trovate vengono annerite nell'immagine e tolte dal testo. **Controlla il risultato a occhio:** una parola che l'OCR non ha riconosciuto non viene nascosta.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Risultato reale: il numero di telefono è stato nascosto, ma l'indirizzo e-mail NO, perché l'OCR ha letto «@» come «G» (ion.popescuGexample.com) e il modello per l'e-mail non ha trovato corrispondenza. Per questo devi controllare il risultato a occhio. Da pre.20 il programma scrive alla fine quante parole ha coperto ciascun modello e avverte quando un modello non ha trovato nulla o quando nel testo sono rimaste parole che sembrano indirizzi o numeri lunghi, esattamente come nella schermata qui sopra.

Lotto grande su più computer

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Esegui lo stesso elenco su ogni macchina, con un `--shard` diverso. Per poca memoria: `--max-memory 500`. Per file sconosciuti o ostili: `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

Il lotto diviso in due (--shard 1/2 e 2/2) e poi unito con --merge-pdf.

Firmare un PDF

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

Il livello giuridico della firma è quello del tuo certificato. La password del certificato si fornisce tramite la variabile d'ambiente, non sulla riga di comando. La marca temporale (`--sign-timestamp`) è stata verificata solo con un'autorità locale tramite HTTP, non con una reale tramite HTTPS.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Firma e verifica con un certificato di prova creato da me (non un certificato reale). «time stamp inside: none»: non ho richiesto la marca temporale.

Pila scansionata con alimentatore, ordine e intervallo di pagine

Molti scanner con alimentatore fanno passare la pila una volta per ogni facciata: prima tutti i fronti (1, 3, 5…), poi tutti i retri, in ordine inverso (6, 4, 2). I file escono nell'ordine di scansione, non in quello del libro. `--duplex-adf` li mette nell'ordine di lettura: fronte 1, retro 1, fronte 2, retro 2… Il numero di pagine deve essere pari (altrimenti il programma si ferma con un messaggio).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Sei file nell'ordine di scansione (scan_001 … scan_006). `--dry-run` mostra l'ordine in cui verrebbero elaborati e quali file verrebbero scritti, poi si ferma senza elaborare nulla: scan_006 finisce al posto 2, scan_005 al posto 4.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

Lo stesso comando senza `--dry-run`, con OCR nativo: il testo esce nell'ordine «Pagina 1 … Pagina 6» (pagine di prova fatte da me, non un libro reale).

Altre opzioni di ordine e selezione (si possono combinare; l'intervallo si applica alla numerazione dei file di ingresso, da 1):

- `--pages 1-10,15,20-`: tiene solo le pagine indicate; `20-` significa «dalla 20 fino alla fine». Funziona anche su pagine prese da PDF o da fogli TIFF con più pagine.
- `--reverse`: inverte l'ordine (pila scansionata dall'ultima pagina).
- `--dry-run`: controlla un lotto grande prima della lunga esecuzione.

Verificato: l'ordine e l'intervallo con test automatici e con sei pagine di prova; non ho provato uno scanner reale con alimentatore. Le opzioni si possono scegliere anche dalla finestra, in «Tutte le opzioni…» (sezione 4).

Testo pulito: correzioni proprie, intestazioni e cedilla

Per i file `.txt` e `.docx` (il livello di testo del PDF, hOCR e JSON conservano le parole lette, invariate):

- `--clean-text`: ș e ț con la virgola sotto, parole spezzate a fine riga riunite (con il trattino mantenuto quando le due metà sono parole dell'elenco e la semplice unione non lo è), virgolette tipografiche, spazi accanto alla punteggiatura. `--cedilla` scrive invece ş e ţ, per programmi e caratteri che non conoscono le lettere con la virgola.

- `--find-replace FIȘIER`: le tue correzioni, una per riga, `greșit => corect`. Le righe che iniziano con `#` sono commenti. Corrispondono solo parole intere (`Ion => Ioan` non tocca «Ionescu») e si applicano nell'ordine del file, dopo `--clean-text`. Utili per nomi propri, abbreviazioni o un timbro che il motore legge sempre ugualmente male.

- `--drop-running-heads`: lascia fuori intestazioni, piè di pagina e numeri di pagina stampati: la prima o l'ultima riga di una pagina che si ripete (le cifre non contano) su almeno metà delle pagine; servono almeno quattro pagine. Le righe tolte sono elencate su stderr, per vedere che cosa è andato via.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

Il file di regole (il primo blocco) e le stesse due righe lette dalla pagina di prova senza e con `--find-replace`: «Ionescu» è diventato «Ionescu-Vale» e «ha» è diventato «hectare».

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

Su sei pagine di prova con l'intestazione «Anuarul Văii Mari» e un numero, il programma ha tolto sei righe di intestazione; il testo inizia direttamente con «Pagina 1». Attenzione: la regola toglie qualsiasi prima/ultima riga che si ripete, quindi in un libro in cui l'ultima riga di ogni pagina si somiglia (per esempio «Poziția în raft: 14») andrebbero via anche quelle righe; per questo sono elencate. La funzione è stata verificata con test e su alcune pagine, non su un grande insieme di libri.

Altre ricette

Le ricette complete sono in `docs/tasks/` nel repository, in inglese e rumeno (verifica di documenti con `--verify-document` e `--mrz`, copia d'archivio, lotto grande).

6. Impostazioni importanti e quando si usano

Profili

```
$ legatorocr --list-profiles | cut -c1-100
book-bw             Text books: auto threshold, black & white, punch holes removed
book-small-color    Colour books: sharp text over a light background, smallest files
document-text       Office documents: sharp text, pictures kept in colour
photo-archive       Archive quality colour, light sharpening
newspaper           Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red    Forms with red rules or stamps: drop red, erase ruled lines
negatives           Negative scans: invert and stretch contrast
doc-birou           Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene       Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim        Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft        Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum        Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma             Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta               Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura           Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos        Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof           user profile
```

legatorocr --list-profiles. L’ultima riga (smokeprof) è un mio profilo di prova, non fa parte del programma.

Un profilo è un insieme di impostazioni già pronto per un tipo di materiale. Si sceglie dalla sezione «Profilo» (interfaccia) o con `--profile NUME` (riga di comando). Puoi avere profili tuoi: configuri le impostazioni, scrivi un nome e premi «Salva profilo».

Profilo	Per che cosa
`book-bw`	libri di testo, in bianco e nero, fori di perforazione rimossi
`book-small-color`	libri a colori, testo nitido su sfondo chiaro, file piccoli
`document-text`	documenti d’ufficio, immagini mantenute a colori
`photo-archive`	fotografie, qualità d’archivio
`newspaper`	giornali: soglia Wolf, macchie eliminate più energicamente
`form-dropout-red`	moduli con linee o timbri rossi
`negatives`	scansioni di negativi
`phone-photos`	foto da telefono: prospettiva corretta, sfondo attorno alla pagina cancellato, libri aperti tagliati a metà, dita rimosse
`phone-photos-a4`	come `phone-photos`, ma ogni pagina su un foglio A4, con il testo ingrandito fino a riempire il foglio (anche per le pagine con poche righe)
`registre-manuscrise`	registri e manoscritti antichi (300–600 dpi), colori mantenuti
`schite-desene`	schizzi e disegni a matita (400 dpi)
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	flussi per documenti d’ufficio, dalla qualità massima al grande volume
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**non verificati su campioni reali**

L’elenco completo lo fornisce `--list-profiles`.

Le impostazioni che contano di più

Impostazioni	Che cosa fa	Quando la cambi
Risoluzione (dpi)	a quanto sono scansionate le pagine	quando l'immagine non ha dpi nell'intestazione; per il testo 300
Raddrizzamento automatico / inclinazione max	il limite dell'angolo corretto automaticamente	quando una pagina che esce «al limite» è in realtà storta
Margini, formato pagina, stessa dimensione	i margini in mm; pagina libera, personalizzata o identica per tutto il libro	per libri con formati misti
Modalità di uscita	colore, grigio, bianco e nero, misto (testo a 1 bit + immagini a colori), ibrido (+ sfondo a bassa risoluzione)	bianco e nero per testo puro; misto per testo con foto
Metodo di soglia	Sauvola (predefinito), Wolf, Niblack, NICK, Bradley, Otsu o automatico	quando il testo esce sbiadito o pieno di macchie; `auto` ne prova più d'uno su ogni pagina
Sensibilità	la sensibilità del metodo Sauvola per l'uscita in bianco e nero	predefinito 0,3; cambiala a piccoli passi e confronta il risultato sulla stessa pagina
Sensibilità immagini	con quanta facilità una zona viene considerata immagine	nella modalità mista/ibrida
Rimuovi i puntini	la forza della pulizia delle macchie (0,25–4; 1 = predefinito)	riducila se spariscono punti o segni diacritici; aumentala se restano macchie
Dewarp (righe curve)	raddrizza le righe arcuate vicino alla rilegatura	per libri spessi; viene saltato se non si vede una curvatura netta
Uniforma l'illuminazione	uniforma lo sfondo	per foto con ombra o illuminazione irregolare
Qualità JPEG	0 = senza perdita; le pagine in bianco e nero sono sempre senza perdita	per file più piccoli (suggerimento: prova 80–90 e confronta dimensione e aspetto)
dpi di uscita	riduce l'immagine di uscita a questi dpi («—» = non ridurre)	per PDF più piccoli; le pagine sotto i 250 dpi vengono ingrandite automaticamente prima dell'OCR, quindi una riduzione eccessiva non aiuta il riconoscimento
PDF/A-2b	PDF per l'archiviazione, con carattere e profilo colore inclusi	per il deposito in archivi; non è stato verificato con veraPDF sulle uscite del programma

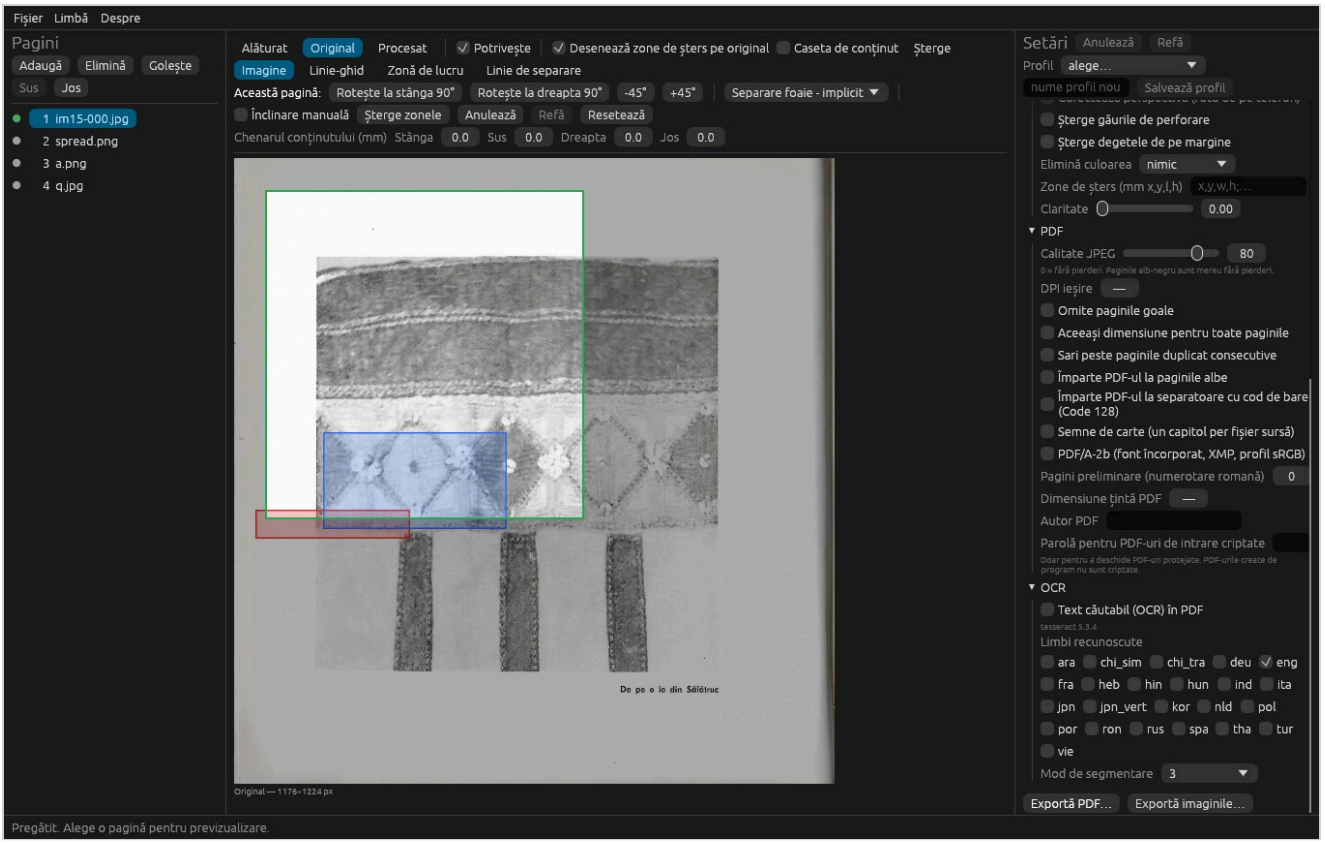
I formati dei campi di testo

Questi campi esistono nelle impostazioni, ma è più facile disegnare sull'originale (sezione 4):

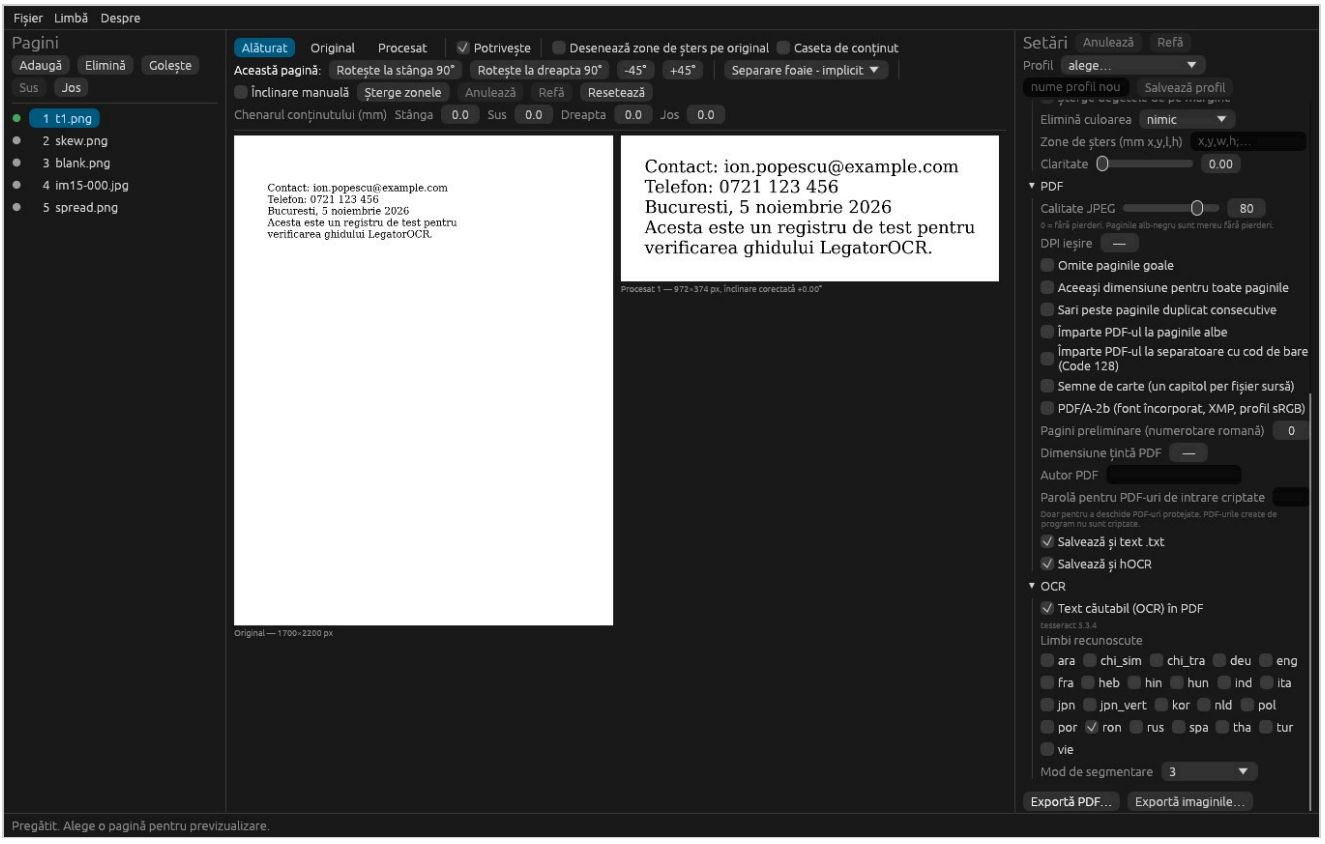
- **Zone da cancellare** e **Zone immagine**: `x,y,l,h` in **millimetri** dall'angolo in alto a sinistra della pagina. Più zone si separano con il punto e virgola: 10,20,30,40;50,60,20,20. Al massimo 64; larghezza e altezza devono essere positive. Se il formato è sbagliato, il campo diventa rosso.
- **Linee guida di raddrizzamento**: `x,y x,y x,y;x,y x,y x,y`, con **frazioni tra 0 e 1** della pagina già raddrizzata (0,0 = angolo in alto a sinistra). Ogni linea ha almeno due punti; in totale al massimo 64 linee.
- Sulla riga di comando: `--erase X,Y,W,H` (ripetibile) e `--dewarp-guide "X,Y X,Y …"` (ripetibile).

7. OCR: motori, lingue e accuratezza

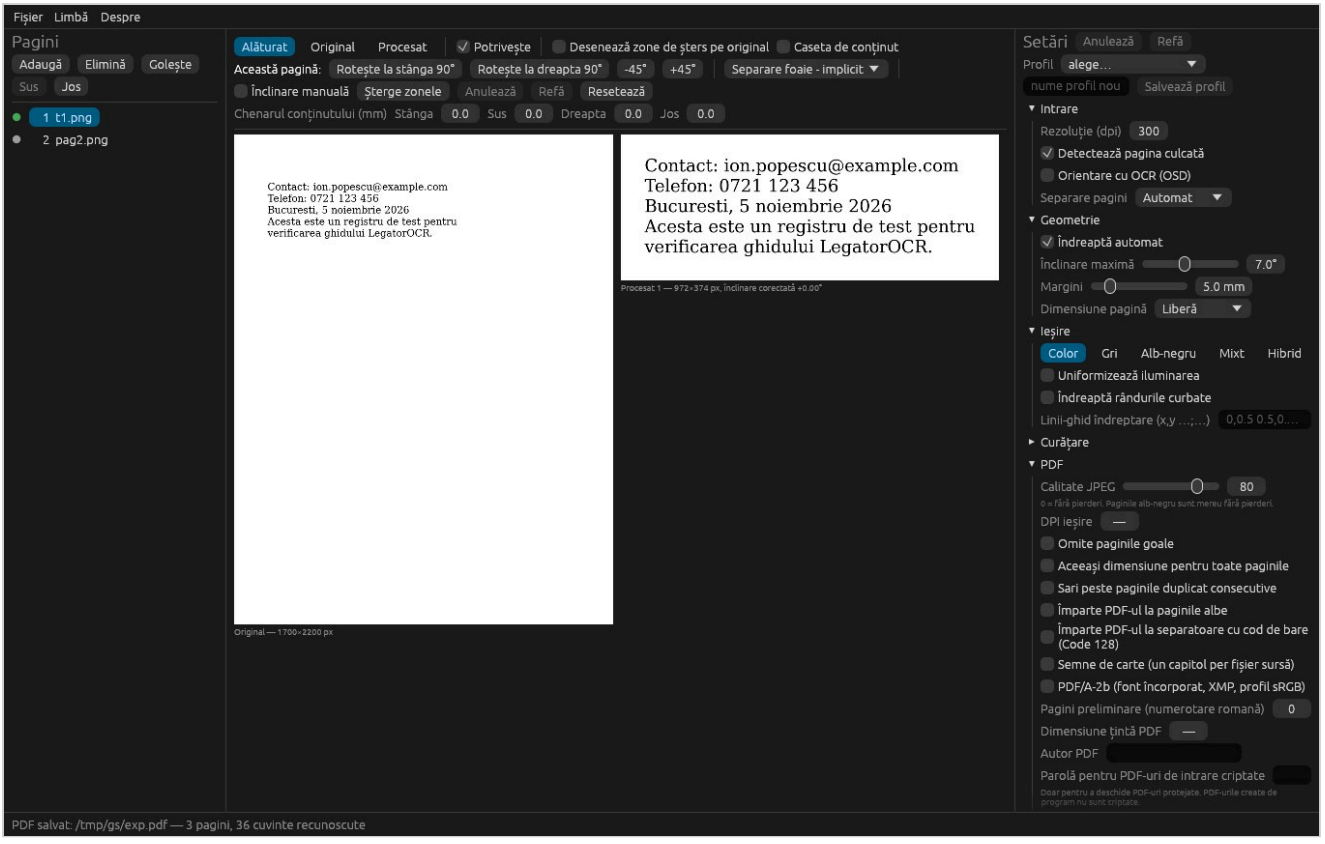
La casella «Testo ricercabile (OCR) nel PDF» (o `--ocr` sulla riga di comando) aggiunge un livello di testo invisibile sopra l'immagine. La lingua si sceglie da «Lingue di riconoscimento» (o `--lang ron`); si può combinare, ad esempio `ron+eng`. Le lingue dell'interfaccia e del motore proprio: rumeno, inglese, francese, italiano, spagnolo, portoghese, tedesco, ungherese.



La sezione OCR delle impostazioni: la casella «Testo ricercabile (OCR) nel PDF», le lingue di riconoscimento (quelle installate in Tesseract) e la modalità di segmentazione. Nella schermata era installato Tesseract 5.3.4, per questo compaiono tutte le sue lingue; la scelta ron l'ho usata nella figura seguente.



Con l’OCR spuntato compaiono anche «Salva anche il testo (.txt)» e «Salva anche hOCR». Qui la lingua scelta è ron.



Dopo l’esportazione, la barra in basso mostra: «PDF salvato: … — 3 pagine, 36 parole riconosciute». (L’esportazione l’ho avviata con un meccanismo di prova del programma, non dalla finestra di dialogo dei file.)

Tre motori

Motore	Come lo scegli	Note
Nativo (del programma)	`--engine native`	senza installazione, scritto in Rust; modello addestrato su testo sintetico, poi rifinito su righe di una rivista rumena e di un manuale del 1960
Tesseract	`--engine tesseract`	programma separato, vedi la sezione 2; usato automaticamente quando è installato e ha la lingua richiesta (`--engine auto`, predefinito)
Ponte ONNX	`--engine tesseract --tesseract scripts/engine-onnx.py`	per utenti avanzati; richiede Python, onnxruntime e modelli scaricati separatamente

```
$ legatorocr scans/text.png --engine native --ocr --lang ron --txt nat.txt --format none; cat nat.txt; echo; legatorocr
scans/text.png --engine tesseract --ocr --lang ron --txt tes.txt --format none; cat tes.txt
OCR engine: LegatorOCR native engine 0.2.0-pre.19, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote nat.txt
Contact: ion.popescu(aexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote tes.txt
Contact: ion.popescuGexample.com
Telefon: 0721 123 456
Bucuresti, 5 noiembrie 2026
Acesta este un registru de test pentru
verificarea ghidului LegatorOCR.
```

La stessa pagina di prova letta dai due motori. Entrambi hanno sbagliato allo stesso modo: «@» è uscito «(a» nel motore nativo e «G» in Tesseract.

I numeri misurati (e che cosa non dicono)

Sono state misurate 8 pagine buone di una rivista rumena, rispetto a un testo di riferimento prodotto da ABBYY, non corretto da una persona. Il tasso di errore sui caratteri, con segni diacritici (la misura originale, dall'edizione 0.2.0-pre.21; in una nuova misura in pre.26 sulle stesse 8 pagine, con lo stesso metodo, il motore nativo ha dato 2,76 %; la differenza rispetto a 2,55 % non l'ho indagata):

Motore	Errori sui caratteri
Nativo	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (con Tesseract)	4,62 %

Letto semplicemente: il motore nativo sbaglia meno **su questo tipo di stampa**. Ma è stato rifinito su testo delle stesse fonti, quindi non si può dire che sia migliore in generale. Su altri documenti, soprattutto stampa antica o insolita, può essere più debole di Tesseract. Il riconoscimento delle parole intere è quasi uguale tra i motori (circa 92 %).

La modalità accurata e l'ortografia antica

- `--accurate` (motore nativo): ogni riga viene letta tre volte (spostata di un pixel in su e in giù) e le probabilità vengono mediate. È più lento (misurato: dal 18 % al 74 % di tempo in più) e ha aiutato solo sulle pagine di rivista (errore sui caratteri 3,66 % → 3,39 % su 12 pagine); su libri e opuscoli non ha cambiato nulla di misurabile. È disattivato per impostazione predefinita.

- L’elenco delle parole rumene accetta anche l’ortografia del 1953–1993 (`cuvînt`, `romîn`, `sînt`): su cinque pagine di un manuale del 1960, trascritte a mano, i caratteri corretti sono saliti dal 99,6 % al 99,7 % e le parole dal 96,0 % al 96,3 %. Una piccola differenza, su cinque pagine.
- Le parole vengono separate agli spazi larghi anche quando la rete non ha scritto lo spazio: le celle di una tabella non escono più attaccate (`CantitatePreț`). Una tabella con linee viene trovata come una sola tabella (Excel: `--tables-xlsx`); una tabella senza linee viene ancora trovata come due tabelle (sinistra e destra), problema non risolto.

Consigli

- Sui tuoi documenti, confronta i motori su 5–10 pagine prima del lotto: `scripts/compare-ocr-text.py` misura gli errori rispetto a testi di riferimento che hai tu.
- Le pagine sotto i 250 dpi vengono ingrandite automaticamente prima del riconoscimento.
- Le pagine con illustrazioni o diagrammi possono produrre testo senza senso nella zona dell’immagine (Tesseract ha letto un’illustrazione come testo su una delle pagine misurate). Controlla queste zone.
- Qualsiasi OCR può inventare o perdere parole. Per atti, registri o cifre, controlla a campione.

8. Uscite e archiviazione

Che cosa vuoi	Come
PDF con testo ricercabile	`--pdf FISIER.pdf --ocr` (interfaccia: Esporta PDF con OCR spuntato)
PDF per l’archiviazione (PDF/A-2b)	`--pdfa`; altre parti con `--pdfa-part 1` o `3`
Immagini elaborate	`-o FOLDER`, con `--format png`, `jpeg` o `tiff`; `--format none` non scrive immagini
Testo semplice delle pagine	`--txt FISIER.txt`
hOCR	la casella «Salva anche hOCR»
Struttura per l’accessibilità	`--tagged ro` (paragrafi etichettati). La conformità PDF/UA **non** è stata convalidata
Copia DjVu	`--djvu FISIER.djvu`
Prova di integrità	`--checksums` e `--archive-package DIR`, poi `--verify-sums`
Progetto (impostazioni e correzioni)	File → Salva progetto (`.lgr`), oppure `--save-project`; `--embed-project` lo nasconde nel PDF

Sul PDF/A

Il programma scrive PDF/A-2b con carattere e profilo sRGB incorporati. La conformità è stata verificata su campioni, **non** con veraPDF su qualsiasi uscita. Se un’istituzione richiede una conformità certificata, esegui il tuo validatore sui file finali.

Sui progetti ScanTailor

`--project FISIER.ScanTailor` apre un progetto ScanTailor: l’elenco delle scansioni e la rotazione per immagine vengono ripresi, mentre l’inclinazione, la separazione e il riquadro del contenuto vengono ritrovati. Il lettore è stato scritto in base alla descrizione del formato e provato su un progetto fatto a mano, non su file di ogni versione di ScanTailor.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project e --project: il progetto si salva e si riapre con lo stesso risultato (2 pagine). Attenzione: in pre.18, --work-area e --cut-at non venivano conservati nel progetto; corretto in pre.19 (verificato: il progetto salvato e riaperto dà le stesse pagine).

9. Problemi frequenti e limiti noti

Sintomo	Che cosa controllare
La pagina esce tagliata o con troppo bianco	il riquadro del contenuto (sezione 4); il riquadro in mm dalla barra «Questa pagina»
Una pagina inclinata resta inclinata	l’inclinazione massima consentita; imposta l’angolo a mano
Il foglio fronte-retro non si taglia dove dovrebbe	la modalità di separazione della pagina: «a metà» o «disattivata»; da pre.18 puoi trascinare una «Linea di taglio» sull’originale oppure usare `--cut-at 0.45`
Un campo di testo diventa rosso	il formato del campo (sezione 6): millimetri per le zone, frazioni 0–1 per le guide
Il testo OCR ha errori	confronta i motori (sezione 7); controlla la risoluzione; passa a Tesseract o viceversa
Il pannello «Da controllare»	pagine segnalate come sospette (vuota, inclinazione al limite, nulla trovato, contenuto attaccato al bordo); non sono per forza sbagliate, ma vale la pena guardarle
La finestra non funziona su Windows o in RDP	manca OpenGL 2+; prova il driver della scheda video
L’app macOS non si avvia	non è firmata: clic destro → Open oppure il comando `xattr` della sezione 2

Limiti noti dell’edizione 0.2.0-pre.61

- Trapezio auto: verificato su fogli sintetici e su 67 foto da telefono di un solo libro (133 pagine), dove ha lasciato intatte la maggior parte delle pagine e ridotto l'inclinazione misurata sulle altre; nessuno ha giudicato il risultato a occhio su altri libri, né su pagine con grandi immagini, tabelle o righe molto corte, dove può non fare nulla o troppo poco. Le impostazioni per pagina e l'inclinazione della linea di taglio sono state provate su fogli sintetici e nei test; la matita tabella fa leggere la zona all'OCR come un blocco, non trova le celle.
- La rotazione di 90°: con una pagina con una fotografia di ornamenti (pagina 15 di un PDF) un tester su Windows ha visto la rotazione saltare da 90° a 180°. Ho riprodotto su Linux una parte del problema: in pre.18, con «Rileva le pagine di lato» spuntato (predefinito), il programma ruotava per errore di 90° questa pagina, benché l’originale sia dritto (la figura nella sezione 4). La soglia di pre.19 era troppo fragile (nel frattempo ho scoperto che anche un’altra pagina dello stesso PDF, la pagina 13, veniva ruotata per errore). In pre.20 il rilevatore conta solo i pezzi della dimensione di una lettera e si astiene sulle pagine con foto o con poche parole. Su 98 pagine di libro (ruotate a 0° e 90°) e 5 pagine con foto, il risultato è identico a pre.18, tranne la pagina 13 (ruotata per errore in pre.18, ora dritta) e

una pagina con una foto coricata, che il rilevatore non gira più (restano l'OSD e la rotazione manuale). Verificato sulla riga di comando, su Linux, su un piccolo corpus. La causa probabile del salto (l'orientamento automatico si sommava alla rotazione manuale) è stata corretta in pre.18: dopo un clic sulla rotazione la pagina resta bloccata, e quattro clic danno 90°, 180°, 270° e di nuovo 0° (verificato nella finestra, su Linux). Che cosa abbia visto esattamente il tester su Windows 11 non ho potuto verificarlo. Se una pagina con foto viene comunque ruotata per errore, deseleziona «Rileva le pagine di lato» oppure usa --no-auto-orient.

- L'area di lavoro, la linea di taglio spostabile, le zone da cancellare e immagine, la griglia di punti, Annulla e Ctrl+Z, il riquadro del contenuto, l'OCR e l'esportazione PDF sono stati provati in una finestra reale su Linux, con il mouse simulato (le schermate della guida). Il ridimensionamento di una zona dall'angolo ha funzionato nella finestra. Le finestre di dialogo native dei file («Esporta PDF…», «Salva progetto», «Apri progetto») hanno funzionato con la finestra GTK di un portale xdg su Linux; su Windows e macOS non le ho provate. Se il sistema non ha alcuna finestra di dialogo, da pre.21 la finestra lo dice invece di non fare nulla (puoi trascinare i file nella finestra o usare la riga di comando). Il salvataggio di un profilo proprio ha funzionato. L'effetto della linea di taglio l'ho verificato con test automatici, con --cut-at e nella finestra (un foglio doppio tagliato in due pagine disuguali, 524 e 674 px). Nei fogli ruotati di 90° o 270° (da pre.21) le pagine escono una sotto l'altra; questo è verificato solo con un test automatico, non nella finestra.

  --save-project: nella build pubblicata pre.18, --work-area e --cut-at dati sulla riga di comando non venivano conservati nel file .lgr (scoperto durante la verifica di questa guida). Corretto in pre.19. Se usi pre.18, ridai le opzioni a --project, non solo dal progetto.

- L'interfaccia grafica non è stata verificata da persone su Windows, macOS o arm64.
- La verifica PDF/UA, la fattura elettronica CIUS-RO e la marca temporale tramite HTTPS con un'autorità reale non sono state convalidate.
- Per una copia PDF/A certificata, il validatore è tuo (ad esempio veraPDF).
- Il diritto di utilizzo del modello OCR proprio (addestrato in parte su pagine con diritti non chiariti) è una questione aperta presso l'autore; vedi `docs/audit/assets-licences.md`.
- Riconoscimento automatico delle pagine capovolte: solo alfabeto latino, almeno 12 righe per pagina; una pagina con tabelle o poco testo può restare intatta (usa «180°»). La finestra delle collezioni e le miniature grandi hanno test automatici, ma l'autore non le ha viste sullo schermo.

10. Come segnalare un problema

Il contributo più utile è una segnalazione da un sistema che l'autore non ha provato. Richiede cinque minuti:

1. Scarica l'ultima edizione per il tuo sistema.
2. Esegui `legatorocr --doctor` e copia tutto il risultato.
3. Elabora una pagina che puoi condividere: `legatorocr PAGINA.jpg --ocr --pdf rezultat.pdf -o pagini`.

4. Apri `rezultat.pdf`: la pagina è dritta e ritagliata come si deve? Il testo si seleziona e si cerca?

Invia, come problema (issue) nel repository `chiuta/LegatorOCR` (o per e-mail):

- il sistema e la versione (ad esempio Windows 11 23H2, macOS 15 arm64, Debian 12 arm64);
- la versione di LegatorOCR;
- il risultato del comando `--doctor`;
- il comando eseguito (o l'impostazione dell'interfaccia);
- che cosa ti aspettavi e che cosa è successo (testo dell'errore o schermata);
- se l'immagine può essere condivisa.

Non inviare documenti con dati personali. Una segnalazione «tutto ha funzionato» è comunque utile: è l'unico modo in cui l'autore viene a sapere che un sistema funziona.

I problemi di sicurezza si segnalano secondo `SECURITY.md`, non pubblicamente.