LegatorOCR – Ghid de utilizare

Ediția 0.2.0-pre.26 (versiune de probă). Text în lucru, în română.

1. Ce este LegatorOCR

LegatorOCR transformă scanări sau poze de pagini într-un PDF curat, cu text care se poate căuta. Rezolvă aceeași problemă ca ScanTailor (separarea paginilor, îndreptarea, decuparea, curățarea), dar adaugă export PDF și OCR. Este scris în Rust, cu cod propriu, fiecare etapă fiind o tehnică de manual. Rulează local, fără cont și fără trimiterea paginilor pe internet. Licență: MIT.

Există două moduri de lucru, cu aceleași motoare dedesubt:

- **Interfața grafică** (`legatorocr-gui`): adaugi pagini, vezi originalul și rezultatul alături, corectezi pagină cu pagină și exporți.
- **Linia de comandă** (`legatorocr`): pentru loturi mari, pentru automatizare și pentru opțiuni pe care interfața nu le arată.

Ce face

- separă foile dublu-față în două pagini, îndreaptă paginile înclinate și decupează marginile;
- curăță fundalul, petele, găurile de perforare, degetele de pe margine și liniile de formular;
- scrie PDF (inclusiv PDF/A pentru arhivare) sau imagini, cu OCR în română și în alte 7 limbi;
- produce și text simplu (`.txt`) și hOCR, și poate semna sau data PDF-ul.

Ce nu face (sau nu a fost dovedit)

- Este o versiune de probă (0.2.0-pre.26). A fost rulată de autor și de asistentul său doar pe Linux; **Windows, macOS și procesoarele arm64 nu au fost încercate de oameni**.
- Acuratețea OCR a fost măsurată pe 8 pagini bune dintr-o singură revistă românească, față de un text de referință produs de alt program, nu corectat de om. Nu o lua drept garanție pentru alte tipuri de tipar.
- OCR-ul poate greși: verifică prin sondaj paginile importante.

2. Instalare și prima rulare

Descarcă arhiva pentru sistemul tău de pe pagina de ediții (Releases) a depozitului `chiuta/LegatorOCR`. Fiecare arhivă are un fișier `.sha256` pentru verificare.

Sistem	Fișier	Note
Linux x86-64 sau ARM64	`.tar.gz`	are nevoie de OpenGL 2+ și de X11 sau Wayland
Windows x86-64	`.zip`	are nevoie de OpenGL 2+; în sesiuni RDP simple poate lipsi
macOS Apple-silicon sau Intel	`.zip` cu `LegatorOCR.app`	**nesemnat**: la prima pornire clic dreapta → Open, sau `xattr -dr com.apple.quarantine LegatorOCR.app`

Poți și să compilezi din sursă: `cargo build --release` (necesită Rust 1.95 sau mai nou).

OCR

Programul are un motor OCR propriu, care funcționează fără instalare. Opțional poți instala Tesseract, un program separat, pe care LegatorOCR îl folosește automat când e prezent și are limba cerută:

- Linux (Debian/Ubuntu): `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS: `brew install tesseract tesseract-lang`
- Windows: `winget install UB-Mannheim.TesseractOCR` și adăugarea lui la `PATH`

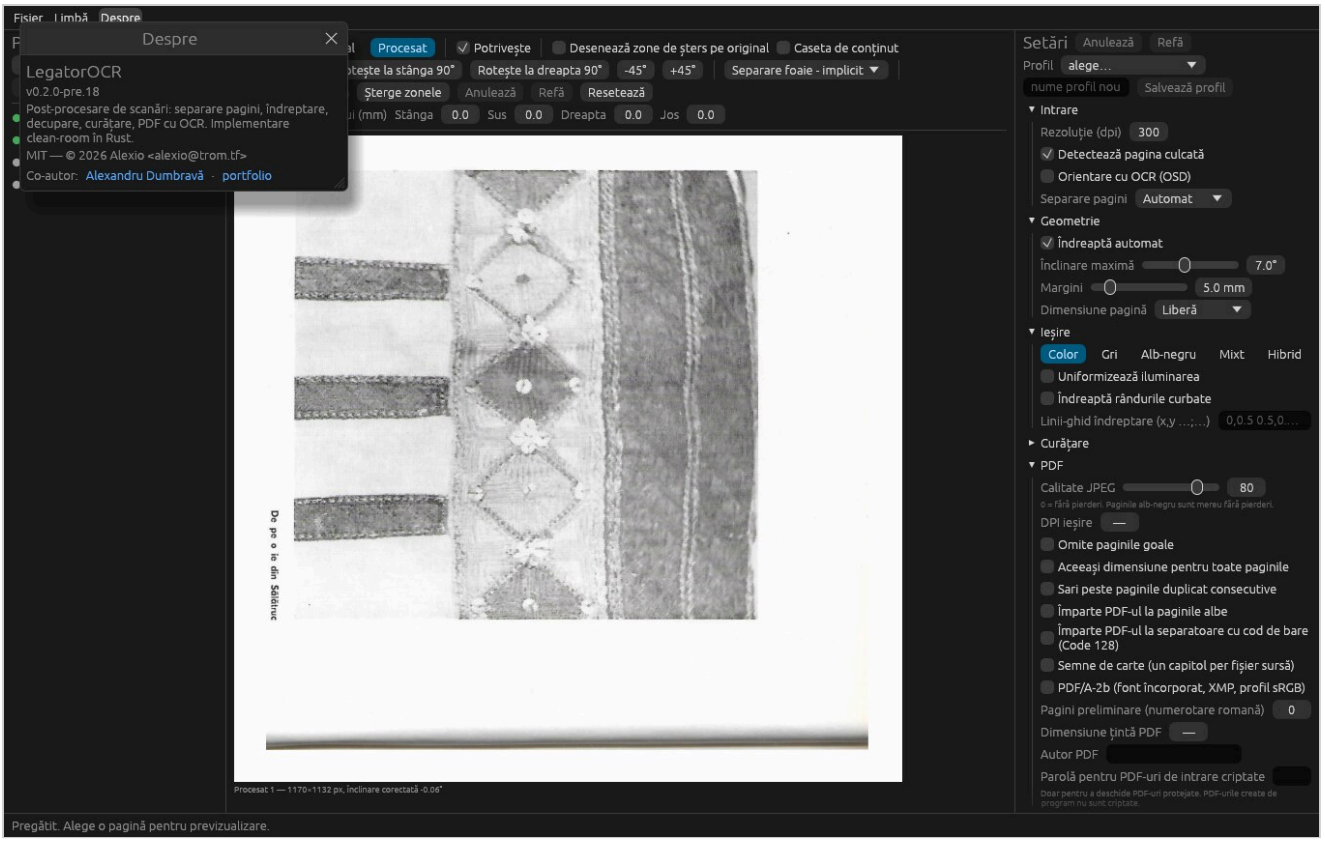
Modelul românesc din pachetele `apt` și `brew` este varianta mică („fast”). Varianta „best” se descarcă manual și se indică cu `--tessdata DIR`. Care citește mai bine paginile tale nu a fost măsurat.

Verifică instalarea

Rulează `legatorocr --doctor`. Afișează versiunea, motorul OCR nativ, Tesseract și modelele de limbă, apoi unelte auxiliare (`pdftoppm`, `gs`, `qpdf`, `mutool`). Rezultatul „missing” la o unealtă opțională nu e o eroare; mesajul de sub el spune dacă e nevoie de ea. Dacă ceva nu merge, copiază tot rezultatul comenzii într-un raport (vezi secțiunea 10).

```
$ legatorocr --doctor
[ok     ] legatorocr                        0.2.0-pre.19
[ok     ] native OCR engine                 built in
[ok     ] tesseract                         tesseract 5.3.4
[ok     ] tesseract model ro (Romanian)     installed
[ok     ] tesseract model en (English)      installed
[ok     ] tesseract model fr (French)       installed
[ok     ] tesseract model it (Italian)      installed
[ok     ] tesseract model es (Spanish)      installed
[ok     ] tesseract model pt (Portuguese)   installed
[ok     ] tesseract model de (German)       installed
[ok     ] tesseract model hu (Hungarian)    installed
[ok     ] pdftoppm                          pdftoppm
[missing] mutool                            not found
          -> optional: alternative renderer for those cases
[ok     ] gs                                gs
[ok     ] qpdf                              qpdf
14 check(s) ok, 1 missing. Missing helpers are optional unless a hint says otherwise.
```

Rezultatul comenzii legatorocr --doctor (pre.20, Linux, într-un terminal real; la fel toate capturile de terminal din ghid, făcute cu xterm): „missing” la mutool este o unealtă opțională, nu o eroare.



Meniul Despre arată versiunea instalată (aici 0.2.0-pre.18). Captură din build-ul pre.18 pe Linux, interfața în română.

3. Fluxul de lucru, pas cu pas

Pentru fiecare pagină, programul parcurge etapele de mai jos în această ordine. Analiza se face pe o copie de aproximativ 150 dpi, iar rezultatul se aplică apoi pe scanarea la rezoluția ei plină.

1. **Orientare.** Se detectează paginile culcate (sfert de tură), după literele paginii: o pagină cu poze sau cu puține cuvinte nu este rotită de acest test. Pentru direcția exactă se poate folosi Tesseract (OSD) sau rotirea manuală.

2. **Separarea foii.** O foaie landscape cu două pagini se taie la mijloc, la banda goală din centru. Poate fi automată, la mijloc sau oprită.

3. **Îndreptarea.** Se estimează unghiul de înclinare din liniile de text și pagina se rotește înapoi. Unghiul se poate fixa manual.

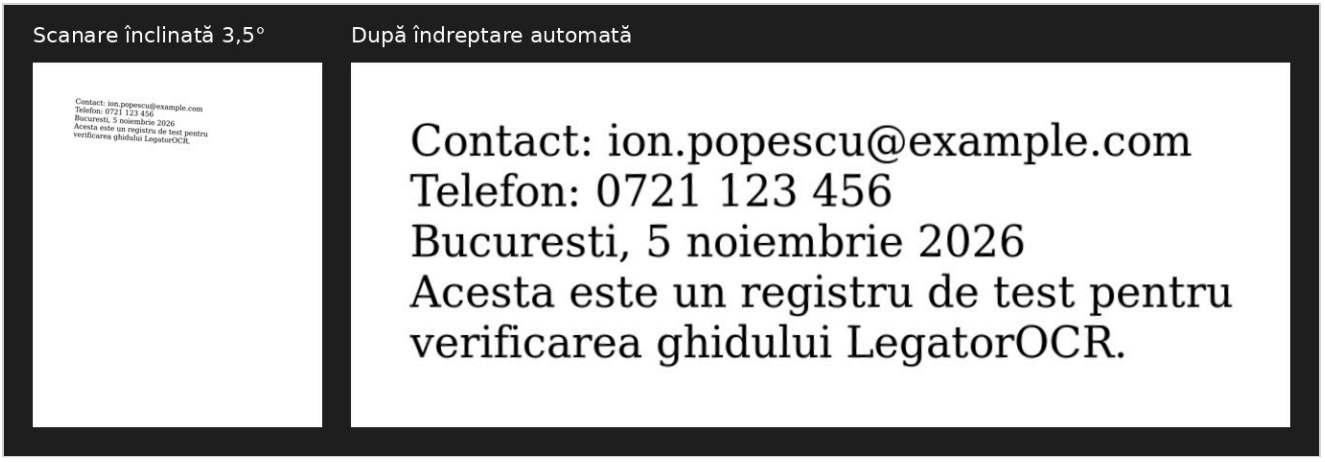
4. **Caseta de conținut.** Se găsește zona cu text și imagini; umbrele scannerului și praful sunt ignorate. Tot ce e în afara ei este repictat cu culoarea hârtiei.

5. **Margini și dimensiune.** Margini în milimetri, opțional dimensiune fixă a paginii sau aceeași dimensiune pentru toată cartea.

6. **Îndreptarea rândurilor curbe** (opțional). Pentru pagini de carte încărcate, cu rânduri curbate lângă cotor.

7. **Iluminare** (opțional). Egalizează fundalul inegal.

8. **Curățarea și binarizarea.** Elimină pete, găuri de perforare, degete, linii; apoi alb-negru, gri, color, mixt sau hibrid.
9. **PDF și OCR.** Se scrie PDF-ul (sau imaginile) și, dacă e bifat, stratul de text.



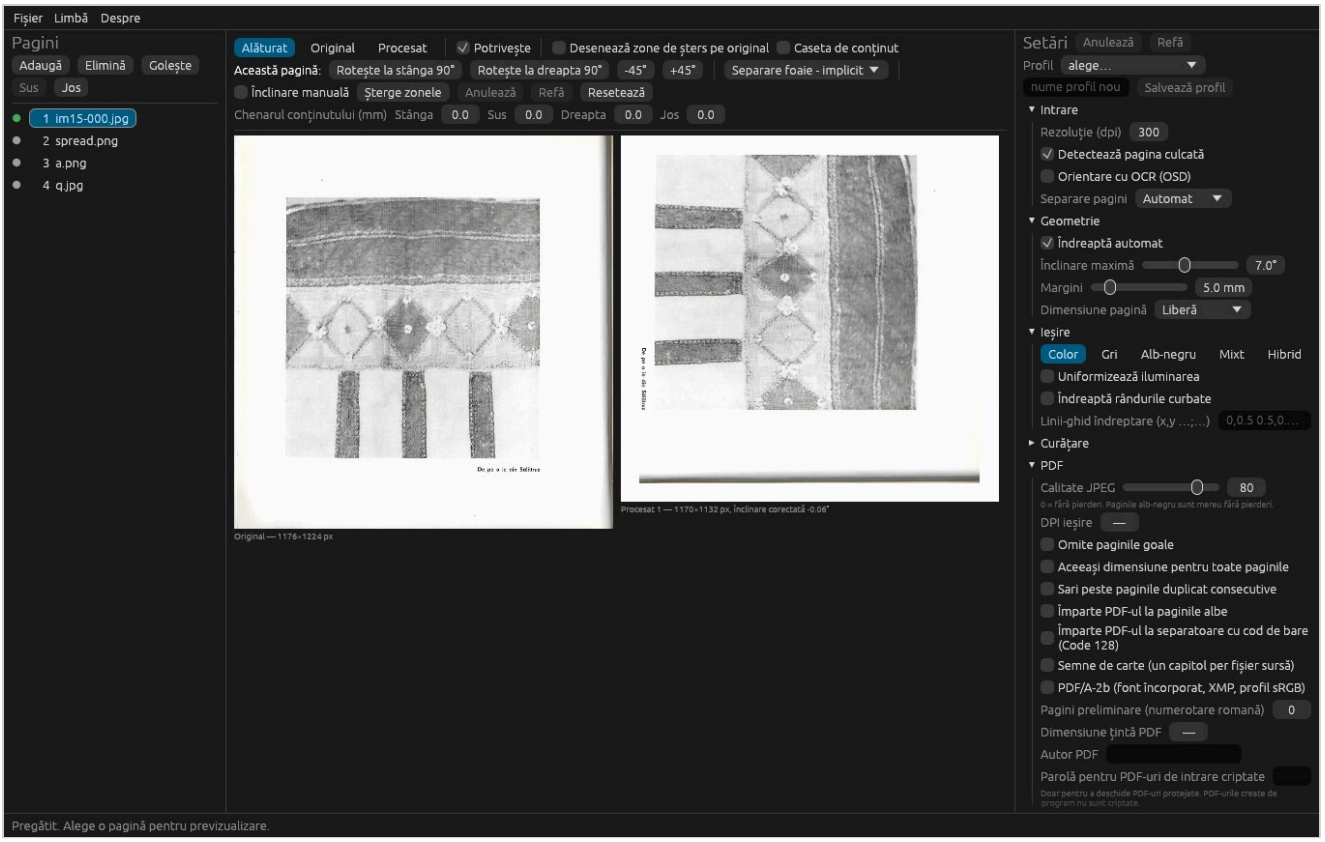
Îndreptarea automată: o scanare înclinată cu 3,5° (foaie de test generată de mine) și rezultatul; programul a măsurat -3,50°.

Reguli de lucru care economisesc timp

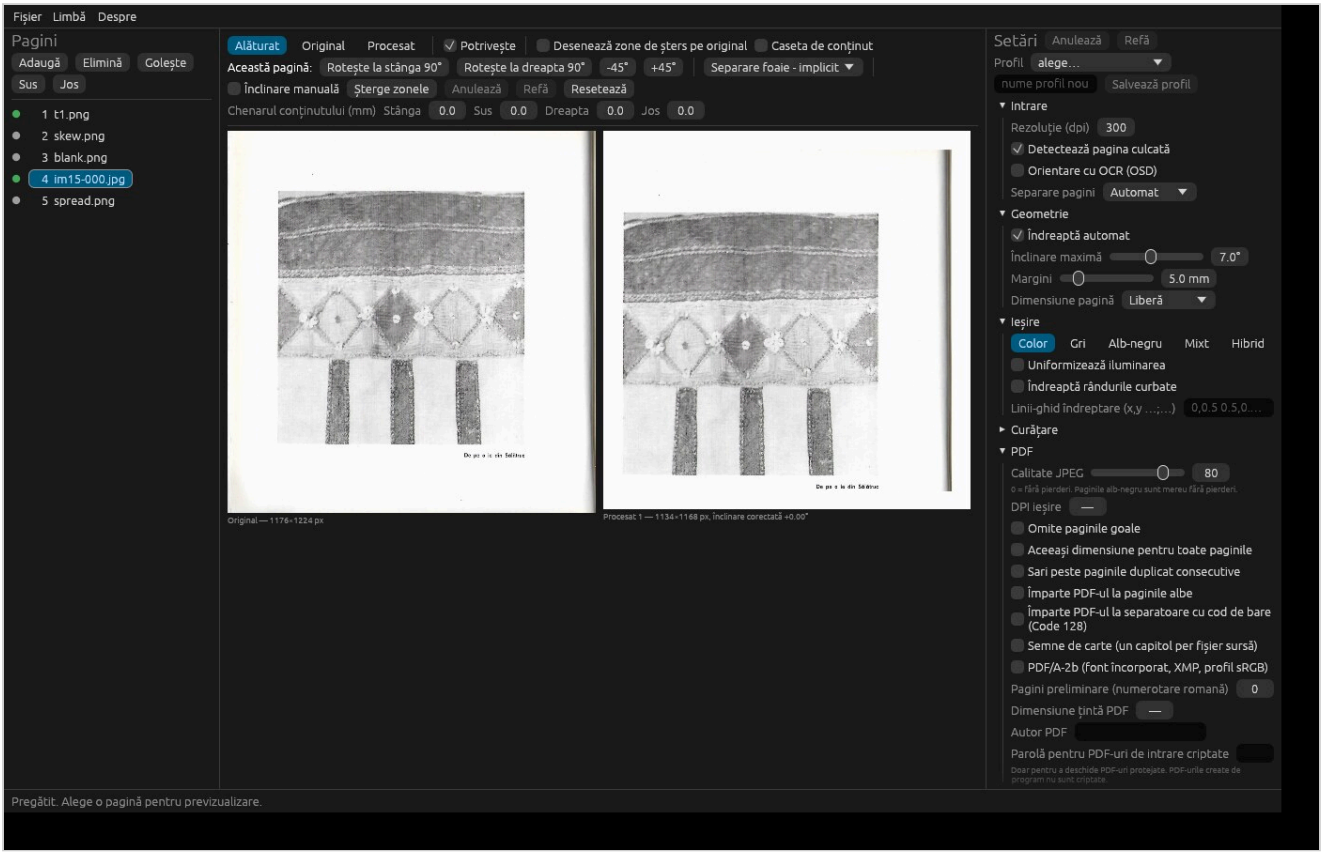
- Fixează mai întâi **rezoluția** corectă (de obicei 300 dpi pentru text). Programul o citește din imagine dacă ea este între 150 și 1200; altfel presupune 300.
- Alege un **profil** potrivit materialului (secțiunea 6) înainte de a umbla la setări individuale.
- Prelucrează 10–20 de pagini într-o probă, verifică rezultatul, apoi pornește lotul mare.
- Interfața marchează paginile „de verificat” (pagină goală, înclinare la limită, nimic găsit, conținut lipit de margine). Treci prin ele cu butonul „Următoarea”.

4. Interfața grafică

Fereastra are trei zone: lista de pagini în stânga, previzualizarea în centru și setările în dreapta. Meniul **Fișier** conține „Adaugă imagini”, „Adaugă un folder”, „Deschide proiect”, „Salvează proiectul”, „Exportă PDF” și „Exportă imaginile”. Limba interfeței (8 limbi) se schimbă din meniul **Limbă**.



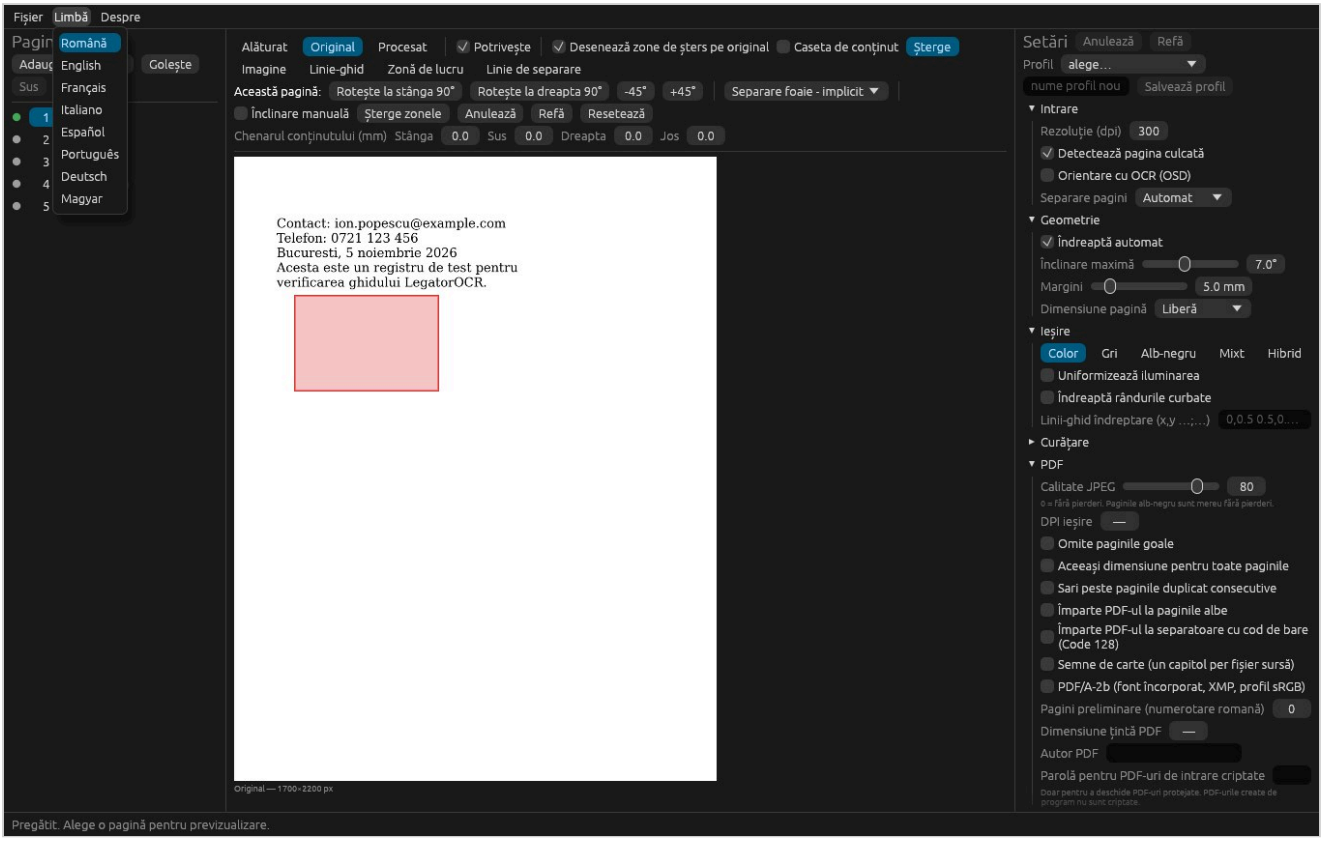
Fereastra principală: lista de pagini în stânga, originalul și pagina procesată la mijloc, setările în dreapta. Pagina din exemplu este o poză fără text, așa că detectarea paginii culcate a rotit-o greșit în pre.18 (corectat în pre.19, vezi mai jos). Captură pre.18 pe Linux.



Aceeași pagină în pre.19, cu „Detectează pagina culcată” bifat: nu mai este rotită (procesat 1134×1168 px, înclinare +0,00°). Captură pre.19 pe Linux.

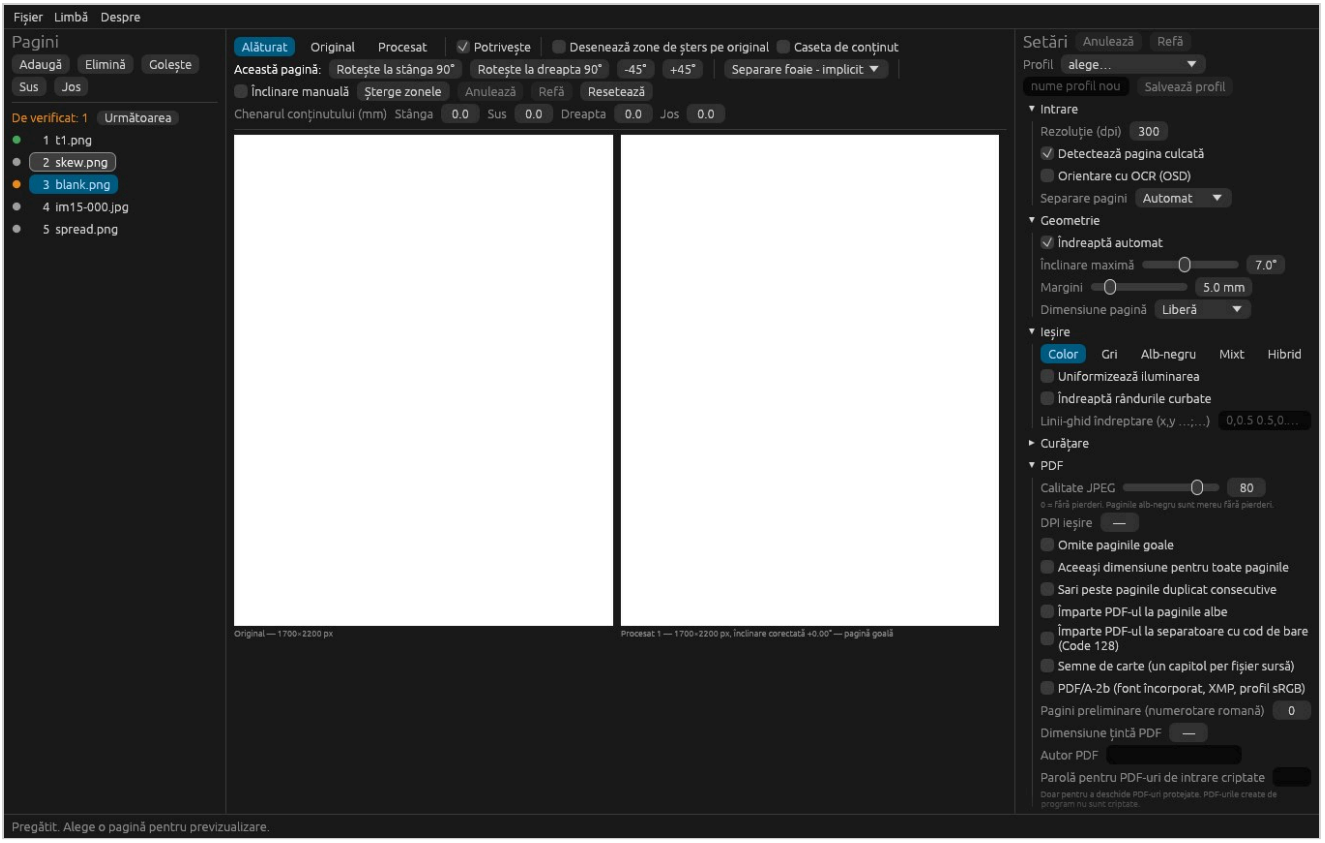


Meniul Fișier: adaugă imagini sau un folder, deschide și salvează proiectul, exportă PDF sau imagini.



Meniul Limbă: cele opt limbi ale interfeței (română, engleză, franceză, italiană, spaniolă, portugheză, germană, maghiară).

Lista de pagini

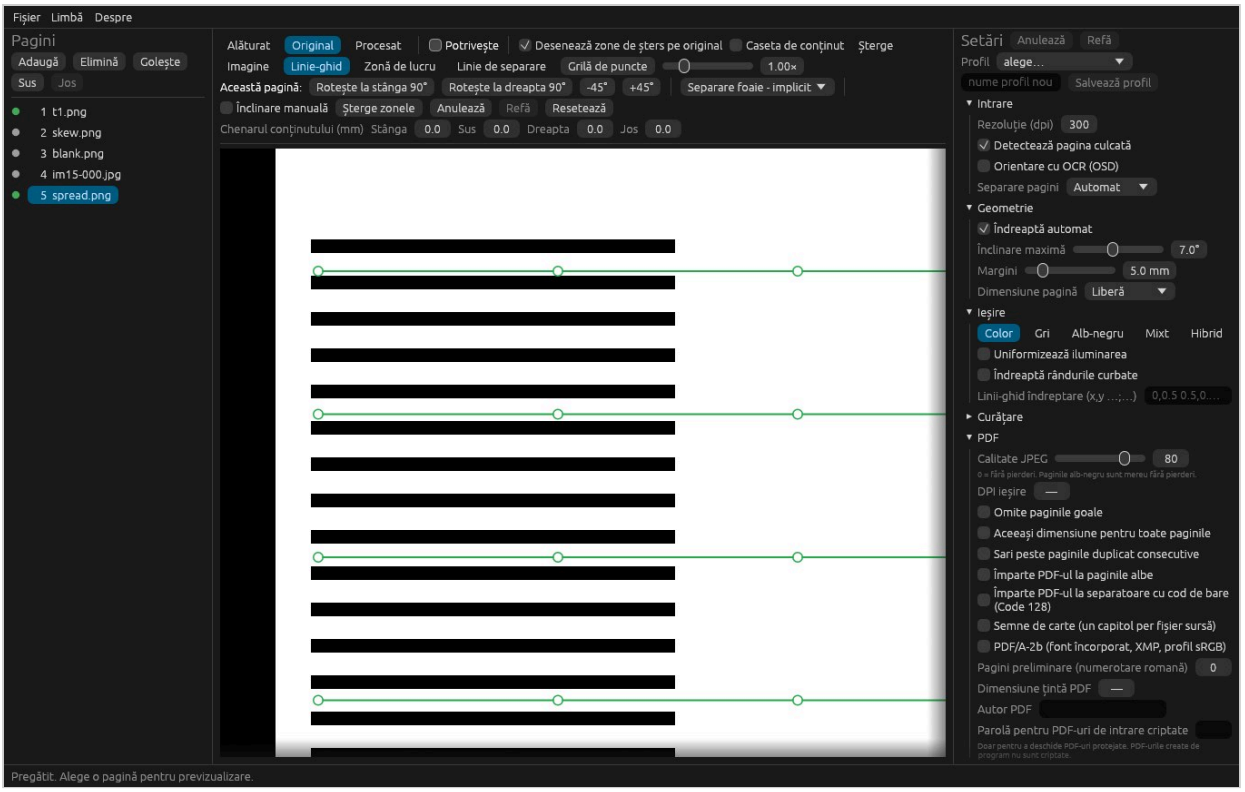


O pagină complet albă este marcată automat: punct portocaliu în listă și panoul „De verificat: 1” cu butonul „Următoarea”.

Trage în ea imagini, PDF-uri, arhive sau un folder, ori apasă „Adaugă”. Butoanele Sus/Jos schimbă ordinea, „Elimină” scoate pagina aleasă, „Golește” scoate tot. Ordinea din listă este ordinea din PDF.

Previzualizarea

- **Alăturat** / **Original** / **Procesat** alege ce vezi. Zonele se desenează pe *Original*; caseta de conținut se corectează pe *Procesat*.
- **Potrivește** mărește sau micșorează imaginea ca să încape. Glisorul de zoom (0,2×–4×) apare doar când *Potrivește* este debifat.

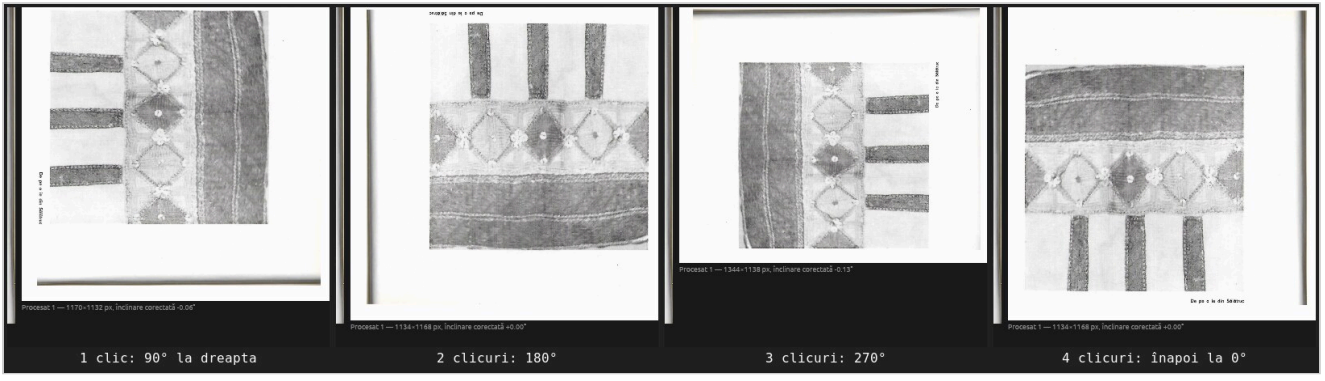


Cu „Potrivește” debifat apare glisorul de zoom (aici 1,00×).

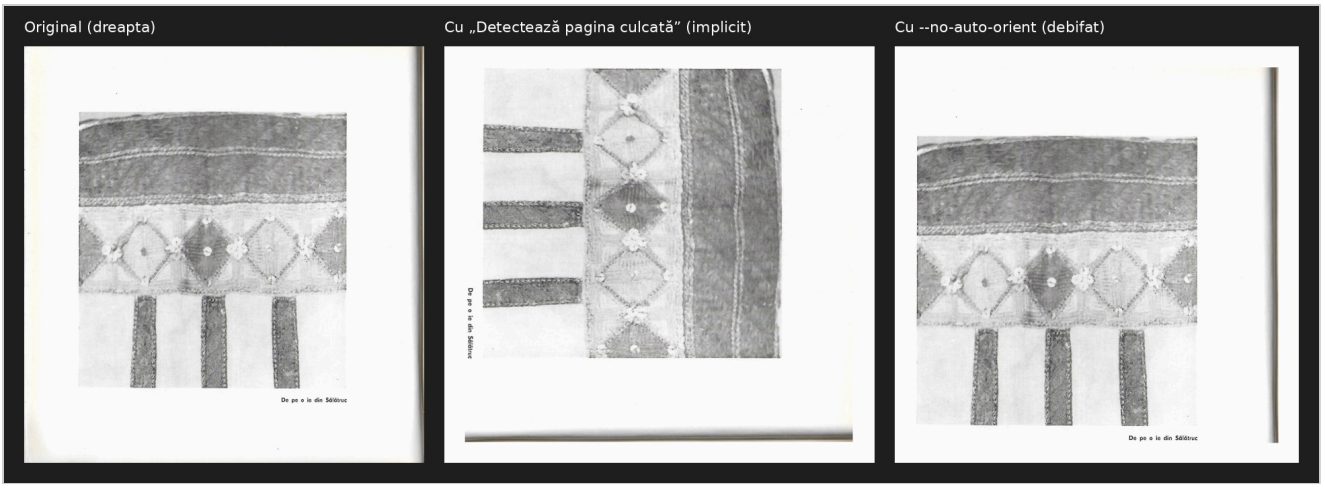
Bara „Această pagină”

Aici corectezi doar pagina aleasă: rotire la stânga sau la dreapta cu 90°, pași de ±45°, înclinare manuală, modul de separare a foii (implicit, automat, la mijloc, oprit), chenarul conținutului în milimetri (stânga, sus, dreapta, jos; valorile pozitive îl măresc) și „Resetează”. **Anulează** și **Refă** (Ctrl+Z, Ctrl+Y) merg pentru toate aceste comenzi, nu doar pentru zone.

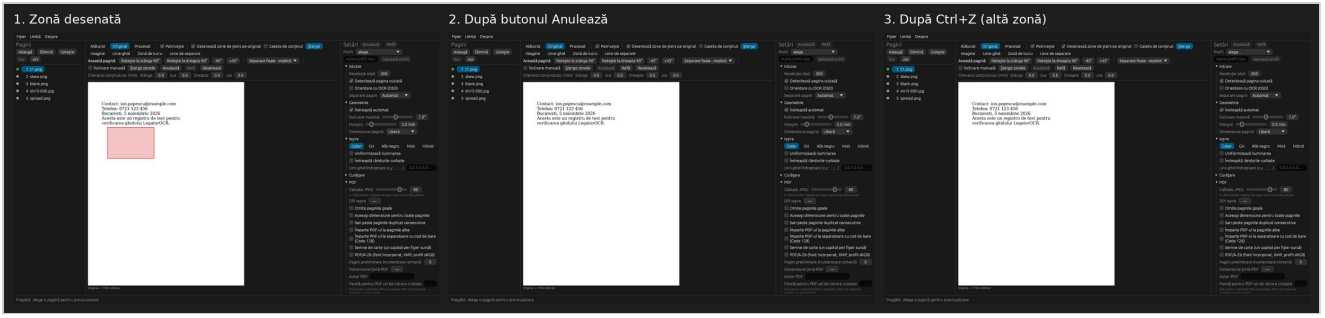
Rotirea manuală blochează orientarea automată (din pre.18): după ce apeși un buton de rotire sau ±45°, pagina nu mai este rotită de detectarea paginii culcate sau de OSD, nici măcar la 0°. „Resetează” îi dă înapoi orientarea automată. Dacă o pagină cu poze e rotită greșit de la început, apasă rotirea de patru ori (sau debifează „Orientare cu OCR (OSD)” și „Detectează pagina culcată” din setări, la Intrare).



Patru clicuri la rând pe „Rotește la dreapta 90°”: 90°, 180°, 270°, apoi înapoi la 0°, fără sărituri. Captură pre.18 pe Linux. Pe Windows 11 nu am putut verifica.



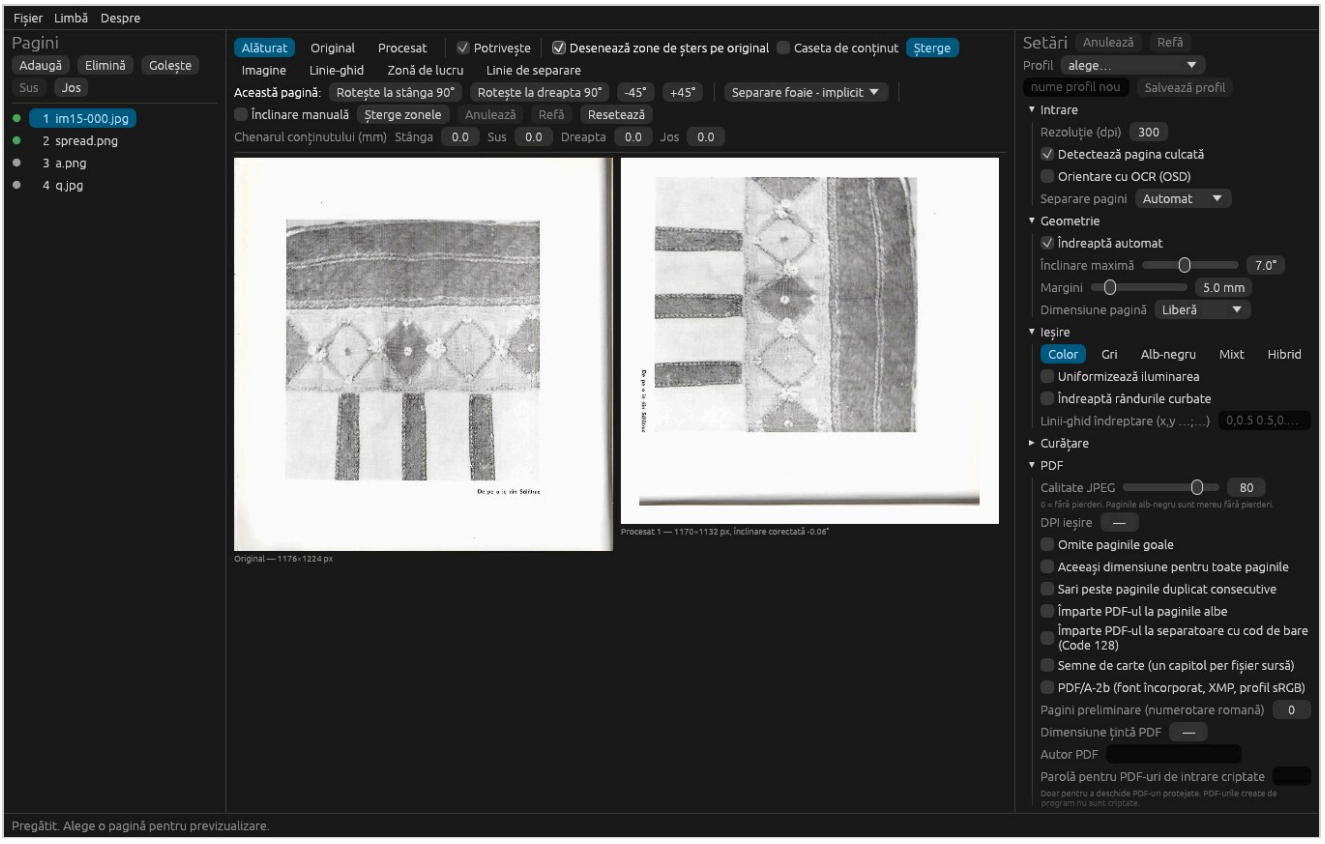
Aceeași pagină (pagina 15 din PDF-ul testerului) și aceleași setări, în afară de detectare: în pre.18, cu „Detectează pagina culcată” bifat (implicit), programul o rotea cu 90° deși originalul e drept (din pre.19–20 nu o mai rotește); cu --no-auto-orient (sau debifat în setări) iese dreaptă. Verificat în linia de comandă; în fereastră am văzut rotirea în pre.18 și lipsa ei în pre.19.



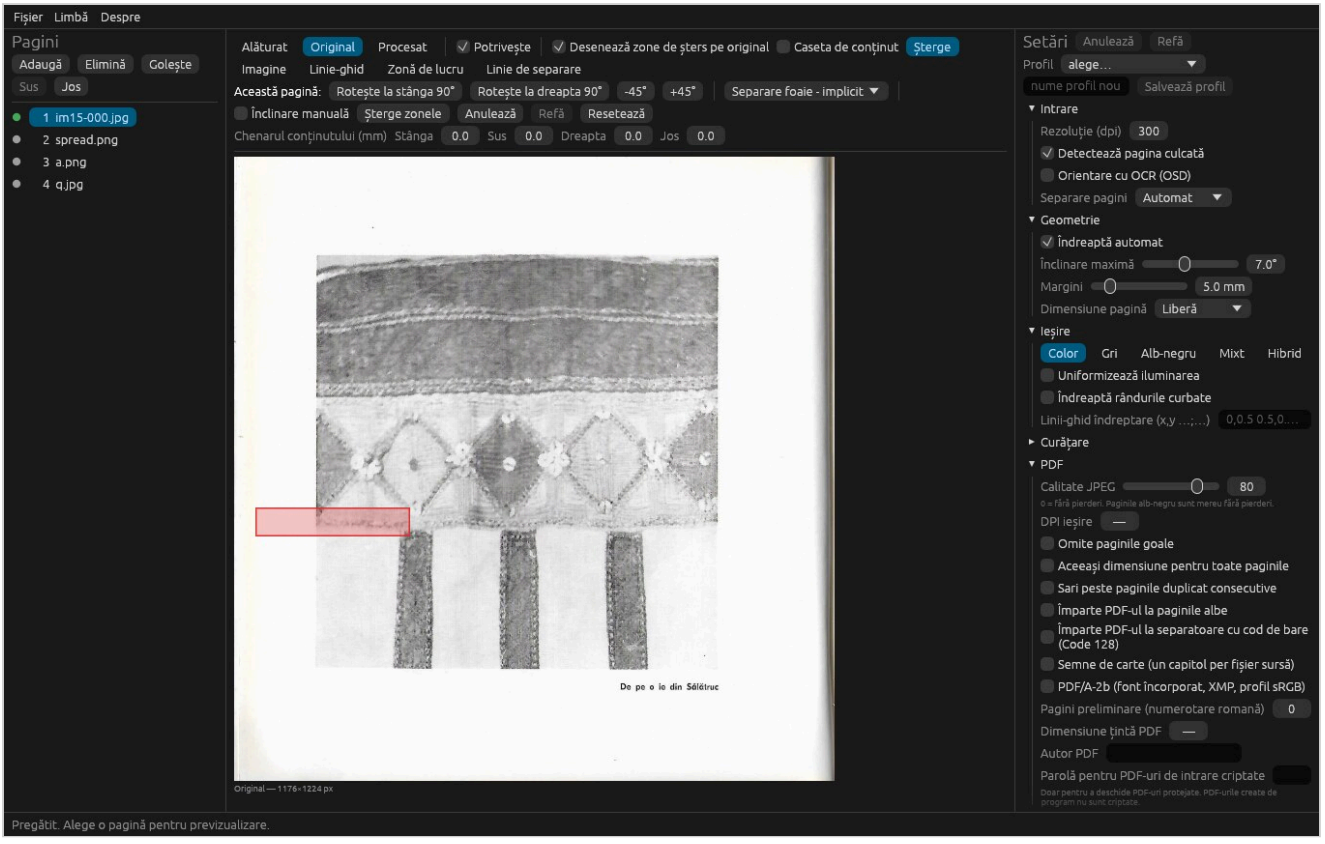
Anulează (butonul) și Ctrl+Z (cu fereastra în prim-plan) scot ultima zonă desenată. Verificat în fereastră.

Zone, ghidaje și caseta de conținut

Bifează „Desenează zone de șters pe original”; apar cinci tipuri de desen (Șterge, Imagine, Linie-ghid, Zonă de lucru, Linie de separare):

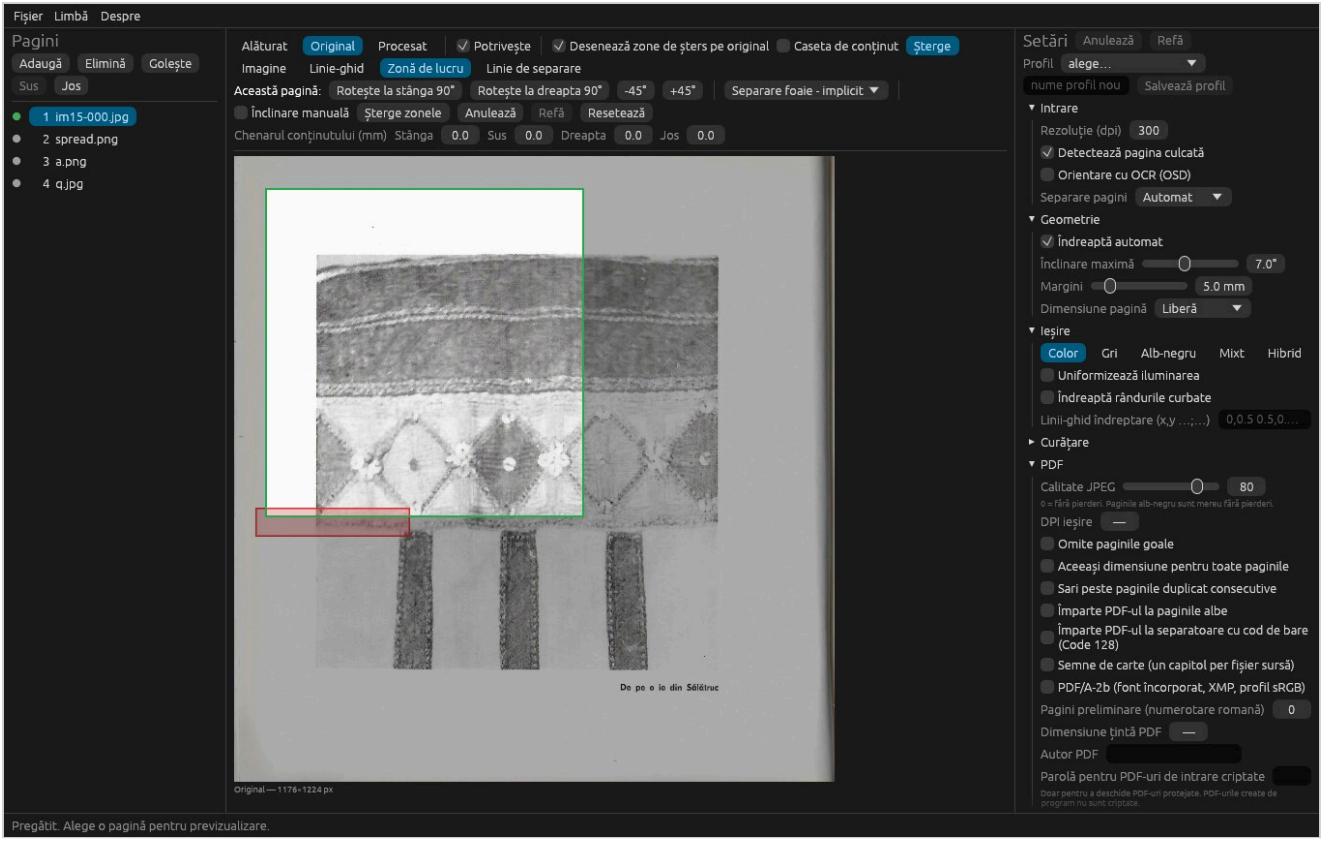


Cu „Desenează zone de șters pe original” bifat apar tipurile de zone: Imagine, Linie-ghid, Zonă de lucru, Linie de separare (și Șterge, tipul implicit).

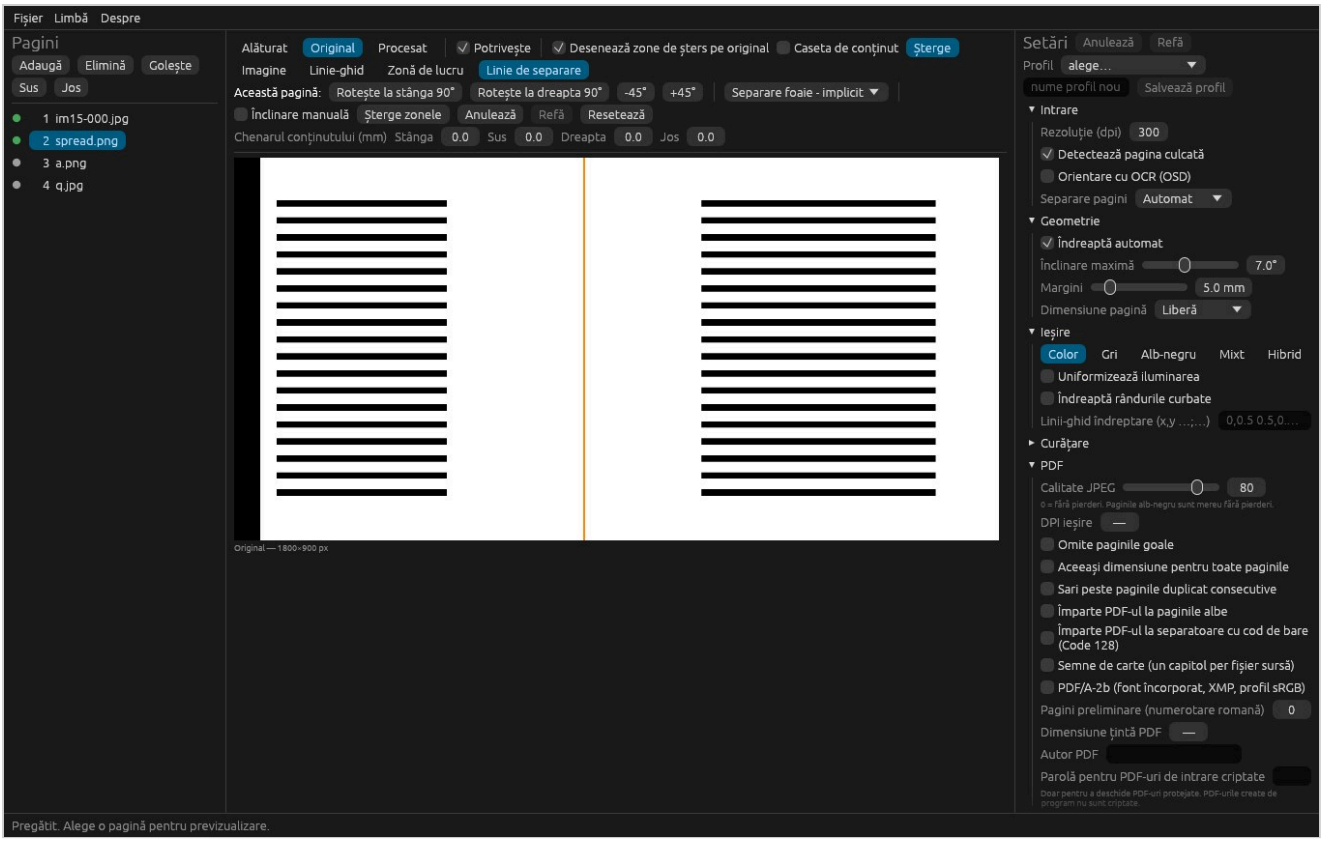


O zonă de șters (roșu) trasă cu mouse-ul pe original, în vizualizarea Original.

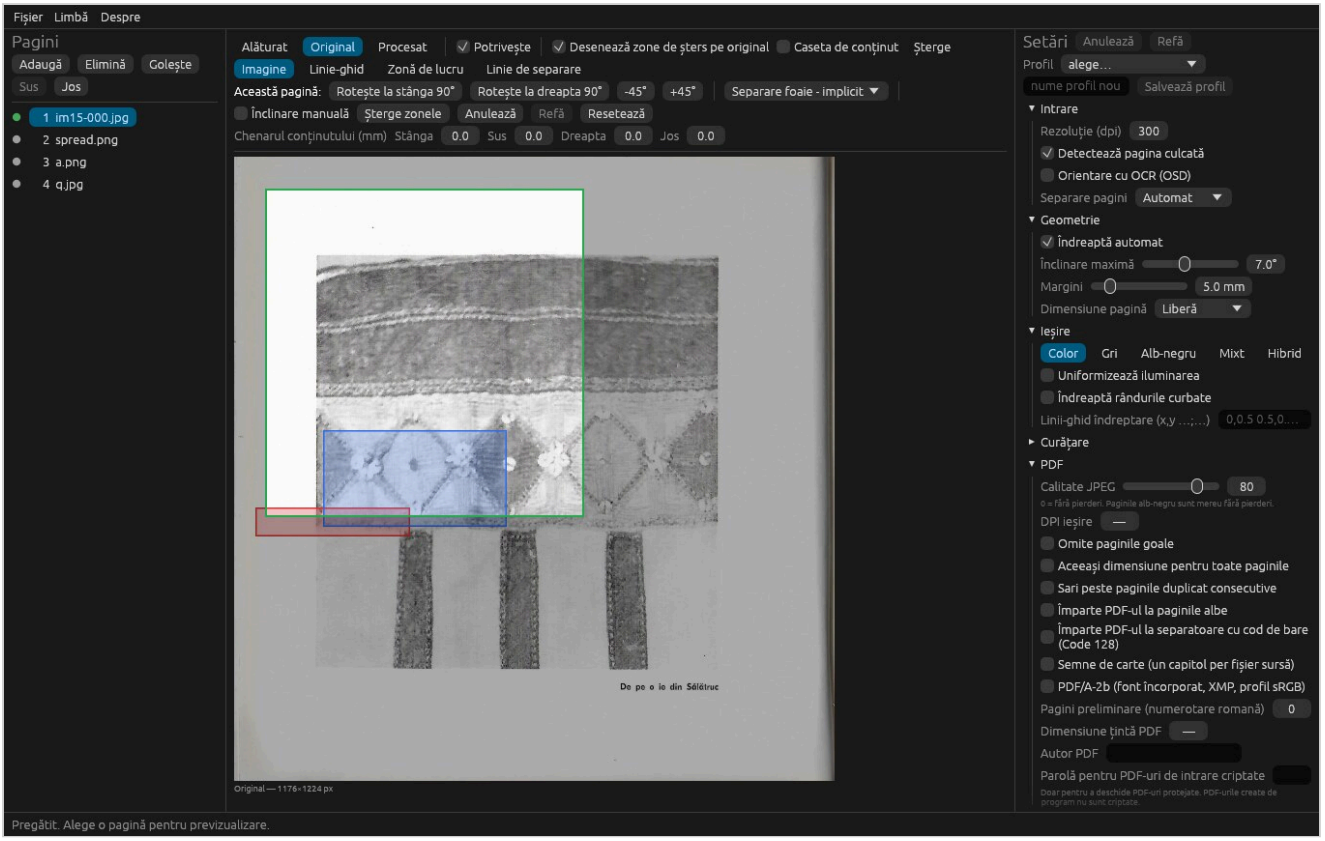
Tip	Cum îl folosești	La ce serve
Șterge	Tragi un dreptunghi pe original. Clic dreapta pe el îl șterge. Tragi de un colț ca să îl redimensionezi.	Pată, ștampilă, nota cuiva, marginea cu umbră
Imagine	La fel ca „Șterge”.	Spune programului că zona e imagine, nu text (rămâne în culori în modul mixt)
Linie-ghid	Tragi liber de-a lungul unui rând curbat. Tragi un nod ca să-l muți; dublu-clic pe linie adaugă un nod, dublu-clic pe nod îl șterge; clic dreapta pe linie o șterge.	Îndreaptă pagina după rândurile pe care le-ai trasat



Zona de lucru (cadru verde): tot ce e în afara ei este înlăturat, iar zona rămasă se vede în pagina procesată. Mai are și o zonă de șters (roșu).



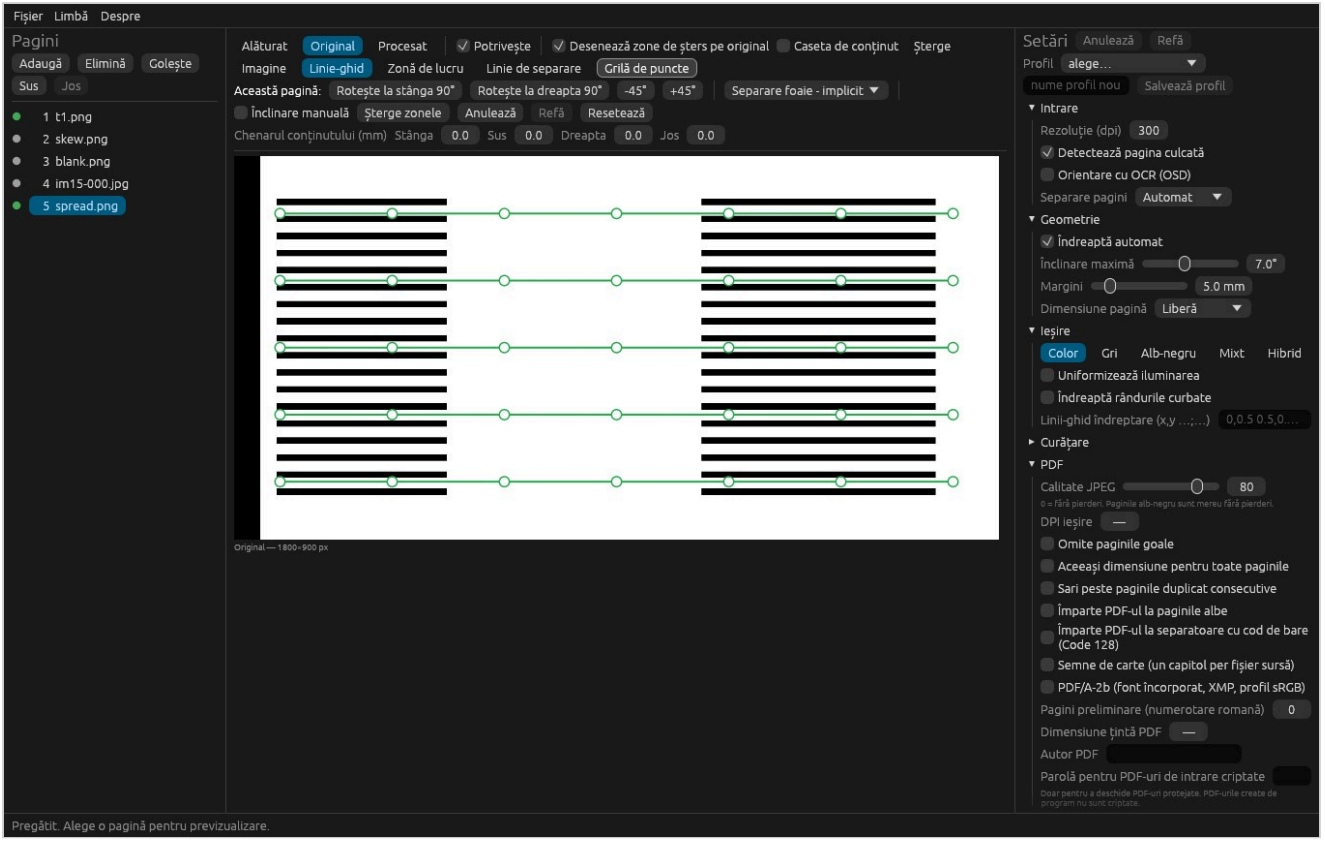
Linia de separare (portocalie) mutată cu mouse-ul pe o foaie dublă. Exemplul este o foaie de test sintetică, cu linii în loc de text.



O zonă de imagine (albastră) desenată pe original. În modul Color nu schimbă nimic; efectul se vede în modul Mixt (figura următoare).



Aceeași pagină și aceeași zonă de imagine (albastră): în modul Mixt zona rămâne gri (stânga), în modul Alb-negru totul devine alb-negru (dreapta). Pagina apare rotită cu 90° de detectarea paginii culcate (vezi mai sus).



„Grilă de puncte” la Linie-ghid: 5 linii a câte 7 puncte, peste rândurile de text.

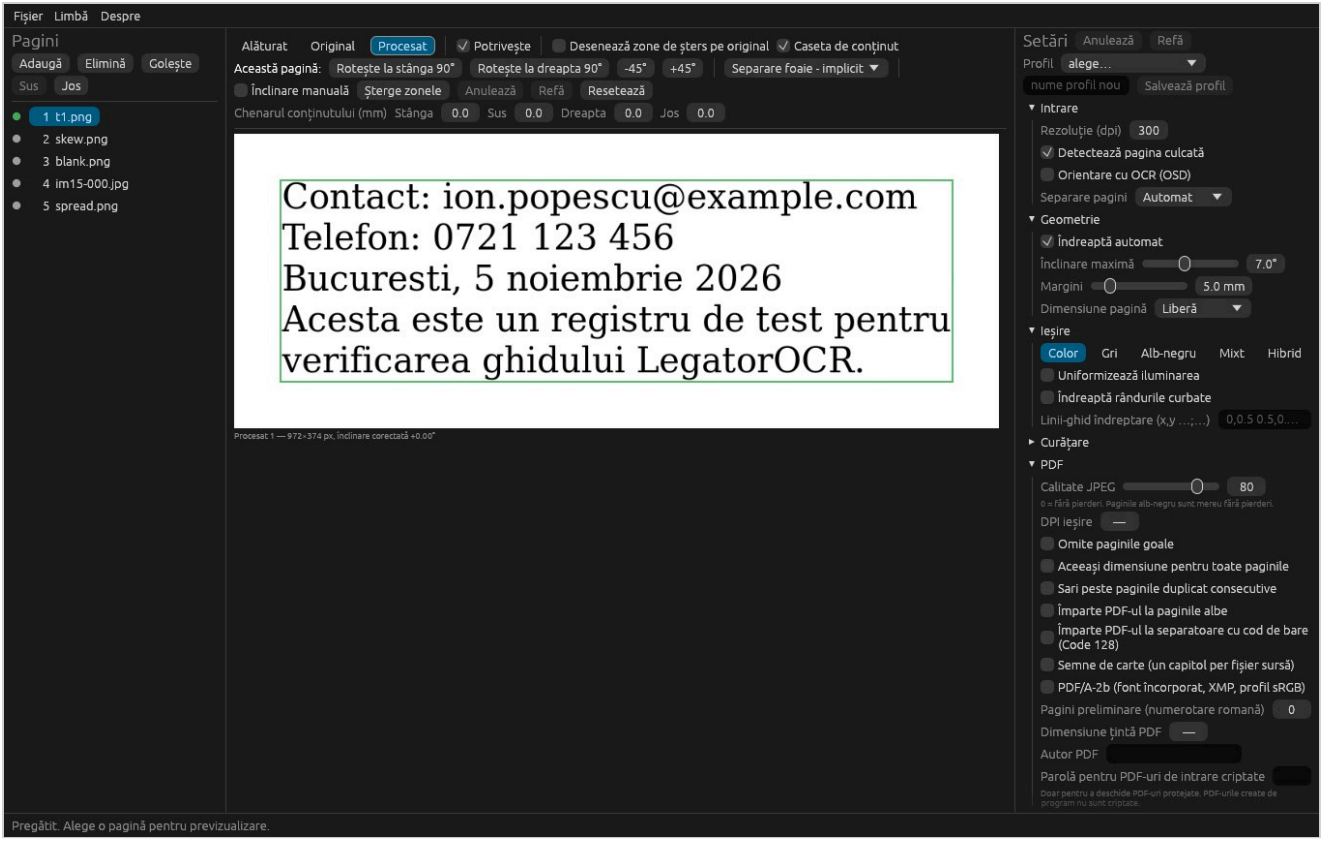
Grilă de puncte (la *Linie-ghid*) adaugă 5 linii a câte 7 puncte, peste care tragi punctele pe rândurile de text. Un al doilea clic pe buton nu mai adaugă aceeași grilă a doua oară. Dacă ai mutat deja puncte, o grilă nouă se adaugă pe lângă cea mutată.

Zonă de lucru (din ediția pre.18): tragi un dreptunghi pe original; tot ce e în afara lui este pictat cu culoarea hârtiei înainte de orice măsurare, deci o margine întunecată sau pagina vecină nu mai contează. Clic dreapta pe original îl elimină. În linia de comandă: `--work-area X,Y,L,H` (milimetri).

Linie de separare (din ediția pre.18): cu clic sau trăgând pe original muti linia verticală portocalie; foaia dublă se taie acolo, nu la mijloc sau la gutieră. Din pre.21 merge la orice rotire;

la foile rotite cu 90° sau 270° linia taie orizontal și paginile ies una sub alta (pagina din stânga a originalului prima). Clic dreapta o elimină. În linia de comandă: `--cut-at 0.45`.

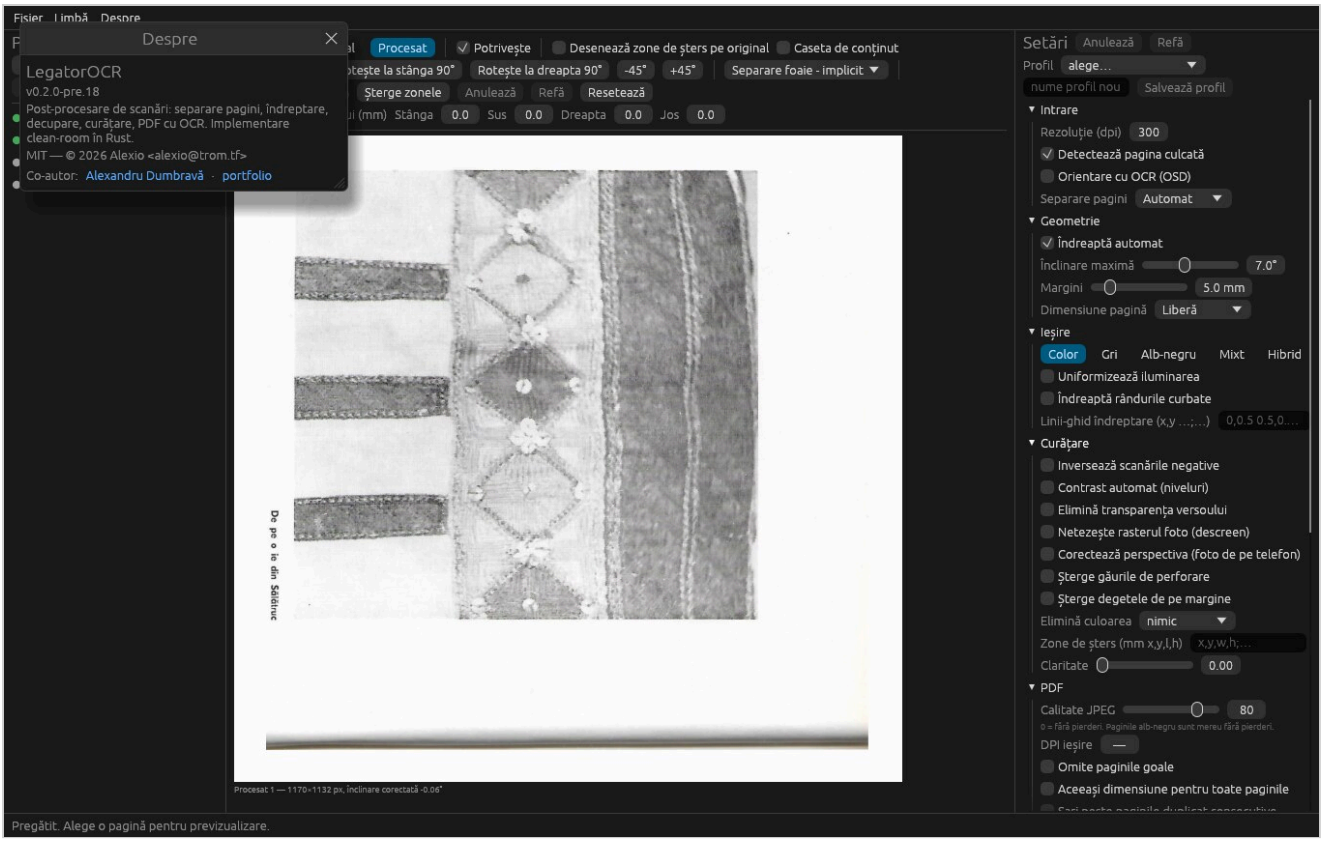
Caseta de conținut (bifa cu același nume) afișează pe pagina procesată un chenar verde. Tragi laturile ca să lărgești sau să înguste zona păstrată. La o foaie dublu-față, schimbarea se aplică ambelor pagini.



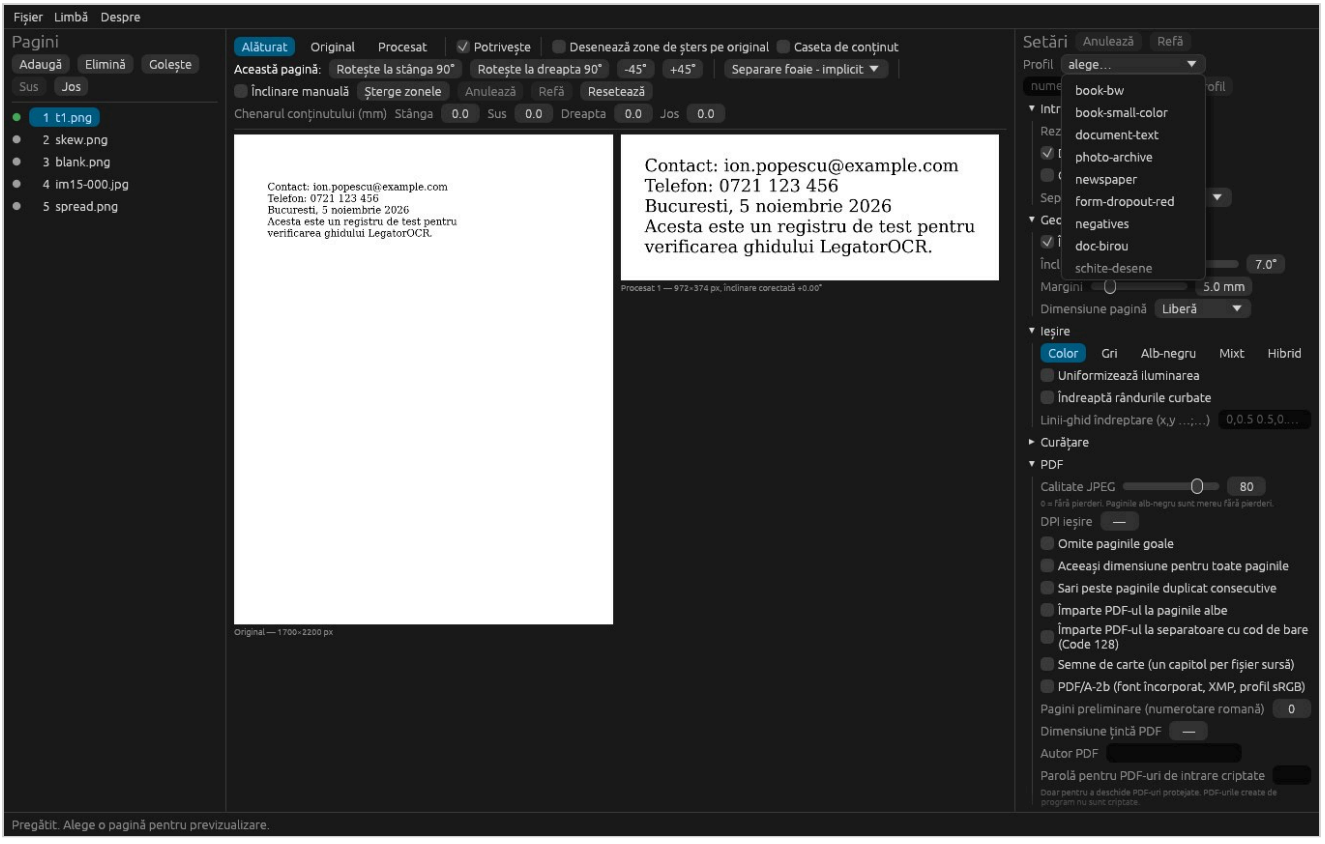
Caseta de conținut (chenar verde) pe pagina procesată.

Setările din dreapta

Se grupează pe secțiuni: Intrare, Geometrie, Ieșire, Curățare, PDF, OCR, plus profilele. Secțiunea 6 explică ce face fiecare.



Secțiunea Curățare din setări, desfăcută: inversare scanări negative, contrast automat, perspectivă, ștergerea găurilor de perforare, zone de șters ca numere.



Lista „Profil” din setări (profilurile integrate; ale tale apar în același loc după „Salvează profil”).

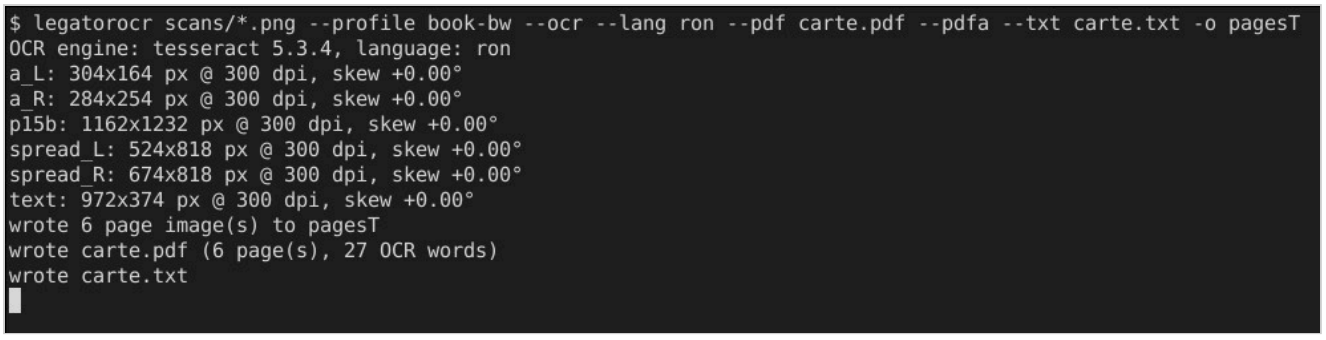
5. Linia de comandă: rețete pentru sarcini frecvente

Sintaxa generală: `legatorocr INTRARI... [opțiuni]`. Intrările pot fi imagini (PNG, JPEG, TIFF, BMP), PDF-uri scanate sau un folder. `legatorocr --help` listează toate opțiunile; `--list-profiles` arată profilele. Opțiunile din rețete sunt verificate automat înaintea fiecărei ediții, deci există cu adevărat; rețetele în sine nu au fost încercate toate pe material real.

Carte scanată → PDF cu text căutabil

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

`--pdfa` scrie PDF/A-2b pentru arhivare, iar `--txt` salvează și textul. `-o pages` este folderul pentru imaginile procesate.

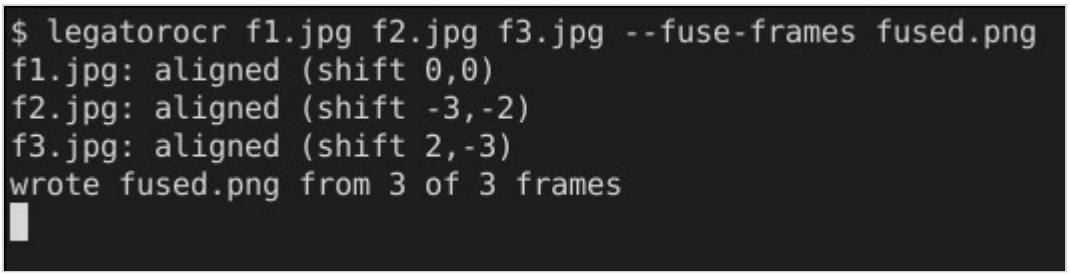


Rețeta pe 4 fișiere de test: 6 pagini în carte.pdf. Cu --pdfa programul scrie PDF/A-2b.

Poze de pe telefon → pagini curate

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

Profilul uniformizează lumina, lărgește intervalul de înclinare și scoate degetele. Mai multe poze ale aceleiași pagini se pot combina întâi cu `--fuse-frames` (ajută la zgomot puternic; la zgomot moderat nu). Opțiunea primește un fișier de ieșire: legatorocr poza1.jpg poza2.jpg poza3.jpg --fuse-frames pagina.png, apoi prelucrezi pagina.png ca de obicei; prima poză este referința.



--fuse-frames cu trei poze ale aceleiași pagini: le aliniază și scrie fused.png din 3 din 3 cadre.

Copie de arhivă cu dovadă de integritate

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

Pachetul păstrează originalele, proiectul, cuvintele OCR cu încredere, ieșirile și un `RUN.txt` care spune cum se reia lucrarea. Pentru copii pe alte discuri: `--backup-from` și `--backup-to`.

```
$ rm -rf registru-arhiva2; legatorocr scans/text.png --profile registre-manuscrise --ocr --lang ron --pdf registru2.pdf
--pdfa --checksums --archive-package registru-arhiva2 -o pagesT2; legatorocr --verify-sums registru-arhiva2/SHA256SUMS.t
xt
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 1 page image(s) to pagesT2
wrote registru2.pdf (1 page(s), 20 OCR words)
wrote registru-arhiva2/derived/ocr.json
archive package: registru-arhiva2 (6 files, 1 originals)
wrote ./SHA256SUMS.txt (2 file(s) added or updated)
5 ok, 0 mismatched, 0 missing
```

Pachetul de arhivă creat și verificat: „5 ok, 0 mismatched, 0 missing”.

Ascunderea numelor și a numerelor înainte de partajare

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

Cuvintele găsite sunt înnegrite în imagine și scoase din text. **Verifică rezultatul cu ochiul:** un cuvânt pe care OCR nu l-a recunoscut nu este ascuns.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Rezultat real: numărul de telefon a fost ascuns, dar adresa de e-mail NU, pentru că OCR a citit „@” ca „G” (ion.popescuGexample.com) și modelul de e-mail nu s-a potrivit. De aceea trebuie să verifici rezultatul cu ochiul. Din pre.20 programul scrie la sfârșit câte cuvinte a acoperit fiecare tipar și avertizează când un tipar nu a găsit nimic sau când au rămas în text cuvinte care par adrese sau numere lungi, exact ca în captura de mai sus.

Lot mare pe mai multe calculatoare

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Rulează aceeași listă pe fiecare mașină, cu alt `--shard`. Pentru memorie mică: `--max-memory 500`. Pentru fișiere necunoscute sau ostile: `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

Lotul împărțit în două (--shard 1/2 și 2/2) și unit apoi cu --merge-pdf.

Semnarea unui PDF

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

Nivelul juridic al semnăturii este cel al certificatului tău. Parola certificatului se dă prin variabila de mediu, nu pe linia de comandă. Marca de timp (`--sign-timestamp`) a fost verificată doar cu o autoritate locală prin HTTP, nu cu una reală prin HTTPS.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Semnarea și verificarea cu un certificat de test creat de mine (nu un certificat real). „time stamp inside: none”: n-am cerut marcă de timp.

Stivă scanată pe alimentator, ordine și interval de pagini

Multe scanere cu alimentator trec stiva o dată pe fiecare față: întâi toate fețele (1, 3, 5…), apoi toate versourile, în ordine inversă (6, 4, 2). Fișierele ies în ordinea scanării, nu a cărții. `--duplex-adf` le pune în ordinea de citire: față 1, verso 1, față 2, verso 2… Numărul de pagini trebuie să fie par (altfel programul se oprește cu un mesaj).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Șase fișiere în ordinea scanării (scan_001 … scan_006). `--dry-run` arată ordinea în care ar fi procesate și ce fișiere s-ar scrie, apoi se oprește fără să proceseze nimic: scan_006 ajunge pe locul 2, scan_005 pe locul 4.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

Aceeași comandă fără `--dry-run`, cu OCR nativ: textul iese în ordinea „Pagina 1 … Pagina 6” (pagini de test făcute de mine, nu o carte reală).

Alte opțiuni de ordine și selecție (se pot combina; intervalul se aplică numerotării fișierelor de intrare, de la 1):

- `--pages 1-10,15,20-`: păstrează doar paginile indicate; `20-` înseamnă „de la 20 până la capăt”. Merge și pe pagini luate din PDF-uri sau din foi TIFF cu mai multe pagini.
- `--reverse`: inversează ordinea (stivă scanată de la ultima pagină).
- `--dry-run`: verifică un lot mare înainte de rularea lungă.

Verificat: ordinea și intervalul cu teste automate și cu șase pagini de test; nu am încercat un scaner real cu alimentator. Aceste opțiuni există doar în linia de comandă, nu în fereastră.

Text curat: corecturi proprii, antete și cedilă

Pentru fișierele `.txt` și `.docx` (stratul de text din PDF, hOCR și JSON păstrează cuvintele citite, neschimbate):

- `--clean-text`: ș și ț cu virgulă dedesubt, cuvinte rupte la capăt de rând lipite (cu cratimă păstrată când cele două jumătăți sunt cuvinte din listă și lipirea simplă nu e), ghilimele tipografice, spații lângă punctuație. `--cedilla` scrie în schimb ş și ţ, pentru programe și fonturi care nu cunosc literele cu virgulă.
- `--find-replace FIȘIER`: propriile tale corecturi, câte una pe linie, `greșit => corect`. Rândurile care încep cu `#` sunt comentarii. Se potrivesc doar cuvinte întregi (`Ion => Ioan` nu atinge „Ionescu”) și se aplică în ordinea din fișier, după `--clean-text`. Utile pentru nume proprii, prescurtări sau o ștampilă pe care motorul o citește mereu la fel de greșit.
- `--drop-running-heads`: lasă afară antetele, subsolurile și numerele de pagină tipărite: prima sau ultima linie a unei pagini care se repetă (cifrele nu contează) pe cel puțin jumătate din pagini; trebuie cel puțin patru pagini. Liniile scoase sunt listate pe stderr, ca să vezi ce a plecat.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

Fișierul de reguli (primul bloc) și aceleași două linii citite de pe pagina de test fără și cu `--find-replace`: „Ionescu” a devenit „Ionescu-Vale” și „ha” a devenit „hectare”.

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

Pe șase pagini de test cu antetul „Anuarul Văii Mari” și un număr, programul a scos șase linii de antet; textul începe direct cu „Pagina 1”. Atenție: regula scoate orice prima/ultimă linie care se repetă, deci la o carte în care ultima linie a fiecărei pagini seamănă (de exemplu „Poziția în raft: 14”) ar pleca și acele linii; de aceea sunt listate. Funcția a fost verificată cu teste și pe câteva pagini, nu pe un set mare de cărți.

Alte rețete

Rețetele complete sunt în `docs/tasks/` din depozit, în engleză și română (verificare de document cu `--verify-document` și `--mrz`, copie de arhivă, lot mare).

6. Setări importante și când se folosesc

Profiluri

```
$ legatorocr --list-profiles | cut -c1-100
book-bw              Text books: auto threshold, black & white, punch holes removed
book-small-color     Colour books: sharp text over a light background, smallest files
document-text        Office documents: sharp text, pictures kept in colour
photo-archive        Archive quality colour, light sharpening
newspaper            Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red     Forms with red rules or stamps: drop red, erase ruled lines
negatives            Negative scans: invert and stretch contrast
doc-birou            Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene        Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise  Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim         Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft         Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum         Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma              Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta                Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura            Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos         Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof            user profile
```

legatorocr --list-profiles. Ultima linie (smokeprof) este un profil de test al meu, nu face parte din program.

Un profil este un set de setări gata făcut pentru un tip de material. Se alege din secțiunea „Profil” (interfață) sau cu `--profile NUME` (linie de comandă). Ai propriile profiluri: configurezi setările, scrii

un nume și apeși „Salvează profil”.

Profil	Pentru ce
`book-bw`	cărți cu text, alb-negru, găuri de perforare scoase
`book-small-color`	cărți color, text clar pe fundal deschis, fișiere mici
`document-text`	documente de birou, imagini păstrate color
`photo-archive`	fotografii, calitate de arhivă
`newspaper`	ziare: prag Wolf, pete eliminate mai puternic
`form-dropout-red`	formulare cu linii sau ștampile roșii
`negatives`	scanări negativ
`phone-photos`	poze de pe telefon
`registre-manuscrise`	registre și manuscrise vechi (300–600 dpi), culori păstrate
`schite-desene`	schițe și desene în creion (400 dpi)
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	fluxuri pentru documente de birou, de la calitate maximă la volum mare
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**neverificate pe probe reale**

Lista completă o dau `--list-profiles`.

Setările care contează cel mai mult

Setări	Ce face	Când o schimbi
Rezoluție (dpi)	cu cât sunt scanate paginile	când imaginea nu are dpi în antet; pentru text 300
Îndreaptă automat / înclinare maximă	limita unghiului corectat automat	când o pagină care iese „la limită” e de fapt strâmbă
Margini, dimensiune pagină, aceeași dimensiune	marginile în mm; pagină liberă, personalizată sau identică pentru toată cartea	pentru cărți cu formate amestecate
Mod de ieșire	color, gri, alb-negru, mixt (text 1-bit + imagini color), hibrid (+ fundal cu rezoluție mică)	alb-negru pentru text pur; mixt pentru text cu poze
Metodă prag	Sauvola (implicit), Wolf, Niblack, NICK, Bradley, Otsu sau automat	când textul iese pâlit sau plin de pete; `auto` încearcă mai multe pe fiecare pagină
Sensibilitate	sensibilitatea metodei Sauvola pentru ieșirea alb-negru	implicit 0,3; schimb-o în pași mici și compară rezultatul pe aceeași pagină
Sensib. imagini	cât de ușor e socotită o zonă drept imagine	în modul mixt/hibrid
Elimină petele mici	forța curățării de pete (0,25–4; 1 = implicit)	micșorează-o dacă dispar puncte sau diacritice; mărește-o dacă rămân pete
Dewarp (rânduri curbe)	îndreaptă rândurile arcuite lângă cotor	pentru cărți groase; se sare dacă nu se vede o curbură clară
Uniformizează iluminarea	egalizează fundalul	pentru poze cu umbră sau iluminare inegală
Calitate JPEG	0 = fără pierderi; paginile alb-negru sunt mereu fără pierderi	pentru fișiere mai mici (sugestie: încearcă 80–90 și compară mărimea și aspectul)
DPI ieșire	micșorează imaginea de ieșire la acest dpi (“—” = nu micșora)	pentru PDF mai mici; paginile sub 250 dpi sunt mărite automat înainte de OCR, deci o reducere prea mare nu ajută recunoașterea
PDF/A-2b	PDF pentru arhivare, cu font și profil de culoare incluse	pentru depunere în arhive; nu a fost verificat cu veraPDF pe ieșirile programului

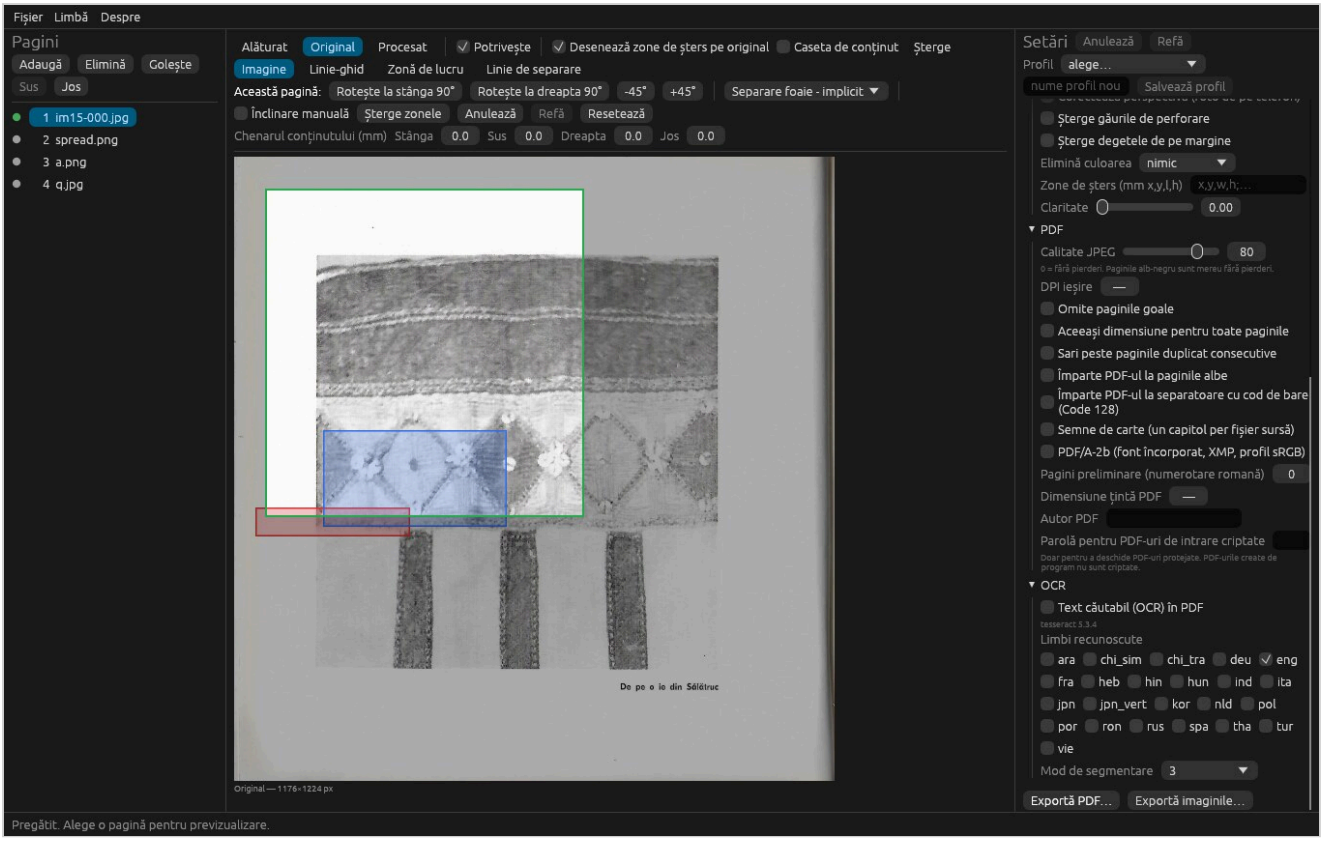
Formatele câmpurilor text

Aceste câmpuri există în setări, dar este mai ușor să desenezi pe original (secțiunea 4):

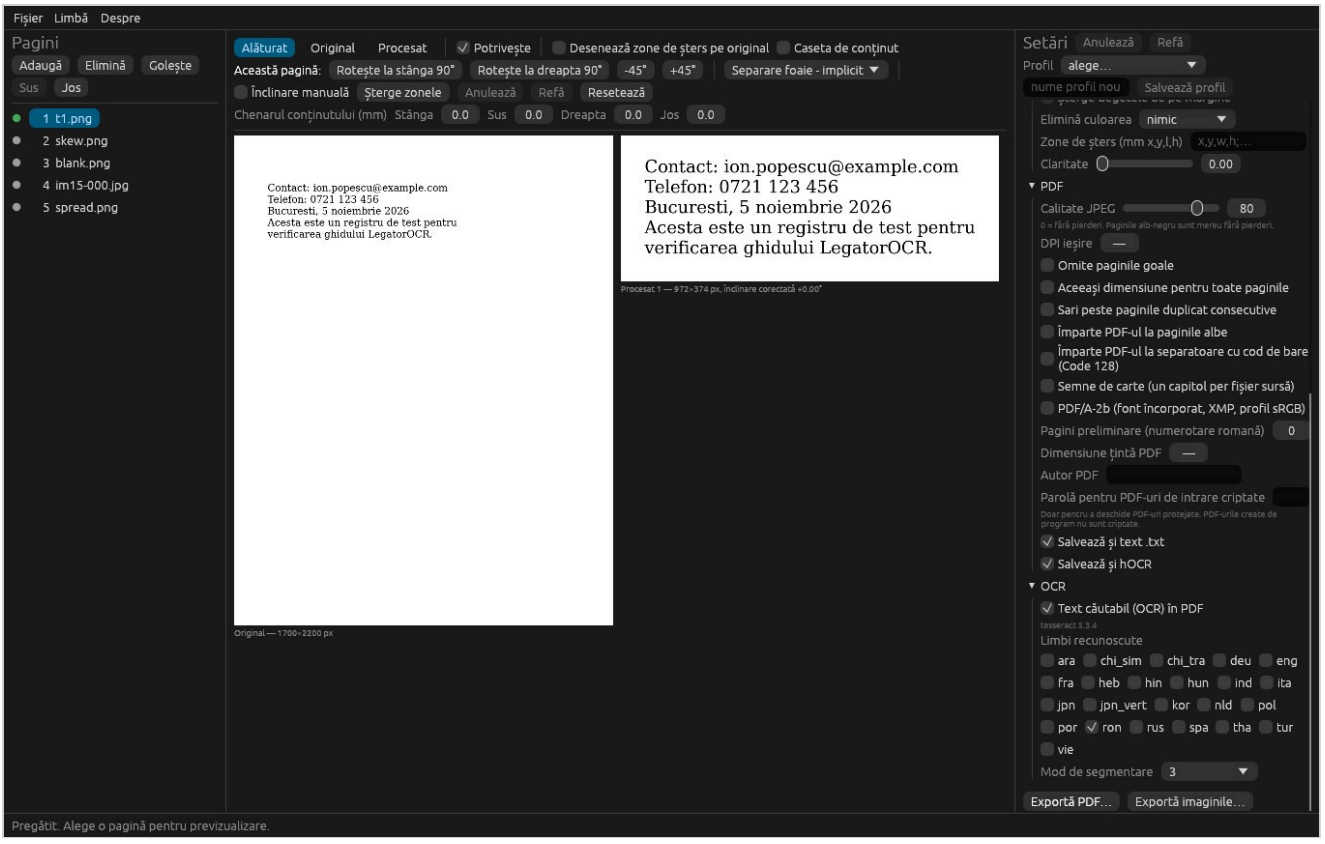
- **Zone de șters** și **Zone imagine**: `x,y,l,h` în **milimetri** de la colțul din stânga sus al paginii. Mai multe zone se separă cu punct-virgulă: 10,20,30,40;50,60,20,20. Cel mult 64; lățimea și înălțimea trebuie să fie pozitive. Dacă forma e greșită, câmpul se face roșu.
- **Linii-ghid îndreptare**: `x,y x,y x,y;x,y x,y x,y`, cu **fracții între 0 și 1** din pagina deja îndreptată (0,0 = colțul din stânga sus). Fiecare linie are cel puțin două puncte; în total cel mult 64 de linii.
- La linia de comandă: `--erase X,Y,W,H` (repetabil) și `--dewarp-guide "X,Y X,Y …"` (repetabil).

7. OCR: motoare, limbi și acuratețe

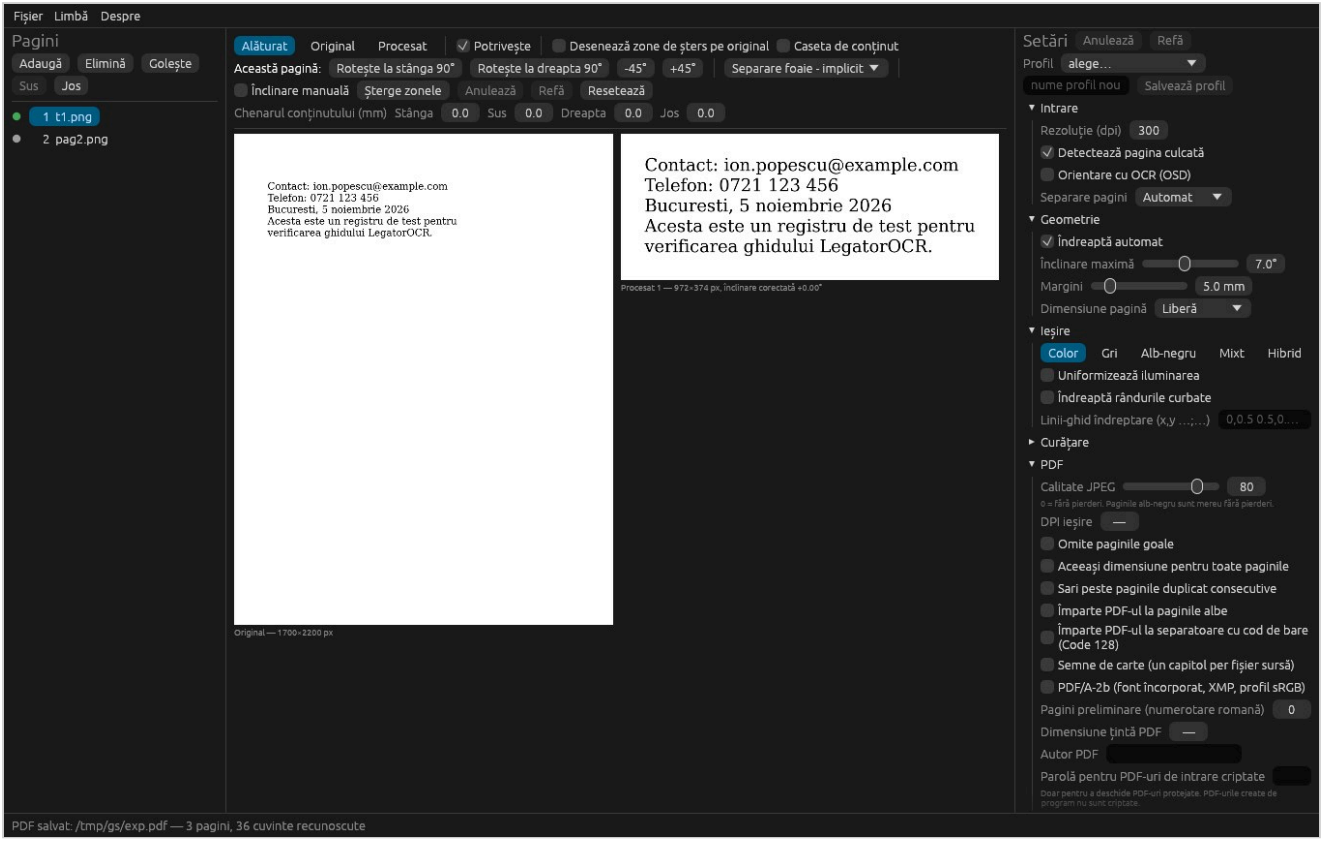
Bifa „Text căutabil (OCR) în PDF” (sau `--ocr` în linia de comandă) adaugă un strat de text nevăzut peste imagine. Limba se alege din „Limbi recunoscute” (sau `--lang ron`); poate fi combinată, de exemplu `ron+eng`. Limbile interfeței și ale motorului propriu: română, engleză, franceză, italiană, spaniolă, portugheză, germană, maghiară.



Secțiunea OCR din setări: bifa „Text căutabil (OCR) în PDF”, limbile recunoscute (cele instalate la Tesseract) și modul de segmentare. În captură era instalat Tesseract 5.3.4, de aceea apar toate limbile lui; alegerea ron am folosit-o în figura următoare.



Cu OCR bifat apar și „Salvează și text .txt” și „Salvează și hOCR”. Aici limba aleasă este ron.



După export, bara de jos arată: „PDF salvat: … — 3 pagini, 36 cuvinte recunoscute”. (Exportul l-am pornit cu un mecanism de test al programului, nu din dialogul de fișiere.)

Trei motoare

Motor	Cum îl alegi	Note
Nativ (al programului)	`--engine native`	fără instalare, scris în Rust; model antrenat pe text sintetic, apoi ajustat pe linii dintr-o revistă românească și dintr-un manual din 1960
Tesseract	`--engine tesseract`	program separat, vezi secțiunea 2; folosit automat când e instalat și are limba cerută (`--engine auto`, implicit)
Punte ONNX	`--engine tesseract --tesseract scripts/engine-onnx.py`	pentru utilizatori avansați; necesită Python, onnxruntime și modele descărcate separat



Aceeași pagină de test citită de cele două motoare. Ambele au greșit la fel: „@” a ieșit „(a” la motorul nativ și „G” la Tesseract.

Cifrele măsurate (și ce nu spun)

S-au măsurat 8 pagini bune dintr-o revistă românească, față de un text de referință produs de ABBYY, nu corectat de om. Rata de erori pe caractere, cu diacritice (măsurătoarea originală, din ediția 0.2.0-pre.21; la o nouă măsurare în pre.26 pe aceleași 8 pagini, cu aceeași metodă, motorul nativ a dat 2,76 %; diferența față de 2,55 % nu am investigat-o):

Motor	Erori pe caractere
Nativ	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (cu Tesseract)	4,62 %

Citit simplu: motorul nativ greșește mai puțin **pe acest tip de tipar**. Dar a fost ajustat pe text din aceleași surse, deci nu se poate spune că e mai bun în general. Pe alte documente, mai ales tipar vechi sau neobișnuit, poate fi mai slab decât Tesseract. Recunoașterea cuvintelor întregi este aproape egală între motoare (aproximativ 92 %).

Modul precis și ortografia veche

- `--accurate` (motorul nativ): fiecare linie este citită de trei ori (deplasată cu un pixel în sus și în jos) și probabilitățile se mediază. Este mai lent (măsurat: cu 18 % până la 74 % mai mult timp) și a ajutat doar pe paginile de revistă (eroarea pe caractere 3,66 % → 3,39 % pe 12 pagini); pe cărți și broșuri nu a schimbat nimic măsurabil. Este oprit implicit.

- Lista de cuvinte românești acceptă și ortografia din 1953–1993 (`cuvînt`, `romîn`, `sînt`): pe cinci pagini dintr-un manual din 1960, transcrise de mână, caracterele corecte au crescut de la 99,6 % la 99,7 % și cuvintele de la 96,0 % la 96,3 %. O diferență mică, pe cinci pagini.
- Cuvintele sunt despărțite la spațiile largi chiar când rețeaua nu a scris spațiu: celulele unui tabel nu mai ies lipite (`CantitatePreț`). Un tabel cu linii e găsit ca un singur tabel (Excel: `--tables-xlsx`); un tabel fără linii este încă găsit ca două tabele (stânga și dreapta), problemă nerezolvată.

Sfaturi

- Pe documentele tale, compară motoarele pe 5–10 pagini înainte de lot: `scripts/compare-ocr-text.py` măsoară erorile față de texte de referință pe care le ai tu.
- Paginile sub 250 dpi sunt mărite automat înainte de recunoaștere.
- Paginile cu ilustrații sau diagrame pot produce text fără sens în zona imaginii (Tesseract a citit o ilustrație drept text pe una din paginile măsurate). Verifică aceste zone.
- Orice OCR poate inventa sau pierde cuvinte. Pentru acte, registre sau cifre, verifică prin sondaj.

8. Ieșiri și arhivare

Ce vrei	Cum
PDF cu text căutabil	`--pdf FISIER.pdf --ocr` (interfață: Exportă PDF cu OCR bifat)
PDF pentru arhivare (PDF/A-2b)	`--pdfa`; alte părți cu `--pdfa-part 1` sau `3`
Imagini procesate	`-o FOLDER`, cu `--format png`, `jpeg` sau `tiff`; `--format none` nu scrie imagini
Text simplu al paginilor	`--txt FISIER.txt`
hOCR	bifa „Salvează și hOCR”
Structură pentru accesibilitate	`--tagged ro` (paragrafe etichetate). Conformitatea PDF/UA **nu** a fost validată
Copie DjVu	`--djvu FISIER.djvu`
Dovadă de integritate	`--checksums` și `--archive-package DIR`, apoi `--verify-sums`
Proiect (setări și corecturi)	Fișier → Salvează proiectul (`.lgr`), sau `--save-project`; `--embed-project` îl ascunde în PDF

Despre PDF/A

Programul scrie PDF/A-2b cu font și profil sRGB încorporate. Conformitatea a fost verificată pe eșantioane, **nu** cu veraPDF pe orice ieșire. Dacă o instituție cere conformitate certificată, rulează propriul validator pe fișierele finale.

Despre proiectele ScanTailor

`--project FISIER.ScanTailor` deschide un proiect ScanTailor: lista de scanări și rotirea per imagine sunt preluate, iar înclinarea, separarea și caseta de conținut sunt găsite din nou. Cititorul a fost scris după descrierea formatului și testat pe un proiect făcut manual, nu pe fișiere din orice versiune ScanTailor.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project și --project: proiectul se salvează și se redeschide cu același rezultat (2 pagini). Atenție: în pre.18, --work-area și --cut-at nu se păstrau în proiect; corectat în pre.19 (verificat: proiectul salvat și redeschis dă aceleași pagini).

9. Probleme frecvente și limite cunoscute

Simptom	Ce să verifici
Pagina iese tăiată sau cu prea mult alb	caseta de conținut (secțiunea 4); chenarul în mm din bara „Această pagină”
Pagină înclinată rămâne înclinată	înclinarea maximă permisă; setează unghiul manual
Foaia dublu-față nu se taie unde trebuie	modul de separare al paginii: „la mijloc” sau „oprită”; din pre.18 poți trage o „Linie de separare” pe original sau folosești `--cut-at 0.45`
Un câmp text se face roșu	formatul câmpului (secțiunea 6): milimetri pentru zone, fracții 0–1 pentru ghidaje
Textul OCR are greșeli	compară motoarele (secțiunea 7); verifică rezoluția; treci la Tesseract sau invers
Panoul „De verificat”	pagini marcate ca suspecte (goală, înclinare la limită, nimic găsit, conținut lipit de margine); nu sunt neapărat greșite, dar merită privite
Nu merge fereastra pe Windows sau în RDP	lipsa OpenGL 2+; încearcă driverul plăcii video
Aplicația macOS nu pornește	nu e semnată: clic dreapta → Open sau comanda `xattr` din secțiunea 2

Limite cunoscute ale ediției 0.2.0-pre.26

- Rotirea cu 90°: la o pagină cu o fotografie de ornamente (pagina 15 dintr-un PDF) un tester pe Windows a văzut rotirea sărind de la 90° la 180°. Am reprodus pe Linux o parte a problemei: în pre.18, cu „Detectează pagina culcată” bifat (implicit), programul rotea greșit cu 90° această pagină, deși originalul e drept (figura din secțiunea 4). Pragul din pre.19 era prea fragil (am descoperit între timp că o altă pagină a aceluiași PDF, pagina 13, tot se rotea greșit). În pre.20 detectorul numără doar piesele de mărimea unei litere și se abține la paginile cu poze sau cu puține cuvinte. Pe 98 de pagini de carte (rotite la 0° și 90°) și 5 pagini cu poze, rezultatul e identic cu pre.18, în afară de pagina 13 (rotită greșit în pre.18, acum dreaptă) și o pagină cu poză culcată, pe care detectorul nu mai întoarce (rămân OSD și rotirea manuală). Verificat în linia de comandă, pe Linux, pe un corpus mic. Cauza probabilă a săriturii (orientarea automată se aduna peste rotirea manuală) a fost corectată în pre.18: după un clic pe rotire pagina rămâne blocată, iar patru clicuri dau 90°, 180°, 270° și înapoi la 0° (verificat în fereastră, pe Linux). Ce a văzut exact testerul pe Windows 11 nu am putut verifica. Dacă o pagină cu poze tot e rotită greșit, debifează „Detectează pagina culcată” sau folosește --no-auto-orient.

- Zona de lucru, linia de separare mutabilă, zonele de șters și de imagine, grilă de puncte, Anulează și Ctrl+Z, caseta de conținut, OCR și exportul PDF au fost încercate într-o fereastră reală pe Linux, cu mouse simulat (capturile din ghid). Redimensionarea unei zone din colț a mers în fereastră. Dialogurile native de fișiere („Exportă PDF…”, „Salvează proiect”, „Deschide proiect”) au mers cu dialogul GTK al unui portal xdg pe Linux; pe Windows și macOS nu le-am încercat. Dacă sistemul nu are niciun dialog, din pre.21 fereastra spune asta în loc să nu facă nimic (poți trage fișierele în fereastră sau folosi linia de comandă). Salvarea unui profil propriu a mers. Efectul liniei de separare l-am verificat prin teste automate, cu --cut-at și în fereastră (o foaie dublă tăiată în două pagini inegale, 524 și 674 px). La foile rotite cu 90° sau 270° (din pre.21) paginile ies una sub alta; asta e verificat doar printr-un test automat, nu în fereastră.

  --save-project: în build-ul publicat pre.18, --work-area și --cut-at date în linia de comandă nu se păstrau în fișierul .lgr (găsit în verificarea acestui ghid). Corectat în pre.19. Dacă folosești pre.18, dă opțiunile din nou la --project, nu doar din proiect.

- Interfața grafică nu a fost verificată de oameni pe Windows, macOS sau arm64.
- Verificarea PDF/UA, factura electronică CIUS-RO și marca de timp prin HTTPS cu o autoritate reală nu au fost validate.
- Pentru o copie PDF/A certificată, validatorul este al tău (de exemplu veraPDF).
- Dreptul de utilizare a modelului OCR propriu (antrenat parial pe pagini cu drepturi neclarificate) este o chestiune deschisă la autor; vezi `docs/audit/assets-licences.md`.

10. Cum raportezi o problemă

Cea mai utilă contribuție este un raport de pe un sistem pe care autorul nu l-a încercat. Durează cinci minute:

1. Descarcă ultima ediție pentru sistemul tău.
2. Rulează `legatorocr --doctor` și copiază tot rezultatul.
3. Rulează o pagină pe care poți să o partajezi: `legatorocr PAGINA.jpg --ocr --pdf rezultat.pdf -o pagini`.
4. Deschide `rezultat.pdf`: pagina e dreaptă și decupată cum trebuie? Textul se selectează și se caută?

Trimite, ca problemă în depozitul `chiuta/LegatorOCR` (sau prin e-mail):

- sistemul și versiunea (de exemplu Windows 11 23H2, macOS 15 arm64, Debian 12 arm64);
- versiunea LegatorOCR;
- rezultatul comenzii `--doctor`;
- comanda rulată (sau setarea din interfață);
- ce te așteptai și ce s-a întâmplat (text de eroare sau captură de ecran);
- dacă imaginea poate fi partajată.

Nu trimite documente cu date personale. Un raport „totul a mers” este tot folositor: este singura cale prin care autorul află că un sistem funcționează.

Probleme de securitate se raportează conform `SECURITY.md`, nu public.