LegatorOCR – Guia do utilizador

Edição 0.2.0-pre.61 (versão de teste). Texto em elaboração, em português.

1. O que é o LegatorOCR

O LegatorOCR transforma digitalizações ou fotografias de páginas num PDF limpo, com texto pesquisável. Resolve o mesmo problema que o ScanTailor (separação das páginas, correção da inclinação, recorte, limpeza), mas acrescenta exportação para PDF e OCR. Está escrito em Rust, com código próprio, e cada etapa é uma técnica de manual. Funciona localmente, sem conta e sem enviar as páginas para a internet. Licença: MIT.

Há dois modos de trabalho, com os mesmos motores por baixo:

- **A interface gráfica** (`legatorocr-gui`): adiciona-se páginas, vê-se o original e o resultado lado a lado, corrige-se página a página e exporta-se.
- **A linha de comandos** (`legatorocr`): para lotes grandes, para automatização e para opções que a interface não mostra.

O que faz

- separa as folhas de dupla página em duas páginas, corrige as páginas inclinadas e recorta as margens;
- limpa o fundo, as manchas, os furos de perfuração, os dedos na margem e as linhas de formulário;
- escreve PDF (incluindo PDF/A para arquivo) ou imagens, com OCR em romeno e noutros 7 idiomas;
- produz também texto simples (`.txt`) e hOCR, e pode assinar ou datar o PDF.

O que não faz (ou não foi demonstrado)

- É uma versão de teste (0.2.0-pre.61). Foi executada pelo autor e pelo seu assistente apenas em Linux; **Windows, macOS e os processadores arm64 não foram experimentados por pessoas**.
- A exatidão do OCR foi medida em 8 páginas boas de uma única revista romena, face a um texto de referência produzido por outro programa, não corrigido por uma pessoa. Não a tome como garantia para outros tipos de impressão.
- O OCR pode errar: verifique por amostragem as páginas importantes.

2. Instalação e primeira execução

Descarregue o arquivo para o seu sistema na página de edições (Releases) do repositório `chiuta/LegatorOCR`. Cada arquivo tem um ficheiro `.sha256` para verificação.

Sistema	Ficheiro	Notas
Linux x86-64 ou ARM64	`.tar.gz`	precisa de OpenGL 2+ e de X11 ou Wayland
Windows x86-64	`.zip`	precisa de OpenGL 2+; em sessões RDP simples pode faltar
macOS Apple-silicon ou Intel	`.zip` com `LegatorOCR.app`	**não assinado**: no primeiro arranque clique direito → Open, ou `xattr -dr com.apple.quarantine LegatorOCR.app`

Também pode compilar a partir do código-fonte: `cargo build --release` (requer Rust 1.95 ou mais recente).

OCR

O programa tem um motor de OCR próprio, que funciona sem instalação. Opcionalmente pode instalar o Tesseract, um programa separado, que o LegatorOCR usa automaticamente quando está presente e tem o idioma pedido:

- Linux (Debian/Ubuntu): `sudo apt install tesseract-ocr tesseract-ocr-ron`
- macOS: `brew install tesseract tesseract-lang`
- Windows: `winget install UB-Mannheim.TesseractOCR` e adicioná-lo ao `PATH`

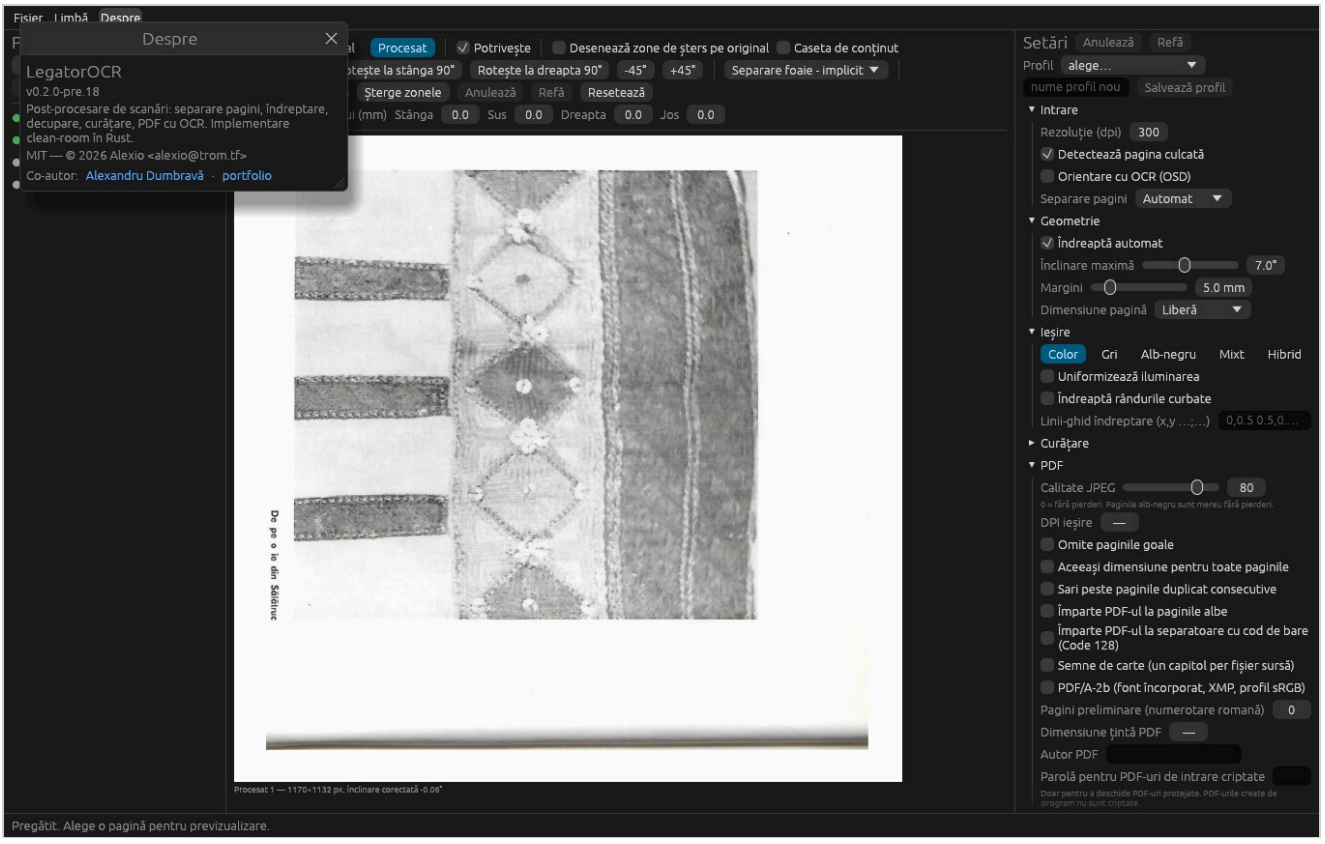
O modelo romeno dos pacotes `apt` e `brew` é a variante pequena („fast”). A variante „best” descarrega-se manualmente e indica-se com `--tessdata DIR`. Qual delas lê melhor as suas páginas não foi medido.

Verificar a instalação

Execute `legatorocr --doctor`. Mostra a versão, o motor de OCR nativo, o Tesseract e os modelos de idioma, e depois as ferramentas auxiliares (`pdftoppm`, `gs`, `qpdf`, `mutool`). O resultado „missing” numa ferramenta opcional não é um erro; a mensagem por baixo diz se ela é necessária. Se algo não funcionar, copie todo o resultado do comando para um relatório (veja a secção 10).

```
$ legatorocr --doctor
[ok     ] legatorocr                        0.2.0-pre.19
[ok     ] native OCR engine                 built in
[ok     ] tesseract                         tesseract 5.3.4
[ok     ] tesseract model ro (Romanian)     installed
[ok     ] tesseract model en (English)      installed
[ok     ] tesseract model fr (French)       installed
[ok     ] tesseract model it (Italian)      installed
[ok     ] tesseract model es (Spanish)      installed
[ok     ] tesseract model pt (Portuguese)   installed
[ok     ] tesseract model de (German)       installed
[ok     ] tesseract model hu (Hungarian)    installed
[ok     ] pdftoppm                          pdftoppm
[missing] mutool                            not found
          -> optional: alternative renderer for those cases
[ok     ] gs                                gs
[ok     ] qpdf                              qpdf
14 check(s) ok, 1 missing. Missing helpers are optional unless a hint says otherwise.
```

O resultado do comando legatorocr --doctor (pre.20, Linux, num terminal real; o mesmo vale para todas as capturas de terminal do guia, feitas com xterm): „missing” em mutool é uma ferramenta opcional, não um erro.



O menu Acerca de mostra a versão instalada (aqui 0.2.0-pre.18). Captura da compilação pre.18 em Linux, interface em romeno.

3. O fluxo de trabalho, passo a passo

Para cada página, o programa percorre as etapas abaixo por esta ordem. A análise faz-se numa cópia de aproximadamente 150 dpi, e o resultado é depois aplicado à digitalização na sua resolução completa.

1. **Orientação.** Detetam-se as páginas deitadas (um quarto de volta), pelas letras da página: uma página com fotografias ou com poucas palavras não é rodada por este teste. Para a direção exata pode usar-se o Tesseract (OSD) ou a rotação manual.

2. **Separação da folha.** Uma folha apaisada com duas páginas corta-se ao meio, na faixa vazia do centro. Pode ser automática, ao meio ou desligada.

3. **Correção da inclinação.** Estima-se o ângulo de inclinação a partir das linhas de texto e a página é rodada de volta. O ângulo pode ser fixado manualmente.

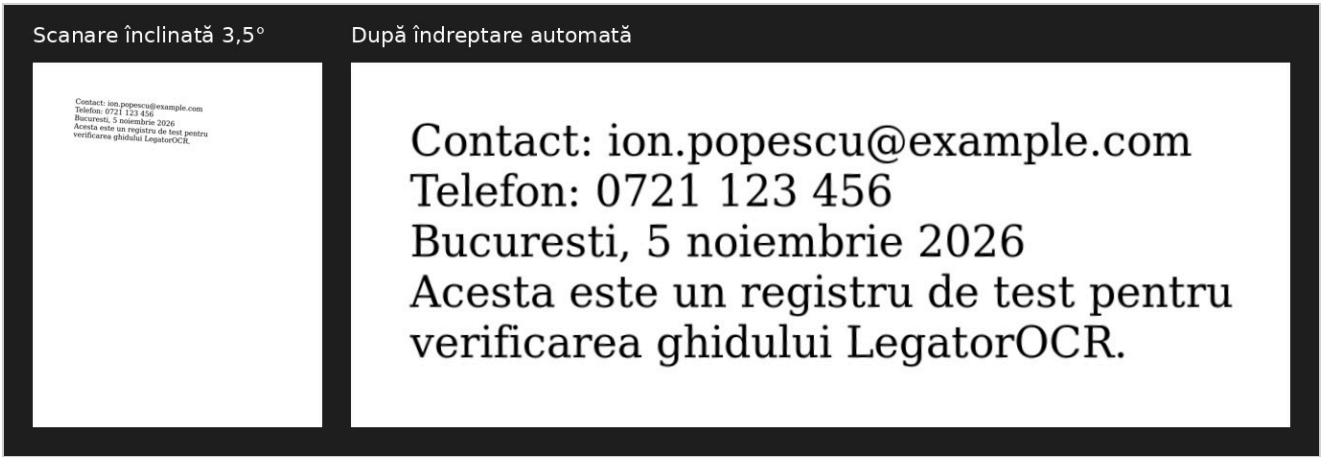
4. **A caixa de conteúdo.** Encontra-se a zona com texto e imagens; as sombras do scanner e o pó são ignorados. Tudo o que fica fora dela é repintado com a cor do papel.

5. **Margens e tamanho.** Margens em milímetros, opcionalmente um tamanho de página fixo ou o mesmo tamanho para todo o livro.

6. **Correção das linhas curvas** (opcional). Para páginas de livro carregadas, com linhas curvadas junto à lombada.

7. **Iluminação** (opcional). Uniformiza o fundo desigual.

8. **Limpeza e binarização.** Elimina manchas, furos de perfuração, dedos, linhas; depois preto e branco, cinzento, cor, misto ou híbrido.
9. **PDF e OCR.** Escreve-se o PDF (ou as imagens) e, se estiver marcada, a camada de texto.



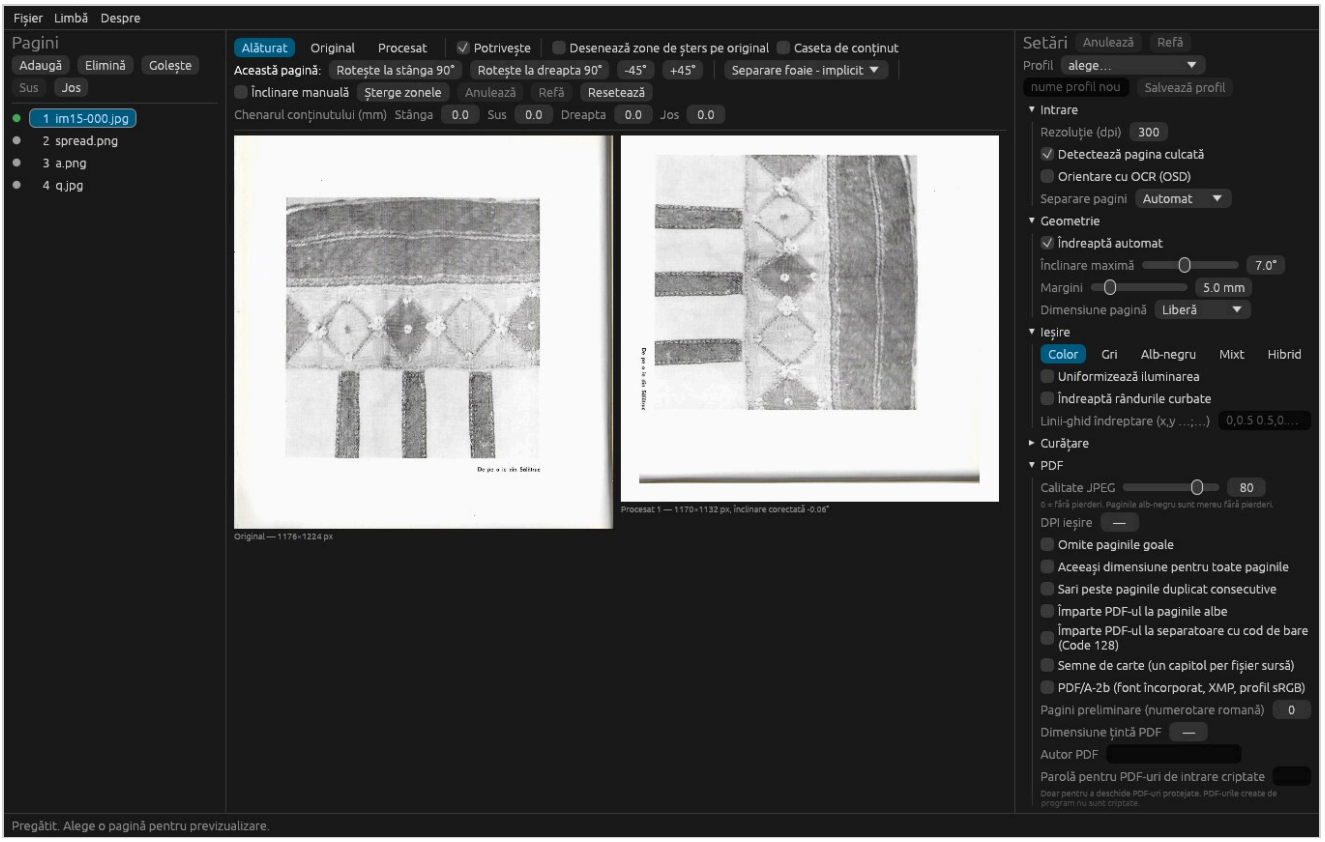
A correção automática da inclinação: uma digitalização inclinada 3,5° (folha de teste gerada por mim) e o resultado; o programa mediu -3,50°.

Regras de trabalho que poupam tempo

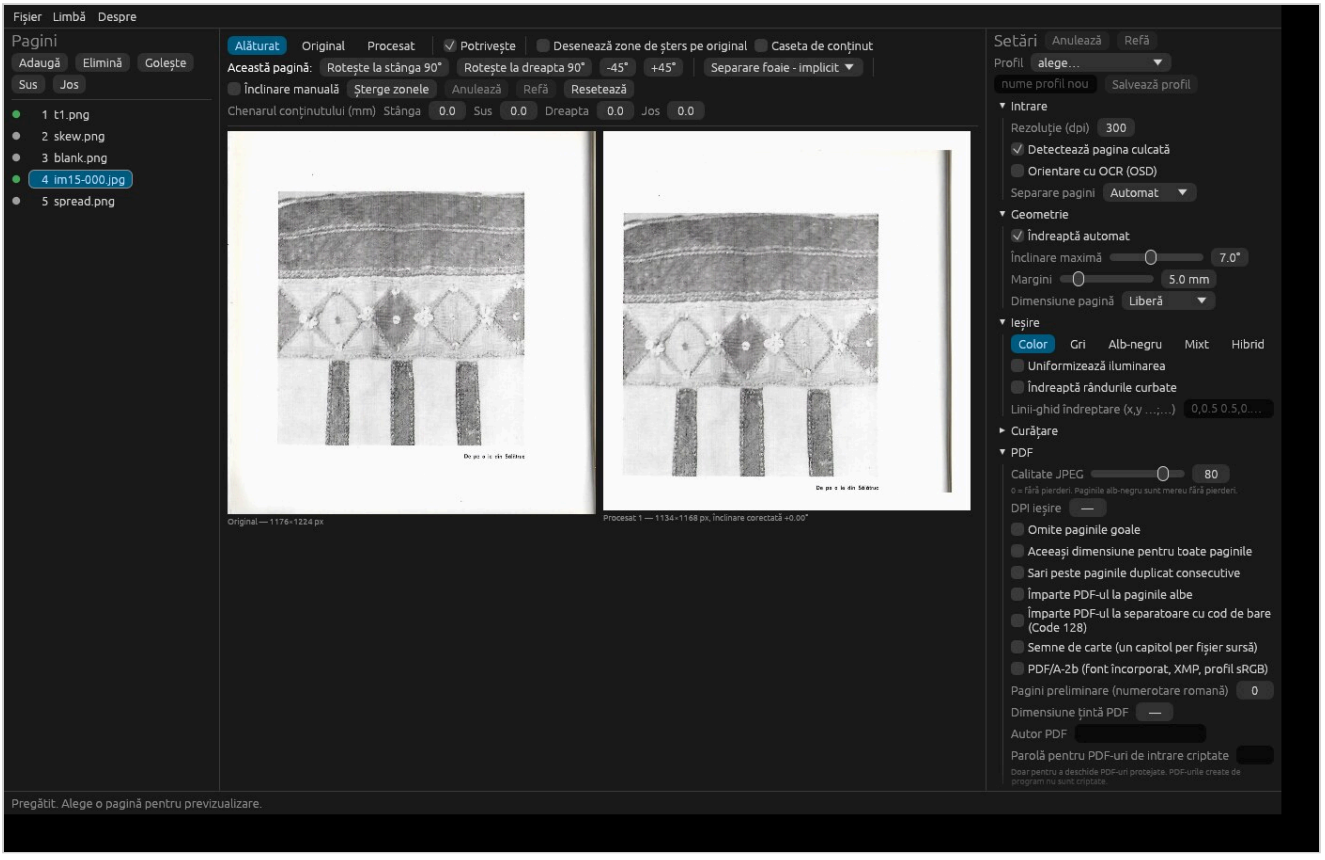
- Fixe primeiro a **resolução** correta (normalmente 300 dpi para texto). O programa lê-a da imagem se estiver entre 150 e 1200; caso contrário assume 300.
- Escolha um **perfil** adequado ao material (secção 6) antes de mexer nas definições individuais.
- Processe 10–20 páginas numa prova, verifique o resultado e só depois lance o lote grande.
- A interface marca as páginas „a verificar” (página em branco, inclinação no limite, nada encontrado, conteúdo colado à margem). Percorra-as com o botão „Seguinte”.

4. A interface gráfica

A janela tem três zonas: a lista de páginas à esquerda, a pré-visualização ao centro e as definições à direita. O menu **Ficheiro** contém „Adicionar imagens”, „Adicionar uma pasta”, „Abrir projeto”, „Guardar o projeto”, „Exportar PDF” e „Exportar as imagens”. O idioma da interface (8 idiomas) muda-se no menu **Idioma**.



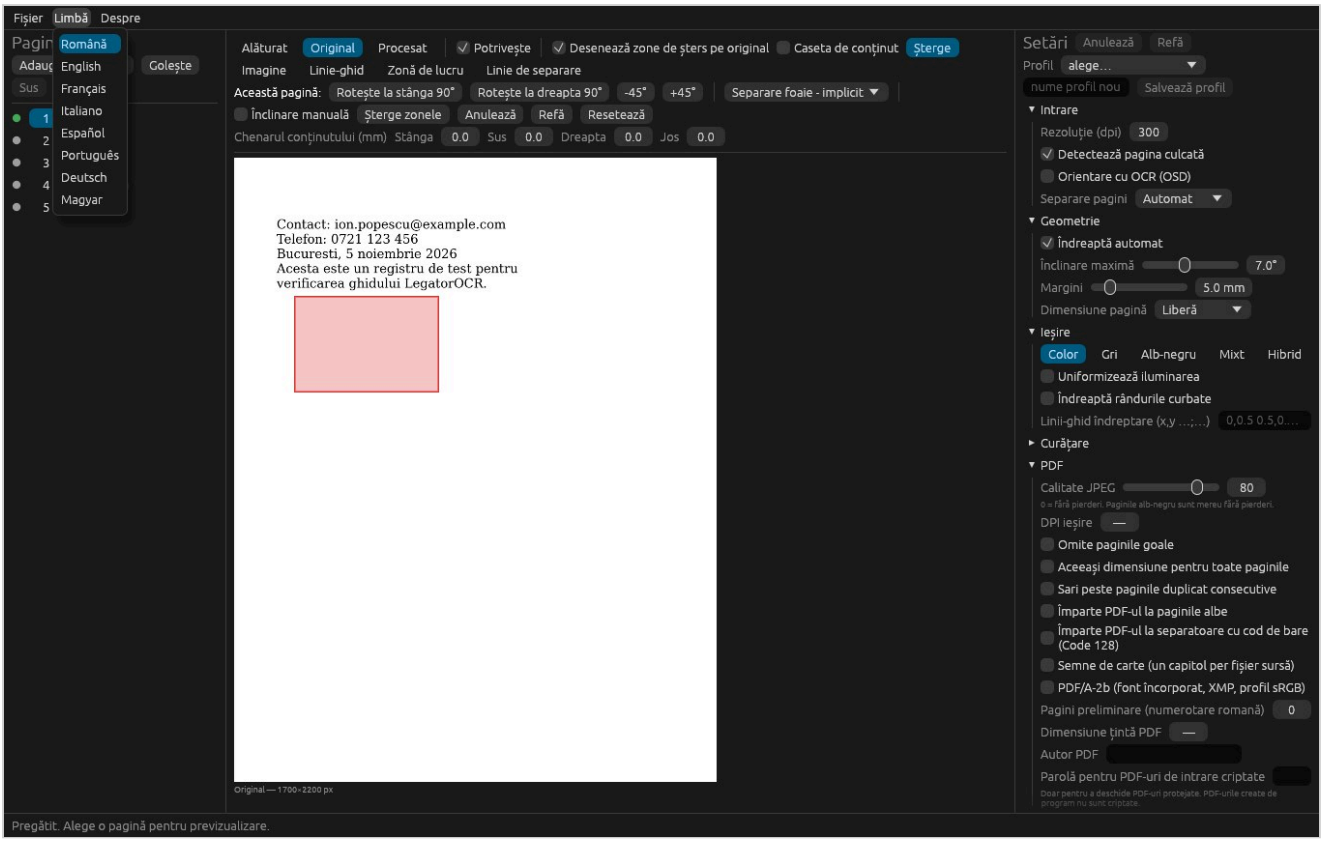
A janela principal: a lista de páginas à esquerda, o original e a página processada ao meio, as definições à direita. A página do exemplo é uma fotografia sem texto, por isso a deteção da página deitada rodou-a erradamente no pre.18 (corrigido no pre.19, veja abaixo). Captura pre.18 em Linux.



A mesma página no pre.19, com „Detetar a página deitada” marcado: já não é rodada (processado 1134×1168 px, inclinação +0,00°). Captura pre.19 em Linux.

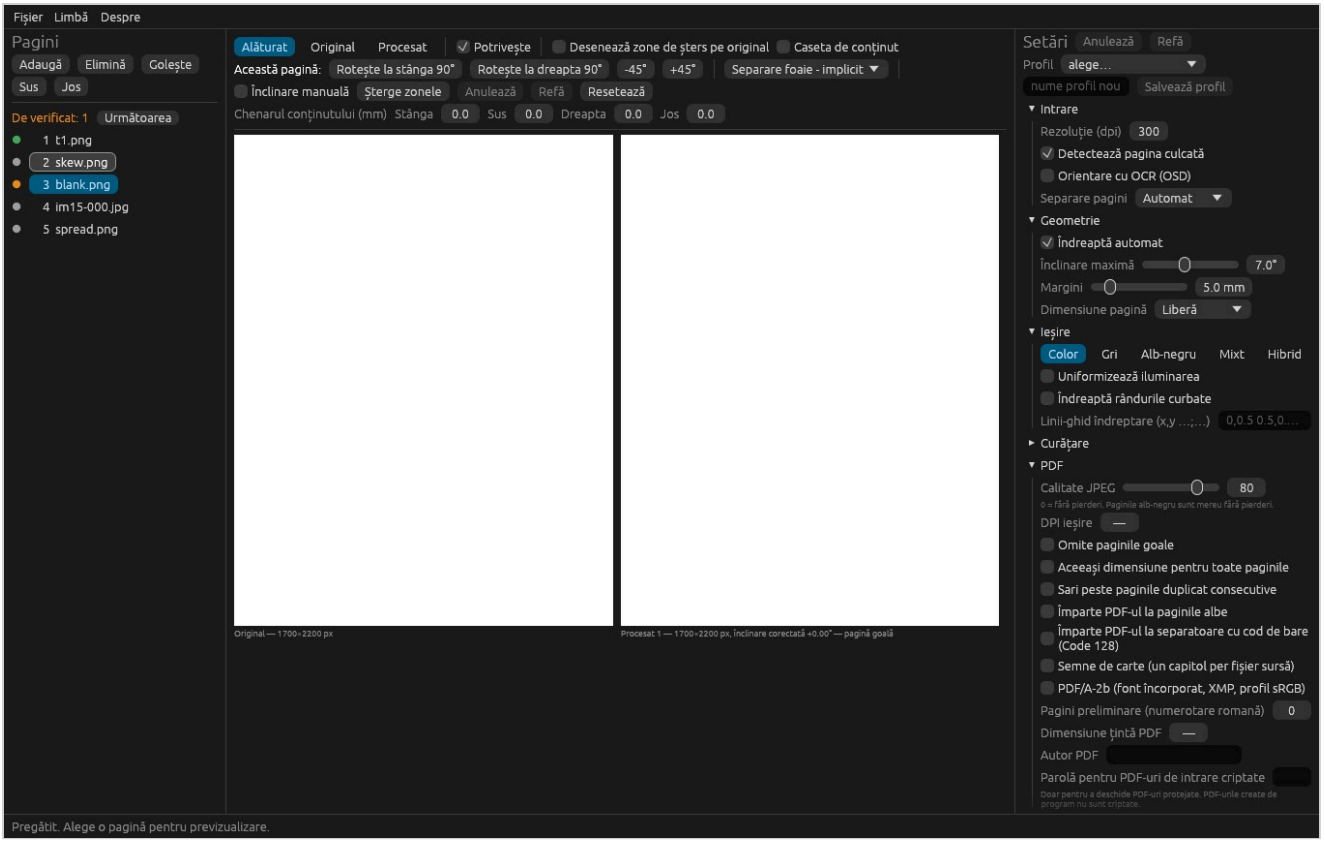


O menu Ficheiro: adiciona imagens ou uma pasta, abre e guarda o projeto, exporta PDF ou imagens.



O menu Idioma: os oito idiomas da interface (romeno, inglês, francês, italiano, espanhol, português, alemão, húngaro).

A lista de páginas

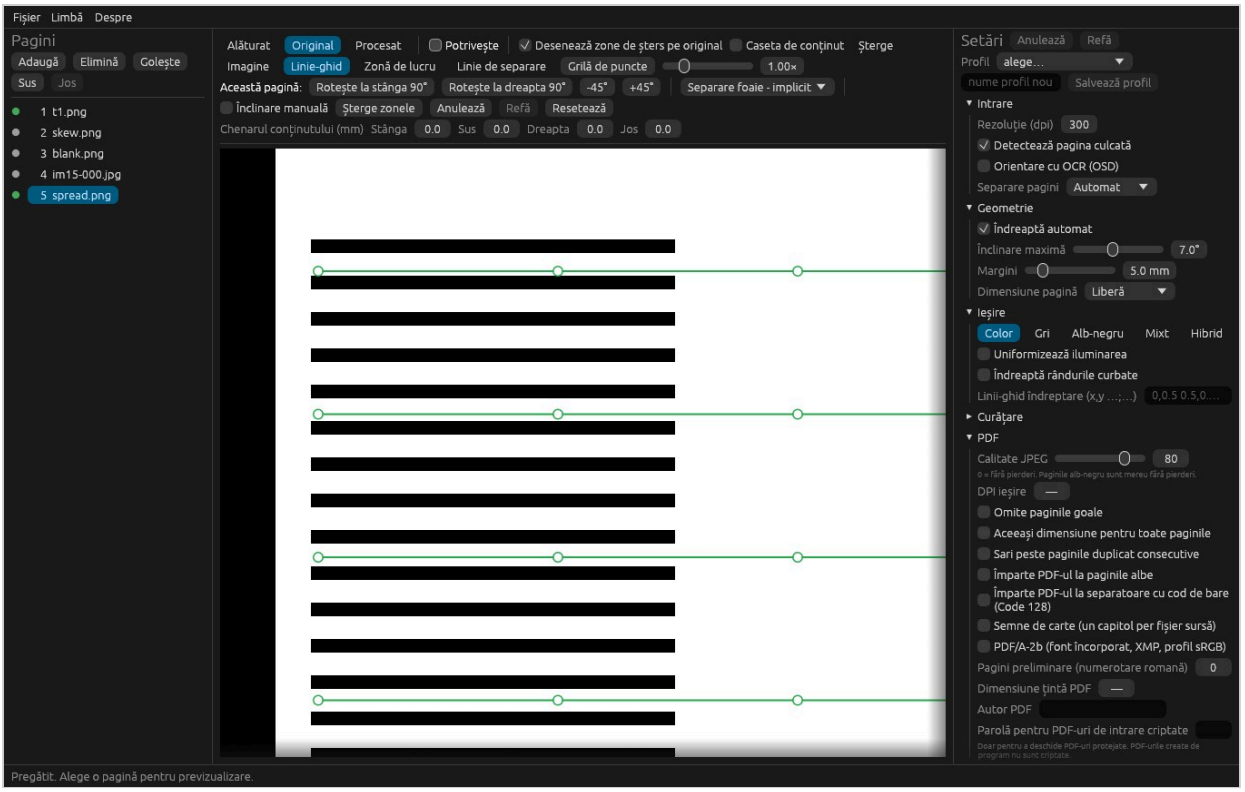


Uma página completamente branca é marcada automaticamente: ponto cor de laranja na lista e o painel „A verificar: 1” com o botão „Seguinte”.

Arraste para ela imagens, PDF, arquivos ou uma pasta, ou prima „Adicionar”. Os botões Para cima/Para baixo mudam a ordem, „Remover” tira a página escolhida, „Esvaziar” tira tudo. A ordem da lista é a ordem no PDF.

A pré-visualização

- **Lado a lado / Original / Processado** escolhe o que se vê. As zonas desenham-se no *Original*; a caixa de conteúdo corrige-se no *Processado*.
- **Ajustar** aumenta ou diminui a imagem para caber. O cursor de zoom (0,2×–4×) só aparece quando *Ajustar* está desmarcado.



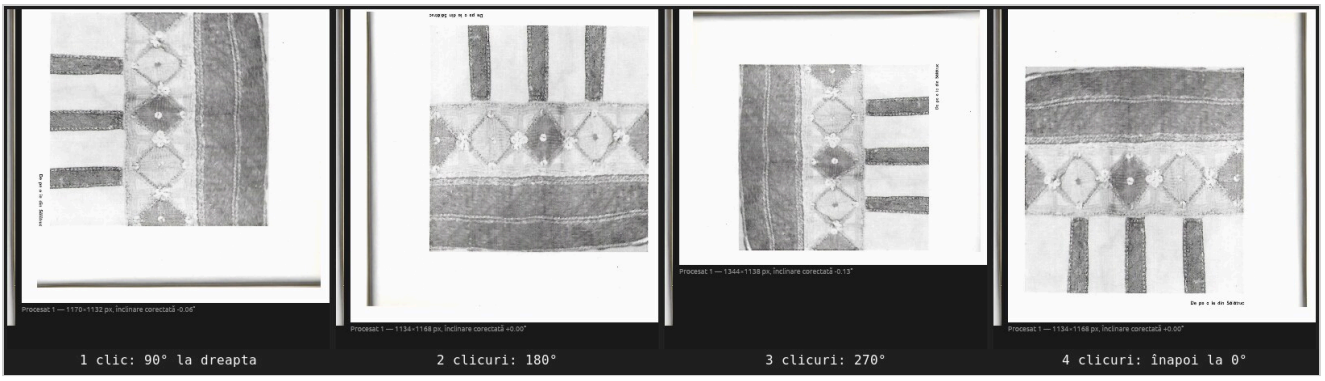
Com „Ajustar” desmarcado aparece o cursor de zoom (aqui 1,00×).

Miniaturas (desde pre.58). Cada página é uma ficha: a imagem pequena em cima, o número e o nome por baixo, e a página escolhida tem uma moldura azul à volta de ambos. Ao lado da caixa «Miniaturas» escolhe-se o tamanho: S (120×90 px), M (240×180, por omissão) ou L (320×240); se o painel for mais estreito, as imagens encolhem. As miniaturas são lidas em segundo plano, só para as páginas visíveis, por isso uma lista longa não abranda a janela. Desmarque «Miniaturas» para a lista compacta de uma linha por página.

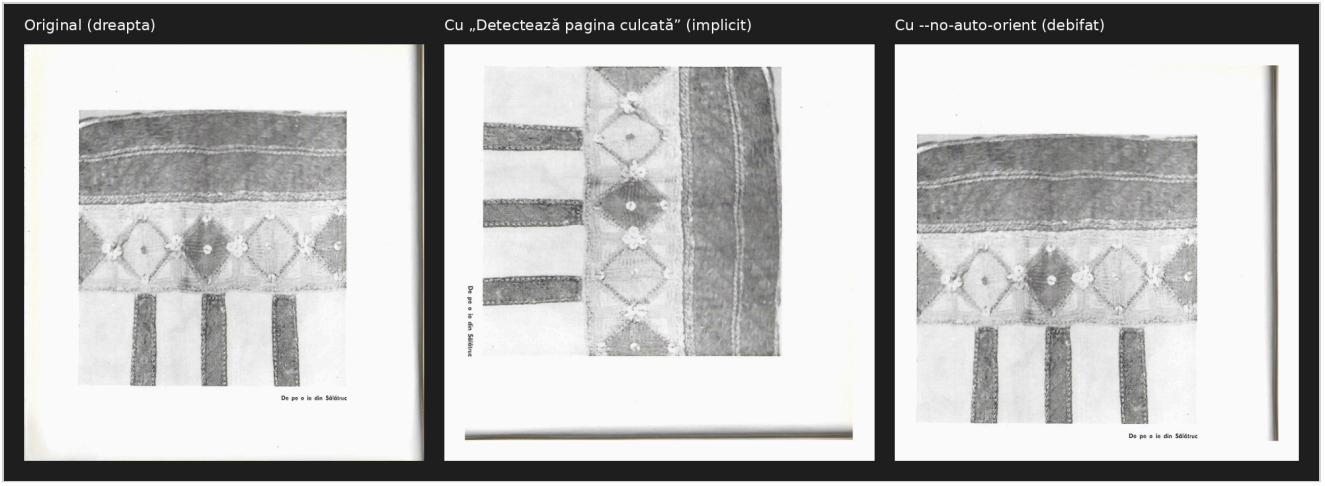
A barra „Esta página”

Aqui corrige apenas a página escolhida: rotação à esquerda ou à direita de 90°, passos de ±45°, inclinação manual, o modo de separação da folha (predefinido, automático, ao meio, desligado), a moldura do conteúdo em milímetros (esquerda, cima, direita, baixo; os valores positivos aumentam-na) e „Repor”. **Anular** e **Refazer** (Ctrl+Z, Ctrl+Y) funcionam para todos estes comandos, não só para zonas.

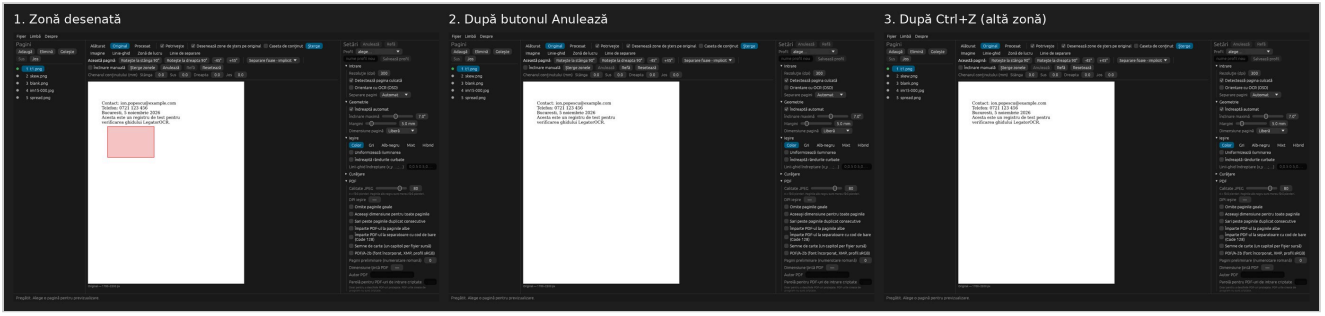
A rotação manual bloqueia a orientação automática (desde o pre.18): depois de premir um botão de rotação ou ±45°, a página deixa de ser rodada pela deteção da página deitada ou pelo OSD, mesmo a 0°. „Repor” devolve-lhe a orientação automática. Se uma página com fotografias for rodada erradamente desde o início, prima a rotação quatro vezes (ou desmarque „Orientação por OCR (OSD)” e „Detetar a página deitada” nas definições, em Entrada).



Quatro cliques seguidos em „Rodar à direita 90°”: 90°, 180°, 270° e depois de volta a 0°, sem saltos. Captura pre.18 em Linux. No Windows 11 não pude verificar.



A mesma página (a página 15 do PDF do testador) e as mesmas definições, exceto a deteção: no pre.18, com „Detetar a página deitada” marcado (predefinição), o programa rodava-a 90° embora o original esteja direito (a partir do pre.19–20 já não a roda); com --no-auto-orient (ou desmarcado nas definições) sai direita. Verificado na linha de comandos; na janela vi a rotação no pre.18 e a sua ausência no pre.19.



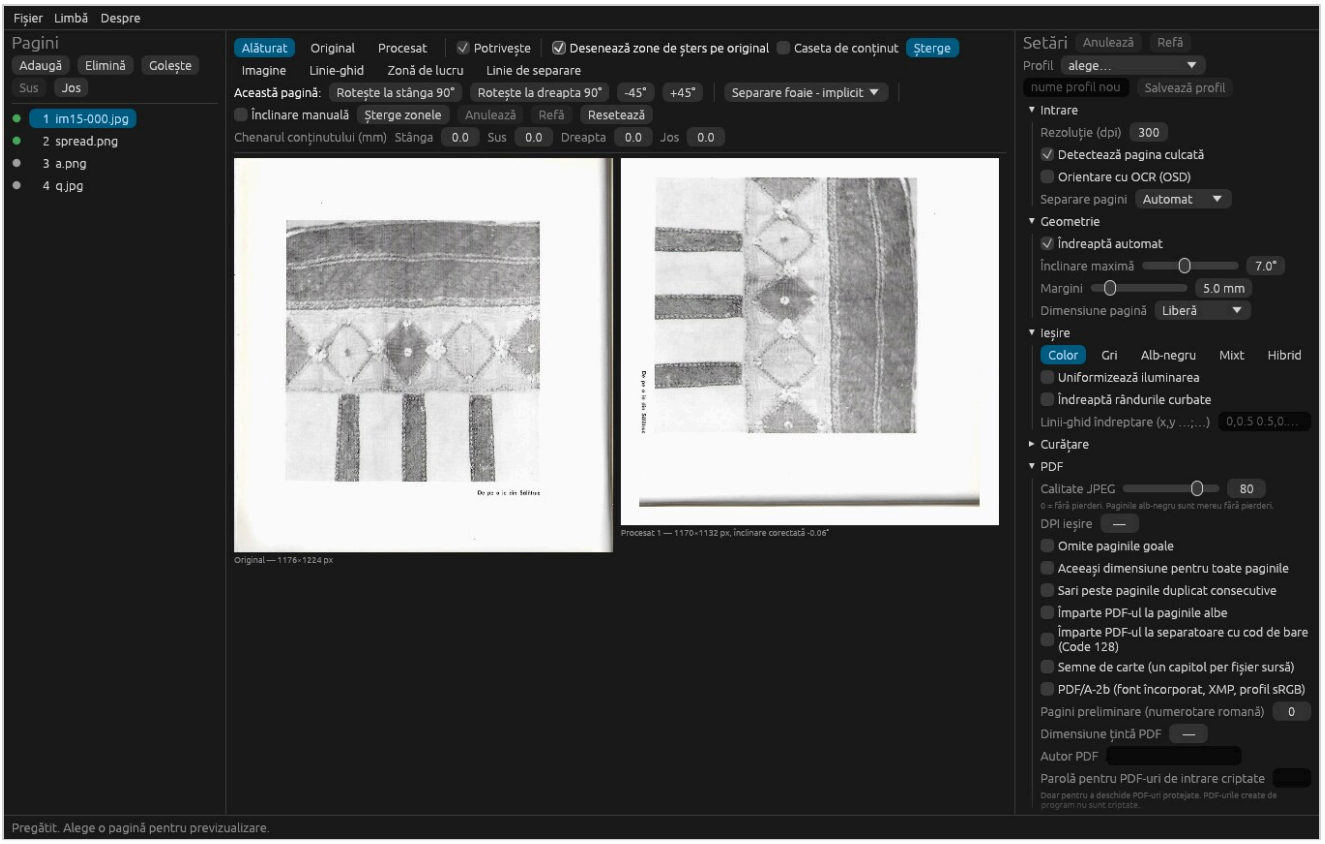
Anular (o botão) e Ctrl+Z (com a janela em primeiro plano) retiram a última zona desenhada. Verificado na janela.

Páginas de cabeça para baixo. O botão «180°» vira a página escolhida (Ctrl+Z desfaz). Além disso, em textos de escrita latina, o programa deteta sozinho as páginas de cabeça para baixo, depois de endireitar: no texto, as hastes ascendentes e as maiúsculas sobressaem acima da linha mais do que as descendentes abaixo, e numa página virada o equilíbrio inverte-se. Só decide se a página tiver pelo menos 12 linhas e pelo menos 70 % delas «votarem» da mesma forma; caso contrário não toca em nada. Não funciona com outras escritas e não toca nas páginas que rodou

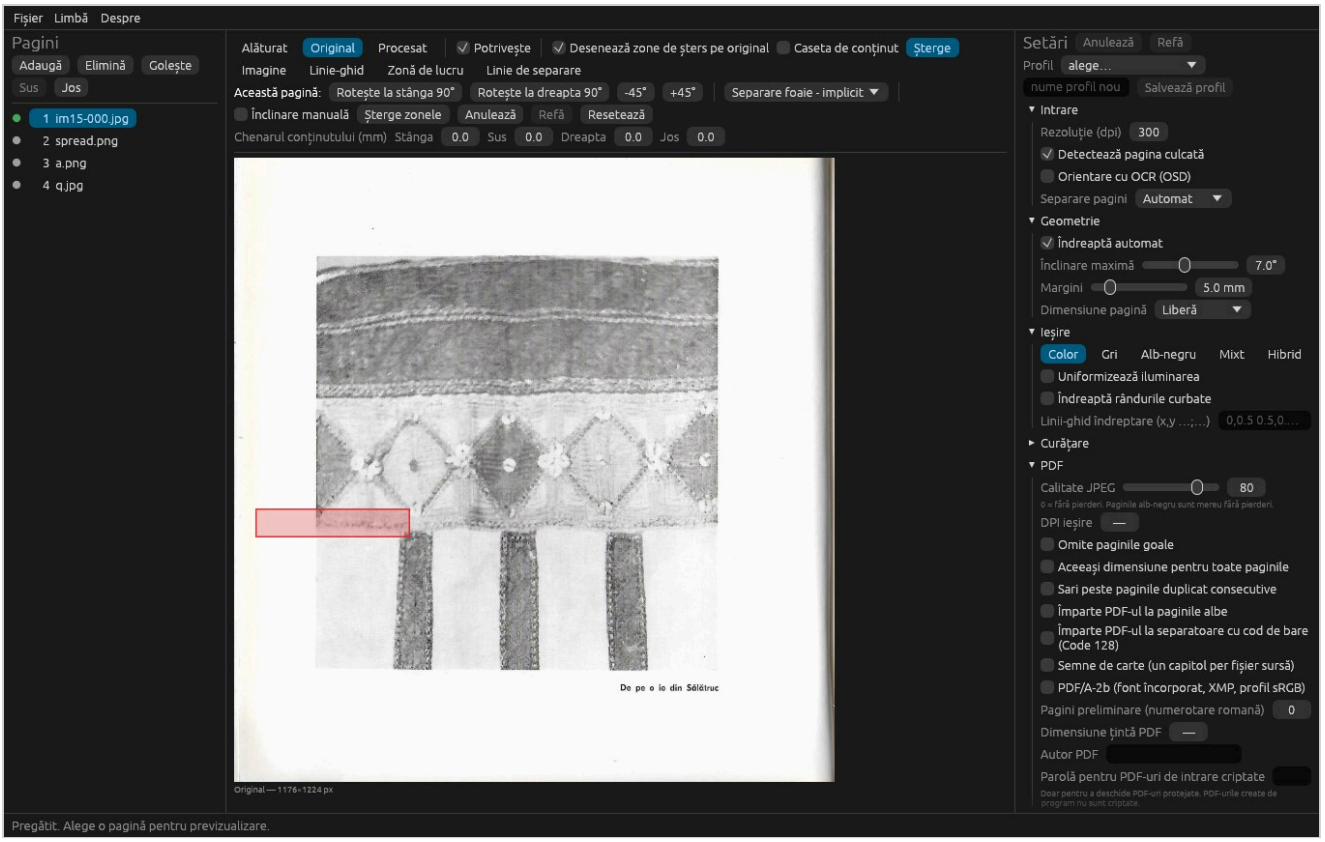
à mão. Verificado em páginas sintéticas e algumas fotografias; se uma página ficar virada, prima «180°».

Zonas, guias e a caixa de conteúdo

Marque „Desenhar zonas a apagar no original”; aparecem cinco tipos de desenho (Apagar, Imagem, Linha-guia, Área de trabalho, Linha de separação):

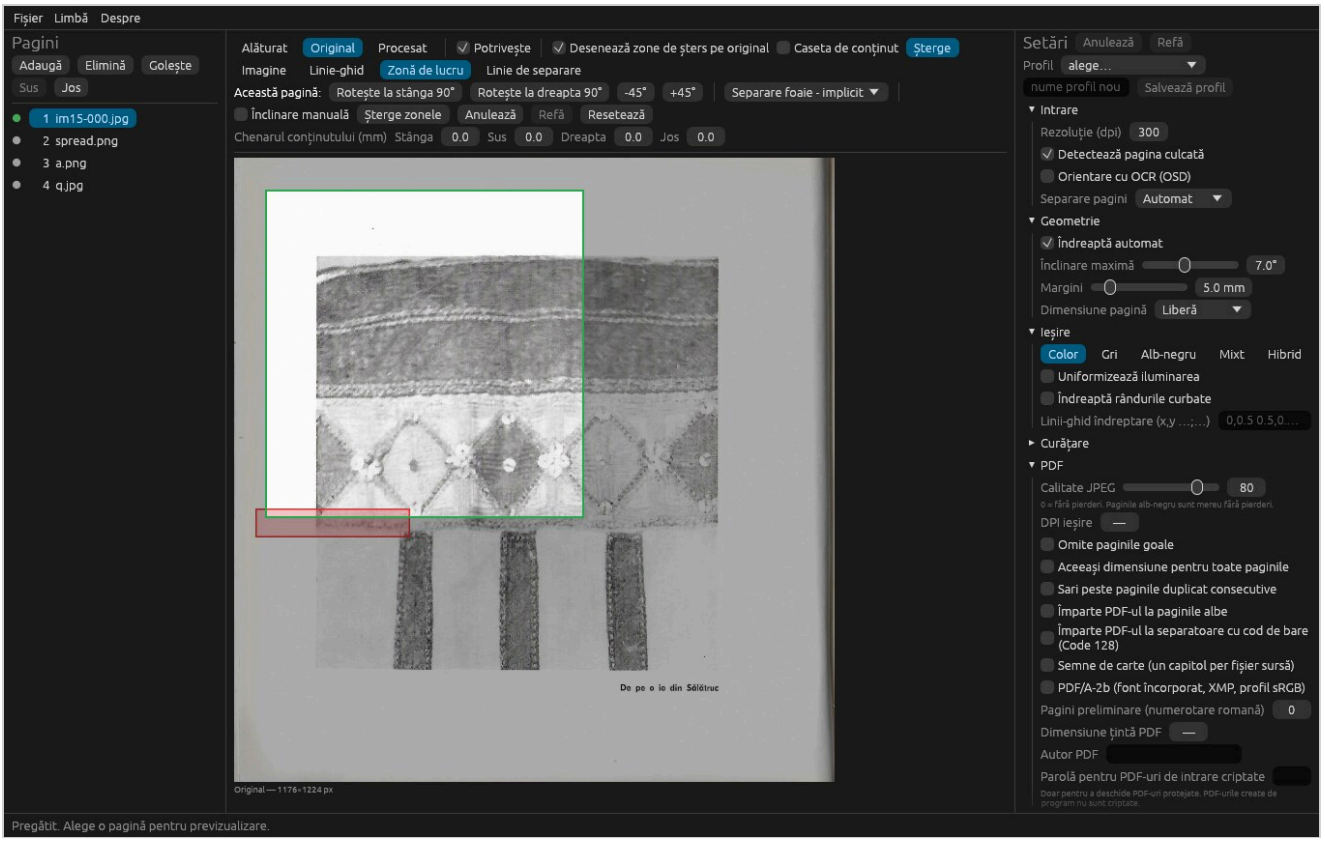


Com „Desenhar zonas a apagar no original” marcado aparecem os tipos de zona: Imagem, Linha-guia, Área de trabalho, Linha de separação (e Apagar, o tipo predefinido).

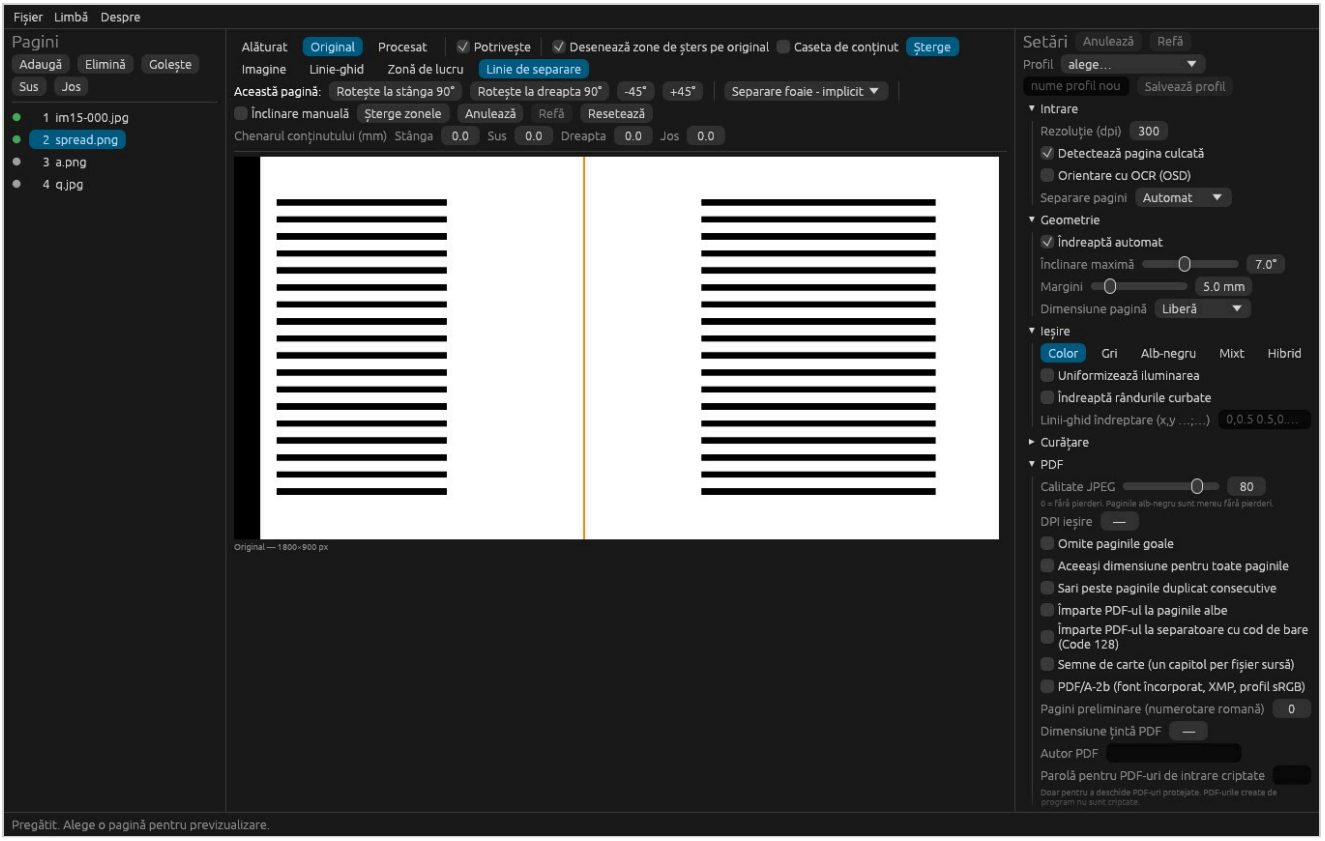


Uma zona a apagar (vermelho) traçada com o rato no original, na vista Original.

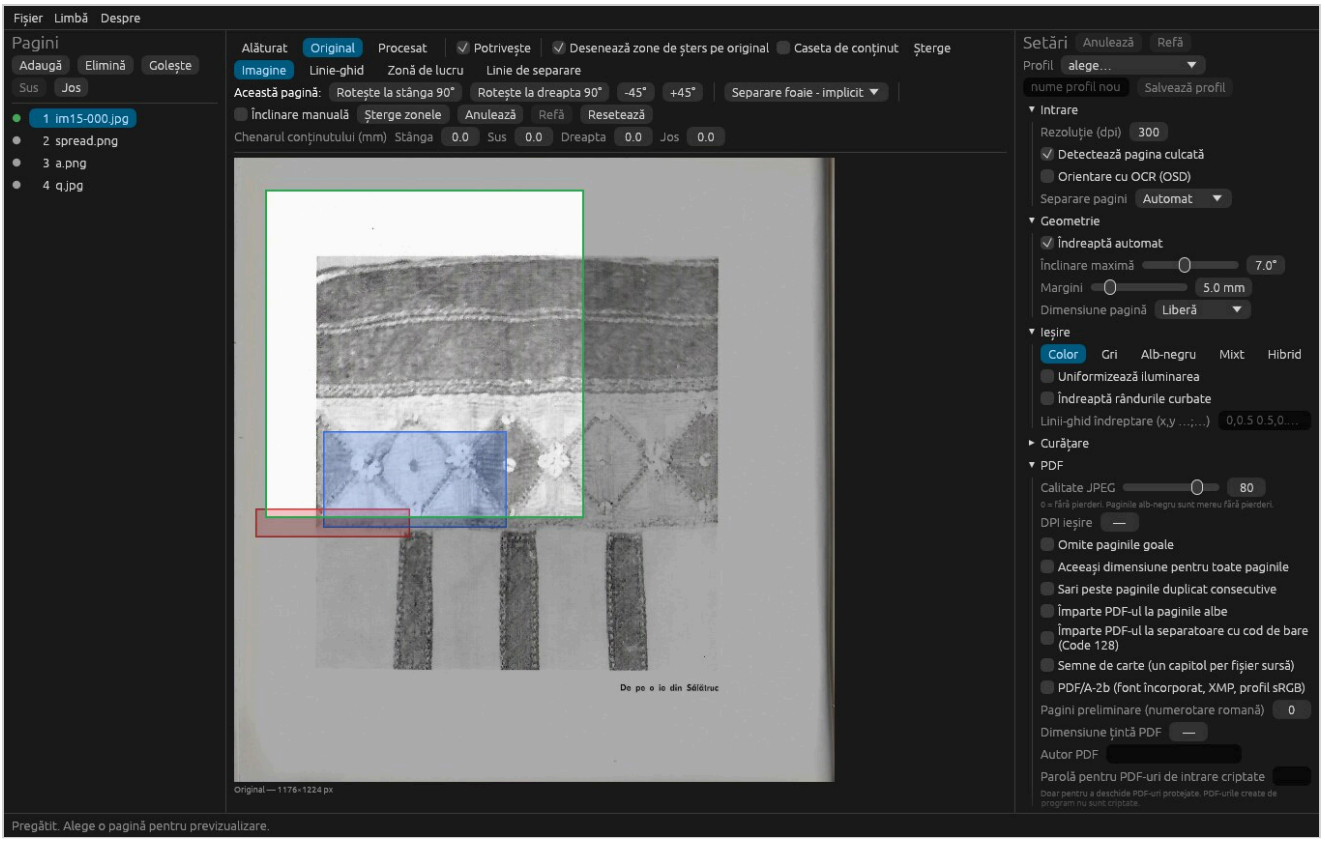
Tipo	Como se usa	Para que serve
Apagar	Arrasta-se um retângulo sobre o original. Clique direito nele apaga-o. Arrastando um canto redimensiona-se.	Mancha, carimbo, nota de alguém, margem com sombra
Imagem	Como „Apagar”.	Diz ao programa que a zona é imagem, não texto (fica a cores no modo misto)
Linha-guia	Arrasta-se livremente ao longo de uma linha curva. Arrasta-se um nó para o mover; duplo clique na linha acrescenta um nó, duplo clique no nó apaga-o; clique direito na linha apaga-a.	Corrige a página segundo as linhas que traçou



A área de trabalho (moldura verde): tudo o que fica fora dela é eliminado, e a zona restante vê-se na página processada. Tem também uma zona a apagar (vermelho).



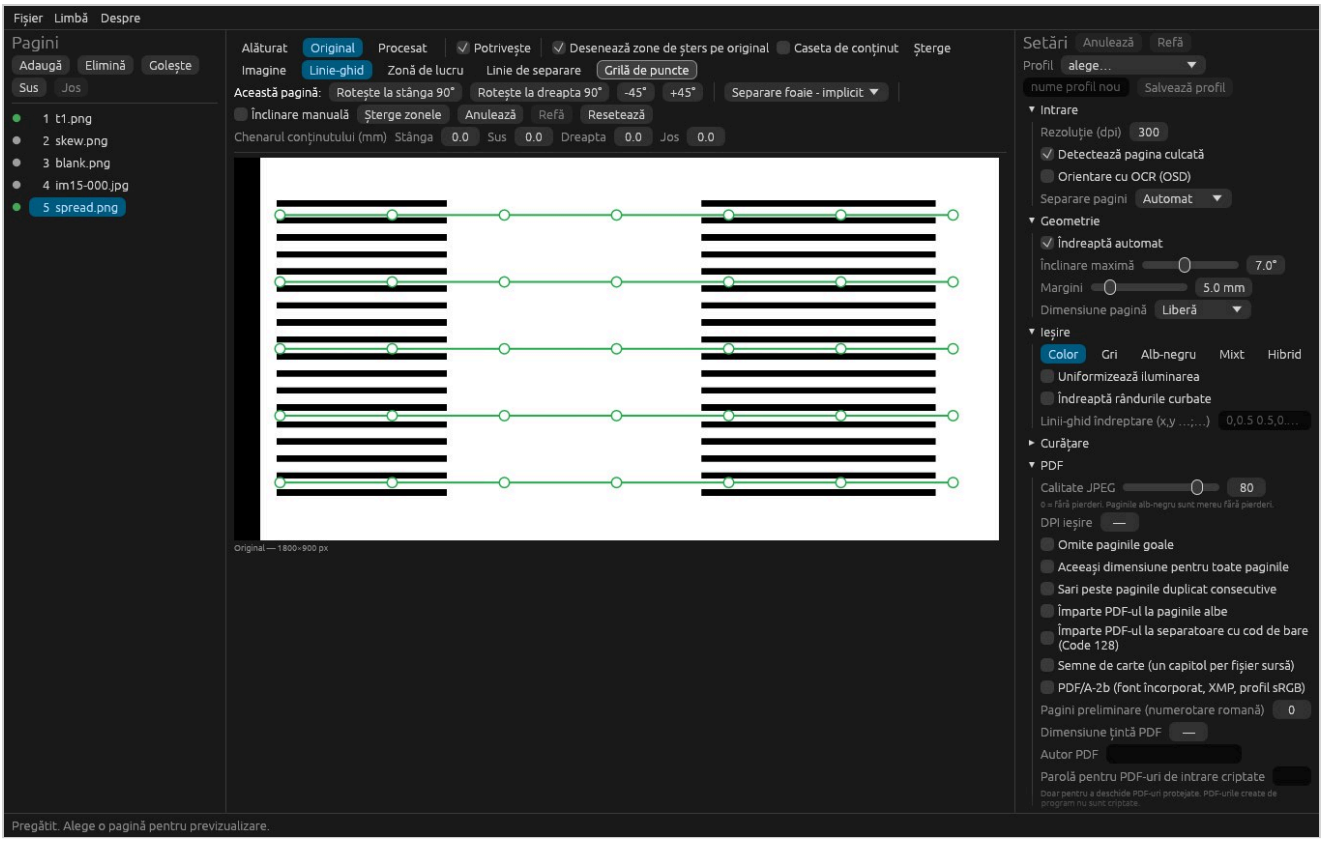
A linha de separação (cor de laranja) movida com o rato numa folha dupla. O exemplo é uma folha de teste sintética, com linhas em vez de texto.



Uma zona de imagem (azul) desenhada no original. No modo Cor não muda nada; o efeito vê-se no modo Misto (figura seguinte).



A mesma página e a mesma zona de imagem (azul): no modo Misto a zona fica cinzenta (esquerda), no modo Preto e branco tudo passa a preto e branco (direita). A página aparece rodada 90° pela deteção da página deitada (veja acima).



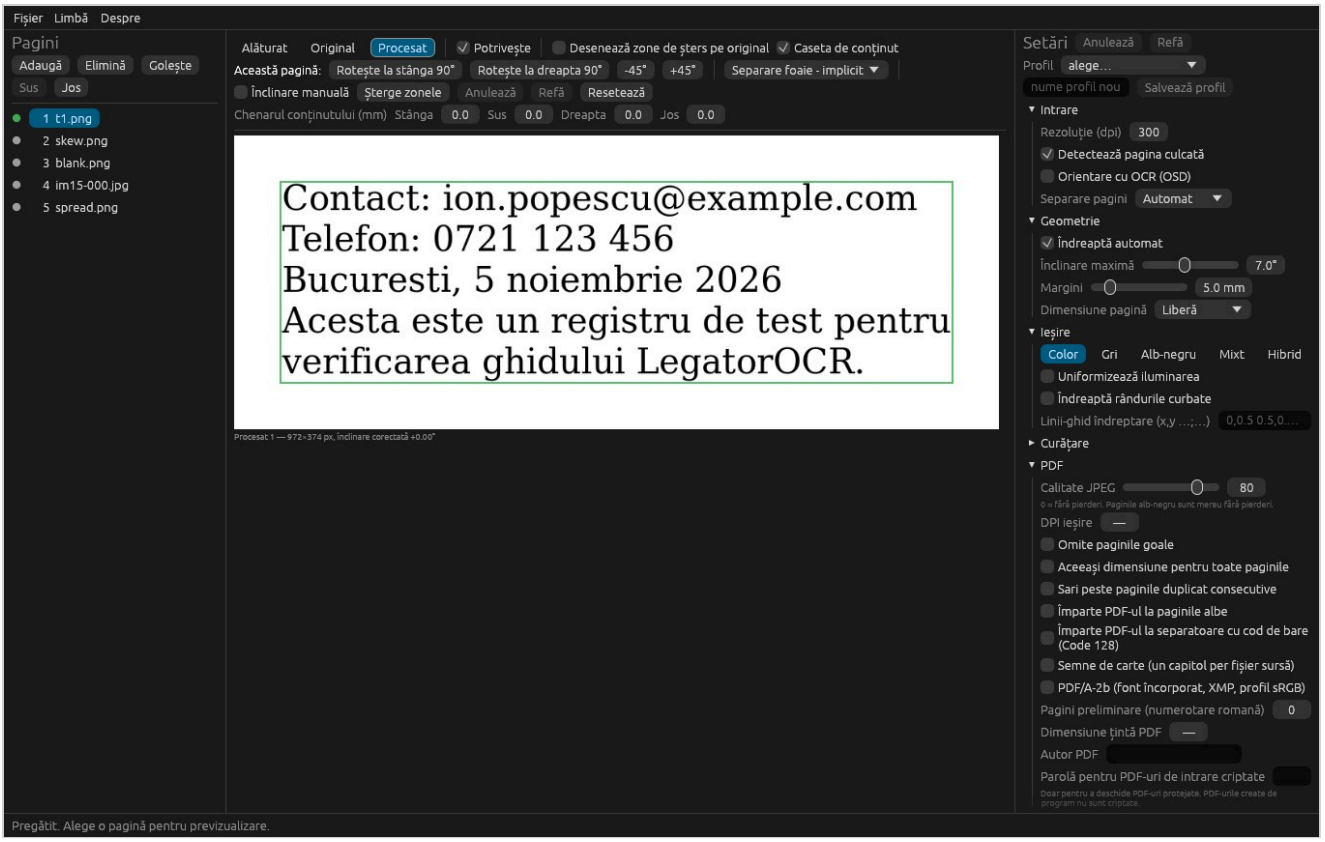
„Grelha de pontos” em Linha-guia: 5 linhas de 7 pontos, sobre as linhas de texto.

Grelha de pontos (em *Linha-guia*) acrescenta 5 linhas de 7 pontos, sobre as quais arrasta os pontos para as linhas de texto. Um segundo clique no botão não acrescenta a mesma grelha uma segunda vez. Se já moveu pontos, uma nova grelha acrescenta-se ao lado da que foi movida.

Área de trabalho (desde a edição pre.18): arrasta-se um retângulo sobre o original; tudo o que fica fora dele é pintado com a cor do papel antes de qualquer medição, pelo que uma margem escura ou a página vizinha deixam de contar. Clique direito no original elimina-o. Na linha de comandos: `--work-area X,Y,L,H` (milímetros).

Linha de separação (desde a edição pre.18): com um clique ou arrastando sobre o original move-se a linha vertical cor de laranja; a folha dupla é cortada aí, não ao meio nem na goteira. Desde o pre.21 funciona com qualquer rotação; nas folhas rodadas 90° ou 270° a linha corta na horizontal e as páginas saem uma por baixo da outra (primeiro a página da esquerda do original). Clique direito elimina-a. Na linha de comandos: `--cut-at 0.45`.

A caixa de conteúdo (a caixa de seleção com o mesmo nome) mostra na página processada uma moldura verde. Arrastam-se os lados para alargar ou estreitar a zona mantida. Numa folha cortada em duas páginas, só muda a página onde se arrasta a moldura.



A caixa de conteúdo (moldura verde) na página processada.

Páginas tortas, corte oblíquo e definições por página

Três ferramentas para folhas fotografadas à mão:

- **Linha de corte oblíqua.** Com «Desenhar zonas de apagamento no original» e o tipo Linha de corte, o controlo «Inclinação da linha» (de −20° a 20°) inclina a linha; cada página fica com o seu lado da linha oblíqua e o outro lado é pintado com a cor do papel. Clique direito na linha: elimina-a e repõe a inclinação a zero. Na linha de comandos: `--cut-angle GRAUS`.
- **Correção trapezoidal.** Dois controlos da barra «Esta página» («Trapézio cima–baixo», «Trapézio esquerda–direita», ±30 %) endireitam antes do corte uma folha fotografada em ângulo. O botão **Trapézio auto** (depois de dividir as páginas) mede cada página — inclinação das linhas de texto e largura do texto em cima e em baixo — e guarda uma correção só para essa página. É prudente de propósito: se há poucas linhas ou as medições se contradizem, deixa a página como está. Verifique o resultado, com Anular à mão. Os botões −45°/+45° mantêm-se. Na linha de comandos: `--keystone-v` e `--keystone-h` (percentagens).
- **Definições por página.** «Definições para: Todas as páginas / Só esta página», por cima de Saída e Limpeza, aplica o modo de saída, o limiar, a remoção de pontos e as outras definições de limpeza a uma só página de uma folha cortada; a moldura verde do conteúdo altera só a página onde é arrastada. Num projeto: `page1.CHAVE = VALOR` / `page2.CHAVE = VALOR` sob [sheet]. Um clique numa página processada seleciona-a (moldura azul): o modo de saída (cinzento, preto e branco, misto), a limpeza, a correção trapezoidal, a caixa verde e os lápis OCR passam a atuar só nela. As zonas OCR desenhadas ficam com essa página (`page1.page_ocr_zones`, `page_ocr_ignore`).

A barra sob a pré-visualização contém a caixa de conteúdo, os lápis OCR e o **Auto-lápis OCR** (em separado para a página esquerda e a direita): põe a zona OCR sobre o conteúdo dessa

página.

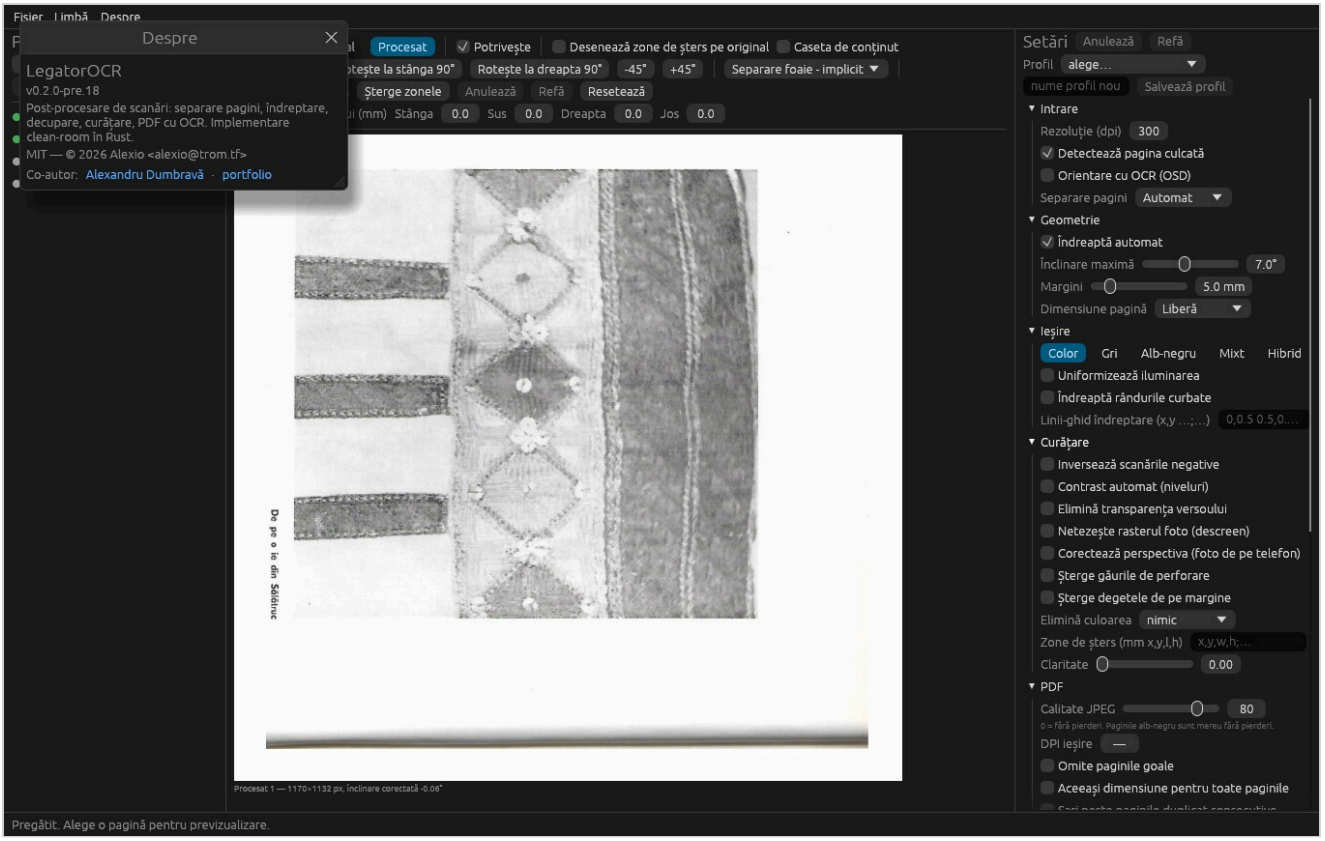
A inclinação manual atua na página selecionada (esquerda ou direita) de uma folha cortada: cada página pode ter o seu próprio ângulo (`page1.page_skew`, `page2.page_skew`).

Zoom: na barra inferior, **A+** / **A-** aumentam ou reduzem toda a interface (também Ctrl + / Ctrl −) e **Auto** ajusta-a ao tamanho da janela. A janela arranca maximizada com zoom automático, para o texto ficar grande e ocupar o ecrã; a escolha é guardada.

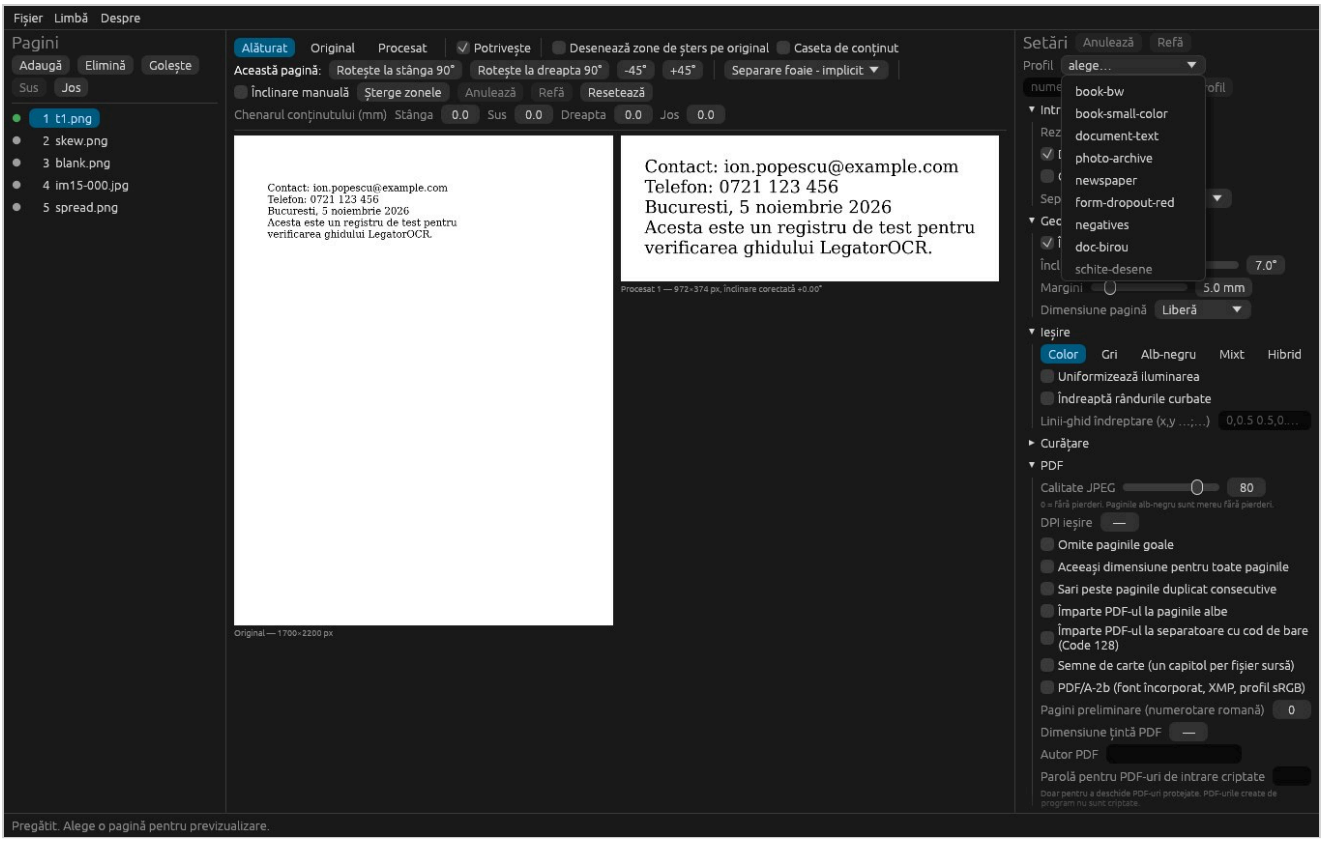
Os tamanhos de página incluem agora A2–A6, B3–B6, Letter, Legal e Tabloid (`--page-size` aceita os mesmos nomes). Lápis OCR nas páginas processadas: verde (zona OCR), vermelho (zona ignorada), violeta (tabela, lida como um bloco linha a linha; `--ocr-zone X,Y,W,H#table`).

As definições à direita

Agrupam-se por secções: Entrada, Geometria, Saída, Limpeza, PDF, OCR, mais os perfis. A secção 6 explica o que cada uma faz.



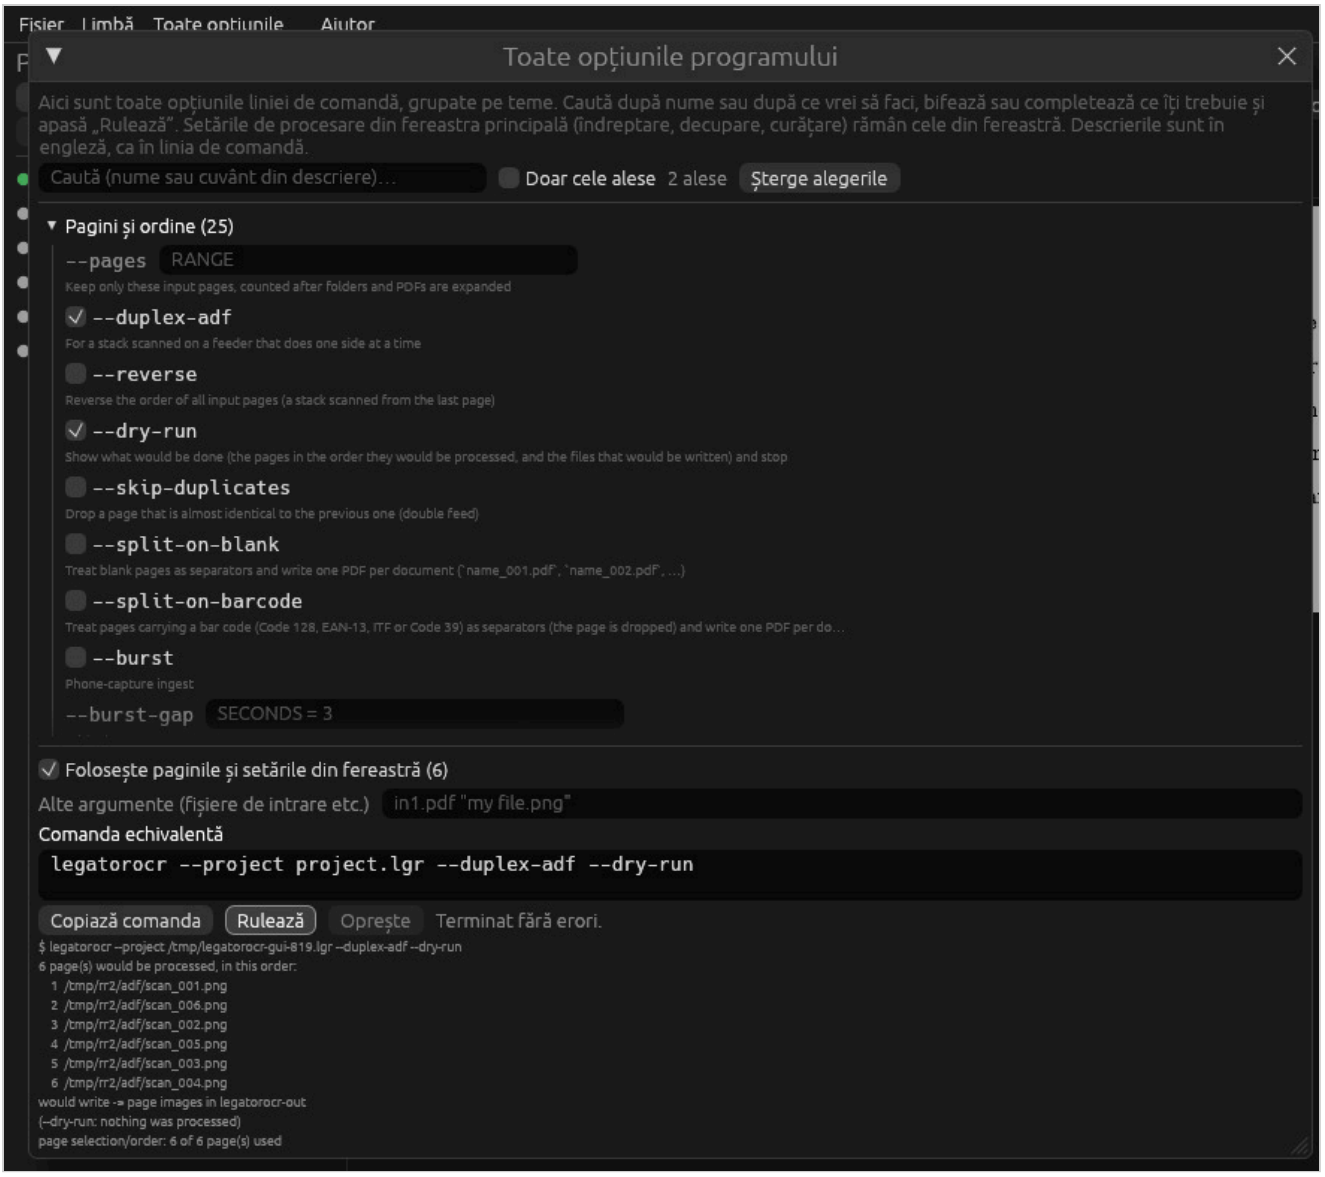
A secção Limpeza das definições, aberta: inverter digitalizações negativas, contraste automático, perspetiva, apagar furos de perfuração, zonas a apagar como números.



A lista „Perfil” nas definições (os perfis integrados; os seus aparecem no mesmo sítio depois de „Guardar perfil”).

Todas as opções e o guia do utilizador

O botão **Todas as opções…** da barra superior abre uma janela com **todas** as opções da linha de comandos (mais de 200), agrupadas por temas: páginas e ordem; correção, recorte e limpeza; saídas (PDF, imagens, documentos); OCR e texto; arquivo, assinatura e verificação; pesquisa e comparação; lotes, sistema e módulos. A lista é lida do próprio programa de linha de comandos fornecido com a janela, pelo que corresponde sempre à edição que tem.



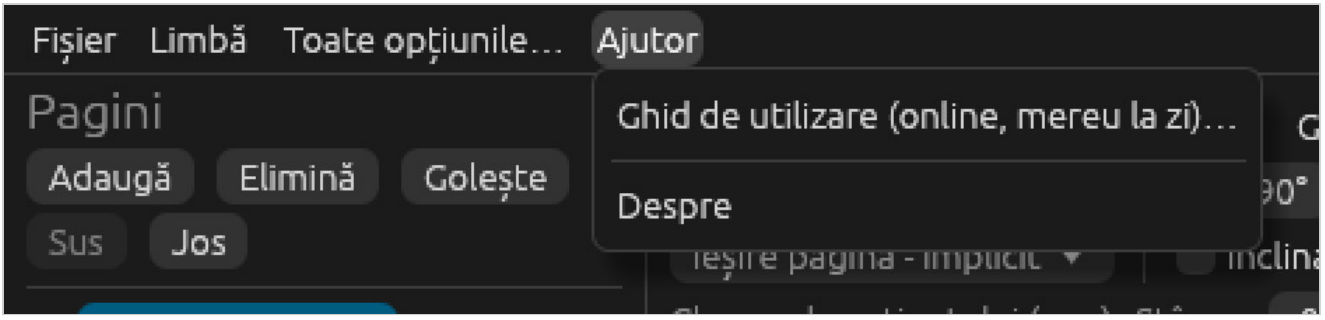
A janela „Todas as opções”, com o grupo „Páginas e ordem” aberto, `--duplex-adf` e `--dry-run` marcados e o resultado da execução: a ordem em que seriam processadas as seis páginas da pilha (páginas de teste feitas por mim).

- **Pesquisar** por nome (`pdf`, `dry`) ou por uma palavra da descrição; os grupos com resultados abrem-se sozinhos. „Só as escolhidas” mostra o que marcou ou preencheu.
- As caixas vazias não são enviadas: uma opção com valor só entra no comando quando escreve algo (ou escolhe de uma lista). O botão **Escolher…** abre o diálogo de ficheiros ou de pastas. Nas opções que podem repetir-se (por exemplo `--erase`) escreve-se um valor por linha.
- **Usar as páginas e as definições da janela** (marcado por omissão): o comando recebe as páginas carregadas, com os ajustes de cada uma, através de um projeto temporário. As definições de processamento da janela principal (correção, recorte, limpeza) têm prioridade; aqui preenche as saídas e as funções especiais. Desmarque para comandos sem páginas (`--doctor`, `--verify-sums`) ou escreva os ficheiros de entrada em „Outros argumentos”.
- **O comando equivalente** atualiza-se à medida que escolhe; pode copiá-lo e usá-lo no terminal ou em scripts. **Executar** executa-o e mostra o resultado por baixo; **Parar**

interrompe-o. Os caminhos relativos são relativos à sua pasta pessoal.

- As descrições das opções estão em inglês, como na linha de comandos; o resto da janela está no idioma escolhido.

O menu **Ajuda** tem a ligação para este guia: *Guia do utilizador (em linha, sempre atualizado)* abre a última versão publicada em legatorocr.chiuta.ro, e *Guia desta edição* (aparece quando o ficheiro PDF está ao lado do programa, como nos arquivos publicados) abre a cópia fornecida com o programa. O guia é refeito em cada edição, e a publicação de uma edição é interrompida se o guia não mencionar a sua versão.



Verificado: a janela, a pesquisa, a marcação, a execução de um comando com as páginas da janela (a captura acima) e a abertura do menu Ajuda, em Linux, num ecrã virtual. Não verificado: Windows, macOS e arm64; a abertura efetiva do guia num navegador (verifiquei apenas o menu); os diálogos „Escolher…”; as traduções dos novos textos da janela (escritas automaticamente).

Coleções

Uma coleção reúne jornais, revistas, livros e semelhantes num único ficheiro `.lgrcol` (JSON). Guarde-o na pasta com as digitalizações: os caminhos no ficheiro são escritos relativos a ele quando o destino fica sob uma pasta comum, de modo que a pasta pode ser movida ou copiada. Cada elemento tem tipo, título, número ou volume, data ou ano, idiomas, fontes (imagens, uma pasta de imagens, um PDF, um projeto `.lgr` guardado), o PDF resultante, um perfil, um estado (por fazer, processado, OCR feito, verificado), número de páginas, etiquetas e notas.

```
legatorocr collection new Archive/ --name "Old papers"
legatorocr collection add Archive/old_papers.lgrcol --folder Archive/scans
legatorocr collection list Archive/old_papers.lgrcol
legatorocr collection run Archive/old_papers.lgrcol --out Archive/pdf
legatorocr collection search Archive/old_papers.lgrcol "Scînteia"
legatorocr collection reindex Archive/old_papers.lgrcol
legatorocr collection set Archive/old_papers.lgrcol i1 --status checked --tags "1977, youth"
legatorocr collection remove Archive/old_papers.lgrcol i2
```

- `add --folder`: cada PDF, projeto `.lgr` e subpasta de imagens torna-se um elemento. Título, tipo, data e número são deduzidos do nome: `scinteia_tineretului_1977_09_8801.pdf` dá um jornal, «Scinteia Tineretului», 1977-09, n.º 8801. É apenas um palpite (os nomes de ficheiro não têm diacríticos; o tipo apoia-se em poucas palavras-chave e na numeração: uma data completa ou um número de 500 ou mais é tomado por jornal); corrija-o na janela. Para `nome_ano_mês_número` um número de três ou mais algarismos é o número da edição (`..._1977_09_8801`); um número de um ou dois algarismos logo a seguir ao mês é um dia só se for um dia real desse mês e, quando é a última parte, o nome não diz revista ou livro

(`gazeta_1914_05_12` é 12 de maio, `revista_sinteza_1985_03_12` é o número 12, `..._1977_09_12_8801` é o dia 12, número 8801).

- `run` processa os elementos com estado «por fazer», cada um com o seu perfil (senão o da coleção, senão as definições predefinidas), com o mesmo código da linha de comandos e da janela (`run_export`). Um elemento que falha (fonte em falta, perfil desconhecido, página ilegível) fica marcado com o motivo e os outros continuam; o ficheiro da coleção e o índice são guardados após cada elemento, por isso um cancelamento ou uma falha não perde o que estava feito. Os PDF vão para junto do ficheiro da coleção ou para `--out`. Com OCR (ativo por omissão; `--no-ocr` desliga-o) o texto reconhecido de cada página vai para `NOME.lgrindex`; o idioma do OCR vem dos idiomas do elemento, senão de `ocr_langs` do perfil, senão o romeno. Um elemento falhado não é repetido, salvo com `--retry-failed` ou `--item ID`.

- `search` procura neste índice. Maiúsculas, diacríticos e a antiga ortografia romena não contam (`Scînteia` encontra `Scânteia`, `sînt` encontra `sunt`). Mostra elemento, página e um excerto: primeiro as páginas com as palavras seguidas, depois (marcadas) as que têm todas as palavras mas afastadas.

- `reindex` (alias `index`) lê a camada de texto dos PDF para o mesmo índice **sem processar nada de novo**: para um elemento cuja fonte é um só PDF que já tem texto (PDF pesquisáveis de outro programa, ou feitos pelo LegatorOCR) e para os elementos processados antes. Lê o PDF feito por `run` se existir, senão a única fonte PDF do elemento; o estado e os ficheiros do elemento não mudam. Uma digitalização sem texto é assinalada (`no text layer`) e não é indexada (processe-a com OCR); um elemento com várias fontes, ou só imagens, não tem PDF para ler. `--item ID` restringe-o. O texto é tomado como o PDF o tem (tipos de letra com tabela ToUnicode, como os escrevem o LegatorOCR, o Tesseract, o ABBYY, o Word …); um PDF cujo texto não se consegue descodificar não dá nada ou dá texto sem sentido.

- `set FICHEIRO ELEMENTO` muda `--title --issue --date --kind --profile --status --tags --notes` (só os dados; um texto vazio limpa o campo; um valor errado não muda nada; `--status todo` faz com que o próximo `run` processe de novo o elemento). `remove FICHEIRO ELEMENTO...` tira elementos da coleção e do índice; os seus PDF e ficheiros de origem não são tocados.

- A janela **Coleções…** (menu Ficheiro, ou Ctrl+K): uma tabela com a letra do tipo, título, número/data, páginas e uma etiqueta de estado (cor e texto), com filtro e ordenação; os detalhes à direita; Adicionar ficheiros, Adicionar pasta, Processar a seleção, Processar tudo o que espera (com progresso e Cancelar), Indexar o texto / Indexar tudo (o `reindex` acima), Abrir PDF, Mostrar pasta; uma caixa de pesquisa em toda a coleção com resultados em que se pode clicar. O duplo clique num resultado abre o PDF nessa página quando o programa PDF predefinido do computador é um que se sabe respeitar o número de página (Linux: Okular, Evince, Zathura, MuPDF, Firefox, Chrome, Chromium, Edge; Windows: SumatraPDF, Adobe Acrobat/Reader, Chrome, Edge, Firefox; apurado perguntando ao sistema que programa abre os PDF); senão o PDF abre normalmente e o número da página é escrito na linha de estado. O processamento a partir da janela usa o Tesseract definido nas definições da janela principal (o perfil de um elemento pode ainda indicar outro). Os seus textos existem nas 8 línguas da janela.

Verificado: testes unitários (adivinhar o nome, incluindo os padrões ano-mês-número, caminhos relativos, ficheiros danificados, pesquisa com diacríticos, um lote que continua após uma falha e

após um pânico, cancelamento, o ficheiro de índice com e sem a sua cache, ficheiros de índice do formato antigo, um índice truncado ou danificado, reindexar um PDF com e sem texto, `set` e `remove`, os comandos de leitor de cada plataforma), testes do programa real e uma execução com Tesseract real em duas páginas sintéticas, também após mover a pasta. **Medido** num índice sintético de 5000 elementos × 20 páginas (100.000 páginas de 350 palavras, ficheiro de texto de 357 MB; compilação release numa máquina partilhada de 2 núcleos, por isso só ordens de grandeza): a abertura demora 62 ms com a cache das listas de palavras (38 MB) e 12 s sem ela (primeira abertura, ou o ficheiro foi alterado por outro programa); 82 MB de memória após abrir (o índice anterior, inteiro em memória: 34 s e cerca de 480 MB); uma pesquisa de uma palavra 40–130 ms, de duas palavras muito frequentes que nunca aparecem juntas 3 s.

Limites: a janela foi escrita e compilada, mas ninguém a viu no ecrã nem clicou nela, por isso os seus novos botões, a linha de estado e a abertura numa página não foram experimentados; os comandos de leitor só têm testes unitários como texto, nunca foram executados com Okular, Acrobat ou os outros; no macOS e com qualquer outro programa PDF a página não é passada, só mostrada na linha de estado; a página de um resultado é a do PDF lido (num elemento processado, o PDF feito por `run`), por isso depois de substituir esse PDF por outro com páginas diferentes execute `reindex`; `reindex` não faz OCR e não consegue ler texto que um PDF não descodifica; o índice é reescrito inteiro a cada gravação (cerca de 2 s para 357 MB), por isso alterar um muito grande é mais lento do que um pequeno; dois programas a escrever os mesmos ficheiros ao mesmo tempo: ganha o último; a regra da ortografia antiga é a de `--ocr-modern-spelling` e pode juntar palavras diferentes (`mână` / `mină`).

5. A linha de comandos: receitas para tarefas frequentes

Sintaxe geral: `legatorocr ENTRADAS... [opções]`. As entradas podem ser imagens (PNG, JPEG, TIFF, BMP), PDF digitalizados ou uma pasta. `legatorocr --help` lista todas as opções; `--list-profiles` mostra os perfis. As opções das receitas são verificadas automaticamente antes de cada edição, pelo que existem de facto; as receitas em si não foram todas experimentadas em material real.

Livro digitalizado → PDF com texto pesquisável

```
legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt
carte.txt -o pages
```

`--pdfa` escreve PDF/A-2b para arquivo, e `--txt` guarda também o texto. `-o pages` é a pasta para as imagens processadas.

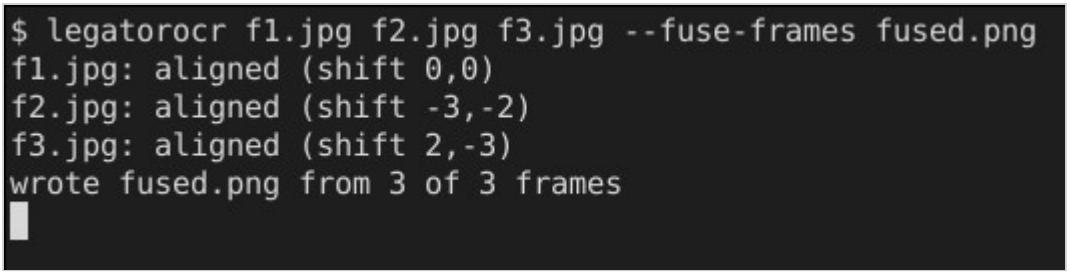
```
$ legatorocr scans/*.png --profile book-bw --ocr --lang ron --pdf carte.pdf --pdfa --txt carte.txt -o pagesT
OCR engine: tesseract 5.3.4, language: ron
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to pagesT
wrote carte.pdf (6 page(s), 27 OCR words)
wrote carte.txt
```

A receita em 4 ficheiros de teste: 6 páginas em carte.pdf. Com --pdfa o programa escreve PDF/A-2b.

Fotografias de telemóvel → páginas limpas

```
legatorocr photos/*.jpg --profile phone-photos --pdf pagini.pdf -o pages
```

O perfil uniformiza a luz, corrige a perspetiva, apaga o fundo à volta da página (`--trim-background`), corta ao meio os livros abertos, alarga o intervalo de inclinação e retira os dedos sem tocar no texto. Uma página que sai sem texto é lida uma segunda vez apenas sobre o seu conteúdo. Para páginas uniformes em A4, com o texto ampliado, use `--profile phone-photos-a4`. Várias fotografias da mesma página podem combinar-se primeiro com `--fuse-frames` (ajuda com ruído forte; com ruído moderado não). A opção recebe um ficheiro de saída: legatorocr foto1.jpg foto2.jpg foto3.jpg --fuse-frames pagina.png, e depois processa pagina.png como de costume; a primeira fotografia é a referência.

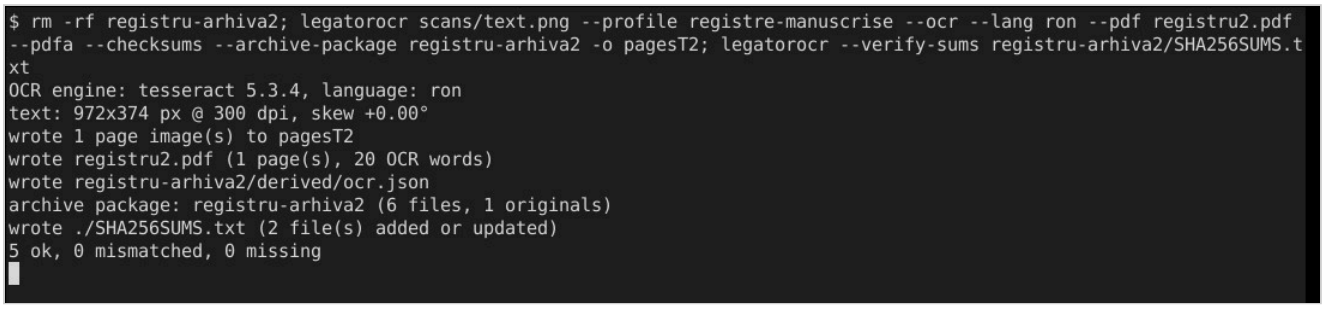


--fuse-frames com três fotografias da mesma página: alinha-as e escreve fused.png a partir de 3 de 3 fotogramas.

Cópia de arquivo com prova de integridade

```
legatorocr scans/*.png --profile registre-manuscrise --ocr --lang ron --pdf registru.pdf --
pdfa --checksums --archive-package registru-arhiva -o pages
legatorocr --verify-sums registru-arhiva/SHA256SUMS.txt
```

O pacote conserva os originais, o projeto, as palavras de OCR com confiança, as saídas e um `RUN.txt` que diz como retomar o trabalho. Para cópias em outros discos: `--backup-from` e `--backup-to`.



O pacote de arquivo criado e verificado: „5 ok, 0 mismatched, 0 missing”.

Ocultar nomes e números antes de partilhar

```
legatorocr scan.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf
```

As palavras encontradas são enegrecidas na imagem e retiradas do texto. **Verifique o resultado a olho:** uma palavra que o OCR não reconheceu não é ocultada.

```
$ legatorocr scans/text.png --ocr --lang ron --redact email,phone-ro --format none --pdf redactat.pdf; pdftotext redacta
t.pdf - | head -4
OCR engine: tesseract 5.3.4, language: ron
text: 972x374 px @ 300 dpi, skew +0.00°
redaction: preset email: 0 covered; preset phone-ro: 1 covered;
warning: preset email matched nothing in 1 page(s). OCR may have misread the value (an "@" is often read as "G" or "(a")
: look at the pages yourself before you hand the files over.
warning: 1 word(s) left in the text still look like personal data (page 1: address-like word). They were NOT covered; ch
eck them by eye.
wrote redactat.pdf (1 page(s), 17 OCR words)
Contact: ion.popescuGexample.com

Telefon:
Bucuresti, 5 noiembrie 2026
```

Resultado real: o número de telefone foi ocultado, mas o endereço de e-mail NÃO, porque o OCR leu „@” como „G” (ion.popescuGexample.com) e o padrão de e-mail não correspondeu. Por isso tem de verificar o resultado a olho. Desde o pre.20 o programa escreve no fim quantas palavras cobriu cada padrão e avisa quando um padrão não encontrou nada ou quando ficaram no texto palavras que parecem endereços ou números longos, exatamente como na captura acima.

Lote grande em vários computadores

```
legatorocr scans/*.png --shard 1/3 --profile book-bw --pdf part1.pdf -o pages1
legatorocr --merge-pdf part1.pdf part2.pdf part3.pdf --pdf carte.pdf
```

Execute a mesma lista em cada máquina, com um `--shard` diferente. Para pouca memória: `--max-memory 500`. Para ficheiros desconhecidos ou hostis: `--isolate-decoders`.

```
$ legatorocr scans/*.png --shard 1/2 --profile book-bw --pdf part1.pdf -o pages1; legatorocr scans/*.png --shard 2/2 --p
rofile book-bw --pdf part2.pdf -o pages2; legatorocr --merge-pdf part1.pdf part2.pdf --pdf carte-m.pdf
shard 1/2: pages 1..2 of 4
a_L: 304x164 px @ 300 dpi, skew +0.00°
a_R: 284x254 px @ 300 dpi, skew +0.00°
p15b: 1162x1232 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages1
wrote part1.pdf (3 page(s))
shard 2/2: pages 3..4 of 4
spread_L: 524x818 px @ 300 dpi, skew +0.00°
spread_R: 674x818 px @ 300 dpi, skew +0.00°
text: 972x374 px @ 300 dpi, skew +0.00°
wrote 3 page image(s) to pages2
wrote part2.pdf (3 page(s))
wrote carte-m.pdf
```

O lote dividido em dois (--shard 1/2 e 2/2) e depois unido com --merge-pdf.

Assinar um PDF

```
LEGATOROCR_P12_PASS=... legatorocr --sign-pdf registru.pdf --sign-p12 certificat.p12 --sign-
name "Nume"
legatorocr --verify-pdf-signatures registru.signed.pdf --sign-ca ca.pem
```

O nível jurídico da assinatura é o do seu certificado. A palavra-passe do certificado dá-se através da variável de ambiente, não na linha de comandos. O carimbo de data/hora (`--sign-timestamp`) foi verificado apenas com uma autoridade local por HTTP, não com uma real por HTTPS.

```
$ LEGATOROCR_P12_PASS=test123 legatorocr --sign-pdf registru.pdf --sign-p12 cert.p12 --sign-name Nume; legatorocr --veri
fy-pdf-signatures registru.signed.pdf --sign-ca ca.pem
wrote registru.signed.pdf
signature 1 [ETSI.CAdES.detached]: data matches, chain verified
  time stamp inside: none
```

Assinatura e verificação com um certificado de teste criado por mim (não um certificado real). „time stamp inside: none”: não pedi carimbo de data/hora.

Pilha digitalizada num alimentador, ordem e intervalo de páginas

Muitos scanners com alimentador passam a pilha uma vez por cada face: primeiro todas as frentes (1, 3, 5…), depois todos os versos, em ordem inversa (6, 4, 2). Os ficheiros saem pela ordem da digitalização, não do livro. `--duplex-adf` põe-nos pela ordem de leitura: frente 1, verso 1, frente 2, verso 2… O número de páginas tem de ser par (caso contrário o programa pára com uma mensagem).

```
$ ls adf; legatorocr adf/*.png --duplex-adf --dry-run
scan_001.png  scan_002.png  scan_003.png  scan_004.png  scan_005.png  scan_006.png
page selection/order: 6 of 6 page(s) used
6 page(s) would be processed, in this order:
    1  adf/scan_001.png
    2  adf/scan_006.png
    3  adf/scan_002.png
    4  adf/scan_005.png
    5  adf/scan_003.png
    6  adf/scan_004.png
would write -> page images in legatorocr-out
(--dry-run: nothing was processed)
```

Seis ficheiros pela ordem da digitalização (scan_001 … scan_006). `--dry-run` mostra a ordem em que seriam processados e que ficheiros se escreveriam, e depois pára sem processar nada: scan_006 vai para o lugar 2, scan_005 para o lugar 4.

```
$ legatorocr adf/*.png --duplex-adf --engine native --ocr --lang ron --pdf carte.pdf --txt carte.txt 2>&1 | tai
$ grep -h Pagina carte.txt | tr -d '\f' | tr '\n' ' '; echo
wrote carte.pdf (6 page(s), 240 OCR words)
wrote carte.txt
Pagina 1 Pagina 2 Pagina 3 Pagina 4 Pagina 5 Pagina 6
```

O mesmo comando sem `--dry-run`, com OCR nativo: o texto sai pela ordem „Página 1 … Página 6” (páginas de teste feitas por mim, não um livro real).

Outras opções de ordem e seleção (podem combinar-se; o intervalo aplica-se à numeração dos ficheiros de entrada, a partir de 1):

- `--pages 1-10,15,20-`: mantém apenas as páginas indicadas; `20-` significa „do 20 até ao fim”. Funciona também em páginas tiradas de PDF ou de folhas TIFF com várias páginas.
- `--reverse`: inverte a ordem (pilha digitalizada a partir da última página).
- `--dry-run`: verifica um lote grande antes da execução longa.

Verificado: a ordem e o intervalo com testes automáticos e com seis páginas de teste; não experimentei um scanner real com alimentador. As opções também se podem escolher na janela, em „Todas as opções…” (secção 4).

Texto limpo: correções próprias, cabeçalhos e cedilha

Para os ficheiros `.txt` e `.docx` (a camada de texto do PDF, o hOCR e o JSON conservam as palavras lidas, inalteradas):

- `--clean-text`: ș e ț com vírgula por baixo, palavras partidas no fim da linha unidas (com hífen mantido quando as duas metades são palavras da lista e a simples junção não é),

aspas tipográficas, espaços junto à pontuação. `--cedilla` escreve em vez disso ş e ţ, para programas e tipos de letra que não conhecem as letras com vírgula.

- `--find-replace FICHEIRO`: as suas próprias correções, uma por linha, `errado => certo`. As linhas que começam por `#` são comentários. Só correspondem palavras inteiras (`Ion => Ioan` não toca em „Ionescu”) e aplicam-se pela ordem do ficheiro, depois de `--clean-text`. Úteis para nomes próprios, abreviaturas ou um carimbo que o motor lê sempre igualmente mal.

- `--drop-running-heads`: deixa de fora os cabeçalhos, rodapés e números de página impressos: a primeira ou a última linha de uma página que se repete (os algarismos não contam) em pelo menos metade das páginas; são precisas pelo menos quatro páginas. As linhas retiradas são listadas em stderr, para ver o que saiu.

```
$ cat reguli.txt
O="--engine native --ocr --lang ron"
legatorocr rev/p01.png $O --txt f0.txt 2>/dev/null
legatorocr rev/p01.png $O --txt f1.txt --find-replace reguli.txt 2>/dev/null
echo "fără regulă:"; grep -h "secretarul\|ha\." f0.txt
echo "cu regulă:"; grep -h "secretarul\|ha\.\|hectare" f1.txt
# corecturi proprii
Ionescu => Ionescu-Vale
ha => hectare
Volumului => Volumul
fără regulă:
în anul 1951 de către secretarul Ionescu.
și suprafața înscrisă în ha. Corecturile se
cu regulă:
în anul 1951 de către secretarul Ionescu-Vale.
și suprafața înscrisă în hectare. Corecturile se
```

O ficheiro de regras (primeiro bloco) e as mesmas duas linhas lidas da página de teste sem e com `--find-replace`: „Ionescu” passou a „Ionescu-Vale” e „ha” passou a „hectare”.

```
$ legatorocr rev/*.png --engine native --ocr --lang ron --clean-text --drop-running-heads --txt rev.txt; head -
OCR engine: LegatorOCR native engine 0.2.0-pre.26, language: ron
p02: 996x904 px @ 300 dpi, skew +0.00°
p01: 992x904 px @ 300 dpi, skew +0.00°
p04: 998x904 px @ 300 dpi, skew +0.00°
p03: 998x904 px @ 300 dpi, skew +0.00°
p05: 998x904 px @ 300 dpi, skew +0.00°
p06: 998x904 px @ 300 dpi, skew +0.00°
wrote 6 page image(s) to legatorocr-out
6 running head/foot/page-number lines left out of the text (e.g. "Anuarul Văii Mari 1", "Anuarul Văii Mari 2",
Văii Mari 3")
wrote rev.txt
Pagina 1
Registrul comunei Valea Mare a fost rescris
în anul 1951 de către secretarul Ionescu.
Fiecare pagină păstrează numele proprietarilor
```

Em seis páginas de teste com o cabeçalho „Anuarul Văii Mari” e um número, o programa retirou seis linhas de cabeçalho; o texto começa diretamente em „Pagina 1”. Atenção: a regra retira qualquer primeira/última linha que se repita, portanto num livro em que a última linha de cada página é parecida (por exemplo „Poziția în raft: 14”) essas linhas também sairiam; por isso são listadas. A função foi verificada com testes e em algumas páginas, não num grande conjunto de livros.

Outras receitas

As receitas completas estão em `docs/tasks/` no repositório, em inglês e romeno (verificação de documento com `--verify-document` e `--mrz`, cópia de arquivo, lote grande).

6. Definições importantes e quando se usam

Perfis

```
$ legatorocr --list-profiles | cut -c1-100
book-bw              Text books: auto threshold, black & white, punch holes removed
book-small-color     Colour books: sharp text over a light background, smallest files
document-text        Office documents: sharp text, pictures kept in colour
photo-archive        Archive quality colour, light sharpening
newspaper            Newsprint: Wolf threshold, stronger speck removal, flattened curl
form-dropout-red     Forms with red rules or stamps: drop red, erase ruled lines
negatives            Negative scans: invert and stretch contrast
doc-birou            Office documents and invoices (scan at 300 dpi): black & white, searchable PDF
schite-desene        Architectural / pencil sketches (scan at 400 dpi): grey, even lighting, light c
registre-manuscrise  Old registers and manuscripts (scan at 300-600 dpi): colour kept faithfully, hi
flux-1-optim         Flux 1 (optim, scan at 300 dpi): sharp 1-bit text, pictures in colour, margins
flux-2-draft         Flux 2 (ciornă / draft): quick grey pass, light compression - for checking and
flux-3-volum         Flux 3 (volum mare / high volume): 1-bit text over a very light background, sma
diploma              Diplomas and certificates (scan at 300-400 dpi): colour seals, stamps and signa
registru-stare-civila Civil-register pages with handwriting and stamps (scan at 400 dpi): colour kep
harta                Maps (scan at 400 dpi or more): colour kept faithfully, no thresholding, no des
partitura            Music scores (scan at 600 dpi): fine 1-bit with a local threshold so thin staff
phone-photos         Pages photographed by phone: level lighting, wider skew range, fingers removed
smokeprof            user profile
```

legatorocr --list-profiles. A última linha (smokeprof) é um perfil de teste meu, não faz parte do programa.

Um perfil é um conjunto de definições já pronto para um tipo de material. Escolhe-se na secção „Perfil” (interface) ou com `--profile NOME` (linha de comandos). Pode ter os seus próprios perfis: configura as definições, escreve um nome e prime „Guardar perfil”.

Perfil	Para quê
`book-bw`	livros com texto, preto e branco, furos de perfuração retirados
`book-small-color`	livros a cores, texto nítido em fundo claro, ficheiros pequenos
`document-text`	documentos de escritório, imagens mantidas a cores
`photo-archive`	fotografias, qualidade de arquivo
`newspaper`	jornais: limiar Wolf, manchas eliminadas com mais força
`form-dropout-red`	formulários com linhas ou carimbos vermelhos
`negatives`	digitalizações de negativos
`phone-photos`	fotografias de telemóvel: perspetiva corrigida, fundo à volta da página apagado, livros abertos cortados ao meio, dedos retirados
`phone-photos-a4`	como `phone-photos`, mas cada página numa folha A4, com o texto ampliado para encher a folha (e as páginas com poucas linhas)
`registre-manuscrise`	registos e manuscritos antigos (300–600 dpi), cores mantidas
`schite-desene`	esboços e desenhos a lápis (400 dpi)
`doc-birou`, `flux-1-optim`, `flux-2-draft`, `flux-3-volum`	fluxos para documentos de escritório, da qualidade máxima ao grande volume
`diploma`, `registru-stare-civila`, `harta`, `partitura`	**não verificados em amostras reais**

A lista completa é dada por `--list-profiles`.

As definições que mais contam

Definição	O que faz	Quando a muda
Resolução (dpi)	com que resolução foram digitalizadas as páginas	quando a imagem não tem dpi no cabeçalho; para texto 300
Corrigir automaticamente / inclinação máxima	o limite do ângulo corrigido automaticamente	quando uma página que sai „no limite” está de facto torta
Margens, tamanho da página, mesmo tamanho	as margens em mm; página livre, personalizada ou idêntica para todo o livro	para livros com formatos misturados
Modo de saída	cor, cinzento, preto e branco, misto (texto de 1 bit + imagens a cores), híbrido (+ fundo de baixa resolução)	preto e branco para texto puro; misto para texto com fotografias
Método de limiar	Sauvola (predefinido), Wolf, Niblack, NICK, Bradley, Otsu ou automático	quando o texto sai desbotado ou cheio de manchas; `auto` experimenta vários em cada página
Sensibilidade	a sensibilidade do método Sauvola para a saída a preto e branco	predefinição 0,3; mude-a em passos pequenos e compare o resultado na mesma página
Sensib. imagens	com que facilidade uma zona é considerada imagem	no modo misto/híbrido
Eliminar manchas pequenas	a força da limpeza de manchas (0,25–4; 1 = predefinição)	diminua-a se desaparecerem pontos ou diacríticos; aumente-a se ficarem manchas
Dewarp (linhas curvas)	endireita as linhas arqueadas junto à lombada	para livros grossos; é ignorado se não se vir uma curvatura clara
Uniformizar a iluminação	iguala o fundo	para fotografias com sombra ou iluminação desigual
Qualidade JPEG	0 = sem perdas; as páginas a preto e branco são sempre sem perdas	para ficheiros mais pequenos (sugestão: experimente 80–90 e compare o tamanho e o aspeto)
DPI de saída	reduz a imagem de saída para este dpi (“—” = não reduzir)	para PDF mais pequenos; as páginas abaixo de 250 dpi são ampliadas automaticamente antes do OCR, pelo que uma redução excessiva não ajuda o reconhecimento
PDF/A-2b	PDF para arquivo, com tipo de letra e perfil de cor incluídos	para entrega em arquivos; não foi verificado com o veraPDF nas saídas do programa

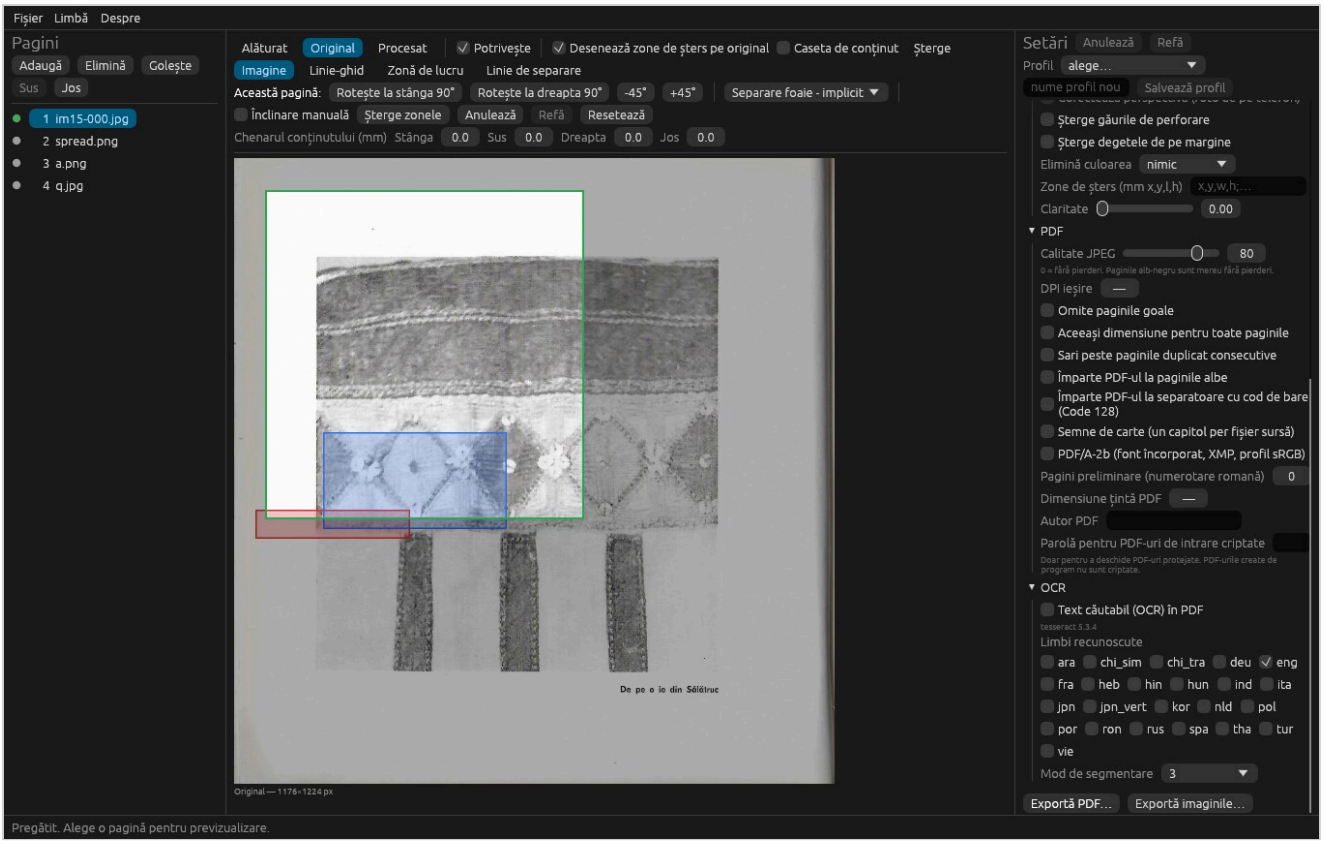
Os formatos dos campos de texto

Estes campos existem nas definições, mas é mais fácil desenhar sobre o original (secção 4):

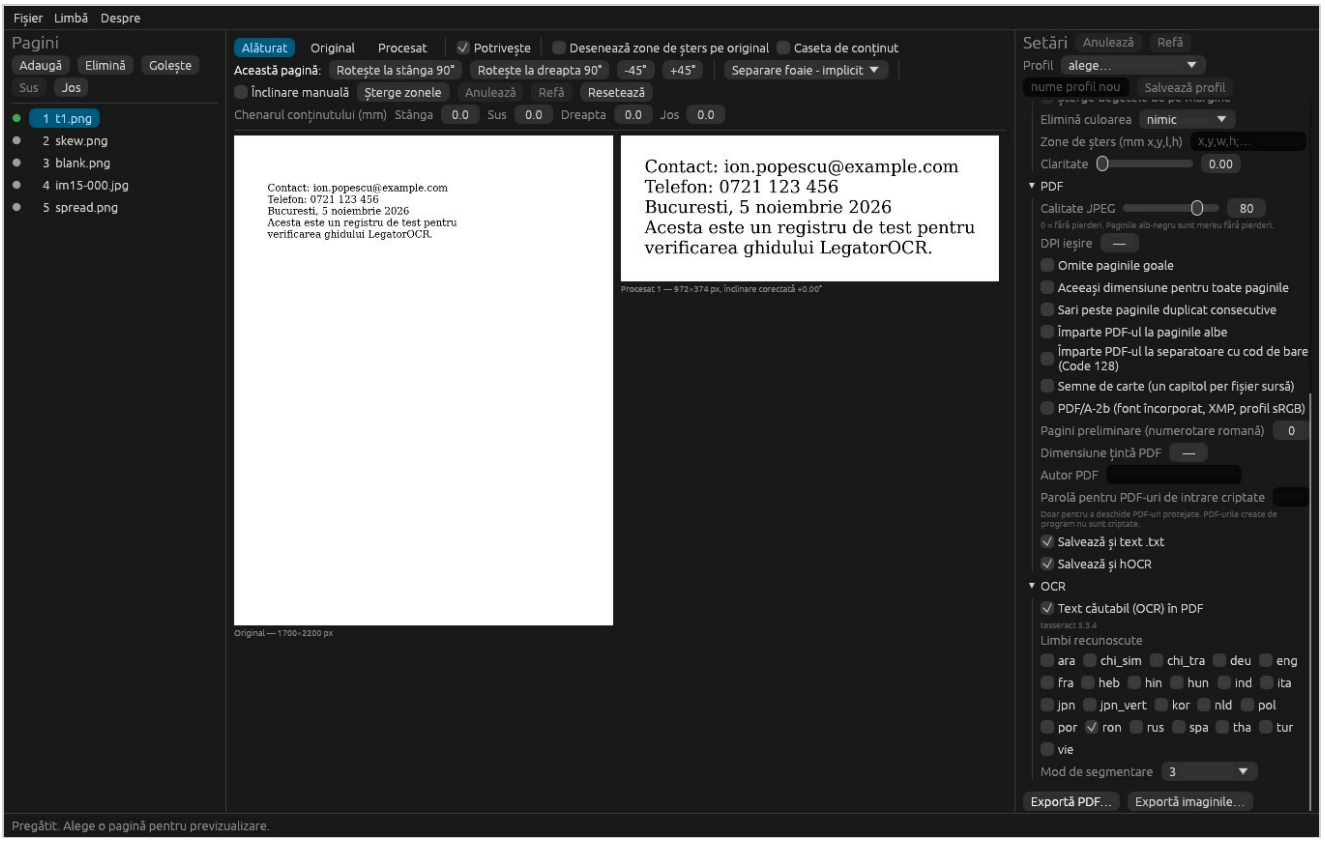
- **Zonas a apagar** e **Zonas de imagem**: `x,y,l,h` em **milímetros** a partir do canto superior esquerdo da página. Várias zonas separam-se com ponto e vírgula: 10,20,30,40;50,60,20,20. No máximo 64; a largura e a altura têm de ser positivas. Se a forma estiver errada, o campo fica vermelho.
- **Linhas-guia de correção**: `x,y x,y x,y;x,y x,y x,y`, com **frações entre 0 e 1** da página já corrigida (0,0 = canto superior esquerdo). Cada linha tem pelo menos dois pontos; no total, no máximo 64 linhas.
- Na linha de comandos: `--erase X,Y,W,H` (repetível) e `--dewarp-guide "X,Y X,Y …"` (repetível).

7. OCR: motores, idiomas e exatidão

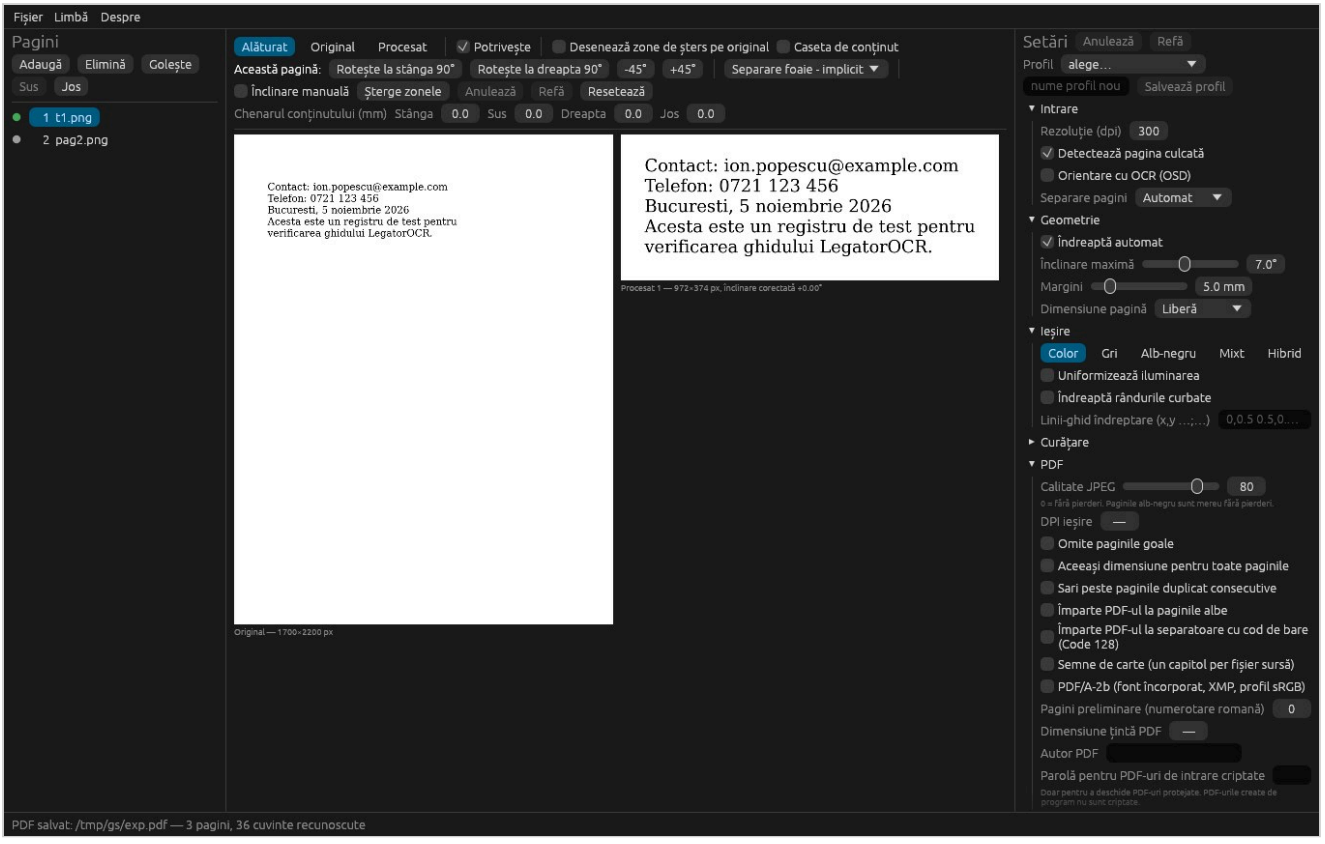
A caixa „Texto pesquisável (OCR) no PDF” (ou `--ocr` na linha de comandos) acrescenta uma camada de texto invisível sobre a imagem. O idioma escolhe-se em „Idiomas reconhecidos” (ou `--lang ron`); pode ser combinado, por exemplo `ron+eng`. Os idiomas da interface e do motor próprio: romeno, inglês, francês, italiano, espanhol, português, alemão, húngaro.



A secção OCR das definições: a caixa „Texto pesquisável (OCR) no PDF”, os idiomas reconhecidos (os instalados no Tesseract) e o modo de segmentação. Na captura estava instalado o Tesseract 5.3.4, por isso aparecem todos os seus idiomas; a escolha ron usei-a na figura seguinte.



Com o OCR marcado aparecem também „Guardar também texto .txt” e „Guardar também hOCR”. Aqui o idioma escolhido é ron.



Depois da exportação, a barra inferior mostra: „PDF guardado: … — 3 páginas, 36 palavras reconhecidas”. (A exportação foi iniciada com um mecanismo de teste do programa, não a partir do diálogo de ficheiros.)

Três motores

Motor	Como o escolhe	Notas
Nativo (do programa)	`--engine native`	sem instalação, escrito em Rust; modelo treinado em texto sintético e depois ajustado em linhas de uma revista romena e de um manual de 1960
Tesseract	`--engine tesseract`	programa separado, veja a secção 2; usado automaticamente quando está instalado e tem o idioma pedido (`--engine auto`, predefinição)
Ponte ONNX	`--engine tesseract --tesseract scripts/engine-onnx.py`	para utilizadores avançados; requer Python, onnxruntime e modelos descarregados à parte



A mesma página de teste lida pelos dois motores. Ambos erraram da mesma maneira: „@” saiu „(a” no motor nativo e „G” no Tesseract.

Os números medidos (e o que não dizem)

Mediram-se 8 páginas boas de uma revista romena, face a um texto de referência produzido pelo ABBYY, não corrigido por uma pessoa. A taxa de erros por carácter, com diacríticos (a medição original, da edição 0.2.0-pre.21; numa nova medição no pre.26 nas mesmas 8 páginas, com o mesmo método, o motor nativo deu 2,76 %; a diferença face a 2,55 % não a investiguei):

Motor	Erros por carácter
Nativo	2,55 %
Tesseract (`ron`)	4,32 %
OCRmyPDF (com Tesseract)	4,62 %

Lido de forma simples: o motor nativo erra menos **neste tipo de impressão**. Mas foi ajustado em texto das mesmas fontes, pelo que não se pode dizer que seja melhor em geral. Noutros documentos, sobretudo impressão antiga ou invulgar, pode ser mais fraco do que o Tesseract. O reconhecimento de palavras inteiras é quase igual entre os motores (aproximadamente 92 %).

O modo rigoroso e a ortografia antiga

- `--accurate` (motor nativo): cada linha é lida três vezes (deslocada um píxel para cima e para baixo) e as probabilidades são tiradas em média. É mais lento (medido: entre 18 % e 74 % mais tempo) e ajudou apenas nas páginas de revista (erro por carácter 3,66 % → 3,39 % em 12 páginas); em livros e brochuras não mudou nada de mensurável. Está desligado por omissão.

- A lista de palavras romenas aceita também a ortografia de 1953–1993 (`cuvînt`, `romîn`, `sînt`): em cinco páginas de um manual de 1960, transcritas à mão, os caracteres corretos subiram de 99,6 % para 99,7 % e as palavras de 96,0 % para 96,3 %. Uma diferença pequena, em cinco páginas.
- As palavras são separadas nos espaços largos mesmo quando a rede não escreveu espaço: as células de uma tabela já não saem coladas (`CantitatePreț`). Uma tabela com linhas é encontrada como uma única tabela (Excel: `--tables-xlsx`); uma tabela sem linhas ainda é encontrada como duas tabelas (esquerda e direita), problema por resolver.

Conselhos

- Nos seus documentos, compare os motores em 5–10 páginas antes do lote: `scripts/compare-ocr-text.py` mede os erros face a textos de referência que você tenha.
- As páginas abaixo de 250 dpi são ampliadas automaticamente antes do reconhecimento.
- As páginas com ilustrações ou diagramas podem produzir texto sem sentido na zona da imagem (o Tesseract leu uma ilustração como texto numa das páginas medidas). Verifique essas zonas.
- Qualquer OCR pode inventar ou perder palavras. Para atos, registos ou números, verifique por amostragem.

8. Saídas e arquivo

O que quer	Como
PDF com texto pesquisável	`--pdf FICHEIRO.pdf --ocr` (interface: Exportar PDF com OCR marcado)
PDF para arquivo (PDF/A-2b)	`--pdfa`; outras partes com `--pdfa-part 1` ou `3`
Imagens processadas	`-o PASTA`, com `--format png`, `jpeg` ou `tiff`; `--format none` não escreve imagens
Texto simples das páginas	`--txt FICHEIRO.txt`
hOCR	a caixa „Guardar também hOCR”
Estrutura para acessibilidade	`--tagged ro` (parágrafos etiquetados). A conformidade PDF/UA **não** foi validada
Cópia DjVu	`--djvu FICHEIRO.djvu`
Prova de integridade	`--checksums` e `--archive-package DIR`, depois `--verify-sums`
Projeto (definições e correções)	Ficheiro → Guardar o projeto (`.lgr`), ou `--save-project`; `--embed-project` esconde-o no PDF

Sobre o PDF/A

O programa escreve PDF/A-2b com tipo de letra e perfil sRGB incorporados. A conformidade foi verificada em amostras, **não** com o veraPDF em qualquer saída. Se uma instituição exigir conformidade certificada, execute o seu próprio validador nos ficheiros finais.

Sobre os projetos ScanTailor

`--project FICHEIRO.ScanTailor` abre um projeto ScanTailor: a lista de digitalizações e a rotação por imagem são aproveitadas, e a inclinação, a separação e a caixa de conteúdo são encontradas de

novo. O leitor foi escrito a partir da descrição do formato e testado num projeto feito à mão, não em ficheiros de qualquer versão do ScanTailor.

```
$ legatorocr scans/text.png --pdf sp.pdf --save-project pr.lgr --format none --work-area 5,5,80,60 --cut-at 0.5; grep -n
 'work_area\|cut_at' pr.lgr; legatorocr --project pr.lgr --pdf sp2.pdf --format none
project saved: pr.lgr
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp.pdf (2 page(s))
31:work_area = 5,5,80,60
32:cut_at = 0.5
text_L: 820x374 px @ 300 dpi, skew +0.00°
text_R: 270x354 px @ 300 dpi, skew +0.00°
wrote sp2.pdf (2 page(s))
```

--save-project e --project: o projeto guarda-se e reabre-se com o mesmo resultado (2 páginas). Atenção: no pre.18, --work-area e --cut-at não se conservavam no projeto; corrigido no pre.19 (verificado: o projeto guardado e reaberto dá as mesmas páginas).

9. Problemas frequentes e limites conhecidos

Sintoma	O que verificar
A página sai cortada ou com demasiado branco	a caixa de conteúdo (secção 4); a moldura em mm na barra „Esta página”
Uma página inclinada continua inclinada	a inclinação máxima permitida; defina o ângulo manualmente
A folha de dupla página não se corta onde devia	o modo de separação da página: „ao meio” ou „desligada”; desde o pre.18 pode arrastar uma „Linha de separação” sobre o original ou usar `--cut-at 0.45`
Um campo de texto fica vermelho	o formato do campo (secção 6): milímetros para zonas, frações 0–1 para guias
O texto do OCR tem erros	compare os motores (secção 7); verifique a resolução; passe para o Tesseract ou vice-versa
O painel „A verificar”	páginas marcadas como suspeitas (em branco, inclinação no limite, nada encontrado, conteúdo colado à margem); não estão necessariamente erradas, mas merecem ser vistas
A janela não funciona no Windows ou em RDP	falta de OpenGL 2+; experimente o controlador da placa gráfica
A aplicação macOS não arranca	não está assinada: clique direito → Open ou o comando `xattr` da secção 2

Limites conhecidos da edição 0.2.0-pre.61

- Trapézio auto: verificado em folhas sintéticas e em 67 fotografias de telemóvel de um único livro (133 páginas), onde deixou intactas a maior parte das páginas e reduziu a inclinação medida nas restantes; ninguém avaliou o resultado a olho noutros livros, nem em páginas com imagens grandes, tabelas ou linhas muito curtas, onde pode não fazer nada ou fazer muito pouco. As definições por página e a inclinação da linha de corte foram experimentadas em folhas sintéticas e em testes; o lápis de tabela faz o OCR ler a zona como um bloco, não encontra células.
- A rotação de 90°: numa página com uma fotografia de ornamentos (a página 15 de um PDF) um testador em Windows viu a rotação saltar de 90° para 180°. Reproduzi em Linux uma parte do problema: no pre.18, com „Detetar a página deitada” marcado (predefinição), o programa rodava erradamente 90° esta página, embora o original esteja direito (a figura da secção 4). O limiar do pre.19 era demasiado frágil (descobri entretanto que outra página

do mesmo PDF, a página 13, também era rodada erradamente). No pre.20 o detetor conta apenas peças do tamanho de uma letra e abstém-se nas páginas com fotografias ou com poucas palavras. Em 98 páginas de livro (rodadas a 0° e 90°) e 5 páginas com fotografias, o resultado é idêntico ao do pre.18, exceto a página 13 (rodada erradamente no pre.18, agora direita) e uma página com uma fotografia deitada, que o detetor já não vira (ficam o OSD e a rotação manual). Verificado na linha de comandos, em Linux, num corpus pequeno. A causa provável do salto (a orientação automática somava-se à rotação manual) foi corrigida no pre.18: depois de um clique na rotação a página fica bloqueada, e quatro cliques dão 90°, 180°, 270° e de volta a 0° (verificado na janela, em Linux). O que o testador viu exatamente no Windows 11 não pude verificar. Se uma página com fotografias continuar a ser rodada erradamente, desmarque „Detetar a página deitada” ou use --no-auto-orient.

- A área de trabalho, a linha de separação móvel, as zonas a apagar e de imagem, a grelha de pontos, Anular e Ctrl+Z, a caixa de conteúdo, o OCR e a exportação PDF foram experimentados numa janela real em Linux, com rato simulado (as capturas do guia). O redimensionamento de uma zona pelo canto funcionou na janela. Os diálogos nativos de ficheiros („Exportar PDF…”, „Guardar projeto”, „Abrir projeto”) funcionaram com o diálogo GTK de um portal xdg em Linux; em Windows e macOS não os experimentei. Se o sistema não tiver nenhum diálogo, desde o pre.21 a janela diz isso em vez de não fazer nada (pode arrastar os ficheiros para a janela ou usar a linha de comandos). Guardar um perfil próprio funcionou. O efeito da linha de separação verifiquei-o por testes automáticos, com --cut-at e na janela (uma folha dupla cortada em duas páginas desiguais, 524 e 674 px). Nas folhas rodadas 90° ou 270° (desde o pre.21) as páginas saem uma por baixo da outra; isto está verificado apenas por um teste automático, não na janela.

  --save-project: na compilação publicada pre.18, --work-area e --cut-at dados na linha de comandos não se conservavam no ficheiro .lgr (encontrado na verificação deste guia). Corrigido no pre.19. Se usa o pre.18, volte a dar as opções em --project, não apenas a partir do projeto.

- A interface gráfica não foi verificada por pessoas em Windows, macOS ou arm64.
- A verificação PDF/UA, a fatura eletrónica CIUS-RO e o carimbo de data/hora por HTTPS com uma autoridade real não foram validados.
- Para uma cópia PDF/A certificada, o validador é seu (por exemplo o veraPDF).
- O direito de utilização do modelo de OCR próprio (treinado parcialmente em páginas com direitos por esclarecer) é uma questão em aberto para o autor; veja `docs/audit/assets-licences.md`.
- Deteção automática de páginas de cabeça para baixo: só escrita latina, pelo menos 12 linhas por página; uma página com tabelas ou pouco texto pode ficar intacta (use «180°»). A janela de coleções e as miniaturas grandes têm testes automáticos, mas o autor não as viu no ecrã.

10. Como comunicar um problema

A contribuição mais útil é um relatório de um sistema que o autor não experimentou. Demora cinco minutos:

1. Descarregue a última edição para o seu sistema.
2. Execute `legatorocr --doctor` e copie todo o resultado.
3. Processe uma página que possa partilhar: `legatorocr PAGINA.jpg --ocr --pdf rezultat.pdf -o pagini`.
4. Abra `rezultat.pdf`: a página está direita e recortada como deve? O texto seleciona-se e pesquisa-se?

Envie, como problema (issue) no repositório `chiuta/LegatorOCR` (ou por e-mail):

- o sistema e a versão (por exemplo Windows 11 23H2, macOS 15 arm64, Debian 12 arm64);
- a versão do LegatorOCR;
- o resultado do comando `--doctor`;
- o comando executado (ou a definição da interface);
- o que esperava e o que aconteceu (texto de erro ou captura de ecrã);
- se a imagem pode ser partilhada.

Não envie documentos com dados pessoais. Um relatório „correu tudo bem” é igualmente útil: é a única forma de o autor saber que um sistema funciona.

Os problemas de segurança comunicam-se segundo o `SECURITY.md`, não publicamente.